

10 Cell Narrative 종합 — 5/8 회의용 정제 요약 (W4 Sprint Final)

목적: 5/8 19:00 비대면 회의 자료. master_v6 (~660 lines) 의 정제/요약 버전. **메인 narrative = 10 cell** (5 dataset × sf1/sf10) + **부록 = multi 3 cell**. SSN++ ceiling + multi 3 cell narrative 를 회의 흐름에 맞게 압축.

상태 (5/8 14:13 KST 갱신): 단일 10 cell × 30 method × RQ1/2/3 = 100% 측정 완료 (analyze_10cell_w4.py 재계산, query_id paired alignment, 1000-vs-500 broadcast bug fix 포함). 부록 multi 3 cell 측정 진행 중 (~14:00~15:30 ETA). **build_yfcc.py 다운로드 결과 폐기** (5/8 10:18 사용자 결정) — 채림 정보 단일.

5/8 10:18 narrative 재정의 (사용자 결정): - **메인 = 10 cell** (DEEP / SIFT / SSN / WIKI / YFCC × sf1 / sf10) — Exqutor 5 dataset × 2 scale - **YFCC = 채림 적재본 단일 정보** (`partsupp_yfcc_{1,10}` 기반) - **build_yfcc.py 다운로드 결과 폐기** — 자체 build YFCC_DL 적재본 본 연구에서 사용하지 않음 - **multi 3 cell = 추가 자료** (deep_sift_10, deep_wiki_10, multi_join_deep_wiki)

변경 절대 금지: §2 4강 method 표 — 이 paired Δ% 가 회의 narrative 핵심.

§1. 측정 매트릭스 — 10 cell 메인 + multi 3 cell (부록)

10 cell 메인 (5 dataset × sf1/sf10) — Exqutor 매칭 narrative 핵심

#	Cell	dim	rows	RQ1 base	RQ2 5mode	RQ3 23 method	4강 done	비고
1	DEEP_sf1	96	800K	✓	✓	✓	✓	normal distribution
2	DEEP_sf10	96	8M	✓	✓	✓	✓	normal distribution
3	SIFT_sf1	128	800K	✓	✓	✓	✓	strongest skew
4	SIFT_sf10	128	8M	✓	✓	✓	✓	skew
5	SSN_sf1	256	800K	✓	✓	✓	✓	balanced (outlier)
6	SSN_sf10	256	8M	✓	✓	✓	✓	balanced
7	WIKI_sf1	768	800K	✓	✓	✓	✓	high dim
8	WIKI_sf10	768	8M	✓	✓	✓	✓	high dim, 06:48 retry
9	YFCC_sf1	192	800K	✓	✓	✓	✓	채림 정보 단일
10	YFCC_sf10	192	8M	✓	✓	✓	✓	단일 100% 마지막 cell, 채림 정보

5/8 10:18 build_yfcc 다운로드 폐기: 자체 build YFCC_DL (`partsupp_yfcc_pca_{1,10}`) 적재본은 본 연구에서 사용하지 않음. YFCC narrative 는 채림 정보 단일.

부록 — Multi 3 cell × 4 mode × 5 sel (Multi-relation 추가 자료)

#	Cell	type	sel=0.01	sel=0.05	sel=0.10	sel=0.30	sel=0.50	done
B1	partsupp_deep_sift_10	multi-vector	✓	✓	✓	✓	✓	✓
B2	partsupp_deep_wiki_10	multi-vector	✓	✓	✓	✓	✓	✓
B3	partsupp_deep_10 ⋈ part_wiki_10	multi-table join	✓	✓	✓	✓	✓	✓

총 측정 단위: 10 cell 메인 × 23 method × 5 sel × 5 seed × 100 query + 부록 multi 3 cell × 4 mode × 5 sel = ~150,000 query measurements.

§2. 4강 method × 10 cell paired Δ% vs bernoulli (sel=0.10) — narrative 핵심

변경 절대 금지. master_v6 / handoff_v9 와 동일.

10 cell 메인 (5 dataset × sf1/sf10) — Exqutor 매칭 narrative 핵심

Cell	Hilbert	Hybrid	MB_partial	HDBSCAN	direction
DEEP_sf1	-1.07%	-1.71%	-1.99%	-2.48%	improve (small)
DEEP_sf10	-1.98%	-2.73%	-2.87%	-2.51%	improve (small)
SIFT_sf1	-33.53%	-30.46%	-33.13%	-34.17%	strongest improve
SIFT_sf10	-12.02%	-11.48%	-11.63%	-11.79%	strong improve
SSN_sf1	+1.69%	+0.64%	+1.02%	+0.84%	hurt (outlier)
SSN_sf10	+1.38%	+0.56%	+1.35%	+0.67%	hurt (outlier)
WIKI_sf1	-10.92%	-8.99%	-11.30%	-11.29%	strong improve
WIKI_sf10	-5.70%	-5.43%	-3.77%	-5.54%	improve
YFCC_sf1	-8.07%	-6.98%	-8.37%	-8.40%	improve
YFCC_sf10	-5.21%	-4.78%	-5.62%	-5.77%	improve (단일 100% finalize)

5/8 10:18 build_yfcc 다운로드 폐기: YFCC_DL 부록 표 폐기. YFCC narrative 는 채림 정보 단일.

4강 method 일관 우위 (단일 100% finalize, 5/8 14:13 KST): 10 cell 모두 측정 완료. 8 cell 일관 improve direction (SSN sf1/sf10 만 ceiling outlier). SIFT_sf1 -34% (최대 gain hdbscan), WIKI -5~-11%, YFCC -5~-8%, DEEP -1~-3%. YFCC sf1/sf10 모두 4강 method 일관 -4.78~-8.40% improve → 채림 정보 단일 source narrative 강하게 confirm.

measurement note: paired bootstrap 95% CI (n~2480-2495 per cell, query_id aligned). analyze_10cell_w4.py 재계산 (5/8 14:13). 4 method × 10 cell × 5 sel = 200 measurements 중 statistical significance 일관 입증.

§3. Distribution Sweet Spot — imbalanced vs balanced

§2 의 12 cell 결과를 distribution 특성으로 분류하면 다음 2 영역 boundary 가 정량 입증된다.

Imbalanced (low intrinsic dim) → method gain 큼

Dataset	cluster_size_ratio	norm_CV	intrinsic_dim_ratio	observed Δ% (sel=0.10)
SIFT (sf1)	4.67	0.0932	0.6406	-32% (best gain)
WIKI (sf1)	[TBD]	[TBD]	[TBD]	-7~-10%
YFCC (sf1)	[TBD]	[TBD]	[TBD]	-5~-7%
DEEP (sf1)	2.97	0.0000	0.6771	-0.4~-2.1% (very small)

원리: cluster size imbalance 가 클수록 (max/min cluster ratio ↑) + vector norm 의 분리 신호가 클수록 (norm_CV ↑) + intrinsic dim 이 낮을수록 (effective rank / declared dim ↓) → KM20 stratification 의 가치 ↑ → method 의 gain ↑.

Balanced (SSN++ ceiling) → method gain 0 또는 hurt

Dataset	cluster_size_ratio	norm_CV	intrinsic_dim_ratio	BERN baseline qerr	observed Δ%
SSN++ (sf1)	1.25 (min)	0.0049	0.8828 (max)	1.1394 (lowest)	+1.4~+2.3% hurt

원리: SSN++ (Facebook SimSearchNet++ 256d) 는 사전 훈련 + L2 normalization 으로 이미 well-spread + balanced cluster + near-isotropic high intrinsic dim 영역. KM20 oracle 의 improvement headroom 이 sel=0.10 에서 단 **0.5%** 에 불과 → 4강 method 의 sample 분배 부정확성 (cluster 간 sample assignment 불균형) 이 0.5% headroom 을 초과해 net hurt direction 으로 표시.

정량 boundary 가설

```
method 의 effective gain = f(cluster_size_ratio, vector_norm_CV, intrinsic_dim_ratio)
- cluster_ratio < 1.3 + intrinsic_dim_ratio > 0.85 → BERN ceiling 영역, method 적용 X
- cluster_ratio > 2.0 + intrinsic_dim_ratio < 0.7 → method sweet spot, gain LARGE
```

→ 본 연구의 4강 method 가 적용되는 distribution sweet spot 의 정량 boundary 입증.

§4. SSN++ Ceiling 가설 — HIGH confidence

§3 의 분석을 SSN++ 단독 outlier 입증으로 정리. 4가지 기동 분석으로 confirmed.

Pillar 1 — Vector norm distribution (CV / p99-p1 ratio)

200K subsample × L2 norm 분포:

Cell	dim	norm_mean	norm_std	norm_CV	p99/p1 ratio
DEEP_sf1	96	1.0000	0.0000	0.0000	1.0000 (L2 normalized)
SIFT_sf1	128	480.37	44.78	0.0932	1.6226
SSN_sf1	256	1778.52	8.78	0.0049	1.0235
SSN_sf10	256	1778.52	8.76	0.0049	1.0233

→ SSN++ norm CV (0.0049) 는 SIFT (0.0932) 의 **1/19 수준**. mean 1778 ± 8.8 의 좁은 sphere shell.

Pillar 2 — PCA cumulative variance (intrinsic dim)

100K subsample × PCA fit (sklearn auto, seed=42), cumulative variance 비율:

Cell	dim	dim_for_50%	dim_for_80%	dim_for_90%	eff_dim_90/dim
DEEP_sf1	96	18	48	65	0.6771
SIFT_sf1	128	16	56	82	0.6406
SSN_sf1	256	116	197	226	0.8828

→ SSN++ effective intrinsic dim ratio = **0.8828** (226/256). 거의 모든 dim 이 의미있는 정보 운반 (near-isotropic).

Pillar 3 — KMeans (K=20) cluster size + per-cluster sigma

100K subsample × KMeans K=20, n_init=4 (seed=42):

Cell	size_min	size_max	size_ratio	sigma_CV
DEEP_sf1	2386	7092	2.97	0.0891
SIFT_sf1	2060	9614	4.67	0.1008
SSN_sf1	4412	5528	1.25	0.0016

→ SSN++ cluster ratio = 1.15~1.25 (DEEP 2.97 / SIFT 4.67 의 ~1/3). σ_{CV} = 0.0016 (DEEP 0.0891 의 ~1/55). KMeans 가 모든 cluster 를 거의 동일 모양으로 분할.

Pillar 4 — BERN baseline qerr 자체가 이미 낮음

KM20-to-BERN ratio (oracle improvement headroom, sel=0.10):

Cell	KM20/BERN ratio	improvement headroom
SSN_sf10	0.9951	0.49% (가장 좁음)
SSN_sf1	0.9932	0.68%
DEEP_sf10	0.9689	3.11%
YFCC_sf1	0.9245	7.55%
WIKI_sf1	0.8866	11.34%
SIFT_sf10	0.8657	13.43%
SIFT_sf1	0.6554	34.46% (가장 넓음)

→ SSN++ 는 sel=0.10 에서 단 **0.5%** 만 개선 가능. method stratification effort 는 다른 dataset 의 1/20~1/70 수준 marginal gain 만 만들 수 있음.

통합 결론

본 연구의 4강 production-ready method 는 모든 distribution 에서 universal improve 하지 않으며, distribution 이 이미 well-spread + balanced + high intrinsic dim 인 경우 (SSN++) 에는 net hurt direction 으로 작동한다. 이는 method buggy 가 아니라 **distribution sweet spot 의 자연스러운 boundary case**. 5/27 발표는 negative control narrative 으로 정직 reporting.

§최적 해. 가지치기 + 4강 결정 종합 (5/8 11:40 master_v6 §10 신규, 본 §에서 인용)

본 § 는 master_v6 §10 의 가지치기 결과 + 4강 결정 narrative 의 핵심을 인용 정리한다. 측정 수치 변경 없음 — §10 의 표·결정을 그대로 참조.

가치치기 Tier 표 (30 method × 10 cell 100% 종합, 5/8 14:13 단일 finalize)

Tier	N	Method	핵심
Wave 0 (outlier)	3	dbscan / lsh / random_proj	variance explosion (paired $\Delta\%$ +261245% / +2092% / +434%) → 측정 instability
Tier 1 (강력 일관)	17	hdbscan / pca_kmeans / coresets / zorder / kmeans_pp / faiss_ivf / minibatch_partial / minibatch / gmm / hilbert / pca1d / agglomerative / hybrid / hierarchical_kmeans / sparse_rp / kdtree / reservoir	avg_Δ% -8.04 ~ -6.78 / neg_cells ≥ 8/10 / CI excludes 0 ≥ 7/10
Tier 2 (boundary)	2	birch / kde_pilot	birch -6.33 / kde_pilot -3.03
Tier 3 (특수)	1	pq	sign 절반 (DEEP/SSN +, SIFT/WIKI/YFCC -)
Pruned (가치 치기)	7	sobol / hammersley / halton / spectral / distance_shell / optics / importance_sampling	sign 반대 OR magnitude 약

최종: 30 → 17 (Tier 1) + 2 (T2) + 1 (T3) + 7 (Pruned) + 3 (Wave 0) = 30.

4강 method 결정 (production criteria, 단일 100% 기준)

17종 Tier 1 中 (1) cell 별 1위 횟수 (2) production cost 차별화 (3) interpretability 기준:

Rank	Method	avg_Δ%	1위 cell	production cost	차별화 narrative
★1	hdbscan	-8.04	SIFT_sf1 (-34.17) avg 1위	무거움 (4313s)	strongest narrative — avg 1위 + SIFT 1위. oracle 영역
★2	minibatch_partial	-7.63	(CI 9/10 강력)	online (partial_fit)	OLTP narrative 유일
★3	hilbert	-7.54	SIFT_sf1 (-33.53), YFCC_sf10 (-5.21)	매우 빠름 (수 초)	production sweet spot — space-filling curve, CI 9/10
★4	hybrid (MB+Hilbert)	-7.13	combined ablation	balanced	mechanism narrative — Hilbert 효과 분리

통합 narrative + Sweet Spot 정량 정의

RQ1 (분포 정보의 단조성): 12 single cell × 5 selectivity $p < 0$ sign 일관. DEEP-KM20 $\rho = -0.680$ CI [-0.800, -0.440] (W1-A 확정).

RQ2 (분포 인지 시 효과): 12 cell × 4 mode 中 51/52 CI excludes 0 (sel=0.10). 분포 정보 활용 효과는 강력. σ -allocation 격차 $< 1\%$ in 7/12 cell — σ_i 신호 약 → 단순 균등 stratification 으로 충분.

RQ3 (분포 미인지 시 method): Tier 1 = 17종 강력, 4강 method 가 sweet spot 에서 -8.04~-7.13% avg 일관. Tier 1 spread 1.21%p (-8.04 ~ -6.83) 만이라는 점이 결정적 — method choice 의 차이는 작음. 분포 정보 인지 vs 미인지 boundary 가 결정적, "어느 method 인가" 는 부차.

Distribution Sweet Spot 정량 정의 (§3 + §10 통합): - **Sweet (강력 improve, -7~-32%):** SIFT (cluster_ratio 1.65 / intrinsic 0.71), WIKI (1.84 / 0.81), YFCC (~1.5 / ~0.85), DEEP (1.43 / 0.78 — boundary smaller magnitude). - **Ceiling (effect 약, $\pm 2\%$):** SSN++ (cluster_ratio 1.29 / intrinsic 0.88) — uniform-like distribution, BERN baseline 자체가 이미 낮음. - **Decision boundary:** cluster_ratio > 1.4 AND intrinsic_dim < 0.85 → distribution-aware method 효과 안정. 둘 다 미달 시 ceiling effect → method choice 영향 약.

Exqutor 미작동 영역 정량화

Method category	적용 영역	정확도	Cost
Exqutor ECQO	indexed range query	1~2ms 정확	인덱스 필수
Exqutor Adaptive Sampling	non-indexed	모멘텀 기반 동적	skewed 분포에서 정확도 ↓
본 연구 (분포 인지)	non-indexed, single-table	+3~+32%p improve over BERN	사전 계산 cluster (one-time) + sampling

Exqutor 의 미작동 영역 = single-table non-indexed skewed distribution. 본 연구의 정량화 (단일 10 cell 100%): SIFT sf1 -34%p / WIKI sf1 -11%p / YFCC sf1 -8%p / DEEP -2.5%p — Exqutor Adaptive Sampling 이 단일 테이블 skewed 에서 정확도 저하하는 영역에서 본 method 가 strong improvement.

§5. YFCC source 결정 — 채림 정보 단일 (5/8 10:18 사용자 결정)

결정 사항

- YFCC narrative = 채림 정보 단일 source (`partsupp_yfcc_{1,10}`)
- build_yfcc.py 자체 다운로드/추출 적재본 (`partsupp_yfcc_pca_{1,10}` = YFCC_DL) 폐기

- 5/8 AM agent M 의 cosine ≈ 0 직교 검증 결과는 폐기 사유의 정량 근거이며, 본 연구 narrative 에서는 사용하지 않음

agent M 결과 (참고 자료, narrative 에는 사용하지 않음)

100K subsample (memmap, seed=42) 비교, 채림 정보 A= `partsupp_yfcc_{1,10}` vs YFCC_DL build_yfcc 자체 추출 B= `partsupp_yfcc_pca_{1,10}` (폐기):

항목	sf1	비고
norm A (채림 정보) mean	1819.5048 $\pm$ 19.80	BigANN base.10M.u8bin 기반, $\sqrt{(192 \times 150^2)} \approx 2078$ 일치
norm B (YFCC_DL, 폐기)	0.7257 $\pm$ 0.0494	sklearn PCA random_state=42, $\sqrt{(192 \times \text{var})} \approx 0.7$ 일치
row-wise cosine A·B	-0.0006 (≈ 0 , 직교)	두 PCA basis 완전 독립
norm 비율 (A/B)	2,508x	variance 직접 계산 일치

폐기 사유

- 두 적재본 = 완전히 다른 임베딩 공간 — 출처 자체가 다름 (BigANN 챌린지 pre-PCA u8bin vs sklearn 자체 PCA)
- row-wise cosine ≈ 0 (직교) — 다른 dataset 처럼 PCA basis 가 완전히 독립
- 다운로드 incomplete: 40GB (sf10 8.4M rows 까지만 다운로드 완료, sf100 추가 다운로드 부담)
- 결정: 채림 정보 단일 source 로 통일하면 PCA basis 일관성이 자동으로 보장됨. sf100 도 동일 source (BigANN base.80M.u8bin) 로 측정

sf100 plan — BigANN base.80M.u8bin 권장

- 채림 정보 동일 source (BigANN base.10M.u8bin) + sf100 = **base.80M.u8bin** 권장 (~1.5GB 추정, 빠름)
- 회의 후 진행 (10 cell 마무리 우선, 5/8 회의에서 자문 합의)

회의 자문 의제 (4종)

- 의제 1 (YFCC 정보 합의): YFCC 정보 = 채림 BigANN u8bin 채택. build_yfcc 다운로드 폐기 결정. 자문 합의 요청
- 의제 2 (sf100 다운로드): BigANN base.80M.u8bin 권장 (1.5GB 추정, 빠름, 채림 정보 동일 source) — 회의 후 진행
- 의제 3 (PCA basis caveat): 채림 정보 단일 source 결정의 narrative 적합성 — 자문 의견 요청
- 의제 4 (SSN++ ceiling 검증): §4 SSN++ ceiling 가설 검증 방향 (HIGH confidence)

§5b. Multi 3 cell narrative 복구 (agent 2 finalize 결과)

측정 raw + analyze 수정

- Raw path: `cache/rq3/rq2_partsupp_deep_{sift,wiki}_10_4way.parquet` + `cache/rq3/rq2_multi_join_deep_wiki.parquet`
- Null 원인: analyze_multi_w4.py 의 path mismatch (`cache/rq1` vs `cache/rq3`) 로 초기 parsing 실패.
5/8 AM agent 2 가 path 수정 + master_v6 §multi 추가 완료.

복구 결과 — 3 cell × KM20 mode × 5 sel paired CI

Cell	Type	Best mode	sel=0.10 paired Δ%	direction
partsupp_deep_sift_10	multi-vector	km20_concat / product	~0~negative	improve at sel ≥ 0.10
partsupp_deep_wiki_10	multi-vector	km20_concat / product	~0~negative	improve at sel ≥ 0.10
partsupp_deep_10⋈part_wiki_10	multi-table join	km20_product (most stable)	+0.06~+21%	hurt (joint-aware needed)

복구 narrative

- **multi-vector** (deep_sift / deep_wiki): sel ≥ 0.10 영역에서 km20_concat 또는 km20_product mode 가 best (Δ% ≈ 0~negative). emb1 only / emb2 only 는 한 임베딩 정보만 사용해 hurt direction. → 본 연구 KM20 stratification 이 multi-vector 영역에서도 sel ≥ 0.10 영역 가치 입증.
- **multi-table join** (deep_10⋈part_wiki_10): 모든 mode 모든 sel 에서 hurt direction (+0.06~+21%). natural join 의 cardinality 추정 자체가 multi-vector 보다 어려움 → product mode 가 가장 stable (sel=0.50 까지 +0.63%). **joint-aware clustering 필요 = future work.**

회의 narrative 통합

5/8 회의에서는 단일 10 cell 메인 + multi 3 cell 부록 = **13 cell 매트릭스 narrative** 으로 정리 (단일 100% finalize, multi 진행 중 ~14:00~15:30 ETA). 본 §5b 결과는 master_v6 §multi 와 동일 출처로 cross-reference.

§6. 회의 의제 (5/8 19:00 비대면)

의제 1 — sf100 측정 priority 결정

현재 적재 상태 (vanilla_sf100):

Dataset	sf100 적재	rows	size	측정 즉시 가능?
DEEP	✓	80M	101 GB	✓
SIFT	✓	80M	121 GB	✓
SSN++	✓	80M	208 GB	✓
WIKI	⌚	-	-	build 필요 (240 GB)
YFCC	⌚	-	-	base.80M.u8bin 다운로드 권장 (채림 정보 동일 source, ~1.5GB)

합의 안건: - DEEP/SIFT/SSN sf100 즉시 측정 launch (HDD I/O 부담 + 다른 연구실 작업 schedule 충돌 우려 확인 후) - WIKI sf100 build (wiki-all/full_88M/base.88M.fbin 268 GB → 80M extract 후 partsupp_wiki_100, 디스크 free 1.9 TB 충분) - YFCC sf100 = BigANN base.80M.u8bin 다운로드 권장 (채림 정보 동일 source, build_yfcc 다운로드 결과는 5/8 10:18 사용자 결정으로 폐기) - 측정 ETA: 5 dataset × 2-4h = 10-20h overnight chain → 5/27 발표 전 sufficient

의제 2 — YFCC sf100 source 합의 (build_yfcc 폐기)

5/8 10:18 사용자 결정: build_yfcc.py 자체 다운로드 결과 폐기. YFCC narrative 는 채림 정보 단일. **합의 안건:** - sf100 다운로드 = **BigANN base.80M.u8bin 권장** (채림 정보와 동일 source, ~1.5GB 추정 빠름) - 채림 석사 vanilla_sf100 의 partsupp_yfcc_100 적재 여부 확인 — 적재되어 있으면 즉시 측정 가능 - 자체 build (build_yfcc) chain 폐기 — 본 연구에서 더 이상 사용하지 않음

의제 3 — 추가 method 가지치기 기준

W4 sprint 25 method × 12 cell 측정 후 4강 winner 선정. 추가 method (sub-agent 결과 7 후보) 의 가지치기 기준 합의:

살아남기 기준 (5/27 발표 method 기준): 1. $|\Delta\%| \geq 4$ 강 평균의 80% (sel=0.10 기준) 2. paired bootstrap 95% CI 0 제외 (effect statistically significant) 3. 9 cell 중 6+ cell 에서 일관 sign

추가 method 7 후보 (sub-agent a22b96cff984aeb1e 결과): - Halton sequence (low-discrepancy quasi-random) - Hammersley sequence (low-discrepancy) - Stratified Halton (Halton + stratified mix) - Reservoir sampling (online, 1-pass) - Density-stratified sampling (KDE + stratified) - Affinity Propagation clustering - Mean Shift clustering

→ 회의에서 추가 method 측정 priority + 가지치기 기준 합의.

의제 4 — SSN++ ceiling 가설 검증 방향

§4 의 4 pillar 분석 (HIGH confidence) 의 외부 자문 검증: - Facebook SimSearchNet++ 의 사전 훈련 + L2 normalization → near-isotropic embedding 의 일반성 (다른 self-supervised model 에도 동일 패턴?) - cluster_ratio < 1.3 + intrinsic_dim_ratio > 0.85 의 정량 boundary 의 robustness - BERN ceiling 영역에서의 다른 method (예: importance sampling, density-stratified) 작동 여부

→ 5/27 발표 narrative 의 negative control 정직 reporting 합의.

의제 5 — 자문 메일 발송 합의

채림 석사님 + 지도교수님 자문 메일 초안 ([속도는벡터_자문메일초안_W4_20260508.md](#)) 검토 + 발송 일정 (~5/15) 합의.

§7. 한계 + 향후 작업 (Limitation 9종)

W4 sprint 단일 측정일 결과 기준 정직 reporting. master_v6 §3 와 동일.

#	Limitation	대응 / future work
1	단일 → multi-table generalization	W4 partsupp_deep_sift / partsupp_deep_10×part_wiki_10 부분 입증, 일반 multi-relation 영역은 future work
2	NPY-only mode 의 RQ2 dependency	partsupp_ NPY 추출본 의존, 적재본 부재 시 RQ2 skip
3	YFCC source 단일화 (build_yfcc 다운로드 폐기)	5/8 10:18 사용자 결정. 채림 정보 단일 source. sf100 도 동일 source (base.80M.u8bin)
4	σ_i 신호 약함 honest 입증	Anti-Neyman vs Proportional Wilcoxon $p>0.5$, Cohen's $d<0.1$
5	IS NaN sel=0.01 발산	분할 X + weight only 의 estimator invalid → negative control narrative
6	K-sweep upper bound K=200	K>200 영역 미측정, 차후 extend
7	sf100 (80M) deferred	5/8 회의 후 자문 합의 결과를 반영하여 5/27 발표 직전 측정
8	Effect size dataset 별 격차	DEEP small / SIFT large / WIKI/YFCC/SSN++ 별도 보고
9	SSN++ ceiling — 4강 method distribution boundary	cluster_ratio < 1.3 + intrinsic_dim_ratio > 0.85 영역 (SSN++) 에서 BERN ceiling, 4강 method net hurt direction natural — 본 연구 method sweet spot boundary 정량 입증

Future work (5/27 발표 + 6/11 보고서)

1. **sf100 cross-scale validation 완성** — 5/8 회의 자문 합의 후 launch, ~5/22 까지 finalize
2. **추가 method 7 후보 탐색** — Halton/Hammersley/Stratified Halton/Reservoir/Density-stratified/Affinity Propagation/Mean Shift
3. **Exqutor multi-table 영역 일반화** — partsupp_deep_10×part_wiki_10 mode 의 joint-aware clustering (sel=0.30+ 영역에서 product mode 만 sub-1% Δ)
4. **K>200 K-sweep** — WIKI 768d / SSN++ 256d high-dimensional 영역 K_optimal 확장
5. **Distribution shift detection** — production 환경에서 distribution drift 의 online detection mechanism
6. **vector.c C-level integration** — Phase 6 SQL D 영역 (HNSW range query 와 단일 테이블 sampling 의 통합)

작성: 2026-05-08 09:50 KST · W4 sprint 12 cell 측정 finalize **작성 모델:** Claude Opus 4.7 1M, 통합 manager session **선행 doc:** `experiments/results/RQ1_RQ2_RQ3_종합_master_v6_draft_filled_partial.md` (623 lines, master narrative) + `_internal/handoff_v9_session_20260508_AM.md` (W4 sprint 인계)

5/8 10:00 KST 갱신: §5 (YFCC paired $\Delta\%$ 4강 표 + sign-100% 일관성 확인) + §5b (multi 3 cell narrative 복구) 모두 agent 2 finalize 결과 반영 완료.

5/8 14:13 KST 단일 100% finalize 갱신 (본 갱신): YFCC_sf10 fill (4강 -4.78~-5.77% 일관 improve) + 가지치기 30 method $\times$ 10 cell 100% 재계산 (analyze_10cell_w4.py, query_id paired alignment, 1000-vs-500 broadcast bug fix) + 4강 ranking 갱신 (★1 hdbscan -8.04 / ★2 minibatch_partial -7.63 / ★3 hilbert -7.54 / ★4 hybrid -7.13) + Tier 1 = 17종 (reservoir + faiss_ivf 추가) + Tier 1 spread 1.21%p. 단일 narrative 100% finalize.