

RQ1 Phase 6 vs Phase 7 — DEEP 1M Selectivity

Gradient 5-cell 비교

작성일: 2026-05-07 KST
측정 기반: `rq1\_phase6\_vs\_phase7\_comparison.json` + master line 81-99 (5/7 W2 발견)
용도: 5/27 발표 Slide 4/6 footnote 보강 + 자문 메일 첨부 (옵션 2 정직 reporting)

I. 배경 — 같은 query pool, 다른 D_target driver

5/7 W2 의 후속 검증에서 발견된 사실 한 가지: 같은 query pool, 같은 5 selectivity, 같은 5 seed, 같은 KM20-BERN 비교 metric 에서 D_target 계산 driver 만 변경했을 때 단조성 trend 의 강도가 크게 달라진다.

driver	환경	사용 위치
Phase 6 (SQL D)	PostgreSQL <code>tablesample</code> + vector.c hook (production-near)	RQ1 5/27 발표 핵심 인용
Phase 7 (numpy D)	Python NumPy 시뮬레이션 (≤10K 캐시 + HT weight=N=1M)	8M cross-scale 검증 외삽

본 doc 은 두 driver 의 측정 결과 격차를 정량 보고하고, origin 가능성과 본 연구의 reporting 방침을 정리한다.

II. 5-cell 비교 — Phase 6 단조 감소 vs Phase 7 약한 trend

Phase 6 vs Phase 7 5-cell bar chart

표 — 5-cell raw

sel	Phase 6 (SQL D)	Phase 7 (numpy D)	$\Delta = \text{Ph6} - \text{Ph7}$
0.01	+8.93%	+3.33%	+5.60%p
0.05	+1.85%	-2.60%	+4.45%p
0.10	-2.06%	-1.31%	-0.75%p
0.30	-3.11%	-0.99%	-2.12%p
0.50	-10.67%	-1.23%	-9.44%p

- Phase 6 양 끝 (s=0.01 vs s=0.50) — +8.93% → -10.67%, dynamic range **19.6%p** 의 강한 단조 감소.
- Phase 7 양 끝 — +3.33% → -1.23%, dynamic range 4.56%p 의 약한 trend.
- Δ 패턴 — 양 끝 cell (s=0.01 / s=0.50) 에서 Δ 절댓값 최대 (+5.60, -9.44), 중간 sel 에서 Δ 절댓값 최소 (-0.75 @ s=0.10). 두 driver 의 격차가 sel 양 끝에서 가장 크게 벌어짐.

참고 — master 표 (line 87-91) 의 Δ 부호 표기는 정정 대상. 위 표는 $\Delta = Ph6 - Ph7$ 정의로 계산된 정확 값이다.

III. per-seed Spearman ρ — 단조성 검정

 per-seed Spearman rho — Phase 6 vs Phase 7

표 — 검정 결과

driver	per-seed ρ (mean)	95% CI	단조 감소 검정
Phase 6	-0.680	[-0.800, -0.440]	CI 0 제외 ✓ (확정)
Phase 7	+0.240	[-0.061, +0.480]	CI 0 포함 ✗ (검정력 약화)

- **Phase 6** — per-seed Spearman ρ 의 95% CI 가 0 을 포함하지 않으며 음수 영역 (-0.800 ~ -0.440) 에 완전히 위치. RQ1 의 핵심 가설 H1-G (sel 이 낮을수록 KM20-BERN 개선이 단조 증가) 가 통계적으로 confirmed.
- **Phase 7** — ρ 가 양수이지만 CI 가 0 을 포함 (-0.061 ~ +0.480). 단조 감소 trend 가 검정력 부족으로 확정 X. (RAND arm 단조성과 시각적 패턴은 일치하나 통계 유의성은 미달.)

IV. Selectivity Gradient Trend — log scale

 Selectivity gradient trend line — Phase 6 solid vs Phase 7 dashed

log(sel) 축에서 보면 Phase 6 line 은 5 sel 에 걸쳐 거의 단조 감소 ($s=0.05$ 의 +1.85% blip 만 예외). Phase 7 line 은 +3.33 → -2.60 → -1.31 → -0.99 → -1.23 의 weak descending pattern.

V. Origin — 격차의 두 가능성

본 연구는 격차의 원인을 단정하지 않고 두 가지 가능한 origin 을 모두 보고한다.

Origin A — vector.c hook 환경의 measurement bias

Phase 6 은 PG production binary (`vector.c` hook 적용) 의 SQL `tablesample` 경로에서 D_target 을 계산. 이 환경은 (i) HNSW index 의 cache locality, (ii) tablesample seed reproducibility, (iii) hook 의 timing instrumentation 영향을 모두 받음. 측정값 자체는 production environment 의 실제 sampling outcome 이지 만, vector.c hook 의 미세한 bias 가 단조성 trend 의 강도를 인위적으로 증폭했을 가능성 배제 불가.

Origin B — numpy estimator 의 sampling-population scope 차이

Phase 7 은 ≤10K 캐시 추출 후 NumPy 시뮬레이션. HT weight 를 N=1M 으로 setting 하나 effective sampling pool 자체는 cache size 로 제한됨. 즉 *population scope mismatch* (cache 10K vs full 1M table) 가 KM20 의 cluster-aware advantage 를 약화시켰을 가능성. 8M cross-scale 검증의 numpy estimator 외삽도 같은 scope 한계에 노출되어 있음을 시사.

VI. 본 연구의 처리 — 옵션 2 정직 reporting

5/27 발표 및 최종 보고서는 두 환경 결과를 **모두 보고** 한다.

1. **핵심 narrative 인용 기준**: Phase 6 (SQL D, vector.c hook). "PG sampling extension 기준 (production-near)" 으로 명시.
2. **Phase 7 결과**: "numpy estimator 시뮬레이션 — 8M cross-scale 외삽 도구" 로 명시 인용. 단조성 검증의 weakening 사실 도 함께 보고.
3. **격차 자체**: measurement methodology 의 robustness 검증 sub-contribution 으로 격상. 즉 "single-table 분포 정보의 가치"라는 RQ1 main claim 은 두 driver 모두에서 *방향 일관* (KM20 양 끝 cell 에서 BERN 대비 차이 발생) 이라는 점을 강조.

VII. 자문 요청 사항 (5/8 회의 후 자문 메일 동봉용)

본 격차에 대해 자문 받고자 하는 항목 :

1. **vector.c hook 환경의 measurement bias 가능성** — production binary instrumentation 이 sampling outcome 의 단조성에 영향을 줄 알려진 케이스가 있는가?
2. **numpy estimator 의 cache-vs-full population scope mismatch** — HT weight 만으로 8M full-table 결과를 외삽하는 것의 한계는 어디까지인가?
3. **옵션 2 정직 reporting 의 학술적 적절성** — 두 measurement methodology 의 결과를 모두 보고하면서 main narrative 는 production-near 환경으로 단일 인용하는 reporting style 이 학술적으로 문제 없는가?

VIII. 산출

산출	위치	비고
Figure 1 (5-cell bar)	<code>experiments/figures/rq1_motivation/phase6_vs_phase7_5sel.png</code>	본 doc §II + Slide 4 footnote
Figure 2 (ρ scatter)	<code>experiments/figures/rq1_motivation/phase6_vs_phase7_rho.png</code>	본 doc §III + Slide 6 footnote
Figure 3 (trend line)	<code>experiments/figures/rq1_motivation/phase6_vs_phase7_trend.png</code>	본 doc §IV + 자문 첨부
재현 스크립트	<code>experiments/code/local_analysis/generate_phase6_vs_phase7_*.py</code>	matplotlib 한글 폰트 helper
Raw 비교 JSON	<code>experiments/results/rq1_motivation/rq1_phase6_vs_phase7_comparison.json</code>	4 cell raw + $\Delta \text{phase7}_{p10} - \text{phase7}_{p10}$
단조성 master	<code>experiments/results/rq1_motivation/rq1_gradient_monotonicity.md</code>	5/6 W1 sprint per-seed ρ 검