

RQ1/RQ2 실험 결과 정리

2026-04-16 최종 업데이트. 모든 계획된 실험 완료.

배경: 무엇을 왜 실험했는가

Exqutor는 벡터 데이터베이스에서 쿼리를 실행할 때, "이 조건에 맞는 행이 대략 몇 개일까?"를 미리 추정합니다. 이 추정이 정확해야 좋은 실행 계획을 세울 수 있습니다. Exqutor는 이 추정을 위해 데이터의 일부를 무작위로 뽑아보는 **샘플링** 방식을 사용합니다.

우리의 핵심 질문은 두 가지입니다:

- **RQ1 (문제 제기):** 벡터 데이터가 공간적으로 쏠려 있을 때, 무작위 샘플링의 추정 정확도가 실제로 떨어지는가?
- **RQ2 (개선):** 데이터의 공간 구조를 반영한 층화 샘플링으로 추정 정확도를 개선할 수 있는가?

측정 방법

- **Q-error:** 추정한 행 수와 실제 행 수의 비율. 1.0이면 완벽한 추정, 클수록 부정확.
- **5-seed 반복:** 같은 실험을 난수 시드 5개로 반복하여 안정성 확인.
- **paired Wilcoxon 검정:** 같은 100개 쿼리에 대해 기존 방식과 개선 방식을 쌍으로 비교. p-value가 0.05 미만이면 "통계적으로 유의한 차이"로 판단.
- **selectivity:** 전체 데이터 중 쿼리 조건에 맞는 비율. 0.500(50%)은 넓은 범위, 0.010(1%)은 좁은 범위.

데이터셋

이름	건수	벡터 차원	특성
DEEP 1M	100만	96	딥러닝 이미지 특징 벡터. 상대적으로 균일한 분포.
DEEP 8M	800만	96	위와 같은 종류, 8배 규모. 외적 타당성 검증용.
SIFT 1.5M	150만	128	이미지 키폰트 벡터. DEEP보다 더 쏠린(skewed) 분포.

실험 1: 데이터가 정말 쏠려 있는가 (RQ1)

방법: DEEP 1M 벡터를 k-means 알고리즘으로 20개 그룹으로 나눈 뒤, 그룹별 크기를 확인.

결과: 그룹 크기가 최소 2.6만 ~ 최대 8.1만으로 약 3배 차이. 데이터가 고르게 분포하지 않고 특정 영역에 몰려 있음을 확인.

의미: 이 쏠림이 있기 때문에 무작위 샘플링이 일부 영역을 과대/과소 대표할 수 있다.

실험 2: Exqutor 소스 코드 분석 (RQ1)

방법: Exqutor의 PostgreSQL 확장 모듈(vector.c) 소스 코드를 직접 분석.

결과: 단일 테이블 벡터 범위 쿼리를 제대로 처리하지 못하는 설계 제약 5종을 발견. 원문은 다중 테이블 조인 시 나리오만 다루고 있었고, 단일 테이블에서는 샘플링 hook 자체가 작동하지 않는 경로가 있었음.

의미: 연구 범위를 단일 테이블 벡터 범위 쿼리로 전환하는 근거. 이 설계 제약 자체도 학술적 기여.

실험 3: 블록 샘플링 → 행 단위 샘플링 교체 (RQ2)

방법: Exqutor의 기본 샘플링 방식인 TABLESAMPLE SYSTEM(블록 단위)을 TABLESAMPLE BERNOULLI(행 단위)로 교체. SYSTEM은 디스크 블록 통째로 뽑아서 같은 블록 안의 행들이 함께 선택되는 편향이 있고, BERNOULLI는 각 행을 독립적으로 선택.

결과: selectivity 구간에 따라 +3.8% ~ +9.6% 개선.

의미: Exqutor의 기존 방식에 있던 기본적인 비효율을 교정. 이후 실험의 baseline이 됨.

실험 4: KM20 층화 샘플링 구현 및 검증 (RQ2)

방법: 데이터를 k-means K=20으로 사전 분할한 뒤, 각 그룹에서 비례 배분하여 샘플을 추출하는 층화 샘플링(stratified sampling)을 Exqutor 소스에 직접 구현(+228줄).

DEEP 1M 결과

selectivity	5-seed 평균 개선	유의한 seed
50% (넓은 범위)	+1.64%	5/5 (전부 유의)
5%	+1.85%	3/5
1% (좁은 범위)	+8.93%	4/5

DEEP 8M 결과 (외적 타당성)

selectivity	5-seed 평균 개선	유의한 seed
50%	+1.76%	4/5
5%	+0.55%	0/5
1%	-0.71%	0/5 (노이즈 지배)

→ 50% 범위에서는 1M과 8M 모두 일관된 개선(+1.6~1.8%), 1M과 CONSISTENT 판정. → 1% 범위에서 8M은 Q-error 자체가 6~8배로 커서 신호 대비 잡음이 지배적.

SIFT 1.5M 결과 (다른 벡터 종류)

selectivity	5-seed 평균 개선	유의한 seed
50%	+3.07%	5/5 (전부 $p < 1e-8$)
5%	+4.39%	5/5 (전부 유의)
1%	-0.53%	1/5

→ DEEP(+1.64%)보다 SIFT에서 효과가 **2배 이상** 큼. → SIFT가 더 쏠린(skewed) 분포이므로 층화 샘플링의 이점이 더 크게 나타남.

실험 5: KM20 vs RANDOM20 대조 실험 — 쓸림이 원인임을 증명 (RQ1+RQ2)

방법: 같은 층화 샘플링 코드를 두 가지 파티션으로 비교. - **KM20:** k-means로 공간 구조를 반영하여 20개 그룹으로 분할 - **RANDOM20:** 완전 무작위로 20개 그룹에 배정 (공간 구조 무시)

차이가 나면 → 개선의 원인이 "공간 구조를 아는 것"임을 증명. 차이가 안 나면 → 단순히 20개로 나누는 것 자체가 원인.

DEEP 1M

selectivity	KM20	RANDOM20	격차
50%	+1.64%	+2.20%	~0 (차이 없음)
5%	+1.85%	+0.79%	+1.1%p
1%	+8.93%	-10.67%	19.6%p

→ 좁은 쿼리(1%)에서 KM20은 개선, RANDOM20은 오히려 악화. 95% 신뢰구간이 완전히 분리되어 **통계적으로 확실한 차이**.

DEEP 8M

selectivity	KM20	RANDOM20	격차
50%	+1.76%	+1.10%	0.7%p
5%	+0.55%	+0.20%	0.4%p
1%	-0.71%	+11.06%	노이즈 지배

→ 50%/5%에서 KM20이 RANDOM20보다 일관되게 우세하나, 1%는 Q-error가 너무 커서 신호 식별 불가.

SIFT 1.5M

selectivity	KM20	RANDOM20	격차
50%	+3.07%	+1.01%	2.1%p
5%	+4.39%	-0.05%	4.4%p
1%	-0.53%	-12.11%	11.6%p

→ SIFT에서는 모든 selectivity 구간에서 KM20이 RANDOM20보다 우세. → 특히 1%에서 RANDOM20이 -12.11% 악화 — DEEP(-10.67%)보다 더 심함. 데이터가 더 쏠려 있을수록 무작위 파티션의 성능이 더 나빠진다는 증거.

실험 6: Two-Level Decomposition — 개선 효과의 분해 (RQ1+RQ2)

방법: 실험 5의 KM20 vs RANDOM20 비교에서, 개선 효과를 두 경로로 분리.

Level 1: 비례 배분(Proportional Allocation) 효과

기존 BERNOULLI 샘플링은 각 행을 독립적으로 추출하므로 표본 크기가 확률적으로 흔들립니다. 층화 샘플링은 각 그룹에서 정확히 비례 배분하므로 표본 크기가 안정됩니다.

증거: 넓은 쿼리(50%)에서는 KM20과 RANDOM20 모두 개선. 파티션 품질과 무관하게 "나누는 것 자체"의 효과.

- DEEP 1M $s=0.500$: KM20 +1.64%, RANDOM20 +2.20%
- SIFT $s=0.500$: KM20 +3.07%, RANDOM20 +1.01%

Level 2: 공간 인식(Spatial Awareness) 효과

쿼리 결과가 소수 그룹에 집중되는 상황(좁은 범위 쿼리)에서, 해당 그룹을 제대로 아는 파티션(KM20)이 추가 이점을 제공합니다.

증거: 좁은 쿼리(1%)에서 KM20과 RANDOM20의 극단적 차이.

- DEEP 1M $s=0.010$: 격차 19.6%p
- SIFT $s=0.010$: 격차 11.6%p

→ 쿼리 범위가 좁아질수록 공간 인식의 중요성이 증가하는 **selectivity gradient** 패턴.

실험 7: 1M 중간 selectivity 보충 (RQ1+RQ2)

방법: DEEP 1M에서 기존에 측정하지 않았던 중간 selectivity 구간(10%, 30%)을 추가 측정하여 selectivity gradient 그래프를 보충.

KM20 결과

selectivity	5-seed 평균 개선	유의한 seed
30%	+2.62%	5/5 (전부 $p < 0.001$)
10%	+4.19%	5/5 (전부 $p < 0.004$)

RANDOM20 결과

selectivity	5-seed 평균 개선	유의한 seed
30%	+0.26%	1/5
10%	+1.74%	0/5

KM20 vs RANDOM20 격차

selectivity	KM20	RANDOM20	격차
30%	+2.62%	+0.26%	2.4%p
10%	+4.19%	+1.74%	2.5%p

→ 중간 구간에서도 KM20이 RANDOM20보다 일관되게 우세. → KM20은 모든 selectivity에서 유의, RANDOM20은 거의 유의하지 않음.

전체 종합: Selectivity Gradient

DEEP 1M에서 selectivity에 따른 KM20 vs RANDOM20 개선폭:

selectivity	KM20	RANDOM20	격차	해석
50%	+1.64%	+2.20%	~0	비례 배분 효과만 (Level 1)
30%	+2.62%	+0.26%	2.4%p	공간 인식 효과 등장
10%	+4.19%	+1.74%	2.5%p	공간 인식 효과 증가
5%	+1.85%	+0.79%	1.1%p	공간 인식 유지
1%	+8.93%	-10.67%	19.6%p	공간 인식 없으면 악화

→ 쿼리 범위가 좁아질수록 "데이터의 공간 구조를 아는 것"이 점점 더 중요해진다. → 교수님 프레이밍 "쓸림 → 성능 저하 → 개선된 sampling으로 해결"과 정확히 일치.

Cross-Dataset 비교

측정	DEEP 1M	DEEP 8M	SIFT 1.5M
KM20 s=0.500	+1.64%	+1.76%	+3.07%
KM20 s=0.050	+1.85%	+0.55%	+4.39%
RANDOM20 s=0.010 악화	-10.67%	노이즈	-12.11%

→ SIFT(더 skewed)에서 KM20 개선 효과가 2배 이상 크고, RANDOM20 악화도 더 심함. → 데이터의 쓸림이 클수록 공간 인식 샘플링의 가치가 높아진다.