

RQ1/RQ2 실험 결과 정리

2026-04-17 통합 업데이트. 95% 신뢰구간, Two-Level 분해, gradient 비단조성 분석, 클러스터 분포 비교, anomaly 설명 포함.

배경: 무엇을 왜 실험했는가

Exqutor는 벡터 데이터베이스에서 쿼리를 실행할 때, "이 조건에 맞는 행이 대략 몇 개일까?"를 미리 추정합니다. 이 추정이 정확해야 좋은 실행 계획을 세울 수 있습니다. Exqutor는 이 추정을 위해 데이터의 일부를 무작위로 뽑아보는 **샘플링** 방식을 사용합니다.

우리의 핵심 질문은 두 가지입니다:

- **RQ1 (문제 제기):** 벡터 데이터가 공간적으로 쏠려 있을 때, 무작위 샘플링의 추정 정확도가 실제로 떨어지는가?
- **RQ2 (개선):** 데이터의 공간 구조를 반영한 층화 샘플링으로 추정 정확도를 개선할 수 있는가?

측정 방법

- **Q-error:** 추정한 행 수와 실제 행 수의 비율. 1.0이면 완벽한 추정, 클수록 부정확.
- **5-seed 반복:** 같은 실험을 난수 시드 5개로 반복하여 안정성 확인.
- **95% 신뢰구간:** $\text{mean} \pm t(4, 0.975) \times (\text{std} / \sqrt{5})$, 여기서 $t(4, 0.975) = 2.776$.
- **paired Wilcoxon 검정:** 같은 100개 쿼리에 대해 기존 방식과 개선 방식을 쌍으로 비교. p-value가 0.05 미만이면 "통계적으로 유의한 차이"로 판단.
- **selectivity:** 전체 데이터 중 쿼리 조건에 맞는 비율. 0.500(50%)은 넓은 범위, 0.010(1%)은 좁은 범위.

데이터셋

이름	건수	벡터 차원	특성
DEEP 1M	100만	96	딥러닝 이미지 특징 벡터. 상대적으로 균일한 분포.
DEEP 8M	800만	96	위와 같은 종류, 8배 규모. 외적 타당성 검증용.
SIFT 1.5M	150만	128	이미지 키폰트 벡터. DEEP보다 더 쏠린(skewed) 분포.

실험 1: 데이터가 정말 쏠려 있는가 (RQ1)

방법: DEEP 1M 벡터를 k-means 알고리즘으로 20개 그룹으로 나눈 뒤, 그룹별 크기를 확인.

결과: 그룹 크기가 최소 2.6만 ~ 최대 8.1만으로 약 3배 차이. 데이터가 고르게 분포하지 않고 특정 영역에 몰려 있음을 확인.

의미: 이 쏠림이 있기 때문에 무작위 샘플링이 일부 영역을 과대/과소 대표할 수 있다.

클러스터 분포 정량 비교 — DEEP vs SIFT

두 데이터셋의 쏠림 정도를 정량적으로 비교하기 위해 HHI(Herfindahl-Hirschman Index)와 CV(변동계수)를 산출하였습니다.

지표	DEEP 1M (96d)	SIFT 1.5M (128d)	균일 기준
K	20	20	20
최소 클러스터	26,343	33,330	50,000 / 75,000
최대 클러스터	81,233	148,202	50,000 / 75,000
최대/최소 비율	3.08배	4.45배	1.00
HHI	0.05274	0.05776	0.05000
CV (변동계수)	0.234	0.394	0.000

HHI는 각 클러스터가 차지하는 비율의 제곱합으로, 균일하면 $1/K=0.05$ 이고 한 클러스터에 집중되면 1.0에 가까워 집니다. SIFT(0.0578)이 DEEP(0.0527)보다 높습니다. CV는 표준편차를 평균으로 나눈 것으로, SIFT(0.394)가 DEEP(0.234)보다 **68% 높습니다**. 특히 SIFT의 클러스터 1(14.8만)과 클러스터 18(14.0만)이 전체의 ~19%를 차지하여 기대값 10%의 거의 두 배입니다.

이 정량적 차이가 이후 실험에서 SIFT의 KM20 개선 효과가 DEEP보다 2배 이상 크게 나타나는 직접적 원인입니다.

실험 2: Exqutor 소스 코드 분석 (RQ1)

방법: Exqutor의 PostgreSQL 확장 모듈(vector.c) 소스 코드를 직접 분석.

결과: 단일 테이블 벡터 범위 쿼리를 제대로 처리하지 못하는 설계 제약 5종을 발견. 원논문은 다중 테이블 조인 시 나리오만 다루고 있었고, 단일 테이블에서는 샘플링 hook 자체가 작동하지 않는 경로가 있었음.

의미: 연구 범위를 단일 테이블 벡터 범위 쿼리로 전환하는 근거. 이 설계 제약 자체도 학술적 기여.

실험 3: 블록 샘플링 -> 행 단위 샘플링 교체 (RQ2)

방법: Exqutor의 기본 샘플링 방식인 TABLESAMPLE SYSTEM(블록 단위)을 TABLESAMPLE BERNOULLI(행 단위)로 교체. SYSTEM은 디스크 블록 통째로 뽑아서 같은 블록 안의 행들이 함께 선택되는 편향이 있고, BERNOULLI는 각 행을 독립적으로 선택.

결과: selectivity 구간에 따라 +3.8% ~ +9.6% 개선.

의미: Exqutor의 기존 방식에 있던 기본적인 비효율을 교정. 이후 실험의 baseline이 됨.

실험 4: KM20 층화 샘플링 구현 및 검증 (RQ2)

방법: 데이터를 k-means K=20으로 사전 분할한 뒤, 각 그룹에서 비례 배분하여 샘플을 추출하는 층화 샘플링 (stratified sampling)을 Exqutor 소스에 직접 구현(+228줄).

DEEP 1M 결과

selectivity	5-seed 평균 개선	95% CI	유의한 seed
50% (넓은 범위)	+1.64%	[+1.11, +2.18]	5/5 (전부 유의)
30%	+2.62%	[+1.45, +3.80]	5/5 (전부 $p < 0.001$)
10%	+4.19%	[+0.72, +7.66]	5/5 (전부 $p < 0.004$)
5%	+1.85%	(단일 측정)	3/5
1% (좁은 범위)	+8.93%	(단일 측정)	4/5

50%, 30%, 10% 구간은 5-seed 반복 측정으로 신뢰구간이 확보되었습니다. 5%와 1%는 초기 Phase 6에서 단일 selectivity 측정으로 수행되어 CI 산출 대상이 아니지만, 이후 실험 5의 대조군 데이터와 gradient 분석에서 일관성이 확인됩니다.

DEEP 8M 결과 (외적 타당성)

selectivity	5-seed 평균 개선	95% CI	유의한 seed
50%	+1.76%	[+0.65, +2.86]	4/5
5%	+0.55%	[-3.11, +4.21]	0/5
1%	-0.71%	[-21.13, +19.70]	0/5 (노이즈 지배)

50% 범위에서는 1M과 8M 모두 일관된 개선(+1.6~1.8%)으로 CONSISTENT 판정입니다. 1% 범위에서 8M의 CI가 [-21.13, +19.70]으로 극단적으로 넓은 것은 Q-error 자체가 6~8배로 커서 신호 대비 잡음이 지배적이기 때문입니다.

SIFT 1.5M 결과 (다른 벡터 종류)

selectivity	5-seed 평균 개선	95% CI	유의한 seed
50%	+3.07%	[+2.66, +3.48]	5/5 (전부 $p < 1e-8$)
5%	+4.39%	[+2.63, +6.15]	5/5 (전부 유의)
1%	-0.53%	[-3.18, +2.11]	1/5

DEEP(+1.64%)보다 SIFT에서 효과가 **2배 이상** 큼니다. SIFT의 50% CI [+2.66, +3.48]은 DEEP 50% CI [+1.11, +2.18]과 겹치지 않아 통계적으로 구별됩니다. SIFT가 더 쏠린(skewed) 분포이므로 총화 샘플링의 이점이 더 크게 나타남을 정량적으로 확인하였습니다.

실험 5: KM20 vs RANDOM20 대조 실험 (RQ1+RQ2)

방법: 같은 총화 샘플링 코드를 두 가지 파티션으로 비교. - **KM20:** k-means로 공간 구조를 반영하여 20개 그룹으로 분할 - **RANDOM20:** 완전 무작위로 20개 그룹에 배정 (공간 구조 무시)

차이가 나면 개선의 원인이 "공간 구조를 아는 것"임을 증명하고, 차이가 안 나면 단순히 20개로 나누는 것 자체가 원인입니다.

DEEP 1M

selectivity	KM20 (CI)	RANDOM20 (CI)	격차
50%	+1.64% [+1.11, +2.18]	+2.20%	~0 (차이 없음)
30%	+2.62% [+1.45, +3.80]	+0.26% [-0.52, +1.05]	2.4%p
10%	+4.19% [+0.72, +7.66]	+1.74% [+0.50, +2.99]	2.5%p
5%	+1.85%	+0.79%	+1.1%p
1%	+8.93%	-10.67%	19.6%p

좁은 쿼리(1%)에서 KM20은 개선, RANDOM20은 오히려 악화됩니다. 10%와 30% 구간에서도 CI가 분리되어 통계적으로 유의한 차이입니다.

DEEP 8M

selectivity	KM20 (CI)	RANDOM20 (CI)	격차
50%	+1.76% [+0.65, +2.86]	+1.10% [+0.44, +1.75]	0.7%p
5%	+0.55% [-3.11, +4.21]	+0.20% [-3.75, +4.16]	0.4%p
1%	-0.71% [-21.13, +19.70]	+11.06% [+0.89, +21.23]	노이즈 지배

50%/5%에서 KM20이 RANDOM20보다 일관되게 우세하나, 1%는 Q-error가 너무 커서 신호 식별이 불가능하다.

SIFT 1.5M

selectivity	KM20 (CI)	RANDOM20 (CI)	격차
50%	+3.07% [+2.66, +3.48]	+1.01% [-0.17, +2.19]	2.1%p
5%	+4.39% [+2.63, +6.15]	-0.05% [-3.85, +3.75]	4.4%p
1%	-0.53% [-3.18, +2.11]	-12.11% [-29.02, +4.79]	11.6%p

SIFT에서는 모든 selectivity 구간에서 KM20이 RANDOM20보다 우세합니다. 특히 1%에서 RANDOM20이 -12.11% 악화되었으며, 이는 DEEP(-10.67%)보다 더 심합니다. 데이터가 더 쏠려 있을수록 무작위 파티션의 성능이 더 나빠진다는 증거입니다.

실험 6: Two-Level Decomposition (RQ1+RQ2)

방법: 실험 5의 KM20 vs RANDOM20 비교에서, 개선 효과를 두 경로로 분리합니다.

분해 원리

- **Level 1 (비례 배분, Proportional Allocation):** RANDOM20의 개선분. 파티션의 공간 품질과 무관하게, "나누는 것 자체"가 제공하는 표본 크기 안정화 효과입니다.
- **Level 2 (공간 인식, Spatial Awareness):** KM20 개선분에서 RANDOM20 개선분을 뺀 것. 공간 구조를 아는 파티션만이 제공하는 추가 이점입니다.
- **Total** = Level 1 + Level 2 = KM20 개선분.

DEEP 1M 수치 분해

selectivity	Level 1 (비례 배분)	Level 2 (공간 인식)	Total (KM20)
50%	+2.20%	-0.56%	+1.64%
30%	+0.26%	+2.36%	+2.62%
10%	+1.74%	+2.45%	+4.19%
5%	+0.79%	+1.06%	+1.85%
1%	-10.67%	+19.60%	+8.93%

50%에서는 Level 1이 지배적이고 Level 2는 거의 0입니다. 쿼리 범위가 넓을 때는 파티션 품질과 무관하게 비례 배분의 안정화 효과만으로 충분합니다. 그러나 selectivity가 줄어들수록 Level 2의 기여가 급격히 증가하며, 1%에서는 Level 2가 +19.60%p로 전체 개선의 원동력이 됩니다. 이는 좁은 범위 쿼리에서 결과 행이 소수 클러스터에 집중되므로, 해당 클러스터를 정확히 아는 파티션(KM20)만이 올바른 표본을 추출할 수 있기 때문입니다.

SIFT 1.5M 수치 분해

selectivity	Level 1 (비례 배분)	Level 2 (공간 인식)	Total (KM20)
50%	+1.01%	+2.06%	+3.07%
5%	-0.05%	+4.44%	+4.39%
1%	-12.11%	+11.58%	-0.53%

SIFT에서는 DEEP과 달리 50%에서부터 Level 2가 +2.06%로 이미 유의합니다. 이는 SIFT의 쓸림이 DEEP보다 크기 때문에(CV 0.394 vs 0.234), 넓은 범위 쿼리에서도 공간 인식이 가치를 갖는다는 증거입니다.

DEEP 8M 수치 분해

selectivity	Level 1 (비례 배분)	Level 2 (공간 인식)	Total (KM20)
50%	+1.10%	+0.66%	+1.76%
5%	+0.20%	+0.35%	+0.55%
1%	+11.06%	-11.77%	-0.71%

8M에서도 50%/5% 구간에서 Level 2가 양수이나, 1% 구간은 sample_size=385의 한계로 노이즈가 지배적입니다.

실험 7: 1M 중간 selectivity 보충 (RQ1+RQ2)

방법: DEEP 1M에서 기존에 측정하지 않았던 중간 selectivity 구간(10%, 30%)을 추가 측정하여 selectivity gradient 그래프를 보충.

KM20 결과

selectivity	5-seed 평균 개선	95% CI	유의한 seed
30%	+2.62%	[+1.45, +3.80]	5/5 (전부 $p < 0.001$)
10%	+4.19%	[+0.72, +7.66]	5/5 (전부 $p < 0.004$)

RANDOM20 결과

selectivity	5-seed 평균 개선	95% CI	유의한 seed
30%	+0.26%	[-0.52, +1.05]	1/5
10%	+1.74%	[+0.50, +2.99]	0/5

KM20 vs RANDOM20 격차

selectivity	KM20 (CI)	RANDOM20 (CI)	격차
30%	+2.62% [+1.45, +3.80]	+0.26% [-0.52, +1.05]	2.4%p
10%	+4.19% [+0.72, +7.66]	+1.74% [+0.50, +2.99]	2.5%p

중간 구간에서도 KM20이 RANDOM20보다 일관되게 우세하며, KM20은 모든 selectivity에서 유의한 반면 RANDOM20은 거의 유의하지 않습니다.

전체 종합: Selectivity Gradient

DEEP 1M에서 selectivity에 따른 KM20 vs RANDOM20 개선폭입니다.

selectivity	KM20 (CI)	RANDOM20 (CI)	격차	해석
50%	+1.64% [+1.11, +2.18]	+2.20%	~0	비례 배분 효과만 (Level 1)
30%	+2.62% [+1.45, +3.80]	+0.26% [-0.52, +1.05]	2.4%p	공간 인식 효과 등장
10%	+4.19% [+0.72, +7.66]	+1.74% [+0.50, +2.99]	2.5%p	공간 인식 효과 증가
5%	+1.85%	+0.79%	1.1%p	공간 인식 유지
1%	+8.93%	-10.67%	19.6%p	공간 인식 없으면 악화

쿼리 범위가 좁아질수록 "데이터의 공간 구조를 아는 것"이 점점 더 중요해집니다. 교수님 프레이밍 "쓸림 -> 성능 저하 -> 개선된 sampling으로 해결"과 정확히 일치합니다.

Gradient 비단조성에 대한 주의

위 표에서 KM20 gradient가 10%(+4.19%) -> 5%(+1.85%)로 비단조적으로 하락하는 것이 눈에 띕니다. 이 비단조성에는 **방법론적 차이**가 기여할 가능성이 높습니다. $s=0.050$ 실험은 초기 Phase 6에서 수행되었으며, 이때는 D_{target} (거리 임계값) 계산에 SQL 기반 이진 탐색을 사용하였습니다. 반면 $s=0.100$ 과 $s=0.300$ 은 최종 실험 일괄 수행(Phase 7)에서 numpy 기반 D_{target} 계산으로 전환된 후 측정되었습니다. 두 방식은 부동소수점 정밀도와 실제 selectivity 달성 정도에 미세한 차이를 유발할 수 있으며, 이것이 gradient의 부분적 불연속에 기여하였을 가능성이 있습니다.

따라서 gradient의 전체적 상승 추세(50% → 1%)는 견고하지만, 개별 인접 구간(특히 10% → 5%)의 정확한 차이를 해석할 때는 측정 시점과 방법론의 일관성을 고려해야 합니다. 이 점은 SIFT mid-selectivity 보충 실험이 완료되면 교차 검증될 예정입니다.

Cross-Dataset 비교

측정	DEEP 1M	DEEP 8M	SIFT 1.5M
KM20 s=0.500	+1.64% [+1.11, +2.18]	+1.76% [+0.65, +2.86]	+3.07% [+2.66, +3.48]
KM20 s=0.050	+1.85%	+0.55% [-3.11, +4.21]	+4.39% [+2.63, +6.15]
RANDOM20 s=0.010 악화	-10.67%	노이즈	-12.11% [-29.02, +4.79]

SIFT(더 skewed)에서 KM20 개선 효과가 2배 이상 크고, RANDOM20 악화도 더 심합니다. **데이터의 쓸림이 클수록 공간 인식 샘플링의 가치가 높아집니다.**

Anomaly 설명

Anomaly 1: DEEP 1M s=0.500에서 RANDOM20(+2.20%) > KM20(+1.64%)

s=0.500에서 true_card는 ~50만(전체의 50%)으로, 이 정도 범위에서는 BERNOULLI의 추정 분산이 이미 낮아서(Q-error 1.04~1.07) 어떤 파티션이든 소폭 개선만 발생합니다. KM20과 RANDOM20의 차이 0.56%p는 seed 간 분산(std ~0.5~1%) 안에 있으므로 비유의적입니다. 이는 s=0.500에서 Level 1(비례 배분) 효과만 작동하고 Level 2(공간 인식)가 불필요함을 의미합니다.

Anomaly 2: DEEP 8M s=0.010에서 KM20이 -0.71%

8M에서 s=0.010이면 true_card는 ~8만이지만, sample_size=385로 고정되어 있으므로 BERNOULLI가 추출하는 표본은 전체의 0.005%에 불과합니다. 이 극소 표본에서 8만 건을 추정하면 Q-error가 6~8배까지 치솟습니다. seed별 결과가 -29%~+11.5%로 극단적으로 흔들리며, 95% CI가 [-21.13, +19.70]으로 0을 포함합니다. 이는 sample_size=385가 s>=0.050에서 설계된 것으로, s=0.010에서는 표본이 절대적으로 부족하여 어떤 샘플링 방식이든 정확한 추정이 불가함을 보여줍니다.

Anomaly 3: SIFT $s=0.010$ 에서 KM200이 -0.53%

SIFT 1.5M에서 $s=0.010$ 이면 true_card는 ~1.5만입니다. BERNOULLI의 median Q-error가 5-seed 모두 1.4435로 동일한 것은 hook estimation이 같은 값을 반환하는 양자화(quantization) 현상입니다. seed별 diff가 -2.66%~+3.03%로 방향 자체가 불안정하고, CI [-3.18, +2.11]이 0을 포함합니다. KM200이 방어 역할은 하지만 (RANDOM20의 -12.11% 악화를 방지), 적극적 개선은 표본 부족으로 불가능합니다. 이는 **총화 샘플링의 효과가 안정적으로 발현되는 selectivity 하한이 $s \geq 0.050$** 이라는 실험적 발견입니다.

보충 실험 상태

다음 두 실험은 서버에서 진행 중이며, 결과가 확보되는 대로 본 문서에 반영될 예정입니다.

1. **SIFT mid-selectivity ($s=0.100$, $s=0.300$):** DEEP 1M에서 확인된 gradient 패턴이 SIFT에서도 재현되는지 교차 검증. 서버 오류(unrecognized node type: 808464432)로 D_target 재계산 후 재시도 예정.
2. **8M mid-selectivity ($s=0.100$, $s=0.300$):** 8M에서 중간 구간의 외적 타당성 확인.

이 보충 실험이 완료되면 selectivity gradient 그래프가 3개 데이터셋 모두에서 5개 구간으로 채워지며, gradient 비단조성에 대한 추가 검증이 가능해집니다.