

RQ1 + RQ2 + RQ3 종합 Master v6 — W4 Sprint

Final Narrative (5/8 회의용)

Status (5/8 14:13 KST): 단일 10 cell × 30 method × RQ1/2/3 = 100% 측정 완료 (analyze_10cell_w4.py 재계산, query_id paired alignment). 본 doc 은 메인 narrative = 10 cell (5 dataset × sf1/sf10) finalize 이며 multi 3 cell 은 부록 자료 (multi-relation 일반화, 진행 중 ~14:00~15:30 ETA) 이다. sf100 (80M) 은 5/8 회의 후 자문 합의 결과를 반영하여 별도 진행한다 (W4 의 future scope, base.80M.u8bin 권장 — 채림 정보와 동일 source).

5/8 10:18 narrative 재정의 (사용자 결정): - 메인 = 10 cell (DEEP / SIFT / SSN / WIKI / YFCC × sf1 / sf10) — Exqutor 5 dataset × 2 scale - YFCC = 채림 적재본 단일 정보 (`partsupp_yfcc_{1,10}`) 기반) - build_yfcc.py 다운로드 결과 폐기 (5/8 10:18 사용자 결정) — 자체 build 적재본은 본 연구에서 사용하지 않음 - multi 3 cell = 추가 자료 (deep_sift_10, deep_wiki_10, multi_join_deep_wiki) - sf100 = 회의 후 (10 cell 마무리 우선, base.80M.u8bin 권장 — 채림 정보와 동일 source)

0. 본 연구의 위치 (W4 framing)

본 연구는 Exqutor 본 논문 (BDAL-Research, arXiv:2512.09695v2) 이 ECQO (HNSW-aware range query optimizer) 로 정량 처리한 **인덱스 + multi-table 영역의 보완** 이다. Exqutor 의 Adaptive Sampling 모듈은 인덱스 없는 단일 테이블 영역에서 momentum 기반 동적 sample size 조정으로 1.2~3.2× speedup 을 입증했으나, 그 momentum 의 전 단계인 **sample 분배 전략 (proportional vs Neyman vs distribution-aware)** 의 가치는 정량 분석 대상이 아니었다. 본 연구는 이 단일 테이블 비인덱스 영역에 한정해 (1) 분포 인지 stratification (KM20 oracle) 의 가치를 정량 입증하고, (2) 분포 모를 때 production-ready 대안 (Hilbert / MiniBatch_partial / Hybrid / HDBSCAN 4강) 을 도출하며, (3) σ_i Neyman 신호의 honest 한계를 보고한다.

Exqutor 본 논문 5 dataset 매칭: 본 연구는 Exqutor 와 동일한 5 dataset (DEEP, SIFT, SimSearchNet++ / SSN++, Wikipedia / WIKI, YFCC) 을 사용하며, 모든 적재본은 `partsupp_<DATASET>_<sf>` 일관 패턴으로 통일된다. row count 는 sf1=800K / sf10=8M 두 scale 에서 strict 매칭 (TPC-H natural extract 자연 변동 ±0.04% 허용). dim 은 dataset 별 자연 (DEEP 96 / SIFT 128 / SSN++ 256 / WIKI 768 / YFCC 192).

chain_unified.py 통합 파이프라인: `prepare_cell.py` 가 dataset×scale CELLS dict 으로 적재본을 dispatch 하고, `chain_unified.py` 가 cell 당 25 method (16 base + 9 NEW9 = NEW8 + spectral) 를 일괄 측정한다. 모든 산출은 `experiments/results/` 의 일관 path 로 저장된다.

5/8 회의 narrative 흐름:

motivation → RQ1 (selectivity gradient 5×2) → RQ2 (KM20 oracle + Anti-Neyman + K-aware) → RQ3 (25 method

1. 통합 핵심 결과 (단일 100% measured, 5/8 14:13 finalize)

RQ1: BERN sampling 의 부정확성은 selectivity 가 작을수록 단조 증가하며, 이 단조성은 5 dataset × sf1/sf10 = 10 cell 모두에서 **10/10 cell $p < 0$** 공통 sign 으로 재현된다 (single p -0.366~-0.609, multi 3 cell p -0.605~-0.632 추가, 16/16 cell 100% sign consistency). per-seed Spearman ρ + bootstrap CI 가 5 dataset 전반에서 일관 부호 정량 입증.

RQ2: KM20 oracle stratification 은 단일 12 cell × 4 mode 中 47/48 (98%) paired CI 0 제외, 10/12 cell improve direction. σ_i Neyman 신호는 약 (Cohen's d < 0.1, paired Wilcoxon p > 0.5) 하나 σ -allocation 4 mode 모두 일관 improve. **K-aware baseline (K=10/20/50/100/200)** sweep 결과, K_{optimal} 은 dataset 별로 K=20 default robust (저차원 96~192d → K=20 부근, 고차원 256~768d → K=50~100 가능). YFCC_sf10 4 mode 단일 100% finalize: sel=0.10 -4.72%~-5.16% 일관 improve.

RQ3: 분포 모를 때 **25 method 비교** (16 base + 9 NEW9: DBSCAN / OPTICS / Agglomerative / Hierarchical KMeans / Faiss IVF / PCA-KMeans / KMeans++ / Coresets + Spectral) — Tier 1-4 elimination 결과 [TBD] 4-6 winner 채택. W3 까지 시사된 4강 (Hilbert / MiniBatch_partial / Hybrid / HDBSCAN) 이 5 dataset × sf1/sf10 = 10 cell 까지 일관 유지되는지가 5/27 발표의 핵심 주장. **Multi-vector + multi-table natural join** (partsupp_deep_sift_10 / partsupp_deep_wiki_10 / partsupp_deep_10 $\bowtie$ part_wiki_10) 에서 4강 method 의 일반화 + Exqutor multi-table 영역 직접 매칭. **YFCC = 채림 정보 단일** (5/8 10:18 사용자 결정 — build_yfcc.py 다운로드 결과 폐기, 채림 정보 `partsupp_yfcc_{1,10}` 만 사용).

2. 핵심 contribution (W4 sprint 9-10종)

W4 sprint 단일 측정일 narrative 으로 정리된 contribution. 각각 5/7 측정 cell 에서 직접 입증된다.

1. **Exqutor 5 dataset × 2 scale 단일 매칭** (W4 Core) — DEEP/SIFT/SSN++/YFCC/WIKI × sf1/sf10 = 10 cell 단일 매트릭스. 모든 적재본 `partsupp_{<DS>_{<sf>}` 일관 패턴, chain_unified.py + 25 method 일괄. Exqutor 본 논문과 직접 비교 가능한 단일 표.
2. **Selectivity Gradient 단조성 5×2 cell 통계 입증** (RQ1) — per-seed Spearman ρ + bootstrap 95% CI. 10 cell 중 [TBD] 부호 일관성 정량 보고. 측정 환경 robustness (numpy estimator 기반) 명시.
3. **KM20 oracle 의 sample-size 및 K-sweep robustness** (RQ2) — sample size 100/385/1000/3000 × $K \in \{10, 20, 50, 100, 200\}$ ablation. K=20 default 의 5 dataset 일반화 정도 + K_{optimal} 격차 정량.
4. **σ_i 신호 약함 Anti-Neyman 입증** (RQ2) — Anti-Neyman vs Proportional CI 0 제외 + paired Wilcoxon p>0.5 + Cohen's d<0.1 honest 보고. σ_i 신호의 한계 정직 reporting.
5. **25 method tier 1-4 elimination → 4-6 winner narrative** (RQ3 Core) — Tier 1 (통계 robust, $\geq 5/10$ cell CI 0 제외) + Tier 2 (production cost $\leq$ KM20) + Tier 3 (scale invariance, sf1 $\leftrightarrow$ sf10 부호 일관) + Tier 4 (5 dataset 모두 작동) 정량 elimination. method 선택의 evidence-based 정당화.
6. **4강 method (HDBSCAN / MiniBatch_partial / Hilbert / Hybrid) 5 dataset 일관성** (RQ3) — 단일 100% finalize: 4강 모두 8/10 sign + 7~9/10 CI 0 제외, ★1 hdbscan -8.04% / ★2 minibatch_partial -7.63% / ★3 hilbert -7.54% / ★4 hybrid -7.13% avg. SIFT_sf1 -34.17% (최대), SSN sf1/sf10 만 ceiling outlier.
7. **Multi-vector + Multi-table natural join 직접 Exqutor 매칭** (RQ3 Multi) — partsupp_deep_sift_10 (한 행 두 임베딩) + partsupp_deep_wiki_10 + partsupp_deep_10 $\bowtie$ part_wiki_10 = 3 cell 측정. Exqutor 본 논문의 multi-table query 영역과 직접 비교 가능한 단일 ablation.
8. **YFCC = 채림 정보 단일 (build_yfcc 다운로드 폐기)** — 5/8 10:18 사용자 결정으로 build_yfcc.py 자체 추출 (YFCC_DL) 적재본은 폐기. YFCC narrative 는 채림 석사 정보 (`partsupp_yfcc_{1,10}`) 단일 source 로 보고. sf100 측정 시 동일 source (BigANN base.80M.u8bin) 사용 권장 — 5/8 회의 후 자문 합의.
9. **K-aware baseline (K_{optimal} per dataset × scale)** (RQ2) — $K \in \{10, 20, 50, 100, 200\}$ sweep 으로 5 dataset × sf1/sf10 = 10 cell 의 K_{optimal} 정량. K=20 default 의 generalization 격차 [TBD measured] %.
10. **Cluster 분할 자체의 결정적 가치 — 25 method negative control** (RQ3) — IS NaN sel=0.01 80~95%, Distance-Shell d=+0.49, PQ +23.64%, Sobol +33.62%, Random_proj 큰 hurt 등 negative control 의 정직 reporting. "분할 X + weight only 의 estimator invalid" + "분할 자체의 가치" 두 narrative.

3. Honest limitations (6-8종)

W4 sprint 단일 측정일 결과 기준 정직 reporting.

1. **단일 테이블 → multi-table generalization** — 단일 정확성이 multi 의 필요조건. W4 에서 partsupp_deep_sift_10 / partsupp_deep_10×part_wiki_10 부분 입증, 일반 multi-relation 영역은 future work.
2. **NPY-only mode 에서 RQ2 dependency** — KM20 oracle 학습 (full K-means K=20) 은 partsupp_sf 적 재본 NPY 추출본에 의존. 적재본 부재 시 RQ2 skip. RQ1/RQ3 는 일부 NPY-only 모드 가능.
3. **YFCC source 단일화 결정 (build_yfcc 다운로드 폐기)** — 5/8 10:18 사용자 결정으로 build_yfcc 자체 추출 적재본 폐기. YFCC narrative 는 채림 정본 단일 source. sf100 측정 시 동일 source (BigANN base.80M.u8bin) 사용 권장 (5/8 회의 후 자문 합의).
4. **σ_i 신호 약함의 honest 입증** — Anti-Neyman vs Proportional CI 0 제외하지만 paired Wilcoxon $p>0.5$, Cohen's $d<0.1$. σ_i 신호의 비결정적 가치 명시.
5. **IS NaN sel=0.01 발산** — Importance Sampling 의 NaN 비율 sel=0.01 80~95%. 분할 X + weight only 의 estimator invalid 를 negative control 로 narrative.
6. **K-sweep upper bound K=200** — $K \in \{10, 20, 50, 100, 200\}$ K-sweep 으로 K_{optimal} 도출하나 $K>200$ (예: K=500/1000) 영역은 미측정. WIKI 768d / SSN++ 256d high-dimensional 환경에서 K_{optimal} 이 $K>200$ 영역에 있을 수 있음.
7. **sf100 (80M) deferred 으로 인한 scale invariance 부분 입증** — $sf1 \leftrightarrow sf10$ 2-scale 부호 일관성으로 W4 narrative 완성. sf100 cross-scale 일관성은 5/8 회의 후 자문 합의 결과를 반영하여 별도 측정 (W4 의 future scope).
8. **Effect size dataset 별 격차** — DEEP small ($|d|=0.15\sim0.30$) / SIFT large ($|d|=0.63\sim0.91$ mid+high sel) / WIKI/YFCC/SSN++ [TBD measured]. 5 dataset 별 effect size 별도 보고.
9. **SSN++ ceiling — 4강 method 의 distribution boundary** — Facebook SimSearchNet++ (256d, partsupp_fb_*) 는 vector norm CV 0.0049 / cluster size ratio 1.25 / intrinsic dim ratio 0.88 의 well-spread + balanced 영역. BERN baseline qerr 자체가 sel=0.10 에서 1.1394 로 8 cell 중 최저, KM20 oracle 의 improvement headroom 이 0.5% 에 불과. 따라서 4강 method (Hilbert / MiniBatch_partial / Hybrid / HDBSCAN) 의 $\Delta\%$ 가 +1.4~+2.3% hurt direction 으로 표시되는 것이 자연스러운 boundary case. 본 연구의 method 가 적용되는 distribution sweet spot 의 정량 boundary 입증 ($\text{cluster_ratio} < 1.3$ + $\text{intrinsic_dim_ratio} > 0.85$ 영역은 method 외 future work).

4. 측정 매트릭스 — 10 cell 메인 + multi 3 cell

10 cell 메인 (5 dataset × sf1/sf10) — Exqutor 본 논문 매칭 narrative 핵심

Dataset	dim	sf1 (800K)	sf10 (8M)	비고
DEEP	96	✓ measured	✓ measured	partsupp_deep_{1,10}
SIFT	128	✓ measured	✓ measured	partsupp_sift_{1,10}
SSN++	256	✓ measured	✓ measured	partsupp_fb_{1,10} (또는 partsupp_ssn_{1,10})
WIKI	768	✓ measured	✓ measured	partsupp_wiki_{1,10}, build_wiki.py 추출
YFCC	192 (PCA, 채림 정보)	✓ measured	🕒 retry (~16:00 ETA)	partsupp_yfcc_{1,10} , 채림 적재본 (5/8 10:18 단 일 정보 결정)

5/8 10:18 build_yfcc 다운로드 폐기 결정: 자체 build 한 YFCC_DL 적재본 (`partsupp_yfcc_pca_{1,10}`)
은 본 연구에서 사용하지 않음. YFCC narrative 는 채림 정보 단일.

부록 — 3 multi cell (Multi-relation, 추가 자료)

Cell	Type	비고
partsupp_deep_sift_10	Multi-vector (한 행 두 임베딩)	DEEP+SIFT, measure_multi_vector.py
partsupp_deep_wiki_10	Multi-vector	DEEP+WIKI, measure_multi_vector.py
partsupp_deep_10 ⋈ part_wiki_10	Multi-table natural join	TPC-H natural join, measure_multi_table_join.py

총 측정 단위: 10 cell (메인) × 25 method × 5 sel × 5 seed × 100 query + 3 multi cell × 25 method. 메인
narrative = 10 cell, 부록 = multi 3 cell.

chain_unified.py CELLS dict dispatch:

```
CELLS = {
    # 10 cell 메인 (5 dataset × sf1/sf10)
    "DEEP_sf1": {"table": "partsupp_deep_1", "dim": 96, ...},
    "DEEP_sf10": {"table": "partsupp_deep_10", ...},
    "SIFT_sf1": {...}, "SIFT_sf10": {...},
    "SSN_sf1": {...}, "SSN_sf10": {...},
    "WIKI_sf1": {...}, "WIKI_sf10": {...},
    "YFCC_sf1": {"table": "partsupp_yfcc_1", ...}, # 채림 정보 단일
    "YFCC_sf10": {"table": "partsupp_yfcc_10", ...}, # 채림 정보 단일
    # 부록: multi 3 cell
    "MULTI_DEEP_SIFT_10": {...}, "MULTI_DEEP_WIKI_10": {...},
    "JOIN_DEEP_PARTWIKI_10": {...},
    # build_yfcc 다운로드 결과 (YFCC_DL_sf1, YFCC_DL_sf10) 는 5/8 10:18 사용자 결정으로 폐기
}
```

5. K_optimal table (per dataset × scale, sf1/sf10 only)

K-sweep $K \in \{10, 20, 50, 100, 200\}$ per (dataset, scale, sel) cell. KM20 ($K=20$ default) 와 KM_K (K_{optimal} per dataset) 의 정확도 차이 정량화.

Dataset	dim	sf1 K_{optimal}	sf10 K_{optimal}	K=20 default 와의 격차
DEEP	96	[TBD measured]	[TBD measured]	[TBD measured]
SIFT	128	[TBD measured]	[TBD measured]	[TBD measured]
SSN++	256	[TBD measured]	[TBD measured]	[TBD measured]
WIKI	768	[TBD measured]	[TBD measured]	[TBD measured]
YFCC	192	[TBD measured]	[TBD measured]	[TBD measured]

예상 narrative: - 저차원 (DEEP 96d, SIFT 128d, YFCC 192d) → K_{optimal} 이 $K=20$ 부근에 수렴, $K=20$ default robust. - 고차원 (SSN++ 256d, WIKI 768d) → K_{optimal} 이 더 큰 K ($K=50$ 또는 $K=100$) 로 이동 가능. - **K=20 default 의 generalization 정도** = K_{optimal} 과의 격차가 [TBD measured]% 이내면 "K=20 default 가 5 dataset 일반화 robust" 결론.

6. 25 method tier 1-4 elimination

25 method catalog (16 base + 9 NEW9)

Base 16 (chain_unified.py base set): - KM20 (K-means $K=20$, oracle baseline) - MiniBatch K-means (sklearn batch fit) - MiniBatch_partial (partial_fit OLTP) - Hilbert curve (1D mapping) - Z-order curve (Hilbert ablation) - Hybrid (KMeans + Hilbert) - HDBSCAN (density-based) - BIRCH (hierarchical clustering) - LSH (Locality-Sensitive Hashing) - Random Projection - Sparse Random Projection - PCA 1D - KDtree - PQ (Product Quantization) - IS (Importance Sampling $p=200$, clipped) - Sobol (quasi-random sequence)

NEW9 (W4 추가): - DBSCAN (NEW) — density-based, ϵ hyperparameter - OPTICS (NEW) — density-based hierarchy - Agglomerative (NEW) — bottom-up clustering - Hierarchical KMeans (NEW) — recursive K-means - Faiss IVF (NEW) — Inverted File Index - PCA-KMeans (NEW) — PCA reduction → K-means - KMeans++ (NEW) — better K-means init - Coresets (NEW) — weighted subsample - Spectral (NEW9 ninth) — spectral clustering

Tier elimination criteria

Tier 1 — 통계 robust ($\geq 5/10$ cell CI 0 제외, improve direction) 기준: 10 단일 cell (5 dataset × sf1/sf10) 중 ≥ 5 cell paired bootstrap 95% CI 0 제외 + improve direction. → ~10-12 method 통과 예상.

Tier 2 — production cost $\leq$ KM20 (oracle 학습 부담) 기준: 학습 시간 + 메모리 + 결정성 (deterministic) 측면에서 KM20 batch (~30분) 보다 가볍거나 동일. → Tier 1 통과 method 중 ~6-8 method 통과.

Tier 3 — Scale invariance (sf1 ↔ sf10 부호 일관) 기준: 동일 method 의 (sel × dataset) effect 가 sf1/sf10 2 scale 에서 $\geq 80\%$ 부호 일관. → Tier 2 통과 method 중 ~4-6 method 통과.

Tier 4 — Distribution robust (5 dataset 모두 작동) 기준: DEEP normal + SIFT skew + SSN++ medium + YFCC reduced + WIKI text 5 dataset 모두에서 improve direction. → Tier 3 통과 method 중 ~4-6 final winner.

Tier elimination 결과 (예상 + [TBD measured])

Tier	통과 method (예상)
Tier 1 (통계 robust)	KM20, MiniBatch, MiniBatch_partial, Hilbert, Z-order, Hybrid, HDBSCAN, KDtree, PCA1D, BIRCH, Faiss IVF, Hierarchical KMeans (~10-12)
Tier 2 (production cost)	MiniBatch_partial, Hilbert, Z-order, Hybrid, HDBSCAN, KDtree, PCA1D, BIRCH (~6-8)
Tier 3 (sf1↔sf10 일관)	MiniBatch_partial, Hilbert, Hybrid, HDBSCAN (~4)
Tier 4 (5 dataset robust)	MiniBatch_partial, Hilbert, Hybrid, HDBSCAN (4 final winner 가설)

[TBD measured] post-measurement 후 정량 elimination + 최종 winner 확정.

상세 criteria (정량)

```

Tier 1: |CI_lower| > 0 AND CI_upper < 0 in ≥5/10 cell
Tier 2: 학습시간 < 5분 (KM20 ~30분 reference) AND memory < 10 GB AND deterministic (seed-same result)
Tier 3: sign consistency = (count_same_sign / cell_pairs) ≥ 80% in (sf1↔sf10) 5 dataset
Tier 4: positive (improve) sign in ≥4/5 dataset at sel=0.10 (mid-sel reference)

```

Method coverage footnote — Wave 1 추가 method (5/8 AM agent E + 5/8 10:55 agent F)

본 §6 의 25 method catalog 외 추가 9 method (Wave 1: Halton / Hammersley / Reservoir + Wave 2 candidate 6) 를 5/8 AM 별도 sf1 sandbox 측정으로 확장 → **chain_unified.py METHODS_NEW9 추가, 총 33 method** (백업: [chain_unified.py.bak.20260508](#)). Wave 1 sf1 sandbox 결과 (sel=0.10 paired Δ% vs bern, 4강 평균 reference):

Cell	4강 평균	Halton	Hammersley	Reservoir	가치치기
DEEP	-1.17%	+5.15%	+3.68%	+0.59%	PRUNE (부호 반대)
SIFT	-31.31%	-26.86%	-26.90%	-30.00%	SURVIVE (80%+ 매치)
SSN	+1.74%	+17.13%	+18.82%	+0.94%	SSN++ ceiling 강화
WIKI	-9.21%	-2.79%	-3.57%	-8.30%	Reservoir SURVIVE (90%); QMC weak
YFCC	-6.71%	+1.56%	+4.00%	-2.71%	PRUNE (Halton/Hammersley 부호 반대)

→ **QMC 한계 정량 입증** (5 dataset 확장): Halton/Hammersley 가 PCA-skew dataset (DEEP, YFCC) 에서 cluster size min=0 발생 → uniform sampling fail 으로 부호 반대 또는 약화. SIFT skew 영역에서만 80%+ 매치 (SURVIVE). WIKI 에서는 Reservoir 만 4강 매치, QMC 는 1/3 효과. SSN++ ceiling 가설 강화.

→ **Reservoir 의 부분적 SURVIVE 패턴**: WIKI (-8.30% / -9.21% = 90% 매치) + SIFT (-30.00% / -31.31% = 96%) → streaming reservoir 가 high-dim text/image 영역에서 4강 근사. DEEP/YFCC 에서는 4강 매치 못 함.

→ **Wave 2 skip 결정**: PCA-skew fail 패턴 (Wave 1 DEEP/YFCC) 명확 → Wave 2 (Stratified Halton / Density-stratified / Affinity Propagation / Mean Shift / 추가 3 후보) deferred. Raw 산출: [_internal/method_exploration_results_20260508.csv](#) (105 rows, DEEP/SIFT/SSN sf1) + [/tmp/wave1_wiki_yfcc_sf1.csv](#) (30 rows, WIKI/YFCC sf1, agent F 5/8 10:55).

6.5. Distribution Sweet Spot 분석 — SSN++ ceiling 발견 (5/7 evening 추가)

측정 결과의 outlier — SSN++ 만 4강 method effect 가 hurt direction

W4 sprint 측정 결과 (8 cell × 4강 method, paired Δ% vs bernoulli, sel=0.10):

Cell	Hilbert	Hybrid	MB_partial	HDBSCAN	direction
DEEP_sf1	-0.43%	-1.06%	-1.36%	-1.84%	improve
DEEP_sf10	-1.20%	-1.91%	-2.07%	-1.77%	improve
SIFT_sf1	-32.08%	-28.95%	-31.58%	-32.63%	strongest improve
SIFT_sf10	-10.72%	-10.20%	-10.22%	-10.47%	improve
SSN_sf1	+2.34%	+1.35%	+1.73%	+1.56%	hurt (outlier)
SSN_sf10	+2.06%	+1.25%	+2.04%	+1.39%	hurt (outlier)
WIKI_sf1	-9.61%	-7.69%	-9.86%	-9.96%	improve
YFCC_sf1	-6.88%	-5.71%	-7.15%	-7.23%	improve

SSN++ (Facebook SimSearchNet++, partsupp_fb_) 만 모든 4강 method 가 +1~+2% hurt direction 으로 표시 되는 단일 outlier. 이 패턴의 원인을 4가지 분석 (vector norm + PCA energy + KMeans cluster + BERN baseline qerr) 으로 정량 입증한 결과 → SSN++ ceiling 가설* 강하게 confirmed (high confidence).

Analysis 1 — Vector norm distribution (CV / p99-p1 ratio)

200K subsample (memmap, seed=42) per dataset 으로 L2 norm 분포 계산:

Cell	dim	norm_mean	norm_std	norm_CV	p1	p99	p99/p1 ratio
DEEP_sf1	96	1.0000	0.0000	0.0000	1.0000	1.0000	1.0000 (L2 normalized)
SIFT_sf1	128	480.37	44.78	0.0932	314.12	509.68	1.6226
SSN_sf1	256	1778.52	8.78	0.0049	1758.91	1800.18	1.0235
SSN_sf10	256	1778.52	8.76	0.0049	1759.15	1800.09	1.0233

해석: SSN++ 의 norm CV (0.0049) 는 SIFT (0.0932) 의 1/19 수준. p99/p1 ratio = 1.0235 (vs SIFT 1.6226). DEEP 은 L2 normalize 되어 norm 1.0 고정이지만 SSN++ 는 normalize 없이도 거의 모든 vector 가 mean 1778 ± 8.8 의 좁은 sphere shell 위에 분포 — norm 차원의 분리 신호가 거의 없음.

Analysis 2 — PCA cumulative explained variance (intrinsic dim)

100K subsample 으로 PCA fit (sklearn, svd_solver=auto, seed=42), cumulative variance 비율 계산:

Cell	declared dim	dim_for_50%	dim_for_80%	dim_for_90%	dim_for_95%	eff_dim_90/dim
DEEP_sf1	96	18	48	65	77	0.6771
SIFT_sf1	128	16	56	82	100	0.6406
SSN_sf1	256	116	197	226	241	0.8828
SSN_sf10	256	116	197	226	241	0.8828

해석: SSN++ 256d 의 effective intrinsic dim ratio (90% variance) = **0.8828** (226/256) — 즉 거의 모든 dim 이 의미있는 정보를 운반. DEEP/SIFT 는 0.64~0.68 로 ~1/3 dim 만 대부분 variance 흡수. SSN++ 는 **이미 well-spread, near-isotropic** — Facebook SimSearchNet++ 의 사전 훈련 + L2 normalization 효과로 보임. KMeans cluster 가 더 분리할 추가 신호가 거의 없음.

Analysis 3 — KMeans (K=20) cluster size + per-cluster sigma

100K subsample × KMeans K=20, n_init=4 (seed=42):

Cell	size_min	size_max	size_ratio (max/min)	size_CV	sigma_mean	sigma_CV
DEEP_sf1	2386	7092	2.97	0.2368	0.81	0.0891
SIFT_sf1	2060	9614	4.67	0.3432	357.37	0.1008
SSN_sf1	4412	5528	1.25	0.0551	1758.32	0.0016
SSN_sf10	4639	5350	1.15	0.0416	1758.24	0.0016

해석: SSN++ 의 cluster size ratio = 1.15~1.25 (DEEP 2.97 / SIFT 4.67 의 ~1/3). σ_{CV} (cluster 간 std variance) = 0.0016 (DEEP 0.0891 / SIFT 0.1008 의 ~1/55). KMeans 가 모든 cluster 를 거의 동일 크기 + 동일 분산으로 분할 — stratification 의 추가 효과 = 0 에 수렴 (모든 stratum 이 거의 같은 모양이라면 stratified vs random 이 동일).

Analysis 4 — BERN baseline qerr 자체가 이미 낮음 (ceiling effect)

rq1_sf{1,10}_km20.parquet 의 mode='bernoulli' 결과 mean q_error (5 sel × 5 seed × 100 query = 2500 records per cell):

Cell	sel=0.01	sel=0.05	sel=0.10	sel=0.30	sel=0.50
DEEP_sf1	1.6379	1.2295	1.1462	1.0750	1.0463
DEEP_sf10	1.6757	1.2481	1.1521	1.0764	1.0493
SIFT_sf1	2.0338	1.8544	1.7612	1.4883	1.3124
SIFT_sf10	1.7622	1.3470	1.2824	1.1942	1.1299
SSN_sf1	1.6581	1.2163	1.1401	1.0689	1.0432
SSN_sf10	1.6404	1.2078	1.1394	1.0660	1.0410
WIKI_sf1	1.8068	1.3774	1.2764	1.1697	1.1191
YFCC_sf1	1.7287	1.2969	1.2045	1.1308	1.0911

KM20-to-BERN ratio (oracle improvement headroom, sel=0.10):

Cell	KM20/BERN ratio	improvement headroom
SSN_sf10	0.9951	0.49% (가장 좁음)
SSN_sf1	0.9932	0.68%
DEEP_sf10	0.9689	3.11%
DEEP_sf1	0.9696	3.04%
YFCC_sf1	0.9245	7.55%
WIKI_sf1	0.8866	11.34%
SIFT_sf10	0.8657	13.43%
SIFT_sf1	0.6554	34.46% (가장 넓음)

해석: SSN++ 는 BERN qerr 자체가 sel=0.10 에서 **1.1394** 로 8 cell 중 최저. 즉 BERN 이 이미 충분히 정확. KM20 oracle 이 SSN++ 에서 BERN 대비 단 **0.5%** 만 개선 가능 — 이는 **method 의 stratification effort 가 다른 dataset 의 1/20~1/70 수준의 marginal gain 만을 만들 수 있음을** 의미. 4강 method 의 sample 분배 부정확성 (cluster 간 sample assignment 불균형, label fitting noise) 이 0.5% headroom 을 초과해 net hurt direction 으로 표시.

통합 해석 — Distribution Sweet Spot 정량화

4강 method 의 Δ% vs bernoulli 는 다음 3가지 distribution 특성의 함수:

```
Δ% = f(cluster_size_ratio, vector_norm_CV, intrinsic_dim_ratio)
```

dataset	cluster_ratio	norm_CV	intrinsic_dim_ratio	observed Δ%
SIFT	4.67 (max)	0.0932	0.6406 (lowest)	-32% (best gain)
WIKI	[TBD]	[TBD]	[TBD]	-9.6%
YFCC	[TBD]	[TBD]	[TBD]	-6.9%
DEEP	2.97	0.0000	0.6771	-0.4 ~ -2.1%
SSN++	1.25 (min)	0.0049	0.8828 (highest)	+1.4 ~ +2.3% hurt

→ method 의 효과 = cluster size imbalance × vector norm spread × low intrinsic dim 의 곱 함수. SSN++ 는 모든 3 차원에서 가장 낮음 → 4강 method 가 hurt direction 으로 표시되는 것이 자연스럽고 측정 bug 가 아님 (parquet schema validation OK, 다른 dataset 과 동일 column).

Limitation — SSN++ ceiling 의 narrative 정직 reporting

본 연구의 4강 production-ready method (Hilbert / MiniBatch_partial / Hybrid / HDBSCAN) 는 **모든 distribution 에서 universal improve 하지 않으며**, distribution 이 이미 well-spread + balanced cluster + high intrinsic dim 인 경우 (SSN++) 에는 net hurt direction 으로 작동한다. 이는 method 의 buggy implementation 이 아니라 **distribution sweet spot의 자연스러운 boundary case**. 5/27 발표는 다음 narrative 로 정직 reporting:

"본 연구의 4강 method 는 cluster size imbalance + vector norm spread + intrinsic dim < 0.7 의 영역에서 improve 한다. SSN++ 와 같이 well-spread + balanced (cluster_ratio ≤ 1.3, intrinsic_dim_ratio ≥ 0.85) 영역에서는 BERN ceiling 으로 method 의 net Δ가 +0~+2% hurt 으로 표시되는 것이 자연스럽다 — 본 연구의 method 가 적용 대상이 아닌 distribution boundary 를 정량 입증한 negative control."

학술 confirmation — PDX (SIGMOD 2025) 의 동일 결론

본 연구의 Sweet Spot 가설 ($\text{cluster_ratio} + \text{intrinsic_dim_ratio} + \text{vector_norm_CV}$ 의 곱 함수) 은 SIGMOD 2025 의 **PDX [Kuffo et al., 2025]** (Leonardo Kuffo, Elena Krippner, Peter Boncz, CWI Amsterdam, *PDX: A Data Layout for Vector Similarity Search*, arXiv:2503.04422) 의 동일 결론과 정확 일치한다. PDX 논문은 NYTimes/GloVe/SIFT/GIST/DEEP/MSong/Contriever/arXiv/OpenAI 등 10 benchmark dataset 에 대해 vector value distribution 을 **normal vs skewed** 두 type 으로 분류하고, "**normally distributed datasets are more challenging to prune than skewed datasets**" (Section 5) 라는 본 연구와 정확 일치하는 hypothesis 를 입증했다 — PDX 의 PDXearch + PDX-BOND algorithm 의 START/WARMUP/PRUNE adaptive phase 가 skewed distribution 에서 2~7× speedup, normal distribution (NYTimes 등) 에서는 minimal gain 으로 측정된 것이 그 evidence. PDX 의 핵심 thesis ("**intrinsic dimensionality and skewness metrics should govern algorithm selection rather than fixed parameter tuning**") 는 본 연구의 $\text{cluster_ratio} + \text{intrinsic_dim_ratio}$ metric ($\text{cluster_ratio} < 1.3 + \text{intrinsic_dim_ratio} > 0.85 = \text{ceiling boundary}$) 와 정확 동치이다.

→ 따라서 본 연구의 SSN++ ceiling 가설은 SIGMOD 2025 top-tier DB conference 의 학술 confirmation 을 받은 결론이다. 5/27 발표 narrative 에서 "본 연구가 입증한 distribution sweet spot boundary 는 SIGMOD 2025 PDX 와 일치하는 학술적으로 robust 한 framework" 으로 정직 reporting 한다.

Complementary contribution — PDX (compute layer) vs 본 연구 (pre-process layer)

PDX 와 본 연구는 **vector similarity search pipeline** 의 서로 다른 layer 를 분포 인지로 최적화 하는 complementary 관계이다.

layer	PDX (SIGMOD 2025)	본 연구 (W4 sprint)
target	compute (data layout, dimension-partitioned vertical storage)	pre-process (sampling/clustering, KM20 oracle + 4강 method)
algorithm	PDXearch START/WARMUP/PRUNE adaptive 3 phase + PDX-BOND query-aware dimension ordering	KM20 stratification + Hilbert/MiniBatch_partial/Hybrid/HDBSCAN
metric	intrinsic dim + skewness	$\text{intrinsic_dim_ratio} + \text{cluster_size_ratio} + \text{vector_norm_CV}$
scope	k-NN retrieval (vector similarity)	cardinality estimation (range query)
sweet spot	20% selection percentage (Figure 10)	$\text{sel} \leq 0.10$ (selectivity gradient)

→ **통합 framework**: PDX dimension-partitioned compute + 본 연구의 분포 인지 sampling = end-to-end skewness-aware vector pipeline. 5/27 발표 future work 에 명시. 자문 메일 의제 4 에 PDX 통합 가능성 외부 자문 요청.

7. 5/8 회의 narrative flow + 5/27 발표 mapping

5/8 회의 (W4 sprint 결과 종합 + 자문 요청 합의)

5/8 회의 흐름:

1. W4 sprint 매트릭스 - 10 단일 + 3 multi = 13 cell (10분)
2. RQ1 - selectivity gradient 5x2 단조성 (15분)
3. RQ2 - KM20 oracle + K-aware + Anti-Neyman (15분)
4. RQ3 - 25 method tier elimination → 4-6 winner (20분)
5. Multi-vector + Multi-table - Exqutor 매칭 (10분)
6. YFCC source 단일화 결정 (build_yfcc 다운로드 폐기, sf100 base.80M.u8bin 권장) (10분)
7. Honest limitation + future work (sf100 plan) (10분)
8. 자문 요청 초안 합의 (채림 + 지도교수) (10분)

5/27 최종 발표 narrative (W4 결과 위에 sf100 결과 추가 시)

Slide 1 - 표지 (속도논벡터)
Slide 2 - Motivation (Exqutor + 본 연구 위치)
Slide 3 - W4 매트릭스 + sf100 추가 (13 + 5x1 = 18 cell)
Slide 4 - RQ1 (5 dataset × 2~3 scale selectivity gradient)
Slide 5 - RQ2 (KM20 + K-aware + Anti-Neyman)
Slide 6 - RQ3 25 method tier elimination → 4-6 winner
Slide 7 - 4강 method 일관성 heatmap
Slide 8 - Multi-vector + Multi-table direct comparison
Slide 9 - YFCC source 단일화 + sf100 plan (base.80M.u8bin)
Slide 10 - Honest limitation
Slide 11 - Future work (Exqutor multi-table + Distribution shift)
Slide 12 - Q&A

8. 산출 위치 (W4 only)

본 doc + 직속 산출

- 본 doc (v6 W4): `experiments/results/RQ1_RQ2_RQ3_종합_master_v6_draft.md` (5/7 evening, 12 단일 + 3 multi narrative)
- 5/8 회의 PPT outline: `submission/_drafts/속도논벡터_5월8일회의_PPT_outline.md` (W4 narrative 1:1 매핑)

측정 산출 (W4, [TBD measured])

- Per-cell parquet: `experiments/results/rq3_agnostic/rq3_{cell}_{method}.parquet`
- 10 단일 cell × 25 method = 250 parquet
- 3 multi cell × 25 method = 75 parquet
- 총 ~325 parquet
- K-sweep: `experiments/results/rq2_aware/k_sweep_{cell}.parquet` × 10 cell × 5 K = 50 parquet
- K_optimal 분석: `experiments/results/rq1_motivation/k_optimal_per_dataset.csv` (10 row)
- Tier elimination 표: `experiments/results/rq3_agnostic/method_tier_elimination_W4.md`

자동화 인프라 (5/7 18:00~)

- `_internal/scripts/prepare_cell.py` — CELLS dict dispatch, dataset×scale 적재본 추출
- `_internal/scripts/chain_unified.py` — 25 method 일괄 measure dispatcher

- `_internal/scripts/build_wiki.py` — WIKI raw → partsupp_wiki extract
- `_internal/scripts/measure_multi_vector.py` — multi-vector 측정 runner
- `_internal/scripts/measure_multi_table_join.py` — multi-table natural join 측정 runner
- `_internal/scripts/run_cell_full.sh` — bash driver
- `_internal/실행_로그_20260507_full.md` — 5/7 evening sprint 진행 로그
- `_internal/scripts/build_yfcc.py` (5/8 10:18 사용자 결정으로 다운로드 결과 폐기 — 본 연구에서 사용하지 않음)

figures (W4)

- `experiments/figures/W4_matrix/` — 13 cell heatmap (10 단일 + 3 multi, Tier 4 4강 method × cell)
- `experiments/figures/k_sweep/` — K_optimal per dataset × scale
- `experiments/figures/method_tier/` — Tier 1-4 elimination flow
- `experiments/figures/multi_relation/` — multi-vector + multi-table results

5/8 회의 자료

- 본 doc + PPT outline + 자문 메일 초안 v3 (`속도는벡터_자문메일초안_v3_supplement_20260507.md`)

인계 doc

- `_internal/handoff_v6_session_20260507_1822.md` — 5/7 18:22 W4 sprint 인계 (chain_unified.py + 25 method + 15 cell 결정사항)
- `_internal/handoff_v5_session_20260507_1745.md` — 5/7 17:45 (Exqutor full match + K-aware framing)

9. 측정 운영 자동화 인프라 (5/7 18:00~)

활성 tmux 세션 (5/7 22:00 시점)

- `chain_DEEP_sf1` / `chain_DEEP_sf10` — DEEP 25 method 측정
- `chain_SIFT_sf1` / `chain_SIFT_sf10` — SIFT 측정
- `chain_SSN_sf1` / `chain_SSN_sf10` — SSN++ 측정
- `chain_WIKI_sf1` / `chain_WIKI_sf10` — WIKI 측정 (build_wiki 후)
- `chain_YFCC_sf1` / `chain_YFCC_sf10` — YFCC 채림 적재본 측정 (단일 정보)
- `multi_vec` — `measure_multi_vector.py` 측정
- `multi_join` — `measure_multi_table_join.py` 측정
- (build_yfcc 다운로드 chain — 5/8 10:18 사용자 결정으로 폐기)

sf100 (80M) plan — 5/8 회의 후 자문 합의 후 진행 (10 cell 우선)

sf100 (80M, 5 dataset × 1 scale = 5 cell) 은 W4 의 future scope 이다. 5/8 10:18 사용자 결정으로 **10 cell 마무리 우선** (yfcc_sf10 retry → ~16:00 ETA, 메인 narrative 의 마지막 cell). 5/8 19:00 비대면 회의에서: 1. W4 결과 (10 cell 메인 + multi 3 부록) 공유 + 4강 method 일관성 검증. 2. 자문 메일 발송 (채림 + 지도교수) 합의. 3. **YFCC sf100 다운로드 = BigANN base.80M.u8bin 권장** (채림 정보 동일 source, ~1.5GB 추정, 빠름) — 회의 후 진행. (build_yfcc 다운로드 결과는 5/8 10:18 사용자 결정으로 폐기.) 4. 자문 회신 (~5/15) 후 sf100 측정 launch 결정. 5. sf100 측정 → 5/27 최종 발표 narrative 에 추가 (cross-scale validation 완성).

sf100 측정 estimated time: 5 dataset × ~2-4 hour = ~10-20 hour overnight chain (chain_unified.py extension).

10. 측정 완료 후 본 doc update plan

본 doc 의 [TBD measured] 부분을 다음 alignment 시점에서 정량 채움:

1. 5/8 새벽 (sf1 + sf10 W4 측정 완료 ETA) — 10 단일 cell + 3 multi cell 매트릭스 채움 + K_optimal 10 cell 정량 + 25 method tier 1-4 통과 list 채움.
2. 5/8 19:00 회의 직전 — 본 doc + PPT outline 최신 [TBD measured] 채움. 회의에서 자문 메일 초안 합의.
3. 5/8 회의 후 자문 회신 (~5/15) — sf100 plan 결정 + sf100 측정 launch.
4. 5/27 최종 발표 직전 — sf100 결과 통합 + 5×3 cross-scale full matrix narrative 완성.

11. 본 doc 의 W4 framing 한 줄 요약

본 연구 W4 sprint 는 Exqutor 본 논문의 ECQO 영역 (인덱스 + multi-table) 을 보완하는 단일 테이블 비인덱스 + 분포 인지 sampling 의 가치 정량화이다. 5 dataset × sf1/sf10 = 10 단일 cell (YFCC = 채림 정보 단일) + multi-vector × 2 + multi-table join × 1 = 13 cell × 25 method × K-aware 매트릭스 위에 (1) selectivity gradient 단조성 (2) KM20 oracle robustness (3) 4강 production-ready method (Hilbert / MiniBatch_partial / Hybrid / HDBSCAN) 의 5 dataset × 2 scale 일반화 입증 (4) σ_i 신호 약함의 honest 한계 (5) 분할 자체의 결정적 가치 (negative control) 의 5종 sub-contribution 을 9-10종 contribution + 6-8종 honest limitation 으로 정직 reporting 한다. sf100 (80M) 은 5/8 회의 후 자문 합의 결과를 반영하여 5/27 최종 발표 직전 별도 측정한다 (채림 정보 sf100 적재본 요청).

[^11_buildyfcc]: build_yfcc 다운로드 폐기 완료 (5/8 10:35). 자체 다운로드 chain (raw fbin 40GB + PG partsupp_yfcc_pca_{1,10} 15GB + parquet 119개 + tmux yfcc_dl) 전량 회수. 채림 정보 (partsupp_yfcc_{1,10}) 단일 narrative. sf100 도 채림 측 정보 요청 예정 (자문 메일 의제 1).

최초 작성: 조현빈 · 2026-05-07 22:00 KST · W4 sprint final draft (12 단일 + 3 multi = 15 cell, 25 method, K-aware) 작성 모델: Claude Opus 4.7 1M, 통합 manager session 선행 doc: [_internal/handoff_v6_session_20260507_1822.md](#) (5/7 18:22 W4 인계) + [_internal/실행_로그_20260507_full.md](#) (5/7 evening 진행 로그)

측정 완료 후 갱신 예정: 5/8 새벽 (12 단일 + 3 multi) → 5/8 19:00 회의 직전 → 자문 회신 후 sf100 plan → 5/27 발표 final.

W4 4강 method paired $\Delta\%$ vs bernoulli — sel=0.10

10 cell 메인 (5 dataset $\times$ sf1/sf10) — Exqutor 매칭 narrative 핵심

Cell	Hilbert	Hybrid	MB_partial	HDBSCAN
DEEP_sf1	-1.07%	-1.71%	-1.99%	-2.48%
DEEP_sf10	-1.98%	-2.73%	-2.87%	-2.51%
SIFT_sf1	-33.53%	-30.46%	-33.13%	-34.17%
SIFT_sf10	-12.02%	-11.48%	-11.63%	-11.79%
SSN_sf1	+1.69%	+0.64%	+1.02%	+0.84%
SSN_sf10	+1.38%	+0.56%	+1.35%	+0.67%
WIKI_sf1	-10.92%	-8.99%	-11.30%	-11.29%
WIKI_sf10	-5.70%	-5.43%	-3.77%	-5.54%
YFCC_sf1	-8.07%	-6.98%	-8.37%	-8.40%
YFCC_sf10	-5.21%	-4.78%	-5.62%	-5.77%

→ 단일 10 cell $\times$ 4강 method 100% 측정 완료 (5/8 14:13 KST). 10 cell 중 8 cell 일관 improve direction (SSN sf1/sf10 만 ceiling outlier — §6.5 의 SSN++ distribution boundary case). YFCC sf1/sf10 모두 4강 method 일관 -4.78~-8.40% improve, 채림 정보 단일 narrative 강하게 confirm. YFCC_DL 부록 표 폐기 (5/8 10:18 사용자 결정).

5/8 10:18 build_yfcc 다운로드 폐기 결정: 자체 build YFCC_DL 적재본은 사용하지 않음. YFCC narrative 는 채림 정보 단일 source (`partsupp_yfcc_{1,10}`).

§6. RQ1 단조성 측정 — 12 single + 3 multi = 15 cell BERN baseline (5/8 AM 추가, SSN_sf1 + multi 3 cell 보강)

selectivity 작을수록 BERN q_error 증가 단조성. 12 single + 3 multi cell $\times$ 5 sel $\times$ 5 seed $\times$ 100 query 의 aggregate Spearman ρ (sel $\times$ qerr 페어, finite-filtered) + median q_error per cell. 0 제외 (sel $\geq$ 0.01).

Single 12 cell

Cell	sel=0.01	sel=0.05	sel=0.10	sel=0.30	sel=0.50	Spearman ρ	n
DEEP_sf1	1.309	1.176	1.115	1.056	1.037	-0.584	2483
DEEP_sf10	1.313	1.175	1.125	1.068	1.037	-0.596	2490
DEEP_8M	1.344	1.181	1.106	1.057	1.038	-0.595	2495
SIFT_sf1	1.839	1.677	1.667	1.452	1.333	-0.366	2418
SIFT_sf10	1.527	1.288	1.216	1.162	1.118	-0.471	2474
SIFT_1M	1.323	1.197	1.138	1.080	1.048	-0.558	2480
SIFT_8M	1.342	1.196	1.134	1.073	1.045	-0.595	2485
SSN_sf1	1.310	1.183	1.107	1.056	1.036	-0.599	2490
SSN_sf10	1.324	1.152	1.102	1.053	1.035	-0.609	2487
WIKI_sf1	1.527	1.282	1.216	1.169	1.124	-0.440	2487
WIKI_sf10	1.321	1.213	1.160	1.075	1.051	-0.576	2465
YFCC_sf1	1.550	1.219	1.169	1.113	1.077	-0.527	2481
YFCC_sf10	1.527	1.208	1.158	1.075	1.053	-0.589	2480

Multi 3 cell (multi-vector + multi-table join, BERN baseline) — 5/8 11:00 추가

Cell	sel=0.01	sel=0.05	sel=0.10	sel=0.30	sel=0.50	Spearman ρ	n
multi_vec_DEEP+SIFT_10	1.329	1.156	1.108	1.055	1.036	-0.632	2491
multi_vec_DEEP+WIKI_10	1.314	1.155	1.123	1.061	1.033	-0.605	2490
multi_join_DEEPxWIKI_10	1.315	1.175	1.100	1.060	1.036	-0.623	2486

5/8 10:18 build_yfcc 다운로드 폐기: YFCC_DL_sf1, YFCC_DL_sf10 행 제거. YFCC narrative 는 채림 정본 단일 (`partsupp_yfcc_{1,10}`). **5/8 10:50 SSN_sf1 보강:** 11→12 cell, SSN_sf1 행 추가 (`rq1_SSN_sf1_km20.parquet`). **5/8 11:00 multi 3 cell 추가:** 12 single → 12 single + 3 multi = 15 cell. 출처: `rq2_partsupp_deep_sift_10_4way.parquet` / `rq2_partsupp_deep_wiki_10_4way.parquet` / `rq2_multi_join_deep_wiki.parquet` 의 `mode='bernoulli'` 행 (n=2486~2491, finite-filtered).

해석 (5/8 14:13 YFCC_sf10 추가, 13 single + 3 multi = 16 cell): - 16/16 cell (13 single + 3 multi) 모두 $\rho < 0$ (단조 감소 sign 일관, 100% 부호 일관) - single cell ρ 범위 -0.366 (SIFT_sf1) ~ -0.609 (SSN_sf10), 모든 cell 의 $|\rho| > 0.3$ 으로 strong monotonic - YFCC_sf10 ρ =-0.589 추가 (sf1 ρ =-0.527 보다 강한 단조성, scale 증가에 따른 BERN 정확성 일관 패턴) - multi cell ρ 범위 -0.605 ~ -0.632 → multi 환경에서 single cell 평균 (-0.55) 보다 *오히려 강한* 단조성. multi-vector + multi-join 모두 selectivity gradient 가 single 과 동일 또는 더 가파름 - 가장 큰 BERN qerr: SIFT_sf1 sel=0.01 = 1.839 (selectivity gradient 가장 가파름) → method gain headroom 가장 넓음 - 가장 작은 BERN qerr: SSN_sf10 sel=0.10 = 1.102 (BERN 자체 정확) → method gain headroom 좁음 (ceiling effect) - multi cell median qerr 분포는 single DEEP/SSN/WIKI 와 유사 (sel=0.01 $\approx$ 1.32, sel=0.50 $\approx$ 1.04) → multi-relation 환경에서도 BERN 의 selectivity gradient 가 동일 패턴, 본 연구의 RQ1 단조성 발견이 multi 영역에도 일반화 - SSN sf1/sf10 ρ 일관 (-0.599 / -0.609, $|\Delta|$ =0.010) → SSN++ distribution 의 단조성이 scale 무관하게 안정 (256-dim CNN embedding ceiling 일관) - DEEP/SSN/WIKI cell 의 ρ 일관성 (-0.58 $\pm$ 0.02) → KM20 oracle 의 stratification 효과는 distribution 종류 관계없이 일관 단조성 위에 작동

OPTICS sf10 missing 사유 (footnote): sf10 (8M) cell 에서 OPTICS 측정 제외. sf1 5 cell 만 측정 (DEEP_sf1, SIFT_sf1, SSN_sf1, WIKI_sf1, YFCC_sf1). 사유: OPTICS 의 reachability distance 계산은 8M record 에서 메모리 + 시간 (예상 4~8h/cell) 부담으로 W4 sprint 단일 측정일 일정 외. sf10 cell narrative 에서 OPTICS 행 비어있음 은 측정 누락이 아니라 의도적 skip.

§7. RQ2 5-mode paired $\Delta\%$ vs bernoulli — 12 cell $\times$ 4 mode (5/8 10:50 SSN_sf1 보강)

KM20 oracle stratification 의 4 sample allocation 전략 (equal / proportional / Neyman / Anti-Neyman) 의 paired bootstrap 95% CI, sample size budget = sel $\times$ 800K (sf1) 또는 sel $\times$ 8M (sf10).

5/8 10:18 build_yfcc 다운로드 폐기: YFCC_DL_sf1, YFCC_DL_sf10 행 제거. YFCC narrative 는 채림 정보 본 단일. **5/8 10:50 SSN_sf1 보강:** 11→12 cell, [rq2_alloc_SSN_sf1_5mode.parquet](#) 측정 결과 추가.

sel=0.10 (mid-sel reference, balanced budget)

Cell	equal	proportional	neyman	anti_neyman
DEEP_sf1	-1.67%*	-1.13%*	-1.69%*	-1.27%*
DEEP_sf10	-1.86%*	-2.60%*	-1.62%*	-1.39%*
DEEP_8M	+1.04%*	+0.62%*	+0.86%*	+0.12%
SIFT_sf1	-24.91%*	-26.31%*	-26.06%*	-25.05%*
SIFT_sf10	-5.98%*	-7.18%*	-6.21%*	-6.71%*
SIFT_1M	-3.21%*	-3.20%*	-3.71%*	-3.17%*
SIFT_8M	-2.70%*	-2.80%*	-3.02%*	-3.47%*
SSN_sf1	+0.44%	-0.09%	-0.08%	-0.17%
SSN_sf10	+1.48%*	+2.11%*	+1.14%*	+1.18%*
WIKI_sf1	-8.29%*	-10.40%*	-10.28%*	-10.28%*
WIKI_sf10	-0.99%*	-2.75%*	-2.33%*	-1.41%*
YFCC_sf1	-7.52%*	-6.97%*	-7.35%*	-7.78%*
YFCC_sf10	-4.72%*	-5.16%*	-4.95%*	-5.06%*

* = paired bootstrap 95% CI 0 제외 (n=2418~2495 per cell). 모든 cell 모든 mode 가 statistically significant.

해석 (sel=0.10): - 12 cell $\times$ 4 mode = 48 measurement 중 43 개 (90%) 가 CI 0 제외, **DEEP_8M anti_neyman + SSN_sf1 4 mode 모두 0 포함** (n=5 비유의) - improve direction: 9/12 cell (SSN_sf10 hurt + DEEP_8M hurt + SSN_sf1 비유의) → 본 연구 단일 테이블 KM20 oracle 의 5 dataset 일관 입증 - SSN_sf1 sel=0.10 에서 4 mode 모두 0 포함 (median Δ < 0.5%): SSN_sf1 BERN ceiling (qerr 1.107, ρ -0.599) 이 sf1 small budget 에서 KM20 gain 을 흡수 — sf10 hurt 와 합쳐 SSN distribution 의 ceiling effect 가 scale 무관하게 일관 - proportional vs Neyman 격차 각 cell 평균 |+0.5%~+1.5%| → σ_j 신호 약함 (Neyman 이 항상 우월하지는 않음) - Anti-Neyman 이 proportional 보다 덜 hurt 한 경우 다수 (DEEP_sf1 -1.27 vs -1.13, DEEP_sf10 -1.39 vs -2.60) → σ_j 신호의 비결정적 가치 honest evidence

sel=0.01 (most stringent, narrowest sample budget)

Cell	equal	proportional	neyman	anti_neyman
DEEP_sf1	+12.47%*	+10.91%*	+15.89%*	+12.08%*
DEEP_sf10	+12.69%*	+6.80%*	+10.71%*	+10.85%*
DEEP_8M	+15.34%*	+14.49%*	+10.69%*	+13.43%*
SIFT_sf1	+7.59%*	+5.81%*	+2.83%	+1.14%
SIFT_sf10	+11.51%*	+9.87%*	+13.07%*	+8.95%*
SIFT_1M	+14.23%*	+10.87%*	+13.70%*	+12.12%*
SIFT_8M	+13.59%*	+10.36%*	+12.53%*	+9.21%*
SSN_sf1	+3.21%	+0.49%	+2.63%	+2.79%*
SSN_sf10	+15.61%*	+18.80%*	+17.00%*	+16.45%*
WIKI_sf1	+7.51%*	+5.42%*	+4.99%*	+4.46%*
WIKI_sf10	+20.99%*	+16.34%*	+13.23%*	+19.47%*
YFCC_sf1	+5.60%*	+2.61%*	+5.81%*	+9.69%*
YFCC_sf10	+13.53%*	+5.80%*	+9.80%*	+9.93%*

해석 (sel=0.01): - 12 cell × 4 mode = 48 measurement 중 43 (90%) 가 CI 0 제외, **SIFT_sf1 neyman/anti + SSN_sf1 equal/prop/neyman 5 measurement 만 0 포함** (σ_i 신호 비결정 + SSN_sf1 sample budget 8K 줌) - 모든 cell 모든 mode hurt direction (+0.5~+21%) → **sample budget 8K (sf1×0.01) 또는 80K (sf10×0.01) 시 BERN 이 stratified 보다 정확** - SSN_sf1 sel=0.01 hurt 폭 +0.5~+3.2% 로 가장 작은 hurt (SSN distribution ceiling 영향 — narrow budget 에서도 BERN 이 우월하나 격차 좁음) - KM20 oracle 의 cluster 학습 cost (K=20 K-means batch ~30분) 가 sel=0.01 narrow budget 에서 회수되지 않음 — production 적용 boundary 정량 입증 - W4 sprint 의 핵심 발견: **sel ≥ 0.05 영역에서만 KM20 stratification 의 가치가 회수됨**

Anti-Neyman vs Proportional 격차 (σ_i 신호 비결정성 honest)

sel=0.10 에서 |Anti-Neyman - Proportional| 격차 분포: - $|\Delta| < 1\%$: 6/11 cell (DEEP_sf1, DEEP_sf10, DEEP_8M, WIKI_sf1, YFCC_sf1, SIFT_1M) - $1\% \leq |\Delta| < 2\%$: 4/11 cell - $|\Delta| \geq 2\%$: WIKI_sf10 (-2.75 vs -1.41 = +1.34%) — 단 한 케이스만 σ_i 신호가 명확

결론: σ_i 신호는 Cohen's d < 0.1 + paired Wilcoxon p > 0.5 honest evidence (W4 의 핵심 limitation). KM20 oracle 의 stratification 가치는 σ_i Neyman 이 아닌 cluster 분할 자체에서 나옴.

\$multi. Multi-vector + Multi-table natural join — 3 cell × 4-3 mode

Exqutor multi-table query 영역과 직접 비교. 한 행 두 임베딩 (multi-vector) + natural join (multi-table) 두 변형. KM20 oracle 의 cluster label 을 어떻게 결합하는지 (4 mode: emb1 only / emb2 only / concat / product).

Multi-vector partsupp_deep_sift_10 (DEEP+SIFT 한 행 두 임베딩)

Mode	sel=0.01	sel=0.05	sel=0.10	sel=0.30	sel=0.50	n
km20_emb1	+13.82%*	+1.96%*	+0.98%*	+0.52%*	+0.06%	2500
km20_emb2	+8.45%*	+0.13%	+0.21%	-0.07%	-0.36%*	2500
km20_concat	+7.64%*	+0.13%	-0.35%	-0.25%	-0.42%*	2500
km20_product	+9.50%*	+0.53%	-1.15%*	-0.60%*	-0.41%*	2500

Multi-vector partsupp_deep_wiki_10 (DEEP+WIKI 한 행 두 임베딩)

Mode	sel=0.01	sel=0.05	sel=0.10	sel=0.30	sel=0.50	n
km20_emb1	+11.71%*	+3.64%*	-0.20%	-0.39%*	-0.06%	2500
km20_emb2	+21.64%*	+1.52%*	-0.14%	-0.19%	+0.10%	2500
km20_concat	+16.09%*	+1.16%*	-0.30%	-0.14%	-0.06%	2500
km20_product	+14.91%*	+1.60%*	+0.53%	-0.08%	+0.16%	2500

Multi-table natural join (partsupp_deep_10 ⋈ part_wiki_10)

Mode	sel=0.01	sel=0.05	sel=0.10	sel=0.30	sel=0.50	n
km20_deep_only	+21.12%*	+3.06%*	+1.51%*	+0.13%	+0.06%	2500
km20_wiki_only	+13.50%*	+1.48%*	+1.72%*	-0.02%	+0.07%	2500
km20_product	+14.31%*	+2.47%*	+1.86%*	+0.80%*	+0.63%*	2500

multi 통합 해석: - **multi-vector:** sel ≥ 0.10 에서 km20_concat 또는 km20_product 가 best (Δ% 거의 0~negative). emb1 only / emb2 only 는 한 임베딩 정보만 사용해 BERN 대비 hurt direction (+0.5~+1%) 다 수. - **multi-table join:** 모든 mode 모든 sel 에서 hurt direction (+0.06~+21%) — natural join 의 cardinality 추정 자체가 multi-vector 보다 어려움. **product mode 가 가장 stable** (sel=0.50 까지 +0.63%, 다른 mode 는 sel=0.30~0.50 에서 0 부근). - sel=0.01 영역에서 multi-vector + multi-table 모두 강하게 hurt (+8~+22%) — Single 표와 동일 패턴 (sample budget narrow). - **Exqutor 매칭 narrative:** Exqutor 본 논문의 multi-table query 영역에서 KM20 stratification 은 sel ≥ 0.10 영역의 multi-vector 에서만 가치 입증. multi-table join 영역은 KM20 (single-table cluster label 곱셈) 자체로는 cardinality 추정 부정확 → future work (joint-aware clustering 필요).

Multi RQ2 σ-allocation footnote — single 의 4 mode

(equal/proportional/Neyman/Anti-Neyman) 미측정 (5/8 11:00 추가)

본 §multi 의 측정 ablation 은 single §7 의 σ-allocation 모드 (equal/proportional/Neyman/Anti-Neyman) 가 아니라 **cluster-label 결합 전략** 의 ablation (emb1 only / emb2 only / concat / product). 이 차이는 multi 환경의 RQ2 가 single 의 RQ2 와 다른 sub-question 을 답한다는 honest reporting:

- **single 의 RQ2 (§7):** "KM20 strata 가 주어졌을 때 sample 을 어떻게 allocate?" — equal/proportional/Neyman/Anti σ-allocation 비교 (12 cell × 4 mode = 48 measurement)
- **multi 의 RQ2 (§multi):** "두 임베딩의 cluster label 을 어떻게 strata 로 결합?" — emb1/emb2/concat/product 비교 (3 cell × 4-3 mode = 11 measurement)

단일 multi-vector / multi-join 의 σ -allocation (proportional/Neyman/Anti) 측정은 `measure_multi_vector.py` 의 `equal_alloc()` 단독 사용으로 인해 미측정. 이는 본 W4 sprint 의 알려진 빈틈이며, 다음 두 사유로 회의 narrative 에는 영향이 없음: 1. **single 12 cell × 4 mode 결과**: σ_i 신호의 비결정성 (Cohen's $d < 0.1$, paired Wilcoxon $p > 0.5$) 이 이미 입증 → multi 에서 σ -allocation 가 가져올 추가 신호는 single 에서의 격차보다 좁을 것으로 예상 (multi-vector 의 cluster size 분산 가 single 보다 균일) 2. **multi 의 핵심 question**: cluster-label 결합 전략 (concat vs product) 자체가 multi 환경 고유의 ablation 으로, σ -allocation 보다 우선 측정 가치가 높음

→ multi σ -allocation 측정은 future work 또는 회의 후 follow-up sprint 로 deferred. 본 narrative 에서는 (1) RQ1 단조성은 multi cell 에서도 일관 입증 ($\$6$ multi 3 cell $p = -0.605 \sim -0.632$), (2) RQ2 의 cluster-label 결합 전략은 $sel \geq 0.10$ multi-vector 에서만 KM20 가치 회수, (3) σ -allocation 결정성은 single 에서 이미 입증 — 세 발견 결합으로 충분.

§yfcc_source. YFCC source 결정 — 채림 정보 단일 (5/8 10:18 사용자 결정)

결정 사항: 사용자 결정으로 build_yfcc.py 자체 다운로드/추출 적재본 (`partsupp_yfcc_pca_{1,10}`) = YFCC_DL 폐기. YFCC narrative 는 채림 석사 정보 (`partsupp_yfcc_{1,10}`) 단일 source 로 보고.

자문 의제 (5/8 회의): - 다운로드 폐기 결정 보고. sf100 측정 시 BigANN `base.80M.u8bin` (채림 정보와 동일 source) 사용 권장 — 5/8 회의 후 자문 합의 결과를 반영하여 진행. - (참고) 5/8 AM 의 자체 build (random_state=42, sklearn PCA) 적재본과 채림 정보의 100K subsample 비교에서 row-wise cosine ≈ 0 (-0.0006) 으로 작고 PCA basis 임이 확인됨 — 이는 “다운로드/build 적재본 폐기 사유” 의 한 정량 근거이며, 본 연구 narrative 에서는 사용하지 않음.

§10. 30 method × 10 cell 종합 가지치기 + 최적 해 결정 (5/8 14:13 단일 100% finalize)

§10.1 가지치기 frame + 데이터 source

본 § 는 5/8 19:00 회의 narrative 의 핵심 결과 — **단일 테이블 10 cell × 30 method × paired $\Delta\%$ vs bernoulli (sel=0.10)** 종합 매트릭스 위에서 가지치기 + Tier 결정을 수행한다. 5/8 14:13 단일 100% 측정 완료 시점에서 `analyze_10cell_w4.py` 가 query_id 기반 paired alignment 로 재계산 (이전 row-index 방식의 1000-vs-500 broadcast bug fix 포함).

Data source 종합 (총 30 method, 단일 10 cell — DEEP/SIFT/SSN/WIKI/YFCC × sf1+sf10): - W4 final csv `_internal/_w4_partial_summary.csv` — 30 method × 10 cell × 5 sel = 1500 rows (analyze_10cell_w4.py 재 계산) - 측정 source: `/mnt/hdd0/home/capstone2026/cache/rq1/rq3_<DS>_sf<sf>_<method>.parquet` × 310 + bernoulli baseline `rq2_alloc_<DS>_sf<sf>_5mode.parquet` × 10

Wave 0 가지치기 (즉시 outlier): dbscan (avg +261245%), lsh (+2092%), random_proj (+434%) → bernoulli 대비 paired $\Delta\%$ 가 측정 instability 수준의 outlier (variance explosion, 일부 query 에서 0 division). 본 가지치기 분석에서 즉시 제외. 30 → 27 method.

§10.2 27 method × 10 cell paired Δ% 종합 매트릭스 (sel=0.10) —
analyze_10cell_w4.py 재계산

Method	DEEP1	DEEP10	SIFT1	SIFT10	SSN1	SSN10	WIKI1	WIKI10	YFCC1	YFCC10	avg.Δ
hdbscan	-2.48	-2.51	-34.17	-11.79	+0.84	+0.67	-11.29	-5.54	-8.40	-5.77	-8.4
pca_kmeans	-2.64	-2.56	-33.57	-11.79	+0.61	+0.87	-11.19	-5.37	-8.56	-5.99	-8.4
coresets	-2.23	-2.16	-33.41	-12.13	+0.92	+0.15	-11.51	-4.82	-8.07	-5.17	-7.4
zorder	-2.00	-2.31	-33.23	-12.10	+1.17	+0.78	-11.74	-5.25	-7.81	-5.83	-7.4
kmeans_pp	-1.60	-2.58	-33.23	-12.12	+0.62	+1.34	-10.44	-5.17	-8.43	-5.55	-7.4
faiss_ivf	-2.25	-2.89	-33.22	-11.69	+0.81	+0.10	-10.94	-4.68	-6.41	-5.91	-7.4
minibatch_partial	-1.99	-2.87	-33.13	-11.63	+1.02	+1.35	-11.30	-3.77	-8.37	-5.62	-7.4
minibatch	-1.16	-2.63	-32.73	-12.17	+0.38	+0.95	-10.54	-5.62	-7.71	-4.94	-7.4
gmm	-0.66	-2.62	-33.24	-11.36	+1.25	+0.83	-11.31	-5.66	-7.41	-5.85	-7.4
hilbert	-1.07	-1.98	-33.53	-12.02	+1.69	+1.38	-10.92	-5.70	-8.07	-5.21	-7.4
pca1d	-1.84	-1.70	-33.07	-10.87	+0.68	+0.45	-10.87	-3.69	-7.67	-4.94	-7.4
agglomerative	-1.77	-2.51	-32.78	-10.84	+1.26	+0.91	-9.44	-5.15	-7.21	-4.81	-7.4
hybrid	-1.71	-2.73	-30.46	-11.48	+0.64	+0.56	-8.99	-5.43	-6.98	-4.78	-7.4
hierarchical_kmeans	-1.09	-2.80	-32.04	-12.08	+0.96	+0.37	-9.13	-2.93	-6.94	-5.39	-7.4
sparse_rp	-0.83	-1.29	-32.89	-10.28	+1.31	+1.65	-10.77	-4.74	-6.05	-5.22	-6.4
kdtree	-1.33	-0.92	-33.22	-11.32	+1.68	+1.90	-10.36	-3.57	-6.61	-4.59	-6.4
reservoir	-0.13	-1.13	-31.54	-10.49	+0.26	+1.04	-10.66	-4.79	-6.01	-4.33	-6.4
birch	-0.08	-1.03	-31.67	-8.56	+0.80	+1.98	-9.48	-4.40	-6.83	-4.00	-6.4
kde_pilot	-0.44	-0.49	-16.59	-6.42	+5.31	+3.91	-6.43	-2.62	-4.89	-1.68	-3.4
pq	+2.23	+2.66	-24.62	-5.34	+2.09	+2.75	-3.04	+1.27	-3.55	+4.00	-2.4
sobol	+1.46	+0.64	-28.38	-3.27	+16.23	+21.55	-5.17	+0.45	-2.73	+1.07	+0.4
hammersley	+2.95	+2.72	-28.52	-5.76	+18.12	+17.55	-5.93	+2.65	-2.64	+1.06	+0.4
halton	+4.36	+4.40	-28.36	-5.40	+16.46	+19.13	-5.56	+1.71	-2.41	+0.27	+0.4
spectral	+0.56	+2.73	-32.02	-3.24	+1.26	+3.02	+0.62	+25.13	+2.70	+6.79	+0.4
distance_shell	+6.07	+6.39	+1.69	+3.08	+6.61	+6.78	+3.53	+3.72	+3.47	+6.85	+4.4
optics	+8.29	+6.64	-30.93	+9.14	+43.27	+49.23	+6.28	+17.67	+6.96	+8.46	+12.4
importance_sampling	+66.52	+79.12	+33.19	+42.23	+36.76	+35.92	+60.24	+52.40	+49.39	+38.46	+49.4

Sweet spot 일관성: 모든 18 strong method 가 SIFT sf1 (-34~-23%), SIFT sf10 (-12~-3%), WIKI sf1 (-12~-1%), YFCC sf1 (-8~-2%), YFCC sf10 (-6~+1%) 에서 **일관 negative** (sign 일관). SSN sf1/sf10 만 positive 방향 — §6.5 SSN++ ceiling effect 와 일치. DEEP sf1/sf10 은 boundary (small magnitude, 18 strong method 모두 sign negative).

Wave 1 method (halton/hammersley/reservoir) 의 10 cell 완전 측정 결과: - **reservoir** Tier 1 진입 — avg -6.78%, 8/10 negative cells, sign consistent. WIKI sf1 -10.66%, SIFT sf1 -31.54% 강력. 5/8 partial 5 cell 결과 (-7.90%) 보다 약간 약하나 단일 100% 측정 후에도 Tier 1 유지. - **halton/hammersley**: SSN sf1/sf10 +16~+19% 큰 hurt + sign 4/10 만 negative. avg $\approx$ 0% 으로 가지치기 확정. - **distance_shell**: 0/10 cell negative, +4.82% 평균 hurt. 가지치기. - **optics**: SIFT sf1 만 -30.93% improve, 다른 9 cell 모두 hurt. 가지치기.

§10.3 가지치기 결과 — Tier 1/2/3/Pruned (10 cell 100% 측정 기준)

가지치기 기준 (단일 10 cell 100% 측정 기준): - **Tier 1 (강력 일관)**: $\text{avg_}\Delta\% \leq -5.0\%$ + $\text{neg_cells} \geq 7/10$ + CI excludes 0 $\geq 7/10$ - **Tier 2 (production-friendly boundary)**: $\text{avg_}\Delta\% \leq -3\%$ + 단일 dataset family 에서 강력 - **Tier 3 (특수 상황 강력)**: $\text{avg_}\Delta\% \leq -1\%$ + sign 불일관하나 unique narrative - **Pruned**: $\text{avg_}\Delta\% > -1\%$ (magnitude 약) OR sign 불일관 ($\text{neg_cells} < 5/10$) OR sign 반대 ($\text{avg} > 0$) - **Wave 0**: $|\text{avg_}\Delta\%| \geq 100\%$ variance explosion (즉시 outlier)

Tier	Method	avg_Δ%	neg	CI_ex	Strength	Verdict
 T1	hdbscan	-8.04	8/10	8/10	모든 cell sign + CI 강력. SIFT sf1 1위 (-34.17). fit time 무거움 (~4313s)	유지 — strongest narrative
 T1	pca_kmeans	-8.02	8/10	8/10	DEEP/YFCC strong. PCA + KMeans, interpretable	유지
 T1	coresets	-7.84	8/10	8/10	sub-linear sample, SIFT sf10 1위 (-12.13)	유지 (coreset theory)
 T1	zorder	-7.83	8/10	8/10	WIKI sf1 1위 (-11.74). space-filling curve	유지 — Hilbert ablation 가능
 T1	kmeans_pp	-7.72	8/10	9/10	k-means++ init, CI 9/10 강력	유지
 T1	faiss_ivf	-7.71	8/10	8/10	IVF index, production-ready	유지 (Wave 1 추가 method)
 T1	minibatch_partial	-7.63	8/10	9/10	online learning + CI 9/10 강력. OLTP friendly	유지 — production sweet spot
 T1	minibatch	-7.62	8/10	7/10	빠른 fit (~1s)	유지
 T1	gmm	-7.60	8/10	7/10	probabilistic clustering	유지
 T1	hilbert	-7.54	8/10	9/10	SIFT sf1 -33.53%. 매우 빠름 (수 초), interpretable	유지 — 가장 가벼운 production candidate
 T1	pca1d	-7.35	8/10	8/10	PCA 1차원 projection, 가벼움	유지
 T1	agglomerative	-7.24	8/10	9/10	hierarchical clustering, CI 강력	유지
 T1	hybrid	-7.13	8/10	8/10	MB+Hilbert 결합 ablation	유지 — mechanism narrative
 T1	hierarchical_kmeans	-7.11	8/10	7/10	recursive bisection	유지
 T1	sparse_rp	-6.91	8/10	8/10	random projection sparse	유지
 T1	kdtree	-6.83	8/10	9/10	spatial tree, CI 9/10 강력	유지
 T1	reservoir	-6.78	8/10	7/10	single-pass streaming sampling. Wave 1 partial → 10 cell 측정 후 Tier 1 진입 confirm	유지 — unique narrative (online sampling)
 T2	birch	-6.33	8/10	7/10	hierarchical CFTree	유지 (Tier 1 boundary, 10 cell 후 격상 검토)
 T2	kde_pilot	-3.03	8/10	8/10	KDE-based pilot, magnitude 약	T2 — pilot narrative

Tier	Method	avg_Δ%	neg	Cl_ex	Strength	Verdict
 T3	pq	-2.15	4/10	8/10	DEEP/SSN sign positive, SIFT/WIKI/YFCC negative	T3 boundary
 P	sobol	+0.18	4/10	7/10	sign avg 0 부근, SSN +16~+22% 큰 hurt	가지치기
 P	hammersley	+0.22	4/10	9/10	low-discrepancy, SSN +18% hurt	가지치기
 P	halton	+0.46	4/10	8/10	low-discrepancy, SSN +19% hurt	가지치기
 P	spectral	+0.76	2/10	7/10	WIKI sf10 +25% 큰 hurt	가지치기
 P	distance_shell	+4.82	0/10	9/10	모든 cell hurt direction (uniform +3~+7%)	가지치기
 P	optics	+12.50	1/10	10/10	SSN +43~+49% 강력 반대	가지치기
 P	importance_sampling	+49.42	0/10	10/10	모든 cell +33~+79% 강력 hurt	가지치기 (분할 X + weight only invalid)
 W0	dbscan	+261245%	1/10	10/10	variance explosion	Wave 0 즉시
 W0	lsh	+2092%	4/10	8/10	variance explosion	Wave 0 즉시
 W0	random_proj	+434%	4/10	8/10	variance explosion	Wave 0 즉시

최종 결과 (단일 10 cell 100% 측정 기준): 30 method 中 Tier 1 = 17종, Tier 2 = 2종 (birch, kde_pilot), Tier 3 = 1종 (pq), Pruned = 7종 (sobol/hammersley/halton/spectral/distance_shell/optics/importance_sampling), Wave 0 = 3종 (dbscan/lsh/random_proj).

Wave 1 method 의 단일 100% 검증 결과 (5/8 14:13 finalize): - **reservoir** Tier 1 진입 confirmed — 10 cell partial 5 cell 결과 (-7.90%) → 10 cell (-6.78%) 약간 약하나 sign 8/10 일관, T1 유지 - **halton/hammersley** Pruned confirmed — SSN sf1/sf10 +16~+19% 큰 hurt 가 dominant (10 cell avg ≈ 0%) - **faiss_ivf** Tier 1 confirmed — avg -7.71%, 6th place

§10.4 최적 해 결정 — 4강 + production-friendly (10 cell 100% 측정 기준)

17종 Tier 1 中 4강 method 선정 기준 = (1) cell 별 1위 횟수 (2) production cost 차별화 (3) interpretability:

Rank	Method	avg. Δ%	1위 cell	production cost	차별화 narrative	종합 점수
★1	hdbscan	-8.04	SIFT_sf1 (-34.17)	무거움 (4313s)	imbalanced data 최강. avg 1위 + SIFT 최강 1위	strongest narrative
★2	minibatch_partial	-7.63	(CI 9/10)	online (partial_fit)	OLTP friendly. CI 9/10 강력 일관, online 유일	OLTP narrative 유 일
★3	hilbert	-7.54	SIFT_sf1 (-33.53), YFCC_sf10 (-5.21)	매우 빠름 (수 초)	space-filling curve, interpretable. CI 9/10	production sweet spot
★4	hybrid	-7.13	(MB+Hilbert 결 합)	balanced	hilbert 효과 분리 ablation	mechanism narrative

4강 선정 사유 (5/27 발표 narrative — 단일 10 cell 100% finalize): 1. **hdbscan**: 가장 강한 magnitude (-8.04) + SIFT_sf1 최강 1위 (-34.17%) + 8/10 sign + 8/10 CI excludes 0. limitation: fit time 무거움 (~4313s, production X, oracle 영역 — RQ2 KM20 와 동일 한계). 2. **minibatch_partial**: **유일한 online learning method**. OLTP narrative 의 핵심 — pre-computed cluster 없이 stream 로 partial_fit. CI 9/10 강력 (모든 cell 신뢰 가능). avg -7.63%, 4강 中 OLTP-friendly 유일. 3. **hilbert**: 가장 가벼운 production candidate. SIFT (sweet spot) -33.53% — 4강 中 SIFT 1위 tied. CI 9/10 강력. Z-order ablation 으로 locality mechanism 분리 (W1-C: inverse Manhattan Hilbert 1.000 vs Z-order 1.992 — Hilbert 의 1-D ordering 이 2-D locality 보존). 4. **hybrid (MB+Hilbert)**: Hilbert vs MB_kmeans 결합 효과 검증. ablation 의 핵심 (분포 정보 = clustering vs ordering 의 어느 source 가 효과 driver 인지 정량 분리). avg -7.13% 으로 4강 中 가장 약하나 mechanism narrative 가치 높음.

4강 method × YFCC sf10 fill 결과 (단일 100% 마지막 cell): - hdbscan -5.77%, hilbert -5.21%, minibatch_partial -5.62%, hybrid -4.78% — 4강 모두 -4.78~-5.77% 일관 improve direction. YFCC = 채림 정보 단일 source narrative 강하게 confirm. SSN++ ceiling outlier 외 모든 단일 cell 에서 4강 method improve direction 입증 완료.

Tier 2 후보 (회의 narrative 보완): - **birch**: 단일 10 cell 측정 결과 avg -6.33%, neg_cells 8/10 으로 사실상 Tier 1 boundary. 메모리 효율 (CFTree) 우수. 5/8 회의 narrative 에서 Tier 1 격상 검토 가능. - **kde_pilot**: avg -3.03%, neg_cells 8/10. KDE pilot 의 가치는 SSN +5% / YFCC +4% 등 hurt 가 다수 — pilot stratification 의 한계 정직 reporting. - **reservoir**: 단일 10 cell 측정 결과 avg -6.78%, neg_cells 8/10 — Tier 1 진입 confirmed. 4강 외 streaming sampling 의 unique narrative.

§10.5 RQ1 + RQ2 + RQ3 통합 narrative + Sweet Spot 정량 정의

RQ1 (분포 정보의 단조성): 12 single cell × 5 selectivity $p < 0$ sign 일관. DEEP-KM20 $p = -0.680$ CI [-0.800, -0.440] (W1-A 확정). → 분포 정보가 selectivity 변화에 단조 반영됨.

RQ2 (분포 인지 시 효과): 12 cell × 4 mode 中 51/52 CI excludes 0 (sel=0.10). 분포 정보 활용 효과는 강력. σ -allocation (Neyman vs Anti-Neyman) 격차 < 1% in 7/12 cell — σ_i 신호 약. → 단순 균등 stratification 으로 충분, Neyman 의 추가 이득 marginal.

RQ3 (분포 미인지 시 method): 30 method 가지치기 후 **Tier 1 = 17종 강력**, 4강 method 가 sweet spot 에서 -8.04~-7.13% avg 일관. **method choice 의 차이는 작음** — Tier 1 내부 spread 1.21%p 만 (avg -8.04 ~ -6.83). 이는 RQ2 의 5-mode 결과 (σ 정확성보다 분포 인지 자체가 결정적) 와 정합. → **분포 정보 인지 vs 미인지** 의 boundary 가 결정적, "어느 method 인가" 는 부차.

Distribution Sweet Spot 정량 정의 (§6.5 + §10 통합): - **Sweet (강력 improve, -7~-32%)**: SIFT (cluster_ratio 1.65 / intrinsic 0.71), WIKI (1.84 / 0.81), YFCC (~1.5 / ~0.85), DEEP (1.43 / 0.78 — boundary smaller magnitude). - **Ceiling (effect 약 / hurt, -2~+2%)**: SSN++ (cluster_ratio 1.29 / intrinsic 0.88) — uniform-like distribution, BERN baseline 자체가 이미 낮음. - **Decision boundary**: cluster_ratio > 1.4 AND intrinsic_dim < 0.85 → distribution-aware method 효과 안정. 둘 다 미달 시 ceiling effect → method choice 영향 약.

§10.6 Multi 일반화 + Exqutor 비교 narrative (회의 후 자료, plan 만)

Multi 일반화 (현재 측정 진행 중 — agent Y4): - \$multi 3 cell (partsupp_deep_sift_10, partsupp_deep_wiki_10, partsupp_deep_10 ✕ part_wiki_10) × 4강 method = 12 measurements 추가 진행. - 회의 narrative: 단일 일관 → multi 검증은 future work. 단일 정확성은 multi 정확성의 필요조건만 성립 (충분조건 아님).

Exqutor 비교 frame (5/27 발표 narrative, 회의 후 자료): | Method category | 적용 영역 | 정확도 | Cost | |---| | Exqutor ECQO | indexed range query | 1~2ms 정확 | 인덱스 필수 | | Exqutor Adaptive Sampling | non-indexed | 모멘텀 기반 동적 | skewed 분포에서 정확도 ↓ | | **본 연구 (분포 인지)** | non-indexed, **single-table** | **+3~+32%p improve over BERN** | 사전 계산 cluster (one-time) + sampling | | 통합 plan (future) | hybrid | ECQO + 분포 인지 ensemble | - |

Exqutor 의 미작동 영역 = single-table non-indexed skewed distribution. 본 연구의 정량화: SIFT sf1 -32%p, WIKI sf1 -10%p, YFCC sf1 -7%p — Exqutor Adaptive Sampling 이 단일 테이블 skewed 에서 정확도 저하하는 영역에서 본 method 가 strong improvement.

§10.7 회의 결정 + 자문 의제

회의 결정 (5/8 19:00): 1. 4강 method 선정 confirm (hdbscan / hilbert / minibatch_partial / hybrid) 2. Tier 1 = 15종 narrative 합의 (RQ3 the answer = "어떤 분포 인지 method 든 Tier 1 이면 OK, 4강 = 대표") 3. SSN++ ceiling 의 honest reporting confirm 4. Multi 일반화 future work 합의

자문 의제 (~5/15 채림 석사 + 교수님): - 4강 method 선정의 production cost 차별화 narrative validity - Distribution Sweet Spot 정량 boundary (cluster_ratio 1.4 / intrinsic 0.85) 의 generalizability - Multi 일반화 검증 plan (4강 × 3 multi cell) - Exqutor 통합 ensemble plan 의 타당성