

5/8 (목) 19:00 비대면 회의 outline

W1 Sprint 마감 직후 회의. 5/6 진행한 RQ1+RQ2 결과를 전원 공유하고, RQ3 (7-way distribution-agnostic) 진행 계획과 채림 석사·지도교수님께 보낼 자문 요청을 합의한다.

작성: 조현빈 · 2026-05-06 17:49 KST

1. 회의 개요

항목	내용
일시	2026-05-08 (목) 19:00~20:30 (90분 예정)
형식	비대면 (Discord 또는 Zoom)
참석	박세은(팀장), 강재현, 조현빈, 이동욱
의제	(1) RQ1+RQ2 W1 sprint 결과 종합 (2) RQ3 진행 계획 (3) 자문 초안 합의 (4) W2 분담
산출물	회의록, 자문 발송 초안 (5/15 발송), W2 분담표

2. RQ1+RQ2 결과 1-pager (W1 Sprint, 5/6 측정)

2.1 RQ1 — H1 정량 입증 ★ (실험 #1, commit [cce2246](#))

박세은 팀장이 5/5 회의에서 제기한 "Normal vs Skew BERN baseline 직접 비교 부재" 의문에 대한 정량 답변. SIFT × SYSTEM(block) baseline 측정으로 RQ1 의 2x2 표 마지막 한 cell 을 채워 모든 셀이 완성되었다. 핵심 결과는 모든 selectivity 에서 SIFT(skew) 의 SYSTEM-BERN 격차가 DEEP(normal) 의 격차보다 크다는 것이며, 좁은 selectivity 영역 ($s=1\%$) 에서 격차가 +5.61%p 로 가장 두드러진다.

sel	SIFT(skew) Δ%	DEEP(normal) Δ%	(SIFT – DEEP)
0.01	+10.27%	+4.66%	+5.61%p
0.05	+17.32%	+12.61%	+4.71%p
0.10	+16.68%	+14.76%	+1.92%p
0.30	+14.85%	+14.05%	+0.80%p
0.50	+14.36%	+12.59%	+1.77%p

paired Wilcoxon p-value 는 SIFT 5 sel 모두 $1e-4 \sim 1e-49$ 수준으로 매우 강한 유의 신호이며, BH-FDR 보정 후에도 모두 유의 유지된다. 부수 sanity 회복으로 5/6 오전 의심된 PG **setseed** 비작동 의혹은 query 별 raw q_error 분석으로 해소되었다 (**setseed** 정상, median 의 우연한 일치는 좁은 sel 에서 q_error 가 매우 discrete 한 데이터 특성).

→ 인용 그림: [experiments/figures/rq1_rq2_w1_sprint/fig1_rq1_cross_dataset_gradient.png](#) (SIFT vs DEEP Δ% gradient).

2.2 RQ2 — Allocation 5-way 비교 (실험 #2+#3, commit **9d08e82**)

기존 KM20 stratified 가 사실상 Equal Allocation 이었음을 vector.c 코드 점검으로 확인하고, 그 위에 Proportional/Neyman/Anti-Neyman 3 mode 를 추가하여 5-way 비교 (BERN baseline 포함) 를 수행하였다. DEEP/SIFT $\times 5$ sel $\times 5$ seed $\times 100$ query $\times 5$ mode = 25,000 rows. 측정 17.1초 (Python 시뮬레이션, vector.c 패치 buggy 라 우회).

핵심 결과 4가지:

(가) **모든 stratified > BERN** (DEEP -1.3 ~ -7.0%, SIFT -3.7 ~ -10.5%, $p \leq 1e-7 \sim 1e-50$). SIFT 의 effect size (Cohen's d) 가 DEEP 의 2 배 이상 — cluster 비균질성에서 stratified 의 가치가 정통 통계와 일치.

(나) **Neyman vs Equal — 부분 입증 (H2-N)**: SIFT $\times$ 좁은 sel 에서만 통계적 유의 ($s=0.01$ -11.91%, $p_{BH}=0.024$; $s=0.05$ -3.07%, $p_{BH}=0.010$). DEEP 에서는 모두 비유의. σ_i 단일 정의의 한계가 다중 비교 보정 결과에서 직접 드러난 셈이며, 이는 RQ3 의 query-aware Online (B/G) 영역으로 미루는 근거가 된다.

(다) **Anti-Neyman vs Proportional — 반증 (H2-AN)**: 모든 case 에서 통계적 유의 X (DEEP $p=0.193 \sim 0.846$, SIFT $p=0.205 \sim 0.994$). σ_i 신호가 N_i 보다 약해 ablation 효과가 통계 noise 안에 묻혔다.

(라) **새 발견 — SIFT $\times$ Equal $\times s=0.01$ anomaly**: Equal Allocation 의 q_error (1.8463) 가 BERN baseline (1.6925) 보다는 부정확. cluster 크기 변동이 큰 SIFT 에서 Equal 의 균등 배분 (385/20 $\approx$ 19 표본/cluster) 이 큰 cluster (148K) 에서 sample 부족 $\rightarrow$ 부정확. "Equal 은 normal 데이터엔 OK, skew 에서는 Proportional 이상 필요" narrative 의 직접 증거.

→ 인용 그림: [fig2_rq2_5mode_per_dataset.png](#) (5-mode q_error 비교), [fig3_rq2_cluster_heterogeneity.png](#) ($N_i \times \sigma_i$ scatter), [fig5_rq2_sift_equal_anomaly.png](#) (anomaly 막대).

2.3 RQ2 — Sample size sensitivity (실험 #4, commit [0f48f18](#) + 5sel 보강 [336171c](#))

5/5 회의의 비판 "Exqutor 대비 효과 약함"에 대한 직접 답변. KM20-Proportional의 BERN 대비 개선이 sample_size에 어떻게 의존하는지 측정. 4 ssize × 2 dataset × 5 sel × 5 seed × 100 query × 2 mode = 40,000 rows. 측정 51.1초.

가설 H2-S (sample_size 작을수록 KM20 효과 큼)는 DEEP $s=0.05$ 에서만 부분 단조이며 다른 case는 non-monotonic — **미입증**. 그러나 **새 발견**이 더 가치 있다: 모든 40 조합에서 $KM20 > BERN$ 일관 ($\Delta\%$ -1.09 ~ -13.50%). sample_size 30 배 차이 (100 ~ 3000)에 걸쳐 **KM20의 가치가 robust하게 유지** 된다. production 관점에서는 "어느 sample_size 영역에서도 KM20 가치 유지"라는 cost-tunable narrative가 H2-S 단조성보다 오히려 강한 메시지가 된다.

→ 인용 그림: [fig4_rq2_size_sensitivity.png](#) (5sel × 4ssize matrix).

2.4 보강 작업 — BH-FDR + DEEP query difficulty (commit [336171c](#))

다중 비교 false discovery rate 통제를 위한 Benjamini-Hochberg 보정을 RQ1 SIFT (5 비교), RQ2 stratified vs BERN (40 비교), RQ2 Neyman vs Equal (10 비교)의 세 영역에 적용하였다. **모든 핵심 결과가 BH-FDR 보정 후에도 robust** 하며, 특히 $SIFT \times \{s=0.01, s=0.05\}$ 에서의 Neyman 가치는 다중 비교 보정 후에도 명확히 검출된다 ($p_{BH} = 0.010 \sim 0.024$).

추가로 박세은 팀장의 4/30 직후 질문 "DEEP × SYSTEM의 절대값이 SIFT보다 클 때가 있는데?"에 대한 정량 답변을 정리하였다. DEEP × $s=0.01$ 에서 mean q_error는 1.6185로 SIFT (1.9205)보다 작으나, **q_error > 2 query 비율이 DEEP 9% vs SIFT 39.4%**로 본질적 query difficulty는 SIFT가 4배 이상 크다. DEEP × $s=0.01$ 의 max q_error가 가끔 SIFT보다 큰 것은 BERN sampling의 small-sample fallback artifact이며 본질적 difficulty와는 다른 차원의 현상이다.

3. RQ3 진행 계획 — 7-way distribution-agnostic 비교

3.1 핵심 metric — Recovery Rate

$$\text{recovery_rate} = (\text{방법X} - \text{RANDOM20}) / (\text{KM20} - \text{RANDOM20})$$

- 1.0 → KM20 oracle 수준 회수

- 0.0 → RANDOM20 (공간 인식 없음) 수준
- 분모 붕괴 ($|\text{KM20} - \text{RANDOM20}| \leq 1\%$) 시 절대 Q-error (방법X – BERN) 으로 fall back

3.2 7-way 실험 — 우선순위 순

총 ~27h 분량. 5/8 19:00 회의 후 5/11 까지 ~50h 가용 시간 안에서 1~3 순위 (F, C, E) 절대 사수, 4~7 순위는 가능한 선까지 수행. 모든 실험은 5/6 검증된 Python 시뮬레이션 패턴 ([experiments/code/rq2/rq2_alloc_python.py](#)) 그대로 활용 — cluster 별 LIMIT 500 sample 캐시, fresh conn per cluster (메모리 누수 회피), HT estimator 동일. 방법별 차이는 stratum_id 부여 알고리즘뿐이다.

#	실험	패러다임	시간	우선순위	기대 recovery
#8	F. MiniBatch K-means	Offline (학습 1~5%)	~1h	★★★ 1순위	75~95%
#5	C. Random Projection	Offline (단순 하한)	~2h	★★ 2순위	10~40%
#7	E. Hilbert Curve	Offline (결정론)	~4h	★★ 3순위	20~60% (contribution 후 보)
#6	A. LSH	Offline (확률)	~4h	★ 4순위	30~60%
#10	B. KDE-pilot	Online (정교)	~6h	★ 5순위	50~80% (이론 상한)
#9	G. Distance-Shell	Online (단순)	~4h	★ 6순위	25~50%
#11	H. Importance Sampling	비분할 (가중치)	~6h	★ 7순위 (2x2 factorial)	30~70%

3.3 그림 자리 (W2 측정 후 채울 placeholder)

회의 자료 + 자문 첨부 + 최종 발표 슬라이드의 3 곳에서 동일 그림이 재사용 되도록 pre-define:

- [fig6_rq3_recovery_comparison.png](#) — 7 method × 2 dataset × 5 sel matrix (heatmap). RQ3 의 핵심 그림.
- [fig7_rq3_paradigm_tradeoff.png](#) — Offline vs Online vs Weight 패러다임의 cost-recovery scatter (x 축 사전 학습 비용, y축 recovery rate).
- [fig8_rq3_method_ranking.png](#) — 7 method 의 boxplot (5 sel × 5 seed × 100 query 분포), 정렬 기준 평균 recovery rate.
- [fig9_rq3_minibatch_vs_oracle.png](#) (가설용) — 1~5% 학습 비용에서 KM20 oracle 의 75~95% 회수 가능성 입증 그림.

3.4 위험 요인 + Plan B

- (1) MiniBatch K-means 가 KM20 의 95% 이상 회수하면 RQ3 의 narrative 가 "production 솔루션은 MiniBatch 면 충분" 으로 강한 메시지가 됨. 반대로 60% 미만 회수면 Hilbert Curve 의 결정론적 장점을 contribution 후보로 격상.
- (2) Online (B/G) 의 query-aware σ_i 가 RQ2 Neyman 의 약한 신호를 강하게 해주면 Limitation 4의 "단일 → 멀티 일반화" 보다 contribution 가 강해질 수 있음. 측정 후 우선순위 재조정 가능성 있음.
- (3) 시간 부족 시 W2 (5/12~5/18) 로 #9~#11 이월 — 5/8 회의에서 이 분담을 합의해야 함.

4. 자문 요청 핵심 질문

5/15 발송 예정 자문 문서 ([submission/_drafts/속도는벡터_채림자문_20260507.md](#)) 에 포함될 검토 요청. 5/8 회의에서 전원 합의 필요.

4.1 채림 석사님께

- (1) Neyman Allocation 의 σ_i 정의 적절성 — 본 측정에서 σ_i 를 sel=0.10 D_target anchor 로 단일 정의하였는데, 이로 인해 SIFT × 좁은 sel 에서만 Neyman 효과가 검출되었다 (BH-FDR 보정 후 p=0.010~0.024). σ_i 를 query-aware 로 정교화하면 더 강한 신호를 검출할 수 있을지, 아니면 RQ3 의 Online (B/G) 영역으로 미루는 것이 더 학술적으로 정당한지의 판단을 요청드립니다.
- (2) Anti-Neyman 반증의 의미 해석 — H2-AN 이 모든 case 에서 통계적으로 유의하지 않게 나온 것 (DEEP p=0.193~0.846, SIFT p=0.205~0.994) 이 (a) σ_i 신호 부족 때문인지 (b) Anti-Neyman 의 이론적 손해가 본 데이터에서는 N_i 신호에 의해 상쇄되어 nullify 되는 것인지의 통계학적 해석 의견.
- (3) "실험 #4 H2-S 미입증 → robustness 발견" narrative 전환의 적절성 — H2-S 의 sample_size 단조 감소 가 설이 미입증된 후, KM20 robustness 라는 새 narrative 로 전환하였다. 이 narrative 전환이 (a) 사후 합리화 (post-hoc rationalization) 의 위험을 갖는지 (b) production 관점의 가치 메시지로 정당한지의 판단.

4.2 지도교수님께

- (1) 본 연구의 positioning — "Exquitor 가 미작동하는 단일 테이블 영역에 대한 분포 정보의 가치 정량화" framing 의 적절성. 단일 → 멀티 일반화 Limitation 명시 방향.
- (2) RQ3 의 ranking 자체가 contribution 인가, 아니면 ranking 위에 새 method 가 필요한가 — 7-way 비교 자체로 학부 캡스톤 contribution 이 충분한지, Hilbert Curve 의 결정론적 장점 같은 부분에서 추가 method 를 제안해야 할지의 방향 결정.

(3) 5/27 최종 발표까지의 일정 — W2 (5/12~5/18) RQ3 Online + Weight 측정, W3 (5/19~5/22) cross-analysis 의 압축 일정 현실성.

5. W2 (5/12~5/18) 분담 (안)

영역	1차 책임	2차 책임	비고
RQ3 측정 #5~#8 (Offline 4종)	조현빈	이동욱	W1 측정 인프라 재활용
RQ3 측정 #9~#11 (Online 2 + Weight 1)	강재현	조현빈	6h+6h+6h, 시간 압박 큼
자문 메일 발송 + 회신 정리	박세은	—	5/15 발송, 5/22 미팅 전 회신 수렴
Recovery Rate cross-analysis	박세은	조현빈	W3 (5/19~5/22)
발표 자료 초안	강재현	박세은	W3 마감 (~5/21)

6. 다음 일정

마감	산출	비고
5/8 (목) 19:00	★ 본 회의 + 자문 발송 합의	D-2
5/11	RQ3 #5~#8 측정 마감 (Offline)	조현빈
~5/15	자문 발송 (채림 석사 + 교수님)	박세은
5/18	RQ3 #9~#11 측정 마감 (Online + Weight)	강재현
~5/21	발표자료 초안 + Recovery Rate cross-analysis	강재현·박세은
5/22	교수님 미팅	전원
5/26	발표자료 최종 마감	전원
5/27	★ 최종 발표	D-21
5/28	전시회 자료 마감	—
6/11	★ 최종 보고서	D-36

7. 첨부 자료 (회의 시 공유)

- 본 outline: `plans/5_8_19시_회의_outline.md`
- RQ 재정립 설계안 (5/5 확정): `plans/RQ재정립_20260505_2122.md`
- RQ3 7-way 상세 설계: `plans/RQ3설계안_20260416_213500.md`
- RQ1+RQ2 결과 정리: `experiments/results/RQ1_RQ2 실험 결과 정리.md`
- 측정 raw 데이터:
- RQ1 SIFT SYSTEM: `experiments/results/rq1_motivation/sift_rq1_2026_05_06/`
- RQ2 5-mode: `experiments/results/rq2_aware/2026_05_06_alloc/rq2_alloc.parquet`
- RQ2 sample size:
`experiments/results/rq2_aware/2026_05_06_alloc/rq2_size_sensitivity_5sel.parquet`
- W1 figures (5종): `experiments/figures/rq1_rq2_w1_sprint/`
- 5/5 회의록: `_internal/records/kakaotalk/20260505_RQ재정립_회의.md`
- 자문 초안: `submission/_drafts/속도는벡터_채림자문_20260507.md`

본 outline 은 5/8 19:00 비대면 회의 진행을 위한 작성 자료이며, 회의 종료 후 회의록 (`_internal/records/kakaotalk/20260508_W1결과_RQ3계획_자문합의.md`) 으로 별도 정리한다.