

Exqutor 기반 캡스톤 연구 방향 설계안

작성일: 2026-04-03 (교수님 미팅 후 전면 개편)

목적: 새 연구 방향(Skew-Aware Sampling) 구체화 → 중간보고서·최종보고서의 근거 자료

버전: v3 — 4/3 교수님 미팅 피드백 반영, Cascade 방향 폐기 후 Sampling 방향 전환

배경: Exqutor의 Adaptive Sampling이 skewed 거리 분포에서 정확도가 떨어지는 문제를 공략

이전 설계안: plans/연구_설계안_20260330_145513.md (Cascade 방향, 폐기)

I. 출발점 — Exqutor의 Adaptive Sampling과 남겨진 문제

Exqutor(arXiv:2512.09695v2)는 벡터 증강 분석 쿼리(VAQ)에서 카디널리티 오추정 문제를 해결했다. pgvector는 벡터 조건의 선택도를 33.3%로 고정 추정하고, VBASE는 50%, DuckDB는 100%로 추정하는데, 실제 선택도는 0.001%~90%까지 다양하므로 옵티마이저가 잘못된 실행 계획을 선택하게 된다. Exqutor는 두 가지 해법을 제시했다.

- **ECQO**: HNSW 인덱스가 있을 때, range query를 실행해 1~2ms 안에 정확한 카디널리티를 획득
- **Adaptive Sampling**: 인덱스가 없을 때, 모멘텀 기반 동적 샘플링으로 카디널리티를 근사

그 결과 pgvector에서 최대 1,000배, VBASE에서 10,000배, DuckDB에서 1.5~37배 성능 향상을 달성했다.

Adaptive Sampling의 암묵적 가정

Exqutor의 adaptive sampling은 [81] Lipton et al.(SIGMOD 1990)의 적응적 샘플링 이론에 기반한다. 초기 소규모 샘플에서 시작해, 추정값의 변화가 수렴할 때까지 샘플 크기를 점진적으로 늘리는 방식이다. 이 접근에는 암묵적 가정이 있다: **무작위 샘플이 전체 데이터의 거리 분포를 대표한다**는 것.

거리 분포가 균일(uniform)하거나 대칭(symmetric)에 가까우면 이 가정이 성립하지만, **skewed 분포에서는 무작위 샘플이 밀도가 높은 영역에 편중되어 tail 영역의 카디널리티를 과소 또는 과대 추정한다**.

예를 들어 right-skewed 거리 분포(대다수의 벡터가 query와 가깝고, 소수만 먼 경우)에서 $\text{dist} < D$ (D 가 큰 값) 조건의 카디널리티를 추정할 때, 무작위 샘플은 가까운 벡터 위주로 뽑히므로 "거의 전부 만족"이라 추정하지만 실제로는 먼 벡터의 비율이 무시할 수 없을 수 있다. 반대로 left-skewed(대다수가 멀고 소수만 가까운) 분포에서 엄격한 조건($\text{dist} < D$, D 가 작은 값)의 카디널리티는 과소추정된다.

논문이 다루지 않은 영역

Exqutor 논문 Section 6.8에서 "고차원 공간에서 샘플링 오버헤드 증가"를 한계로 인정했지만, **분포 형태(skewness)에 따른 추정 정확도 변화**는 분석하지 않았다. 논문의 벤치마크(TPC-H/DS 확장)가 비교적 고른 분포의 데이터셋에서 수행되었기 때문에, skewed 환경에서의 성능은 미검증 상태다. 또한 라틴 하이퍼큐브 샘플링(LHS)과 같은 대안적 샘플링 기법은 구현 복잡도를 이유로 고려하지 않았다.

II. 핵심 연구 질문

"벡터 거리 분포가 skewed인 환경에서, Exqutor의 무작위 적응적 샘플링 대비 분포 특성을 고려한 샘플링 전략이 카디널리티 추정 정확도를 유의미하게 개선할 수 있는가?"

하위 연구 질문 (3개 — 실험 단계와 1:1 대응)

RQ1 (Motivation 검증): Exqutor의 adaptive sampling은 거리 분포의 skewness에 따라 추정 정확도가 얼마나 달라지는가?

- *가설 H1:* skewness가 클수록 Q-error가 증가한다. 특히 $|\text{skewness}| > 1$ 인 분포에서 Q-error가 uniform 대비 2배 이상 악화.
- *맞을 때:* 개선의 필요성 확인 → RQ2, RQ3 진행
- *틀릴 때:* Exqutor가 이미 충분히 robust → skew의 정의를 더 극단적으로 확장하거나, 특정 선택도 구간에서만 나타나는 취약점 탐색

RQ2 (Distribution-Aware): 거리 분포의 형태를 알고 있을 때, 층화 샘플링(stratified sampling)이 무작위 적응적 샘플링보다 카디널리티 추정 정확도를 얼마나 개선하는가?

- *가설 H2:* 분포에 맞게 strata를 설정하면 Q-error가 무작위 대비 50% 이상 감소. skew가 심할수록 개선 폭이 큼.
- *맞을 때:* distribution-aware 전략의 유효성 확인 → 실용적 의미 논의
- *틀릴 때:* strata 경계 설정 전략을 재조정, 또는 importance sampling으로 전환

RQ3 (Distribution-Agnostic): 거리 분포를 모르는 상황에서, pilot sample 기반 자동 층화(KDE-pilot stratification)가 무작위 적응적 샘플링보다 정확한가?

- *가설 H3:* 소규모 pilot(전체의 1~5%)으로 분포를 추정한 후 층화하면, 순수 무작위 대비 Q-error가 30% 이상 개선. pilot 오버헤드를 포함해도 총 샘플링 비용 증가가 20% 미만.
- *맞을 때:* 사전 정보 없이도 skew-robust한 추정 가능 → 실무 적용 가능성
- *틀릴 때:* pilot 자체가 skew에 취약 → pilot 크기 확대 또는 다른 agnostic 기법(QMC, LHS) 탐색

RQ 간 관계

RQ1에서 문제 존재가 확인되면 → RQ2(이론적 상한: 분포를 알 때)와 RQ3(현실적 해법: 분포를 모를 때)를 순차 진행한다. 이 구조가 교수님의 2 트랙(aware/agnostic)과 정확히 대응된다.

III. 연구 방향 — 3단계 실험 구조

1단계: Motivation 실험 (RQ1)

목적: Exqutor의 adaptive sampling이 skewed 분포에서 실제로 정확도가 떨어지는지 정량적으로 확인.

방법:

(a) 거리 분포 프로파일링

석사분이 제공할 실제 데이터셋에서 다양한 query vector를 N개(50~100개) 무작위 추출. 각 query에 대해: - 전체 데이터와의 거리를 계산하여 거리 분포 도출 - Fisher's skewness coefficient(γ) 측정 - 분포 시각화 (히스토그램 + KDE)

(b) Exqutor 방식 카디널리티 추정

동일 query에 대해 Exqutor의 모멘텀 기반 무작위 adaptive sampling으로 카디널리티 추정. 선택도 구간별 분리 측정: - 선택도 구간: 0.1%, 1%, 5%, 10%, 30%, 50% - 실제 카디널리티(full scan)와 비교하여 Q-error 산출 -

$$Q\text{-error} = \max(\text{estimated}/\text{actual}, \text{actual}/\text{estimated})$$

(c) 핵심 산출물

- **Skewness vs Q-error 산점도** — 논문의 핵심 Figure. skew가 클수록 Q-error가 높아지는 경향을 시각화
- **분포 유형별 Q-error 박스플롯** — query들을 skewness 구간($|\gamma| < 0.5$, $0.5 \sim 1$, $1 \sim 2$, $2+$)으로 그룹핑
- **선택도별 Q-error 히트맵** — skewness $\times$ 선택도 2차원에서 취약 구간 식별

판단 기준: skewness $|\gamma| > 1$ 인 query 그룹의 평균 Q-error가 $|\gamma| < 0.5$ 인 그룹 대비 2배 이상이면 RQ2, RQ3 진행. 차이가 미미하면 skew 정의를 재조정.

2단계: Distribution-Aware Stratified Sampling (RQ2)

목적: 분포를 안다는 가정 하에, 최적 층화 전략으로 얼마나 개선 가능한지 상한을 측정.

방법:

(a) Strata 설정 전략 3가지 비교

전략	Strata 경계 결정 방법	각 구간 샘플 수
Equal-width	거리 범위를 K등분	균등 배분
Equal-frequency	각 구간에 동일 수의 데이터가 포함되도록 분할	균등 배분
Neyman allocation	Equal-frequency 분할 + 구간 내 분산에 비례하여 샘플 배분	분산 비례

K(strata 수)를 3, 5, 10, 20으로 변화시키며 최적 K 탐색.

(b) 비교 baseline

전략	설명
Random (Exqutor)	모멘텀 기반 무작위 adaptive sampling
Stratified-EW	Equal-width stratification
Stratified-EF	Equal-frequency stratification
Stratified-Neyman	Neyman allocation
Oracle	Full scan 기반 정확한 카디널리티 (상한)

(c) 측정 지표

- Q-error (주 지표)
- 샘플 수 대비 정확도 곡선 — 같은 정확도를 달성하기 위해 필요한 샘플 수 비교
- 선택도 구간별 정확도 — 어떤 선택도에서 개선이 가장 큰지

(d) 실험 매트릭스

전체 조합: 전략 4가지 × K 4가지 × 선택도 6구간 × query 50~100개. 핵심 비교는 전략 간 Q-error 차이이므로, query는 skewness 그룹으로 묶어 그룹 평균으로 분석.

3단계: Distribution-Agnostic KDE-Pilot Stratification (RQ3)

목적: 분포를 모르는 현실적 상황에서도 층화 샘플링의 이점을 살릴 수 있는지 확인.

방법:

(a) KDE-Pilot 알고리즘

```
Step 1: Pilot sample (전체의 1~5%) 무작위 추출  
Step 2: Pilot에서 거리값 계산 → KDE로 분포 추정  
Step 3: 추정된 분포 기반으로 strata 경계 자동 결정  
Step 4: 나머지 샘플을 strata별로 할당하여 추출  
Step 5: 카디널리티 추정
```

(b) Pilot 크기 sensitivity 분석

Pilot 비율: 0.5%, 1%, 2%, 5%에서 각각 최종 Q-error 비교. Pilot이 작을수록 오버헤드는 줄지만 분포 추정 품질이 떨어지는 트레이드오프.

(c) 비교

2단계의 모든 baseline에 **KDE-Pilot** 추가. 핵심 비교: - KDE-Pilot vs Random(Exqutor) — agnostic 환경에서의 개선 폭 - KDE-Pilot vs Stratified-Neyman(Oracle 분포) — 이론적 상한 대비 몇 % 도달하는지

(d) 총 비용 분석

Pilot 오버헤드 포함한 총 샘플링 비용(= pilot 샘플 수 + main 샘플 수)을 Exqutor와 동일 조건에서 비교. 비용 대비 정확도 효율 곡선 산출.

IV. 데이터셋 및 실험 환경

데이터셋

- **주 데이터셋**: 석사분이 제공할 Exqutor 실험 데이터 (4월 둘째 주 수령 예정). TPC-H/DS 기반 VAQ 벤치마크 + 벡터 임베딩 포함 예상. 수령 후 거리 분포의 skewness 프로파일링 먼저 수행.
- **Query 선택 전략**: 데이터셋 전체에서 무작위로 query vector를 50~100개 추출 → 각 query의 거리 분포 skewness를 측정 → skewness 구간별로 그룹핑하여 실험에 사용.

실험 환경

항목	내용
서버	연구실 서버 (교수님 제공 확정, 스펙은 수령 후 기재)
소프트웨어	PostgreSQL 16 + Exqutor 패치 빌드 + pgvector
샘플링 구현	Python (NumPy, SciPy) — Exqutor adaptive sampling을 Python으로 재구현
재현성	모든 실험에 seed 고정, 각 조건 5회 반복 실행 후 중앙값 사용

측정 지표

지표	정의	용도
Q-error	$\max(\text{estimated}/\text{actual}, \text{actual}/\text{estimated})$	주 정확도 지표
상대 오차	$ \text{estimated} - \text{actual} / \text{actual}$	보조 정확도 지표
샘플 효율	목표 Q-error 달성에 필요한 최소 샘플 수	비용 대비 효율
Skewness (γ)	Fisher's skewness coefficient	분포 특성 분류

LHS 백그라운드 위치

Latin Hypercube Sampling은 메인 실험 기법이 아닌 **관련 연구(Related Work)** 및 **이론적 배경**으로 다룬다. 1차원 거리값에 LHS를 적용하면 equal-frequency stratification과 사실상 동일하나, 다차원 확장(벡터 공간 직접 총화) 가능성은 향후 연구로 언급한다. Exqutor가 구현하지 않은 이유(고차원 오버헤드)를 분석하여 기술한다.

V. 예상 기여 및 일정

예상 기여

1. Exqutor adaptive sampling의 skew 취약점 실증: 거리 분포 skewness와 Q-error 간 정량적 관계를 최초로 분석
2. Distribution-aware stratified sampling의 효과 입증: skewed 환경에서 층화 전략별 개선 폭 비교 → 최적 전략 제시
3. Distribution-agnostic KDE-pilot 기법 제안: 사전 정보 없이도 skew-robust한 카디널리티 추정이 가능함을 실험적으로 검증
4. 비용-정확도 트레이드오프 분석: pilot 오버헤드 포함 총 비용 대비 정확도 효율 곡선 제시

위험 요소 및 대안

위험	대응
석사분 데이터의 skew가 충분하지 않음	합성 skewed 벡터를 보조 데이터로 추가 생성
RQ1에서 skew-Q-error 상관이 약함	특정 선택도 구간(극소/극대)에 집중하여 취약 구간 탐색
KDE-pilot의 분포 추정이 부정확	pilot 크기를 늘리거나, KDE 대신 histogram 기반 추정으로 단순화
서버 환경 세팅 지연	Python standalone 실험(DB 없이 벡터 연산만)을 먼저 진행

일정 (잠정)

주차	내용	산출물
4/3~4/10	LHS·층화 샘플링 이론 정리 + 설계안 확정	이론 정리 문서, 설계안 v3
4/10~4/17	Exqutor 코드·데이터 수령 + 환경 세팅	서버 환경 구축 완료
4/17~4/25	1단계(RQ1) Motivation 실험	Skewness vs Q-error 분석
4/28	중간발표 + 중간보고서 제출	발표자료, 보고서
4/28~5/20	2단계(RQ2) + 3단계(RQ3) 본실험	전략별 비교 결과
5/20	분반 수업 (전시회 준비)	전시 준비
5/27~5/29	최종발표 + 전시회 마감	발표자료
6/5	전시회	포스터/데모
6/11	최종보고서 제출	최종보고서

기존 설계안과의 관계

기존 Cascade 설계안(plans/연구_설계안_20260330_145513.md)은 **폐기**. 구조적으로 재활용한 부분: - Section I (출발점) — Exqutor 배경은 유지하되, 문제 정의를 Cascade에서 Sampling으로 교체 - 논문 분석 자산 ([80] Selectivity Estimation, [81] Adaptive Sampling 등) — 그대로 활용 - 실험 환경 설정 — 서버/데이터셋 부분 유지

참고 문헌

- Exqutor: arXiv:2512.09695v2
- [80] Haas et al., "Selectivity and Cost Estimation for Joins Based on Random Sampling", JCSS 1996
- [81] Lipton et al., "Practical Selectivity Estimation through Adaptive Sampling", SIGMOD 1990
- [67] Determining Sample Size (LHS 이론 배경)
- [74] Consistent Flexible Selectivity Estimation (조건부 선택도)