

# RQ3 설계안: Distribution-Agnostic 총화 샘플링

2026-04-16 확정. 7가지 방법 전수 비교.

## 연구 질문

**RQ3:** 데이터 분포를 사전에 모를 때, 공간 인식 총화 샘플링(KM20)의 이점을 얼마나 회수할 수 있는가?

## 가설

**H3:** Distribution-agnostic 방법들은 사전 클러스터링(KM20) 대비 유의미한 비율의 개선 효과를 회수하면서도, 사전 학습 불필요 또는 극소 비용이라는 운영 이점을 제공한다.

## 핵심 지표: Recovery Rate

$$\text{recovery\_rate} = (\text{방법X} - \text{RANDOM20}) / (\text{KM20} - \text{RANDOM20})$$

- 1.0 = KM20과 동일 (oracle 수준)
- 0.0 = RANDOM20과 동일 (공간 인식 없음)
- 음수 = RANDOM20보다 나쁨

## RQ3의 출발점: KM20의 한계

RQ2에서 KM20이 효과적임을 확인했으나, 실용화에 4가지 한계가 있다:

| 한계            | 설명                                           |
|---------------|----------------------------------------------|
| 사전 계산 필요      | k-means를 전체 데이터에 돌려야 함 (1M: ~30초, 8M: ~분 단위) |
| stratum_id 저장 | 모든 행에 클러스터 라벨 컬럼 추가 필요                       |
| 데이터 변경 시 재계산  | INSERT/UPDATE 시 k-means 재실행 or 근사 할당         |
| K 선택 문제       | K=200이 최적인지 모름. 데이터마다 다를 수 있음                |

이 한계를 극복하는 방법을 체계적으로 탐색하는 것이 RQ3.

## 초기 후보 D (Exqutor Hybrid) 제외 이유

초기 브레인스토밍에서 "Exqutor Adaptive + 우리 총화 하이브리드"(D)를 검토했으나 제외: 1. Phase 7에서 Adaptive update path SIGSEGV 크래시 → 디버깅 필요 2. 디버깅해도 Phase 7 negative finding (hook\_est 기반 STRAT가 BERN보다 나쁨) 3. "Exqutor 버그 수정"은 RQ3의 취지(새로운 방법론 제안)와 안 맞음 4. 구현 난이도 최상, 6주 내 비현실적

## 7가지 방법 평가 매트릭스

|             | A. LSH | B. KDE | C. RandProj | E. Hilbert | F. MiniBatch | G. Shell | H. Import |
|-------------|--------|--------|-------------|------------|--------------|----------|-----------|
| 이론적 정당성     | 강      | 강      | 강 (JL)      | 최강 (30년)   | 중            | 중        | 강         |
| 기대 recovery | 30~60% | 50~80% | 10~40%      | 20~60%     | 75~95%       | 25~50%   | 30~70%    |
| 구현 난이도      | 중      | 상      | 하           | 중          | 하            | 중        | 상         |
| 6주 내 가능     | ✓      | ⚠      | ✓           | ✓          | ✓            | ✓        | ⚠         |
| 사전 학습       | 해시 1회  | 불필요    | 사영 1회       | index 1회   | 1~5%         | 불필요      | 불필요       |
| INSERT 대응   | O(1)   | 자동     | O(1)        | O(1)       | O(d·K)       | 자동       | 자동        |
| 논문 기여도      | 높음     | 높음     | 중           | 최고         | 중            | 중        | 높음        |
| RQ1/2 연결    | 자연     | 자연     | 자연          | 자연         | 자연           | 자연       | 자연        |

## 3가지 패러다임 × 7가지 방법

### 패러다임 1: Offline Partition (데이터 로드 시 1회 계산)

#### C. Random Projection

- 이론: Johnson-Lindenstrauss lemma — 랜덤 방향 사영이 거리를  $\epsilon$  이내로 보존
- 메커니즘: 랜덤 단위벡터  $r$  생성 → 각 벡터  $v$ 의 사영값  $v \cdot r$  계산 → K등분
- 구현: 내적 1회, 가장 단순
- 기대 recovery: 10~40% (1D로 다차원 구조 포착 한계, RANDOM20과 차이 없을 수도)
- 역할: 최단순 하한선

#### A. LSH (Locality-Sensitive Hashing)

- 이론: 해시 충돌 확률이 거리에 반비례 → 가까운 벡터가 같은 버킷
- 메커니즘: 랜덤 하이퍼플레인  $p$ 개 →  $2^p$  버킷 → 비례 배분
- 구현: 해시 함수 ~30줄
- 기대 recovery: 30~60%
- 역할: 확률적 공간 포착

#### E. Hilbert Curve (Space-Filling Curve)

- 이론: Hilbert 곡선은  $d$ 차원 → 1D 매핑에서 공간 인접성을 최대한 보존. R-tree, 공간 DB에서 30년간 검증.
- 메커니즘: 벡터 양자화 → Hilbert index 계산 → index 기준 K등분
- 구현: hilbertcurve 라이브러리 + 양자화
- 기대 recovery: 20~60% (고차원에서 curse of dimensionality로 하향 가능)
- 역할: 결정론적 공간 포착. 벡터 카디널리티 추정에 최초 적용.
- 주의: 96d/128d에서 locality 보존이 약해질 수 있음 → negative finding도 기여

#### F. Mini-batch K-means

- 이론: Sculley 2010 — 데이터의 1~5%만 보고 근사 클러스터링
- 메커니즘: sklearn MiniBatchKMeans → 센트로이드 학습 → 나머지  $O(d \cdot K)$  할당
- 구현: sklearn 한 줄
- 기대 recovery: 75~95% (근사 k-means이므로 KM20에 근접)
- 역할: "얼마만큼의 사전 학습으로 충분한가"에 대한 답. 비용-효과 상한선.

## 패러다임 2: Online Query-Adaptive (쿼리 시점 동적 적응)

### G. Distance-Shell

- **이론:** 쿼리 벡터 중심 동심원 분할. 카디널리티 조건 충족 행이 내부 shell에 집중.
- **메커니즘:** pilot 샘플(~385개) → 거리 분위수로 K개 shell → shell별 비례 배분 본 샘플
- **구현:** 2-pass (pilot → 본 샘플)
- **기대 recovery:** 25~50%
- **역할:** 단순 적응형. B(KDE)의 단순화 버전.

### B. KDE-pilot (Kernel Density Estimation)

- **이론:** Silverman bandwidth로 비모수 밀도 추정 → Neyman 최적 배분
- **메커니즘:** pilot 샘플 → KDE로 거리 분포 밀도 추정 → 밀도 높은 영역에 더 많은 샘플 배분
- **구현:** scipy KDE + 2-pass
- **기대 recovery:** 50~80% (쿼리별 최적화이므로 이론적으로 가장 정교)
- **역할:** 정교한 적응형. 이론적 상한.

## 패러다임 3: Weight-based (파티션 없이 가중치 조정)

### H. Importance Sampling

- **이론:** 최적 importance weight는  $f(x)/g(x)$ 에 비례. 층 분할 없이 각 샘플의 가중치를 조정하여 분산 감소.
  - **메커니즘:** BERNOULLI로 샘플 추출 → 각 샘플의 로컬 밀도 추정 → 밀도 역수 가중치로 보정된 카디널리티 추정
  - **구현:** hook\_est 반환 공식 수정 (가중 평균)
  - **기대 recovery:** 30~70% (가중치 추정 정확도에 의존)
  - **역할:** 비분할 패러다임 대표. 층화와 근본적으로 다른 접근.
-

## 9-way 비교 체계

|                   |                                |
|-------------------|--------------------------------|
| 보정 없음             | BERNOULLI (Exqutor 원본)         |
|                   |                                |
| 무의미 하한            | RANDOM20 (무작위 분할)              |
|                   |                                |
| Offline Partition | ├ C. Random Projection (최단순)   |
|                   | ├ A. LSH (확률적)                 |
|                   | ├ E. Hilbert Curve (결정론적)      |
|                   | ├ F. Mini-batch KM (근사 학습)     |
|                   |                                |
| Online Adaptive   | ├ G. Distance-Shell (단순 적응)    |
|                   | ├ B. KDE-pilot (정교한 적응)        |
|                   |                                |
| Weight-based      | ├ H. Importance Sampling (비분할) |
|                   |                                |
| 오라클 상한            | KM20 (사전 클러스터링)                |

예상 순서:  $\text{RANDOM20} \leq C \leq \{A, E, G\} \leq \{B, H\} \leq F \leq \text{KM20}$

## 실험 설계

### 데이터셋

- DEEP 1M (96d) — 상대적으로 균일
- SIFT 1.5M (128d) — 더 skewed

### Selectivity

- 1%, 5%, 10%, 30%, 50% (RQ1/RQ2와 동일 5점)

### 반복

- 5-seed × 100 query (RQ1/RQ2와 동일)

### 측정 지표

- Q-error (hook\_est vs true\_card)
- paired Wilcoxon p-value

- Recovery Rate
- 

## 구현 계획

### Week 1 (4/28~5/4): Offline Partition 3종

- C (RandProj): 구현 ~2시간, 실험 ~2시간
- A (LSH): 구현 ~4시간, 실험 ~2시간
- E (Hilbert): 구현 ~4시간, 실험 ~2시간
- F (MiniBatch): 구현 ~1시간, 실험 ~2시간

### Week 2 (5/5~5/11): Online + Weight

- G (DistShell): 구현 ~4시간, 실험 ~3시간
- B (KDE-pilot): 구현 ~6시간, 실험 ~4시간
- H (Importance): 구현 ~6시간, 실험 ~3시간

### Week 3 (5/12~5/18): 분석

- Recovery Rate 비교 그래프
- 패러다임 간 cross-analysis
- 비용-효과 분석 (사전 학습 시간 vs recovery)

### Week 4 (5/19~5/27): 최종 발표 준비

- 최종 보고서 작성
  - 발표 슬라이드
  - 포스터
- 

## 논문 기여 3가지

1. 체계적 비교: 벡터 카디널리티 추정에서 distribution-agnostic 7가지 방법의 최초 체계적 비교
2. Recovery Rate 프레임워크: oracle(KM20) 대비 회수율 개념 도입, 비용-효과 정량 평가

3. Hilbert Curve 최초 적용: 공간 DB 기법(space-filling curve)을 벡터 카디널리티 추정에 적용

## RQ1/RQ2와의 연결

RQ3의 모든 방법은 RQ1/RQ2에서 발견한 문제를 해결하는 연장선:

- **RQ1:** 밀도가 비균일하다 → uniform sampling이 나쁘다
- **RQ2:** 밀도 비균일을 파티션으로 교정 (KM20 총화)
- **RQ3 파티션 방법 (A/C/E/F):** KM20과 같은 교정을 사전 학습 없이 달성
- **RQ3 적응형 (B/G):** 쿼리 시점에 동적으로 교정
- **RQ3 가중치 (H):** 같은 문제를 다른 메커니즘(가중치)으로 교정 — 밀도가 높은 영역을 "덜 세고" 낮은 영역을 "더 세는" 효과

H(Importance Sampling)는 Control Variate 기법의 상위 개념이며, 총화와는 근본적으로 다른 분산 감소 경로. 둘 다 보여줘야 "밀도 비균일 교정"이라는 상위 프레이밍이 완성됨.

## Exqutor Adaptive Sampling과의 관계

Exqutor 논문의 기존 Adaptive Sampling은 "이전 쿼리 결과로 sample\_size를 모멘텀 기반 조정"하는 feedback 기반 학습. 이는 우리 RQ3의 Online Adaptive 패러다임에 해당하나:

1. Phase 7에서 Adaptive update path가 SIGSEGV 크래시 (design constraint #5)
2. 크래시 회피(update\_sample\_size=off)해도 hook\_est 기반 STRAT가 BERN보다 나쁜 negative finding
3. Adaptive가 조정하는 건 sample\_size(표본 크기)이지 sample\_allocation(표본 배분)이 아님

따라서 우리 RQ3는 "Exqutor Adaptive의 한계를 인식하고, sample\_allocation 차원의 대안을 제시"하는 positioning.

## 탈락 후보 상세

| 후보                               | 탈락 이유                                                    |
|----------------------------------|----------------------------------------------------------|
| I. Density-Inverse Pre-weighting | H(Importance)의 offline 변형. 구현이 거의 동일하므로 독립 항목 불필요        |
| J. Query-Adaptive Projection     | G(Distance-Shell)의 열등 버전. 쿼리 방향 1D 사영 < 유클리드 거리 전체       |
| K. Mini-batch PCA + Projection   | C(RandProj)의 변형. 약간의 사전 학습으로 사영 방향 최적화. C 실험 시 비교 1줄로 처리 |
| Latin Hypercube Sampling         | 고차원(96d+)에서 $K^d$ 셀 폭발 → 차원 축소 필수 → C와 동치                |
| Tree-based (VP/KD/Ball)          | 구축 비용이 k-means와 비슷. KM20과 차별 없음                          |
| Balanced Sampling (Cube)         | 이론적이나 구현 극난. 학부 캡스톤 범위 초과                                |
| Coreset Construction             | 샘플링이 아닌 부분집합 선택 문제. RQ3 범위 밖                             |
| Multi-armed Bandit               | 반복 쿼리 학습. 단일 쿼리 기준인 우리 세팅에 부적합                           |
| Optimal Transport                | Wasserstein 기반. 이론적이나 구현 비현실적                            |
| Control Variate                  | H(Importance)의 특수 케이스. H에 통합                             |

## 방법 분류 교차표 (정보 시점 × 포착 방식)

|                | 직접 분할         | 좌표 변환                              | 거리 기반                  | 가중치 조정         |
|----------------|---------------|------------------------------------|------------------------|----------------|
| <b>Offline</b> | F (MiniBatch) | C (RandProj), A (LSH), E (Hilbert) | —                      | —              |
| <b>Online</b>  | —             | —                                  | G (DistShell), B (KDE) | H (Importance) |
| <b>None</b>    | RANDOM20      | —                                  | —                      | BERNOULLI      |

빈 셀(Offline×거리, Offline×가중치, Online×분할, Online×변환)은 기존 방법의 변형이거나 논리적으로 다른 셀에 귀결됨을 확인 완료.

## 핵심 구현 인사이트

7가지 방법의 차이는 **stratum\_id를 어떻게 할당하느냐**뿐이다. 측정 파이프라인(multiseed\_paired, D\_target numpy 계산, Exqutor 로그 파싱, paired Wilcoxon)은 RQ2에서 완성된 것을 그대로 재활용. 각 방법마다:

1. Python으로 stratum\_id 계산 (50~100줄)
2. DB에 `UPDATE table SET stratum_id = 새값`
3. 기존 파이프라인으로 측정

H(Importance)만 예외 — hook\_est 반환 공식을 가중 평균으로 수정해야 함. 나머지 6개는 stratum\_id 할당 코드만 다르고 실험 코드는 동일.

## 맹점 점검 완료 사항

- 층화 프레임 간헐 → H(가중치)로 커버
- 실험 세팅 특수성 → B/G의 2-pass는 Python에서 해결
- 방법 간 조합 → 개별 먼저, 조합은 후속 연구
- 기대 효과 과대평가 → Hilbert/RandProj는 고차원 한계 가능, negative도 기여
- Feedback 기반 → Exqutor Adaptive가 커버, Phase 7 negative로 제외 근거
- 7가지 외 독립 방법 부재 확인 (I/J/K/LHS/Tree/Balanced/Coreset/MAB 전부 기존 7가지의 변형 또는 범위 밖)
- 정보 이론(엔트로피 분할) → Neyman allocation(B)과 동치
- 신호 처리(FFT/Wavelet 사영) → 벡터에 주파수 구조 없어 근거 없음. C의 열등 변형
- Balanced Sampling (Cube Method) → Exqutor BERNOULLI/STRATIFIED 경로와 프레임워크 불일치. 표본 선택을 직접 지정해야 하므로 hook\_est 로그 파싱 불가, 7-way 동일 조건 비교 불가
- Random Voronoi (K개 랜덤 시드 최근접) → F(MiniBatch)의 learning\_fraction=0% 케이스. F 실험에서 파라미터 변화로 커버
- Random Partition Tree (계층적 랜덤 사영) → C(RandProj)의 hierarchical 변형. 메커니즘 원리 동일
- Graph Partition (k-NN 그래프 컷) → 구축 비용  $O(N \cdot k \cdot d)$ 로 KM20 동급. RQ3 목적 불부합
- Spectral Clustering →  $O(N^2)$  유사도 행렬 필요. 1M 규모 비현실적
- Anchor-based Distance Profile → M차원 프로필에 A/C/E/F 중 하나 적용하므로 독립 방법 아님
- Ensemble (다중 방법 투표) → LSH(A)가 정확히 이것 (p개 하이퍼플레인 조합)