

산학협력프로젝트 수행계획서 (내부 기준 문서)

팀명: 속도는벡터

지도교수: 박광현

프로젝트명: Skew-Aware Sampling for Cardinality Estimation in Vector-Augmented Analytical Queries

상태: 내부 기준 문서 — 4/3 교수님 미팅 후 방향 전환 반영 (제출본은 submission/ 폴더의 4/2 제출 버전)

1. 프로젝트 개요

1.1 연구 배경

벡터 증강 분석 쿼리(VAQ)에서 카디널리티 오추정은 쿼리 옵티마이저의 핵심 병목이다. Exqutor(arXiv:2512.09695v2)는 모멘텀 기반 적응적 샘플링(Adaptive Sampling)으로 이 문제를 해결하여 pgvector 최대 1,000배, VBASE 10,000배의 성능 향상을 달성했다.

그러나 Exqutor의 Adaptive Sampling은 벡터 거리 분포가 고른 데이터에서만 검증되었으며, 거리 분포가 치우쳐 있는(skewed) 환경에서의 추정 정확도는 미검증 상태이다.

1.2 연구 목표

Skewed 거리 분포 환경에서 Exqutor의 무작위 적응적 샘플링 대비 카디널리티 추정 정확도(Q-error)를 개선하는 층화 샘플링(Stratified Sampling) 기법을 제안하고 실험적으로 검증한다.

1.3 연구 범위

- 포함: 카디널리티 추정 정확도(Q-error) 비교 실험
- 제외: 쿼리 실행 성능(end-to-end latency) 최적화, 새 인덱스 구조 개발

2. 연구 질문 및 가설

RQ	질문	가설
RQ1	Exqutor의 adaptive sampling은 skewness에 따라 정확도가 얼마나 달라지는가?	$ y > 1$ 에서 Q-error가 $ y < 0.5$ 대비 2배 이상 악화
RQ2	분포를 알 때 층화 샘플링이 얼마나 개선하는가?	Q-error 50% 이상 감소, skew가 심할수록 개선 폭 증가
RQ3	분포를 모를 때 KDE-pilot 자동 층화가 유효한가?	Q-error 30% 이상 개선, pilot 오버헤드 20% 미만

3. 세부 추진 계획

3.1 Phase 1 — 이론 연구 및 환경 구축 (4/3~4/17)

세부 과제	내용	산출물
샘플링 이론 정리	LHS, Stratified Sampling, Neyman allocation, KDE 이론 학습	이론 정리 문서
설계안 확정	실험 설계, RQ, 지표, 비교 전략 확정	설계안 v3 (완료)
환경 세팅	석사분 코드·데이터 수령, 연구실 서버 구축	실험 환경 Ready

3.2 Phase 2 — Motivation 실험 (4/17~4/25)

세부 과제	내용	산출물
거리 분포 프로파일링	Query 50~100개의 거리 분포 skewness 측정	분포 프로파일 데이터
Exqutor 방식 추정	무작위 adaptive sampling Q-error 측정 (선택도 6구간)	Q-error 데이터
상관 분석	Skewness vs Q-error 산점도, 히트맵	RQ1 결과 Figure

3.3 Phase 3 — 본실험 (4/28~5/20)

세부 과제	내용	산출물
Stratified Sampling 구현	EW/EF/Neyman 3전략 × K=3,5,10,20	샘플링 모듈
KDE-Pilot 구현	Pilot(0.5~5%) + KDE + 자동 총화	KDE-Pilot 모듈
비교 실험	5개 전략(Random/EW/EF/Neyman/KDE-Pilot) 비교	RQ2, RQ3 결과

3.4 Phase 4 — 중간보고 (4/28)

세부 과제	내용	산출물
중간보고서 작성	Phase 1~3 결과 + 방향 전환 경위 서술	중간보고서
중간발표 준비	발표자료 제작	PPT

3.5 Phase 5 — 심화 실험 및 최종 정리 (5/20~6/11)


세부 과제	내용	산출물
Pilot sensitivity	Pilot 비율별 정확도-비용 트레이드오프 심화 분석	비용-정확도 곡선
추가 데이터셋	다른 skew 특성의 데이터셋에서 일반화 검증	일반화 결과
최종 정리	최종보고서 + 발표자료 + 전시 포스터	최종 산출물

4. 팀원 역할 분담

이름	주 역할	부 역할
박세은 (팀장)	프로젝트 관리, 실험 설계 검증	중간·최종 보고서 총괄
강재현	샘플링 이론 연구, KDE-Pilot 구현	발표자료 제작
조현빈	실험 환경 구축, 데이터 분석	문서 작성·정리
이동욱	Stratified Sampling 구현, 비교 실험	시각화

역할은 유동적으로 배분. 전원이 모든 Phase에 참여하되, 위 역할을 우선 담당.

5. 일정표 (Gantt)



마일스톤	일정	상태
설계안 v3 확정	4/3	✓
이론 정리 완료	4/10	■
환경 구축 완료	4/17	■
RQ1 Motivation 결과	4/25	■
중간발표 + 중간보고서	4/28	■
RQ2 + RQ3 본실험 결과	5/20	■
최종발표 + 전시회 마감	5/27~5/29	■
전시회	6/5	■
최종보고서 제출	6/11	■

6. 실험 환경

항목	내용
서버	연구실 서버 (교수님 제공 확정, 스펙 수령 후 기재)
DB	PostgreSQL 16 + Exqutor 패치 + pgvector
데이터	석사분 제공 Exqutor 실험 데이터 (skewed 거리 분포 포함)
구현	Python 3.10+ (NumPy, SciPy, scikit-learn)
버전 관리	GitHub (johyunbin/Capstone)
협업	Notion, 카카오톡

7. 기대 성과

1. Exqutor adaptive sampling의 skew 취약점에 대한 최초 실증 데이터
2. Skewed 환경에서 카디널리티 추정 정확도를 개선하는 층화 샘플링 전략 비교 결과
3. 사전 정보 없이도 적용 가능한 KDE-pilot 기법 제안 및 검증
4. 비용-정확도 트레이드오프 분석을 통한 실무 적용 가이드라인

8. 위험 관리

위험 요소	영향	대응 방안
석사분 데이터의 skew 부족	RQ1 동기 약화	합성 skewed 벡터 보조 데이터 생성
서버 세팅 지연	실험 일정 지연	Python standalone 실험 선행 (DB 없이 벡터 연산만)
KDE 분포 추정 부정확	RQ3 결과 약화	histogram 기반 추정으로 단순화
중간보고 전 결과 부족	보고서 내용 부족	Phase 2(Motivation)까지는 반드시 완료