

RQ1/RQ2 실험 공유 및 중간발표 초안 (4/15~4/17 카톡 기록)

기간: 2026-04-15 17:15 ~ 2026-04-17 12:46 KST

참여자: 조현빈, 박세은, 강재현, 이동욱

맥락: RQ1/RQ2 실험 진행 상황을 시간대별로 팀에 공유하고, 2차 자문 요청·보고서 내용 정리·지도확인서 초안 작성·중간발표 PPT 초안 공유까지 이어진 3일치 그룹 대화

2026-04-15 (수)

17:15 조현빈 — RQ1/RQ2 실험 현황

[완료]

- 1M 벡터를 20개 그룹으로 클러스터링 → 그룹 크기가 최소 2.6만~최대 8.1만으로 데이터가 특정 영역에 몰려 있음을 확인 → RQ1
- Exqutor 소스 코드 분석 → 단일 테이블 쿼리를 제대로 처리하지 못하는 설계 제약 5종 발견, 연구 범위를 단일 테이블로 전환 → RQ1
- Exqutor 기본 샘플링 방식(SYSTEM)을 통계적으로 더 정확한 방식(BERNOULLI)으로 교체 → +3.8~9.6% 개선 → RQ2
- 공간 구조를 반영한 층화 샘플링(KM20)을 직접 구현 → 기존 대비 +1.64% 추가 개선 (5회 반복, 통계적으로 유의) → RQ2
- 같은 층화 샘플링을 "공간 구조를 아는 파티션(KM20)" vs "무작위 파티션(RANDOM20)"으로 비교 → 넓은 쿼리에서는 차이 없지만, 좁은 쿼리에서는 19.6%p 격차 발생. 쏠림이 성능 저하의 원인임을 직접 증명 → RQ1+RQ2
- 위 대조 실험에서 개선 효과가 "표본 크기 안정화"와 "공간 인식" 두 경로로 분리됨을 발견 (Two-Level Decomposition) → RQ1+RQ2

[진행 중]

- 1M에서 확인한 결과가 800만 건에서도 재현되는지 검증 중 → 5회 중 4회 완료, 현재 평균 +1.83% → RQ2

[예정]

- 800만 건에서도 쿼리 범위별 KM20 vs RANDOM20 격차 재현 확인 → RQ1+RQ2
- 다른 종류의 벡터(SIFT 128d)에서도 같은 패턴이 나타나는지 검증 → RQ1+RQ2

- 1M에서 중간 쿼리 범위(10%, 30%) 추가 측정하여 그래프 보충 → RQ1+RQ2

17:18 조현빈

- 파일: [속도는벡터_2차 자문요청.pdf](#)
- 자문 요청은 이 파일로 하면 될 것 같은데
- 세은님이 메일 보내실래요?

17:29 박세은

넵 지금 작성 중입니다

17:40 박세은

메일 드렸습니다. 모두 참조에 걸어서, 확인 가능하실 것 같습니다

17:40 조현빈

네 확인했습니다

20:50 조현빈 — [실험 완료] 8M KM20 vs BERN ($s=0.500$, 외적 타당성)

1M에서 확인한 +1.64% 개선이 800만 건에서도 재현되는지 검증

- 5-seed 평균 **+1.76%** (95% CI [1.10%, 2.39%])
- 5회 중 4회 통계적으로 유의
- 1M 결과와 **CONSISTENT** 판정

seed	개선	p-value
0.1	+1.54%	0.039*
0.2	+2.37%	0.0001***
0.3	+2.85%	0.001**
0.4	+0.55%	0.189
0.5	+1.47%	0.013*

결과 파일: [experiments/results/rq2_aware/8m_km20_s0500_5seed.json](#) 다음 실험: 8M RANDOM20 gradient (현재 진행 중)

22:45 조현빈

다음 실험은 규모가 커서 내일 아침은 돼야 끝나겠네요

22:46 조현빈

혹시 문서 보시고 피드백 주실 분들은 카톡 남겨주세요. 내일 계속 진행/수정해볼게요

2026-04-16 (목)

07:29 조현빈 — RQ1/RQ2 실험 현황 (4/16 07:20 기준)

[완료]

- 1M 벡터를 20개 그룹으로 클러스터링 → 그룹 크기가 최소 2.6만~최대 8.1만으로 데이터가 특정 영역에 몰려 있음을 확인 → RQ1
- Exqutor 소스 코드 분석 → 단일 테이블 쿼리를 제대로 처리하지 못하는 설계 제약 5종 발견, 연구 범위를 단일 테이블로 전환 → RQ1
- Exqutor 기본 샘플링 방식(SYSTEM)을 통계적으로 더 정확한 방식(BERNOULLI)으로 교체 → +3.8~9.6% 개선 → RQ2

4. 1M에서 공간 구조를 반영한 층화 샘플링(KM20) 직접 구현 → 기존 대비 +1.64% 추가 개선 (5회 반복, 통계적으로 유의) → RQ2
5. 1M에서 같은 층화 샘플링을 "공간 구조를 아는 파티션(KM20)" vs "무작위 파티션(RANDOM20)"으로 비교 → 넓은 쿼리에서는 차이 없지만, 좁은 쿼리에서는 19.6%p 격차 발생. 쓸림이 성능 저하의 원인임을 직접 증명 → RQ1+RQ2
6. 위 대조 실험에서 개선 효과가 "표본 크기 안정화"와 "공간 인식" 두 경로로 분리됨을 발견 (Two-Level Decomposition) → RQ1+RQ2
7. 800만 건(8M)에서도 KM20 층화 샘플링이 재현되는지 검증 → 5-seed 평균 +1.76%, 1M과 일관된 결과 확인 → RQ2

[진행 중]

- 800만 건에서도 쿼리 범위별 KM20 vs RANDOM20 격차가 재현되는지 검증 중 → KM20/RANDOM20 양쪽 3개 selectivity 측정 중, RANDOM20 s=0.500 3/5 seed 완료 (나머지 ~09:00 완료 예상) → RQ1+RQ2

[예정]

- SIFT 128d(1M과 다른 종류의 벡터)에서 거리 임계값 재계산 후 KM20 vs BERN 검증 → RQ2
- SIFT 128d에서도 KM20 vs RANDOM20 격차가 나타나는지 검증 → RQ1+RQ2
- 1M에서 중간 쿼리 범위(10%, 30%) 추가 측정하여 selectivity gradient 그래프 보충 → RQ1+RQ2

11:02 조현빈 — RQ1/RQ2 실험 현황 (4/16 11:00 기준)

[완료]

1. 1M 벡터를 20개 그룹으로 클러스터링 → 그룹 크기가 최소 2.6만~최대 8.1만으로 데이터가 특정 영역에 몰려 있음을 확인 → RQ1
2. Exquator 소스 코드 분석 → 단일 테이블 쿼리를 제대로 처리하지 못하는 설계 제약 5종 발견, 연구 범위를 단일 테이블로 전환 → RQ1
3. Exquator 기본 샘플링 방식(SYSTEM)을 통계적으로 더 정확한 방식(BERNOULLI)으로 교체 → +3.8~9.6% 개선 → RQ2
4. 1M에서 공간 구조를 반영한 층화 샘플링(KM20) 직접 구현 → 기존 대비 +1.64% 추가 개선 (5회 반복, 통계적으로 유의) → RQ2
5. 1M에서 같은 층화 샘플링을 "공간 구조를 아는 파티션(KM20)" vs "무작위 파티션(RANDOM20)"으로 비교 → 넓은 쿼리에서는 차이 없지만, 좁은 쿼리에서는 19.6%p 격차 발생. 쓸림이 성능 저하의 원인임을 직접 증명 → RQ1+RQ2
6. 위 대조 실험에서 개선 효과가 "표본 크기 안정화"와 "공간 인식" 두 경로로 분리됨을 발견 (Two-Level Decomposition) → RQ1+RQ2
7. 800만 건(8M)에서도 KM20 층화 샘플링이 재현되는지 검증 → 5-seed 평균 +1.76%, 1M과 일관된 결과 확인 → RQ2

8. 800만 건에서도 쿼리 범위별 KM20 vs RANDOM20 비교 → $s=0.500$ 에서 양쪽 모두 개선 (표본 안정화 효과), $s=0.010$ 은 측정 노이즈 지배적 → RQ1+RQ2

9. SIFT 128d에 대한 거리 임계값(D_{target}) 재계산 완료 → RQ2

[진행 중]

- SIFT 128d(다른 종류의 벡터)에서 KM20 층화 샘플링의 개선 효과 검증 중 → RQ2

[예정]

- SIFT 128d에서도 KM20 vs RANDOM20 격차가 나타나는지 검증 → RQ1+RQ2
- 1M에서 중간 쿼리 범위(10%, 30%) 추가 측정하여 selectivity gradient 그래프 보충 → RQ1+RQ2

14:49 박세은 — 현재 상황 정리 요청

현재 상황을 정리해보면, DEEP 데이터셋에 대해서 실험. 기본적으로 block 단위였던 것을 바꿔서 row 단위 sampling 인 bernoulli 샘플링을 하였고 이게 샘플 안정화 레벨, 그리고 거기서 나아가 데이터셋을 20개로 쪼갤 때 거리-aware 방식인 KM20 이나 거리 무시 방식인 RANDOM20 으로 해봤을 때 차이가 나는 것도 확인했고 이게 공간 인식 레벨. 지금은 1퍼센트 근처의 소소한 개선을 확인. 이런 내용인 게 맞나요?

14:51 조현빈 — 단계 구분 보정

큰 틀은 맞는데, 단계 구분을 약간 보정하면:

1단계: SYSTEM → BERNOULLI (block → row) - 이걸 Exqutor 의 기존 방식이 비효율적이었던 걸 고친 것 (+3.8~9.6%) - 우리 연구의 기여라기보다 baseline 교정

2단계: BERNOULLI → Stratified (층화 샘플링) 여기서 Two-Level 이 나뉜다: - **Level 1 (표본 안정화)**: 20개로 쪼개서 비례 배분만 해도 표본 크기가 안정됨. KM20 이든 RANDOM20 이든 발생. $s=0.500$ 에서 둘 다 개선되는 게 이 효과. - **Level 2 (공간 인식)**: 쪼개는 방식이 거리 기반(KM20) 일 때만 추가 이점. 좁은 쿼리에서 KM20 과 RANDOM20 이 격차 벌어지는 게 이 효과.

개선 폭: - DEEP 1M/8M $s=0.500$: +1.6~1.8% (소소하지만 통계적으로 유의) - 그런데 지금 돌아가고 있는 SIFT 는 $s=0.500$ 에서 +3.07% ($p<1e-8$), $s=0.050$ 에서 +4.39% — 데이터셋에 따라 효과 크기가 달라진다

그래서 "1% 근처 소소한 개선" 은 DEEP 에 한정된 얘기고, SIFT 에서는 3~4% 로 더 크다. 이렇게 정리할 수 있겠네요.

14:52 박세은

네네 사실 DEEP 데이터셋이 균일한 데이터셋이고 SIFT 데이터셋이 skew 한 데이터셋으로 여겨졌었거든요. 그래서 SIFT 에서 효과가 더 큰 게 맞는데 3% 정도면 생각보다 작네요.

14:52~14:53 조현빈

- 아직 SIFT 가 실험이 다 안돼서
- SIFT 128d 에서 KM20 샘플링 하고
- RANDOM20 샘플링 해서
- 비교까지 해봐야 정확할 것 같긴 해요
- 아직 데이터를 다 받지는 못하고 진행 중이어서
- 오늘 중으로 다 될 것 같긴 한데 실험이 계속 이어서 진행하고 있어서

14:53 박세은

저는 사실 DEEP 랜덤 샘플링 vs. SIFT 랜덤 샘플링이 첫 실험일 줄 알았어요. 나이브하게 생각했을 때는

14:54 박세은

그런데 DEEP 에서도 이렇게 여러 계층의 실험을 해주셔서 내용이 풍부할 것 같네요

14:54 조현빈

네, 내용만 취사선택하면 될 것 같아요

17:58 조현빈 — 실험 결과 공유

- 파일: [RQ1_RQ2 실험 결과 정리.pdf](#)
- git 에 experiments 에 데이터들 다 있으니까 확인해보셔도 돼요

18:49 조현빈

자문 피드백 오면 그거 반영해서 중간 발표 준비 할까요?! 그때까진 추가로 할 건 없을 거 같은데

18:50 조현빈

지도확인서만 한 명이 RQ1, RQ2 관련해서 실험 진행했다고 서술하면 될 것 같은데

19:22 박세은

넵 자문 피드백 금방 주실 것 같아서 그때까지는 각자 할 것(시험공부 등...) 하면서 기다릴까요?

19:23 조현빈

네! 어차피 따로 준비할 건 없고 이제 시험보고서 발표 내용하고 PPT 만들고. 내용 이해만 하면 될 것 같아요~!! 딱히 뭐 저는 시험 신경 안 써서 RQ3 는 어떤 게 좋을지 Claude 랑 같이 여러 선택지로 알아봐볼게요!

19:39 강재현

어제오늘 과제 땀에 시간 많이 못 썼는데 오늘 밤에 확인해볼게요. 나중에 발표자료랑 발표는 담당하겠습니다.

19:44 박세은

그럼 저희 오늘은 지도확인서 내용만 작성해보면 될 것 같네요

19:54 조현빈 — 지도확인서 초안

제가 초안 드릴게요!

4월 3일 교수님 지도 미팅에서 확인한 "데이터 쓸림 → uniform sampling 성능 저하 → 개선된 sampling" 프레임िंग에 따라, RQ1(문제 제기) 과 RQ2(개선 방안) 에 대한 실험을 수행하였다.

RQ1 에서는 DEEP 96d 와 SIFT 128d 두 종류의 벡터 데이터셋에 대해 k-means 클러스터링을 수행하여 공간적 쓸림을 확인하고, 공간 구조를 반영한 파티션(KM20) 과 무작위 파티션(RANDOM20) 의 대조 실험을 통해 쓸림이 추정 정확도 저하의 원인임을 검증하였다.

RQ2 에서는 KM20 기반 층화 샘플링을 Exqutor 소스에 직접 구현하여, DEEP 1M/8M 및 SIFT 1.5M 세 가지 데이터셋에서 기존 대비 +1.6~4.4% 의 추정 정확도 개선을 확인하였다. 또한 개선 효과가 "표본 크기 안정화" 와 "공간 인식" 두 경로로 분리됨을 발견하였다(Two-Level Decomposition).

중간 발표에서는 RQ1 과 RQ2 의 실험 결과를 보고하고, 최종 발표에서 RQ3(분포를 사전에 모를 때의 적응형 층화 샘플링) 을 다룰 예정이다.

20:03 박세은

넵 이거 활용해서 지도내역서 작성하고 내일 서명받겠습니다

20:04 조현빈

넵!

2026-04-17 (금)

12:11 조현빈 — 중간발표 PPT 초안 공유

- 파일: [속도는벡터_중간발표_20260417_0000.pptx](#)
- 대충 초안이고 git 에 업로드 해봤습니다

12:12 조현빈

- (사진)
- 이런 건 그대로 써도 될 것 같기도 하고, 디자인 업그레이드 할 거 있으면 해도 좋을 것 같아요

12:15 박세은

Figure 들은 전반적으로 그대로 써도 될 퀄리티인 것 같아요

12:22 이동욱

PPT 제가 담주에 시험 끝나고 바로 한번 다듬어볼게요

12:22 조현빈

사실 PPT 다듬기보다는 일단 보고서 내용을 결정해야 돼서

12:23 조현빈

전반적으로 검토부터 하는 게 필요합니다. 실험은 더 진행 안 해도 데이터는 충분한 것 같아서. 내용/방향을 확실하게 결정하는 게 중요할 것 같습니다. 자문 피드백 오면 반영할 부분 고려하고

12:23 이동욱

그 보고서 내용이 깃헙에 올라와있는 거도 초안인 거죠?

12:24 조현빈

네, 260417_0000 기준이요

12:46 조현빈 — 팀원 온보딩 문서 공유

현재 흐름을 이해하기 어려울 것 같아서 따로 문서화해봤습니다. git 에도 업데이트 되어있구요

- 파일: [팀원 온보딩_20260417.pdf](#)

이 대화의 의의 — 기록 관점

1. **실험 진행 로그의 타임스탬프 축적:** 4/15 17:15 초기 현황 → 4/15 20:50 8M KM20 완료 → 4/16 07:29 → 4/16 11:02 → 최종 4/16 17:58 결과 PDF 공유. 실험 완료 시점과 각 이정표 발생 시점이 본 기록으로 실시간 고정됨.
2. **박세은 팀장의 프레이밍 정교화 기여 (4/16 14:49~14:54):** "1% 근처 소소한 개선"이라는 초기 인식이 조현빈의 2단계 Two-Level 재설명 + SIFT 3~4% 숫자 공개로 보정되었고, 이 대화가 이후 중간보고서 §4.9~§4.10 narrative 에 영향을 주었다.
3. **지도확인서 문구 확정 (4/16 19:54):** 이 문구가 확인서 6차의 실제 서술 근거로 사용됨.
4. **역할 분담 확정 (4/16 19:23, 19:39):** 조현빈 RQ3 탐색 + 시험 없는 상태 지속 작업, 강재현 발표자료·발표 담당. 이후 4/17 overnight 커밋 [2feb998](#) 에서 "발표자 강재현" 공식 확정으로 이어짐.
5. **"실험은 충분하다" 판단 (4/17 12:23):** 팀 공식 차원에서 "실험 종료, 내용/방향 결정이 본선" 임이 선언됨. 이 대화 이후 세션의 모든 작업이 **실험** → **문서** 로 초점 이동.

원문 그대로 인용을 원칙으로 하되, 가독성을 위해 개행·마크다운 강조·표 포맷만 적용함. 오타/띄어쓰기 일부 교정 포함.