


실험 과정 모식도

전체 구조: "쓸림 → 성능 저하 → 개선"

교수님 핵심 질문
"데이터가 쓸려있을 때 → uniform이 나빠지고 → 개선된 sampling"



실험 타임라인

Phase 1~2 (RQ1)	8개 skewness 지표 × 6 selectivity → 전부 상관 < 0.2 → "글로벌 지표로는 쓸림 포착 불가" → data-side partition 필요성 정당화
Phase 3	Exqutor design constraint 5종 발견 → "왜 Exqutor가 이런 구조인지" 학술적 기여
Phase 4 (개선 1)	Pivot A: block → row sampling 교체 → +3.8~9.6% 개선 (4구간 $p < 0.001$)
Phase 5	로컬 skewness 지표 4종 추가 → 역시 무상관 → data-side partition 방향 재확인
Phase 6 (개선 2)	Pivot C: KM20 stratified sampling 구현 → $s=0.500$ 에서 +1.64% (5-seed CI [1.25, 2.02])
★ 현재	RANDOM20 Control Experiment (오늘 완료) → "쓸림이 원인임을 증명"하는 대조 실험

★ RANDOM20 대조 실험 결과 (오늘)

실험 설계:

같은 stratified sampling 코드를 두 가지 partition으로 비교

KM20 partition

k-means로
공간 구조
반영한 20개
클러스터

vs

RANDOM20 partition

무작위로
20개 그룹
(공간 구조
무시)

결과 - Selectivity Gradient:

query 범위	KM20 (공간 인식)	RANDOM20 (무작위)	차이
넓은 (s=0.5)	+1.64%	+2.20%	~0
중간 (s=0.05)	+1.85%	+0.79%	+1.1%p
좁은 (s=0.01)	★ +8.93%	★ -10.67%	+19.6%p

해석:

넓은 범위: 데이터가 전체에 퍼짐
→ 아무렇게나 나눠도 OK → 공간 인식 불필요

좁은 범위: 데이터가 특정 영역에 집중
→ 그 영역을 정확히 알아야 함 → 공간 인식 필수
→ 무작위로 나누면 오히려 악화 (-10.67%)

= 교수님의 "쏟림 → 성능 저하 → 개선" 실험적 확인

다음 단계

지금까지 (4/15)

- ✓ Phase 1~6 완료
- ✓ RANDOM20 대조 완료
- ✓ selectivity gradient 확인

앞으로 (→4/28 중간발표)

- 중간보고서/슬라이드 반영
- 자문이메일 (4/16 마감)
- 8M 외적 타당성 재측정
- HHI 집중도 정량 분석
- RQ3: KDE-pilot / LSH-bucket
(최종발표까지)