

RANDOM20 Control 실험 결과 공유

박세은 요약에 대한 답변

세은이가 정리한 내용 대부분 맞아요! 한 가지 업데이트가 있어서 실험 결과와 함께 공유합니다.

맞는 부분

- ✓ skewness 측정치 → Q-error 무상관 → 사용 안 함
- ✓ 1단계: block → row 샘플링 (Pivot A)
- ✓ 2단계: KM20 클러스터링 → 각 클러스터에서 샘플링 (Pivot C)
- ✓ KM20: +1.64% 개선

수정 부분

"RANDOM20 실험 결과는 개선 없음으로 예상"

→ 실험해봤더니 **selectivity**에 따라 결과가 달라졌습니다.

실험 결과

RANDOM20 = 데이터를 무작위로 20개 그룹으로 나눈 뒤 같은 stratified sampling 적용. KM20과의 차이 = "공간 구조를 아느냐 모르느냐".

selectivity	KM20 (공간 인식)	RANDOM20 (무작위)	차이
0.500 (넓은 범위)	+1.64%	+2.20%	거의 같음
0.050 (중간 범위)	+1.85%	+0.79%	KM20 약간 우세
0.010 (좁은 범위)	+8.93%	-10.67%	KM20이 19.6%p 우세

핵심 발견

selectivity가 낮을수록 (= query가 찾는 데이터가 특정 영역에 집중될수록): - KM20 (공간 구조를 아는 상태): **개선 폭이 커진다** (+1.6% → +8.9%) - RANDOM20 (공간 구조를 모르는 상태): **오히려 나빠진다** (+2.2% → -10.7%)

교수님 프레이밍과의 연결

이 결과는 교수님이 말씀하신 "데이터가 쏠려있을 때 → 기존 방식이 나빠지고 → 개선된 sampling으로 해결"과 정확히 일치합니다.

구체적으로: 1. **데이터가 쏠려있다**: cluster 크기가 26K~81K (3배 차이) 2. **좁은 범위를 찾을 때 쏠림이 더 심하다**: $s=0.010$ 에서 true matches가 소수 cluster에 집중 3. **공간 구조를 아는 sampling만 개선**: KM20은 +8.93%, 무작위(RANDOM20)는 -10.67%

이게 뭘 의미하나

- **넓은 범위 query** ($s=0.500$): 어차피 데이터가 전체에 퍼져있어서, 아무렇게나 나눠도 비슷한 결과 → "공간 인식" 불필요
- **좁은 범위 query** ($s=0.010$): 찾는 데이터가 특정 영역에 몰려있어서, 그 영역을 정확히 알아야 제대로 추정 → "공간 인식" 필수

→ 교수님의 "쏠림 → 성능 저하 → 개선" 프레이밍이 실험적으로 확인됨.

다음 할 일

1. 이 결과를 중간보고서/슬라이드에 반영
2. 자문 이메일 (내일 마감) — 이 결과를 핵심으로 재작성
3. 각 selectivity에서 "얼마나 쏠려있는지" (cluster 집중도) 정량 분석

git

```
git pull origin main
```

하면 최신 결과 받을 수 있어요. 주요 파일: -
experiments/results/rq1_motivation/random20_selectivity_gradient.md — 전체 분석 - plans/연구재설계
안_20260415.md — 연구 재설계안