

[16] Scalable Similarity Search for Big Data

저자: Pavel Zezula (Masaryk University, Czech Republic) 학회/년도: Springer INFOSCALE 2015 (초청 강연)

분량: 초청 논문/서베이, 약 12페이지 역할군: (D) 이론적 기반

요약

이 서베이 논문은 대규모 유사도 검색의 **이론적 기초**를 제공한다. **메트릭 공간(metric space)** 이론이라는 수학적 근거 위에서 유사도 검색을 정의하며, "왜 벡터 검색의 결과 건수를 예측하기 어려운가"를 이론적으로 설명한다.

핵심 기여: 1. **메트릭 공간의 기하학적 성질**: 고차원 공간에서의 거리 분포 특성 분석 2. **M-tree 인덱스 구조**: 메트릭 공간의 분할 기반 동적 인덱스 3. **고차원의 저주와 카디널리티**: 거리 집중(concentration) 현상의 수학적 분석 4. **분산 환경으로의 확장**: 빅데이터 환경에서의 유사도 검색

이 논문은 Exqutor가 통계 기반이 아닌 실제 인덱스 탐색 기반의 카디널리티 추정을 선택한 이유의 이론적 근거를 제공한다.

상세분석

16.1 해결하고자 하는 문제: 빅데이터 시대의 유사도 검색

세 가지 핵심 도전 과제:

- 확장성(Scalability)**: - 데이터가 수십억 건에서 수조 건으로 증가해도 응답 시간이 허용 범위 내여야 한다. - 기존 풀 스캔(brute-force) 방식은 $O(n)$ 복잡도이므로, 데이터 크기 n 이 1000배 증가하면 응답 시간도 1000배 증가한다. 이는 참을 수 없다. - 인덱스를 통해 $O(\log n)$ 또는 $O(\log^k n)$ 수준으로 개선해야 한다.
- 프라이버시 보존(Privacy Preservation)**: - 클라우드 아웃소싱 환경에서 원본 데이터는 공개하지 않으면서 유사도 검색을 수행해야 한다. - 암호화된 데이터에 대한 검색(searchable encryption) 기술이 필요하다.
- 멀티모달 통합(Multimodal Integration)**: - 텍스트, 이미지, 오디오, 비디오 등 서로 다른 모달리티의 데이터를 하나의 통합 프레임워크에서 검색해야 한다. - 각 모달리티를 공통 벡터 공간으로 매핑하는 임베딩 기술이 필요하다.

16.2 메트릭 공간(Metric Space) 이론: 수학적 기초

메트릭 공간의 정의:

메트릭 공간 (X, d) 는 집합 X 와 거리 함수 $d: X \times X \rightarrow \mathbb{R}$ 로 구성되며, 거리 함수가 다음 공리를 만족한다:

1. 양의 정부호성 (Positivity):

2. $d(x, y) \geq 0$ (거리는 항상 0 이상)

3. $d(x, y) = 0 \iff x = y$ (같은 점 사이의 거리만 0)

4. 대칭성 (Symmetry):

5. $d(x, y) = d(y, x)$ (x 에서 y 까지의 거리 = y 에서 x 까지의 거리)

6. 삼각 부등식 (Triangle Inequality):

7. $d(x, z) \leq d(x, y) + d(y, z)$ (우회하는 것보다 직접 가는 것이 가깝다)

삼각 부등식의 힘:

삼각 부등식이 핵심이다. 이 성질 덕분에:

$$d(x, z) \leq d(x, y) + d(y, z)$$

만약 $d(x, y) + d(y, z) <$ 현재까지의 최소 거리 라면, $d(x, z)$ 는 이미 본 것보다 작을 수 없다. 따라서 **z 를 검사할 필요 없다.**

이런 식으로 많은 거리 계산을 건너뛰(prune) 수 있어, 전수 검색 없이도 유사도 검색이 가능하다.

예시: 뉴욕 지도에서의 거리

삼각 부등식: $d(A, C) \leq d(A, B) + d(B, C)$


뜻: A에서 C까지의 직선거리 $\leq$ A→B→C의 경로거리

이 성질을 활용하면: - A에서 거리 5km 이내인 장소를 찾을 때 - B를 거쳐가는 모든 경로를 검사하는 것이 아니라 - A에서 거리 5km 이내의 "동네" 영역만 검색하면 된다.

16.3 M-tree: 메트릭 공간의 동적 인덱스 구조

M-tree의 개념:

M-tree는 B-tree처럼 균형 잡힌 트리 구조를 메트릭 공간에 적용한 것이다.



각 노드는: - **중심점(pivot/representative)**: 그 부분트리를 대표하는 점 - **반경(covering radius)**: 중심점으로 부터 이 부분트리의 가장 먼 점까지의 거리

검색 과정:

쿼리 점 q에서 거리 r 이내의 모든 점을 찾을 때:

1. 루트 노드부터 시작
2. 각 자식 노드에 대해:
 - 삼각 부등식으로 가지 제거(pruning):
 $d(q, \text{자식중심}) - \text{자식반경} > r$ 이면
 → 이 가지는 검색할 필요 없음
 - 그 외는 재귀적으로 탐색
3. 리프 노드에서 정확한 거리 계산 및 필터링

M-tree의 장점: - 동적 삽입/삭제 지원 (B-tree처럼) - 다양한 메트릭(유클리드, 맨해튼, 편집 거리 등) 지원 - 메트릭 공간의 특성만 만족하면 모든 데이터 타입 지원

16.4 고차원의 저주와 거리 분포의 집중(Concentration)

고차원 공간의 기하학적 성질:

차원이 높아질수록 흥미로운(그리고 직관에 반하는) 현상들이 일어난다:

1. 거리의 집중(Distance Concentration):

고차원 공간에서 모든 점 사이의 거리가 거의 같아진다.

예시: 무작위 단위 벡터 1,000개 생성

차원	최소 거리	최대 거리	차이
2D	0.1	1.9	1.8
10D	1.2	1.5	0.3
100D	1.41	1.42	0.01
1000D	1.414	1.415	0.001

1000차원에서는 모든 점이 서로 거의 같은 거리(약 $\sqrt{2} \approx 1.414$)에 있다!

수학적 설명:

d차원 공간에서 무작위 단위 벡터들 사이의 거리 $E[D]$ 는:

$$E[D] \approx \sqrt{(2d/\pi) \times (1 - 1/(4d) + O(1/d^2))}$$

$$d \rightarrow \infty \text{ 일 때, 표준편차 } \sigma[D] \approx \sqrt{(1/(2d))}$$

거리의 변동 계수(coefficient of variation):

$$CV = \sigma[D] / E[D] \approx \sqrt{(\pi/(2d))}$$

이것은 d에 반비례하므로, 차원이 높아질수록 거리 분포가 더 집중된다.

2. "저주"의 의미:

거리가 집중되면:

모든 데이터 점 사이의 거리가 비슷함

↓

거리 임계값 $d(q, x) < r$ 을 만족하는 점의 비율이 급격히 변함

↓

카디널리티를 정확히 예측하기 극도로 어려움

예: 쿼리 반경 r 을 0.1 증가시키면: - 저차원: 결과 점 10% 증가 - 고차원: 결과 점 200% 증가 (넓이 vs. 부피 증가의 차이)

16.5 고차원 카디널리티 추정의 어려움

히스토그램 기반 통계의 한계:

관계형 DB는 스칼라 값의 카디널리티 추정을 위해 히스토그램을 사용한다:

값 범위	튜플 개수
0~100	1,000
100~200	2,000
200~300	800

가격이 150인 상품 수를 추정하려면, 100~200 범위의 히스토그램을 보면 된다.

하지만 벡터 거리에는 이런 방식이 작동하지 않는다:

WHERE embedding <=> query < 0.1

이 조건을 만족하는 벡터의 개수는: - 데이터 분포에 완전히 의존 - 쿼리 벡터의 위치에 의존 - 임계값의 작은 변화에 극도로 민감

예: - $r = 0.09$: 결과 1,000개 - $r = 0.10$: 결과 10,000개 - $r = 0.11$: 결과 50,000개

히스토그램을 구성하려면 쿼리 벡터마다 미리 거리를 계산하고 저장해야 하는데, 이는 불가능하다 (쿼리마다 다르기 때문).

16.6 본 논문과의 관계

이 논문이 보여주는 것:

1. 벡터 카디널리티 추정의 이론적 어려움:

고차원 공간에서 거리 분포의 집중 현상이 일어나므로, 기존의 통계 기반 추정(히스토그램)은 근본적으로 작동할 수 없다.

2. Exqutor가 통계 기반 대신 실제 탐색 기반을 선택한 이유:

카디널리티를 정확히 얻는 유일한 방법은: - 실제 인덱스를 탐색해서 결과를 세는 것

Exqutor의 ECQO는 이 철학을 따른다:

쿼리 플래너 단계 → ECQO 혹은 실제 인덱스 범위 탐색 (1~2ms)
→ 정확한 카디널리티 얻음 → 옵티마이저에 전달 → 최적 계획

3. 왜 Exqutor의 1~2ms 오버헤드가 정당한가:

쿼리 실행 시간이 수백ms ~ 수초인데, 플래너 단계에서 1~2ms를 투자하여 최적 계획을 얻는 것은 매우 합리적이다.

특히 선택도가 극도로 불확실한 경우(0.1%에서 90%까지 변할 수 있는 경우), 정확한 추정 비용 1~2ms는 하찮다.

16.7 메트릭 공간 이론과 현대 벡터 검색의 연결

2015년 논문의 한계:

이 서베이는 2015년 기준이므로: - HNSW, DiskANN 같은 최근 그래프 기반 인덱스는 다루지 않음 - 학습된 인덱스(learned index) 개념은 없음 - 신경망 기반 임베딩의 고차원 특성은 다루지 않음

하지만 기본 원리는 여전히 유효:

메트릭 공간의 거리 집중 현상은 변하지 않으므로, HNSW나 DiskANN을 사용하더라도 카디널리티 추정 문제는 여전히 존재한다.

추가 제기 문제

1. **적응적 인덱스 구조**: M-tree는 정적이지만, 데이터가 자주 업데이트되는 환경에서는 재구축 비용이 크다. 동적 데이터 환경에 최적화된 인덱스 구조 연구가 필요하다.
2. **고차원 특화 인덱스**: 메트릭 공간 이론은 일반적이지만, 특정 차원 범위(예: 768차원 BERT 벡터)에 최적화된 인덱스를 설계하는 것이 가능할까?
3. **카디널리티 상한/하한 추정**: 정확한 값을 얻을 수 없다면, 최소한 상한과 하한을 빠르게 추정할 수 있는 방법이 있을까? 이를 통해 옵티마이저가 비효율적인 선택을 피할 수 있을까?
4. **멀티모달 통합의 현실화**: 논문은 멀티모달 통합을 언급하지만, 실제로 텍스트, 이미지, 오디오를 하나의 메트릭 공간으로 통합하는 것의 실무적 난제는 무엇인가?