

[21] DNA Sequence Classification with Milvus

저자: Milvus Team 유형: 기술 블로그 포스트, milvus.io 분량: 블로그 포스트 (수 페이지) 역할군: (A) VAQ 동기 부여

요약

이 자료는 전문 벡터 DB인 Milvus를 이용하여 DNA 서열 분류를 수행하는 실제 응용 사례를 보여준다. DNA 서열을 벡터로 변환하고 Milvus에서 유사도 검색을 통해 알려진 서열을 찾아 분류하는 파이프라인을 설명한다. 단순한 벡터 검색뿐 아니라 **종(species), GC 함량, 서열 길이 같은 메타데이터 필터**와 검색을 함께 사용한다는 점이 중요하다. 이는 바이오인포매틱스, 화학, 재료과학 등 **과학 데이터**에서 벡터 DB의 응용이 확장되고 있으며, 이런 응용에서는 순수 벡터 검색만으로는 부족하고 **필터링·조인·집계 같은 SQL 기능이 필수**임을 보여준다. Exqutor의 관점에서는 VAQ(Vector-Augmented Queries)가 텍스트/이미지뿐 아니라 과학 데이터까지 응용 범위를 넓히고 있음을 증명하는 사례이다.

상세분석

21.1 DNA 서열과 벡터화의 기초

DNA 데이터의 특성

DNA는 4가지 뉴클레오티드(핵염기)로 이루어진 서열이다: - **A** (아데닌, Adenine) - **T** (티민, Thymine) - **G** (구아닌, Guanine) - **C** (사이토신, Cytosine)

예시 DNA 서열:

```
>genome_123
ATCGATCGATCGATCGTAGCTAGCTAGCTAGC...
```

DNA 서열의 특징: - 길이: 수백 개 (미토콘드리아 DNA) ~ 수십억 개 (인간 게놈) - 정보 함량: 각 위치의 뉴클레오티드는 유전 정보를 담음 - 기능적 보존: 진화 과정에서 같은 기능을 하는 서열은 변하지 않음 (보존 영역)

왜 벡터화가 필요한가?

DNA를 직접 비교하는 것은 매우 비싸다:

Traditional approach:

SEQUENCE 1: ATCGATCG...	(100만 글자)
SEQUENCE 2: ATCGAGCG...	(100만 글자)
비교 알고리즘: 동적 계획	
시간 복잡도: $O(n * m)$	
= $O(100만 * 100만)$	
= 조 번의 연산	

결과: 백만 시퀀스에서 가장 비슷한 것을 찾으려면?

- $1조 \times 100만$ = 극우주 수준의 연산
- 실용적이지 않음

벡터화의 해결책:

Vectorization approach:

SEQUENCE 1
→ k-mer 분석
→ 벡터로 변환
→ 벡터 1536D

비교: 두 1536차원 벡터 거리 계산

시간 복잡도: $O(1536)$ = ~수천 번의 연산

결과: 100만 시퀀스 검색도 초 단위로 완료

21.2 DNA 서열의 벡터 표현 방법

방법 1: k-mer 기반 특징 벡터

k-mer의 개념:

DNA 서열: ATCGATCGATCG

k=3 (3-mer 추출):

ATC, TCG, CGA, GAT, ATC, TCG, CGA, ATC, TCG, ATG...

k-mer 빈도 벡터:

전체 가능한 3-mer: $4^3 = 64$ 가지

각 3-mer의 빈도를 64차원 벡터로 표현

예시:

AAA: 0, AAC: 0, AAG: 1, AAT: 0,

ACA: 2, ACC: 0, ACG: 1, ACT: 0,

...

TTT: 0, TTC: 1, TTG: 0, TTT: 0

결과 벡터: [0, 0, 1, 0, 2, 0, 1, 0, ..., 0, 1, 0, 0]

특성:

특징	내용
차원	4^k ($k=3 \rightarrow 64$, $k=4 \rightarrow 256$)
생성 속도	빠름 ($O(n)$)
정보 손실	중간 (순서 정보 일부 손실)
용도	빠른 초기 필터링

k값의 선택:

k=2: 16차원, 너무 간단 (기능 구분 어려움)

k=3: 64차원, 일반적 (빠르고 충분한 정보)

k=4: 256차원, 더 정확 (계산 비용 증가)

k=5+: 고차원, 느림 (실시간 검색 부적절)

방법 2: 사전학습 딥러닝 임베딩 모델

DNA2Vec / DNABERT:

전통적 NLP 모델을 DNA에 적용:

DNABERT (DNA BERT):

1. DNA를 "토큰"으로 취급 (k-mer 또는 코돈)
2. 사전학습 언어 모델 (BERT)을 DNA 데이터로 미세조정
3. 각 DNA 서열을 고정 길이 벡터로 변환
4. 유사한 기능의 DNA는 벡터 공간에서 가까이 위치

장점:

- 생물학적 의미를 포착 (기능 유사성)
- 1536차원 밀집 벡터 (정보 손실 적음)
- 사전학습으로 일반화 성능 우수

단점:

- 계산 비용 높음 (GPU 필요)
- 블랙박스 모델 (해석 어려움)
- 재학습 비용

방법 3: 하이브리드 방식

DNABERT 임베딩 + k-mer 특징의 하이브리드:

DNABERT: 의미 정보 (기능 유사성)
k-mer: 해석 가능 정보 (서열 특성)

1. DNABERT로 1536D 벡터 생성
2. k-mer 특징 64D 추가
3. 총 1600D 벡터로 검색

이점:

- 검색 정확도 향상 (두 관점 모두 고려)
- 결과 해석 가능 (k-mer 기여도 확인)

21.3 DNA 분류 파이프라인

기본 구조

1. 쿼리 DNA 서열 입력

예: 새로운 박테리아 서열

↓

2. 벡터 변환

- k-mer 추출

- DNABERT 임베딩

- 결과: 1536D 벡터

↓

3. Milvus에서 유사 검색

```

SELECT id, species, sequence

FROM dna\_collection

WHERE embedding <-> query\_vec < threshold

LIMIT 10

```

결과: 유사한 서열 10개

↓

4. 분류 결정

- 검색된 서열의 종(species)을 확인

- 투표 방식: 상위 10개 중 가장 많은 종

- 신뢰도: 최상위 결과의 거리로 측정

결과: 새로운 서열 = "종 X"로 분류

구체적 코드 예시

```
import milvus
import numpy as np
from sklearn.preprocessing import normalize

# 1. Milvus 연결
client = milvus.Milvus(host='localhost', port=19530)

# 2. DNA 벡터화
from transformers import AutoTokenizer, AutoModel

tokenizer = AutoTokenizer.from_pretrained("dnabert")
model = AutoModel.from_pretrained("dnabert")

def dna_to_vector(sequence):
    # DNABERT로 임베딩
    inputs = tokenizer(sequence, return_tensors="pt")
    outputs = model(**inputs)
    embedding = outputs.last_hidden_state[:, 0, :].detach().numpy()
    return normalize(embedding)[0] # 정규화

# 3. 쿼리 실행
query_sequence = "ATCGATCGATCGATCGATCG..."
query_vector = dna_to_vector(query_sequence)

# 4. Milvus에서 검색
results = client.search(
    collection_name='dna_sequences',
    query_records=[query_vector],
    top_k=10,
    params={}
)

# 5. 결과 분석
species_votes = {}
for result in results[0]:
    species = metadata[result.id]['species']
    species_votes[species] = species_votes.get(species, 0) + 1

predicted_species = max(species_votes, key=species_votes.get)
confidence = max(species_votes.values()) / 10 # 상위 10개 중 비율
```

21.4 실세계 요구사항: 필터링의 필요성

블로그 포스트는 명시적으로 다루지 않지만, 실제 생물정보학 응용에서는 다음과 같은 필터가 필수적이다:

메타데이터 필터의 종류

1. **분류학적 정보** `WHERE species = 'E. coli' AND genus = 'Escherichia' AND kingdom = 'Bacteria'`
2. **서열 특성** `WHERE sequence_length BETWEEN 10000 AND 50000 AND gc_content BETWEEN 0.45 AND 0.55 AND has_open_reading_frame = true`
3. **데이터 출처** `WHERE source_database = 'NCBI' AND sequencing_date > '2020-01-01' AND sequencing_method = 'Illumina'`
4. **기능 정보** `WHERE protein_family = 'RecA' AND organism_status = 'pathogenic' AND antibiotic_resistance IS NOT NULL`

복합 필터 쿼리의 예

```
-- 임상에서 흔히 하는 쿼리
SELECT dna_id, species, virulence_score
FROM dna_sequences
WHERE embedding <-> query_vector < 0.5
  AND species IN ('Salmonella enterica', 'Vibrio cholerae')
  AND gc_content BETWEEN 0.4 AND 0.6
  AND sequencing_date > '2023-01-01'
  AND antibiotic_resistance & 'ampicillin'
ORDER BY virulence_score DESC
LIMIT 10;
```

이 쿼리는: - 벡터 검색: `embedding <-> query_vector < 0.5` - 메타데이터 필터: `species IN (...)` - 범위 필터: `gc_content BETWEEN 0.4 AND 0.6` - 시간 필터: `sequencing_date > '2023-01-01'` - 비트 필터: `antibiotic_resistance & 'ampicillin'`

이것이 VAQ(Vector-Augmented Query)의 실제 모습이다.

21.5 Milvus의 메타데이터 필터링

Milvus는 벡터 검색과 메타데이터 필터를 함께 지원한다:

```

# Milvus 스키마 정의
from milvus import FieldSchema, CollectionSchema

fields = [
    FieldSchema(name="id", dtype=DataType.INT64, is_primary=True),
    FieldSchema(name="embedding", dtype=DataType.FLOAT_VECTOR, dim=1536),
    FieldSchema(name="species", dtype=DataType.VARCHAR),
    FieldSchema(name="gc_content", dtype=DataType.FLOAT),
    FieldSchema(name="sequence_length", dtype=DataType.INT64),
    FieldSchema(name="sequencing_date", dtype=DataType.VARCHAR),
]

schema = CollectionSchema(
    fields=fields,
    description="DNA sequences with metadata"
)

client.create_collection(
    collection_name='dna_sequences',
    schema=schema
)

# 벡터 + 메타데이터 함께 삽입
entities = [
    [id_1, id_2, ...], # id
    [vec_1, vec_2, ...], # embedding
    ['E. coli', 'Bacillus', ...], # species
    [0.48, 0.52, ...], # gc_content
    [5000000, 3000000, ...], # sequence_length
    ['2023-01-15', '2023-02-20', ...], # sequencing_date
]

client.insert(
    collection_name='dna_sequences',
    records=entities
)

# 메타데이터 필터와 함께 벡터 검색
expr = "species == 'E. coli' AND gc_content > 0.4"
results = client.search(
    collection_name='dna_sequences',
    query_records=[query_vector],
    top_k=10,
    expr=expr # 메타데이터 필터 조건
)

```

Milvus의 한계:

- 필터 + 벡터 검색은 지원하지만, 조인은 지원하지 않는다

- 여러 메타데이터 필터는 가능하지만, 다른 벡터 DB와의 교차 검색은 불가능

21.6 생물정보학 응용의 특성

이 자료가 중요한 이유는 벡터 검색의 응용 범위를 보여주기 때문이다:

기존 응용 (텍스트/이미지)

웹 검색, 추천 시스템, 이미지 검색
 → 사용자가 정의한 "유사성" 개념이 분명함
 → 벡터 검색이 주요 기능

과학 데이터 응용 (DNA, 단백질, 분자)

서열 분류, 구조 검색, 물성 예측
 → 도메인 전문 지식 + 벡터 검색이 결합됨
 → 필터링, 조인, 집계가 필수
 → VAQ가 필수

생물정보학 데이터의 규모:

인간 게놈:
 - 크기: ~3십억 뉴클레오타이드
 - 유사도 검색 시간: 순차 검색으로 분 단위
 - 벡터 검색으로: 밀리초 단위 가능

단백질 서열 데이터베이스 (UniProt):
 - ~2억 개의 단백질 서열
 - k-mer 필터링 + 벡터 검색 → 실시간 가능

미생물 메타게놈:
 - 환경 샘플에서 수백만 개의 서열 추출
 - 종 분류, 기능 주석을 동시에 수행

21.7 본 논문과의 관계

이 자료는 VAQ의 동기를 보여주는 **응용 사례 연구**이다:

VAQ가 필요한 이유:

1. 단일 벡터 검색 부족 ``sql -- 불충분한 쿼리 SELECT * FROM dna_db WHERE embedding <-> query_vec < 0.5

```
-- 현실 요구사항 SELECT * FROM dna_db WHERE embedding <-> query_vec < 0.5 AND species = target_species AND gc_content > 0.4 AND sequencing_quality > 50 ORDER BY similarity DESC ``
```

1. 필터 + 벡터 결합

2. Milvus: 가능하지만 조인 없음

3. PostgreSQL + pgvector: 조인은 가능하지만 카디널리티 추정 불확실

4. Exqutor: 조인 + 정확한 카디널리티 추정

5. 멀티 테이블 시나리오 `sql SELECT s.species, s.virulence, COUNT(*) AS cnt FROM dna_sequences s JOIN clinical_cases c ON s.id = c.dna_id WHERE s.embedding <-> query_vec < 0.5 AND c.location = 'Hospital-X' AND c.isolation_date > '2023-01-01' GROUP BY s.species, s.virulence ORDER BY cnt DESC`

이 쿼리를 효율적으로 처리하려면: - 벡터 필터 선택도 정확 추정 - 조인 순서 최적화 - 필터와 조인의 통합 계획

추가 제기 문제

1. 임베딩 품질의 검증 부족

DNABERT로 생성한 벡터가 **기능적 유사성**을 실제로 포착하는지 검증 필요: - 같은 기능의 단백질 유전자 → 벡터도 가까운가? - 기능이 다른 단백질 → 벡터도 먼가? - 진화적 거리 vs 벡터 거리의 상관성?

논문/블로그는 이런 검증을 명시적으로 제시하지 않음.

2. 대규모 데이터에서의 성능

예시는 상대적으로 작은 데이터셋(수백만 서열)을 가정: - 전체 NCBI 데이터베이스(십억 서열) 규모에서는? - 실시간 인덱스 업데이트 (매일 수백만 서열 추가) 가능한가? - Milvus의 확장성 한계가 있을 수 있음

3. 메타데이터 필터의 복잡성

블로그는 단순 필터(카테고리, 범위)만 다룸: - 복잡한 논리 (AND/OR/NOT의 중첩) - 다중 속성의 정규화 (예: 종의 계층 분류) - 동적 메타데이터 (시간에 따라 변하는 임상 정보)

이런 경우 SQL의 SELECT 문이 훨씬 자연스러움.

추가 제기 문제

1. 벡터 표현의 도메인 의존성

DNA 임베딩(DNABERT)이 모든 분류 작업에 최적인가? - 종 분류: 매우 효과적 - 기능 분류: 중간 수준 - 구조 예측: 별도의 모델 필요

각 응용마다 최적 임베딩 모델이 다를 수 있으므로, "범용 벡터" 개념이 생물정보학에서는 위험.

2. 필터링 조건의 통합 최적화

메타데이터 필터를 벡터 검색과 함께 사용할 때:

전략 1: 벡터 먼저

1. 벡터 검색으로 후보 1000개 추출
 2. 그 중 메타데이터 필터 적용
- 문제: 필터 선택도 낮으면 유효 결과 부족

전략 2: 필터 먼저

1. 메타데이터 필터로 데이터 축소
 2. 축소된 데이터에서 벡터 검색
- 문제: 필터 선택도 낮으면 인덱스 활용 안 됨

전략 3: 동시 처리 (NHQ의 아이디어)

- 필터와 벡터를 그래프에서 동시에 고려
- 문제: Milvus는 미지원, SQL 기반 DB 필요

3. 실시간 업데이트의 비용

생물정보학 데이터베이스는 지속적으로 업데이트됨: - NCBI GenBank: 매일 수백만 서열 추가 - 각 추가 시마다:

1. 임베딩 생성 (GPU 사용) 2. Milvus에 삽입 3. 인덱스 재구축

이 비용이 검색 성능에 미치는 영향을 측정해야 함.