

[68] Learned Cardinalities: Estimating Correlated Joins with Deep Learning

요약

본 논문은 2018년 Kipf et al.이 제시한 선구적 연구로, 신경망을 활용하여 데이터베이스 조인 카디널리티(결과 행 수)를 추정하는 방법을 제안한다. 전통적인 통계 기반 카디널리티 추정의 한계를 극복하기 위해 딥러닝 모델을 도입했다. 특히 상관관계가 있는 속성들 간의 복잡한 의존성을 학습할 수 있다는 점이 핵심이다.

기존 데이터베이스 옵티마이저는 히스토그램이나 샘플링 기반 통계로 카디널리티를 추정했으나, 이들은 다중 속성 간의 복잡한 상관성을 포착하지 못했다. Learned Cardinalities는 심층 신경망(Deep Neural Networks)을 훈련하여 데이터 분포를 학습하고, 조인 조건에 따른 정확한 카디널리티를 예측한다.

모델 구조는 인코더-디코더 아키텍처로, 입력 속성값들을 벡터로 인코딩하고 조인 조건을 학습하여 출력 카디널리티를 도출한다. 실험 결과 기존 통계 방법 대비 평균 오류를 50% 이상 감소시켰다.

본 논문과의 관계: Exqutor는 선택도(selectivity) 추정에 있어서 통계 기반과 학습 기반의 하이브리드 접근을 취하고 있으며, Learned Cardinalities의 딥러닝 기반 접근 방식이 이론적 배경을 제공한다. 특히 범위 필터와 벡터 검색의 결합된 선택도 추정에서 비슷한 학습 패러다임을 활용한다.

상세분석

68.1 핵심 기술 및 방법론

신경망 기반 카디널리티 추정의 정의: Learned Cardinalities는 조인 카디널리티 추정을 함수 근사 문제(function approximation problem)로 재정의한다. 전통적 접근은 통계 공식에 의존했지만, 이 논문은 신경망이 데이터의 실제 분포를 직접 학습할 수 있다고 제안한다.

모델 아키텍처: - **입력층:** 각 속성의 범위 또는 값을 정규화된 벡터로 인코딩 - **은닉층:** 속성 간 상관성을 포착하기 위한 다층 퍼셉트론(MLP) - **출력층:** 예측된 카디널리티 값 - **손실함수:** 상대 오류(relative error)를 최소화하도록 설계

학습 데이터 생성: 실제 데이터베이스에서 다양한 조인 조건으로 쿼리를 실행하고 실제 카디널리티를 수집한다. 이를 통해 모델이 실제 데이터 분포의 특성을 반영하도록 훈련한다.

68.2 핵심 기여도

다중 속성 상관성 학습: 전통적 히스토그램은 개별 속성이나 2-way 상관성만 효율적으로 표현할 수 있으나, 신경망은 고차원 상관성을 암묵적으로 학습한다. 이는 실제 데이터베이스의 복잡한 종속성을 더 잘 포착한다.

통계 기반 방법의 한계 극복: - 히스토그램: 메모리 비용과 정확도의 트레이드오프 - 샘플링: 낮은 카디널리티 범위에서 부정확 - 독립성 가정: 실제 데이터의 상관성을 무시

신경망은 이러한 제약을 우회하여 더 정확한 예측을 제공한다.

성능 개선: 벤치마크 데이터셋(TPC-H, Join Order Benchmark)에서 평균 상대 오류(Median Relative Error)를 기존 방법 대비 50-75% 감소시켰다.

68.3 학습 및 적용 과정

오프라인 학습 단계: 1. 데이터베이스에서 대표적인 쿼리 세트 생성 2. 각 쿼리의 실제 카디널리티 수집 3. 신경망 모델 훈련 (수천~수만 샘플 필요) 4. 검증 데이터셋으로 성능 평가

온라인 추정 단계: - 옵티마이저가 새로운 조인 조건에 대해 신경망 모델에 질의 - 밀리초 단위의 빠른 추론 속도 (기존 통계 조회와 유사) - 옵티마이저는 예측된 카디널리티를 기반으로 실행 계획 선택

68.4 실험 및 결과

실험 설정: - 데이터셋: TPC-H (1GB), Join Order Benchmark (IMDB 데이터) - 비교 대상: PostgreSQL 히스토그램 통계, 기본 샘플링 - 메트릭: 상대 오류(Relative Error), 오류의 p50/p75/p90 백분위수

주요 결과: - 단순 조인: 10-30% 오류 감소 - 복잡한 다중 속성 상관성: 50-75% 오류 감소 - 콜드 스타트(cold start) 문제: 충분한 훈련 데이터 필요

제한사항: - 새로운 데이터 분포에 대한 재훈련 필요 - 학습 데이터 선택의 편향성 가능성 - 극단값(extreme values)에서의 예측 부정확

68.5 본 논문과의 관계

선택도 추정의 진화: Exqutor는 범위 필터와 벡터 검색의 결합된 선택도를 추정해야 하는데, Learned Cardinalities의 딥러닝 기반 접근이 이 문제의 이론적 토대를 제공한다.

하이브리드 전략: Exqutor의 선택도 추정은 경량 ML 모델(논문 [70])과 학습 기반 방법의 조합을 활용하는데, Learned Cardinalities는 더 복잡한 모델 구조의 가능성을 시사한다.

카디널리티 vs 선택도: - Learned Cardinalities: 조인 결과의 절대 행 수 - Exqutor의 문제: 범위 필터 조건을 만족하는 행의 비율 개념적으로 유사하며, 신경망 활용이라는 점에서 공통점이 있다.

추가 제기 문제

1. **동적 데이터 적응성**: 데이터 분포가 시간에 따라 변할 때, 모델을 재훈련하지 않고도 새로운 분포에 적응할 수 있는 방법은?
2. **샘플 효율성**: 훈련에 필요한 쿼리 샘플 수를 최소화하면서 정확도를 유지할 수 있는가?
3. **모델 복잡성의 트레이드오프**: 더 정확한 예측을 위해 신경망 크기를 키우면 추론 시간이 증가하는데, 최적의 모델 크기는?
4. **범위 검색과의 결합**: 벡터 검색과 범위 필터를 함께 고려할 때 카디널리티 추정의 복잡성은 어떻게 증가하는가?
5. **외삽(Extrapolation) 능력**: 훈련 데이터 범위를 벗어난 값에 대해 신경망은 얼마나 잘 외삽할 수 있는가?