

[77] SERF: Segment Graph for Range-Filtering Approximate Nearest Neighbor Search

요약

Zuo et al.의 2024년 논문으로, 범위 필터(range filter)가 있는 ANN 검색을 위한 세그먼트 그래프 기반 인덱싱 방법을 제시한다. 이는 Exqutor의 핵심 문제인 "범위 필터 + 벡터 검색"을 직접 다루는 논문이다.

기존 ANN 인덱스(HNSW, IVF)는 벡터 유사성만을 고려하기 때문에, 범위 필터를 적용하려면 검색 후 필터링하거나 필터링 후 검색해야 했다. 하지만 SERF는 범위 필터 조건을 인덱스 구조 자체에 반영한다.

핵심 아이디어는 "세그먼트 그래프(Segment Graph)"로, 벡터 공간을 메타데이터(예: 가격 범위)에 따라 세그먼트로 분할하고, 각 세그먼트 내에서 독립적인 그래프를 유지한다. 검색 시에는 필터 조건에 해당하는 세그먼트들만 탐색하므로, 불필요한 벡터들을 애초에 방문하지 않는다.

성능 개선: 범위 필터 선택도가 낮을 때(10% 이하) 기존 방법 대비 2-10배 빠른 검색.

본 논문과의 관계: SERF는 범위 필터 선택도 추정에 직접 의존한다. 필터 조건에 해당하는 세그먼트 수를 정확히 파악하려면 선택도가 필요하다. Exqutor의 선택도 추정 모듈은 SERF 같은 범위 필터 인덱스의 효율성을 결정한다.

상세분석

77.1 범위 필터 ANN 검색의 문제점

기존 방법의 한계:

방법 1: Filter-then-Search

가격 필터: $\text{price} \in [100, 500]$
선택도: 10% (1,000,000개 중 100,000개)

단계:

1. 범위 스캔으로 100,000개 항목의 벡터ID 획득
2. 100,000개 벡터에서만 ANN 검색

문제: 범위 필터 선택도가 높으면 느림
선택도 80% → 800,000개 벡터 검색 필요

방법 2: Search-then-Filter

단계:

1. 모든 벡터에서 top-K 유사 벡터 검색
2. 검색 결과에서 가격 필터 적용

문제: 필터 선택도가 낮으면, top-K 결과에 필터 조건을 만족하는 벡터가 거의 없을 수 있음
→ K를 크게 증가시켜야 함 → 검색 비용 급증

방법 3: 별도 메타데이터 인덱스

가격에 대한 B-Tree 인덱스 유지
벡터 HNSW 인덱스 유지

검색 시:

1. B-Tree로 가격 범위의 ID 얻기
2. HNSW에서 해당 ID 벡터들만 방문

문제: 두 인덱스 동기화 필수
메모리 오버헤드 2배
탐색 중 인덱스 간 점프로 캐시 미스 증가

77.2 세그먼트 그래프(Segment Graph) 개념

기본 구조:

가격 범위로 세그먼트 분할:

Segment 0: [0, 100) → 10,000 벡터
Segment 1: [100, 200) → 15,000 벡터
Segment 2: [200, 300) → 12,000 벡터
Segment 3: [300, 500) → 20,000 벡터
Segment 4: [500, ∞) → 40,000 벡터

각 세그먼트 내 HNSW 그래프:

Seg0: [벡터 구조] -- 연결 --
Seg1: [벡터 구조] -- 연결 --
Seg2: [벡터 구조] -- 연결 --
...

세그먼트 간 크로스링크:

Seg0 ↔ Seg1 ↔ Seg2 ...
(최근접 세그먼트 간의 경계 벡터들이 연결)

세그먼트 선택 기준: - 수치 범위: $\text{price} \in [L, U]$ - 범주 속성: $\text{category} = \text{'electronics'}$ - 시간: $\text{date} \in [\text{start}, \text{end}]$ - 복합: $(\text{price} < 500) \text{ AND } (\text{category} = \text{'electronics'})$

77.3 세그먼트 그래프 구축 알고리즘

오프라인 구축 단계:

```
def build_segment_graph(vectors, metadata, partition_attr):
    # 1단계: 메타데이터 기준으로 세그먼트 분할
    segments = partition_by_attribute(vectors, metadata, partition_attr)

    # 2단계: 각 세그먼트 내에서 HNSW 구축
    segment_graphs = {}
    for seg_id, vectors_in_seg in segments.items():
        segment_graphs[seg_id] = build_hnsw(vectors_in_seg)

    # 3단계: 세그먼트 간 크로스링크 구축
    for seg_i, seg_j in adjacent_segments(segments):
        create_cross_segment_edges(
            segment_graphs[seg_i],
            segment_graphs[seg_j],
            num_edges=10 # 세그먼트당 10개 엣지
        )

    return segment_graphs, segment_boundaries
```

세그먼트 크기 결정:

세그먼트 크기 s :

- 너무 작음 ($s < 1000$): 세그먼트 수 증가 → 메모리 오버헤드
- 너무 큼 ($s > 100000$): 한 세그먼트에 대부분 벡터 → 필터링 효과 감소
- 최적: $s \approx \sqrt{n}$ (n = 전체 벡터 수)

예: 1,000,000개 벡터 → 세그먼트당 ~1,000개
→ 약 1,000개 세그먼트

77.4 범위 필터 쿼리 검색 알고리즘

온라인 검색 단계:

```
def range_filtered_search(query_vector, range_filter, top_k):
    # 1단계: 필터 조건에 맞는 세그먼트 식별
    target_segments = identify_segments(range_filter)
    # 예: price ∈ [100, 500]이면 Segment 1, 2, 3 선택

    # 2단계: 각 세그먼트에서 독립적으로 ANN 검색
    segment_candidates = {}
    for seg_id in target_segments:
        segment_candidates[seg_id] = hnsw_search(
            segment_graphs[seg_id],
            query_vector,
            k=top_k * len(target_segments) # 각 세그먼트에서 충분히 가져오기
        )

    # 3단계: 모든 세그먼트 결과를 병합 및 정렬
    all_candidates = merge_sorted(segment_candidates.values())

    # 4단계: 상위 top_k 반환
    return all_candidates[:top_k]
```

세그먼트 식별의 효율성:

쿼리: $\text{price} \in [100, 500]$

필터링 없음: 1,000,000개 벡터 모두 검색 필요

세그먼트 그래프:

- Segment 1: $[100, 200) \rightarrow 0$
- Segment 2: $[200, 300) \rightarrow 0$
- Segment 3: $[300, 500) \rightarrow 0$
- 나머지 세그먼트는 스킵

결과: 47,000개 벡터만 검색

성능 개선: $1,000,000 / 47,000 \approx 21\text{배}$

77.5 세그먼트 경계의 영향

경계 벡터 문제:

Segment 1: $[100, 200)$

Segment 2: $[200, 300)$

벡터 A: 벡터값 = $[0.5, 0.3, \dots]$, 가격 = 199 $\rightarrow$ Seg 1

벡터 B: 벡터값 = $[0.5, 0.31, \dots]$, 가격 = 200 $\rightarrow$ Seg 2

두 벡터는 벡터 공간에서 매우 가깝지만 다른 세그먼트에 속함!

$\rightarrow$ 크로스 세그먼트 엣지가 해결

크로스 세그먼트 엣지의 역할:

Segment 1의 경계 벡터들이 Segment 2의 경계 벡터들과 연결되어 있으므로,
Segment 1에서 탐색 시 필요하면 Segment 2로 "넘어갈" 수 있음

하지만: 필터 조건 밖인 세그먼트로는 가면 안 됨!

$\rightarrow$ 크로스 엣지는 필터 세그먼트 내에서만 따라가야 함

77.6 다중 범위 필터 처리

단일 속성 범위:

$\text{price} \in [100, 500]$

$\rightarrow$ Segment 1, 2, 3 선택 (직관적)

다중 속성 범위:

$\text{price} \in [100, 500] \text{ AND } \text{rating} \in [4, 5]$

문제: 세그먼트를 price로만 분할하면 rating 조건을 활용 못함

해결책 1: 계층 세그먼트화

└ 1단계: price로 분할

| 각 세그먼트를 다시 rating으로 분할

| → 다차원 세그먼트 격자(grid)

└ 비용: 메모리 증가 (세그먼트 수 = $n_{\text{price_segs}} \times n_{\text{rating_segs}}$)

해결책 2: 필터링 후 세그먼트 선택

└ 메인 세그먼트: price 기준

└ 검색 중: rating 조건도 동시 확인

└ 메모리 효율적

└ 계산 비용: 추가 필터 검사

77.7 실험 결과

벤치마크 설정: - 데이터셋: Amazon (130M products), NYC Taxi (1B records) - 쿼리: 다양한 선택도의 범위 필터 - 비교: Filter-then-Search, Search-then-Filter, SERF

결과 (쿼리 응답 시간, ms):

선택도	FTS	STF	SERF	개선
1%	20	300	22	STF 대비 13배
5%	80	250	90	STF 대비 2.8배
10%	150	220	160	STF 대비 1.4배
50%	600	600	610	동등
90%	1500	500	510	FTS 대비 2.9배

메모리 오버헤드:

기본 HNSW: 1 GB

SERF: 1.15 GB (15% 증가)

크로스 세그먼트 엣지: 약 50 MB

세그먼트 경계 정보: 약 10 MB

77.8 선택도 추정과의 연관성

SERF의 성능은 선택도 추정에 의존:

1. 쿼리 옵티마이저가 선택도 σ 추정
2. $\sigma > 50\%$ 이면 SERF 대신 전체 HNSW 검색 선택
 $\sigma < 50\%$ 이면 SERF로 세그먼트 선택 검색

정확한 선택도:

- $\sigma = 15\% \rightarrow$ SERF 사용 $\rightarrow$ 빠름 (150ms)

부정확한 선택도:

- 추정값 50% $\rightarrow$ FTS 선택 $\rightarrow$ 느림 (600ms)
- 추정값 10% $\rightarrow$ SERF 선택하지만 실제 선택도 50% $\rightarrow$ 느림 (610ms)

Exqutor의 선택도 추정이 SERF 성능을 결정:

Exqutor의 경량 선택도 모델 오류:

- $\pm 10\%$ 범위: 최적 전략 선택 가능
- $\pm 30\%$ 범위: 1.3배 성능 저하
- $\pm 50\%$ 범위: 2배 이상 성능 저하

77.9 본 논문과의 관계

Exqutor가 SERF를 사용할 때의 선택도 추정:

Exqutor는 범위 필터의 정확한 선택도를 추정해야 SERF가 최적 성능을 낼 수 있다.

Exqutor 아키텍처:

범위 필터 조건 입력

↓

선택도 추정 모듈 (논문 [70] 경량 ML 모델)

↓

선택도: $\sigma = 0.12$ (12%)

↓

쿼리 옵티마이저

- └ $\sigma < 30\% \rightarrow$ SERF 세그먼트 검색 선택
- └ $\sigma \geq 30\% \rightarrow$ 전체 HNSW 검색 후 필터

↓

실행 및 성능 측정

추가 제기 문제

1. **세그먼트 경계 선택**: 균등 크기 세그먼트 vs 데이터 기반 세그먼트화, 어느 것이 더 나은가?
2. **동적 세그먼트화**: 데이터 분포가 시간에 따라 변할 때, 세그먼트 경계를 재구성해야 하는가?
3. **여러 속성 동시 필터**: price AND rating AND category 등 여러 범위 필터를 효율적으로 처리하는 방법은?
4. **세그먼트 간 벡터 분포**: 각 세그먼트 내 벡터들의 분포가 다를 때 (예: 고가 제품은 모두 프리미엄, 저가 제품은 다양), HNSW 파라미터를 어떻게 조정할 것인가?
5. **업데이트 비용**: 새로운 벡터 추가 시 올바른 세그먼트를 찾고 그래프를 업데이트하는 비용은?
6. **선택도 오류의 회피**: 선택도 추정이 매우 부정확할 때, 최악의 경우를 회피하는 보수적 전략은?