

Exqutor 논문 통합 요약

1. 논문 정보

제목: Exqutor: Extended Query Optimizer for Vector-augmented Analytical Queries

저자: Hyunjoon Kim, Chaerim Lim, Hyeonjun An (연세대학교 BDAI Lab), Rathijit Sen (Microsoft Gray Systems Lab), Kwanghyun Park (연세대학교)

출처: arXiv:2512.09695v2 [cs.DB], 2025 년 12 월 11 일

2. 핵심 문제: VAQ 카디널리티 추정

현대 데이터 애플리케이션에서는 LLM 기반 RAG(Retrieval-Augmented Generation) 워크플로우가 널리 사용되고 있다. 이 과정에서 벡터 유사도 검색(VSS)이 핵심 역할을 하지만, 실무에서는 단순한 top-k 검색을 넘어 벡터 검색과 SQL 의 조인, 필터링, 집계를 결합한 복잡한 분석 쿼리가 필요하다. 이를 벡터 증강 분석 쿼리(VAQ)라고 부른다.

문제는 기존 범용 벡터 데이터베이스(pgvector, VBASE, DuckDB)들이 벡터 유사도 연산의 카디널리티를 정확하게 추정하지 못한다는 점이다. pgvector 는 항상 33.3%, VBASE 는 50.0%, DuckDB 는 100.0% 수준의 고정 비율로 추정하여, 옵티마이저가 잘못된 실행 계획을 수립하고 쿼리 성능이 심각하게 저하된다. 예를 들어 벡터 검색 결과가 200 건인데 시스템이 8,000 만 건이 나올 것으로 추정하면, 불필요한 Full Table Scan 과 Hash Join 을 선택하게 되어 실행 시간이 기하급수적으로 증가한다.

3. 제안 기법: ECQO + 적응적 샘플링

Exqutor 는 기존 범용 벡터 데이터베이스의 쿼리 옵티마이저에 통합되는 확장 모듈로, 두 가지 보완적 기법을 제공한다.

ECQO(Exact Cardinality Query Optimization): 벡터 인덱스가 존재할 때, 계획 수립 단계에서 HNSW 인덱스를 이용한 범위 검색을 실제로 실행하여 정확한 카디널리티를 얻는다. HNSW 는 계층적 그래프 탐색으로 동작하기 때문에 계획 단계에서도 매우 빠르게(1~2ms) 완료되고, 검색 결과는 캐시되어 실제 실행 단계에서 재사용되므로 오버헤드가 미미하다.

적응적 샘플링: 벡터 인덱스가 없을 때는 샘플링 기반 접근을 사용한다. 초기 샘플 크기는 통계학적 신뢰도 계산식으로 결정되지만(기본 385 행), 이후 Q-error 피드백에 따라 모멘텀 기반의 동적 조정을 수행한다. 이를 통해 각 데이터셋의 특성(클러스터링, 차원, 분포 편향)에 자동으로 적응하여 일관된 추정 정확도를 유지한다.

4. VAQ 벤치마크: TPC-H/TPC-DS 확장

Exqutor 는 최초의 벡터 증강 분석 쿼리 전용 벤치마크를 제시한다. 기존 TPC-H 와 TPC-DS 벤치마크를 확장하여 벡터 데이터를 통합했다.

TPC-H 확장에서는 partsupp 테이블에 이미지 임베딩(DEEP, SIFT, SimSearchNet++) 및 텍스트 임베딩(WIKI)을 추가하고, TPC-DS 는 item 테이블에 임베딩을 추가했다. 핵심 특징은 top-k 검색이 아닌 범위 검색(range search)을 사용한다는 점이다. 범위 검색은 임계값 D 에 따라 반환 건수가 동적으로 변하므로 카디널리티 추정이 더 어렵고, 따라서 옵티마이저에 더 큰 도전 과제가 된다.

5. 실험 결과: 성능 향상

ECQO 적용 시 쿼리 실행 시간 단축이 극적이다. pgvector에서는 최대 1,000 배(3 orders of magnitude) 향상, VBASE는 10,000 배(4 orders of magnitude), DuckDB는 1.5 배~37.2 배 향상을 달성했다. 구체적으로 pgvector의 한 쿼리에서 기존 52,535 초(약 14.6 시간)에서 15.571ms(0.016 초)로 단축되었다.

개선 메커니즘은 정확한 카디널리티로 인해 옵티마이저가 벡터 필터를 우선 적용하여 초기에 데이터를 대폭 줄이고, Nested Loop Join 같은 효율적인 조인 방식과 Index Scan을 선택하게 되기 때문이다. ECQO의 오버헤드는 약 1~2ms로 무시할 수 있는 수준이다.

벡터 인덱스가 없을 때 적응적 샘플링은 고정 샘플링 대비 1.2 배~3.2 배, 적응적 샘플링이 추가로 최대 1.4 배의 속도 향상을 제공한다. 또한 태그 필터링, 멀티 벡터 쿼리, 복잡한 TPC-DS 시나리오에서도 일관되게 높은 성능 개선을 보이며, 기존 학습 기반 방법(SelNet)보다 최대 16.1 배 빠르다.

6. 범용성과 확장성

Exqutor는 pgvector(PostgreSQL 기반), VBASE(PostgreSQL 기반), DuckDB(임베디드 OLAP)라는 서로 다른 아키텍처의 세 시스템에 성공적으로 통합되었다. pgvector와 VBASE는 플래너 혹은 확장하여 구현했고, DuckDB는 논리적 옵티마이저 규칙을 수정하여 구현했다. 데이터 크기를 늘려도(Scale Factor 1→100) 성능 이득이 안정적으로 유지되는 확장성을 보인다.

7. 한계점 및 미해결 문제

고차원 공간에서 샘플링 오버헤드가 거리 계산 비용으로 인해 증가할 수 있다. 또한 기존 데이터베이스 시스템의 비용 모델(cost model)이 ANN 인덱스의 성능 특성(계층적 탐색의 로그 시간 복잡도)을 제대로 반영하지 못하여, 정확한 카디널리티가 있어도 최적이지 않은 계획을 선택할 수 있다. 향후 과제는 고차원 공간에서의 효율적 샘플링 알고리즘과 벡터 인덱스의 특성을 반영한 정제된 비용 모델 개발이다.

8. 핵심 용어 정리

용어	설명
VAQ	벡터 검색 + 관계형 연산(조인, 필터, 집계)이 결합된 분석 쿼리
카디널리티	쿼리 연산의 결과로 나오는 행의 수. 실행 계획 수립의 핵심 정보
선택도	전체 데이터 중 조건을 만족하는 비율
HNSW	계층적 그래프 기반의 근사 최근접 이웃(ANN) 인덱스
ECQO	계획 단계에서 실제 쿼리 일부를 실행해 정확한 카디널리티를 얻는 기법
Q-error	추정 카디널리티와 실제 카디널리티의 비율로, 추정 정확도 측정 지표
범위 검색	유사도 임계값 D 이하의 모든 벡터를 반환하는 검색 (top-k 검색과 다름)
적응적 샘플링	Q-error 피드백과 모멘텀을 이용해 샘플 크기를 동적으로 조정하는 기법

논문 오픈소스: <https://github.com/BDAI-Research/Exqutor>