

레퍼런스 6편 통합 요약

전체 맥락

벡터 검색과 관계형 쿼리를 하나의 시스템에서 처리해야 한다는 현대적 요구는 데이터베이스 커뮤니티에 새로운 도전을 제시했다. Exqutor가 직면한 핵심 문제는 이 통합 환경에서 **쿼리 최적화기가 벡터 연산의 카디널리티(결과 크기)를 정확히 추정하지 못한다**는 것이다.

이 6편의 논문들은 문제의 다양한 측면을 조망한다. PostgreSQL의 구조적 한계를 분석하고, 하이브리드 쿼리를 최초로 구현한 AnalyticDB-V의 시도, 그리고 범용 벡터 DB(VBASE, SingleStore-V)의 혁신적 기술들을 거쳐, 이론적 기반(Context-Enhanced Joins)에 이르기까지. 각 연구는 어느 한 부분은 해결했지만, 카디널리티 추정의 정확성이 필요하다는 공통의 결핍을 드러낸다. Exqutor는 바로 이 빈틈을 메우는 연구이다.

개별 논문 요약

[1] AnalyticDB-V: A Hybrid Analytical Engine

저자: Alibaba Group 연구팀

학회/년도: VLDB 2020

구조화 데이터와 비구조화 데이터를 함께 처리하는 현대적 요구에서, 기존 시스템들은 두 데이터를 별개의 파이프라인으로 관리했다. AnalyticDB-V는 벡터 유사도 검색을 SQL의 물리적 연산자로 정의하여, ANNS 연산이 SQL 옵티마이저에 의해 자동으로 최적화될 수 있도록 했다. Lambda 아키텍처로 실시간 데이터와 배치 인덱스를 관리하고, VGPQ(Vector Graph Product Quantization)라는 새로운 ANN 알고리즘을 제안했다. 정확도 인식 비용 기반 최적화는 ANN 연산의 정확도와 비용 사이의 트레이드오프를 옵티마이저가 관리할 수 있게 했다.

본 논문과의 관계: AnalyticDB-V는 벡터-SQL 통합의 개척자이며, VAQ(Vector-Augmented Analytical Query) 개념의 원형을 제시했다. 그러나 벡터 검색 결과의 카디널리티 추정 문제는 깊이 다루지 않았으며, 이것이 Exqutor가 해결하는 핵심 문제이다. 정확도 인식 최적화는 정확도만 고려했지, 결과 크기의 예측은 다루지 못했다.

[6] Context-Enhanced Relational Operators with Vector Embeddings

저자: EPFL (Viktor Sanca, Manos Chatzakis, Anastasia Ailamaki)

출처: arXiv:2312.01476 (ICDE 2023 논문의 확장판)

이 논문은 벡터 임베딩을 관계형 대수에 공식적으로 통합하는 이론적 기초를 제공한다. **임베딩 연산자 E**로 테이블의 각 튜플을 임베딩 벡터로 변환하고, **컨텍스트 강화 조인 E-Join**으로 벡터 유사도 기반 조인을 정의한다. 프리페치 최적화로 각 튜플의 임베딩을 한 번만 계산하면 되도록 하여 모델 호출 비용을 $O(|R| \times |S|)$ 에서 $O(|R| + |S|)$ 로 감소시킨다. 가장 혁신적인 기여는 Nested Loop Join을 행렬 곱셈으로 변환하는 **텐서 조인**이다. 이를 통해 SIMD 활용과 캐시 최적화로 10~100배의 성능 향상을 달성했다.

논문은 인덱스 조인이 항상 우월하지 않음을 보여준다. 저선택도에서는 스캔 방식이, 고선택도에서도 스캔이 더 빠를 수 있다. 인덱스가 유리한 범위는 제한적이다.

본 논문과의 관계: 이 논문의 이론적 틀은 Exqutor의 철학적 기반이다. 텐서 조인의 성능 분석은 "정확한 카디널리티만 있으면 인덱스 조인과 스캔 조인 중 최적의 것을 선택할 수 있다"는 Exqutor의 주장을 강력히 뒷받침한다. 저선택도에서는 스캔이, 중간 범위에서는 인덱스가, 고선택도에서 다시 스캔이 유리하다는 발견은 정확한 카디널리티 추정의 절대적 필요성을 증명한다.

[7] SingleStore-V: An Integrated Vector Database System

저자: SingleStore/MemSQL 개발팀

학회/년도: VLDB 2024

SingleStore-V는 OLTP와 OLAP을 모두 지원하는 분산 관계형 DB에 벡터 검색을 통합했다. 핵심 기술은 Top() 물리적 연산자로, ORDER BY + LIMIT 패턴을 인식하여 벡터 인덱스에서 바로 top-k를 추출한다. 세그먼트 기반 저장 구조를 활용하여 각 불변 세그먼트에 독립적 인덱스를 구축하고, 쿼리 시 모든 세그먼트를 병렬로 검색한다. Faiss와 hnswlib 같은 다양한 벡터 라이브러리를 블랙박스로 지원하는 플러그형 아키텍처를 제공한다.

본 논문과의 관계: SingleStore-V는 단일 테이블 내 top-k 검색에 특화된 최적화이다. Exqutor와의 근본적 차이는 SingleStore-V는 "벡터 검색 자체를 빠르게" 하는 데 집중하고, Exqutor는 "정확한 카디널리티로 더 나은 실행 계획을 세우게" 함으로써 복잡한 조인 쿼리를 최적화한다는 점이다. 두 접근법은 상호 보완적이다.

[10] VBASE: Unifying Online Vector Similarity Search and Relational Queries

저자: Microsoft Research Asia

학회/년도: OSDI 2023

VBASE의 혁신은 **완화된 단조성(Relaxed Monotonicity)** 개념이다. 전통적 인덱스(B-tree)는 엄격한 단조성을 가지지만, 벡터 인덱스(HNSW)는 이를 보장할 수 없다. VBASE는 벡터 인덱스 탐색이 통계적으로 점차 품질이 낮아진다는 관찰에서, TopK라는 고정 값 없이 동적으로 탐색을 종료할 수 있음을 발견했다. Volcano 모델의 Next() 인터페이스에 이 종료 조건을 통합함으로써, 벡터 인덱스를 관계형 연산자와 직접 결합했다. PostgreSQL 기반 구현에서 온라인 벡터 쿼리에 대해 최대 1,000배, 분석적 유사도 쿼리에서는 7,000배의 성능 향상을 달성했다.

본 논문과의 관계: VBASE는 Exqutor 실험에서 가장 극적인 개선을 보인 시스템(최대 10,000배)이다. VBASE의 독립적 메모리 인덱스 관리 구조는 PostgreSQL의 버퍼 풀과 분리되어 있어, Exqutor의 비용 추정이 더 정확해질 여지를 제공한다. VBASE 위의 Exqutor 적용이 가장 큰 개선을 이룬 이유는, VBASE가 벡터 선택도를 고정값(50%)으로 추정했기 때문이다.

[11] Milvus: A Purpose-Built Vector Data Management System

저자: Zilliz, HUST

학회/년도: SIGMOD 2021

Milvus는 벡터 데이터의 저장과 유사도 검색에 특화된 전문 벡터 데이터베이스다. 클라우드 네이티브 아키텍처로 저장과 연산을 분리하여 탄력성을 확보하고, 세그먼트 기반 데이터 관리로 대규모 확장성을 제공한다. FLAT, IVF_FLAT, IVF_PQ, HNSW, SCANN, DiskANN 등 다양한 벡터 인덱스를 지원하고, 속성 필터링과 다중 벡터 검색 같은 고급 기능을 제공한다. 조절 가능한 일관성 수준으로 성능과 일관성의 트레이드오프를 사용자가 선택할 수 있게 했다.

본 논문과의 관계: Milvus 같은 전문 벡터 DB의 근본적 한계는 복잡한 관계형 연산(특히 다중 테이블 조인)을 지원하지 않는다는 것이다. 이것이 Exqutor가 pgvector, VBASE, DuckDB 같은 범용 벡터 DB를 대상으로 하는 이유이다. 전문 DB는 벡터 검색만 빠르지만, 범용 DB는 SQL의 모든 기능을 지원하되 벡터 부분에서 최적화가 부족하다.

[20] PostgreSQL의 벡터 데이터 관리 근본 한계

저자: Purdue University (Yingzi Zhang, Shaolong Liu, Jianguo Wang)

학회/년도: ICDE 2024

이 논문은 "관계형 DB의 벡터 지원에 근본적 한계가 있는가?"라는 질문에 체계적으로 답한다. PostgreSQL과 Faiss의 상세한 비교를 통해 5가지 핵심 한계를 발견한다.

버퍼 풀 오버헤드: HNSW 그래프 탐색의 무작위 노드 접근마다 래치 획득이 필요하여 성능 저하. **튜플 접근 오버헤드:** 벡터 추출 전 트랜잭션 정보 파싱과 MVCC 가시성 확인이 불필요한 비용 추가. **공간 증폭:** PostgreSQL의 고정 페이지 구조와 MVCC 메타데이터로 인덱스 크기가 과도하게 증가. **인덱스 구축 시간:** WAL 로깅과 버퍼 풀 경유로 구축이 수배~수십배 느림. **쿼리 최적화 한계:** 벡터의 고차원 분포를 표현할 수 없어 선택도를 고정 상수(33.3%)로 추정.

논문은 일부는 근본적(버퍼 풀, MVCC)이지만 일부는 구현으로 해결 가능(벡터 통계, 전용 버퍼 풀)함을 결론짓는다.

본 논문과의 관계: 이 논문의 "PostgreSQL의 옵티마이저가 벡터 선택도를 고정값으로 추정한다"는 발견이 바로 Exqutor가 해결하는 핵심 문제다. Exqutor는 통계 정보 없이도 벡터 인덱스를 직접 탐색하여 정확한 카디널리티를 얻는다. 또한 공간 증폭 문제는 PostgreSQL의 비용 모델이 HNSW 인덱스 비용을 과대추정하는 원인으로 언급되며, 이것이 Exqutor의 비용 추정 개선이 필요한 이유를 강화한다.

6편 비교표

논문	시스템 범주	핵심 기여	본 논문과의 연결점
[1] AnalyticDB-V	하이브리드 엔진	ANNS 연산자, 정확도-비용 트레이드오프	VAQ 개념 원조, 카디널리티 추정 미해결
[10] VBASE	범용 벡터 DB	완화된 단조성, Volcano 통합	실험 대상, 극적 개선(최대 10,000배)
[7] SingleStore-V	범용 벡터 DB	Top() 연산자, 세그먼트 인덱스	경쟁 접근, top-k 특화 vs. 조인 최적화
[11] Milvus	전문 벡터 DB	클라우드 네이티브, 다양한 인덱스	전문 vs. 범용의 차이 설명
[6] Context-Enhanced	이론 기초	E-연산자, 텐서 조인	카디널리티 정확성 필요성 증명
[20] PostgreSQL 한계	문제 분석	버퍼 풀, 고정 선택도 문제	Exqutor의 문제 설정 근거