

[5] Analytical Engines with Context-Rich Processing; Towards Efficient Next-Generation Analytics 총정리

저자: Viktor Sanca, Anastasia Ailamaki (EPFL — Data-Intensive Applications and Systems Lab)

학회/년도: ICDE 2023 (IEEE 40th International Conference on Data Engineering) — Vision Paper

분량: 약 8 페이지

역할군: (D) 이론적 기반; 임베딩을 관계형 대수에 통합하는 비전

요약

이 논문은 [6]번 논문(Context-Enhanced Relational Operators with Vector Embeddings)의 **전신**이 되는 **비전 논문**으로, 임베딩을 관계형 대수에 통합하는 아이디어의 출발점이다. 비전 논문(Vision Paper)이란 구체적인 실험보다는 **새로운 연구 방향을 제시하고 커뮤니티의 논의를 유도**하는 논문으로, [6]의 기술적 기여를 이해하기 위한 철학적·개념적 배경이 된다.

핵심 메시지는 현대 데이터의 **80~90%가 비구조화 데이터**인데, 관계형 DBMS는 여전히 구조화 테이블에 최적화되어 있다는 것이다. 따라서 **임베딩 연산자(E-Operator)**를 **관계형 대수의 공식 연산자로 정의**하면, 기존 최적화 규칙(선택 푸시다운, 조인 재정렬 등)을 임베딩 연산에도 자동으로 적용할 수 있다. 이것이 바로 VAQ(Vector-Augmented Analytical Query) 최적화의 이론적 토대가 된다.

본 논문과의 관계; 비전 논문으로서 구체적인 실험은 없지만, "임베딩을 관계형 대수에 통합하면 어떤 이득을 얻을 수 있을까"라는 근본적 질문에 대한 답을 제시하며, Exqutor가 이를 실행하는 데 필요한 정확한 카디널리티 추정의 필요성을 이론적으로 정당화한다.

상세분석

5.1 해결하고자 하는 문제; 데이터의 본질적 변화

데이터 생태계의 변화

과거(2010년대 초):

데이터 구성:

- 구조화: 80% (숫자, 날짜, 범주형)
- 비구조화: 20% (이미지, 텍스트)

도구 분포:

- RDBMS 투자: 80% (SQL, 트랜잭션, ACID)
- 비구조화 처리: 20% (특수 시스템)

현대(2020년대):

- 구조화: 10~20% (메타데이터만 해당)
- 비구조화: 80~90% (텍스트, 이미지, 오디오, 비디오)

도구 분포:

- RDBMS: 여전히 60% 투자 (기존 자산)
- 새로운 도구: 40% (벡터 DB, LLM, 특수 엔진)

→ ****Mismatch****! 데이터는 비구조화인데 도구는 구조화 중심

전형적인 데이터 분석 파이프라인의 문제

현재 관행:

[Step 1] 구조화 데이터

관계형 DB	
user_id, age, city	

↓

[Step 2] 비구조화 데이터 추출

사진, 텍스트	
(DB 밖으로 반출)	

↓

[Step 3] 임베딩 생성 (DB 외부)

ML 파이프라인	
BERT, ResNet 실행	
→ 벡터 생성	

↓

[Step 4] 벡터 DB 에 로드

Milvus 또는 pgvector	
벡터 저장	

↓

[Step 5] 유사도 검색

별도 쿼리로 검색	
Top-k 결과 수집	

↓

[Step 6] 결과를 다시 원래 DB 와 조인

수동 코딩으로	
프로그래밍으로 결합	

문제:

- **복잡함:** 개발자가 6 개 단계의 ETL 을 수동 관리
- **비효율:** 각 단계마다 데이터를 반복 로드/저장
- **최적화 불가:** DB 옵티마이저가 전체 파이프라인을 볼 수 없음 (일부는 블랙박스)
- **응답 시간:** 각 단계의 레이턴시가 누적되어 전체 응답 시간이 수십 초 이상 가능

5.2 핵심 제안; E-Operator 와 E-Scan 프레임워크

E-Operator (Embedding Operator)

임베딩을 관계형 대수의 공식 연산자로 정의:

$$E\mu(R) = \{t \in R, t \rightarrow \mu(t)\}$$

쉽게 말하면:

입력: 관계(테이블) R 과 임베딩 모델 μ

예; $R = (user_id, user_image)$

$\mu = \text{ResNet-50 이미지 임베딩 모델}$

출력: R 의 각 튜플(행)에 대해 임베딩 벡터를 추가한 새로운 관계

예; $(user_id, user_image, embedding[512])$

중요한 성질

1. 역연산 가능성:

$$E\mu^{(-1)}(E\mu(R)) = R$$

즉, 원래 데이터를 복원할 수 있다.

예시:

임베딩 후 → 벡터 유사도 검색 → 이미지 메타데이터 추출

← 원본 user_id, user_image 로 돌아갈 수 있음

2. 관계형 대수와의 호환성:

기존 관계형 규칙이 그대로 적용됨:

$\sigma_p(R)$ = 선택 (조건 p 를 만족하는 행만)

예; $\sigma_{age>25}(users)$ = 나이 25 세 이상 사용자

$\pi_A(R)$ = 프로젝션 (특정 컬럼만 선택)

예; $\pi_{user_id, name}(users)$ = id 와 이름만

이런 연산과 $E\mu(R)$ 을 결합할 때 동치 규칙이 성립:

$$\sigma_{age>25}(E\mu(R)) \equiv E\mu(\sigma_{age>25}(R))$$

즉, 나이 필터를 임베딩 전에 할지 후에 할지는 동등하다.

그런데 ****비용이 다르다!****

E-Scan 프레임워크

컨텍스트 풍부한 데이터의 소비(consume)·교환(exchange)·캐싱(cache) 인터페이스:

[E-Scan 구현]

- |— Consume: 테이블의 행(row)을 읽을 때
| 해당 컨텍스트 데이터도 함께 임베딩
|
- |— Exchange: 임베딩 결과를 다른 연산자에 전달
| (예; 조인 연산자가 임베딩 벡터를 직접 사용)
|
- |— Cache: 동일 데이터에 대한 반복 임베딩 방지
| 예; 같은 user_image 를 여러 쿼리에서 사용할 때
| 첫 번째 쿼리에서 계산한 임베딩을 재사용

5.3 대수적 동치 규칙 (Algebraic Equivalence Rules)

E-Operator 가 기존 관계형 대수와 **합성 가능(composable)**함을 보여준다:

선택 푸시다운 (Selection Pushdown)

$$\sigma_p(E\mu(R)) \equiv E\mu(\sigma_p(R))$$

예시:

쿼리: 임베딩한 후, 나이 > 25 인 사용자만 필터

| [계획 A] 임베딩 먼저 (비효율) |

- | | |
|------------------------------|--|
| 1. 전체 1,000,000 명 사용자 | |
| 2. 각각 ResNet 실행 (임베딩) | |
| → 1,000,000 × 100ms = 100K 초 | |
| 3. 나이 필터 적용 | |
| → 결과 500,000 명 (50%) | |
| 비용: 100K 초 + IO + 필터링 | |

| [계획 B] 필터 먼저 (효율적) |

- | | |
|---------------------------|--|
| 1. 나이 > 25 조건으로 필터 | |
| → 결과 500,000 명 | |
| 2. 500,000 명만 임베딩 | |
| → 500,000 × 100ms = 50K 초 | |
| 비용: 필터링 + 50K 초 + IO | |

결론: 계획 B 가 50K 초 절감 (50% 성능 향상)

프로젝션 푸시다운 (Projection Pushdown)

$$\pi_A(E\mu(R)) \equiv E\mu(\pi_{\{A \cup \text{attr}\}}(R))$$

즉, 프로젝션할 컬럼을 임베딩 이전에 미리 선택할 수 있다.

예시:

최종 결과에서 user_id 와 embedding 만 필요하다면,
user_name, user_email 은 임베딩 전에 버려도 된다.
(임베딩 모델의 입력에는 user_image 만 필요하므로)

5.4 본 논문과의 관계: 왜 정확한 카디널리티가 필요한가

동치 규칙이 있어도 최적의 계획을 선택해야 함

쿼리: 1,000,000 명 사용자 중
 - 나이 > 25 (선택도 50%)
 - 임베딩 후 유사 이미지 검색

동치 규칙에 의해 가능한 실행 계획들:

[계획 1] 필터 먼저

```
SELECT * FROM users
WHERE age > 25    -- 50 만명 (카디널리티 500K)
AND embedding_similarity > 0.8
```

비용 추정:

- 필터링: $1M \times 1ms = 1,000ms$
- 임베딩: $500K \times 100ms = 50,000ms$
- 유사도 검색: $500K \times 10ms = 5,000ms$
- 합계: $56,000ms$

[계획 2] 유사도 검색 먼저

```
SELECT * FROM users
WHERE embedding_similarity > 0.8 -- ???건 (카디널리티 불명)
AND age > 25
```

비용 추정:

- 임베딩: $1M \times 100ms = 100,000ms$ ← 모든 사용자!
- 유사도 검색: $1M \times 10ms = 10,000ms$
- 필터링: $??? \times 1ms$ (결과 크기 불명)
- 합계: $110,000ms + ???$

문제: 유사도 검색의 결과 카디널리티를 모르면?

→ 계획 2 의 비용을 정확히 추정할 수 없음
 → 옵티마이저가 계획 1 vs. 2 를 비교 불가능

Exqutor 의 역할

Exqutor 는 정확한 카디널리티를 제공한다:

"유사도 0.8 이상인 이미지는 대략 50,000 건입니다"

이제 옵티마이저가:

- 계획 1: $500K$ 임베딩 + $500K$ 검색 = $55,000ms$
- 계획 2: $1M$ 임베딩 + $1M$ 검색 + $50K$ 필터 = $110,050ms$
- 계획 1 이 훨씬 나음!

라고 올바르게 판단할 수 있다.

5.5 데이터 특성에 따른 최적 전략의 변화

선택도가 높을 때 (많은 결과)

쿼리: 1,000,000 명 중

- 임베딩 유사도 > 0.8 → 500,000 건 (50% 선택도)
- 나이 > 25 → 500,000 건 (50% 선택도)
- 교집합: 약 250,000 건

최적 계획: 필터와 유사도 검색을 병렬로 고려

```
SELECT * FROM users
```

```
WHERE age > 25 OR embedding_similarity > 0.8
```

→ 임베딩과 필터링이 함께 이루어지면 중간 결과 최소화

선택도가 낮을 때 (적은 결과)

쿼리: 1,000,000 명 중

- 임베딩 유사도 > 0.9 (매우 유사) → 1,000 건 (0.1% 선택도)
- 나이 > 80 (매우 고령) → 100,000 건 (10% 선택도)

최적 계획: 더 선택도 높은 것을 먼저 (유사도 검색)

하지만 그 전에 저비용 필터(나이)를 먼저?

1M 임베딩 비용이 매우 크므로

- 나이 필터 먼저: 100K 사람만 임베딩 → $100K \times 100ms = 10K$ 초
- 유사도 검색 필터: 결과 약 1K 명

vs.

- 1M 모두 임베딩: $1M \times 100ms = 100K$ 초 (너무 크다)
- 유사도 검색: 1K 명

→ 필터 먼저 하는 것이 낫다!

5.6 비전 논문의 한계와 후속 연구의 필요성

이 논문이 제시하는 아이디어는 강력하지만:

1. 구체적 실험 부재

- 대수적 동치 규칙은 이론적으로 소리가 나지만
- 실제 구현 시 성능이 얼마나 향상될지는 미지수

1. 비용 모델의 정확성

- 임베딩 모델의 비용은 입력 크기, 모델 복잡도, 하드웨어에 따라 크게 변함
- 일반화된 비용 모델을 만들기 어려움

1. 메모리 제약 미고려

- E-Scan 캐싱은 필요한 메모리가 많을 수 있음
- 대규모 데이터에서는 메모리 부족 가능

1. 동적 특성 미반영

- 데이터 분포가 시간에 따라 변함 (concept drift)
- 최적의 실행 계획도 변할 수 있음

5.7 본 논문과 Exqutor의 관계

이론과 실무의 연결

[5] 비전 논문 (ICDE 2023)

- └ E-Operator의 정의 및 동치 규칙 제시
- └ "임베딩을 관계형 대수에 통합 가능하다"

↓ (후속 연구)

[6] Context-Enhanced Operators (2023)

- └ 비전을 실제 구현으로 변환
 - └ 텐서 조인으로 100 배 성능 향상
- └ 인덱스 vs. 스캔 선택도가 중요함을 발견

↓ (파생 연구)

[Exqutor] (암시적)

- └ "정확한 카디널리티가 있으면..."
- └ 옵티마이저가 최적 계획 선택 가능
- └ 카디널리티 추정을 HNSW 인덱스 탐색으로 해결

Exqutor의 기여

[5]의 비전을 완성하기 위해 필요한 것:

1. **정확한 카디널리티 추정** ← Exqutor가 제공
2. **동적 적응** ← Exqutor의 런타임 샘플링
3. **실제 성능 평가** ← Exqutor의 HNSW, pgvector, VBASE 실험

추가 제기 문제

1. 임베딩 모델의 선택:

- 같은 데이터를 여러 임베딩 모델(BERT, RoBERTa, GPT)로 임베딩 가능
- 각 모델은 비용과 정확도가 다름
- 옵티마이저가 이를 자동 선택할 수 있을까?

1. 다중 임베딩 필드:

- 한 테이블에 여러 임베딩 필드 (텍스트 임베딩, 이미지 임베딩 등)
- 동적 프로그래밍으로 최적 계획을 찾을 수 있을까?

1. 분산 환경에서의 확장:

- 데이터가 여러 노드에 분산될 때
- 임베딩 계산을 어느 노드에서 할지
- 네트워크 비용을 어떻게 고려할지

1. 임베딩과 필터 간의 상관관계:

- 나이와 이미지 유사도가 독립적이지 않을 수 있음
- 고령자의 사진과 젊은이의 사진이 같은 주제일 때 임베딩이 달라질 수 있음
- 이런 상관관계를 비용 모델에 반영?