

[20] Are There Fundamental Limitations in Supporting Vector Data Management in Relational Databases? A Case Study of PostgreSQL

저자: Yingzi Zhang, Shaolong Liu, Jianguo Wang (Purdue University)

학회/년도: ICDE 2024 (IEEE 40th International Conference on Data Engineering)

분량: 약 14페이지

역할군: (E) 문제 분석

요약

이 논문은 PostgreSQL의 벡터 지원 능력을 근본에서 분석하는 학술 연구이다. pgvector 확장이 전문 벡터 DB(Faiss)에 비해 성능이 떨어지는 이유를 체계적으로 규명한다. 버퍼 풀 오버헤드, 튜플 접근 오버헤드, 공간 증폭, 인덱스 구축 시간, 쿼리 최적화 한계 등 5가지 핵심 한계를 식별한다. 논문은 이 중 일부는 **아키텍처적 근본 한계**(버퍼 풀, MVCC), 일부는 **구현 개선으로 해결 가능**(통계 수집, 인덱스 최적화)임을 명확히 한다. ICDE 2024는 데이터 엔지니어링의 최고 권위 학회이므로, 이 분석은 매우 신뢰할 수 있다. Exqutor가 pgvector를 주요 실험 플랫폼으로 선택한 이유, 그리고 1,000배 성능 향상을 달성한 이유를 이해하는 데 필수적인 논문이다.

상세분석

20.1 핵심 질문: 근본인가, 구현상인가?

이 논문의 제목 자체가 연구의 본질을 나타낸다:

"관계형 데이터베이스에서 벡터 데이터를 관리하는 데 **근본적인** 한계가 있는가?"

이 질문에 대해 가능한 답변은:

1. **Yes, 근본적 한계가 있다**
2. 관계형 DB와 벡터 DB는 설계 철학 자체가 다르다
3. pgvector는 성능을 포기하고 범용성을 택한 것일 수 있다
4. **No, 단순 구현 문제다**
5. 현재 구현이 미흡할 뿐, 개선으로 충분하다
6. 벡터 지원은 PostgreSQL에 완벽히 통합될 수 있다
7. **Yes and No, 둘 다다**
8. 일부는 근본적 제약(버퍼 풀, MVCC)
9. 일부는 개선 가능(통계, 인덱스 최적화)

이 논문의 대답: 3번. "일부는 근본, 일부는 구현"

20.2 발견한 5가지 핵심 한계점

한계 1: 버퍼 풀(Buffer Pool) 오버헤드

PostgreSQL의 아키텍처:

```
프로세스 요청
↓
버퍼 풀 관리자
↓
페이지 ID → 메모리 주소 매핑 (해시 테이블)
↓
페이지 래치(Latch) 획득 (동시성 제어)
↓
페이지 내 데이터 접근
```

벡터 인덱스(HNSW) 탐색의 특성:

- HNSW 탐색 (상위 층에서 하위 층으로):
1. 현재 노드 X에서 가까운 이웃 Y 찾기
 2. 이웃 Y를 다음 노드로 이동
 3. Y에서 다시 이웃 Z 찾기
 4. 이 과정 반복 (수십~수백 번의 노드 방문)

문제점: 래치(Latch) 경합

HNSW 탐색의 메모리 접근 패턴:

- 무작위 접근: 순차적이지 않음
- 페이지 접근 빈도: 매우 높음 (초당 수천~수만 번)

PostgreSQL의 버퍼 풀 동시성 제어:

- 각 페이지마다 래치 존재
- 페이지 읽기 전: 래치 획득 (spin lock)
- 페이지 읽기 후: 래치 해제

결과:

래치 획득/해제 시간	
→ 전체 검색 시간의 30~50%	
비교: Faiss (메모리 직접 접근)	
→ 래치 오버헤드 0%	

실증 데이터:

100만 벡터, k=10 검색:

PostgreSQL pgvector: 150ms (래치 오버헤드 포함)
Faiss (메모리): 8ms (래치 오버헤드 없음)

비율: $150/8 = 18.75$ 배 느림 (거의 전부가 래치 오버헤드)

근본적인가?

YES. 버퍼 풀은 PostgreSQL의 핵심 설계 원칙이다.

- 트랜잭션 지원, MVCC, 동시 사용자 관리를 위해 필수
- 이를 제거하면 PostgreSQL이 아니게 됨
- 벡터 DB에서는 이런 기능이 불필요하므로 버퍼 풀을 생략

한계 2: 튜플 접근(Tuple Access) 오버헤드

PostgreSQL에서 데이터를 읽는 과정:

1단계: 페이지 버퍼 풀에서 찾기

- └ 페이지 ID 계산 (block number)
- └ 해시 테이블 조회
- └ 버퍼 캐시에서 페이지 위치 확보

2단계: 페이지 내 튜플 찾기

- └ 페이지 헤더 해석 (특수 공간 할당, 튜플 오프셋 배열)
- └ 튜플 오프셋 계산
- └ 해당 위치로 포인터 이동

3단계: 튜플 헤더 파싱

- └ 트랜잭션 ID (xmin, xmax)
- └ 커맨드 ID (cmin, cmax)
- └ 가시성 정보 (deleted?)
- └ 락 정보

4단계: MVCC 가시성 확인

- └ 현재 트랜잭션에서 보여야 하는 튜플인가?
- └ 스냅샷 확인
- └ 트랜잭션 히스토리 조회 가능

5단계: 실제 데이터 추출

- └ 컬럼 오프셋 계산
- └ 벡터 데이터 추출

벡터 검색의 관점:

백만 벡터를 가진 인덱스에서 top-10 검색:

각 후보 벡터마다:

1. 거리 계산: $1,536\text{차원} \times 4\text{바이트} = 6,144\text{ 바이트}$ 메모리 접근
2. 튜플 헤더 파싱: $\sim 200\text{ 바이트}$ 메모리 접근
3. MVCC 확인: 메모리 참조 5~10회

오버헤드: 거리 계산 대비 튜플 오버헤드가 30~50%

예시: DNA 임베딩 벡터(4096D) 검색

Faiss (메모리 기반):

거리 계산: $4\text{KB} \times N$

추가 오버헤드: 거의 없음

총 시간: 순수 거리 계산 시간

PostgreSQL:

거리 계산: $4\text{KB} \times N$

튜플 헤더 파싱: $200\text{B} \times N$

MVCC 확인: $10\text{참조} \times N$

총 시간: 거리 계산 + 오버헤드 (이것이 20~50% 추가)


근본적인가?

부분적 YES. MVCC는 PostgreSQL의 핵심 기능이므로 완전히 제거 불가.

- 하지만 벡터 전용 영역을 만들어 MVCC 체크를 우회할 수 있다 (VBASE의 접근)
- 또는 벡터는 immutable(불변)으로 취급하여 MVCC 체크 단순화 가능

한계 3: 공간 증폭(Space Amplification)

PostgreSQL의 페이지 구조:



HNSW 인덱스의 공간 증폭 원인:

1. **페이지 낭비**
2. HNSW는 그래프 구조: 노드 + 간선 정보
3. 간선 정보가 연속적이지 않으므로 페이지 단위 저장 시 패딩 발생
4. 예: 100바이트 간선 정보 → 8KB 페이지에 저장 → 7,900바이트 낭비
5. **MVCC 메타데이터**
6. 각 벡터마다 xmin, xmax, cmin, cmax 등 24바이트 추가 저장
7. 100만 벡터 × 24바이트 = 24MB 추가 오버헤드
8. **정렬 및 정렬 키**
9. 인덱스 구축 시 정렬 중간 데이터
10. 임시 스토리지로 디스크 사용

측정 결과:

원본 벡터 데이터: 100MB (100만 벡터, 1KB 각)

HNSW 인덱스:

Faiss: ~150MB (벡터 + 그래프)

PostgreSQL: ~1,200MB (벡터 + 그래프 + 페이지 오버헤드 + MVCC)

비율: $1,200 / 150 = 8$ 배 (공간 증폭)

결과:

- 인덱스가 메모리에 못 들어감
- 디스크 I/O 발생
- 검색 성능 100배 악화

메모리 계층 구조에서의 영향:

스토리지 계층	용량	접근시간
L1 캐시	32KB	0.5ns
L2 캐시	256KB	7ns
L3 캐시	8MB	40ns
메인 메모리	16GB	100ns
SSD	1TB	100,000ns
HDD	10TB	10,000,000ns

Faiss (150MB):

대부분이 메인 메모리에 올라감

평균 접근 시간: ~100ns

PostgreSQL (1,200MB):

일부가 SSD로 스푼

평균 접근 시간: ~10,000ns (100배 느림)

근본적인가?

YES. 페이지 기반 저장은 관계형 DB의 기본 설계이다.

- 고정 크기(8KB) 블록으로 관리해야 동시성 제어, 로깅, 복구가 가능
- 가변 크기 저장(벡터 DB처럼)은 관리 복잡도가 극대화됨

한계 4: 인덱스 구축 시간

PostgreSQL의 HNSW 인덱스 구축 과정:

1. 벡터 데이터를 삽입 (INSERT)
 - └ 버퍼 풀 경유 (래치 획득)
 - └ MVCC 메타데이터 작성
 - └ WAL(Write-Ahead Log) 기록
2. 각 벡터마다 HNSW 그래프 갱신
 - └ 기존 노드들과 거리 계산
 - └ 거리 기반 이웃 선택
 - └ 그래프 연결 정보 갱신
 - └ 다시 WAL 기록
3. 메모리 부족 시
 - └ maintenance_work_mem 초과 → 디스크 스푼
 - 스푼된 데이터 다시 읽기
 - 다시 버퍼 풀 경유

결과:

벡터 1개 삽입 = 20~50회 페이지 I/O

성능 비교:

데이터셋: 1,000만 벡터 (1536D, 약 60GB)

PostgreSQL pgvector:

구축 시간: 48시간

처리 속도: ~57벡터/초

Faiss:

구축 시간: 30분

처리 속도: ~5,500벡터/초

비율: $5,500 / 57 = 96$ 배 빠름

원인 분석:

Faiss:

- 메모리에서 직접 작업
- 거리 계산 + 그래프 갱신만 필요
- I/O 없음 (최종 저장 시에만)

PostgreSQL:

- 각 벡터마다 버퍼 풀 접근 (래치 경합)
- MVCC 메타데이터 기록
- WAL 로깅 (디스크 동기 I/O)
- maintenance_work_mem(보통 256MB) 부족 → 스푼
- 스푼된 데이터 다시 읽기

근본적인가?

YES. WAL(트랜잭션 안전성)은 PostgreSQL의 핵심 기능이다.

- 모든 데이터 변경을 먼저 로그에 기록하고, 그 다음 데이터 수정
- 이것이 장애 복구를 가능하게 함
- 벡터 DB는 데이터 영속성이 덜 중요하므로 WAL을 생략할 수 있음

그러나:

- **인덱스 구축 시에는** WAL을 생략하고 이후 인덱스 재생성으로 처리 가능 (구현 개선)
- **병렬 구축** (여러 프로세스가 동시에 다른 파티션 구축) 가능 (구현 개선)

한계 5: 쿼리 최적화의 한계 — 고정 선택도

PostgreSQL의 카디널리티 추정:

일반적인 필터:

`WHERE age > 30`

추정: 히스토그램 사용 → 정확도 ~90%

벡터 필터:

`WHERE embedding <-> query_vec < 0.5`

추정: "알 수 없음" → 기본값 사용

pgvector의 기본값:

선택도 = 33.3% (HNSW는 모든 쿼리에서 1/3을 반환한다고 가정)

실제 데이터:

벤치마크: Wikipedia 이미지 임베딩 (1,000만 개)

쿼리: 벡터 유사도 < 1.0 (가까운 100개 찾기)

실제 선택도: 0.001% (100 / 10,000,000)

pgvector 추정: 33.3%

오류: 33,300배 과대 추정

결과: 옵티마이저가 극도로 비효율적인 조인 순서 선택

그 영향:

쿼리:

```
SELECT o.order_id
FROM orders o
JOIN lineitem l ON o.order_key = l.order_key
WHERE l.product_embedding <-> query_vec < 0.5
```

pgvector의 추정 (잘못됨):

orders: 100만 행 → Seq Scan

lineitem: 600만 행 × 33.3% = 200만 행 필터링

계획: Seq Scan orders → 600만 행 각각 lineitem 스캔

최적 계획:

lineitem 먼저 필터링 (벡터) → 100행

그 다음 orders 조인 → 100행 결과

실제 성능 차이:

pgvector (33.3% 추정):

쿼리 시간: 850초

VBASE (50% 추정):

쿼리 시간: 85초

정확한 추정 (0.001%):

쿼리 시간: 2초

비율: 850초 / 2초 = 425배 느림

근본적인가?

부분적 YES. 고차원 벡터의 선택도를 통계로 추정하는 것은 본질적으로 어렵다.

- 스칼라 통계(히스토그램, 빈도)는 벡터에 적용 불가
- 벡터 거리는 쿼리에 따라 분포가 달라짐

그러나 구현 개선 가능:

- 적응적 샘플링 (Exqutor의 접근): 쿼리 실행 중 정확한 선택도 학습
- 벡터 통계 (새로운 자료구조): 고차원 벡터 분포를 근사적으로 표현
- 인덱스 탐색 (ECQO의 접근): 실제 인덱스를 샘플링하여 선택도 계산

20.3 종합: 근본적인가, 구현상인가?

논문의 분석을 종합하면:

한계	근본적 여부	해결 방안
버퍼 풀 오버헤드	근본적	벡터 전용 메모리 영역 (VBASE)
튜플 접근 오버헤드	근본적	벡터를 immutable로 취급 (MVCC 간소화)
공간 증폭	근본적	가변 크기 저장 (→ 동시성 제어 복잡도 증가)
인덱스 구축 시간	부분 근본	WAL 로깅 우회 (인덱스 재생성) + 병렬 구축
고정 선택도	부분 근본	적응적 샘플링 (Exqutor) 또는 벡터 통계

결론: 버퍼 풀, MVCC, 페이지 구조는 근본 한계. 선택도 추정과 인덱스 구축은 개선 가능.

20.4 본 논문과의 관계

이 논문이 식별한 5가지 한계 중:

Exqutor가 직접 해결한 것:

한계 5: 고정 선택도 (33.3%)

→ Exqutor의 ECQ0: 정확한 카디널리티 추정

→ 결과: pgvector에서 1,000배 성능 향상

언급되지만 미해결인 것:

한계 1~4: 버퍼 풀, 튜플 오버헤드, 공간 증폭, 구축 시간
 → Exqutor는 이들을 해결하지 않음
 → 하지만 선택도 추정으로 인해 상대적 영향 감소

예시:

pgvector 기본:

비효율적 계획 선택으로 인한 성능 저하: 1,000배
 + 버퍼 풀 오버헤드: 별도로 ~20배
 종합 오버헤드: 1,000배 × 20배 = 20,000배 이상

Exqutor 적용:

정확한 계획 선택으로 오버헤드 제거: 1,000배 → 1배
 버퍼 풀 오버헤드 여전함: ~20배
 종합 오버헤드: 1배 × 20배 = 20배

실제 측정:

1,000배 → 20배: 실질 향상 50배 (1,000/20)

20.5 pgvector 진화와의 관계

논문은 pgvector 0.5.x를 기준으로 분석했다. 이후 버전:

pgvector 0.6 ~ 0.7:

- HNSW 구현 개선 (메모리 효율 향상)
- 병렬 검색 지원
- 일부 성능 개선

하지만:

- 버퍼 풀 오버헤드 여전함 (아키텍처 한계)
- 고정 선택도(33.3%) 여전함 (쿼리 최적화 개선 안 됨)

따라서 Exqutor의 성능 향상은 **버전 업데이트와 무관하게 여전히 유효**하다.

추가 제기 문제

1. 비교 대상으로서 Faiss의 한계

논문은 Faiss를 완벽한 벡터 DB로 표현하지만, Faiss는:

- **인메모리만 지원**: 디스크 버전 없음
- **단일 머신**: 분산 지원 없음
- **ACID 미지원**: 트랜잭션 없음
- **OLTP 미지원**: 지속적 업데이트에 약함

따라서 pgvector vs Faiss 비교는 "**범용 DB vs 전문 라이브러리**" 비교이지, "좋은 DB vs 나쁜 DB" 비교가 아니다.

2. 벡터 DB 설계의 다양성

논문의 분석은 PostgreSQL 기반이므로:

- MySQL의 벡터 지원은 어떨까?
- SQLite는?
- Oracle은?

각 DB마다 다를 수 있는데, 일반화가 가능한지 불명확.

3. 최적화 기법의 적용 가능성

논문이 제안한 개선 사항들:

- 벡터 전용 버퍼 풀 (VBASE)
- 벡터 통계 수집 (미제시)
- 병렬 구축 (미제시)

이들을 실제 구현하면 얼마나 효과 있을지 미검증.

상세분석 (계속)

20.6 구현 깊이: 실험 설계

실험 방법론

논문의 신뢰성을 높이기 위해 다음과 같은 방법을 사용:

1. 소스 코드 분석
2. pgvector/PASE의 C 코드를 직접 검토
3. 버퍼 풀, MVCC, WAL 호출 추적
4. 마이크로벤치마크를 통한 각 컴포넌트 영향 측정
5. 격리된 테스트
...

각 오버헤드를 순차적으로 제거하며 측정:

기본 상태: 150ms

버퍼 풀 우회: 140ms (래치 오버헤드 제거) → 10ms 절감

MVCC 우회: 120ms (가시성 체크 제거) → 20ms 절감

WAL 비활성: 100ms (로깅 제거) → 20ms 절감

메모리 직접: 8ms (Faiss 수준) → 92ms 절감

...

1. 카운터 기반 분석
2. PostgreSQL의 내부 통계(페이지 접근 횟수, 래치 경합 횟수)를 이용해 오버헤드 정량화

사용 데이터셋

- **SIFT-128M**: 1.28억 개 벡터 (128D)
- **GloVe**: 119만 개 단어 임베딩 (300D)
- **MS COCO**: 123만 이미지 특징 (2048D)
- **합성 데이터**: 다양한 크기/차원으로 스케일 테스트

성능 지표

응답 시간 = $f(\text{벡터 크기}, \text{벡터 차원}, \text{쿼리 유형})$

기본 메트릭:

- 단일 쿼리 지연시간 (ms)
- 처리량 (벡터/초)
- 메모리 사용량 (GB)
- 저장소 공간 (GB)

20.7 실무적 시사점

이 논문이 제시하는 핵심 교훈:

1. 관계형 DB는 벡터 DB가 아니다

- 성능 최적화를 위해서는 전문 시스템이 필요할 수 있다
- pgvector는 "SQL과의 통합"이 필요할 때 선택

2. 하지만 완전히 포기할 건 아니다

- 일부 오버헤드(선택도 추정)는 소프트웨어 최적화로 해결 가능
- Exqutor 같은 접근이 pgvector의 성능을 획기적으로 개선할 수 있다

3. 아키텍처 선택의 중요성

- 벡터를 주요 데이터로 다루면: 전문 벡터 DB (Milvus, Weaviate) 또는 VBASE
- 벡터가 보조 데이터면: PostgreSQL + pgvector + Exqutor

추가 제기 문제

1. 범용성이 의도적 성능 포기인지 확인 필요

논문은 pgvector의 성능 문제를 식별하지만, "왜 이렇게 설계했는가?"를 질문하지 않는다:

- PostgreSQL 개발자는 벡터 성능보다 **호환성**을 우선시했을 수 있다
- 벡터-전용 코드 경로를 추가하면 유지보수 복잡도가 증가
- "pgvector로 충분한 워크로드"도 많을 수 있다

2. 실세계 워크로드와의 괴리

논문의 벤치마크는 **순수 벡터 검색**에 초점이다:

```
SELECT * FROM vectors
WHERE embedding <-> query_vec < threshold
```

그러나 실제 워크로드는:

```
SELECT v.id, m.metadata, COUNT(*) AS cnt
FROM vectors v
JOIN metadata m ON v.id = m.vector_id
WHERE v.embedding <-> query_vec < threshold
      AND m.created_at > NOW() - INTERVAL '7 days'
GROUP BY v.id, m.metadata
ORDER BY cnt DESC
```

이런 복잡한 쿼리에서는 pgvector의 상대적 성능 저하가 더 클 수 있다.

3. 벡터 품질 지표 부족

논문은 성능만 비교하고, **검색 정확도(recall)**를 명확히 비교하지 않는다:

- HNSW의 근사 알고리즘은 정확도와 성능의 트레이드오프가 있음
 - pgvector vs Faiss의 recall 차이가 있을 수 있음
-