

[35] K-nearest neighbor

저자: L. E. Peterson

학술지: Scholarpedia, vol. 4, no. 2, p. 1883, 2009

주제: KNN 알고리즘의 기본 개념과 이론

요약

본 논문은 Scholarpedia 에 발표된 K-nearest neighbor(KNN) 알고리즘에 대한 종합 개요 논문이다. KNN 은 기계학습에서 가장 단순하면서도 강력한 비모수 분류 및 회귀 알고리즘 중 하나로, 주어진 쿼리 포인트로부터 가장 가까운 K 개의 학습 샘플을 기반으로 예측을 수행한다.

논문에서는 KNN 의 기본 원리, 거리 측정 방식, 최적 K 값 선택 방법, 그리고 계산 효율성 개선 방안을 다룬다. 특히 유클리드 거리, 맨해튼 거리 등 다양한 거리 메트릭과 그들의 특성을 설명한다. 또한 KNN 의 장점으로는 구현의 단순성, 비모수 성질, 그리고 다양한 문제에 대한 적응성을 강조한다.

본 논문과의 관계: Exqutor 시스템은 벡터 기반의 유사도 검색을 위해 KNN 개념을 확장한다. 본 논문은 KNN 의 기본적인 이론적 배경을 제공하며, Exqutor 가 구현하는 필터링 기반 근접 이웃 검색의 근본이 되는 개념이다.

상세분석

35.1 KNN 알고리즘의 기본 원리

K-nearest neighbor 는 지도학습의 기본적인 인스턴스 기반 학습(instance-based learning) 방법이다.

알고리즘의 핵심은 주어진 쿼리 포인트 q 에 대해 학습 데이터셋에서 거리 기준으로 가장 유사한 K 개의 샘플을 찾아 이들의 레이블을 기반으로 q 의 클래스를 결정하는 것이다.

- **분류(Classification):** 다수의 클래스 중 가장 빈번하게 나타나는 클래스로 예측
- **회귀(Regression):** K 개 이웃의 값의 평균 또는 가중 평균으로 예측
- **거리 기반 의존성:** 알고리즘의 정확성은 거리 메트릭 선택에 크게 좌우됨

35.2 거리 메트릭과 특성

논문에서 다루는 주요 거리 측정 방식들:

유클리드 거리(Euclidean Distance)

- 가장 널리 사용되는 거리 메트릭
- $d(x, y) = \sqrt{\sum (x_i - y_i)^2}$
- 저차원 데이터에서 좋은 성능

맨해튼 거리(Manhattan Distance)

- $d(x, y) = \sum |x_i - y_i|$
- 고차원 데이터에서 유클리드보다 성능이 좋을 수 있음

민코프스키 거리(Minkowski Distance)

- 일반화된 거리 메트릭으로 p 값에 따라 다양한 거리 정의 가능
- p=1 일 때 맨해튼, p=2 일 때 유클리드

35.3 최적 K 값 선택

K 값은 모델의 성능을 크게 영향을 미치는 중요한 하이퍼파라미터다:

- **작은 K:** 낮은 편향이지만 높은 분산. 노이즈에 민감
- **큰 K:** 높은 편향이지만 낮은 분산. 클래스 불균형 문제
- **최적화 방법:** 교차 검증(cross-validation)을 통한 K 선택

35.4 계산 효율성과 확장성

원본 KNN 은 모든 학습 데이터와의 거리를 계산해야 하므로 $O(nd)$ 시간 복잡도를 가진다. 고차원 또는 대규모 데이터에서는 계산 비용이 매우 크다.

- **공간 분할 방법:** KD-트리, R-트리 등의 인덱스 구조 사용
- **근사 기법:** 정확한 K-NN 대신 근사 근접 이웃 검색(ANN) 활용
- **차원 축소:** PCA 등으로 데이터 차원 감소

35.5 KNN 의 장단점

장점:

- 구현이 매우 단순명확
- 새로운 데이터에 빠르게 적응 가능
- 다양한 거리 메트릭으로 유연성 제공
- 비모수 방식으로 데이터 분포 가정 불필요

단점:

- 높은 계산 복잡도 (특히 예측 시점)
- 모든 학습 데이터를 메모리에 유지 필요
- 고차원 데이터에서 "차원의 저주" 문제
- K 값 선택의 민감성

35.6 본 논문과의 관계

Exqutor 시스템에서 구현하는 필터링 기반 벡터 검색은 KNN 개념의 확장이다:

- **기본 개념:** 벡터 임베딩 공간에서 K 개의 근접 이웃을 검색
 - **거리 메트릭:** 코사인 유사도, 유클리드 거리 등을 활용
 - **효율성 개선:** HNSW 와 같은 근사 기법으로 $O(\log n)$ 복잡도로 감소
 - **필터링 추가:** 속성 기반 필터링을 통해 조건부 KNN 검색 수행
-

추가 제기 문제

1. **고차원 벡터 공간에서의 거리 메트릭 선택:** 현대의 임베딩 모델(예: BERT, GPT)에서 생성되는 고차원 벡터들에 대해 어떤 거리 메트릭이 가장 적절한가?
2. **필터 조건과 K-NN의 상호작용:** 속성 기반 필터를 적용할 때 정확한 K 개의 결과를 보장하기 위한 최적 전략은 무엇인가?
3. **동적 K 값 조정:** Exqutor가 동적으로 K 값을 조정하여 필터링된 결과의 질을 개선할 수 있을까?
4. **거리 계산의 정규화:** 벡터 정규화가 필터링 성능에 미치는 영향에 대한 실증적 분석이 필요하다.