

[37] Generalized k-nearest neighbor rules

저자: J. C. Bezdek, S. K. Chuah, and D. Leep

학술지: Fuzzy Sets and Systems, vol. 18, no. 3, pp. 237-256, 1986

주제: 퍼지 집합을 이용한 KNN의 일반화

요약

본 논문은 KNN 알고리즘을 퍼지 논리(fuzzy logic)를 이용하여 일반화하는 연구다. 기존의 경직된 KNN 규칙(hard KNN rules)을 확장하여 퍼지 멤버십 함수(fuzzy membership functions)를 도입한 유연한 분류 방법을 제시한다.

논문에서는 퍼지 KNN이 경계 근처의 샘플들을 더 잘 처리할 수 있음을 보여준다. K개 이웃으로부터의 투표 결과를 확률적으로 또는 유사도 가중치로 계산하는 대신, 퍼지 멤버십 함수를 사용하여 각 클래스에 대한 부분적 소속도(partial membership)를 계산한다.

본 논문과의 관계: Exqutor의 필터링 기반 벡터 검색에서 필터 조건의 만족도를 연속적으로 표현할 수 있는 퍼지 논리 개념이 있으며, 본 논문의 일반화된 KNN 개념은 정확성과 유연성 사이의 균형을 맞추는 데 영감을 줄 수 있다.

상세분석

37.1 기존 KNN과의 비교

경직된 KNN (Hard KNN):

- 이웃의 클래스 레이블을 그대로 사용
- 투표(voting): 가장 많은 표를 받은 클래스로 분류
- 이진 결정: 한 클래스 또는 다른 클래스
- 경계 근처의 샘플에 대해 불안정할 수 있음

가중 KNN (Weighted KNN):

- 거리에 반비례하는 가중치 적용
- 더 가까운 이웃에 더 큰 영향력 부여
- 부드러운 성능 개선 하지만 여전히 이진 결정

퍼지 KNN (Fuzzy KNN):

- 각 샘플의 클래스에 대한 멤버십 정도를 퍼지 집합으로 표현
- 0과 1 사이의 연속적 값으로 부분 소속도 표현
- 분류 결과의 신뢰도(confidence) 제공
- 경계 영역의 샘플들을 더 자연스럽게 처리

37.2 퍼지 멤버십 함수

기본 개념:

퍼지 집합 A에 대한 멤버십 함수 $\mu_A(x)$ 는 x가 A에 속할 정도를 $0 \leq \mu_A(x) \leq 1$ 로 나타낸다.

삼각형 멤버십 함수:

- 가장 널리 사용되는 형태
- 선형 증가/감소 구간 포함
- 직관적이고 계산 효율적

종 모양 멤버십 함수:

- 가우시안(Gaussian) 또는 시그모이드 형태
- 중심에서의 소속도가 최대
- 부드러운 전환

사다리꼴 멤버십 함수:

- 플래토 영역을 가진 형태
- 특정 범위에서 완전한 소속도 유지

37.3 퍼지 KNN의 작동 원리

단계별 알고리즘:

1. K개 이웃 선택
2. 쿼리 포인트 q로부터 거리 기준으로 K개의 가장 가까운 샘플 선택
3. 이 단계에서는 기존 KNN과 동일
4. 멤버십 계산

5. 각 이웃이 각 클래스에 속할 정도를 멤버십 함수로 계산
6. 거리 기반 또는 특성 기반 멤버십 함수 사용 가능
7. 퍼지 집계
8. K개 이웃의 멤버십을 집계 (보통 합산 또는 평균)
9. 각 클래스에 대한 종합 멤버십 점수 계산

10. 의사결정

11. 최대 멤버십을 가진 클래스 선택
12. 또는 멤버십 값에 따른 신뢰도 평가

수식 예시:

$$\mu_C(q) = (1/K) * \sum_{i=1 \text{ to } K} \mu_C(x_i)$$

여기서 $\mu_C(x_i)$ 는 이웃 x_i 가 클래스 C에 속할 정도

37.4 거리에 기반한 퍼지 멤버십

거리-기반 멤버십 함수:

- 멤버십이 거리에 따라 결정됨
- 더 가까운 이웃이 더 높은 멤버십 값
- 일반적인 형태:

$$\mu(x_i) = 1 / (1 + (d_i / \sigma)^2)$$

여기서 d_i 는 쿼리까지의 거리, σ 는 스케일 파라미터

매개변수 선택의 중요성:

- σ 값에 따라 감소 곡률 결정
- 작은 σ : 가까운 이웃만 중요
- 큰 σ : 먼 이웃도 고려

37.5 퍼지 KNN의 장점

분류 안정성:

- 경계 영역의 샘플들을 더 부드럽게 처리
- 노이즈에 대한 강건성 향상
- 클래스 불균형 문제 완화

신뢰도 정보:

- 분류 결과의 신뢰도를 정량화
- 낮은 신뢰도의 분류 결과 식별 가능
- 거부 옵션(rejection option) 제공 가능

유연한 해석:

- 분류 결과를 이진 결정 대신 연속적 확률로 표현
- 어플리케이션의 요구에 따른 임계값 조정 가능

37.6 퍼지 KNN의 단점 및 한계

계산 복잡도:

- 각 클래스별 멤버십 계산으로 인한 추가 비용
- 멤버십 함수 평가의 복잡성

파라미터 설정:

- 멤버십 함수 형태 선택 어려움
- 스케일 파라미터(σ) 설정의 민감성
- 교차 검증을 통한 최적화 필요

이론적 정당성:

- 퍼지 멤버십이 실제 확률을 나타내는가?
- 멤버십 함수와 데이터의 불확실성 관계 정의 애매

37.7 본 논문과의 관계

Exqutor 시스템에서 필터링을 고려한 KNN 검색을 수행할 때 퍼지 논리 개념 적용 가능성:

속성 필터링의 퍼지화:

- 필터 조건을 이진(만족/불만족) 대신 연속적 만족도로 표현
- 예: 가격이 "100달러 근처"인 상품 검색
- 퍼지 멤버십 함수로 필터 조건의 유연한 표현

가중 검색:

- 거리와 필터 만족도를 결합한 가중 점수 계산
- 사용자의 선호도에 따른 가중치 조정
- 정확한 일치와 근사적 일치 모두 고려

신뢰도 기반 순위 지정:

- 결과의 신뢰도를 사용자에게 전달
- 임계값 이하의 신뢰도 결과 필터링 가능

추가 제기 문제

1. **벡터 공간에서의 퍼지 KNN**: 고차원 벡터 임베딩 공간에서 퍼지 멤버십 함수를 어떻게 정의할 것인가?
2. **필터와 거리의 퍼지 결합**: 속성 필터 조건과 벡터 거리를 퍼지 논리로 결합했을 때의 성능 이득은?
3. **멤버십 함수 학습**: 데이터로부터 최적의 멤버십 함수를 자동으로 학습할 수 있을까?
4. **다중 필터의 퍼지 논리 결합**: 여러 속성 필터의 AND/OR 조합을 퍼지 집합으로 어떻게 표현할까?
5. **해석 가능성**: 퍼지 KNN의 결과를 사용자에게 어떻게 해석 가능한 형태로 제시할 것인가?
6. **성능과 불확실성**: 퍼지 멤버십 함수가 실제 불확실성을 올바르게 반영하는가?