

## [62] YFCC100M: The New Data in Multimedia Research

---

### 요약

---

본 논문은 Yahoo Flickr Creative Commons 100 Million (YFCC100M) 데이터셋을 소개하는 2016년 CACM 논문이다. 저자들은 Flickr 플랫폼에서 수집한 1억 개의 이미지로 구성된 대규모 공개 멀티미디어 데이터셋을 제시한다. 이는 컴퓨터 비전과 멀티미디어 연구 분야에서 가장 광범위하게 사용되는 벤치마킹 데이터셋 중 하나가 되었다.

#### YFCC100M의 핵심 특징:

- 규모: 1억 개의 이미지와 동영상
- 출처: Flickr의 Creative Commons 라이선스 콘텐츠
- 메타데이터: 업로더, 태그, 위치 정보, 카메라 정보 등 풍부한 부가 정보
- 공개성: 연구 커뮤니티에 무료 공개

#### 멀티미디어 연구에서의 중요성:

- 이전 데이터셋보다 훨씬 큰 규모 → 딥러닝 모델 훈련에 적합
- 다양한 사진 스타일과 주제 포함
- 실제 사용자가 올린 자연스러운 이미지 (수작업으로 큐레이션된 것 아님)
- 개인정보 존중 (Creative Commons 라이선스 확인)

#### YFCC100M의 활용:

- 이미지 분류, 객체 감지, 장면 이해 등의 기반 데이터
- 이미지 검색, 유사성 학습의 벤치마크
- 멀티모달 연구(텍스트+이미지) 기반 데이터

Exquitor 연구에서 YFCC100M은 벡터 검색 시스템을 평가하기 위한 실제 규모의 이미지 컬렉션으로 활용되며, 이미지 기반 벡터 검색의 성능 특성을 이해하는 데 중요한 역할을 한다.

## 상세분석

---

### 62.1 데이터셋의 역사적 맥락

#### 1.1 이전 세대 데이터셋의 한계

- ImageNet: 높은 품질이지만 규모 제한 (~1.4M 이미지)
- COCO: 상세 주석이 있지만 매우 큰 규모 불가능 (~330K 이미지)
- Academic의 비용: 고품질 수작업 큐레이션의 비용 증가

#### 1.2 왜 YFCC100M인가?

2010년대 초중반에:

- 소셜 미디어에서 자연스러운 대규모 이미지 데이터 활용 가능
- 메타데이터의 풍부함 (사용자 태그, 위치, 촬영 정보 등)
- 개인정보 보호 가능한 Creative Commons 라이선스

이는 데이터셋 수집의 인식 전환을 대표한다.

### 62.2 데이터셋의 구성과 특징

#### 2.1 수치적 규모

- 이미지: 1억 개
- 동영상: 추가로 포함
- 메타데이터: 업로더, 촬영일, GPS 좌표, 카메라 모델, 렌즈 정보
- 사용자 생성 태그: 평균 5-10개 태그/이미지

#### 2.2 데이터 다양성

다양한 이미지 카테고리:

- 풍경, 건축, 음식, 동물, 사람 등
- 다양한 촬영 환경과 조건
- 전 세계 다양한 지역의 이미지

#### 2.3 메타데이터의 가치

GPS 좌표로부터:

- 지역별 시각적 특징 연구 가능
- 동일 장소의 다양한 시간대 이미지 연구
- 지리 공간 시각 인식 연구

사용자 태그로부터:

- 대규모 약지도(weak label) 데이터 생성
- 사람의 의도와 관심 파악
- 태그의 다양성로부터 시각적 개념의 복잡성 이해

### 62.3 멀티미디어 연구에서의 활용

#### 3.1 이미지 분류 벤치마크

타스크: 이미지를 1000개 카테고리로 분류  
평가 지표: Top-1, Top-5 정확도  
의미: 다양한 분류 모델의 성능 비교 기준

YFCC100M 활용: 사전 훈련(pre-training) 데이터  
- ImageNet만으로는 부족한 다양성 제공  
- 더 견고한 특징 학습 가능

### 3.2 이미지 검색 벤치마크

타스크: 쿼리 이미지와 가장 유사한 이미지 찾기  
평가 지표: Recall@k, NDCG, MAP  
의미: 검색 시스템의 효율성과 정확도 평가

YFCC100M 활용:  
- 대규모 갤러리(1억 이미지)에서 검색 테스트  
- 실제 인터넷 규모의 검색 문제 모사  
- 시스템 확장성 평가

### 3.3 객체 감지와 장면 이해

- 약지도 학습으로 수백만 이미지 활용
- 자동으로 객체 위치 정보 생성
- 이전에 불가능했던 규모의 학습

## 62.4 벡터 검색 시스템의 벤치마킹

### 4.1 YFCC100M을 이용한 평가

현대 벡터 검색 시스템의 성능 평가:

1. 이미지 임베딩 생성
2. 사전 훈련된 CNN 모델 사용
3. 각 이미지 → 고차원 벡터 변환
4. 벡터 인덱스 구축
5. 1억 벡터를 특정 시스템(Faiss, Milvus 등)에 인덱싱
6. 메모리, 디스크 사용량 측정
7. 검색 성능 평가
8. 쿼리 이미지 선택
9. 검색 레이턴시 측정
10. Recall 계산 (정확한 kNN과 비교)

### 4.2 성능 특성 분석

- 작은 배치(수천 이미지): 모든 시스템 비슷한 성능
- 중간 규모(수백만 이미지): 시스템 차이 명확
- 대규모(1억 이미지): 인덱싱 및 검색 기법의 중요성 극대화

## 62.5 데이터셋의 한계와 편향

### 5.1 출처의 편향

- Flickr 사용자 특성: 선진국, 특정 언어권 과다 대표
- 촬영 주제의 편향: 관광 명소, 특정 문화에 집중
- 사진 스타일: 아마추어부터 전문가 수준

### 5.2 데이터 품질 문제

- 약지도 태그의 부정확성
- 스팸 또는 부적절한 콘텐츠 포함 가능성
- GPS 정보의 부정확성 (사용자 수동 입력 또는 생략)

### 5.3 시대성 문제

- 2016년 데이터셋 → 2010년대 초중반 이미지 주로 포함
- 최신 스마트폰의 이미지 특성(높은 해상도, 처리된 색감 등) 과소 표현
- 패션, 기술 트렌드의 시간차

## 62.6 본 논문과의 관계

Exqutor에서 YFCC100M을 활용하는 이유:

- **실제 규모의 벤치마크**: 1억 이미지는 대규모 벡터 검색의 현실적 규모
- **다양한 쿼리 시나리오**: 다양한 이미지 주제로부터 실제 사용 사례 모사
- **메타데이터 활용**: 위치, 촬영일, 태그 등의 메타데이터와 결합한 복합 쿼리 평가
- **기존 연구와의 비교**: 수많은 기존 연구가 YFCC100M을 사용했으므로 결과 비교 용이

구체적으로:

- 텍스트 필터 + 이미지 유사도 검색의 하이브리드 쿼리 평가
- 위치 기반 필터 + 벡터 검색의 지리 공간 쿼리 평가
- 시간 범위 필터와 벡터 검색의 결합 평가

## 추가 제기 문제

---

1. **시대 편향 보정**: YFCC100M이 2010년대 초반 이미지 중심이라면, 현대 스마트폰 이미지의 특성(높은 해상도, 자동 보정 등)에 대한 시스템의 성능은 어떻게 변할 것인가?
2. **메타데이터 품질**: GPS 정보의 20-30%가 없거나 부정확하다면, 지리 공간 필터 기반 쿼리의 신뢰성은? 필터링 성공률의 변동이 큰가?
3. **태그 기반 필터의 한계**: 사용자 생성 태그가 부정확하거나 모호할 때(예: "sunset" 태그가 붉은색 어떤 사진든 붙어있음), 태그와 벡터 검색의 결합이 효과적인가?
4. **표현 편향의 영향**: 선진국 관광지 이미지 과다 표현이 학습된 임베딩 모델에 편향을 가져오는가? 특정 장소나 문화의 검색 정확도가 떨어지는가?
5. **장기 이미지 검색의 과제**: 같은 장소의 오래된(2012) 이미지와 최신(2024) 이미지를 매칭해야 할 때 성능은? 건축, 자연 변화가 임베딩 유사도에 어떻게 영향을 주는가?
6. **동적 데이터셋 관리**: 1억 이미지 데이터셋이 매년 추가된다면 어떻게 관리할 것인가? 인덱스 재구축 주기는? 모델 업데이트에 따른 기존 임베딩의 유효성은?