

## [63] Results of the Big ANN: NeurIPS'23 Competition

---

### 요약

---

본 논문은 2023년 NeurIPS에서 개최된 Big ANN(Approximate Nearest Neighbor) 경쟁의 결과를 분석하는 arXiv 논문이다. 저자들은 H. V. Simhadri 등이 제시한 이 경쟁이 1억에서 10억 규모의 벡터 데이터셋에서 정확한 최근접 이웃 검색 알고리즘의 성능을 객관적으로 비교하는 표준 벤치마크를 제공한다.

#### Big ANN 경쟁의 목표:

- 다양한 규모의 벡터 검색 문제를 정의
- 동일한 하드웨어 환경에서 다양한 시스템의 성능 비교
- 학계와 산업의 ANN 알고리즘 발전 추적
- 성능 측면(속도, 정확도, 메모리)의 객관적 평가

#### 경쟁 구성:

- 여러 데이터셋 (SIFT, GIST, 텍스트 임베딩, 이미지 특징)
- 다양한 규모 (1억, 10억 벡터)
- 제한된 메모리 조건 (1GB, 10GB, 100GB, 1TB)
- 고정 하드웨어 환경 (동일 프로세서, 메모리, 저장소)

#### 주요 결과:

- 알고리즘의 선택이 성능에 미치는 영향이 매우 큼
- 가정 효과(memory vs speed trade-off)의 구체적 정량화
- 최신 기법(그래프 기반, 하이브리드)의 우월성 입증
- 개발자와 연구자에게 알고리즘 선택 지침 제공

Big ANN 경쟁은 벡터 검색 시스템의 성능 평가에 새로운 표준을 제시하며, Exqutor 같은 벤치마킹 연구의 직접적인 참고 자료가 된다.

## 상세분석

### 63.1 경쟁 설계의 혁신

#### 1.1 표준화의 필요성

이전까지 벡터 검색 연구의 문제점:

- 각 논문이 자신의 데이터셋과 평가 방법 사용
- 결과 비교 불가능 (사과와 오렌지 비교)
- 알고리즘 발표자의 자유도 높음 → 결과 신뢰도 하락
- 업계와 학계의 성능 차이 미스터리

Big ANN이 해결한 것:

- 동일한 데이터셋, 평가 지표, 하드웨어 사용
- 투명한 평가 프로세스
- 재현 가능한 결과

#### 1.2 경쟁의 3가지 축

규모 (Scale)

1억 벡터 (100M)

10억 벡터 (1B)

메모리 제약 (Memory Budget)

1GB, 10GB, 100GB, 1TB

데이터셋 다양성 (Data Types)

SIFT: 컴퓨터 비전 특징

GIST: 장면 이해 특징

YFCC: 실제 이미지 임베딩

TRIPLES: 텍스트 임베딩

MSMARCO: 문서 검색 임베딩

### 63.2 주요 데이터셋과 특성

#### 2.1 SIFT (128차원)

- 고전적 컴퓨터 비전 특징
- 매우 높은 차원도(128)에 비해 크기는 작음
- 특성: 클러스터링 어려움, 높은 기하학적 복잡도

#### 2.2 GIST (960차원)

- 이미지의 전체 장면 특성 인코딩
- 더 높은 차원도
- 특성: 서로 다른 이미지 간의 거리 분포가 다양함

#### 2.3 YFCC (1000차원)

- 실제 신경망에서 생성된 이미지 임베딩
- 학습된 표현 (vs 수작업 설계)
- 특성: 의미론적 유사성을 잘 인코딩

## 2.4 MSMARCO (768차원)

- BERT 임베딩 기반 텍스트 표현
- NLP 분야의 표준 벤치마크
- 특성: 의미론적 검색의 현실성 반영

## 63.3 경쟁 결과의 주요 발견

### 3.1 알고리즘 성능 순위

상위 항목들의 공통 특징:

- 그래프 기반 방법 (HNSW, RobustPQ, SRS)
- Top recall(>99%) 달성
- 메모리 효율적
- 검색 속도 우수
- 하이브리드 접근법
- 양자화 + 그래프의 결합
- 메모리-속도-정확도의 균형
- 계층적 구조
- 거친 검색(coarse) + 정세 검색(fine)
- 단계적 정제

### 3.2 메모리 트레이드오프 분석

메모리 1GB 제약:

- 극단적 압축 필요 (1비트 ~ 4비트)
- Recall ~60-70% 수준
- 매우 빠른 검색

메모리 10GB 제약:

- 합리적 압축 (4비트 ~ 8비트)
- Recall ~85-90% 수준
- 실무 적용 가능 수준

메모리 100GB 이상:

- 거의 손실 없는 표현 가능
- Recall >98% 달성
- 검색 속도 최우선 최적화 대상

### 3.3 규모 확장성

100M 벡터 (1억)

- 웹 규모(웹 페이지 검색 등) 초기 수준
- 대부분의 알고리즘 실용적 성능

1B 벡터 (10억)

- 대규모 인터넷 스케일
- 알고리즘 간 성능 차이 극대화
- 메모리 효율성 극도로 중요

## 63.4 상위 솔루션의 기법

### 4.1 그래프 기반 방법의 우월성

HNSW (Hierarchical Navigable Small World):

- 계층적 그래프 구조
- 로그 복잡도의 검색
- 메모리 오버헤드 작음 (원본 벡터 저장 필요)
- Recall 매우 높음

### 4.2 양자화의 발전

Residual Quantization:

- 벡터를 단계적으로 양자화
- 각 단계에서 남은 오차(residual) 인코딩
- 정확도 개선으로 메모리 효율성 향상

Product Quantization:

- 부분벡터 독립 양자화
- 빠른 거리 계산
- 대규모 데이터셋에 적합

### 4.3 하이브리드 접근법

최고 성능 팀들의 공통점:

1. 계층적 구조: 거칠게 후보 선정
2. 정밀 인덱싱: 선택된 영역 내에서 정확한 검색
3. 재순위: 상위 k개에 대해 더 정확한 계산
4. 압축: 각 단계마다 다양한 수준의 양자화

## 63.5 실무적 시사점

### 5.1 시스템 선택 지침

- 메모리 충분(100GB+): HNSW 기반 시스템 추천
- 메모리 제약(10GB): PQ + 그래프 하이브리드
- 극도의 제약(1GB): 극단적 양자화 필수

### 5.2 성능 벤치마킹의 표준

Big ANN이 제시한 평가 방법:

- Recall@1 (가장 정확한 최근접 이웃 찾기)
- QPS (초당 쿼리 처리 능력)
- 메모리 사용량
- 인덱싱 시간

이 지표들의 조합으로 종합적 비교

### 5.3 연구 방향의 지표

경쟁 결과가 시사하는 방향:

- 메모리 효율적인 그래프 기반 방법의 지속적 개선

- 하드웨어 특화 최적화 (GPU, 벡터 프로세서)
- 동적 인덱싱 (데이터 추가/삭제 효율성)
- 멀티벡터 객체 검색 (복합 임베딩)

## 63.6 본 논문과의 관계

Exqutor의 벡터 검색 벤치마킹에서:

- **표준 지표 채택:** Big ANN이 제시한 recall, QPS 메트릭 활용
- **데이터셋 선택:** 다양한 데이터셋(SIFT, YFCC 등) 활용 정당화
- **성능 기준:** 상위 시스템의 성능 수준을 비교 기준으로 설정
- **메모리 제약 분석:** 현실적 메모리 제약 조건 하에서의 성능 평가

구체적으로:

- SQL 쿼리와 벡터 검색의 결합에서 벡터 부분의 성능 최적화 기준 제공
- TPC-H 확장 시 벡터 검색의 예상 성능 수준 설정
- 다양한 벡터 데이터 타입(이미지, 텍스트)에서의 성능 차이 예측

## 추가 제기 문제

---

1. **하드웨어 의존성**: Big ANN 경쟁이 특정 CPU(예: AMD EPYC)에서 수행되었는데, 다른 하드웨어(ARM, GPU)에서는 순위가 얼마나 바뀌는가?
2. **데이터 분포의 영향**: SIFT(매우 높은 차원도, 희소성)와 MSMARCO(낮은 차원도, 밀집성)에서 최적 알고리즘이 다른가? 하이브리드 시스템은 가능한가?
3. **동적 업데이트**: Big ANN이 정적 인덱스만 평가했는데, 벡터가 지속적으로 추가되는 환경에서의 성능은? 온라인 알고리즘과의 성능 격차는?
4. **메모리-정확도의 한계**: 메모리 1GB에서 recall 60-70%는 현실적으로 충분한가? 응용 사례별로 필요한 최소 recall은?
5. **쿼리 배치 효과**: Big ANN이 배치 쿼리(여러 쿼리 동시 처리)를 평가했는가? 배치 크기 변화에 따른 성능 변동은?
6. **하이브리드 쿼리**: 벡터 검색 + 메타데이터 필터의 복합 쿼리는 Big ANN에서 평가되었는가? 필터 선택도(selectivity)에 따른 성능 변화는?