

# [67] Determining Sample Size: Statistical Sampling Theory

## 요약

본 논문은 1992 년 Israel 등에 의해 발표된 통계학 기반의 표본 크기 결정 방법론이다. 이는 대규모 모집단에서 통계적으로 유의미한 결론을 도출하기 위해 필요한 최소 표본 크기를 계산하는 방법을 제시한다. 이 이론은 실험 설계, 시뮬레이션, 벤치마크 연구에서 핵심적인 역할을 한다.

### 표본 크기 결정의 중요성:

- 너무 작은 표본: 통계적 신뢰도 낮음, 결론 신뢰할 수 없음
- 너무 큰 표본: 불필요한 계산 비용, 실험 기간 연장
- 최적 표본: 통계적 유의성 + 실무적 효율성의 균형

### 핵심 개념:

- 신뢰도(Confidence Level): 일반적으로 95%, 99%
- 오차 한계(Margin of Error): 결과가 벗어날 수 있는 범위
- 표준편차(Standard Deviation): 데이터의 변동성
- 신뢰 구간(Confidence Interval): 모수가 포함될 범위

### 표본 크기 공식:

$$n = (Z * \sigma / E)^2$$

n: 필요한 표본 크기

Z: 신뢰도에 따른 값 (95% → 1.96, 99% → 2.576)

$\sigma$ : 모집단의 표준편차

E: 허용 오차 한계

**실무 응용:**

- 데이터베이스 성능 테스트
- 머신러닝 모델의 샘플 크기
- A/B 테스트 설계
- 시뮬레이션 실험

Exqutor에서 벡터 검색 시스템의 성능을 평가할 때, 초기 표본 크기를 결정하는 데 이 통계 이론이 기초가 된다. 특히 대규모 데이터셋(10억 벡터)에서 현실적인 표본 크기를 선택하기 위해 이 방법론을 적용한다.

---

## 상세분석

### 67.1 통계 표본 추출의 기초

#### 1.1 모집단 vs 표본

모집단(Population):

- 조사 대상이 되는 전체 집합
- 예: 1 억 개의 벡터 모두

표본(Sample):

- 모집단에서 선택된 부분집합
- 예: 1 억 개 벡터 중 1000 개 선택

실제 상황:

- 모집단 전체 분석은 비용이 매우 높음 (시간, 계산)
- 대신 표본으로 모집단의 특성 추정

#### 1.2 표본 추출의 종류

확률 표본 추출:

##### 1. 단순 무작위 표본 추출(Simple Random Sampling)

- 각 원소가 선택될 확률이 동일
- 가장 편향 없는 방법

##### 2. 계층 표본 추출(Stratified Sampling)

- 모집단을 층(strata)으로 나누고 각 층에서 표본 추출
- 예: 크기별 벡터 클러스터에서 각각 추출

##### 3. 군집 표본 추출(Cluster Sampling)

- 모집단을 군집으로 나누고 일부 군집 전체 선택
- 예: 벡터 공간의 일부 지역만 선택

비확률 표본 추출:

- 편의 표본 추출(Convenience Sampling)
- 의도 표본 추출(Purposive Sampling)
- 편향 가능성 높음 (벤치마킹에는 부적절)

### 1.3 표본 크기의 역할

표본이 작을 때:

- 표본 평균의 변동성 큼
- 신뢰 구간 넓음
- 통계적 검정력 낮음

표본이 클 때:

- 표본 평균이 모집단 평균에 가까움
- 신뢰 구간 좁음
- 통계적 검정력 높음
- 하지만 계산 비용 증가

## 67.2 표본 크기 결정 공식

### 2.1 기본 공식

신뢰 구간 기반:

$$n = (Z * \sigma / E)^2$$

여기서:

- Z: 표준정규분포의 임계값

\* 95% 신뢰도 → Z = 1.96

\* 99% 신뢰도 → Z = 2.576

\* 90% 신뢰도 → Z = 1.645

-  $\sigma$ : 모집단의 표준편차

\* 사전에 알려지지 않으면 예비 표본에서 추정

- E: 허용 오차 한계

\* 평균값의 ± 몇 %까지 허용할 것인가

\* 예: 평균 레이턴시의 ±10ms

### 2.2 예제: 벡터 검색 레이턴시

상황:

- 벡터 검색 시스템의 쿼리 레이턴시 측정

- 목표: 모집단 평균 레이턴시를 ±5ms 오차 범위로 추정 (95% 신뢰도)

- 예비 조사: 표준편차  $\sigma = 20\text{ms}$

계산:

$$n = (1.96 * 20 / 5)^2$$

$$= (7.84)^2$$

$$= 61.5$$

$$\approx 62 \text{ 개 쿼리}$$

해석:

- 최소 62 개의 쿼리를 실행해야 함

- 이로써 95% 신뢰도로 평균 레이턴시를 ±5ms 범위로 추정 가능

## 2.3 비율(Proportion) 추정용 공식

$$n = (Z / E)^2 * p * (1-p)$$

- p: 예상 비율 (예: recall rate)
- (1-p): 그 반대 비율
- p \* (1-p): 최대값 0.25 (p=0.5 일 때)

예: 벡터 검색 정확도(recall@100)

- 목표: 정확도를  $\pm 5\%$  오차 범위로 추정 (95% 신뢰도)
- 예상 recall: 90%

$$\begin{aligned} n &= (1.96 / 0.05)^2 * 0.9 * 0.1 \\ &= (39.2)^2 * 0.09 \\ &= 138 \end{aligned}$$

→ 최소 138 개 쿼리 필요

## 67.3 Exqutor 논문에서의 적용

### 3.1 초기 표본 크기 결정

Exqutor 는 대규모 데이터셋에서 벡터 검색 성능을 평가할 때:

문제 정의:

- 1 억 개의 벡터 검색 성능 평가
- 모든 벡터에 대해 처리하면 시간이 매우 오래 걸림
- 대표성 있는 표본의 크기는?

적용:

1. 목표 정확도: 평균 레이턴시  $\pm 10\%$  (95% 신뢰도)
2. 예비 조사: 1000 개 벡터로 미리 테스트
  - 평균 레이턴시: 50ms
  - 표준편차: 8ms
  - 변동계수(CV):  $8/50 = 16\%$
3. 표본 크기 계산:
  - 오차 한계:  $50\text{ms} * 10\% = 5\text{ms}$
  - $n = (1.96 * 8 / 5)^2 = 9.83^2 \approx 97$  개
4. 결론: 최소 100 개의 벡터 쿼리가 표본으로 충분

### 3.2 실제 구성

계층 표본 추출 적용:

- 데이터: 1 억 개 벡터
- 클러스터: 차원도별로 분류
- 각 클러스터에서 비례적으로 표본 추출

이점:

- 다양한 벡터 특성 반영
- 편향 감소
- 표본 크기 최적화 가능

## 67.4 통계적 검정과의 연관

### 4.1 가설 검정

귀무가설( $H_0$ ): 두 시스템의 성능이 같다  
 대립가설( $H_1$ ): 두 시스템의 성능이 다르다

예: 시스템 A vs 시스템 B의 레이턴시 비교

표본 크기와 검정력(Power):

- 작은 표본: 실제로 다른데 같다고 결론낼 수 있음 (제 2 종 오류)
- 적절한 표본: 실제 차이를 감지할 확률 높음

필요한 표본 크기 = 신뢰도 + 검정력 함수

- 신뢰도:  $\alpha = 0.05$  (95%)
- 검정력:  $\beta = 0.80$  (80% 확률로 차이 감지)

### 4.2 효과 크기(Effect Size)

Exqutor의 경우:

- 시스템 A 레이턴시: 50ms
- 시스템 B 레이턴시: 55ms
- 실제 차이: 5ms

이것이 통계적으로 유의미한가?

- 표본이 작으면: 우연의 변동으로 보일 수 있음
- 적절한 표본 크기로: 실제 차이인지 판단 가능

필요 표본 크기는 예상 차이의 크기에 반비례:

- 차이가 크면: 적은 표본으로 충분
- 차이가 작으면: 큰 표본 필요



## 67.5 실무적 고려사항

### 5.1 비용-편익 분석

추가 표본의 비용:

- 계산 비용: 각 쿼리마다 계산 필요
- 시간: 모든 쿼리 실행 완료까지 기다려야 함
- 저장소: 결과 저장 필요

추가 표본의 이득:

- 신뢰도 증가
- 오차 한계 감소
- 더 정확한 결론

최적 지점: 신뢰도와 비용의 균형

### 5.2 시간 제약

Exqutor 논문의 현실:

- 서로 다른 시스템들과 설정 비교
- 벡터 검색 시스템 평가는 시간이 오래 걸림

해결책:

- 초기 표본 크기: 충분히 신뢰할 수 있는 최소 크기
- 1 억 벡터에서 수만~수십만 벡터 표본 사용
- 통계적으로 유의미한 결론 도출 가능

### 5.3 다양한 설정에서의 표본

Exqutor의 여러 실험:

- 다양한 벡터 데이터셋 (SIFT, YFCC, 텍스트)
- 다양한 인덱싱 방법
- 다양한 메모리 제약

각 설정마다 표본 크기를 독립적으로 결정하거나,  
보수적으로 모든 설정에 대해 동일하게 큰 표본 사용 가능

## 67.6 표본 크기의 한계와 주의

### 6.1 표본 크기만으로는 부족

좋은 표본 크기:

- 통계적으로는 중요
- 하지만 충분조건은 아님

도 고려해야 할 점:

1. 표본의 대표성: 크기만 크다고 대표성이 있는가?
2. 표본 추출 방법: 무작위 추출이 가능한가?
3. 측정 오차: 도구(벤치마크)의 신뢰성
4. 외부 효과: 다른 변수의 영향 (시스템 부하 등)

### 6.2 표본 편향

벡터 검색 벤치마킹 사례:

- 특정 차원도의 벡터만 사용 (편향)
- 특정 데이터 분포만 사용 (편향)
- 최적화된 하드웨어에서만 테스트 (편향)

결과: 통계적으로 정확하지만 현실성이 떨어질 수 있음

## 67.7 본 논문과의 관계

Exqutor의 실험 설계에서:

- **초기 표본 크기:** 1억 벡터에서 몇 만개를 선택할 것인가 결정
- **신뢰도 설정:** 95% vs 99% 신뢰도 선택에 따른 표본 크기 영향
- **다중 비교:** 여러 시스템, 데이터셋, 설정 비교 시 표본 크기 조정
- **통계적 유의성:** "이 성능 차이가 우연이 아닌가?" 판단 기준

구체적으로:

- TPC-H 쿼리 실행: 전체 데이터 vs 표본 데이터
  - 벡터 인덱싱: 모든 벡터 vs 대표 표본
  - 성능 비교: 신뢰할 수 있는 최소 표본 크기 결정
-

## 추가 제기 문제

1. **다양한 벡터 특성:** 차원도, 분포, 특성이 다른 벡터 데이터셋(SIFT, YFCC, 텍스트 임베딩)에서 필요한 표본 크기가 얼마나 다른가?
2. **편향의 영향:** 계층 표본 추출 vs 단순 무작위 표본 추출에서 필요한 표본 크기의 차이는? 어떤 방법이 더 효율적인가?
3. **시간 의존성:** 시간이 지나면서 벡터 데이터의 분포가 변할 때(temporal drift), 표본 크기 결정은 어떻게 변해야 하는가?
4. **다중 메트릭:** 레이턴시, recall, 메모리 사용량 등 여러 메트릭을 동시에 평가할 때, 필요한 표본 크기는 단일 메트릭의 경우보다 얼마나 커져야 하는가?
5. **오차 한계의 선택:** Exqutor 가 평균 레이턴시의  $\pm 10\%$  vs  $\pm 5\%$  vs  $\pm 1\%$  중 어느 것을 목표로 할 것인가? 실무적으로 의미 있는 차이는 얼마인가?
6. **신뢰도와 검정력:** 95% 신뢰도 + 80% 검정력 vs 99% 신뢰도 + 90% 검정력에서 필요한 표본 크기의 차이는?
7. **이상치 처리:** 극히 느리거나 빠른 쿼리(outlier)를 어떻게 처리할 것인가? 이것이 필요한 표본 크기에 어떻게 영향을 미치는가?
8. **초기 예비조사:** Exqutor 가 정확한 표본 크기를 계산하기 위해 필요한 예비조사 규모는? 오버헤드는 얼마인가?