

[69] DeepDB: Learn from Data, Not from Queries!

요약

DeepDB는 Hilprecht et al.의 2019년 논문으로, 데이터 자체를 학습하는 데이터 기반 카디널리티 추정 방법을 제시한다. 이전 Learned Cardinalities가 쿼리 결과(레이블)에 의존했다면, DeepDB는 데이터 분포 자체를 직접 모델링한다. 특히 Sum-Product Networks(SPNs)라는 확률 그래픽 모델을 활용하여 데이터의 결합 확률 분포(joint probability distribution)를 학습한다.

핵심 아이디어는 데이터베이스의 실제 데이터로부터 생성적 모델(generative model)을 구축하는 것이다. 이 모델은 임의의 속성 조합과 값 범위에 대해 선택도를 직접 계산할 수 있다. SPNs는 비매개변수적 확률 모델로서 복잡한 고차원 분포를 효율적으로 표현할 수 있다는 장점이 있다.

DeepDB의 주요 기여는 SPN을 데이터베이스 시스템에 처음으로 적용했다는 점과, 메모리와 정확도의 우수한 트레이드오프를 달성했다는 점이다. 실험 결과 기존 히스토그램보다 10배 이상 적은 메모리로 더 높은 정확도를 제공했다.

본 논문과의 관계: Exqutor의 범위 필터 선택도 추정은 데이터 분포에 대한 사전 지식이 필수적인데, DeepDB의 데이터 기반 분포 학습 방식이 직접적인 방법론적 참고가 된다. 특히 고차원 속성 공간에서의 선택도 계산에서 SPN의 효율성이 매우 관련성 높다.

상세분석

69.1 Sum-Product Networks (SPNs) 개요

확률 그래픽 모델로서의 SPN:

SPN은 방향성 비순환 그래프(DAG)로 표현되는 확률 모델로, 합(sum) 노드와 곱(product) 노드로 구성된다. 각 노드는:

- 곱 노드: 조건부 독립 변수들의 결합 확률을 표현
- 합 노드: 여러 분포의 가중 혼합(weighted mixture)을 표현
- 잎 노드: 개별 속성의 한계 분포(marginal distribution)

이 구조는 고차원 분포를 컴팩트하게 표현하면서도 효율적인 추론을 가능하게 한다.

SPN의 장점:

- 비매개변수적 모델: 데이터 분포의 형태를 미리 가정하지 않음
- 확률론적 기초: 모든 계산이 확률론적으로 해석 가능
- 효율적 계산: 트리 구조로 인한 $O(n)$ 복잡도의 확률 계산

69.2 DeepDB의 핵심 알고리즘

SPN 학습 프로세스:

1. 데이터베이스에서 샘플 또는 전체 데이터 로드
2. ID-SPN(Identity-Splitting SPN) 구축 알고리즘 적용:
 - 재귀적으로 속성 공간을 분할
 - 각 분할에서 통계적으로 독립적인 속성 그룹화
 - 계층적으로 곱 노드와 합 노드 추가
3. 각 잎 노드에 Histogram 또는 Kernel Density Estimation(KDE) 적용

선택도 계산:

- 조건부 확률: $P(\text{속성 범위} \mid \text{조건})$ 계산
- 카디널리티: 선택도 $\times$ 전체 테이블 크기
- 범위 쿼리: 범위에 포함된 bin(bin)의 확률 합산

69.3 메모리 효율성

메모리 사용량 비교:

- PostgreSQL 기본 통계: 속성당 100 바이트
- 1000개 바이닝 히스토그램: 속성당 수 KB
- DeepDB SPN: 속성당 수백 바이트 (데이터 복잡도에 따라)

메모리 최적화:

- 유니버설 함수 근사(universal function approximation) 없이도 실용적 정확도 달성
- 적응적 bin 크기 조정으로 중요 영역에 더 많은 리소스 할당
- 정보 손실을 최소화하는 추상화 수준 선택

69.4 높은 차원성 문제 대응

차원의 저주(Curse of Dimensionality):

전통적 히스토그램은 고차원에서 bin의 개수가 지수적으로 증가하여 실용적이지 않다.

DeepDB의 솔루션:

- 속성 간 의존성 발견: 독립적인 속성 부분집합 식별
- 곱 노드를 통한 인수분해(factorization): 독립적 부분만 곱하기로 결합
- 최소 결합 그래프(minimum spanning tree) 기반의 구조 학습

이를 통해 실제로는 10개 이상의 속성에서도 효율적 학습이 가능하다.

69.5 실험 결과

벤치마크 설정:

- 데이터셋: IMDB (movies 관련), Synthetic (다양한 특성의 데이터)
- 비교 대상: PostgreSQL 통계, 바이닝 히스토그램, Learned Cardinalities
- 메트릭: 상대 오류(Q-Error), 메모리 사용량

주요 결과:

- 정확도: Median Q-Error 5~10 (히스토그램 50~100 대비)
- 메모리: 히스토그램의 1/10 이하
- 속도: 쿼리당 밀리초 단위의 추론

약점:

- 매우 높은 차원(20+)에서는 성능 저하
- 카테고리형 속성이 많을 때 모델 복잡도 증가
- 극단값 범위에서 정확도 감소

69.6 본 논문과의 관계

분포 학습 vs 선택도 추정:

Exqutor는 범위 필터와 벡터 검색의 교집합 선택도를 추정하는데, DeepDB의 확률 분포 학습 방식은 다음과 같은 시사점을 제공한다:

- 데이터 기반 접근의 정당성: 통계를 임시로 수집하기보다 데이터의 구조를 학습
- 확률론적 기초: 선택도를 확률로 해석하면 벡터 검색과 범위 필터의 결합을 확률론적으로 모델링 가능
- 메모리-정확도 트레이드오프: Exqutor의 경량 모델 설계에서 중요한 고려사항

고차원 처리:

벡터 임베딩은 본질적으로 고차원이므로 DeepDB의 차원 축소 기법이 직접 적용 가능하다.

추가 제기 문제

1. **SPN 구조의 최적성**: 주어진 데이터에 대해 최적의 SPN 구조를 자동으로 찾는 알고리즘은 무엇인가?
2. **온라인 적응성**: 데이터가 점진적으로 변할 때, SPN을 재구성하지 않고도 업데이트할 수 있는가?
3. **조건부 선택도**: A가 주어졌을 때 B의 선택도를 계산할 때, SPN의 정확도는 어떻게 변하는가?
4. **결합(Join) 선택도**: 두 개 이상의 테이블 간 조인 선택도 추정으로의 확장은?
5. **벡터 차원과의 상호작용**: 고차원 벡터 검색과 범위 필터를 함께 모델링할 때, SPN의 계산 복잡도는?