

[70] Selectivity Estimation for Range Predicates Using Lightweight Models

요약

Dutt et al.의 VLDB 2019 논문으로, 범위 술어(range predicate)에 대한 선택도 추정에 경량 머신러닝 모델을 활용하는 방법을 제시한다. 이 논문은 Exqutor의 범위 필터 선택도 추정과 직접적인 관련성이 있다.

전통적인 통계 기반 선택도 추정은 히스토그램, 샘플링 등을 사용했으나, 실제 데이터의 분포 특성을 정확히 반영하기 어려웠다. 본 논문은 선형 회귀(Linear Regression), 의사결정 트리(Decision Trees), 랜덤 포레스트(Random Forests) 같은 경량 ML 모델을 사용하여 더 정확한 선택도를 추정하는 방법을 제안한다.

핵심 기여는 범위 술어 선택도 추정이라는 구체적 문제에 대해 경량 모델이 충분히 정확하면서도 계산 비용이 낮다는 점을 입증한 것이다. 특히 여러 범위 조건이 결합된 경우(AND/OR)의 선택도 추정에서 우수한 성능을 보인다.

본 논문과의 관계: Exqutor의 핵심 문제인 "범위 필터와 벡터 검색 조건의 결합된 선택도 추정"은 이 논문의 범위 술어 선택도 추정 기법을 직접 활용할 수 있다. 특히 경량 모델 사용이라는 설계 철학이 완벽하게 일치한다.

상세분석

70.1 범위 술어 선택도 추정의 문제 정의

전통적 접근의 한계:

- **히스토그램:** 메모리 효율적이나 정확도 제한
 - Equi-width: 데이터 분포를 반영하지 못함
 - Equi-depth: 경계 결정의 어려움
- **샘플링:** 낮은 카디널리티 범위에서 부정확
- **통계 공식:** 독립성 가정으로 인한 오류

범위 술어의 정의:

속성 A에 대해 [L, U] 범위의 선택도:

$$\text{selectivity}(A \in [L, U]) = |\{t: L \leq t.A \leq U\}| / |\text{전체 행 수}|$$

70.2 경량 머신러닝 모델의 적용

선택된 모델들:

2.1 선형 회귀 (Linear Regression)

- 형태: $\text{selectivity} = \beta_0 + \beta_{-1} \cdot (L) + \beta_{-2} \cdot (U) + \beta_3 \cdot (U-L) + \dots$
- 장점: 매우 빠른 추론, 해석 가능
- 단점: 선택도의 비선형 특성을 포착하지 못할 수 있음

2.2 의사결정 트리 (Decision Trees)

- 범위를 재귀적으로 분할하여 각 부분에서 지역적 선택도 학습
- 장점: 비선형 관계 포착, 해석 가능
- 단점: 과적합 위험, 트리 깊이 제한 필요

2.3 랜덤 포레스트 (Random Forests)

- 여러 의사결정 트리의 앙상블
- 장점: 과적합 감소, 높은 정확도
- 단점: 메모리 사용량 증가, 추론 시간 증가 (여전히 "경량"임)

2.4 그라디언트 부스팅 (Gradient Boosting)

- 순차적으로 약한 학습기를 결합
- 장점: 매우 높은 정확도
- 단점: 학습 시간 증가

70.3 훈련 데이터 생성 전략

샘플 생성:

1. 범위 경계 선택: 데이터 사분위수, 백분위수 활용
2. 범위 길이 다양화: 작은 범위부터 전체 범위까지
3. 겹침(Overlap) 고려: 다양한 위치의 범위 포함

선택도 레이블:

- 실제 데이터에서 정확한 선택도 계산
- 또는 대규모 샘플링으로 근사

70.4 다중 범위 조건 처리

단일 속성 다중 범위 ($A \in [L1, U1]$ OR $[L2, U2]$):

- 각 범위의 선택도 독립 추정 후 합산
- 또는 결합된 모델로 직접 학습

다중 속성 범위 ($A \in [LA, UA]$ AND $B \in [LB, UB]$):

- 속성 간 상관성 고려 필수
- 순차적 조건화: $P(A) \times P(B|A)$
- 또는 결합 모델: 두 범위를 동시에 입력으로 받음

상관성 처리:

- 속성 간 의존성이 높을 때: 결합 모델이 더 정확
- 속성 간 독립적일 때: 단일 모델 결합 가능

70.5 실험 및 평가

벤치마크 설정:

- 데이터셋: TPC-H, Synthetic data (다양한 분포)
- 비교 대상: 히스토그램, 경험적 통계, Learned Cardinalities
- 메트릭: Q-Error (Quantile Error), Mean Absolute Error

실험 결과:

모델	정확도(Q-Error)	추론시간	메모리	학습비용
Linear Reg	5-10	<1ms	<1KB	매우낮음
Decision Tree	3-5	<1ms	<10KB	낮음
Random Forest	2-3	1-5ms	<100KB	중간
Deep Learning	1.5-2	5-10ms	1MB+	높음

주요 발견:

- 경량 모델로도 충분한 정확도 달성 가능
- 선택도 분포(uniform vs. skewed)에 따라 최적 모델이 다름
- 다중 속성 범위에서는 모델 결합 방식이 중요

70.6 Exqutor 적용에의 의미

범위 필터 선택도 추정:

Exqutor의 핵심 문제인 범위 필터(range predicate)의 선택도 추정은 이 논문의 방법론을 직접 활용할 수 있다.

구체적 적용:

```
selectivity(price ∈ [min_price, max_price] AND category = "electronics")
= selectivity_model.predict([min_price, max_price, category_id])
```

경량 모델 선택의 정당성:

- 벡터 검색의 필터링 단계에서 밀리초 단위의 응답 시간 필요
- 메모리 오버헤드 최소화 (DRAM이 제한적일 수 있음)
- 온라인에서 모델 재훈련 가능성 고려

다중 조건 결합:

벡터 유사성 조건 + 범위 필터 조건의 결합 선택도는 이 논문의 "다중 범위 조건"을 범위 필터와 벡터 유사성으로 확장한 것으로 볼 수 있다.

추가 제기 문제

1. **동적 분포 변화:** 데이터 분포가 시간에 따라 변할 때, 모델을 얼마나 자주 재훈련해야 정확도를 유지할 수 있는가?
2. **범위 외삽(Extrapolation):** 훈련 범위를 벗어난 $[L', U']$ 범위에 대해 모델의 예측 정확도는?
3. **속성 간 강한 상관성:** 여러 속성이 강하게 상관되어 있을 때 (예: 위도-경도), 경량 모델로도 충분한가?
4. **벡터 검색과의 결합:** 벡터 유사성 점수 분포와 범위 필터 선택도를 어떻게 결합할 것인가?
5. **훈련 데이터 선택:** 어떤 범위를 훈련 데이터로 선택하느냐가 성능에 얼마나 영향을 주는가?
6. **극한 케이스:** 매우 낮은 선택도(0.001% 이하)의 범위에 대해 정확도를 유지할 수 있는가?