

[80] Selectivity and Cost Estimation for Joins Based on Random Sampling

요약

Haas, Naughton, Seshadri, Swami 의 JCSS 1996 논문으로, 조인 선택도(join selectivity) 추정을 위한 무작위 샘플링의 이론적 기초를 제시한 '고전' 논문이다. 이 논문은 데이터베이스 통계와 표본론을 결합하여 샘플링 기반 추정의 수학적 모델을 정립했다.

핵심 기여:

1. **이론적 프레임워크:** 조인 크기 추정의 통계 모델 개발
2. **신뢰도 분석:** 샘플 크기와 추정 오류의 관계 공식화
3. **점근 분포(Asymptotic Distribution):** 표본 크기가 클 때의 분포 특성 증명
4. **실용적 가이드:** 필요한 샘플 크기 결정 방법 제시

본 논문은 이후 30 년 가까이 샘플링 기반 카디널리티 추정 연구의 이론적 기반이 되었다. 특히 신뢰도 구간 계산, 적응적 샘플링, 그리고 비용 모델에 광범위하게 인용된다.

본 논문과의 관계: Exqutor 의 적응적 샘플링 방식의 직접적인 이론적 토대다. 특히 선택도 추정의 신뢰도를 정량화하고 필요한 샘플 크기를 결정하는 방법론을 제공한다. Exqutor 는 범위 필터와 벡터 검색의 결합 선택도 추정에 이 논문의 통계 이론을 적용할 수 있다.

상세분석

80.1 조인 선택도의 수학적 정의

기본 정의:

테이블 T1: N_1 개 행

테이블 T2: N_2 개 행

조인 조건 P 에 대해:

조인 결과 = T1 과 T2 의 행 중 P 를 만족하는 쌍의 집합

조인 카디널리티:

$C = |\{(t1, t2) : t1 \in T1, t2 \in T2, P(t1, t2) = \text{true}\}|$

조인 선택도:

$\sigma = C / (N_1 \times N_2)$

예시:

T1: 고객 테이블 (10,000 명)

T2: 주문 테이블 (100,000 건)

조인 조건: 고객.id = 주문.고객_id

조인 결과: 90,000 건 (평균 고객당 9 개 주문)

카디널리티: C = 90,000

선택도: $\sigma = 90,000 / (10,000 \times 100,000) = 0.009$ (0.9%)

80.2 샘플링 이론의 적용

표본 선택도의 분포:

T1 에서 n_1 개, T2 에서 n_2 개 행을 무작위로 샘플링할 때,

샘플 내 조인 결과를 c 라 하면:

표본 선택도: $\sigma_{\text{hat}} = c / (n_1 \times n_2)$

이 추정량의 분포:

Case 1: 선택도가 고정되어 있고 $n \rightarrow \infty$ 일 때

중심극한정리(Central Limit Theorem):

$$\sqrt{n} \times (\sigma_{\text{hat}} - \sigma) \rightarrow N(0, \sigma(1-\sigma))$$

분포: σ_{hat} 는 점근적으로 정규분포

평균: σ

표준편차: $\sqrt{\sigma(1-\sigma) / n}$

Confidence Interval (95% 신뢰도):

$$P(\sigma_{\text{hat}} - 1.96 \times \sigma_{\text{SE}} < \sigma < \sigma_{\text{hat}} + 1.96 \times \sigma_{\text{SE}}) = 0.95$$

$$\text{여기서 } \sigma_{\text{SE}} = \sqrt{(\sigma_{\text{hat}}(1-\sigma_{\text{hat}}) / n)}$$

정규 근사의 신뢰도를 높이려면 n 이 충분해야 함:

$$n \times \sigma_{\text{hat}} > 5 \text{ and } n \times (1-\sigma_{\text{hat}}) > 5$$

80.3 조인에 특정한 이슈

독립성 가정:

조인 조건이 두 테이블의 행을 독립적으로 선택할 때:

$$\sigma(T1, T2) = \sigma(T1) \times \sigma(T2)$$

예:

T1 에서 P_1 을 만족할 확률: $\sigma_1 = 0.2$ (20%)

T2 에서 P_2 를 만족할 확률: $\sigma_2 = 0.5$ (50%)

조인 선택도: $\sigma = 0.2 \times 0.5 = 0.1$ (10%)

(T1.A = T2.A 인 등호 조인이 아닐 때 근사)

등호 조인(Equi-join)의 특수성:

T1.id = T2.id 형태의 조인

경우 1: 외래키 관계 있음

└─ 모든 T2.id 가 T1 에 존재

$$\sigma = N_2 / (N_1 \times N_2) = 1 / N_1$$

(매우 낮은 선택도 가능)

경우 2: 일반적인 등호 조인

$$\sigma = m / (N_1 \times N_2)$$

m = 두 테이블의 공통 키 개수

80.4 점근 성질(Asymptotic Properties)

큰 n 에서의 행동:

샘플 크기 n 이 클 때:

1. 일관성(Consistency):

$\hat{\sigma} \rightarrow \sigma$ (거의 확실하게)

샘플 크기가 증가하면 추정치가 참값으로 수렴

2. 정규 수렴(Normal Convergence):

$(\hat{\sigma} - \sigma) / \sqrt{\sigma(1-\sigma)/n} \rightarrow N(0, 1)$

정규분포로 수렴 속도: $O(1/\sqrt{n})$

3. 효율성(Efficiency):

분산: $\text{Var}(\hat{\sigma}) = \sigma(1-\sigma) / n$

가장 작은 분산을 가짐 (비편향 추정량 중)

80.5 신뢰도와 샘플 크기의 관계

정밀도 요구사항:

$\pm \varepsilon$ 범위의 오류를 $100(1-\alpha)\%$ 신뢰도로 원할 때:

필요한 샘플 크기:

$$n = z_{1-\alpha/2}^2 \times \sigma(1-\sigma) / \varepsilon^2$$

여기서 $z_{1-\alpha/2}$ 는 표준 정규분포의 상위 $\alpha/2$ 백분위수:

- 90% 신뢰도 ($\alpha=0.1$): $z = 1.645$

- 95% 신뢰도 ($\alpha=0.05$): $z = 1.960$

- 99% 신뢰도 ($\alpha=0.01$): $z = 2.576$

구체적 계산 예시:

목표: 선택도 $\sigma = 0.01$ (1%)을 $\pm 20\%$ 상대 오류, 95% 신뢰도로 추정

$$\text{절대 오류 } \varepsilon = \sigma \times 0.2 = 0.01 \times 0.2 = 0.002$$

필요 샘플:

$$n = 1.96^2 \times 0.01 \times 0.99 / 0.002^2$$

$$n = 3.84 \times 0.0099 / 0.000004$$

$$n = 9,504$$

테이블이 1,000,000 행이면: 샘플율 = $9,504 / 1,000,000 \approx 1\%$

선택도에 따른 샘플 크기:

같은 조건 ($\pm 20\%$ 오류, 95% 신뢰도)에서:

$$\sigma = 0.5 \text{ (50\%): } n \geq 2,401$$

$$\sigma = 0.1 \text{ (10\%): } n \geq 9,604$$

$$\sigma = 0.01 \text{ (1\%): } n \geq 9,504 \text{ (}\sigma \text{와 } (1-\sigma) \text{이 비슷해서 최대)}$$

$$\sigma = 0.001 \text{ (0.1\%): } n \geq 95,040$$

$$\sigma = 0.0001 \text{ (0.01\%): } n \geq 950,399$$

선택도 감소에 따라 필요 샘플 선택도의 역함수에 비례

80.6 다중 조인에의 확장

체인 조인(Chain Join):

T1 JOIN T2 JOIN T3

각 조인의 선택도:

$$\sigma_{1_2} = P(t1, t2 \text{ 만족}) = 0.1$$

$$\sigma_{2_3} = P(t2, t3 \text{ 만족}) = 0.2$$

결합 선택도 (독립성 가정):

$$\sigma_{\text{total}} = \sigma_{1_2} \times \sigma_{2_3} = 0.1 \times 0.2 = 0.02 \text{ (2\%)}$$

문제: σ_{total} 이 σ_{1_2} , σ_{2_3} 보다 낮음

→ 최종 카디널리티 추정이 더 불안정

스타 조인(Star Join):

중앙 테이블 T1 과 여러 dimension 테이블 T2, T3, T4 조인

T1 과 T2 의 선택도: $\sigma_{1_2} = 0.3$

T1 과 T3 의 선택도: $\sigma_{1_3} = 0.4$

T1 과 T4 의 선택도: $\sigma_{1_4} = 0.5$

결합 선택도: $\sigma_{\text{total}} = 0.3 \times 0.4 \times 0.5 = 0.06 \text{ (6\%)}$

문제: 테이블이 많을수록 선택도는 더 낮아짐

80.7 비용 모델에의 적용

조인 실행 비용 추정:

조인 비용 = CPU_비용 + I/O_비용 + 메모리_비용

CPU 비용: 조인된 행 수 $\times$ 행당_처리비용
 $= C \times \text{cost_per_row}$
 $= N_1 \times N_2 \times \sigma \times \text{cost_per_row}$

I/O 비용: 접근해야 할 페이지 수
 $= (N_1 \times \text{page_size}_1) + (N_2 \times \text{page_size}_2)$
 (선택도가 낮으면 CPU 비용이 지배적)

정확한 σ 추정 $\rightarrow$ 정확한 비용 예측 $\rightarrow$ 최적 실행 계획

80.8 본 논문과의 관계

Exqutor의 샘플링 기반 선택도 추정:

Exqutor는 범위 필터와 벡터 검색의 결합 선택도를 추정하는데, 이 논문의 이론을 직접 적용할 수 있다:

1 단계: 이론적 기초 적용

범위 필터: WHERE price $\in$ [L, U]

벡터 검색: WHERE similarity(embedding) > θ

쿼리 선택도:

$$\sigma = P(\text{가격 조건}) \times P(\text{유사도 조건})$$

이는 논문의 곱셈 규칙(independent join selectivity)

과 동일한 형태

2 단계: 샘플 크기 결정

목표 정확도: $\pm 15\%$ 상대 오류, 90% 신뢰도

추정된 $\sigma = 0.12$ (범위 필터 15% $\times$ 벡터 80%)

필요 샘플 크기:

$$\epsilon = 0.12 \times 0.15 = 0.018$$

$$z = 1.645 \text{ (90\% 신뢰도)}$$

$$n = 1.645^2 \times 0.12 \times 0.88 / 0.018^2$$

$$n \approx 250 \text{ 개 (전체 1\% 미만)}$$

3 단계: 신뢰도 검증

수집한 샘플에서:

c = 범위 필터 AND 유사도 조건 만족하는 행 수

신뢰도 구간:

$$\sigma_{\text{hat}} \pm 1.645 \times \sqrt{\sigma_{\text{hat}}(1 - \sigma_{\text{hat}}) / n}$$

이 구간이 충분히 좁으면 추정 사용

너무 넓으면 추가 샘플링

논문 [80]의 핵심 가치:

1. **이론적 정당성:** 샘플링 기반 추정의 수학적 기초 제공
 2. **샘플 크기 결정:** $n = z^2 \times \sigma(1-\sigma) / \epsilon^2$ 공식
 3. **신뢰도 계산:** 점근 정규분포를 이용한 신뢰도 구간 계산
 4. **다중 조인 확장:** 곱셈 규칙을 통한 복합 선택도 추정
 5. **실무 적용:** 이후 모든 샘플링 기반 옵티마이저의 기반
-

추가 제기 문제

1. **소 샘플 문제:** n 이 작을 때($n < 30$), 정규 근사가 타당한가? (카이제곱 등 다른 분포 필요?)
2. **상관성 위반:** 범위 필터와 벡터 임베딩이 상관되어 있을 때, 곱셈 규칙이 여전히 유효한가?
3. **모수 σ 의 사전 정보:** σ 를 모르면 샘플 크기 n 을 미리 결정할 수 없는데, 이를 어떻게 해결할 것인가?
 - 해결책: $\sigma = 0.5$ 로 가정 (최악의 경우) → 과도한 샘플 수집
1. **스트리밍 업데이트:** 데이터가 지속적으로 추가될 때, 과거 샘플이 유효한가?
2. **적응적 샘플링의 다중비교:** 여러 쿼리의 선택도를 동시에 추정할 때, 각각 독립적으로 샘플링하면 총 샘플 비용이 급증하는데, 이를 최적화할 수 있는가?
3. **비선형 선택도 관계:** 실제로는 $\sigma_1 \times \sigma_2 \neq \sigma_{\text{total}}$ 일 때(상관성 있을 때), 편향을 추정할 수 있는가?