

[11] Milvus: A Purpose-Built Vector Data Management System

저자: Jianguo Wang, Xiaomeng Yi, Rentong Guo, Hai Jin, Peng Xu 외 다수 (Zilliz, HUST)

학회/년도: SIGMOD 2021

분량: 약 14페이지

역할군: (C) 경쟁/비교 시스템

요약

Milvus는 **전문(특화) 벡터 데이터베이스의 대표 시스템**으로, 벡터 데이터의 저장과 대규모 유사도 검색에 특화되어 설계되었다. 관계형 데이터베이스와 달리, 복잡한 SQL 쿼리 기능보다 **벡터 검색 성능과 확장성**에 집중한다.

Milvus의 핵심 특징은:

1. **클라우드 네이티브 아키텍처:** 저장과 연산의 분리로 탄력적 확장 가능
2. **세그먼트 기반 관리:** 데이터를 불변 세그먼트로 관리하여 인덱싱 간소화
3. **다양한 벡터 인덱스 지원:** FLAT, IVF_FLAT, IVF_PQ, HNSW, DiskANN 등
4. **조절 가능한 일관성:** 성능과 데이터 일관성의 트레이드오프를 사용자가 제어
5. **실제 산업 적용:** 이미지/비디오 검색, 추천 시스템, 생체 인증 등 10+ 실제 응용

Milvus는 높은 검색 성능과 확장성을 제공하지만, **멀티 테이블 조인**이나 **복잡한 SQL 분석 쿼리**를 지원하지 않는다는 근본적 한계가 있다. 이것이 Exqutor가 범용 벡터 DB(pgvector, VBASE, DuckDB)를 대상으로 하는 이유이다.

상세분석

4.1 전문 벡터 DB란 무엇인가

전문 벡터 DB는 **벡터 데이터의 저장과 유사도 검색**에 특화된 시스템이다. 관계형 데이터베이스처럼 복잡한 SQL 쿼리를 지원하는 것이 목표가 아니라, 대규모 벡터를 빠르고 정확하게 검색하는 것이 목표이다.

Milvus가 해결하는 핵심 도전 과제 5가지:

1. **사용하기 쉬운 인터페이스**: 다양한 응용 분야의 개발자가 쉽게 벡터 검색을 활용할 수 있도록 파이썬, Java, Go 등 여러 언어의 SDK를 제공한다. 개발자는 복잡한 인덱스 구조를 이해할 필요 없이, 간단한 API(search, insert, delete)만으로 벡터 검색 시스템을 구축할 수 있다.
2. **이기종 컴퓨팅 최적화**: CPU와 GPU를 효율적으로 활용하여 성능을 극대화한다. 벡터 검색은 높은 병렬성을 가지므로, GPU의 수천 개 코어를 활용하면 성능을 10배 이상 향상시킬 수 있다. Milvus는 이러한 GPU 가속을 자동으로 처리하므로, 개발자는 GPU 프로그래밍 없이도 GPU의 이점을 누릴 수 있다.
3. **단순 유사도 검색을 넘어서는 고급 쿼리**: 속성 필터링(메타데이터 조건), 다중 벡터 검색(여러 벡터 필드 동시 검색), 범위 검색(거리 임계값) 등 실무에서 필요한 고급 기능을 지원한다.
4. **동적 데이터 관리**: 실시간으로 데이터가 삽입·수정·삭제되면서 동시에 검색 요청을 처리해야 하는 상황을 안정적으로 지원한다. 인덱스를 재구축하지 않으면서도 새로운 데이터를 즉시 검색 가능하게 만드는 것이 핵심이다.
5. **확장성과 가용성**: 분산 환경에서 데이터와 쿼리 처리를 여러 노드에 분산시켜, 수십억 건의 벡터를 저장·검색할 수 있어야 한다. 동시에 노드 장애 시에도 서비스가 중단되지 않도록 복제(replication)를 지원해야 한다.

4.2 시스템 구조: 클라우드 네이티브 아키텍처

Milvus는 **클라우드 네이티브 아키텍처**를 채택하여 다음 특징을 갖는다.

저장과 연산의 분리:

- **저장소**: Amazon S3, Google Cloud Storage 같은 객체 스토리지를 사용하여 고가용성과 확장성을 확보한다. 데이터는 스토리지에 영구적으로 저장되며, 여러 노드에서 동시에 접근할 수 있다.
- **연산**: 상태 없는(stateless) 컴포넌트들이 탄력적으로 확장·축소된다. 쿼리 처리 노드는 필요에 따라 동적으로 추가하거나 제거할 수 있으므로, 트래픽 변동에 자동으로 대응할 수 있다.

세그먼트 기반 데이터 관리:

- 데이터는 **컬렉션(Collection)** 단위로 관리되며, 이는 관계형 DB의 테이블에 해당한다.
- 컬렉션은 여러 **세그먼트(Segment)**로 나뉘며, 이는 물리적 저장 단위이다. 각 세그먼트는 불변(immutable)이므로, 한 번 생성되면 수정되지 않는다.
- 세그먼트 단위로 독립적인 인덱스를 구축하고 검색을 수행한다. 새 데이터가 들어오면 새 세그먼트가 생성되고, 백그라운드에서 정기적으로 여러 세그먼트를 병합한다.

조절 가능한 일관성(Tunable Consistency):

- **로그 백본(log backbone)**: 모든 쓰기 작업을 순서대로 로그에 기록하여, 분산 시스템에서 데이터 일관성을 관리한다.
- 사용자는 일관성-성능 트레이드오프를 제어할 수 있다:
- **강한 일관성(Strong)**: 쓰기 직후 읽기 시 최신 데이터 보장. 하지만 모든 노드가 동기화될 때까지 기다려야 하므로 느림.
- **세션 일관성(Session)**: 같은 세션 내에서만 읽기 일관성 보장. 서로 다른 세션은 약간의 시간 차이가 있을 수 있음.
- **최종 일관성(Eventual)**: 가장 빠르지만, 최신 데이터 반영에 약간의 지연이 있을 수 있음.

4.3 지원하는 벡터 인덱스: 다양한 시나리오 대응

Milvus는 다양한 시나리오에 맞는 벡터 인덱스를 지원한다:

인덱스 유형	특징	적합한 경우
FLAT	전수 검색 (brute-force)	소규모 데이터(~10만 건), 100% 정확도 필요 시
IVF_FLAT	클러스터링 기반 + 전수 검색	중규모 데이터(~100만 건), 높은 정확도 원할 때
IVF_PQ	클러스터링 + 양자화(압축)	대규모 데이터(~수억 건), 메모리 절약 필수 시
HNSW	계층적 그래프 기반	빠른 검색 필요, 메모리 충분할 때
SCANN	Google 개발, 양자화 기반	높은 처리량, 실시간 검색 필요할 때
DiskANN	SSD 기반	메모리 부족 시 대규모 데이터 저장 필요할 때

인덱스 선택의 실제 고려사항:

- **데이터 크기**: 작을수록 정확도 높은 FLAT/IVF_FLAT 선택. 클수록 성능 중심의 PQ/HNSW 선택.
- **응답 시간**: 밀리초 단위 응답이 필요하면 HNSW. 수초 단위 허용하면 IVF_PQ로 메모리 절약.
- **업데이트 빈도**: 자주 업데이트되면 HNSW(동적 구조). 거의 업데이트 안 되면 IVF_PQ(정적 구조) 선택.
- **정확도 요구사항**: 재현율(recall) 99%+ 필요하면 HNSW. 90% 정도 허용하면 PQ.

4.4 고급 쿼리 기능: 벡터 검색을 넘어서

Milvus는 단순 top-k를 넘어서 다양한 고급 기능을 지원한다.

속성 필터링: 벡터 유사도 검색 시 스칼라 속성 조건을 함께 적용

```
results = collection.search(
    data=[query_vector],
    anns_field="embedding",
    param={"metric_type": "L2", "params": {"nprobe": 10}},
    limit=10,
    expr="price < 100 AND category == 'electronics'" # 속성 필터
)
```

이렇게 하면 임베딩이 유사하면서 동시에 가격이 100 이하이고 카테고리가 전자제품인 상품만 반환된다.

다중 벡터 검색: 여러 벡터 필드를 동시에 검색하고 결과를 결합. 예를 들어, 상품의 이미지 벡터와 설명 텍스트 벡터를 모두 고려하여 유사한 상품을 찾을 수 있다.

범위 검색: 거리 임계값을 기반으로 한 범위 검색. "매우 유사한(거리 < 0.1) 데이터만" 찾아달라는 식의 쿼리를 지원한다.

4.5 실제 응용 사례: 10+ 산업 분야

논문은 Milvus 위에 구축한 실제 응용을 소개한다:

- **이미지/비디오 검색 시스템**: 전자상거래 플랫폼에서 "유사한 상품 찾기", SNS에서 "같은 사진의 다른 게시물 찾기"
- **화학 분자 구조 분석**: 신약 개발 과정에서 기존 화학식과 유사한 새로운 화학식 검색
- **COVID-19 데이터셋 검색**: 전염병 연구에서 유사한 사례 검색
- **개인화 추천 시스템**: 사용자 행동 벡터와 상품 벡터의 유사도를 기반으로 추천

- **생체 인증**: 얼굴 인식, 홍채 인식 등에서 데이터베이스 내 유사한 생체 정보 검색
- **지능형 질의응답(Q&A)**: 사용자 질문의 의미 벡터와 기존 답변의 의미 벡터 비교

4.6 본 논문과의 관계: 전문 vs. 범용의 핵심 차이

Milvus 같은 전문 벡터 DB의 **근본적 한계**는 복잡한 관계형 연산(조인, 집계, 서브쿼리 등)을 지원하지 않는다는 것이다.

속성 필터링의 한계: Milvus의 속성 필터링은 단일 컬렉션 내에서만 작동한다. 예를 들어:

- 가능: "가격 < 100 AND 카테고리 == 전자제품인 유사 상품 찾기"
- 불가능: "유사 상품을 찾되, 해당 상품을 판매하는 판매자의 등급이 4점 이상인 경우만" (판매자 정보는 다른 컬렉션에 있음)

조인 불가능: 두 벡터를 기반으로 두 테이블을 조인할 수 없다.

이것이 바로 Exqutor가 Milvus 대신 pgvector, VBASE, DuckDB 같은 **범용 벡터 DB**를 대상으로 하는 이유이다. 범용 벡터 DB는 SQL의 모든 기능을 지원하지만, 벡터 검색의 카디널리티 추정이 부정확하다는 문제가 있다. Exqutor는 이 문제를 해결한다.

추가 제기 문제

Milvus의 세그먼트 기반 아키텍처는 확장성은 뛰어나지만, 세그먼트 수가 많아지면 쿼리 시 모든 세그먼트를 방문해야 하는 오버헤드가 발생할 수 있다. 이를 해결하기 위해 백그라운드에서 주기적으로 세그먼트를 병합하는 정책이 필요하지만, 병합과 검색 사이의 타이밍을 어떻게 최적화할 것인가는 여전히 설계 문제로 남아있다.

또한 Milvus가 속성 필터링을 지원하더라도, 필터의 선택도에 따라 인덱스 접근 전략이 어떻게 최적화되는지에 대한 공개 정보가 제한적이다. Exqutor의 ECQO 개념을 Milvus에 적용할 수 있을가에 대한 고민은 흥미로운 미래 연구 주제이다.