

골짜기 바닥을 따라가야 하지만,
기울기는 수직 방향(벽) 쪽을 더 크게 지시:

기울기가 수직 방향을 지시	
^v^v^v^v^v	
이동	→ → → (수평 진행 느낌)
	↓ ↑ ↓ ↑ (수직 진동)

결과: 골짜기 바닥으로 내려가지 못하고 벽을 왔다갔다함

간단한 이차 함수:

$L(x, y) = 100 \cdot x^2 + y^2$

기울기:

$\nabla L = [200 \cdot x, 2 \cdot y]$

시작점: (1, 1)

학습률: $\alpha = 0.01$

SGD 진행:

Iteration 0: (1, 1)

$\nabla L = [200, 2]$

이동 = [-2, -0.02]

Iteration 1: (-1, 0.98)

$\nabla L = [-200, 1.96]$

이동 = [2, -0.0196]

Iteration 2: (1, 0.96)

계속 x 좌표가 -1, 1, -1, ... 반복

y는 천천히 0으로 수렴

결론:

- x 축: 지그재그 (비효율)
- y 축: 느린 수렴
- 전체: 매우 느린 수렴 (수백 이터레이션 필요)

NNNN d

모멘텀 없는 SGD:

$\theta(t+1) = \theta(t) - \alpha \cdot \nabla L(\theta(t))$

모멘텀이 있는 SGD:

$v(t) = m \cdot v(t-1) + \nabla L(\theta(t))$ -- "속도" 벡터 누적

$\theta(t+1) = \theta(t) - \alpha \cdot v(t)$ -- 누적 속도로 이동

또는:

$v(t) = m \cdot v(t-1) + (1-m) \cdot \nabla L(\theta(t))$ -- 정규화 버전

평균 G % %/ 0
결G / 850데
몇e/ /100
G

d

모멘텀 없음:

매 순간 기울기 방향으로만 이동

↓ (기울기에 좌우됨)

↓

↓ (벽을 따라 튀어나감)

↗ ↘ ↗ ↘ (지그재그)

모멘텀 있음:

- 이전 이동의 관성을 유지
 - ↓ (기울기 + 관성)
 - ↓ (수직 성분은 상쇄)
 - ↓ (수평 성분은 누적)
- → → → (일정 방향으로 수렴)

공학적 유추:

- 기울기 = 순간 힘
- 모멘텀 = 질량 × 속도 (뉴턴의 제2법칙)

공은 벽에 부딪혀도 이전 속도 때문에 계속 진행
지그재그 운동이 상쇄됨

위의 이차 함수 예제를 모멘텀으로:

$$L(x, y) = 100 \cdot x^2 + y^2$$

모멘텀 계수 $m = 0.9$

Iteration 0: $(1, 1)$, $v = (0, 0)$

$$\begin{aligned} \nabla L &= [200, 2] \\ v(1) &= 0.9 \cdot [0, 0] + [200, 2] = [200, 2] \\ \theta(1) &= (1, 1) - 0.01 \cdot [200, 2] = (-1, 0.98) \end{aligned}$$

Iteration 1: $(-1, 0.98)$, $v = [200, 2]$

$$\begin{aligned} \nabla L &= [-200, 1.96] \\ v(2) &= 0.9 \cdot [200, 2] + [-200, 1.96] = [180 - 200, 1.8 + 1.96] = [-20, 3.76] \\ \theta(2) &= (-1, 0.98) - 0.01 \cdot [-20, 3.76] = (-0.8, 0.94) \end{aligned}$$

Iteration 2: $(-0.8, 0.94)$, $v = [-20, 3.76]$

$$\begin{aligned} \nabla L &= [-160, 1.88] \\ v(3) &= 0.9 \cdot [-20, 3.76] + [-160, 1.88] = [-18 - 160, 3.384 + 1.88] = [-178, 5.264] \\ \theta(3) &= (-0.8, 0.94) - 0.01 \cdot [-178, 5.264] = (-0.62, 0.89) \end{aligned}$$

관찰:

- SGD 없음: x 는 $\pm 1, \pm 1, \dots$ 진동
- 모멘텀 있음: x 는 $1 \rightarrow -1 \rightarrow -0.8 \rightarrow -0.62 \rightarrow \dots$ (수렴하는 방향)

결과: 모멘텀으로 수렴 속도 약 5~10배 향상

기초 개념

5ms:

G

기본 모멘텀:

$$v(t) = m \cdot v(t-1) + \nabla L(\theta(t))$$

이동은 현재 위치의 기울기를 따름

Nesterov AGM:

$$v(t) = m \cdot v(t-1) + \nabla L(\theta(t) - \alpha \cdot m \cdot v(t-1))$$

이동은 "모멘텀이 취할 위치"의 기울기를 따름

장점: "앞서 보기(lookahead)" 효과

- 모멘텀으로 이동할 예상 위치에서 기울기 계산
- 과잉 이동(overshooting) 방지
- 수렴이 더 안정적

G

기본 모멘텀:

$$\begin{array}{l} \nearrow \quad \quad \quad \text{(현재)} \\ | \quad \searrow \quad \quad \text{(기울기)} \\ | \quad \quad \quad \text{(이동)} \\ \text{└───} \searrow \quad \quad \text{(새 위치)} \end{array}$$

NAG:

```

↗ (현재)
|   ↘ (예상 위치)
|   ↓ (그 위치의 기울기)
└─\___ (조정된 이동)

```

NING

<u>111111111111111111</u>		
f gam	C8d	
QaTNI 498	A8d	
a꺾~갸g0교	988d	

MNIST 학습:

SGD (모멘텀 없음):

- 100 epoch 후 오류율: 2.5%
- 수렴까지 소요 시간: 500 epoch

SGD + 기본 모멘텀 ($m=0.9$):

- 100 epoch 후 오류율: 1.2%
- 수렴까지 소요 시간: 100 epoch
- 5배 빠른 수렴

SGD + NAG ($m=0.99$):

- 100 epoch 후 오류율: 0.8%
- 수렴까지 소요 시간: 50 epoch
- 10배 빠른 수렴

CIFAR-10 학습:

모멘텀 없음: 300 epoch
기본 모멘텀: 60 epoch (5배 개선)
NAG: 40 epoch (7.5배 개선)

MNIST에서 모멘텀 계수 m 의 영향:

$m = 0.0$ (모멘텀 없음):

epoch 50 후: 3.0% 오류
epoch 200 후: 2.0% 오류

$m = 0.5$:

epoch 50 후: 1.5% 오류
epoch 200 후: 1.2% 오류

$m = 0.9$:

epoch 50 후: 1.2% 오류
epoch 200 후: 0.8% 오류

$m = 0.95$:

epoch 50 후: 1.1% 오류
epoch 200 후: 0.7% 오류

$m = 0.99$:

epoch 50 후: 1.0% 오류
epoch 200 후: 0.6% 오류

결론:

- $m = 0.9 \sim 0.99$ 가 대부분의 경우 최적
- m 이 높을수록 수렴이 빠르지만, 너무 높으면 불안정

m

더 현대적인 방법 Adam (적응적 학습률 + 모멘텀):

MNIST:
SGD + NAG: 50 epoch, 0.6% 오류
Adam: 60 epoch, 0.5% 오류 (약간 더 좋음)

CIFAR-10:
SGD + NAG: 40 epoch, 8% 오류
Adam: 50 epoch, 7% 오류 (약간 더 좋음)

결론:
- Adam이 약간 더 좋지만, 계산 복잡도가 높음
- 단순한 SGD + NAG도 충분히 우수함
- 하이퍼파라미터 조정이 더 간단

NNCS

구조적 과소적합과 구조적 과대적합

과소적합과 과대적합의 5 가지 증상:

기본 알고리즘:
 $s(t)$ = 현재 샘플 크기

쿼리 실행 후:
 $Q-error(t) = (\text{추정 카디널리티}) / (\text{실제 카디널리티})$

IF $Q-error(t) > \text{threshold}$:
 샘플을 늘려야 함
ELSE IF $Q-error(t) < \text{threshold}$:
 샘플을 줄여도 됨

G

예시: 추정이 계속 틀리는 경우

Query 1: 추정 100, 실제 1,000 → $Q-error = 0.1$ (과소 추정)
→ 샘플 2배 증가

Query 2: 추정 500, 실제 200 → $Q-error = 2.5$ (과대 추정)
→ 샘플 2배 감소

Query 3: 추정 50, 실제 300 → $Q-error = 0.17$ (과소 추정)
→ 샘플 2배 증가

결과: 샘플 크기가 계속 진동 (불안정)

G

Exquator의 수식:
 $\Delta s(t) = s(t+1) - s(t)$ (이전 변화)

$s(t+1) = s(t) + m \cdot \Delta s(t) + (1-m) \cdot \alpha \cdot \text{feedback}(Q-error)$

여기서:
 $m = 0.9$ (모멘텀 계수)
 $\alpha = 0.99$ 의 감쇠로 학습률 조절
 $\text{feedback}()$ = $Q-error$ 기반 신호

Gk 40과 비교

3

Query 1: $Q-error = 0.1 \rightarrow \text{feedback} = +50$ (샘플 증가 신호)
 $s(1) = 100 + 0.9 \cdot 0 + 0.1 \cdot 50 = 105$

Query 2: $Q-error = 2.5 \rightarrow \text{feedback} = -30$ (샘플 감소 신호)
 $s(2) = 105 + 0.9 \cdot 5 + 0.1 \cdot (-30)$
 $= 105 + 4.5 - 3 = 106.5$

Query 3: Q-error = 0.17 → feedback = +40

$$\begin{aligned} s(3) &= 106.5 + 0.9 * 1.5 + 0.1 * 40 \\ &= 106.5 + 1.35 + 4 = 111.85 \end{aligned}$$

관찰:

- 아래 위를 진동하지만 (Q-error 변화)
- 전체 추세는 안정적으로 증가
- 모멘텀이 급격한 변동을 평활화(smoothing)

공통점과

G

딥러닝의 세팅:

VL(손실함수 기울기) = 노이즈가 큼 (확률적 그래디언트)

카디널리티 추정의 세팅:

feedback(Q-error) = 노이즈가 큼 (쿼리마다 다른 선택도)

공통점:

- 변동성이 큼
- 모멘텀으로 변동을 평활화하면 안정적 수렴

G

정적 쿼리(항상 같은 선택도):

모멘텀 없음: 20 쿼리 후 수렴

모멘텀 있음: 10 쿼리 후 수렴 (2배)

변동성이 큰 쿼리(선택도 크게 변함):

모멘텀 없음: 50 쿼리 후도 불안정

모멘텀 있음: 20 쿼리 후 수렴 (안정성 향상)

NNZ 다섯번

공통점과

G

class AdaptiveSampler:

def __init__(self, initial_sample_size=1000, m=0.9):

self.sample_size = initial_sample_size

self.previous_delta = 0 # 이전 변화

self.m = m # 모멘텀 계수

self.alpha = 0.99 # 학습률 감쇠

self.learning_rate = 1.0

def adjust(self, q_error):

"""

q_error: 추정 카디널리티 / 실제 카디널리티

"""

학습률 감쇠

self.learning_rate *= self.alpha

오류 신호 (로그 스케일)

if q_error > 1.5: # 과대 추정

feedback = -self.learning_rate

elif q_error < 0.7: # 과소 추정

feedback = +self.learning_rate

else:

feedback = 0 # 충분히 정확

모멘텀 기반 조정

new_delta = (self.m * self.previous_delta +
(1 - self.m) * feedback)

self.sample_size += new_delta

self.sample_size = max(100, self.sample_size) # 최소 크기

self.sample_size = min(10000, self.sample_size) # 최대 크기

self.previous_delta = new_delta

```
return int(self.sample_size)
```

G

초기 샘플 크기: 1,000

Query 1: 추정 5,000 vs 실제 50,000 → Q-error = 0.1

feedback = +0.99

$\text{delta} = 0.9 * 0 + 0.1 * 0.99 = 0.099$

$\text{new_sample} = 1,000 + 0.099 = 1,000.099 \rightarrow 1,000$ (변화 미미)

Query 2: 추정 8,000 vs 실제 50,000 → Q-error = 0.16

feedback = +0.98 (감쇠됨)

$\text{delta} = 0.9 * 0.099 + 0.1 * 0.98 = 0.0891 + 0.098 = 0.1871$

$\text{new_sample} = 1,000 + 0.1871 = 1,000.1871 \rightarrow 1,000$

... (여러 쿼리 반복)

Query 50: Q-error가 여전히 0.1 근처

delta가 누적되어 → 1,200으로 증가

Query 100:

모멘텀 효과로 점진적으로 표본 크기 증가

Q-error가 개선되기 시작

95

결 J 85F 너85F

G

G

G 너

GaR/ 0

G

G

G8589, 너FF,

GaR / 0

공고려마 결J85 5

: 5

3

G

/

0

/

0

L

5

=5

공고려마 J 85F

G

G

/

0

G

3

5

MG

% % G
G
G % %/ 3 0
3 5

NG

공공기관
STH
G , 3 ,
G , 3 ,

OG

G
/
0
/ f m 과 과 Na ~ 결
/
0
5