

[35] K-nearest neighbor

저자: L. E. Peterson 학술지: Scholarpedia, vol. 4, no. 2, p. 1883, 2009 주제: KNN 알고리즘의 기본 개념과 이론

요약

본 논문은 Scholarpedia에 발표된 K-nearest neighbor(KNN) 알고리즘에 대한 종합 개요 논문이다. KNN은 기계 학습에서 가장 단순하면서도 강력한 비모수 분류 및 회귀 알고리즘 중 하나로, 주어진 쿼리 포인트로부터 가장 가까운 K개의 학습 샘플을 기반으로 예측을 수행한다.

논문에서는 KNN의 기본 원리, 거리 측정 방식, 최적 K값 선택 방법, 그리고 계산 효율성 개선 방안을 다룬다. 특히 유클리드 거리, 맨해튼 거리 등 다양한 거리 메트릭과 그들의 특성을 설명한다. 또한 KNN의 장점으로 구현의 단순성, 비모수 성질, 그리고 다양한 문제에 대한 적응성을 강조한다.

본 논문과의 관계: Exqutor 시스템은 벡터 기반의 유사도 검색을 위해 KNN 개념을 확장한다. 본 논문은 KNN의 기본적인 이론적 배경을 제공하며, Exqutor가 구현하는 필터링 기반 근접 이웃 검색의 근본이 되는 개념이다.

상세분석

35.1 KNN 알고리즘의 기본 원리

K-nearest neighbor는 지도학습의 기본적인 인스턴스 기반 학습(instance-based learning) 방법이다. 알고리즘의 핵심은 주어진 쿼리 포인트 q 에 대해 학습 데이터셋에서 거리 기준으로 가장 유사한 K개의 샘플을 찾아 이들의 레이블을 기반으로 q 의 클래스를 결정하는 것이다.

- **분류(Classification):** 다수의 클래스 중 가장 빈번하게 나타나는 클래스로 예측
- **회귀(Regression):** K개 이웃의 값의 평균 또는 가중 평균으로 예측
- **거리 기반 의존성:** 알고리즘의 정확성은 거리 메트릭 선택에 크게 좌우됨

35.2 거리 메트릭과 특성

논문에서 다루는 주요 거리 측정 방식들:

유클리드 거리(Euclidean Distance) - 가장 널리 사용되는 거리 메트릭 - $d(x, y) = \sqrt{(\sum (x_i - y_i)^2)}$ - 저차원 데이터에서 좋은 성능

맨해튼 거리(Manhattan Distance) - $d(x, y) = \sum |x_i - y_i|$ - 고차원 데이터에서 유클리드보다 성능이 좋을 수 있음

민코프스키 거리(Minkowski Distance) - 일반화된 거리 메트릭으로 p값에 따라 다양한 거리 정의 가능 - p=1일 때 맨해튼, p=2일 때 유클리드

35.3 최적 K값 선택

K값은 모델의 성능을 크게 영향을 미치는 중요한 하이퍼파라미터다:

- **작은 K:** 낮은 편향이지만 높은 분산. 노이즈에 민감
- **큰 K:** 높은 편향이지만 낮은 분산. 클래스 불균형 문제
- **최적화 방법:** 교차 검증(cross-validation)을 통한 K 선택

35.4 계산 효율성과 확장성

원본 KNN은 모든 학습 데이터와의 거리를 계산해야 하므로 $O(nd)$ 시간 복잡도를 가진다. 고차원 또는 대규모 데이터에서는 계산 비용이 매우 크다.

- **공간 분할 방법:** KD-트리, R-트리 등의 인덱스 구조 사용
- **근사 기법:** 정확한 K-NN 대신 근사 근접 이웃 검색(ANN) 활용
- **차원 축소:** PCA 등으로 데이터 차원 감소

35.5 KNN의 장단점

장점: - 구현이 매우 단순명확 - 새로운 데이터에 빠르게 적응 가능 - 다양한 거리 메트릭으로 유연성 제공 - 비모수 방식으로 데이터 분포 가정 불필요

단점: - 높은 계산 복잡도 (특히 예측 시점) - 모든 학습 데이터를 메모리에 유지 필요 - 고차원 데이터에서 "차원의 저주" 문제 - K값 선택의 민감성

35.6 본 논문과의 관계

Exquor 시스템에서 구현하는 필터링 기반 벡터 검색은 KNN 개념의 확장이다:

- **기본 개념:** 벡터 임베딩 공간에서 K개의 근접 이웃을 검색
- **거리 메트릭:** 코사인 유사도, 유클리드 거리 등을 활용
- **효율성 개선:** HNSW와 같은 근사 기법으로 $O(\log n)$ 복잡도로 감소
- **필터링 추가:** 속성 기반 필터링을 통해 조건부 KNN 검색 수행

추가 제기 문제

1. **고차원 벡터 공간에서의 거리 메트릭 선택**: 현대의 임베딩 모델(예: BERT, GPT)에서 생성되는 고차원 벡터들에 대해 어떤 거리 메트릭이 가장 적절한가?
2. **필터 조건과 K-NN의 상호작용**: 속성 기반 필터를 적용할 때 정확한 K개의 결과를 보장하기 위한 최적 전략은 무엇인가?
3. **동적 K값 조정**: Exquator가 동적으로 K값을 조정하여 필터링된 결과의 질을 개선할 수 있을까?
4. **거리 계산의 정규화**: 벡터 정규화가 필터링 성능에 미치는 영향에 대한 실증적 분석이 필요하다.