

와[의석통 세 본통 합백 확분y기분s 석 한합재s확합 특

A: : H v l b_ p n t t h n 고는 고를 말 x 고를 고나 5 t pa6s 5 t pa6s
7 t pa6f 7 t pa6f
7
t pa6s 달 t pa6f N
t pa6f N
1 2
t pa6s N
1 5 5 2
t pa6s LL N
1b l Wp5 2
5
1 대를 변용
N
5
c 동태 달 t pa6s 5
7

[[R 분류와 분류기본

?? t pa 6f

설계 목표:

- SQL 쿼리 성능 비교의 표준화
- 상대적으로 단순하고 이해하기 쉬운 구조
- 재현 가능한 실험 환경

현실과의 차이:

1. 단일 도메인: 항공 우주 부품 공급망
2. 균등 분포: 랜덤하게 생성된 데이터
3. 단순 스키마: 8개 테이블만 사용
4. 정적 워크로드: 고정된 22개 쿼리

?A

다양한 데이터 출처:

- POS(판매점) 데이터
- 온라인 주문 데이터
- 고객 관계 정보
- 재고 정보

- 마케팅 캠페인 데이터

비균등 분포:

- 인기 상품은 자주, 비인기 상품은 드물게 팔림
- 특정 시간(휴가)에 판매 집중
- 지역별 선호도 편차

복잡한 비즈니스 로직:

- 다중 채널 데이터 통합
- 반품, 교환 처리
- 프로모션 효과 분석

[[D 분류] 기본

A7

TPC-DS 테이블 구성 (99개 중 일부):

고객 관련:

- customer: 기본 고객 정보
- customer_address: 배송/청구 주소
- customer_demographics: 인구 통계

판매 채널:

- store: 오프라인 매장 정보
- web_site: 온라인 판매 채널
- catalog_page: 카탈로그 페이지

거래 데이터:

- store_sales: 매장 판매
- web_sales: 온라인 판매
- catalog_sales: 카탈로그 판매

상품 관련:

- item: 상품 기본 정보
- inventory: 재고
- promotion: 프로모션

총 99개 테이블 vs TPC-H의 8개

A7

Zipf 분포 (현실의 히트상품 패턴):

- 소수의 상품이 대부분 판매
- 다수의 상품이 거의 팔리지 않음
- 키워드 검색처럼 장꼬리 분포

계절성 데이터:

- 특정 시즌(크리스마스, 여름) 판매 급증
- 요일별 패턴 (주말 증가)
- 휴일 효과

지역별 편차:

- 도시 vs 시골 지역의 선호도 차이
- 문화권별 상품 선호도
- 배송비 등의 지역별 차별화

[[T 분류] 기본 dd

B7

Type A: 단순 쿼리 (약 30개)

- 1-2개 테이블, 간단한 WHERE 절
- 기본 집계 함수

Type B: 중간 복잡도 (약 50개)

- 3-5개 테이블 조인
- 복합 필터링
- 윈도우 함수

- Type C: 고복잡도 (약 19개)
- 6개 이상 테이블 조인
 - 자체 조인(self-join) 포함
 - 상관 서브쿼리
 - CTE(Common Table Expression) 사용

B7A

- 시계열 분석:
- Q11: 작년 대비 올해 고객 성장률
- 연도별 비교
 - CASE문과 윈도우 함수

- 마켓 바스켓 분석:
- Q33: 함께 구매되는 상품 조합
- 자체 조인으로 같은 고객의 구매 패턴
 - 상관관계 분석

- 고객 분할:
- Q48: 구매 패턴별 고객 세분화
- 다중 조인
 - 복합 그룹화

- 상품 추천:
- Q20: 자주 함께 팔리는 상품
- 판매 데이터의 연관성 분석

B7B

- 비즈니스 질문과의 직결:
- "이번 분기 판매 추이는?"
 - "어떤 제품이 인기인가?"
 - "고객 만족도는?"
 - "마케팅 효과는?"

이 질문들이 TPC-DS 쿼리에 반영됨

[[DW분류와 분류도분

C7

평균 실행 시간 (1TB 데이터):

- TPC-H:
- Q1: 1초
 - Q5: 5초
 - Q17: 30초
 - 평균: 10초

- TPC-DS:
- Q11: 15초 (자체 조인)
 - Q33: 45초 (복잡한 마켓 바스켓)
 - Q48: 90초 (3중 조인 + 서브쿼리)
 - 평균: 40초

→ 4배 더 복잡한 워크로드

C7A

- TPC-H:
- 인덱싱으로 큰 성능 향상
 - 조인 순서 최적화 중요
 - 기존 DBMS 최적화로 충분

- TPC-DS:
- 인덱싱 효과 제한적 (많은 조인으로 인해)
 - 쿼리 재작성(rewrite) 필요
 - 통계 기반 카디널리티 추정의 한계 드러남

[[DW

D7 tpads

- 현재 TPC-DS:
- 수치, 날짜, 범주형 데이터만
 - 텍스트 검색은 정확히 매칭

- 현실의 데이터 웨어하우스:
- 고객 리뷰 (자유 텍스트)
 - 상품 설명 (텍스트)
 - 피드백 코멘트 (텍스트)
 - 이미지 (비정형 데이터)

- 벡터 검색 추가의 필요성:
- "긍정적인 피드백을 남긴 고객"
 - "특정 스타일의 옷을 찾는 고객"
 - "유사한 리뷰를 남긴 다른 고객"

D7A

전통적 TPC-DS Q33 (마켓 바스켓):

```
SELECT product1, product2, COUNT(*)
FROM store_sales s1
JOIN store_sales s2
  ON s1.customer_id = s2.customer_id
WHERE s1.item_id < s2.item_id
GROUP BY product1, product2
```

확장된 버전 (벡터 검색 추가):

```
SELECT product1, product2, COUNT(*)
FROM store_sales s1
JOIN store_sales s2
  ON s1.customer_id = s2.customer_id
WHERE s1.item_id < s2.item_id
  AND item_description_embedding SIMILAR_TO
      (SELECT description_embedding FROM item WHERE id = ?)
GROUP BY product1, product2
```

의미: 특정 스타일의 상품을 자주 함께 구매하는 고객 찾기

[[Q

E7 tpads

- 정적 데이터:
- 한 번 생성 후 수정 없음
 - 실제 데이터는 지속적 변화

- 고정 쿼리:
- 99개 쿼리는 모든 분석 패턴을 다 커버하지 못함
 - 특히 텍스트, 이미지 검색은 완전히 빠짐

- 단일 도메인:
- 소매점만 다룸
 - 금융, 의료, 전자상거래 등의 특수성 없음

E7A

- 다양한 데이터 타입 통합:
- 구조화(수치) + 반구조화(텍스트) + 비정형(이미지)

- 현실적 분석 쿼리:
- 단순 WHERE 필터 뿐 아니라
 - 의미론적 유사도 기반 필터링

- 성능 이슈의 다양성:
- 전통적 쿼리 최적화 이슈
 - 벡터 인덱싱의 효율성
 - 혼합 조인 순서 최적화

[[Q

c동태달 tpa6s N
Nt pa6f tpa6s
NLL
N 5 5
Nt pa6f
N
tpa6s

?7		Ntpa6s	?t_ 달?	: t_					U
	U								
A7		Ntpa6s				10대 이상은 군을 나가는 군 때 많은 걸 군 때 많이 받		2	5
		U		U					
B7		N							U
	1구분과	U							
C7		Ntpa6s				5			
		U							
D7LL		Ntpa6s	LL						U
	U								
E7		Ntpa6s		5				U	
									U
H7		N		1apu5to	5	2		U	
		U							