



- 가장 편향 없는 방법

## 2. 계층 표본 추출(Stratified Sampling)

- 모집단을 층(strata)으로 나누고 각 층에서 표본 추출
- 예: 크기별 벡터 클러스터에서 각각 추출

## 3. 군집 표본 추출(Cluster Sampling)

- 모집단을 군집으로 나누고 일부 군집 전체 선택
- 예: 벡터 공간의 일부 지역만 선택

비확률 표본 추출:

- 편의 표본 추출(Convenience Sampling)
- 의도 표본 추출(Purposive Sampling)
- 편향 가능성 높음 (벤치마킹에는 부적절)

## 74

표본이 작을 때:

- 표본 평균의 변동성 큼
- 신뢰 구간 넓음
- 통계적 검정력 낮음

표본이 클 때:

- 표본 평균이 모집단 평균에 가까움
- 신뢰 구간 좁음
- 통계적 검정력 높음
- 하지만 계산 비용 증가

## 1 m[e

## 84

신뢰 구간 기반:

$$n = (Z * \sigma / E)^2$$

여기서:

- Z: 표준정규분포의 임계값
  - \* 95% 신뢰도 → Z = 1.96
  - \* 99% 신뢰도 → Z = 2.576
  - \* 90% 신뢰도 → Z = 1.645
- $\sigma$ : 모집단의 표준편차
  - \* 사전에 알려지지 않으면 예비 표본에서 추정
- E: 허용 오차 한계
  - \* 평균값의  $\pm$ 몇 %까지 허용할 것인가
  - \* 예: 평균 레이턴시의  $\pm 10ms$

## 84 E

상황:

- 벡터 검색 시스템의 쿼리 레이턴시 측정
- 목표: 모집단 평균 레이턴시를  $\pm 5ms$  오차 범위로 추정 (95% 신뢰도)
- 예비 조사: 표준편차  $\sigma = 20ms$

계산:

$$\begin{aligned} n &= (1.96 * 20 / 5)^2 \\ &= (7.84)^2 \\ &= 61.5 \\ &\approx 62\text{개 쿼리} \end{aligned}$$

해석:

- 최소 62개의 쿼리를 실행해야 함
- 이로써 95% 신뢰도로 평균 레이턴시를  $\pm 5ms$  범위로 추정 가능

## 84 .q n = 1 / (p \* (1-p))

$$n = (Z / E)^2 * p * (1-p)$$

- p: 예상 비율 (예: recall rate)
- (1-p): 그 반대 비율
- p \* (1-p): 최대값 0.25 (p=0.5일 때)

예: 벡터 검색 정확도(recall@100)  
- 목표: 정확도를 ±5% 오차 범위로 추정 (95% 신뢰도)  
- 예상 recall: 90%

$$n = (1.96 / 0.05)^2 * 0.9 * 0.1$$
$$= (39.2)^2 * 0.09$$
$$= 138$$

→ 최소 138개 쿼리 필요

I mfg 결

947

C 단변량

E

문제 정의:  
- 1억 개의 벡터 검색 성능 평가  
- 모든 벡터에 대해 처리하면 시간이 매우 오래 걸림  
- 대표성 있는 표본의 크기는?

- 적용:
1. 목표 정확도: 평균 레이턴시 ±10% (95% 신뢰도)
  2. 예비 조사: 1000개 벡터로 미리 테스트
    - 평균 레이턴시: 50ms
    - 표준편차: 8ms
    - 변동계수(CV):  $8/50 = 16\%$
  3. 표본 크기 계산:
    - 오차 한계:  $50ms * 10\% = 5ms$
    - $n = (1.96 * 8 / 5)^2 = 9.83^2 \approx 97개$
  4. 결론: 최소 100개의 벡터 쿼리가 표본으로 충분

948

계층 표본 추출 적용:  
- 데이터: 1억 개 벡터  
- 클러스터: 차원도별로 분류  
- 각 클러스터에서 비례적으로 표본 추출

이점:  
- 다양한 벡터 특성 반영  
- 편향 감소  
- 표본 크기 최적화 가능

I mfh

: 47

귀무가설(H0): 두 시스템의 성능이 같다  
대립가설(H1): 두 시스템의 성능이 다르다

예: 시스템 A vs 시스템 B의 레이턴시 비교

표본 크기와 검정력(Power):  
- 작은 표본: 실제로 다른데 같다고 결론낼 수 있음 (제2종 오류)  
- 적절한 표본: 실제 차이를 감지할 확률 높음

필요한 표본 크기 = 신뢰도 + 검정력 함수  
- 신뢰도:  $\alpha = 0.05$  (95%)  
- 검정력:  $\beta = 0.80$  (80% 확률로 차이 감지)

: 48 .C 규격능 규격

Exqutor의 경우:  
- 시스템 A 레이턴시: 50ms  
- 시스템 B 레이턴시: 55ms  
- 실제 차이: 5ms

이것이 통계적으로 유의미한가?

- 표본이 작으면: 우연의 변동으로 보일 수 있음
- 적절한 표본 크기로: 실제 차이인지 판단 가능

필요 표본 크기는 예상 차이의 크기에 반비례:

- 차이가 크면: 적은 표본으로 충분
- 차이가 작으면: 큰 표본 필요

## I m[

?4 3

추가 표본의 비용:

- 계산 비용: 각 쿼리마다 계산 필요
- 시간: 모든 쿼리 실행 완료까지 기다려야 함
- 저장소: 결과 저장 필요

추가 표본의 이득:

- 신뢰도 증가
- 오차 한계 감소
- 더 정확한 결론

최적 지점: 신뢰도와 비용의 균형

?48

Exqutor 논문의 현실:

- 서로 다른 시스템들과 설정 비교
- 벡터 검색 시스템 평가는 시간이 오래 걸림

해결책:

- 초기 표본 크기: 충분히 신뢰할 수 있는 최소 크기
- 1억 벡터에서 수만~수십만 벡터 표본 사용
- 통계적으로 유의미한 결론 도출 가능

?49

Exqutor의 여러 실험:

- 다양한 벡터 데이터셋 (SIFT, YFCC, 텍스트)
- 다양한 인덱싱 방법
- 다양한 메모리 제약

각 설정마다 표본 크기를 독립적으로 결정하거나,  
보수적으로 모든 설정에 대해 동일하게 큰 표본 사용 가능

## I m[

A4

좋은 표본 크기:

- 통계적으로는 중요
- 하지만 충분조건은 아님

도 고려해야 할 점:

1. 표본의 대표성: 크기만 크다고 대표성이 있는가?
2. 표본 추출 방법: 무작위 추출이 가능한가?
3. 측정 오차: 도구(벤치마크)의 신뢰성
4. 외부 효과: 다른 변수의 영향 (시스템 부하 등)

A48

벡터 검색 벤치마킹 사례:

- 특정 차원도의 벡터만 사용 (편향)
- 특정 데이터 분포만 사용 (편향)
- 최적화된 하드웨어에서만 테스트 (편향)

결과: 통계적으로 정확하지만 현실성이 떨어질 수 있음

## I m[m

c 단본 분

E

