

결기판개: 8: A0
 VS 3
 VS / f 결기판개: 3
 G
 교과목명/kimG
 교과목명
 과목명 /교과목명 0
 결기판개
 결기판개
 결기판개
 결기판개
 3 / 3 3 0
 5
 GW교과
 3
 5

- ↳ **가비판** G
- 모든 시스템이 동등한 조건에서 테스트:
 - ↳ 데이터 동일
 - ↳ 쿼리 동일
 - ↳ 메모리 제약 동일
 - ↳ 하드웨어 동일
 - ↳ 충분한 워밍업(warm-up) 시간 제공

[illegible]

T.고급개강기열기열개관	9f	A8FC	
--------------	----	------	--

G

G

6

G

/구거전교별 3건 → 구관별 3건 → 구관교대별 0

G

/9f 0

/9850

dbQ

?59 | 개만개만 0

$$\text{Recall@k} = |\text{실제 top-k n 반환된 top-k}| / k$$

예: 실제 top-10은 [1,2,3,4,5,6,7,8,9,10]

반환된 top-10은 [1,2,3,4,5,11,12,13,14,15]

$$\text{Recall@10} = 5/10 = 50\%$$

5 km/h 구배와 1 기압에서 끓는점

QPS = 총 쿼리 수 / 측정 시간(초)

측정 조건:

- 단일 쓰레드 QPS (기준선)
- 멀티 쓰레드 QPS (병렬성 측정)
- 부하 곡선 (동시 클라이언트 증가에 따른 QPS 변화)

5. $e^- \rightarrow \mu^- + \nu_e + \bar{\nu}_\mu$ 0

p50_latency: 중앙값 응답 시간

p95_latency: 상위 5% 응답 시간 (꼬리 지연)

p99_latency: 상위 1% 응답 시간

시스템 품질 판단:

- p50: 일반적 성능
- p95/p99: 안정성 (SLA 확보)

? 5A n검과무선검과무선e→교체하기

높은 QPS = 낮은 latency? (반드시 아님)

↳ 배치 처리로 높은 처리량 얻을 수 있으나 개별 지연 증가

?B

인덱싱 메모리: 구축 중 최대 메모리

서빙 메모리: 쿼리 처리 중 메모리 (인덱스 + 버퍼)

메모리 효율: QPS / GB (단위 메모리당 처리량)

dbCa

G

A59

```
query = {
  "vector": [0.1, 0.2, ..., 0.5], # d-차원 벡터
  "top_k": 10,
  "metric": "cosine" # or "l2", "inner_product"
}
```

A5 2

```
query = {
    "vector": [0.1, 0.2, ..., 0.5],
    "top_k": 10,
    "filter": {
        "price": {"$lt": 100},
        "category": "electronics"
    }
}
```

A5

```
query = {
  "filter": {
    "date": {"$gte": "2024-01-01"},
    "status": "active"
  }
}
```

```
}  
}  
# 벡터 검색 없이 필터링만
```

A5A

```
query = {  
    "vector_search": {...},  
    "keyword_search": {...},  
    "combine": "linear_combination" # 가중 조합  
}
```

db00

9G

데이터셋 다운로드 / 생성
벡터 DB 인스턴스 시작 (컨테이너 기반)
메모리, CPU 할당 확인

: G

벡터들을 DB에 로드
다양한 인덱싱 파라미터로 여러 설정 시도
└─ HNSW M=16, ef=200
└─ HNSW M=8, ef=100
└─ IVF nlist=1000, nprobe=10
└─ ...

?G

100회 쿼리 실행 (캐시 워밍)
메모리 할당 안정화
스케줄러 스트레스 해제

AG

10,000~100,000개 쿼리 실행
각 쿼리의 latency, recall 기록

BG

QPS, p50/p95/p99 latency 계산
Recall vs Latency 곡선 그리기
메모리 효율 계산

db00

G

System: Milvus 2.3
Dataset: SIFT-1M
Metric: L2

Configuration: index_type=HNSW, M=16, ef_construction=200, ef_search=10

Result:

QPS: 1,200 req/s
Latency (p50): 0.8 ms
Latency (p95): 2.5 ms
Latency (p99): 5.0 ms
Recall@10: 98.5%
Memory: 850 MB
Memory efficiency: 1.41 QPS/MB

G

ki m /9: 880G
곡 F 건과개간 /B결관GmeR
과관+관 /FE3, 0G
/95A90G

db00

G

필터 선택도 10% (10,000개 벡터만 매칭):
QPS: 1,800 req/s (필터만으로 90% 제거)
Recall@10: 95%

필터 선택도 50% (500,000개 벡터 매칭):
QPS: 950 req/s
Recall@10: 95%

필터 선택도 100% (모든 벡터 매칭):
QPS: 800 req/s
Recall@10: 95%

G
kim / 0
/ 6 0

db

필터 선택도 10% (10,000개 벡터만 매칭):
QPS: 1,800 req/s (필터만으로 90% 제거)
Recall@10: 95%

필터 선택도 50% (500,000개 벡터 매칭):
QPS: 950 req/s
Recall@10: 95%

필터 선택도 100% (모든 벡터 매칭):
QPS: 800 req/s
Recall@10: 95%

95 G kim
G kim
G kim
G/ kim4 kim06 kim
: 5 G
~ 스 스
~ 스 스
?5 G
~
필터 선택도 10% (10,000개 벡터만 매칭):
QPS: 1,800 req/s (필터만으로 90% 제거)
Recall@10: 95%

~

95 G VS P
: 5 G P
?5 G P
A5 G P
B5 G P
C5 G VS P