

[79] Random Sampling Over Joins Revisited

요약

Zhao et al.의 SIGMOD 2018 논문으로, 조인 크기(join cardinality) 추정을 위한 현대적 무작위 샘플링(random sampling) 기법을 재검토한다. 이전 연구들(1990년대)이 샘플링의 이론적 기초를 제시했다면, 본 논문은 현대 데이터베이스 환경에서 샘플링의 실용성과 한계를 재평가한다.

핵심 기여: 1. **현대적 재평가**: 데이터 크기 증가, 분석 쿼리의 특성 변화에 따른 샘플링 효과 분석 2. **적응적 샘플링**: 쿼리 특성에 따라 샘플 크기와 방법을 동적으로 조정 3. **하이브리드 접근**: 샘플링과 다른 추정 기법의 조합

논문은 무작위 샘플링이 여전히 유용하지만, 극단적 선택도(매우 높거나 낮음)에서는 신뢰도가 떨어진다는 점을 보인다. 또한 샘플 수와 정확도의 관계를 정량화하여 실무에서의 샘플 크기 결정에 가이드를 제공한다.

본 논문과의 관계: Exqutor의 적응적 샘플링(Adaptive Sampling) 방식의 이론적 토대를 제공한다. 특히 범위 필터와 벡터 검색의 결합 선택도를 추정할 때, 샘플링이 얼마나 신뢰도 있는지를 평가할 수 있게 해준다. Exqutor는 이 논문의 방법론을 기반으로 적응적 샘플 크기 결정 메커니즘을 구현할 수 있다.

상세분석

79.1 샘플링의 기본 원리

무작위 샘플링 기반 선택도 추정:

데이터 집합 S : N 개 행
샘플 집합 T : n 개 행 (S 에서 무작위로 선택)

쿼리 술어 P 에 대해:
 s = P 를 만족하는 S 의 행 수
 t = P 를 만족하는 T 의 행 수

추정: $s_{est} = s \times (N / n)$
오류: 표준편차 $\sigma = \sqrt{s(N-s) / n}$

신뢰도 구간(Confidence Interval):

95% 신뢰도:

$[s_est - 1.96\sigma, s_est + 1.96\sigma]$

예시:

$s_est = 1000$ (추정 선택도 1%)

$\sigma = 100$

신뢰도 구간: $[800, 1200]$ ($\pm 20\%$ 오류)

79.2 조인 선택도 추정의 특수성

단순 술어 vs 조인 술어:

단순 술어: `SELECT * FROM T WHERE age > 20`

적용: 단일 테이블에 대한 샘플링

조인 술어: `SELECT * FROM T1 JOIN T2 ON T1.id = T2.id WHERE age > 20`

적용: 두 테이블의 샘플을 조인 후 필터

문제: 조인이 샘플링 정확도에 미치는 영향

조인에서의 샘플링 방법:

방법 1: 사전 샘플링(Pre-join Sampling)

T1에서 샘플 추출 → T2에서 샘플 추출 → 샘플들끼리 조인

장점: 빠름 (샘플 크기만큼만 조인)

단점: 두 샘플이 정렬되지 않음 (실제 조인 파트너 놓칠 수 있음)

정확도 손실: 높음 (특히 조인 선택도가 낮을 때)

방법 2: 사후 샘플링(Post-join Sampling)

T1과 T2 전체 조인 → 결과에서 샘플 추출

장점: 정확함 (실제 조인 결과에서 샘플)

단점: 느림 (전체 조인 필요)

정확도: 높음 (단순 쿼리와 동일)

방법 3: 스트리밍 샘플링(Streaming Sampling)

조인 중간에 점진적으로 샘플 수집
충분한 신뢰도 도달 시 종료 (조인 완료 전)

장점: 빠르고 정확할 수 있음
단점: 조인 비용 예측 어려움

79.3 샘플 크기 결정

표본 오류(Sampling Error) 공식:

조인 선택도 σ 에서 상대 오류 ϵ 를 원할 때:

필요한 샘플 크기:

$$n \geq (z^2 \times \sigma \times (1-\sigma)) / \epsilon^2$$

여기서 z = 신뢰도 계수 (95%일 때 $z \approx 1.96$)

예시:

$\sigma = 0.1$ (10% 선택도)

$\epsilon = 0.1$ ($\pm 10\%$ 오류 허용)

$z = 1.96$

$$n \geq (1.96^2 \times 0.1 \times 0.9) / 0.1^2$$

$$n \geq (3.84 \times 0.09) / 0.01$$

$$n \geq 34.56 \approx 35 \text{개 샘플}$$

다른 선택도:

$\sigma = 0.01$ (1% 선택도) $\rightarrow n \geq 354 \text{개}$

$\sigma = 0.001$ (0.1% 선택도) $\rightarrow n \geq 3,456 \text{개}$

$\sigma = 0.0001$ (0.01% 선택도) $\rightarrow n \geq 34,560 \text{개}$

선택도에 따른 샘플 크기 급증:

선택도가 1/10으로 감소하면, 필요 샘플 크기는 약 10배 증가
 $\rightarrow$ 매우 낮은 선택도는 샘플링으로 추정 불가능할 수 있음

79.4 현대 데이터에서의 실험 결과

실험 설정: - 데이터셋: TPC-H (1GB, 10GB), 실제 로그 분석 데이터 - 조인 조건: 다양한 선택도 (0.1% ~ 100%) -

샘플 크기: 1% ~ 100%

결과 (상대 오류):

선택도	샘플 1%	샘플 5%	샘플 10%	샘플 50%
50%	2%	1%	<1%	<1%
10%	8%	3%	2%	<1%
1%	30%	10%	5%	1%
0.1%	>100%	30%	15%	3%
0.01%	>100%	>100%	50%	10%

발견: - 선택도 1% 이상: 5% 샘플로 충분 (오류 < 10%) - 선택도 0.1%: 50% 샘플 필요 (오류 3%) - 선택도 0.01% 이하: 샘플링으로는 신뢰도 낮음

79.5 적응적 샘플링

동적 샘플 크기 조정:

```
def adaptive_sampling(query, initial_sample_rate=0.01):
    sample_rate = initial_sample_rate
    confidence = 0.0

    while confidence < 0.95: # 95% 신뢰도 목표
        # 1단계: 현재 샘플 크기로 추정
        sample = data.sample(frac=sample_rate)
        result = query.execute(sample)

        # 2단계: 신뢰도 평가
        confidence = compute_confidence(result)

        # 3단계: 신뢰도 부족 시 샘플 증가
        if confidence < 0.95:
            sample_rate = min(sample_rate * 2, 1.0)
        else:
            break

    return result
```

선택도 추정과의 피드백:

```
초기 샘플에서 추정된 선택도  $\sigma_{est}$ :
└  $\sigma_{est}$  기반으로 필요 샘플 크기 계산
  └ 추가 샘플 수집 여부 결정
    └ 목표 신뢰도 달성 시 종료
```

79.6 극한 선택도에서의 문제

매우 낮은 선택도 (< 0.01%):

조인 결과: $N1 \times N2$ 중 극소수만 매칭

예: $100M \times 100M = 10^{16}$ 행 중 1,000행만 결과
선택도 = 10^{-13}

이 경우:

- 1% 샘플: $10^8 \times 10^8 = 10^{16}$ 중 최대 몇 개 매칭?
- 기댓값 $1,000 / 10,000 = 0.1$ (극도로 불안정)

해결책:

1. 샘플 크기 대폭 증가 (비용 증가)
2. 샘플링 대신 다른 기법 사용 (통계, 모델 등)
3. 하이브리드: 샘플링 + 추적(tracing) 결합

79.7 본 논문과의 관계

Exqutor의 적응적 샘플링 전략:

Exqutor는 범위 필터와 벡터 검색의 선택도를 모두 고려해야 한다:

전체 쿼리 선택도:

$$\sigma_{total} = \sigma_{range} \times \sigma_{vector}$$

예:

$$\begin{aligned}\sigma_{range} &= 15\% \text{ (범위 필터)} \\ \sigma_{vector} &= 80\% \text{ (벡터 유사도 상위 k\%)} \\ \sigma_{total} &= 0.15 \times 0.80 = 12\%\end{aligned}$$

필요한 샘플 크기 ($\pm 10\%$ 오류):

$$\begin{aligned}n &\geq (1.96^2 \times 0.12 \times 0.88) / 0.1^2 \\ n &\geq 400 \text{ 개 (전체의 } \sim 0.04\% \text{)}\end{aligned}$$

Exqutor의 적응적 샘플링:

1단계: 초기 샘플 (1% 크기)로 선택도 추정
추정된 $\sigma = 12\% \rightarrow$ 필요 샘플 약 400개

2단계: 신뢰도 평가
현재 샘플: 10,000개 (1%)
신뢰도: 95% 이상 달성

3단계: 충분하면 추정 결과 사용
추가 샘플링 불필요

논문 [79]의 이론적 기초:

- 샘플 크기와 정확도의 수학적 관계 제공
- 선택도에 따른 샘플 크기 계산 방법 제시
- 적응적 샘플링의 정당성 입증
- 극한 케이스에서의 한계 지적

추가 제기 문제

1. **샘플 바이어스**: 데이터가 균등하지 않거나 클러스터링될 때, 무작위 샘플링이 정확한가?
2. **시간 비용 트레이드오프**: 샘플 수집과 쿼리 실행에 걸리는 총 시간을 최소화할 최적 샘플 크기는?
3. **스트리밍 데이터**: 지속적으로 새로운 데이터가 추가될 때, 샘플을 어떻게 유지할 것인가?
4. **다중 쿼리**: 여러 쿼리의 선택도를 동시에 추정할 때, 샘플을 공유할 수 있는가?
5. **벡터 유사도의 샘플 추정**: 벡터 검색은 top-k 결과의 "선택도"가 정의되기 어려운데, 이를 샘플링으로 추정할 수 있는가?
6. **상관성 처리**: 범위 필터 속성과 벡터 임베딩 사이의 숨은 상관성이 있을 때, 샘플링 정확도에 미치는 영향은?