

# [80] Selectivity and Cost Estimation for Joins Based on Random Sampling

## 요약

Haas, Naughton, Seshadri, Swami의 JCSS 1996 논문으로, 조인 선택도(join selectivity) 추정을 위한 무작위 샘플링의 이론적 기초를 제시한 '고전' 논문이다. 이 논문은 데이터베이스 통계와 표본론을 결합하여 샘플링 기반 추정의 수학적 모델을 정립했다.

핵심 기여: 1. **이론적 프레임워크**: 조인 크기 추정의 통계 모델 개발 2. **신뢰도 분석**: 샘플 크기와 추정 오류의 관계 공식화 3. **점근 분포(Asymptotic Distribution)**: 표본 크기가 클 때의 분포 특성 증명 4. **실용적 가이드**: 필요한 샘플 크기 결정 방법 제시

본 논문은 이후 30년 가까이 샘플링 기반 카디널리티 추정 연구의 이론적 기반이 되었다. 특히 신뢰도 구간 계산, 적응적 샘플링, 그리고 비용 모델에 광범위하게 인용된다.

본 논문과의 관계: Exqutor의 적응적 샘플링 방식의 직접적인 이론적 토대다. 특히 선택도 추정의 신뢰도를 정량화하고 필요한 샘플 크기를 결정하는 방법론을 제공한다. Exqutor는 범위 필터와 벡터 검색의 결합 선택도 추정에 이 논문의 통계 이론을 적용할 수 있다.

## 상세분석

### 80.1 조인 선택도의 수학적 정의

기본 정의:

테이블 T1:  $N_1$ 개 행

테이블 T2:  $N_2$ 개 행

조인 조건 P에 대해:

조인 결과 = T1과 T2의 행 중 P를 만족하는 쌍의 집합

조인 카디널리티:

$C = |\{(t1, t2) : t1 \in T1, t2 \in T2, P(t1, t2) = \text{true}\}|$

조인 선택도:

$\sigma = C / (N_1 \times N_2)$

예시:

T1: 고객 테이블 (10,000명)

T2: 주문 테이블 (100,000건)

조인 조건: `고객.id = 주문.고객_id`

조인 결과: 90,000건 (평균 고객당 9개 주문)

카디널리티:  $C = 90,000$

선택도:  $\sigma = 90,000 / (10,000 \times 100,000) = 0.009$  (0.9%)

## 80.2 샘플링 이론의 적용

표본 선택도의 분포:

T1에서  $n_1$ 개, T2에서  $n_2$ 개 행을 무작위로 샘플링할 때, 샘플 내 조인 결과를  $c$ 라 하면:

표본 선택도:  $\sigma_{\text{hat}} = c / (n_1 \times n_2)$

이 추정량의 분포:

Case 1: 선택도가 고정되어 있고  $n \rightarrow \infty$ 일 때

중심극한정리(Central Limit Theorem):

$\sqrt{n} \times (\sigma_{\text{hat}} - \sigma) \rightarrow N(0, \sigma(1-\sigma))$

분포:  $\sigma_{\text{hat}}$ 는 점근적으로 정규분포

평균:  $\sigma$

표준편차:  $\sqrt{\sigma(1-\sigma) / n}$

Confidence Interval (95% 신뢰도):

$$P(\sigma_{\text{hat}} - 1.96 \times \sigma_{\text{SE}} < \sigma < \sigma_{\text{hat}} + 1.96 \times \sigma_{\text{SE}}) = 0.95$$

$$\text{여기서 } \sigma_{\text{SE}} = \sqrt{(\sigma_{\text{hat}}(1-\sigma_{\text{hat}}) / n)}$$

정규 근사의 신뢰도를 높이려면  $n$ 이 충분해야 함:

$$n \times \sigma_{\text{hat}} > 5 \text{ and } n \times (1-\sigma_{\text{hat}}) > 5$$

## 80.3 조인에 특정한 이슈

독립성 가정:

조인 조건이 두 테이블의 행을 독립적으로 선택할 때:

$$\sigma(T1, T2) = \sigma(T1) \times \sigma(T2)$$

예:

T1에서 P\_1을 만족할 확률:  $\sigma_1 = 0.2$  (20%)

T2에서 P\_2를 만족할 확률:  $\sigma_2 = 0.5$  (50%)

조인 선택도:  $\sigma = 0.2 \times 0.5 = 0.1$  (10%)

(T1.A = T2.A인 등호 조인이 아닐 때 근사)

등호 조인(Equi-join)의 특수성:

T1.id = T2.id 형태의 조인

경우 1: 외래키 관계 있음

└ 모든 T2.id가 T1에 존재

$$\sigma = N_2 / (N_1 \times N_2) = 1 / N_1$$

(매우 낮은 선택도 가능)

경우 2: 일반적인 등호 조인

$$\sigma = m / (N_1 \times N_2)$$

$m$  = 두 테이블의 공통 키 개수

## 80.4 점근 성질(Asymptotic Properties)

큰  $n$ 에서의 행동:

샘플 크기  $n$ 이 클 때:

1. 일관성(Consistency):

$\sigma_{\text{hat}} \rightarrow \sigma$  (거의 확실하게)

샘플 크기가 증가하면 추정치가 참값으로 수렴

2. 정규 수렴(Normal Convergence):

$(\sigma_{\text{hat}} - \sigma) / \sqrt{\sigma(1-\sigma)/n} \rightarrow N(0, 1)$

정규분포로 수렴 속도:  $O(1/\sqrt{n})$

3. 효율성(Efficiency):

분산:  $\text{Var}(\sigma_{\text{hat}}) = \sigma(1-\sigma) / n$

가장 작은 분산을 가짐 (비편향 추정량 중)

## 80.5 신뢰도와 샘플 크기의 관계

정밀도 요구사항:

$\pm \epsilon$  범위의 오류를  $100(1-\alpha)\%$  신뢰도로 원할 때:

필요한 샘플 크기:

$$n = z^2_{\{1-\alpha/2\}} \times \sigma(1-\sigma) / \epsilon^2$$

여기서  $z_{\{1-\alpha/2\}}$ 는 표준 정규분포의 상위  $\alpha/2$  백분위수:

- 90% 신뢰도 ( $\alpha=0.1$ ):  $z = 1.645$

- 95% 신뢰도 ( $\alpha=0.05$ ):  $z = 1.960$

- 99% 신뢰도 ( $\alpha=0.01$ ):  $z = 2.576$

구체적 계산 예시:

목표: 선택도  $\sigma = 0.01$  (1%)을  $\pm 20\%$  상대 오류, 95% 신뢰도로 추정

$$\text{절대 오류 } \epsilon = \sigma \times 0.2 = 0.01 \times 0.2 = 0.002$$

필요 샘플:

$$n = 1.96^2 \times 0.01 \times 0.99 / 0.002^2$$

$$n = 3.84 \times 0.0099 / 0.000004$$

$$n = 9,504$$

$$\text{테이블이 1,000,000행이면: 샘플율} = 9,504 / 1,000,000 \approx 1\%$$

선택도에 따른 샘플 크기:

같은 조건 ( $\pm 20\%$  오류, 95% 신뢰도)에서:

$\sigma = 0.5$  (50%):  $n \geq 2,401$

$\sigma = 0.1$  (10%):  $n \geq 9,604$

$\sigma = 0.01$  (1%):  $n \geq 9,504$  ( $\sigma$ 와  $(1-\sigma)$ 이 비슷해서 최대)

$\sigma = 0.001$  (0.1%):  $n \geq 95,040$

$\sigma = 0.0001$  (0.01%):  $n \geq 950,399$

선택도 감소에 따라 필요 샘플 선택도의 역함수에 비례

## 80.6 다중 조인에서의 확장

체인 조인(Chain Join):

T1 JOIN T2 JOIN T3

각 조인의 선택도:

$\sigma_{1_2} = P(t_1, t_2 \text{ 만족}) = 0.1$

$\sigma_{2_3} = P(t_2, t_3 \text{ 만족}) = 0.2$

결합 선택도 (독립성 가정):

$\sigma_{\text{total}} = \sigma_{1_2} \times \sigma_{2_3} = 0.1 \times 0.2 = 0.02$  (2%)

문제:  $\sigma_{\text{total}}$ 이  $\sigma_{1_2}$ ,  $\sigma_{2_3}$ 보다 낮음

→ 최종 카디널리티 추정이 더 불안정

스타 조인(Star Join):

중앙 테이블 T1과 여러 dimension 테이블 T2, T3, T4 조인

T1과 T2의 선택도:  $\sigma_{1_2} = 0.3$

T1과 T3의 선택도:  $\sigma_{1_3} = 0.4$

T1과 T4의 선택도:  $\sigma_{1_4} = 0.5$

결합 선택도:  $\sigma_{\text{total}} = 0.3 \times 0.4 \times 0.5 = 0.06$  (6%)

문제: 테이블이 많을수록 선택도는 더 낮아짐

## 80.7 비용 모델에서의 적용

조인 실행 비용 추정:

조인 비용 = CPU\_비용 + I/O\_비용 + 메모리\_비용

CPU 비용: 조인된 행 수 × 행당\_처리비용  
=  $C \times \text{cost\_per\_row}$   
=  $N_1 \times N_2 \times \sigma \times \text{cost\_per\_row}$

I/O 비용: 접근해야 할 페이지 수  
=  $(N_1 \times \text{page\_size}_1) + (N_2 \times \text{page\_size}_2)$   
(선택도가 낮으면 CPU 비용이 지배적)

정확한  $\sigma$  추정 → 정확한 비용 예측 → 최적 실행 계획

## 80.8 본 논문과의 관계

Exqutor의 샘플링 기반 선택도 추정:

Exqutor는 범위 필터와 벡터 검색의 결합 선택도를 추정하는데, 이 논문의 이론을 직접 적용할 수 있다:

1단계: 이론적 기초 적용

범위 필터: WHERE price  $\in [L, U]$   
벡터 검색: WHERE similarity(embedding) >  $\theta$

쿼리 선택도:  
 $\sigma = P(\text{가격 조건}) \times P(\text{유사도 조건})$

이는 논문의 곱셈 규칙(independent join selectivity)  
과 동일한 형태

2단계: 샘플 크기 결정

목표 정확도:  $\pm 15\%$  상대 오류, 90% 신뢰도  
추정된  $\sigma = 0.12$  (범위 필터 15% × 벡터 80%)

필요 샘플 크기:  
 $\epsilon = 0.12 \times 0.15 = 0.018$   
 $z = 1.645$  (90% 신뢰도)

$n = 1.645^2 \times 0.12 \times 0.88 / 0.018^2$   
 $n \approx 250$ 개 (전체 1% 미만)

3단계: 신뢰도 검증

수집한 샘플에서:

$c$  = 범위 필터 AND 유사도 조건 만족하는 행 수

신뢰도 구간:

$$\sigma_{\text{hat}} \pm 1.645 \times \sqrt{(\sigma_{\text{hat}}(1-\sigma_{\text{hat}}) / n)}$$

이 구간이 충분히 좁으면 추정 사용

너무 넓으면 추가 샘플링

#### 논문 [80]의 핵심 가치:

1. **이론적 정당성**: 샘플링 기반 추정의 수학적 기초 제공
2. **샘플 크기 결정**:  $n = z^2 \times \sigma(1-\sigma) / \epsilon^2$  공식
3. **신뢰도 계산**: 점근 정규분포를 이용한 신뢰도 구간 계산
4. **다중 조인 확장**: 곱셈 규칙을 통한 복합 선택도 추정
5. **실무 적용**: 이후 모든 샘플링 기반 옵티마이저의 기반

## 추가 제기 문제

1. **소 샘플 문제**:  $n$ 이 작을 때( $n < 30$ ), 정규 근사가 타당한가? (카이제곱 등 다른 분포 필요?)
2. **상관성 위반**: 범위 필터와 벡터 임베딩이 상관되어 있을 때, 곱셈 규칙이 여전히 유효한가?
3. **모수  $\sigma$ 의 사전 정보**:  $\sigma$ 를 모르면 샘플 크기  $n$ 을 미리 결정할 수 없는데, 이를 어떻게 해결할 것인가?
4. **해결책**:  $\sigma = 0.5$ 로 가정 (최악의 경우) → 과도한 샘플 수집
5. **스트리밍 업데이트**: 데이터가 지속적으로 추가될 때, 과거 샘플이 유효한가?
6. **적응적 샘플링의 다중비교**: 여러 쿼리의 선택도를 동시에 추정할 때, 각각 독립적으로 샘플링하면 총 샘플 비용이 급증하는데, 이를 최적화할 수 있는가?
7. **비선형 선택도 관계**: 실제로는  $\sigma_1 \times \sigma_2 \neq \sigma_{\text{total}}$ 일 때(상관성 있을 때), 편향을 추정할 수 있는가?