

[속도는벡터] 연구 진행 경과 보고 및 3차 자문 요청

멘토님 안녕하십니까, 연세대학교 캡스톤 디자인 속도는벡터 팀입니다.

4월 20일 2차 자문에서 (1) 단일 테이블 시나리오로 범위를 좁힌 것의 타당성, (2) 비례 배분 효과와 공간 인식 효과를 분리한 Two-Level Decomposition의 학술적 가치, (3) 중간 발표의 메시지 방향에 대해 조언해 주셨습니다. 그 이후로 연구가 크게 진전되어, 5월 27일·29일 양일 최종 발표를 앞두고 경과를 공유드리고 세 가지 자문을 구하고자 합니다.

연구 경과

중간 발표까지는 두 가지를 다루었습니다. 무작위 표본 추출이 한쪽으로 쏠린 데이터에서 얼마나 부정확한지, 그리고 데이터 분포를 반영해 표본을 뽑으면 무작위 표본보다 얼마나 더 정확해지는지를 한 가지 표본 추출 방법으로 확인했습니다. 이후 최종 발표를 향해서는 그 표본 선택 단계의 개입을 16가지 방법과 세 방식 비교로 확장해, 모든 데이터셋과 모든 조건에 걸쳐 본격적으로 측정했습니다. 그리고 5월 중순부터는 추정 정확도에서 한 발 더 나아가, 검증된 결합 추정값을 실제 PostgreSQL 엔진에 직접 주입해 실행 시간(latency)까지 달는 엔진 적용 검증 실험을 수행했습니다.

먼저 추정 정확도 측정의 범위를 크게 넓혔습니다. 중간 발표까지 쓰던 한 가지 표본 추출 방식(k-means 기반 계층화)을, 공간 곡선·차원 축소·양자화·클러스터링 등 일곱 가지 접근을 대표하는 16가지 방법으로 확장했습니다. 다만 논문 Exqutor에서 저희가 손대는 지점은 '표본을 뽑는 단계' 하나로 일관되게 한정했고, 카디널리티 추정 알고리즘과 표본 크기 보정 과정은 논문 그대로 두었습니다.

측정 설계도 발전시켰습니다. 2차 자문 때 말씀드린 '분포 인지 표본 대 무작위 표본'의 대조를, 한 번의 측정에서 세 가지 방식을 똑같은 데이터·똑같은 조건으로 동시에 비교하는 설계로 다듬었습니다. 세 방식은 ① 기존 방식(논문의 무작위 표본 추출), ② 완전 대체(논문의 표본을 저희 방법으로 통째 교체), ③ 결합(논문의 추정값과 저희 방법의 추정값을 평균)입니다. 이 설계로 모든 데이터셋과 모든 조건(선택도·데이터 규모·단일과 다중 구조·계층 수)에 걸쳐 1508번을 측정했습니다.

핵심 결과는 다음과 같습니다. 결합 방식은 기존 방식과 비교해 1508번의 측정 가운데 89.1%에서 추정 오차가 더 작았습니다(개선 폭은 중앙값으로 약 4.4%). 반면 완전 대체 방식은 35.2%에서만 더 나아, 저희 방법으로 논문의 표본을 통째 바꾸는 것은 불안정함을 확인했습니다. 완전 대체는 효과가 없을 수도 있는 방식을 일부러 측정해 본 것으로, 개선의 원천이 새 방법 자체가 아니라 논문 방식과의 '결합'에 있음을 역으로 입증해 주었습니다. 데이터 측면에서는 공개된 단일 벡터 데이터셋 다섯 종에 더해 서로 다른 두 데이터셋의 벡터를 이어 붙인 다중 벡터 데이터를 직접 만들어 측정 범위를 한 번 더 넓혔습니다.

한편 측정을 검증하던 중에는 비교 기준이 되는 기존 방식의 표본 추출 구현에서 미묘한 결함을 발견했습니다. 데이터를 두 단계로 나눠 표본을 뽑던 구조가 일부 조건에서 기준값의 오차를 부풀리고 있었던 것입니다. 이를 데이터 전체에서 한 번에 뽑는, 논문에 더 충실한 방식으로 바로잡았습니다. 그 결과 개선 수치는 수정 전보다 다소 보수적이 되었으나, 더 엄정한 기준 위에서 나온 값이 되었습니다.

여기까지가 5월 중순의 진행이었고, 그 이후 한 달 가가이는 추정 정확도에서 한 단계 더 나아가 **실제 PostgreSQL 엔진에 결합 추정값을 주입해 실행 시간까지 측정하는 엔진 적용 검증 실험**을 진행했습니다. 오프라인에서 검증된 결합 추정값(저희가 강하다고 골라낸 13가지 method × 결합 방식)을 패치된 PostgreSQL 엔진의 카디널리티 주입 인터페이스로 직접 넣은 뒤, 같은 쿼리·같은 데이터에서 ① 기본 엔진(추정 개입 없음), ② 베이스라인(논문 무작위 추정), ③ 결합 13가지, ④ 정답 카디널리티 네 조건을 같은 자리에서 비교했습니다. 측정 평면은 DEEP-sf=10·선택도 0.001의 핵심 12 cell(쿼리 4종 × 분포 3종) × 16 variant × 15회 반복 = 총 2,880회의 실행, 이후 선택도 0.01~0.1의 carry-over 8 cell을 더해 20 cell · 580 paired · 4,800회 실행을 확보했습니다. 한 cell 한 줄로 줄이면 "분포 인지 결합 추정값을 PostgreSQL이 그대로 받아들였을 때, 실행 계획이 정답과 같아지고 실행 시간이 기본 엔진 대비 몇 배 빨라지는가"를 측정했다고 할 수 있습니다.

엔진 적용 검증의 핵심 결과는 세 가지입니다. **첫째, 결합 13가지 모두 기본 엔진 대비 중앙값 3~7배의 가속**(168개 짝지은 비교 모두 paired Wilcoxon $p < 0.05$ 유의)을 만들었습니다. 둘째, 결합 13가지는 정답 카디널리티가 만드는 실행 계획을 **94.9%(156/164) 회복**했습니다. 같은 자리에서 베이스라인(논문 무작위 방식)은 12개 cell 중 7개 cell만(58.3%) 정답 계획을 회복했습니다 — 본 연구의 결합 방식은 베이스라인보다 정답에 더 안정적으로 수렴합니다. 셋째, 그러나 베이스라인·결합·정답 세 조건 사이의 **실행 시간 자체는 통계적으로 동등**합니다(168개 짝지은 비교 중 7.7%만 유의, Hedges' g 86.9% 가 small effect). 즉 결합 방식이 베이스라인보다 빨리 실행되는 것은 아니지만, **계획 회복의 견고성(robustness)에서 우위를 가지며 실행 시간 자체로는 동등**하다는 두 결론이 분리되어 나옵니다. 정직하게 한 가지 예외는 남아 있습니다 — Q9 × 선택도 0.1의 한 cell에서는 결합이 정답과 다른 계획을 만들면서 오히려 0.93배 감속하는 단일 예외(plan ≠ baseline이지만 sub-optimal로 유도)가 관측되었습니다.

5월 20일에는 위 결론의 통계적 견고성을 다축으로 보강하는 세 가지 후속 분석을 추가로 수행했습니다. (1) **plan 회복 효과 분층** — 580 paired의 효과 크기 분포를 plan 회복 여부로 나누면 회복 그룹은 large effect 5.4%, 비회복 그룹은 26.3%로 약 5배 차이가 났습니다. 계획 회복이 실행 시간 동등성을 매개하는 인과의 사슬이 정량으로 드러납니다. (2) **cluster paired bootstrap** (B=2,000회, cell 단위 재추출) — 신뢰 구간 너비가 단순 행 단위 bootstrap의 2.31~2.64배로 넓어졌습니다. cell 내부의 상관을 보정해도 동등성 결론이

견고함을 다시 확인합니다. (3) **분산 분해(variance decomposition)** — 실행 시간의 변동을 선택도·query·조건·교호작용으로 OLS Type-III SS 분해했더니($n=4,800$, $R^2=0.937$), 기본 엔진을 제외한 모델 3(B1·결합·정답, $n=4,500$)에서 **조건 % SS = 0.00% ($p=0.866$)** 으로 사라졌습니다. 선택도가 70.8%·query가 4.6%·잔차가 24.3%로 변동을 모두 설명하고, 베이스라인·결합·정답 세 조건 사이의 실행 시간 차이는 분산 분해의 정량으로도 동등하다고 확정됩니다.

마지막으로 한 가지 정직히 말씀드릴 점은, 본 엔진 적용 검증은 pgvector(저희가 직접 패치한 PostgreSQL 16) 단일 엔진을 대상으로 수행했다는 사실입니다. 박광현 교수님이 후속 제안하신 4 엔진 통합 측정(pgvector·VBASE·DuckDB·vss·Exqutor 비교)은 VBASE·DuckDB의 빌드 환경 준비와 동등 측정 틀 작성에 15~25시간이 필요한 반면 서버 권한이 5월 21일 종료되어, 본 연구 범위 안에서는 단일 엔진 검증으로 마무리하고 4 엔진 통합 일반화 검증은 **향후 연구 과제**로 명시 분리하기로 했습니다. 검증된 결합 추정값을 다른 엔진에도 동일하게 적용할 수 있는지의 일반화 검증은 본 연구의 결합 방식이 학술적·실용적 가치를 가진다는 결론과는 독립된 별도의 question으로 보고 있습니다.

자문 요청

세 가지에 대해 멘토님의 판단을 여쭙고 싶습니다.

첫째, 엔진 적용 검증의 메시지 정리에 대한 조언입니다. 위의 결과 중 "결합 13가지가 정답 계획을 94.9% 회복하지만 실행 시간 자체로는 베이스라인과 동등하다"는 두 결론의 분리가 본 연구의 핵심 메시지로 적절한지 여쭙고 싶습니다. 학부 캡스톤 최종 발표 청중 입장에서는 "94.9% 회복"이라는 직관적 수치와 "통계적 동등성"이라는 학술적 정직성이 어색하게 들릴 수 있을 것 같습니다. 저희는 이를 "본 연구의 결합 방식은 빨라지는 것이 아니라 더 안정적으로 정답 계획에 수렴한다 — 실행 시간 자체는 동등하면서 계획 회복의 견고성에서만 우위를 가진다"는 한 문장으로 정돈하려 합니다. 이 framing이 학술적으로 정확하면서 동시에 학부 청중에게 설득력 있는지, 또는 다른 한 줄로 다듬어야 한다면 어떤 방향인지 조언 부탁드립니다.

둘째, honest exception(Q9 × 선택도 0.1)의 위치에 관한 조언입니다. 위에 적은 대로 단 한 cell에서 결합이 0.93배 감속하는 예외가 관측되었습니다. 저희는 이를 "결합 방식이 만능이 아니며 선택도가 높은 일부 cell에서 sub-optimal 계획을 유도할 가능성이 남아 있음을 정직히 보고한다"는 limitation으로 본문 §6.4 향후 작업의 한 갈래로 두려 합니다. 비교 기준 결합을 정직히 보정한 5월 중순의 경험과 같은 맥락에서, 이 단일 예외를 limitation으로 두는 처리가 학부 캡스톤 보고서·발표에서 적절한지, 또는 condition-of-effect로 본문에 더 명시적으로 끌어와야 할 사안인지 의견 부탁드립니다.

셋째, 4 엔진 통합 측정의 future work 정직 framing에 대한 조언입니다. 위에 적은 대로 본 연구는 pgvector 단일 엔진 검증으로 마무리하고, 박광현 교수님이 후속 제안하신 4 엔진 통합은 서버 권한 종료와 빌드 환경 제약을 정직히 들어 향후 연구로 분리하려 합니다. 학부 캡스톤 최종 평가에서 "제안의 일반화 검증이 단일 엔진에 머물렀다"는 점이 약점으로 받아들여질 가능성과, 반대로 "범위를 정직히 명시하고 future work로 분리한 학술적 절제"로 평가받을 가능성 사이의 무게가 궁금합니다. 본문에서 이 단일 엔진 한계를 어느 수준의 명시성으로 다루는 것이 좋을지(§5 본문에 짧게 명시 vs §6.4 future work에 명확히 분리)도 함께 조언 부탁드립니다.

앞으로의 일정

5월 27일·29일 양일 최종 발표(10분 발표와 5분 질의응답, 무단결석 시 발표 점수 0점, 가산점 = 질문)와 5월 28일 정오 전시 포스터 PDF 제출, 6월 5일 졸업 전시회, 6월 11일 최종 보고서 제출이 남아 있습니다. 이번 자문에 대한 회신을 5월 24일경까지 주실 수 있다면 최종 발표 자료와 6월 11일 최종 보고서에 충분히 반영하겠습니다. 다만 발표가 임박해 일정이 촉박하실 수 있으니, 부담되지 않으면 핵심만 간단히 짚어 주셔도 큰 도움이 됩니다. 필요하시면 현재까지 작성한 발표 자료와 최종 보고서 초안(15페이지)을 함께 보내드리겠습니다.

감사합니다.

속도는벡터 팀 드림