

5/27 최종 발표 — narrative 흐름 (쉽고 간단 설명) + 클로드 디자인 input spec

이 자료의 목적: 5/27 최종 발표 (academic deck) narrative 흐름을 1 slide 1 메시지로 단순 정리. 사용자가 5/15 박광현 교수님 미팅 confirm 후 5/16~5/26 sprint에 [Claude Design](#)에 input으로 직접 사용.

작성: 2026-05-11 19:42 KST · 5/11 paper exact 측정 종합 narrative 기반 + 5/8 시점 academic-deck v3 (16 slide) base + 5/16~5/26 update plan 통합.

분량: 18 slide (5/8 16 + 신규 S6.5 paradigm + S10.5 CaseB ensemble) × 1 page spec each

0. 발표 전체 흐름 (한 단락 요약)

Exqutor 논문이 풀지 못한 단일 테이블 영역에서 우리는 paper의 sampling 방식을 그대로 두고, 우리 method의 추정값을 산술 평균으로 ensemble 추가했다. 결과는 **paper baseline 대비 92.9% 우위 + 5 paradigm 모두 statistical 압도**다. 이 과정에서 학술 정직성 발견 2건 (★3 hilbert defect + RQ2 Neyman paradox)를 honest disclosure하고, 신규 paradigm 2개 (P10 KDE / P9 HyperLogLog)를 발굴했다.

7단계 storyline (slide 흐름과 일치)

1. **문제** (S1-S4): pgvector/VBASE/DuckDB는 고정 비율로 카디널리티 추정 — Exqutor가 §V-A는 풀고 §V-B는 unstratified Bernoulli만
2. **접근** (S5): paper §V-B는 그대로, 우리 method를 산술 평균 ensemble로 추가 (paper-friendly augment)
3. **검증 RQ1/RQ2** (S6-S7): 분포 정보가 정확도에 직접 영향 + Anti<Prop>Neyman paradox honest finding
4. **paradigm framework** (S6.5 신규): 9 paradigm × 56 method, P9/P10 신규 발굴
5. **CaseA 무너짐** (S8): 우리 method 단독 대체는 0/437 outperform (paper §V-B 자체 robust)
6. **CaseB climax** (S10.5 신규 + S11): ensemble paired 92.9% / Cliff's δ 63.5% + 5 paradigm 모두 anchor
7. **honest** (S15) + closing (S16): 18 limitation + Future work 8건

Slide 1 (Cover) — 표지

제목: Skew-Aware Stratified Sampling Ensemble for Vector-augmented Analytical Queries

부제: paper §V-B Adaptive Sampling baseline의 분포 인지 ensemble augment 정량 검증

비유: 일기예보 모델이 "기온 평균"으로만 예측하는데, 우리는 "기온 평균 + 분포 인지 cluster 평균"의 산술 평균을 추가 — 한 쪽이 틀려도 다른 쪽이 보완

메타: 속도는벡터 (박세은 / 강재현 / 조현빈 / 이동욱) · 박광현 교수님 (BDAl) · 2026-05-27

Slide 2 (TOC) — 오늘의 흐름

한 줄: 7단계로 짧게 — 문제 → 접근 → RQ1/RQ2/RQ3 → CaseA 무너짐 → CaseB climax → honest

카드 7장: Problem · Approach · RQ1 · RQ2 paradox · paradigm 9 · CaseB ensemble · Future

Slide 3 (Problem) — 무엇이 문제

한 줄: pgvector 33.3% / VBASE 50% / DuckDB 100% — 고정 비율로 카디널리티 추정 → 1000-10000× 느린 query

핵심 수치: 실제 selectivity 0.001%~90% 범위 → 고정 비율 대비 100× 이상 빗나감

비유: 어떤 쿼리든 "결과는 33%일 거야" 무조건 가정 → query plan 잘못 선택 → 1만 배 느린 실행

Slide 4 (Prior — Exqutor) — 이전 연구

한 줄: Exqutor 논문은 §V-A ECQO (인덱스 있을 때 HNSW, 1-2ms 정확)와 §V-B Adaptive Sampling (인덱스 없을 때 momentum 기반 동적 sample size, 식 1-6) 두 paradigm으로 해결

핵심: 본 연구는 §V-B 한정 영역에서 우리 method ensemble augment 추가 (§V-A는 paper main result 그대로 인정)

비유: paper가 "두 갈래 길"을 풀었는데 우리는 그 중 한 갈래(§V-B)에 추가 갈림길을 만들어 정확도 ↑

Slide 5 (Approach) — 우리 접근

한 줄: paper §V-B Bernoulli sampling 그대로 유지 + 우리 method KM20 stratified의 산술 평균 ensemble
($(\text{est1} + \text{est2}) / 2$)

핵심 코드 (3줄):

```
estimator 1 = paper §V-B Bernoulli (paper exact 그대로)
estimator 2 = 우리 method (분포 인지 stratified)
final cardinality = (est1 + est2) / 2      ← simple average
```

비유: 두 의사 진단 중 "한 의사 의견만" vs "두 의사 평균" → 평균이 더 정확 (한 쪽 진단 실수해도 다른 쪽이 보완, bias-variance trade-off)

왜 산술 평균?: random sampling은 bias=0/variance↑ + stratified는 분포 가정 시 variance↓ → 산술 평균이 robust

Slide 6 (RQ1) — 분포 차이가 정확도에 영향

한 줄: DEEP/SIFT/SSN sf=100 5 cell 측정 → Bernoulli vs KM20 stratified mean Q-error gap **+3.74%** (Bernoulli 부정확)

핵심 수치: paper Fig 12 영역 8 cells mean trim Q-error **1.6180** vs paper 1.69 (-4.26%, paper review-grade 일치)

비유: 인구 조사를 무작위 100명 vs 연령대별 25명씩 → 연령대별이 더 정확 (분포 인지 효과)

시각화: Bernoulli vs KM20 bar chart × 5 cells

Slide 7 (RQ2 — Anti<Prop<Neyman paradox) ★ 신규 narrative

한 줄: 분포 알면 prop allocation 답 (Bern→Prop -9.53%) — 단 Anti < Prop < Neyman paradox 발견 (paper §V-B 이론 위배 양상)

핵심 수치 (5-way): | Bernoulli | Equal | **Prop** | Neyman | **Anti** | |:-:|:-:|:-:|:-:| | 1.748 | 1.644 | **1.580** | 1.595 | **1.540 (최저)** |

Honest finding: σ_j range 1.3-1.6× 좁음 + N_i CV=0 → σ -weighted Neyman alloc cos_sim 0.99 → budget noise > Neyman signal의 자연 결과 (boundary case). PartSupp PK가 균등 분포라 Neyman 변별력 marginal.

비유: 시험 점수가 모든 학년에서 거의 비슷하면, 학년별 가중치 (Neyman) vs 균등 가중치 (Equal) 차이가 안 남

다음 slide 자연 전환: σ range 좁은 영역에서는 prop이 답 → σ range 큰 영역 (분포 추정 framework, RQ3)으로 자연 전환

Slide 6.5 (paradigm framework 9) ★ 신규 slide

한 줄: stratification 알고리즘을 **inductive bias 9 paradigm**으로 분류

카드 9개: 1. **P1 Cluster** (9 method) — "유사 데이터는 군집을 이룸" (k-means) 2. **P2 Spatial** (12 method) — "1D 분할" (Hilbert curve, Z-order) 3. **P3 Streaming** (6 method) — "single-pass / OLTP" (Chao 1982 weighted) 4. **P4 DimReduction** (12 method) — "고차원→저차원 투영" (sparse RP) 5. **P5 QMC** (8 method) — "결정론적 균등" (Sobol, LSH) 6. **P6 Quantization** (6 method) — "vector→codeword" (RaBitQ, MHIST) 7. **P9 InfoTheoretic** ★ 신규 (1 method, 9 cells) — "sketch / cardinality 추정" (HyperLogLog) 8. **P10 Density** ★ 신규 (1 method) — "non-parametric density" (KDE Parzen) 9. P7 Subspace + P8 Graph (future work, CLIQUE / Leiden + Bao VLDB 2025)

왜 중요?: 5/8 시점 5 paradigm × 11 method → 5/11 시점 **9 paradigm × 56 method**로 확장 (P9/P10 신규 paradigm 발굴이 학술 contribution)

Slide 8 (RQ3 — paradigm rollup 9) — 4강 framing 폐기

한 줄: 9 paradigm × 56 method × 9 cells × 2 modes 측정 → CaseB ensemble paradigm rollup **5 paradigm** 모두 statistical 압도

핵심 수치 (CaseB mean Δ%): - 🏆 **P10 Density (KDE Parzen):** -11.93% (1 cell, Q4 진행 중) - 🏆 **P9 InfoTheoretic (HyperLogLog):** -7.60% (9 cells, 5/9 signif p_adj<0.05) ★ - 🏆 **P3 Streaming (Chao 1982):** -6.53% - [4] **P4 DimReduction (sparse_rp ★ 4):** -5.92% - [5] **P2 Spatial (★ 3 alias + M6/M7/hilbert_real):** -5.52%

5/8 → 5/11 변경: "4강" framing (HDBSCAN/MB_partial/Hilbert/Hybrid) → **paradigm rollup 9** narrative 전환

시각화: 9 paradigm bar chart (CaseB Δ% horizontal bars, 색깔 statistical signif 강도)

Slide 9 (★3 Hilbert defect rectify) — 학술 contribution

한 줄: 5/8 4강 ★3 Hilbert는 코드상 PCA 2D lex sort (Faloutsos 1989 ✖) — alias `pca2d_lex` 정직 명명 + 진짜 Hilbert anchor 3건 추가

4건 paradigm anchor: 1. ★3 hilbert (alias `pca2d_lex`) — 결과 보존 2. **M6 zorder_morton** (Morton 1966 IBM Tech Rep) 3. **M7 skilling_hilbert** (Skilling 2004, conditional swap simplification 1줄 disclosure) 4. **hilbert_real** (Wikipedia xy2d 표준) — 9 cells × CaseB **mean -8.2%, 6/9 signif ★**

비유: 5/8 시점 ★3 Hilbert 측정 결과는 "PCA proxy locality"였음. 진짜 Hilbert curve의 locality 효과를 분리 측정해보니 (M6/M7/hilbert_real) — 이 4건 비교가 학술 contribution

왜 alias로 보존?: 학술 정직성 + paradigm rollup honest comparison (5/8 측정 결과 자체는 valid, reference만 정정)

Slide 10 (★2 MB_partial) — P1 Cluster anchor

한 줄: minibatch_partial M2 (Sculley 2010 partial_fit) — CaseA 단독 대체 시 **method-mean -10.17%** (단일 method 우위 강력)

핵심: P1 Cluster의 OLTP partial_fit 친화 anchor. 단 paradigm 차원에서는 P10/P9/P3가 더 강함

시각화: minibatch_partial CaseA Δ% per cell bar

Slide 10.5 (CaseB ensemble climax) ★ 신규 slide — 본 연구 main contribution

한 줄: paper §V-B Bernoulli + 우리 method 산술 평균 ensemble의 통계 압도

핵심 수치 4개 (paper review-grade): - **paired CaseB > CaseA: 92.9% (404/435)** — paper review-grade
- **Cliff's δ large better ($\geq +0.474$): 63.5% (284/447)** - **Hedges' g large effect ($g \leq -0.8$): 56.4% (252/447)** - **Trial-level sign test: 740/1030 (71.8%, $p=3.1e-46$)** ← binomial 강유의

비유: 두 의사 진단 평균이 어느 한 의사 단독 진단보다 정확 (92.9% 케이스)

시각화: Cliff's δ bucket bar (CaseA worsening 36.8% vs CaseB better 63.5% — **4.4× anchor**)

Slide 11 (Negative Control + CaseA 무너짐) — honest disclosure

한 줄: CaseA 단독 대체는 무너짐 (one-sided BH $0/437 = 0.0\%$) → CaseB ensemble만이 robust

핵심 finding: paper §V-B Adaptive Sampling 자체가 momentum + Q-error feedback loop로 robust → 단독 대체 narrative 폐기, ensemble augment narrative만 유효

비유: paper의 sampling 방식 자체를 "교체"하는 것은 통계 무효, "보완"만이 통계 압도

Slide 12 (Cross-scale) — sf1/10/100

한 줄: DEEP × sf=1/10/100 모두 paper exact 일치 (Fig 14 영역 mean qe_trim within paper $1.69 \pm 5\%$)

시각화: sf 별 Q-error trend line (B1 vs CaseA vs CaseB)

Slide 13 (Mechanism — locality) — paradigm 분리 검증

한 줄: ★3 alias (PCA proxy) vs M6 Z-order vs M7 Skilling vs hilbert_real (Wikipedia 표준) 4건 anchor 분리 검증 → P2 Spatial paradigm rollup -5.52%

시각화: 4 method × 9 cells × 2 modes $\Delta\%$ heatmap

Slide 14 (Effect Size Honesty) — paper review-grade 통계

한 줄: Hedges' g + Cliff's δ + paradigm rollup + cherry-pick prevention 4축 통계 검증

핵심: - Cliff's δ large better 63.5% (CaseB) vs worsening 36.8% (CaseA) → **4.4× anchor** - Top winners: pq @ A5-sf1 ($g=-7.15$) / sparse_rp @ A5-sf1 ($g=-7.14$) / vinecopula @ A5-sf1 ($g=-7.05$) - Reproducibility 280/280 byte-identical (deterministic)

시각화: Hedges' g × Cliff's δ scatter

Slide 15 (Limitation 18 카드) — honest disclosure

한 줄: 18 limitation 4 group (A v1 4 + B 5/8 W4 4 + C V7 audit 3 + **D 5/11 신규 5**)

5/11 신규 5건: - **L12** 측정 미커버 233 cells (20.5%) 9 카테고리 정직 분류 - **L13** RQ2 Neyman/Anti paradox honest finding - **L14** ★3 hilbert PCA alias (Faloutsos 1989 **✗**) - **L15** byte-identical cells 7쌍 (A1-DEEP ≡ A5-sf100) - **L16** A4-sel sel=0.001 calibration parquet 부재 fallback

비유: 18 honest 한계 → 후속 연구 출발점 8건 (P7 CLIQUE / P8 Leiden + Bao VLDB 2025 등)

Slide 16 (Closing) — 감사 + Q&A

한 줄: 감사합니다 / Q&A — paper §V-B 영역 한정 contribution 정량 입증

참고: GitHub [johyunbin/Capstone](#) + arXiv:2512.09695v2

클로드 디자인 input prompt (사용자가 5/16~5/26에 직접 사용)

다음 prompt를 [Claude Design](#) academic-deck/Slides.jsx에 input:

기존 16-slide academic deck (Style A: 흰 배경 + navy stripe + numbered badge + Apple SD Gothic Neo)을 18

핵심 narrative 변경 (5/11 paper exact 측정 결과 반영):

1. "4강" framing 폐기 → "9 paradigm × 56 method × CaseB ensemble climax"
2. 신규 narrative anchor:
 - paired CaseB > CaseA 92.9% (404/435)
 - Cliff's δ large better 63.5% (284/447)
 - Hedges' g large 56.4% (252/447)
 - paradigm rollup P10 -11.93 / P9 -7.60 (9 cells signif) / P3 -6.53 / P4 -5.92 / P2 -5.52
3. 신규 slide 2개:
 - S6.5 paradigm framework 9 (P1-P10)
 - S10.5 CaseB ensemble climax (본 연구 main contribution)
4. 학술 contribution 정정:
 - *3 hilbert defect rectify (PCA alias 정직 명명 + M6/M7/hilbert_real 4건 anchor)
 - RQ2 AntiProp<Neyman paradox honest finding (σ range narrow 자연 결과)
 - P9 InfoTheoretic + P10 Density 신규 paradigm 발굴
5. Limitation 8 → 18 (5/11 신규 5건: drop 233 cells / RQ2 paradox / *3 alias / byte-identical / sel=0.00

각 slide는 "1 줄 핵심 메시지 + 핵심 수치 1-2개 + 비유 (학술 용어 풀어쓰기) + 시각화" 4 항목으로 구성. 학

시점 권고

시점	작업
5/12~5/14	본 narrative spec 박세은 / 강재현 / 이동욱 검토 + 카톡 공유
5/15 (금) 14:00	박광현 교수님 미팅 — narrative confirm
5/15 저녁	미팅 confirm 결과로 본 spec minor 정정 (만약 narrative 변경 시)
5/16~5/19	클로드 디자인에 본 spec input → 18-slide deck v4 생성
5/20~5/22	deck v4 박세은 검토 + figures 6건 통합 (experiments/figures/paper_exact_v7/)
5/23~5/26	deck v4 finalize + 강재현 발표 리허설
5/27 (수) 19:00	최종 발표

작성: 2026-05-11 19:42 KST

다음: 5/15 박광현 미팅 confirm 후 narrative 정합성 점검 → 5/16~5/19 클로드 디자인 input → deck v4 생성