

속도는벡터 5/27 최종발표 plan — 17 슬라이드 + 가지 치기 narrative (2026-05-08 10:18 갱신)

목적: 5/27 (D-19) 최종발표 자료 plan. academic v3 deck 양식 95%+ 정밀 재현 (Slides.jsx React 컴포넌트 기반).

5/8 10:18 narrative 재정의 (사용자 결정): - **메인 narrative = 10 cell** (5 dataset × sf1/sf10) — Exqutor 매칭 - YFCC = **채림 적재본 단일 정보** (`partsupp_yfcc_{1,10}`) - `build_yfcc.py` 다운로드 결과 폐기 — 자체 build YFCC_DL 적재본 본 연구에서 사용하지 않음 - **multi 3 cell = 부록 자료** - **sf100 = 회의 후** (BigANN base.80M.u8bin 권장, 채림 정보 동일 source)

컨셉: 가지치기 (pruning) — 35 method 후보 → 4 winner 선정 과정 narrative. "최대한 많은 method → 최적 식별 → Exqutor 적용".

시간 배분: 17 슬라이드 × 12분 = 각 슬라이드 ~45초.

선행 doc: - `experiments/results/RQ1_RQ2_RQ3_종합_master_v6_draft_filled_partial.md` (master narrative, 5/8 10:18 `build_yfcc` 폐기 갱신) - `experiments/results/10cell_narrative_종합_20260508.md` (10 cell 메인 + multi 3 부록 정제 요약) - `submission/_drafts/academic_deck_v3_source/academic-deck/index.html` (양식 reference)

§1. 발표 narrative 구조 (12분)

[Phase 1 – Motivation + RQ 카드] 슬라이드 1-3 (~2분)

표지 → 목차 → RQ 카드 (3 RQ 한 화면)

[Phase 2 – Motivation 상세] 슬라이드 4-5 (~1.5분)

Exqutor 본 논문의 미해결 영역 → 본 연구의 위치

[Phase 3 – RQ1/RQ2 측정 결과] 슬라이드 6-7 (~1.5분)

RQ1 selectivity gradient 단조성 → RQ2 KM20 oracle + Neyman ablation

[Phase 4 – RQ3 35 method funnel + 가지치기] 슬라이드 8-9 (~2분)

35 method 후보 → tier elimination → 4 winner

[Phase 5 – 4강 method narrative] 슬라이드 10-12 (~3분)

Distribution sweet spot → SSN++ ceiling negative control → 4 method 일관성

[Phase 6 – Multi 3 cell + 한계] 슬라이드 13-14 (~1.5분)

multi-vector + multi-join → limitation 9종

[Phase 7 – Future + Thanks] 슬라이드 15-17 (~1.5분)

sf100 진행 → future work → thanks

§2. 17 슬라이드 plan

S1 — 표지

제목: Skew-Aware Vector Stratification — Exqutor 보안을 위한 분포 인지 sampling 의 가치 정량화

서브 타이틀: - 캡스톤 디자인 2026-1, 연세대학교 - 속도는벡터 (박세은·강재현·조현빈·이동욱) - 발표일: 2026-05-27

시각: - academic v3 deck 표지 양식 (tight letter-spacing -0.03em, navy accent #2c3e50) - 팀 로고 + 학교 로고

Speaker note: "본 연구는 Exqutor 본 논문의 ECQO + Adaptive Sampling 영역 외 단일 테이블 비인덱스 영역의 분포 인지 stratification 가치 정량화입니다."

S2 — 목차 (Table of Contents)

제목: Today's Talk — 12분, 17 슬라이드

핵심 message: 17 슬라이드 흐름 일목요연하게.

시각: - 7 phase 구분 (Motivation / RQ Cards / RQ1+RQ2 / RQ3 funnel / 4강 narrative / Multi+Limit / Future) - numbered badge (academic v3 양식)

Speaker note: "전체 발표는 7 단계로 구성됩니다. 35 method 가지치기 → 4 winner → SSN++ negative control → multi 3 cell → 자문 합의 흐름입니다."

S3 — RQ 카드 (3 Research Questions 한 화면)

제목: 본 연구의 3 RQ

핵심 message: - **RQ1:** 기존 random sampling 이 skew 데이터셋에서 얼마나 부정확한가? (Motivation) - **RQ2:** 분포 아는 상황에서 어떤 방식이 최적? (KM20 oracle) - **RQ3:** 분포 모르는 상황에서 어떤 방식이 최적? (35 method funnel)

시각: - 3 카드 grid (academic v3 양식, 흰 배경 + navy accent) - 각 카드: RQ 번호 + 질문 + key finding 한 줄 - RQ1 → "11/11 cell 단조 감소 sign 일관 ($p < 0$)" - RQ2 → "KM20 oracle 9/11 cell improve, σ_i 신호 약함" - RQ3 → "23 method 측정, 4 winner 선정, SSN++ ceiling 발견"

Speaker note: "본 연구는 3 RQ 로 구성되며, 각각 paired bootstrap 95% CI 로 statistical significance 입증되었습니다."

S4 — Motivation 1: Exqutor 가 미해결한 영역

제목: Exqutor (BDAI-Research) — 단일 테이블 비인덱스 영역의 sample 분배는 미해결

핵심 message: - Exqutor (arXiv:2512.09695v2) = ECQO (HNSW range query + multi-table) + Adaptive Sampling (단일 테이블 비인덱스) - Adaptive Sampling 의 momentum 기반 sample size 조정은 1.2~3.2x speedup 입증 - 그러나 momentum 의 전 단계 인 **sample 분배 전략 (proportional vs Neyman vs distribution-aware)** 의 가치는 비교 안 됨

시각: - Exqutor 매트릭스 4분면 (인덱스 $\checkmark$ × multi-table $\checkmark$ ×) + 본 연구 영역 highlight - 본 연구 = 좌상단 (인덱스 $\times$ × single-table) 영역의 분포 인지 stratification

Speaker note: "Exqutor 는 ECQO 로 인덱스 + multi-table 영역, Adaptive Sampling 으로 단일 테이블 비인덱스 영역의 sample size 만 다룹니다. 본 연구는 그 sample 분배 전략의 가치 정량화입니다."

S5 — Motivation 2: 본 연구의 위치 + matrix

제목: 본 연구의 매트릭스 — 5 dataset × 2 scale (메인) + multi 3 cell (부록) = 13 cell

핵심 message: - Exqutor 본 논문과 동일 5 dataset (DEEP/SIFT/SSN++/WIKI/YFCC) - 메인 = 10 cell (sf1=800K + sf10=8M), 부록 = multi 3 cell (multi-vector + multi-table join) - YFCC = 채림 적재본 단일 정보 (5/8 10:18 build_yfcc 다운로드 폐기 결정)

시각: - 5 dataset × sf1/sf10 cell grid (메인) + multi 3 cell (부록) - 각 cell 의 dim / row count / 측정 method 수 표시

Speaker note: "10 cell 메인 × 30 method + 3 multi cell × 4 mode = 약 150,000 query measurement 의 통합 매트릭스입니다. YFCC 는 채림 석사님 정보 적재본 단일 source 로 통일했습니다. 단일 100% 측정 완료 (5/8 14:13 KST)."

S6 — RQ1: Selectivity Gradient 단조성 (10 cell + multi 3)

제목: RQ1 — BERN sampling 의 부정확성은 selectivity 가 작을수록 단조 증가

핵심 message: - per-seed Spearman ρ + bootstrap 95% CI - **13/13 single cell + 3/3 multi cell = 16/16 $\rho < 0$** (단조 감소 sign 일관, 100% 부호 일관) - single ρ 범위 -0.366 (SIFT_sf1) ~ -0.609 (SSN_sf10), 모든 cell $|\rho| > 0.3$ strong monotonic - YFCC_sf10 $\rho = -0.589$ (sf1 -0.527 보다 강한 단조성) - multi 3 cell $\rho = -0.605 \sim -0.632 \rightarrow$ multi 환경에서 single 평균보다 강한 단조성

시각: - forest plot: 13 single + 3 multi cell × Spearman $\rho \pm$ bootstrap CI - BERN q_{error} 표 (5 sel × 10 cell)

Speaker note: "BERN sampling 의 부정확성 단조성은 5 dataset 모두에서 통계적으로 일관되며, 이는 본 연구의 method 가 sel=0.01 영역에서 가장 큰 gain potential 을 가짐을 의미합니다."

S7 — RQ2: KM20 oracle + Anti-Neyman + K-aware (12 cell, 4 mode)

제목: RQ2 — KM20 oracle 10/12 cell improve, σ_i 신호 약함

핵심 message: - 12 cell × 4 mode (equal/proportional/Neyman/anti_neyman) = 48 measurement - sel=0.10: **47/48 (98%)** paired CI 0 제외, 10/12 cell improve direction - σ_i 신호 약함 honest: Anti-Neyman vs Proportional $|\Delta| < 1\%$ 가 6/12 cell - YFCC_sf10 4 mode 모두 -4.72%~-5.16% 일관 improve (단일 100% finalize)

시각: - 11 cell × 4 mode heatmap (sel=0.10, paired $\Delta\%$) - σ_i 신호 정량 (Cohen's $d < 0.1$, paired Wilcoxon $p > 0.5$)

Speaker note: "KM20 oracle 의 stratification 가치는 σ_i Neyman 이 아닌 cluster 분할 자체에서 나옵니다. 이는 4 강 method (Hilbert/Hybrid/MiniBatch_partial/HDBSCAN) 가 σ_i 정보 없이도 효과를 만드는 mechanism 입니다."

S8 — RQ3 Phase 1: 가지치기 funnel (33 → 16 살아남기 → 4강 → production-friendly 1)

제목: RQ3 — 33 method 시도 → Tier 1 살아남기 16종 → 4강 → production-friendly 1

핵심 message: - W4 sprint 측정: 30 method (16 base + 9 NEW9 + Wave 1 7종) × 10 cell (5 dataset × sf1/sf10) = 1500 measurement - **5/8 14:13 가지치기 결과 단일 100% finalize** (master_v6 §10): - **Wave 0 (variance explosion outlier):** dbscan / lsh / random_proj — paired $\Delta\%$ +261245% / +2092% / +434% → 즉시 제외 (3종) - **Tier 1 (강력 일관, 17종):** hdbscan / pca_kmeans / coresets / zorder / kmeans_pp / faiss_ivf / minibatch_partial / minibatch / gmm / hilbert / pca1d / agglomerative / hybrid / hierarchical_kmeans / sparse_rp / kdtree / reservoir (avg -8.04 ~ -6.78, neg $\geq 8/10$, CI excludes 0 $\geq 7/10$) - **Tier 2 (boundary, 2 종):** birch (avg -6.33), kde_pilot (-3.03) - **Tier 3 (특수, 1종):** pq (sign 절반) - **Pruned (7종):** sobol / hammersley / halton / spectral / distance_shell / optics / importance_sampling - **funnel narrative:** 30 → Wave 0 outlier 3 제외 → Tier 1+T2 살아남기 **19종** (T1 17 + T2 2) → **4강 (production criteria 결정)** → ★3 hilbert (production-friendly 1)

시각: - funnel chart: **30 → 19 살아남기 → 4강 → production-friendly 1** - 살아남기 vs 가지치기 narrative card 2종 (Tier 1 17종 강력 일관 + Wave 0 outlier 3종) - 단일 10 cell × 30 method 매트릭스 (paired $\Delta\%$ color heatmap)

Speaker note: "본 연구는 학술적 기여로 30 method 광범위 시도 + 가지치기 framework 을 제시합니다. 결정적 발견은 Tier 1 = 17종 살아남기 (avg $\Delta\%$ -8.04 ~ -6.78) 의 spread 1.21%p 만이라는 점 — **method choice 의 차이는 작고, 분포 정보 인지 vs 미인지 boundary 가 결정적.** 4강은 그 중 production cost 차별화 + cell 별 1 위 횡수 + interpretability 기준의 대표 4종입니다."

S9 — RQ3 Phase 2: 4강 method 결정 (production criteria) + 1.24%p spread 메시지

제목: 4강 결정 (★1 hdbscan / ★2 hilbert / ★3 minibatch_partial / ★4 hybrid) + Tier 1 spread

핵심 message: - 가지치기 기준 (단일 10 cell 100% 측정 기준): 1. avg $\Delta\% \leq -5.0\%$ + neg_cells $\geq 7/10$ + CI excludes 0 $\geq 7/10$ → **Tier 1** 2. avg $\Delta\% \leq -3\%$ + 단일 dataset family 강력 → **Tier 2** 3. avg $\Delta\% \leq -1\%$ + sign 불일관 + unique narrative → **Tier 3** 4. avg $\Delta\% > -1\%$ OR sign 반대 → **Pruned** 5. |avg $\Delta\%$ | $\geq 100\%$ variance explosion → **Wave 0**

- 4강 method = production criteria 결정 (cell 별 1위 횟수 + cost 차별화 + interpretability, 단일 100% 기준):

Rank	Method	avg_Δ%	1위 cell	production cost	차별화 narrative
★1	hdbscan	-8.04	SIFT_sf1 (-34.17) avg 1위	무거움 (4313s)	strongest narrative — avg 1위 + SIFT 1위. oracle 영역 (production X)
★2	minibatch_partial	-7.63	(CI 9/10)	online (partial_fit)	OLTP narrative 유일. CI 9/10 강력 일관
★3	hilbert	-7.54	SIFT_sf1 (-33.53), YFCC_sf10 (-5.21)	매우 빠름 (수 초)	production sweet spot — space-filling curve. CI 9/10
★4	hybrid (MB+Hilbert)	-7.13	(combined ablation)	balanced	mechanism narrative — Hilbert 효과 분리 ablation

- 핵심 메시지 (학술 contribution): Tier 1 spread = 1.21%p (-8.04 ~ -6.83) — Tier 1 내부 method choice 차이는 작음. 분포 정보 인지 vs 미인지 boundary 가 결정적. 본 연구의 RQ3 답 = "어느 분포 인지 method 든 Tier 1 이면 OK, 4강 = 대표".

시각: - 4강 method × production 특성 표 (학습 시간 / Deterministic / Online OK / interpretability) - 10 cell heatmap (4강 × cell, paired Δ% color) - Tier 1 spread 1.21%p callout (메시지 강조)

Speaker note: "4강은 학습 cost / online 가능 여부 / interpretability 의 production criteria 로 differentiated 된 대표 method 입니다. ★1 hdbscan = strongest narrative (oracle, avg 1위 -8.04%), ★2 minibatch_partial = OLTP narrative 유일, ★3 hilbert = production sweet spot (가장 빠름, CI 9/10), ★4 hybrid = ablation narrative. 결정적 메시지는 Tier 1 spread 1.21%p — method choice 보다 분포 인지가 결정적."

S10 — Distribution Sweet Spot — imbalanced vs balanced

제목: 4강 method 의 distribution sweet spot — sweet vs ceiling (PDX SIGMOD 2025 학술 confirmation)

핵심 message: - Imbalanced (low intrinsic dim) → sweet spot: - SIFT skew: -32% (best gain) - WIKI 768d: -7~-10% - YFCC PCA 192d: -5~-7% - Balanced (SSN++ ceiling) → method gain 0~hurt: - SSN_sf1/sf10: +1.4~+2.3% hurt (outlier) - **학술 confirmation — PDX [Kuffo et al., SIGMOD 2025, CWI Amsterdam, arXiv:2503.04422]:** - "normally distributed datasets are more challenging to prune than skewed datasets" (10 benchmark) - "intrinsic dimensionality and skewness metrics should govern algorithm selection rather than fixed parameter tuning" - 본 연구의 cluster_ratio + intrinsic_dim_ratio metric 과 PDX 의 skewness + intrinsic_dim metric 정확 일치

시각: - 12 cell scatter plot: cluster_size_ratio (x) × intrinsic_dim_ratio (y) → 색=Δ% - 정량 boundary: cluster_ratio < 1.3 + intrinsic_dim_ratio > 0.85 영역 = ceiling - PDX 결론 callout (SIGMOD 2025) — 동일 hypothesis 의 학술 confirmation

Speaker note: "본 연구의 4강 method 가 적용되는 distribution sweet spot 의 정량 boundary 입니다. 모든 distribution 에서 universal improve 하지는 않습니다. 동일 hypothesis 가 SIGMOD 2025 PDX 논문 (Kuffo et al., CWI Amsterdam) 에서 10 benchmark 로 학술 confirmation 받았다는 점이 본 결론의 robustness 를 보강 합니다."

S11 — SSN++ Ceiling 가설 (Pillar 1-2)

제목: SSN++ Ceiling — vector norm + intrinsic dim

핵심 message (4 pillar 분석 중 1-2):

Pillar 1 — Vector norm distribution: - SSN++ norm CV = **0.0049** (SIFT 0.0932 의 1/19) - mean 1778 ± 8.8 의 좁은 sphere shell — norm 차원 분리 신호 거의 없음

Pillar 2 — PCA intrinsic dim: - SSN++ effective dim ratio (90% var) = **0.8828** (DEEP 0.6771 / SIFT 0.6406) - 거의 모든 dim 이 의미있는 정보 운반 (near-isotropic)

시각: - Pillar 1: norm distribution histogram (SSN++ vs SIFT vs DEEP) - Pillar 2: PCA cumulative variance curve (dim_for_50/80/90/95% per dataset)

Speaker note: "SSN++ (Facebook SimSearchNet++) 는 사전 훈련 + L2 normalization 으로 이미 well-spread + near-isotropic 영역입니다."

S12 — SSN++ Ceiling 가설 (Pillar 3-4) + Negative Control

제목: SSN++ Ceiling — KMeans cluster + BERN baseline

핵심 message (4 pillar 중 3-4):

Pillar 3 — KMeans cluster size + sigma: - SSN++ cluster_ratio = **1.25** (DEEP 2.97 / SIFT 4.67 의 1/3) - σ_{CV} = **0.0016** (SIFT 0.1008 의 1/55) - 모든 cluster 거의 동일 크기 + 분산

Pillar 4 — BERN baseline qerr ceiling: - SSN_sf10 sel=0.10 BERN qerr = **1.1394** (8 cell 중 최저) - KM20 improvement headroom = **0.5%** (SIFT_sf1 의 1/70)

시각: - Pillar 3: KMeans cluster size barplot (12 cell) - Pillar 4: KM20/BERN ratio table (improvement headroom)

Speaker note: "SSN++ ceiling 은 method buggy 가 아니라 distribution sweet spot 의 자연스러운 boundary case — 본 연구의 negative control narrative 입니다."

S13 — Multi 3 cell (multi-vector + multi-table-join 4강 일반화, 5/8 17:50 STAGE 1+2+3 완료)

제목: Multi 3 cell — 단일 → multi 25.2× shrinkage (필요조건 정량화)

핵심 message:

핵심 정량 (5/8 STAGE 1+2+3 완료, 4강 method × multi 3 cell × sel=0.10)

- 단일 sweet spot 4강 평균 $|\Delta\%| = 17.13\%$ (SIFT_sf1 / WIKI_sf1 / YFCC_sf1)
- multi-vector 4강 평균 $|\Delta\%| = 0.67\%$ (deep_sift_10 + deep_wiki_10)
- multi-table-join 4강 평균 $|\Delta\%| = 0.68\%$ (partsupp_deep_10 ⋈ part_wiki_10, 8M JOIN, FK 4-to-1)
- → **25.2× 약화** (magnitude shrinkage) — 단일 정확성은 multi 정확성의 **필요조건만 성립** (충분조건 X)
- multi-vector ≈ multi-join → shrinkage 발생 지점 = "vector 수 증가" 단계, table join 단계 추가 약화 없음

Cell 별 4강 paired $\Delta\%$ (sel=0.10)

Cell	Type	4강 paired $\Delta\%$ (hdb / hil / hyb / mb_p)	부호
partsupp_deep_sift_10 (96+128 dim)	multi-vector	-1.02 / -0.48 / +0.31 / -1.30	3/4 negative
partsupp_deep_wiki_10 (96+768 dim)	multi-vector	+1.15 / +0.06 / +0.08 / +0.99	0/4 negative (boundary)
partsupp_deep_10⋈part_wiki_10 (8M JOIN)	multi-table join	+0.29 / -0.85 / -0.22 / +1.38	2/4 negative

- **multi-vector**: 4강 method 의 ranking 노이즈 수준 와해 ($|\Delta|$ 모두 < 1.5%)
- **multi-table join**: 5/8 17:50 측정 완료. multi-vector 와 동일한 magnitude shrinkage 영역 (0.68% ≈ 0.67%). ranking 단일과 거의 역순 (hilbert > hybrid > hdbscan > mb_partial)
- **narrative**: 단일 → multi-vector → multi-join 25.2× shrinkage 가 본 연구의 **outer boundary** 정량화. multi-relation 일반화는 **joint-aware clustering** 또는 **multi-vector decomposition** 별도 설계 필요 (future work)

보조 자료 (KM20 mode ablation, 5/8 AM agent)

- 3 cell × 3-4 KM20 mode (emb1/emb2/concat/product) × 5 sel paired CI — 단일 12 cell + multi 3 cell = 15 cell 매트릭스

- raw: `cache/rq3/multi_4kang_partsupp_deep_{sift,wiki}_10.parquet` + `cache/rq3/multi_4kang_join_deep_wiki.parquet` (4강 일반화 multi 3 cell) + `rq2_partsupp_deep_{sift,wiki}_10_4way.parquet` + `rq2_multi_join_deep_wiki.parquet` (KM20 ablation)

시각: - 4강 method × 3 multi cell grouped bar (sel=0.10) + 단일 sweet spot reference -17.13% horizontal line - multi-vector vs multi-join magnitude 거의 동일 (0.67 ≈ 0.68) 시각 강조 - 차트 source: `build_charts_5_8.py:build_s11()`

Speaker note: "본 연구의 *outer boundary* — 단일 정확성이 multi 정확성보다 25.2배 강한 magnitude 를 보입니다. 단일 sweet spot (-7~-32%) 이 multi-vector 영역에서 0.67%, multi-table-join 영역에서 0.68% 노이즈 수준으로 약화되어, '단일 정확성은 multi 정확성의 필요조건이지 충분조건이 아니다' 가 정량 입증됩니다. multi-vector 와 multi-table-join 의 magnitude 가 거의 동일 — shrinkage 의 발생 지점은 'join 자체' 가 아닌 'vector 수 증가' 단계 입니다. multi-relation 일반화는 joint-aware clustering 또는 multi-vector decomposition 별도 설계가 필요한 future work 입니다."

S14 — Honest Limitations (9종)

제목: 한계 9종 — honest reporting

핵심 message:

#	Limitation	대응
1	단일 → multi-table generalization	partsupp_deep_sift / multi-join 부분 입증
2	NPY-only mode RQ2 dependency	적재본 부재 시 RQ2 skip
3	YFCC source 단일화 결정 (build_yfcc 폐기)	채림 정보 단일 source, sf100 BigANN 동일 source 통일
4	σ_i 신호 약함	Wilcoxon $p>0.5$, $d<0.1$
5	IS NaN sel=0.01 발산	Negative control narrative
6	K-sweep upper bound K=200	K>200 영역 future work
7	sf100 (80M) deferred	5/8 회의 후 launch
8	Effect size dataset 별 격차	dataset 별 separate reporting
9	SSN++ ceiling distribution boundary	method sweet spot 정량 boundary 정직 입증

시각: - 9 limitation 표 + 각 future work link

Speaker note: "9 limitation 모두 future work 으로 link 됩니다. 특히 #9 SSN++ ceiling 은 본 연구의 negative control 핵심입니다."

S15 — sf100 진행 + Cross-Scale Validation + YFCC 단일 정보 결정 (5/8 10:35 갱신)

제목: sf100 (80M) 진행 + Cross-Scale Validation + YFCC 단일 정보 결정

핵심 message: - 5/8 회의 후 자문 합의 → 5/15 자문 회신 → ~5/22 sf100 launch - **DEEP/SIFT/SSN sf100 적재 완료** (101/121/208 GB) — 즉시 측정 가능 - WIKI sf100 build (240 GB 추가 필요, 채림 측 협의) - **YFCC source 결정 (5/8 10:35 finalize):** - 채림 적재본 단일 정보 채택 (`partsupp_yfcc_{1,10}` , BigANN base.10M.u8bin) - build_yfcc.py 자체 다운로드/추출 chain **폐기 완료** (raw fbin 40GB + PG 15GB + parquet 119개 회수, 5/8 10:35) - **sf100 = 채림 측에 정보 요청** (자체 다운로드 X) — source 일관성 + 다운로드 부담 회피 - ETA: 자문 회신 후 launch (~5/22)

시각: - sf100 plan timeline (5/8 회의 → 자문 → 채림 정보 요청 → launch → 5/27) - sf1/sf10/sf100 cross-scale validation 매트릭스 (채림 정보 단일) - YFCC 단일 정보 결정 callout (자체 다운로드 폐기 → 채림 정보 단일 source)

Speaker note: "sf100 결과는 5/27 발표에 추가되어 cross-scale validation (sf1↔sf10↔sf100) 일관성을 완성합니다. YFCC sf100 은 채림 측 정보 적재본을 요청하여 sf1/sf10 과 동일한 BigANN benchmark source 로 단일 narrative 를 유지합니다 (자체 다운로드 부담 회피)."

S16 — Future Work

제목: Future Work — Exqutor 일반화 + Distribution Shift + PDX 통합

핵심 message: 1. **sf100 cross-scale validation 완성** (~5/22) 2. **추가 method 7 후보 탐색** (Halton/Hammersley/Stratified Halton/Reservoir/Density-stratified/Affinity Propagation/Mean Shift) 3. **Exqutor multi-table 영역 일반화** (joint-aware clustering) 4. **K>200 K-sweep** (WIKI 768d / SSN++ 256d high-dim) 5. **Distribution shift detection** (production online detection) 6. **vector.c C-level integration** (Phase 6 SQL D 영역) 7. **PDX (SIGMOD 2025) 통합 — end-to-end skewness-aware vector pipeline:** - PDX [Kuffo, Krippner, Boncz, CWI Amsterdam, *PDX: A Data Layout for Vector Similarity Search*, arXiv:2503.04422]: vector similarity search **compute** layer (dimension-partitioned vertical storage + PDXsearch START/WARMUP/PRUNE adaptive 3 phase + PDX-BOND query-aware dimension ordering, 2~7× speedup) - 본 연구: **pre-process** layer (KM20 oracle + 4강 method 분포 인지 sampling) - 통합: PDX dimension-partitioned compute + 본 연구 분포 인지 sampling = **end-to-end skewness-aware vector pipeline** — sample 분배부터 retrieval 까지 동일 metric (intrinsic_dim + cluster_ratio) 으로 일관 분포 인지

시각: - 7 future work × 일정 timeline (caption) - Exqutor + PDX 본 연구 매핑 표 (compute layer / pre-process layer / index layer)

Speaker note: "본 연구는 단일 테이블 비인덱스 영역의 sample 분배 가치 정량화에 집중했습니다. 본 framework 은 Exqutor multi-table 영역으로 일반화 가능하며, SIGMOD 2025 의 PDX (CWI Amsterdam) 와 통합하여 end-to-end skewness-aware vector pipeline 을 future work 으로 제안합니다 — PDX 가 compute layer 를 분포 인지로 최적화하고 본 연구가 pre-process layer 를 분포 인지로 최적화하므로, 두 contribution 은 정확히 complementary 합니다."

S17 — Thanks + Q&A

제목: Thanks — Q&A

핵심 message: - 채림 석사님 (서버 환경 + vanilla_sf100 적재본 지원) - 지도교수님 (research framework 자문) - 팀 (속도는벡터): 박세은·강재현·조현빈·이동욱

시각: - 팀 사진 또는 로고 - 자료 링크 (GitHub, 보고서, 발표자료)

Speaker note: "감사합니다. 질문 받겠습니다."

§3. 부록 슬라이드 (Optional Backup, 1-3 슬라이드)

Backup 1 — 다음 30 method 측정 가지치기 결과 (5/27 시점)

제목: 5/27 시점 method 가지치기 — 35 후보 → 4 winner

시각: - 35 method × tier 통과 표 (8 살아남기 기준 적용) - Halton/Hammersley/Stratified Halton/Reservoir/Density-stratified/Affinity Propagation/Mean Shift 의 후속 측정 결과 (5/15~5/22)

Backup 2 — RQ1 단조성 11 cell ρ 상세

11 cell × Spearman ρ + bootstrap CI raw 표.

Backup 3 — RQ2 5mode × 11 cell paired $\Delta\%$ (sel=0.01/0.05/0.10/0.30/0.50)

11 cell × 4 mode × 5 sel = 220 measurement raw 표.

§4. academic v3 deck 양식 정밀 재현 — 95%+ 정합

양식 spec (academic v3 zip + index.html 분석)

색: - Navy accent: #2c3e50 (HSL 210, 29%, 24%) - White background: #ffffff - Gray text: #6b7280

Font: - 표지/제목: JetBrains Mono v2.304 + tight letter-spacing -0.03em - 본문: Pretendard Variable v1.3.9 (한글) + Inter v4.0 (영문 mix) - mono label: JetBrains Mono (badge / numbered list)

Layout: - 16:9 aspect ratio (1920×1080) - numbered badge (S1-S17) - single system (DARK hybrid 금지, magazine 양식 금지)

5/27 deck 빌드 process

1. 자료 finalize: yfcc_sf10 retry 완료 (~16:00) + multi 3 cell narrative 완성 + sf100 결과 통합 (~5/22)
2. academic_deck_5월27일발표/index.html 빌드 (academic_deck_v3_source 양식 기반, 17 slides)
3. 차트 재출력: build_charts_5_27.py (S6/S8/S10/S11/S14 차트 갱신, S12 SSN++ ceiling 차트 추가)
4. build_native_pptx_5_27.py 빌드: 1865 lines + 기존 spc_em + add_chart_image 헬퍼 재사용
5. PDF/HTML/image.pptx 재생성: LibreOffice headless 또는 Keynote export
6. 시각 검증 (5/26): Pretendard 한글 렌더링 + tight letter-spacing + 차트 위치 검증

§5. 가지치기 narrative 의 핵심 메시지 (5/27 발표)

"본 연구는 학술적 기여로 35 method 의 광범위 비교 + 가지치기 framework 을 제시합니다. 4 winner (Hilbert / Hybrid / MiniBatch_partial / HDBSCAN) 는 distribution sweet spot 영역에서 production-ready 대안입니다. 단, SSN++ 와 같은 well-spread + balanced + high intrinsic dim 영역에서는 BERN ceiling 으로 method gain 0 또는 hurt direction 으로 표시되는 것이 자연스러우며, 이는 본 연구 method 의 적용 boundary 를 정량 입증한 negative control 입니다. 35 method 가지치기 framework 은 Exqutor 본 논문의 multi-table 영역 일반화 + Distribution shift detection + vector.c C-level integration 의 future work 으로 link 됩니다."

§6. 살아남는 method 후보 + 가지치기 결과 (5/8 14:13 단일 100% finalize)

5/8 14:13 가지치기 결과 (master_v6 §10 — 30 method × 10 cell 100% 종합 매트릭스)

Wave 0 (즉시 outlier, variance explosion) — 측정 instability 수준의 outlier: - dbscan (avg +261245%), lsh (+2092%), random_proj (+434%) → 3종 즉시 제외

Tier 1 (강력 일관 살아남기, 17종) — avg_Δ% -8.04 ~ -6.78 / neg_cells ≥ 8/10 / CI excludes 0 ≥ 7/10:

Rank	Method	avg_Δ%	neg_cells	CI_excl
1	hdbscan	-8.04	8/10	8/10
2	pca_kmeans	-8.02	8/10	8/10
3	coresets	-7.84	8/10	8/10
4	zorder	-7.83	8/10	8/10
5	kmeans_pp	-7.72	8/10	9/10
6	faiss_ivf	-7.71	8/10	8/10
7	minibatch_partial	-7.63	8/10	9/10
8	minibatch	-7.62	8/10	7/10
9	gmm	-7.60	8/10	7/10
10	hilbert	-7.54	8/10	9/10
11	pca1d	-7.35	8/10	8/10
12	agglomerative	-7.24	8/10	9/10
13	hybrid	-7.13	8/10	8/10
14	hierarchical_kmeans	-7.11	8/10	7/10
15	sparse_rp	-6.91	8/10	8/10
16	kdtree	-6.83	8/10	9/10
17	reservoir	-6.78	8/10	7/10

핵심 메시지: Tier 1 spread = **1.21%p (-8.04 ~ -6.83)** — 내부 method choice 차이 작음. 분포 정보 인지 vs 미 인지 boundary 가 결정적.

Tier 2 (boundary, 2종) — Tier 1 boundary: - birch (avg -6.33, neg 8/10, CI 7/10) — sign 강하나 magnitude T1 미달 - kde_pilot (avg -3.03, neg 8/10, CI 8/10) — magnitude 약 + SSN/YFCC hurt

Tier 3 (특수, 1종) — sign 절반: - pq (avg -2.15, DEEP/SSN sign positive, SIFT/WIKI/YFCC negative — sweet spot 의 부분 SURVIVE)

Pruned (가지치기, 7종) — sign 반대 OR magnitude 약:

Method	avg_Δ%	가지치기 사유
sobol	+0.18	sign 절반, SSN +16~+22% 큰 hurt
hammersley	+0.22	low-discrepancy, SSN +18% hurt
halton	+0.46	low-discrepancy, SSN +19% hurt
spectral	+0.76	WIKI sf10 +25% 큰 hurt
distance_shell	+4.82	모든 cell uniform hurt direction
optics	+12.50	SSN +43~+49% 강력 반대
importance_sampling	+49.42	모든 cell +33~+79% 강력 hurt (분할 X invalid)

4강 method 결정 (production criteria, 단일 100% 기준)

17종 Tier 1 中 (1) cell 별 1위 횟수 (2) production cost 차별화 (3) interpretability 기준:

Rank	Method	avg_Δ%	1위 cell	production cost	차별화 narrative
★1	hdbscan	-8.04	SIFT_sf1 (-34.17) avg 1위	무거움 (4313s)	strongest narrative — avg 1위 + SIFT 1위. oracle 영역
★2	minibatch_partial	-7.63	(CI 9/10 강력)	online (partial_fit)	OLTP narrative 유일
★3	hilbert	-7.54	SIFT_sf1 (-33.53), YFCC_sf10 (-5.21)	매우 빠름 (수 초)	production sweet spot — space-filling curve, CI 9/10
★4	hybrid (MB+Hilbert)	-7.13	combined ablation	balanced	mechanism narrative — Hilbert 효과 분리 ablation

Distribution Sweet Spot 정량 boundary (§10.5)

- **Sweet (improve -7~-32%):** cluster_ratio > 1.4 AND intrinsic_dim < 0.85 → SIFT (1.65 / 0.71), WIKI (1.84 / 0.81), YFCC (~1.5 / ~0.85), DEEP (1.43 / 0.78 — boundary smaller magnitude)
- **Ceiling (effect 약, ±2%):** cluster_ratio < 1.4 AND intrinsic_dim > 0.85 → SSN++ (1.29 / 0.88) — uniform-like distribution

5/8 회의 합의 사항

1. 4강 method 선정 confirm (★1 hdbscan / ★2 minibatch_partial / ★3 hilbert / ★4 hybrid)
2. Tier 1 = 17종 narrative 합의 — RQ3 의 답 = "어느 분포 인지 method 든 Tier 1 이면 OK, 4강 = 대표"
3. SSN++ ceiling honest reporting confirm
4. Multi 일반화 future work 합의

Raw 산출: [_internal/_w4_partial_summary.csv](#) (1500 rows × 30 method × 10 cell, analyze_10cell_w4.py 재계산).

§7. 5/27 발표 본 deck 빌드 일정 (5/8~5/27)

일정	마일스톤	작업
5/8 19:00	회의 자료 ready	본 plan + master_v6 + PPTX 검토
~5/15	자문 회신 ETA	채림 + 지도교수 회신
5/15~5/22	sf100 측정 launch	DEEP/SIFT/SSN sf100 + WIKI build
5/15~5/22	추가 method 7 후보 측정	가지치기 기준 합의 후 launch
5/22	교수님 미팅	sf100 결과 + narrative 검토
5/22~5/26	5/27 deck 빌드	academic v3 양식 95%+ 재현
5/26	발표자료 최종 마감	시각 검증 + dry run
5/27	★ 최종 발표 (D-19)	17 슬라이드 × 12분
5/28	전시회 자료 마감	포스터 + demo
6/11	최종 보고서	80+ pages 학술 산문

작성: 2026-05-08 11:50 KST · W4 sprint 12 cell finalize + 가지치기 + 4강 결정 (master_v6 §10) 반영 **작성**
모델: Claude Opus 4.7 1M, 통합 manager session **선행 doc:** - [submission/_drafts/속도는벡터_5월8일회의_PPT_outline.md](#) (5/8 회의 PPT 15 slide outline) - [submission/_drafts/academic_deck_v3_source/academic-deck/index.html](#) (양식 reference) - [experiments/results/10cell_narrative_종합_20260508.md](#) (10 cell 정제 요약, 5/8 10:18 build_yfcc 폐기 갱신) - [experiments/results/RQ1_RQ2_RQ3_종합_master_v6_draft_filled_partial.md](#) §10 (가지치기 + 4강 결정 종합 매트릭스)

5/8 10:18 KST 갱신: 메인 narrative 재정의 (10 cell + multi 3 cell 부록), build_yfcc 다운로드 폐기 결정 반영 (§S5 매트릭스 / §S15 sf100 plan / §S14 limitation #3 갱신). 자체 build YFCC_DL 적재본 폐기 → 채림 정보 단일 source.

5/8 11:50 KST 갱신: §S8 funnel narrative (33 → 16 살아남기 → 4강 → production-friendly 1) + §S9 4강 결정 + §6 가지치기 결과 + Distribution Sweet Spot 정량 boundary.

5/8 14:13 KST 단일 100% finalize 갱신 (본 갱신): YFCC_sf10 fill (4강 -4.78~-5.77%) + 가지치기 30 method × 10 cell 100% 재계산 (analyze_10cell_w4.py, query_id paired alignment, 1000-vs-500 broadcast bug fix) + 4강 ranking 갱신 (★1 hdbscan -8.04 / ★2 minibatch_partial -7.63 / ★3 hilbert -7.54 / ★4 hybrid -7.13) + Tier 1 spread 1.21%p. 단일 narrative 100% finalize.

5/8 17:50 KST multi 3 cell finalize 갱신: §S13 4강 × multi 3 cell 완료 (multi-vector 2 cell + multi-table-join 1 cell). 단일 17.13% → multi-vector 0.67% → multi-join 0.68% shrinkage chain 25.2× 확정. multi-vector 와 multi-join magnitude 거의 동일 → shrinkage 발생 지점 = "vector 수 증가" 단계.

다음 갱신 예정: sf100 측정 결과 (~5/22) → §S15 / §S16 / §6 갱신.