

# 분포 인지형 stratification 으로 Exqutor 보강하기

Skew-Aware Stratification for Vector Cardinality Estimation

## TEAM

속도는벡터

박세은 · 강재현 · 조현빈 · 이동욱

## ADVISOR

박광현 교수

BDAI 연구실

## BASE PAPER

Exqutor

arXiv:2512.09695v2

# 01 배경

Exqutor 논문이 명시한 한계와 본 연구의 출발점

## 1. Exqutor 논문이 명시한 한계

03 / 18

// Adaptive Sampling estimator 의 정확도는  
sampling 방식 자체의 **분포 의존성**에 제약된다.

원 논문 §V-B Adaptive Sampling 영역 – 인덱스 부재 시 Bernoulli random sampling 으로 카디널리티 추정.  
sample budget  $N=385$  + 모멘텀 기반 동적 조정 (Eq 1-6) 으로 paper 가 명시한 한계.

## 1. 우리가 잡은 주제

04 / 18

# 분포를 알 때 / 모를 때 **모두** 에서 더 정확한 sampling 방식을 찾는다

원 논문이 명시한 sampling 한계 → 분포 인지형 stratification 으로 보강 가능한가?

# 02 연구 질문

RQ1 · RQ2 · RQ3 — 분포 인지의 단계적 검증

## 2. 세 단계 연구 질문

06 / 18

BASELINE

### RQ1

Random sampling 이 skew 데이터셋에서 얼마나 부정확한가?

Bernoulli 단일 vs KM20 stratified

속도는벡터 · 박세은 · 강재현 · 조현빈 · 이동욱

KNOWN DISTRIBUTION

### RQ2

분포를 알 때 어떤 allocation 이 최적인가?

Bernoulli / Equal / Proportional /  
Neyman / Anti-Neyman

UNKNOWN DISTRIBUTION

### RQ3

분포를 모를 때 어떤 알고리즘이 최적인가?

8 paradigm × 56 method

FINAL 5\_27 · v3

## 2. RQ1 — random sampling 의 부정확함

07 / 18


**+3.74%**

**Bernoulli 단일 vs KM20 stratified mean gap**

DEEP / SIFT / SimSearchNet++ × sf=100 · 5 cells × 5 trials · 분포 인지 stratification 의 출발점

## 2. RQ2 — 분포를 알면 Proportional 이 답

08 / 18



Bernoulli → Proportional **-9.53%** · 분포 정보 활용 시 추정 안정성 정량 입증



## 2. RQ3 — 분포를 모를 때

09 / 18

**실제 환경에서는 분포를 모른다.**  
**→ 분포를 추정하는 알고리즘이 필요하다.**

8 paradigm 측면에서 분포 추정 알고리즘 search · 56 method portfolio 비교

# 03

## 알고리즘 Portfolio

8 paradigm × 56 method 비교 search

### 3. 8 paradigm × 56 method

|                                                                                    |                                                                   |                                                                         |                                                                          |
|------------------------------------------------------------------------------------|-------------------------------------------------------------------|-------------------------------------------------------------------------|--------------------------------------------------------------------------|
| <div><div>밀도 추정n=1</div><div>확률 밀도 함수 추정 (Parzen KDE)</div></div>                  | <div><div>정보 이론n=9</div><div>카디널리티 추정 (HyperLogLog)</div></div>   | <div><div>스트리밍n=44</div><div>weighted reservoir (Chao 1982)</div></div> | <div><div>차원 축소n=104</div><div>random projection (sparse RP)</div></div> |
| <div><div>공간 분할n=107</div><div>space-filling curve (Hilbert + Z-order)</div></div> | <div><div>균등 격자n=62</div><div>quasi-Monte Carlo (QMC)</div></div> | <div><div>클러스터n=87</div><div>k-means 계열 (MiniBatch)</div></div>         | <div><div>양자화n=53</div><div>vector quantization (PQ)</div></div>         |

총 56 method × 9 cells × 2 modes = 1001 file · paper exact 측정

# 04

## 실험 framework

Exqutor 재현 + 대체 (CaseA) vs 증강 (CaseB)

## 4. paper 재현 검증 anchor

13 / 18

**-4.3%**

**paper Fig.12 mean qe\_trim 재현 · 1.69 → 1.618**

8 cells · measurement variance 범위 내 일치 · paper exact 100% 정확 재현 입증

## 4. 대체 vs 증강 — 두 가지 적용 방식

14 / 18

CASEA · REPLACE

### 대체

$$\text{est\_final} = \text{est\_method}$$

paper Bernoulli baseline 을 우리 method 로 **단독 교체**

CASEB · AUGMENT

### 증강

$$\text{est\_final} = (\text{est\_b1} + \text{est\_method}) / 2$$


paper Bernoulli + 우리 method **산술 평균 ensemble**

두 방식 모두 **single + multi cell** 전반에서 비교

AdaptiveState (Eq 1-6) + sample budget N=385 paper exact 보존

## 4. Paradigm rollup — CaseB 증강 효과

15 / 18



negative = 증강 후 정확도 개선 · 5 paradigm 통계적으로 압도 ·  $1.06\times \sim 1.14\times$  `qe_trim` 정확도 향상

## 4. 가장 우수 알고리즘 5선

밀도 추정

-11.93%

Parzen KDE

PARZEN 1962

데이터 점 주변 kernel 함수로 PDF 추정 → cluster 분포를 부드럽게 추정

정보 이론

-7.60%

HyperLogLog

FLAJOLET 2007

hash leading-zero 분포로 distinct count 추정 → 1.5KB 로 cardinality 근사

스트리밍

-6.63%

Chao weighted

CHAO 1982

weighted reservoir sampling → stream 환경에서 분포 비례 sample

차원 축소

-6.03%

Sparse RP

LI · HASTIE · CHURCH 2006

1/vD 희소 random matrix → 고차원을 저차원으로 (JL 보장)

공간 분할

-5.57%

Hilbert + Z-order

MORTON 1966

space-filling curve → 고차원 공간을 1D 로 보존, 인접성 유지



## 4. 대체 vs 증강 — 결정적 비교

17 / 18

CASEA · REPLACE

0 / 493

outperform 0 cell

Bernoulli 단독 교체 시 단 하나도 우위 X  
→ 단독 대체 무효

CASEB · AUGMENT

92.5%

paired better (455 / 492)

증강이 거의 모든 cell 에서 paper baseline 우위  
→  $p < 1 \times 10^{-45}$

단독 대체 X → 증강 적용 만 유효

paper review-grade evidence · Cliff's  $\delta$  large 63.0% · Hedges'  $g$  large 55.7%

# 감사합니다

질문 환영합니다