

연구 지도 확인서

2026-1학기 종합설계프로젝트 — 속도는벡터 2026-05-08 작성 (v3 — RQ3 paradigm framework 학술
정합성 정정 반영)

항목	내용
팀명	속도는벡터 (인증설)
소속	연세대학교 컴퓨터과학과
연구 주제	Exqutor 기반 단일 테이블 벡터 범위 쿼리에서의 분포 인식 샘플링 연구
원논문	Exqutor — Extended Query Optimizer for Vector-augmented Analytical Queries (arXiv:2512.09695v2)
작성일	2026-05-08 (v3)
제출자	박세은 (팀장)
지도 석사	임채림
지도 교수	(성함)

1. 5/5 회의 이후 5/8 까지의 진행 사항

지난 5월 5일 비대면 회의에서 RQ 구조를 RQ1 (Normal vs Skew 정량 비교) / RQ2 (분포 인지 시 최적 방식) / RQ3 (분포 미인지 시 최적 방식) 의 3-tier 로 재정립한 이후, 5월 6일부터 5월 8일까지 사흘간 W1 sprint 를 진행 하였습니다.

RQ1 과 RQ2 는 SF1 (800K) 과 SF10 (8M) 두 데이터 규모에서 측정을 완료하였으며, RQ3 는 실험에 진행할 분 포 미인지 sampling method 의 후보군을 학술 출처 검토를 통해 5 개 paradigm × 11 개 representative method 로 선정하는 단계까지 진행하였습니다. 5/8 저녁에는 학술 정합성 심층 검증을 추가로 수행하여 paradigm naming 과 representative 선정의 학술적 근거를 정정·보강하였습니다. RQ3 의 본 측정은 W2 (5/9~5/15) 에 launch 예정이며, 본 확인서는 RQ1/RQ2 의 측정 결과 종합과 RQ3 의 paradigm framework, 그리고 향후 일정에 대한 자문을 요청드리는 자료입니다.

5월 8일 19시에 전원이 참가한 비대면 회의에서 박세은 팀장이 W1 sprint 결과를 정리하고 다음 세 가지를 W2 방향으로 합의하였습니다 — (가) Exqutor 원논문의 Adaptive Sampling 과의 정면 비교 실험 추가, (나) RQ3 본 측정 launch 와 multi-table 적용 확장, (다) 자문 회신 후 5월 27일 최종 발표까지의 추가 실험 우선순위 확정.

2. W1 sprint 결과 종합 (5/6~5/8)

2.1 RQ1 — Normal vs Skew 분포 직접 비교 (SF1-SF10 측정 완료)

5 개 dataset (DEEP 96d / SIFT 128d / SimSearchNet++ 256d / WIKI 768d / YFCC 192d) 의 SF1 (800K) 와 SF10 (8M) 두 규모에 대하여 selectivity 5 구간 ($s = 0.01, 0.05, 0.10, 0.30, 0.50$) 에서 BERN 의 q-error 와 분포 skew 지표 (HHI / cluster_ratio / intrinsic_dim) 간의 단조 상관 (Spearman ρ) 을 측정하였습니다. 10 개 single cell 모두에서 $\rho < 0$ 의 sign 일관성 100% 가 관찰되었으며, 대표 셀인 DEEP-KM20 의 $\rho = -0.680$ (95% CI [-0.800, -0.440], 0 제외) 으로 통계적 유의성도 확보되었습니다. 이는 "selectivity 가 좋아질수록 BERN 부정확도가 단조 증가하며, 이 경향이 skew 데이터에서 더 강하게 나타난다" 는 가설 H1 의 정량 증거입니다.

2.2 RQ2 — KM20 + Allocation Mode Ablation (SF1-SF10 측정 완료)

RQ1 과 동일한 5 dataset $\times$ 2 SF = 10 single cell 에 대하여 KM20 (K=20 cluster) 위에서 5 개의 sample allocation mode (BERN baseline / Proportional / Neyman / Anti-Neyman / Equal) 를 selectivity 5 구간에서 비교하였습니다. 분포를 알 때 stratification 의 효과를 확인한 결과 selectivity 0.10 구간에서 paired bootstrap 95% CI 가 0 을 제외하는 cell 비율이 매우 높게 (51/52 cell, 98.1%) 관찰되었으며, "분포를 알 때 KM20 기반 stratification 이 BERN 대비 강건한 우위를 갖는다" 는 RQ2 의 1차 결론에 도달하였습니다.

한편 5 개 mode 간의 q-error 격차가 1%p 미만인 cell 이 7/12 (58.3%) 에 달하여, **mode 선택보다 분포 인지 자체가 결정적**이라는 부수 발견을 확보하였습니다. Neyman vs Anti-Neyman 비교에서도 Neyman 의 우위는 평균 0.7%p 수준에 머물렀으며, 이로써 σ 정보의 marginal contribution 은 K=20 기준에서 제한적임을 확인하였습니다.

2.3 RQ3 — 실험 진행할 method 선정 단계 (paradigm framework 도출)

RQ3 는 본 측정에 앞서 학술 문헌 검토를 통해 분포 미인지 sampling method 의 후보군을 체계적으로 선정하는 단계를 거쳤습니다. 광범위한 후보 (~30 method) 를 검토한 후 inductive bias 의 학술적 근거에 따라 다음 5 개 paradigm 으로 분류하고, 각 paradigm 에서 1~3 개의 representative method 를 선정하였으며, 5/8 저널 학술 정합성 심층 검증 (ACM Computing Surveys 2024 의 clustering taxonomy + Wu UWisconsin 의 sampling-based cardinality estimation survey 와 cross-check) 을 통해 paradigm naming 을 다음과 같이 확정하였습니다.

Paradigm	Inductive bias	학술 출처	Representative
P1. Density Clustering	"유사 데이터는 군집을 이룬다"	MacQueen 1967 (KMeans) / Campello et al. 2013 (HDBSCAN)	HDBSCAN, MiniBatch K-means, GMM
P2. Space-Filling Locality	"고차원 → 1D mapping 후 quantile 분할"	Hilbert 1891 / Lawder-King 2001 (SIGMOD) / Faloutsos & Roseman 1989	Hilbert curve, faiss IVF
P3. Online Streaming	"OLTP 환경 = partial fit / single-pass"	Sculley 2010 (WWW Web-scale K-means) / Vitter 1985 (TOMS Reservoir)	MiniBatch_partial, Reservoir
P4. Linear Projection	"고차원 핵심 정보는 저차원 투영 보존"	Johnson-Lindenstrauss 1984 / Achlioptas 2003 (PODS/JCSS)	sparse RP, PCA1D
P5. Low-discrepancy / Quasi-random	"결정론적 균등 sampling 으로 random variance 감소"	Sobol 1967 / Niederreiter 1992 / Halton 1960	Sobol, Halton (baseline 검증용)

본 paradigm framework 의 의도는 "분포 정보 없이도 어떤 inductive bias 로 stratification 학습이 가능한가" 의 학술적 답변을 5 paradigm × 11 representative method 의 비교 매트릭스로 정량화하는 것입니다. 본 측정은 W2 (5/9~5/15) 부터 launch 예정이며, 측정 후 paradigm 별 효과 + production 적합성 (학습 비용 / online 적응성 / 해석 가능성) 을 비교하여 4 위 안의 representative 를 5월 27일 발표의 핵심 contribution 으로 보고할 계획입니다. 현재 단일 SF1·SF10 측정 결과로 도출한 4강 후보는 **HDBSCAN (P1, density)**, **MiniBatch_partial (P3, online streaming)**, **Hilbert curve (P2, space-filling)**, **sparse RP (P4, data-independent linear projection — Achlioptas 2003)** 로 5 paradigm 중 4 paradigm 의 distinct representative 가 1위씩 차지하는 학술 narrative 가 형성되어 있습니다.

다만 2.2 의 RQ2 결과가 "mode 선택보다 분포 인지 자체가 결정적" 이라는 부수 발견을 확보하였으므로, RQ3 본 측정에서도 method 간 격차보다는 paradigm 간 narrative 가 핵심 결과가 될 것으로 예상하고 있으며, 이는 본 확인서의 검토 요청 사항 (1) 과 (2) 항에 반영하였습니다.

3. 향후 일정 (5/9~6/11)

주차	기간	작업
W2	5/9~5/15	자문 회신 대기 + RQ3 paradigm framework 본 측정 launch + Adaptive Sampling baseline 측정
W3	5/16~5/22	발표자료 초안 작성 + 측정 결과 종합 + 5/22 교수님 미팅
W4	5/23~5/27	발표자료 finalize + 시연 리허설 + ★ 5/27 최종 발표
W5	5/28~6/4	최종보고서 drafting + 5/28 전시회 자료 마감
W6	6/5~6/11	최종보고서 finalize + ★ 6/11 제출

데이터 규모는 SF1 (800K) 과 SF10 (8M) 을 본 연구의 측정 범위로 고정하기로 합의하였습니다. SF100 (80M) 은 5월 27일 발표 전까지 단일 cell 측정에만 12시간 이상이 소요되어 가용 시간이 부족하며, 본 확인서의 검토 요청 사항 (4) 항에서 해당 가용성에 대한 자문을 함께 요청드립니다.

4. 본 연구의 contribution (5/8 update)

(1) **RQ1 — Normal vs Skew × Block vs Row 정량 비교**: 5 dataset × SF1·SF10 = 10 single cell 의 sign 일관 100%, DEEP-KM20 $\rho = -0.680$ [-0.800, -0.440] 의 통계 유의 단조 신호. 박세은 팀장이 제기한 연구 동기 ("normal 에서 잘되던 random 이 skew 에서는 안 나오더라") 의 정량 증거입니다.

(2) **Selectivity Gradient 분석**: 좁은 쿼리 ($s=1\%$) 에서 KM20 vs RANDOM20 격차가 19.6%p 에 달하며, 이는 Exqutor 원논문이 다루지 않은 영역입니다.

(3) **Two-Level Decomposition**: Level 1 (Proportional, K 등분의 표본 안정화 효과) 과 Level 2 (Spatial, 공간 구조 인식 효과) 의 분해 framework. RQ2 의 5-mode ablation 에서 mode 간 격차가 1%p 미만인 cell 이 58.3% 에 달하여, **Level 1 이 본 연구의 핵심 메커니즘임**이 정량 입증되었습니다.

(4) **RQ3 Paradigm Framework**: 분포 미인지 sampling 의 학술 후보군을 5 paradigm (Density Clustering / Space-Filling Locality / Online Streaming / Linear Projection / Low-discrepancy Quasi-random) 으로 체계화하고 각 paradigm 의 inductive bias 와 학술 출처 (1891 ~ 2018) 를 정리. 본 framework 자체가 "분포 정보 없이 어떤 학습이 가능한가" 에 대한 본 연구의 답변이며, 5/8 학술 정합성 심층 검증을 통해 ACM Computing Surveys 2024 와 Wu UWisconsin 의 standard taxonomy 와 align 함을 확인하였습니다.

(5) **PDX (SIGMOD 2025) 학술 confirmation**: 본 thesis 의 핵심 framing — "intrinsic_dim + skewness 가 algorithm selection 을 결정한다" — 와 정확히 일치하는 후속 학회 논문이 발표되었음을 5월 8일 회의에서 확인 하였습니다. PDX 는 compute layer (data layout for fast similarity), 본 연구는 pre-process layer (sampling 분배 전략) 로 complementary contribution 을 형성합니다.

5. Limitation 자기 점검

본 연구의 한계와 향후 연구 방향을 다음과 같이 명시합니다.

(1) RQ2 의 KM20 + Neyman 은 **oracle benchmark** 이며 production 솔루션이 아닙니다. 실제 운영 솔루션은 RQ3 의 distribution-agnostic method 이며, 본 연구의 가치는 분포 정보의 이론적 상한과 회수율을 정량화하는데 있습니다.

(2) 사전 계산 비용은 **one-time cost** 이며, 이는 HNSW 인덱스 빌드와 같은 layer 입니다 (DEEP 1M K=20: 1.2 초, 메모리는 HNSW 의 1/1000). 쿼리 응답 시점은 stratum_id lookup O(1) 입니다.

(3) **INSERT/UPDATE 빈번한 OLTP 환경**은 본 연구 범위 외이며, 본 연구는 analytical workload (bulk load + 다수 쿼리) 를 가정합니다. RQ3 의 P3 paradigm (Online Streaming, MiniBatch_partial 등) 이 이 부담을 1/20~1/100 수준으로 완화할 가능성이 있으나, 본격 OLTP 검증은 future work 입니다.

(4) **단일 → 멀티 테이블 일반화** 및 **RQ3 본 측정**은 W2 (5/9~5/15) 진행 예정이며, 본 확인서는 W1 sprint 의 RQ1/RQ2 finalize 와 RQ3 framework 도출까지의 결과를 보고드리는 자료입니다. 단일 테이블 정확성은 멀티 테이블 정확성의 필요조건이지 충분조건은 아니며, 멀티 테이블에서는 join key 분포·상관 등 추가 차원이 있어 별도 검증이 필요합니다.

(5) **누락 paradigm**: Sketch family (HyperLogLog Flajolet 2007 / Count-Min Cormode-Muthukrishnan 2005) 는 cardinality estimation literature 의 standard 한 축이나, 본 연구가 *stratum* 학습 (sampling 위에 올리는 framework) 이지 distinct count 가 아니므로 architectural mismatch 로 별도 paradigm 으로 다루지 않았습니다. Graph-based ANN (HNSW Malkov 2018) 은 Exqutor 원논문이 ECQO 로 처리한 영역으로 본 연구의 인덱스 부재 scope 외이며, 두 영역 모두 future work 로 명시합니다.

(6) **누락 method**: P5 의 LSH (Indyk-Motwani 1998) 는 hashing-based ANN 의 representative 이나 본 연구 K=20 stratification 에 hyperparameter mismatch 로 Wave 0 측정에서 fail 하였으며, 이로써 P5 paradigm 은 "Low-discrepancy / Quasi-random" 단일 inductive bias 로 통일하였습니다 (LSH 는 future work 의 hyperparameter tuning 영역). Mean-Shift (Comaniciu-Meer 2002) 는 P1 density 의 또 다른 축이나 K-fixed 가정과 mismatch 하여 future work, R-tree (Guttman 1984) 는 bbox overlap 이 본 연구의 disjoint partition 과 mismatch 하여 kdtree 측정으로 tree-based 대표를 cover 하였고, MinHash (Broder 1997) 는 set similarity 용으로 vector data 와 architectural mismatch 입니다.

6. 검토 요청 사항

채림 석사님 및 지도교수님께 다음 사항에 대한 검토 의견을 요청드립니다.

(1) RQ3 의 5 paradigm framework (Density Clustering / Space-Filling Locality / Online Streaming / Linear Projection / Low-discrepancy Quasi-random) 의 학술적 유효성 — 분포 미인지 sampling 의 분류 체계로서 본 5 paradigm 이 적절한지, 누락된 paradigm 이 있는지의 검토. 특히 §5 의 (5) 항에서 limitation 으로 분류한 Sketch family 와 Graph-based ANN 의 처리 방식이 적절한지의 권장.

(2) 각 paradigm 의 representative method 선정의 이론적 정당성 — 11 개 representative method 가 paradigm 별 inductive bias 를 충실히 대표하는지, 또는 추가/대체 후보가 있는지의 권장. 특히 P4 의 ★4 후보로 sparse RP (Achlioptas 2003, data-independent) 와 PCA1D (Pearson 1901, data-dependent) 중 "분포 모를 때" 라는 RQ3 framing 에 sparse RP 가 더 적합하다는 본 팀의 판단에 대한 검토.

(3) Exqutor 원논문의 Adaptive Sampling 과의 정면 비교 실험 설계의 적절성 — 동일 dataset / selectivity / sample_size 조건에서 KM20 + RQ3 representative ensemble 과 Adaptive Sampling baseline 의 q-error 를 paired 비교하는 W2 실험안.

(4) SF100 (80M) 실험의 5월 27일 최종 발표 전 가용성에 대한 현실적 추정 — 단일 cell 12시간 이상 소요 시 W2~W4 일정 안에서 어느 dataset / selectivity 조합에 한정하여 측정하는 것이 적절한지의 권장.

(5) PDX (SIGMOD 2025, CWI Amsterdam, arXiv:2503.04422) 학술 confirmation 의 본 연구 contribution narrative 통합 방식 — 발표 슬라이드에서 어느 위치 (Motivation / Contribution / Discussion) 에 배치하는 것이 학술 기여 강조에 효과적인지의 권장.

7. 첨부 자료

- RQ 재정립 설계안 (5/5): [plans/RQ재정립_20260505_2122.md](#)
- 5/5 연구지도확인서 (이전): [submission/_drafts/archive/W4_5월6일~7일_pre회의/속도는벡터_연구지도확인서_20260505.md](#)
- 본 확인서 v2 (5/8 narrative 축소): [submission/_drafts/속도는벡터_연구지도확인서_20260508.md](#)
- RQ3 paradigm framework + 5 paradigm × representative selection:
[experiments/results/RQ1_RQ2_RQ3_종합_master_v6_draft_filled_partial.{md,pdf}](#) (W1 sprint 후보군 검토 자료)
- RQ3 paradigm framework 학술 정합성 심층 검증: [_internal/RQ3_paradigm_심층검증_20260508.md](#) (5/8 저녁 정정 근거)
- 5/8 회의록: [_internal/records/kakaotalk/20260508_19시_RQ123sprint_회의.md](#)

- W1 sprint 진행 자료 (5/8): [submission/_drafts/속도는벡터 - Academic v3 · Final 5_27.pdf](#)

본 확인서를 통해 보고드린 RQ1·RQ2 의 SF1·SF10 측정 결과와 RQ3 의 paradigm framework 도출 단계 (5/8 학술 정합성 심층 검증 반영) 를 토대로, 자문 회신을 받은 후 W2 (5/9~5/15) 에 RQ3 본 측정을 launch 하겠습니다. 검토 의견을 회신해 주시면 5월 27일 최종 발표 전까지 반영하겠습니다. 감사합니다.

— 속도는벡터 일동

(별첨) 박세은 팀장 카톡 update message draft

다음은 박세은 팀장에게 보낼 v3 update 카톡 message draft (조현빈 직접 발송용) 입니다.

세은아, 어제 카톡 공유한 v2 narrative (RQ1/RQ2 finalize + RQ3 method 선정 단계) 에서 RQ3 paradigm framework 학술 정합성 심층 검증을 추가로 돌려서 v3 으로 업데이트했어. 결과적으로 narrative 방향은 그대로 유지되고 paradigm naming 정정 4가지만 반영했어.

(1) P5 명칭을 "Hashing/QR" → "Low-discrepancy / Quasi-random" 단일 inductive bias 로 통일 (LSH 와 Sobol 의 학술 분야가 달라서 분리. LSH 는 Wave 0 fail 로 limitation 명시). (2) ★4 = sparse RP (Achlioptas 2003 PODS, data-independent) 확정 — RQ3 의 "분포 모를 때" framing 과 가장 강한 일치 + ARI orthogonality #1. (3) 누락된 method (Sketch / Mean-Shift / R-tree / MinHash) 는 추가 측정 X, limitation §5 명시로 충분. (4) 4강 narrative (HDBSCAN / MB_partial / Hilbert / sparse RP) 변경 X — 5 paradigm 중 4 paradigm distinct representative 가 학술 강함.

자문 메일 outline 3줄 (실험 / SF1·SF10 / 자문 only) 은 그대로 유지하고, 지도확인서 v3 finalize 후 자문 회신 받으면 자문 메일은 별도로 작성할 예정이야. v3 검토해줘 — 문제 없으면 PDF 변환해서 발송 준비할게.

— 현빈