
속도는 벡터

벡터 분석 쿼리의 카디널리티 추정을 위한
분포 인지 표본 선택

박세은 · 강재현 · 조현빈 · 이동욱

속도는 벡터

박광현 교수
연세대학교 · 지도교수

왜 카디널리티 추정이 중요한가



조건을 만족하는 행의 수를 잘못 추정하면 →
잘못된 실행 계획 → 느린 쿼리

33%


pgvector — 늘 전체의 33%로 가정

100%

DuckDB — 늘 100%로 가정

기존 벡터 데이터베이스는 이 값을 데이터와 무관하게 고정 비율로 어렵한다

논문이 푼 것, 우리가 바꾼 것



논문 **Exqutor**의 추정 알고리즘은 그대로 인정한다

표본 뽑는 방식만 — 무작위 → 분포 반영

연구가 걸어온 길




측정 범위가 단계마다 넓어지며, 초점이 "특정 방법이 우수하다"에서 "표본 선택 단계를 바꾸는 것 자체의 효과"로 분명해졌다

분포를 반영해 표본을 뽑는 세 단계

STEP 1


분포 파악



데이터를 비슷한 것끼리 **20개 그룹**으로 나눈다

STEP 2


표본 추출



각 그룹에서 **골고루** 표본을 뽑는다

STEP 3

결합



논문 추정값과 우리 추정값을 **평균** 낸다

세 가지 방식을 같은 조건으로 비교했다

비교의 기준


기존 방식



논문 그대로의 **무작위 표본 추출**로 추정.

우리 표본만 사용

완전 대체



무작위 표본을 우리 표본으로 **통째 교체**해 추정.

두 추정값 평균

결합



논문 추정값과 우리 추정값을 **평균** 내어 함께.


한 번의 측정에서 세 방식을 **똑같은 데이터·똑같은 조건**으로 동시 비교 → 차이가 방식 때문임을 분명히

무엇을, 어떤 조건으로 측정했는가


	데이터셋	8종 · 96~864 차원	차원과 도메인을 폭넓게
	데이터 규모	10만 · 100만 · 1000만	데이터가 커질 때 효과 변화
	선택도	0.1% · 1% · 10%	쿼리 조건이 좁을 때부터 넓을 때까지
	표본 선택 방법	16가지	7가지 접근을 고루 대표
	계층 수	10 · 20 · 30 개	논문 기본값 20 중심으로 적을 때·많을 때

측정한 데이터셋

단일 벡터 데이터셋



다중 벡터 데이터셋




96차원부터 864차원까지 — 단일 벡터와 다중 벡터를 아우른다

데이터가 쏠려 있을 때, 무작위는 쏠린 곳만 뽑는다


기존 방식 · 무작위

표본이 봉우리에 집중



분포 인지 표본 추출

전 영역에서 골고루




분포를 반영하면 드문 영역까지 표본에 들어와 추정이 정확해진다

16가지 방법, 7가지 접근



공간 곡선

Hilbert 곡선 · Z-order 곡선 · 고차원 Hilbert 곡선 · IVF 클러스터링



차원 축소

주성분 분석 · 독립성분 분석 · 랜덤 SVD · 희소 랜덤 투영



통계적 총화

누적 제공근 총화 · Lavallée-Hidiroglou 총화



양자화

RaBitQ 양자화 · 다차원 히스토그램



클러스터링

미니배치 K-means · 가우시안 혼합 모델 (GMM)



스트리밍 표본 추출

가중 표본 추출



정보 이론 기반

HyperLogLog

16


총 측정 방법

다음 7장에서 한 접근씩


다음 일곱 장에서 각 접근이 어떻게 분포를 반영하는지 큰 개념 그림으로 본다

공간 곡선 - 고차원을 한 줄로 펼친다

APPROACH ① · SPACE-FILLING CURVE



펼친다




가까운 점은 펼친 뒤에도 가깝게 유지된다




흩어진 고차원 데이터 위로 한 줄짜리 곡선을 지나가게 해 데이터를 곡선 순서대로 펼친다 → 균등 구간으로 자르면 계층이 된다

차원 축소 — 핵심 축으로 압축한다

APPROACH ② · DIMENSION REDUCTION



한 축으로 압축 → 구간으로 자른다




정보가 가장 많이 담긴 방향만 남긴다

고차원 데이터를 정보가 가장 많이 담긴 한두 개의 축으로 압축한다 → 그 축 위에서 데이터를 구간으로 나누면 계층이 된다

통계적 총화 – 같은 양씩 구간을 나눈다

APPROACH ③ · STATISTICAL STRATIFICATION



값 분포 곡선의 각 구간 면적(데이터 양)이 같아지도록 자른다 – 싹린 쪽은 좁게, 드문 쪽은 넓게. 설문조사 표본설계에서 온 고전 기법

양자화 — 짧은 코드로 바꿔 묶는다

APPROACH ④ · QUANTIZATION

벡터

$v = (3.2, -1.8, 0.5, 2.1, \dots)$


부호

짧은 비트 코드

1 0 1 1 0 1

묶기

같은 코드끼리 묶음 (계층)




벡터를 짧은 코드로 요약해 같은 코드끼리 묶는다

벡터의 각 값 부호를 0/1로 바꿔 짧은 비트 코드를 만든다 → 같은 코드를 가진 데이터끼리 한 묶음(계층)으로


클러스터링 – 비슷한 것끼리 묶는다

APPROACH ⑤ · CLUSTERING

흩어진 점들



색깔별 군집 → 각 군집이 계층




흩어진 점들을 색깔별 군집(원)으로 모은다 – 각 군집이 하나의 계층. 측정에서는 다소 불안정 (뒤에서 결과로 다룸)

스트리밍 표본 추출 — 한 번 훑으며 골라낸다

APPROACH ⑥ · STREAMING SAMPLING

데이터가 한 줄로 흘러간다

표본 (선택됨)





크기 = 가중치 (큰 점일수록 표본에 들어올 확률 높음)

데이터가 한 줄로 흘러가는 중에 가중치가 높은 데이터를 표본으로 골라낸다 — 데이터를 두 번 보지 않고 한 번에

정보 이론 기반 — 해시로 요약한다

APPROACH ⑦ · INFORMATION-THEORETIC

데이터



짧은 요약 (스케치)

3	5	2	7
4	1	6	3

아주 적은 메모리로
데이터의 분포를 요약

데이터를 해시 함수에 통과시켜 아주 적은 메모리로 분포를 요약(스케치)한다 → 그 요약으로 계층을 부여

결합 방식이 추정 오차를 89.1%에서 줄였다

89.1%



결합 방식이 기존 방식보다 추정 오차를 줄인 비율

1508번의 측정 중 **1344번** 더 정확
추정 오차 중앙값 약 **4.4%** 감소

신호의 견고함

통계적으로 의미 있는 개선


65%

개선 폭이 큰 경우

72%

완전 대체는 불안정하다 — 결합이 답이다

완전 대체



기존 방식보다 나은 경우

35.2%

결합



기존 방식보다 나은 경우

89.1%


표본을 통째로 바꾸면 우리 방법이 강할 때만 좋고 약할 때 크게 나빠진다 → 두 추정값을 **결합**하면 논문 방식이 안전망이 되어 안정적으로 개선

16가지 방법 중 14가지가 기존 방식을 안정적으로 이긴다

14 / 16

모든 조건에서 안정적으로 우월

공간 곡선·차원 축소·층화 계열이 강하다.
클러스터링 계열 둘만 약해 권장에서 제외.



개선 폭의 중앙값(%) — 음수가 개선

선택도가 높을수록 더 안정적으로 개선된다

선택도는 전체 데이터 중
조건을 만족하는 비율

조건에 맞는 데이터가 많을수록 분포 반영의 이점이 **더 분명**해진다



결합 방식이 기존 방식을 이긴 비율

단일 벡터와 다중 벡터 모두에서 일관되게 우월

단일 벡터

89.1%

A horizontal progress bar with a dark blue segment representing 89.1% and a light gray segment representing the remaining 10.9%.

다중 벡터

89.2%

A horizontal progress bar with a dark blue segment representing 89.2% and a light blue segment representing the remaining 10.8%.

한 행에 벡터가 하나든 여럿이든, **결합 방식이 기존 방식을 이긴 비율**이 거의 같다 — 효과가 흔들리지 않는다

데이터를 20개 계층으로 나눌 때가 가장 좋다




결합 방식이 기존 방식을 이긴 비율

너무 **적으면** 쏠린 분포를 충분히 못 나눈다

너무 **많으면** 계층마다 표본이 얇아진다

20개가 균형점 — 논문 기본값과 일치

정확도와 분포 파악 시간의 균형



균형

가중 표본 추출

11초 · 최고 정확도

가장 빠름

희소 랜덤 투영

2.9초 · 분포 파악 최단

권장 제외

가우시안 혼합 모델

느리고 부정확

데이터 유형을 보고 방법을 자동으로 고른다

1 데이터가 들어온다



2 데이터 유형 판별
크기 · 구조 · 차원



3 유형에 맞는 표본 선택 방법 자동 선택



4 결함 방식으로 카디널리티 추정

사람이 매번
방법을 고르지 않고,
데이터 유형에 따라
자동으로

측정 결과를 종합해 만든 우리의 제안 — 추정 알고리즘은 그대로 두고, **표본 선택 방법만** 데이터에 맞춰 바꾼다

결론

1

분포를 반영한 표본 선택이
추정 오차를 **89.1%에서** 줄였다



2

통째 교체는 불안정 —
두 추정값의 **결합**이 답이다



3

선택도·데이터 구조·계층 수
모든 조건에서 **일관되게** 우월



4

데이터 유형에 따라
방법을 **자동으로** 고르는 방식을 제안



추정 알고리즘은 그대로 두고, 표본을 뽑는 방식만 바꾸는 것만으로 추정이 더 정확해진다

한계와 다음 단계

① 정직하게 남기는 점

- 비교 기준의 측정 방식에 작은 문제를 발견해 바로잡았다 — **더 엄정한 기준** 위의 값
- 가장 큰 규모의 다중 벡터 데이터는 **일부 조합만** 측정

✓ 다음 단계

6월 11일

최종 보고서 — 전체 결과 상세

엔진 일반화 검증

PostgreSQL · DuckDB에서

같은 효과 확인

감사합니다

질의응답