

---

# 속도는 벡터

VAQ 카디널리티 추정에서 표본 선택 한 단계를 통제 실험으로 검증하다

---

박세은 · 강재현 · 조현빈 · 이동욱

연세대학교 컴퓨터과학과 · 속도는벡터

박광현 교수님

연세대학교 BDAI 연구실 · 지도교수

# 벡터 증강 분석 쿼리 — 분석가가 풀려는 한 문제

## 분석가의 요청

"공급자 부품 이미지와 비슷한 부품들을 찾아,  
2024년 데이터에서 고객 리뷰를 분석해 적절한 할인율을 결정해  
줘."





```
SELECT discount  
FROM parts <-> reviews  
WHERE year=2024 ...
```

한 SQL 안에 이미지 유사 검색 + 텍스트 리뷰 + 시계열 분석이 결합되는 시대

벡터 검색이 정형 SQL 의 조인·집계·필터와 함께 실행

# 그런데 옵티마이저가 결과 행 수를 잘못 추정하면



카디널리티 추정 오차 → 잘못된 실행 계획 → 최대 1만 배 느려짐

한 쿼리 안에서 단 한 단계의 추정 실수가 전체 응답 시간을 결정

## 기존 시스템은 어떻게 추정하나

pgvector

33.3%

늘 전체의 33.3% 가정

VBASE

50%

늘 50% 가정

DuckDB

100%

늘 100% 가정


데이터와 무관한 고정 비율 — 실제 선택도 0.001% ~ 100% 변동인데 고정값으로 가정

# Exqutor 가 제안한 두 메커니즘

메커니즘 01 · 인덱스 有

## ECQO

HNSW range query 로 1-2 ms 안에 정확한 카디널리티




HNSW 다층 구조

메커니즘 02 · 인덱스 無 · 본 연구 무대

## Adaptive Sampling

무작위 베르누이 표본 + momentum 보정으로 추정



베르누이 표본 + 보정 (식 1-6)

# 우리는 그 안의 표본 선택 한 단계만 들여다봤습니다

## §V-B Adaptive Sampling — step-by-step



### 연구 질문

무작위 베르누이 표본 추출 → 분포 인지 총화 표본 추출 로 바꾸면,  
추정이 더 정확해지는가?

식 1-6 (N=385 표본 예산·momentum 보정) 은 그대로 두고

"어떤 표본을 뽑을 것인가" 한 단계만 통제 변인으로

# 어떻게 접근했나 — 한 측정 안에서 네 방식 동시 산출

방식 01 · 논문 그대로

**베이스라인 방식**

무작위 베르누이 표본 한 번 — 비교의 기준

방식 02 · 분포 인지 단독

**단독 대체 방식**

method 표본으로 무작위를 **통째 치환**

방식 03 · 두 추정의 평균

**결합 방식**

베이스라인 + method 추정값 **산술 평균**

방식 04 · 통제군

**평균 비교군**

method 자리에 **또 다른 무작위 베르누이** 넣고  
평균

같은 시드·데이터·쿼리·표본 예산 — **외생 요소 완전 통제**

5 데이터셋 (DEEP·SIFT·SSN·WIKI·PartSupp PK) · 16 method · 5 조작변인

**= 1,508 cell × 4 방식 = 6,032 추정값 짝 비교**

● 결과

## 관측 결과

89.1%



결합 방식이 베이스라인을 89.1%의 측정에서 이긴다

1,344 / 1,508 cell

추정 오차 중앙값 결합이 4.38% 더 작음

이 89% 우위가 분포 인지의 효과인가? — 다음 슬라이드의 통제군이 답합니다



# 메커니즘 규명 — 통제군이 무엇을 보여 주는가

| 추정 방식                                 | 평균 추정 오차     | 베이스라인 이긴 비율 |
|---------------------------------------|--------------|-------------|
| 베이스라인 (무작위 단독)                        | 1.944        | —           |
| 단독 대체 (분포 인지 단독)                      | 1.984 (더 나쁨) | 44%         |
| 결합 방식 (논문 + 분포 인지 평균)                 | 1.477        | 99%         |
| 평균 비교군 (논문 + 또 다른 무작위 평균 · 사후 분석)     | 1.459        | 100%        |
| ★ 사전 등록 통제 측정 (또 다른 무작위 두 번 평균 · 9 셀) | 1.373        | 100%        |

평균 비교군과 사전 등록 통제 측정 모두 결합 방식보다 더 정확 — 89% 우위는 분포 인지가 아닌 앙상블 평균 효과

hyperloglog (무작위 해시) 단독 +2.57% 악화 → 평균에 넣으면 -4.58% '개선' 둔갑 — method 정체 무관 증거

5/23 9 셀 × 10 회 반복 × 1,000 쿼리 사전 등록 측정  
평균 추정 오차 1.373 (vs 결합 1.473) — 9/9 셀 통제군 우위

통제군을 두지 않았다면 모르고 지나갔을 결과 · 사후 + 사전 등록 두 층 입증

# 그러면 분포 인지 단독으로는?

단독 대체 방식 — portfolio 악화



베이스라인보다 정확한 경우

35.2%

결합 방식 — 평균 효과 (참조)



베이스라인보다 정확한 경우

89.1%

단독 대체 better% 35.2% · 평균  $\Delta\%$  +12.90% — portfolio 전체 악화

분포 인지 단독으로 무작위 표집을 대체할 수 없다

● 적용

# 추정 정확도 향상이 — 실제 엔진 속도로 이어졌을까



엔진 적용 가속 폭

3~7x

베이스라인 방식이 이미 정답 수준 가속을 회복

정답 계획 회복률 (결합 13종 평균)

94.9%

베이스라인 4.43x  $\approx$  결합 4.46x  $\approx$  정답 4.54x — 동등

결합 방식과 베이스라인 모두 정답 수준 plan 회복 — latency 동등 = 음성·구조적 결과

● 적용

## 베이스라인 ↔ 결합 — 직접 짚지어 비교하면



paired  $\Delta\%$  중앙값 **+0.13%** · 빠름 349 · 느림 379 — 동전 던지기

노이즈 바닥  $\pm 17\%$  — 두 방식의 차이가 측정으로 분리되지 않음

● 적용

# 본 연구가 정말로 한 일

## 기여 01

표본 선택 단계 개입의 효과 범위를 통제 실험으로 분리

평균 비교군이 입증

## 기여 02

분포 인지 단독 대체는 무작위 표집을 대체할 수 없음

portfolio +12.90% 악화

## 기여 03

추정 정확도 ↑ 가 엔진 latency ↓ 로 이어지지 않는 구조적 한계

베이스라인이 이미 정답 plan 회복

## 기여 04

2,880 회 엔진 적용 검증 · 1,508 회 오프라인 짝 비교 · pgvector 직접 패치

측정 하네스 자체가 유효한 산출물

기법을 제안한 연구가 아니라 — 통제 실험으로 진짜 메커니즘과 한계를 규명한 연구

통제군을 추가로 설계한 것이 — 학부 캡스톤으로서 가장 엄밀하게 한 일

# 다음 사람이 이어할 수 있는 일

Group A · 메커니즘 후속

## 양상블 평균 효과를 이론·실증으로 확장

- 결합 방식의 분산 감소 효과를 Cochran 1977 composite estimator 이론으로 대조
- 더 강한 분포 정보 (KDE · Wavelet histogram) 가 단독으로 베이스라인을 이길 수 있는 영역 측정
- 다른 엔진 (VBASE · DuckDB · Milvus) 확장 측정

Group B · 산업 적용 framework (placeholder)

## 실 엔진 도입 안의 두 선택지

- 결합 방식 기본값 안 vs method-aware 동적 선택 안 trade-off
- 박세은 팀장 · 박광현 교수님 · 박성원 멘토 합의 후 결정

---

# 감사합니다

질의응답