

인덱스 부재 시 Adaptive Sampling 개선

— 표본 선택 단계의 통제
실험

박세은 · 강재현 · 조현빈 · 이동

홍익
스톤
속도 벡터 · 연세대학교 컴퓨터과학과 캡

박광현 교수 (BDAI 연구실) · 지도교수 지도연

구원 임채림 · 멘토 박성원 (삼성전자 AI센터)

배경

벡터 증강 분석 쿼리 (Vector-Augmented Query, VAQ)

분석
가



이 부품 사진이랑 비슷한 부품
들이 최근 가장 많이 팔린 주문
은?

예시 분석 쿼리 — 관계형 조건과 벡터 유사도를 한 SQL 안에

```
SELECT l_orderkey, o_orderdate, o_shippriority
FROM customer, orders, lineitem, partsupp_deep
WHERE c_mktsegment = 'HOUSEHOLD'
```

← 관계형 조건 (예: 가정용 카테고리 · 1995-03-14 이전
주문)

```
AND c_custkey = o_custkey
AND l_orderkey = o_orderkey
AND o_orderdate < DATE '1995-03-14'
AND l_shipdate > DATE '1995-03-14'
AND ps_partkey = l_partkey AND ps_suppkey = l_suppkey
```

```
AND ps_embedding <-> '[쿼리 부품 벡터]' < 0.86
ORDER BY ps_embedding <-> '[쿼리 부품 벡터]';
```

← 벡터 유사도 — 임베딩
비교

VAQ 결과



유사 부품 추출

• customer

• orders

• lineitem

• partsupp_deep

유사 부품의 매출 상위 주문 도
→ 분석결과

배경

카디널리티 한 곳이 잘못되면 — 최대 1만 배 느려짐

벡터 테이블 100만 행 같은 SQL 같은 데

VIDEO PLACEHOLDER
PLACEHOLDER



작동 원리 영상 — 엔진 탑재 이전

SQL 입력 → cardinality ~~잘못~~ (baseline) → Hash plan → 메모리 폭주

Claude Design HTML animation → 화면 녹화 → PowerPoint 에서 manual embed

카디널리티 추정 오차 → 잘못된 실행 plan 선택 → 응답 시간 1만 배

10,000× 응답 시간 차이

벡터 데이터셋 DEEP · 표준 분석 쿼리 예시

배경

기존 시스템 — 데이터 무관 고정 비율

pgvector

33.3 %

늘 전체의 33.3%로 가
정

VBASE

50 %

늘 전체의 50%로 가
정

DuckDB-vss


100 %

늘 100%로 가
%

세 시스템 모두 데이터·임계값과 무관하게 고정 비율로 어림 → 거의 모든 쿼리에서 잘

못된 plan

인덱스가 없을 때 — Adaptive Sampling (적응적 표본 추출)



방법

본 연

RESEARCH QUESTION

카디널리티 추정을 더 잘할 수 있는 표본 추출 방식은 무엇일까?

baseline



무작위 베르누이 · 균일 무작위
점들



대
조

샘플링 방식 탐
색



다양한 패턴 묶음 — 클러스터·곡선·해
시 등

방법

동일 쿼리에 세 가지 추정 방식을 동시 적용

같은 쿼리 · 같은 데이터
에서

baseline

(= 논문 원본 · 무작위 베르누이 방식)



cardinality 추정 1개

단독 대체

(= 베르누이를 분포 인지 표본으로 완전 치환)



cardinality 추정 1개 (회색)

CORE

결합

(= baseline + 분포 인지 추정값의 산술 평균)



cardinality A

cardinality B

↓ 산술 평균

결합 cardinality

같은 조건에서 직접 비교 가능

방법

1,508가지 조합으로 검증

DATASETS
데이터셋
5



DEEP
이미지 검색 · 96d



SIFT
이미지 feature · 128d



SSN++
이미지 유사도 · 256d



YFCC
멀티미디어 · 192d



PartSupp PK
TPC-H · 관계형

VARIABLES
조작변인
4

SCALE FACTOR · 데이터 크기

$sf = 1 \cdot 10 \cdot 100$

SELECTIVITY · 쿼리 조건 폭

$0.001 \cdot 0.01 \cdot 0.1$

K · 계층 수

$10 \cdot 20 \cdot 30$

METHOD · 표본 추출 방식

16 종 (베르누이 + 분포 탐색 15)


한 변인 = 한 차원 나머지 고정 · 비교 통제

COMBINATIONS
조합

5 데이터셋 $\times$ $sf \{1 \cdot 10 \cdot 100\} \times sel \{.001 \cdot .01 \cdot .1\} \times K$
 $\{10 \cdot 20 \cdot 30\} \times 16 \text{ method}$

= 1,508

의도 max 3,600 중 실측 1,508 (41.9% 구조화 부분 측정 측정)



동일 조건 동시 측정 → 직접 비교

엔진 응답 시간 측정은 별도 — DEEP $sf=10$ 환경 · 다음 슬라이드 11 에서 156 plan 소개

방법

표본 추출 방식 — baseline + 분포 인지 16 method 中 강한 13 method

baseline



균일 무작위 점들 분포 인지 16 method 中 강한 13 paradigm 분류

P1

2 method

공간 곡선



Hilbert · Z-order

P2

3 method

차원 축소



PCA · rSVD

P3

2 method

고전 stratification



cum-vf

P4

2 method

양자화



RaBitQ · grid

P5

1 method

클러스터링



KMeans · GMM

P6 ★

1 method

스트리밍



chao_weighted

P7

2 method

해시



md5 prefix

13

METHOD

7 paradigm

결과

Q-error 비교 — baseline vs 결합

결합 방식이 baseline 보다 Q-error 우

89.1%


1,344 / 1,508 cell · 결합 방식 우
우위

1,508 측정 중 1,344 cell 에서 결합 방식이 baseline 보다 더 낮은 Q-error → paired better

better 89.1%

▼ 낮을수록 더 정확한 추
정 (가로축 구간 1.30 — 1.50)

baseline



1.4582

결합

✓
1.4019

더 정확

적용

엔진 응답 시간 동일 / 최적 plan 선택 비율 우위

pgvector 기본

Adaptive Sampling 적용 X

5,677 ms (1.0×)

baseline

논문 원본

977.6 ms (5.77× ↑)

결합


본 연구

983.5 ms (5.70× ↑)

baseline 과 결합 latency 사실상 동등 (0.07× 격차)


DEEP 데이터셋 sf=10 환경 · 12개 매개변수 조합 × 13개 분포 인지 method = 156개 plan · 평균 응답 시간

baseline 최적 plan 선택



정답 91 · 오답 65 · 58.3%

결합 최적 plan 선택



정답 148 · 오답 8 · 94.9%

+57 최적 plan

+57

91 → 148 plan

최적 plan 선택 = 카디널리티 추정 정확 → 빠른 plan 도달 (느린 plan plan 회피)

적용

최종 엔진 작동 원리 — 결합 방식

적용

벡터 테이블 100만 행 · 같은 sf · 결합 cardinality 적용

VIDEO PLACEHOLDER



작동 원리 영상 — 최종 엔진 (

SQL 입력 → cardinality **정확 추정 (10배)** → Nested Loop plan → Index Scan 즉시

Claude Design interactive mockup → 화면 녹화 → PowerPoint 에서 manual embed

정확한 cardinality 추정 → 정답 실행 plan → 빠른 응답 시

5.70x 응답 시간 단

DEEP sf=10 · pgvector 기본 대비 결합 최종


축

적용

Future Work — 두 갈래

GROUP A — 검증 범위 확장 + 산업 자원

본 측정 평면 → 확장 평면



scale ↑

selectivity ↑

engine 다양

resource 산업적

더 큰 데이터 · 넓은 selectivity · 다른 엔진에서 결합 효과

과 검증

GROUP B — History-aware Adaptive Sampling

과거 query → 현재 query 추정



feedback 누적 → sampling ↓ → cost ↓

과거 feedback

더 적은 sampling

cost ↓

감사합니다

Q&A 환영합니다

박세은 · 강재현 · 조현빈 · 이동

홍익
스톤

소프트웨어 · 연세대학교 컴퓨터과학과 캡

박광현 교수 (BDAI 연구실) · 지도교수 지도연
구원 임채림 · 멘토 박성원 (삼성전자 AI센터) 자

자료 · 코드 — github.com/johyunbin/Capstone