

속도는벡터 → 임채림 연구원님 — 본 연구 측정 데이터 정리 (v3)

수신: 임채림 연구원 (BDAI 연구실) 발신: 속도는벡터 (박세은 팀장 경유 · 조현빈 작성) 목적: 본 연구 (Exqutor §V-B 표본 선택 단계 controlled verification) 의 실험 환경·측정값·결합 13 method 의 실제 엔진 효과를 156 plan 단위로 상세 정리.

1. 본 연구의 핵심 질문

인덱스가 없는 상황에서 Exqutor 논문의 적응적 표본 추출 (§V-B) 의 "표본 선택 단계" 를 무작위 베르누이에서 분포 인지 총화로 바꾸면, 카디널리티 추정과 실제 엔진 응답 시간이 어떻게 달라지는가?

본 자료는 이 질문에 대한 측정 결과를 5 항목으로 정리한다 — (가) 실험 환경, (나) 베이스라인의 정확도와 응답 시간, (다) 16 method 중 가장 정확한 method, (라) 156 plan (12 cell × 13 결합 method) 의 B1·CaseB 완전 상세 비교, (마) 측정의 한계.

2. 실험 환경

2.1 서버 하드웨어

항목	값
호스트	BDAI 연구실 서버 165.132.140.240 (계정 capstone2026)
CPU	Intel Xeon Gold 6530 · 128 vCPUs
RAM	1.0 TB
GPU	4× NVIDIA RTX 6000 Ada 49 GB (본 측정은 CPU 만 사용)
Disk	/mnt/hdd0 13 TB
PostgreSQL	Exqutor patched pgvector · 포트 55435 · DB wns41559
OS·환경	Linux + tmux 다중 세션

본 연구의 측정 환경은 Exqutor 논문의 측정 환경과 동일하다 ("Intel Xeon Gold 6530 with 128 vCPUs and 1.0 TB of RAM", arXiv:2512.09695v2 §VI verbatim).

2.2 데이터셋

5 개 단일 벡터 데이터셋 + 다중·연접(concat) 조합:

데이터셋	차원	서버 테이블
DEEP	96	partsupp_deep_{1,10,100}
SIFT	128	partsupp_sift_{1,10,100}
SimSearchNet++ (SSN)	256	partsupp_fb_{1,10,100} (서버 alias: fb)
WIKI	768	partsupp_wiki_{1,10}
YFCC	192	partsupp_yfcc_{1,10}
다중 (DEEP+SIFT 등)	224·288·864·1024	(직접 연접)

2.3 측정 평면 (1,508 측정 portfolio)

변인	값
TPC-H 분석 쿼리	Q3·Q9·Q10·Q12 (벡터 술어가 SeqScan 분기에서 평가)
Scale Factor	1 · 10 · 100
거리 임계값 D 의 selectivity	0.001 · 0.01 · 0.10
총화 수 K	10 · 20 · 30
표본 선택 method	16 종 (7 paradigm 대표)
측정 mode (3-way matched)	베이스라인 (B1) · 단독 대체 · 결합 (CaseB)
trials per 측정	10 회 반복 × 1,000 queries per trial
총 측정 수	1,508 측정 portfolio (각 측정 = 3 mode matched, 합 4,524 행)

본 portfolio 는 구조화 분할로, 완전 요인 설계 (max 3,600) 의 약 42% 다. $K=20 \cdot sel=0.01$ 중심으로 측정 밀도를 두텁게 두었다.

2.4 Adaptive Sampling Hyperparam (논문 §V-B verbatim carry)

변수	값	의미
N	385	초기 표본 예산 (식 1: $\lceil 1.96^2 \cdot 0.25 / 0.05^2 \rceil = 385$)
m	0.9	momentum coefficient (식 4)
η_0	0.1	초기 학습률 (식 4)
α	50	target Q-error 가중치 (식 3)
β	1.5	target Q-error (식 3)
γ	0.99	학습률 감쇠 (식 6)
update_period	50 queries	표본 크기 갱신 주기

본 연구는 위 hyperparam·식 1-6 을 모두 그대로 두고 표본을 어디서 뽑을 것인가 하는 한 단계만 변경했다.

3. Exqutor 베이스라인 (B1) 측정 결과

3.1 카디널리티 추정 정확도

- 1,508 측정 × 베이스라인 mode 의 Q-error trim mean = **1.4582**
- median 1.5616 · std 0.1925 · range [1.15, 1.66]
- (Q-error 정의: 식 2 verbatim — $q = \max(C_{est}/C_{true}, C_{true}/C_{est})$, 1.0 이 완벽, 작을수록 정확)

3.2 실제 엔진 응답 시간 (DEEP sf=10, 12 셀 × 15 회 반복)

조건	응답 시간 (trim mean, 12 셀 평균)	가속 배수
기본 pgvector (카디널리티 미주입)	5,677 ms	1.0× (기준)
Exqutor 베이스라인 inject	978 ms	5.77×
결합 inject (CaseB 13 method 평균)	984 ms	5.70×
정답 카디널리티 inject (oracle)	992 ms	5.65×

세 inject 가 거의 동등하게 빠르다. 즉 추정값을 주입만 하면 베이스라인 plan 만으로 이미 약 5-6× 가속 가능. 표본을 어떻게 뽑았느냐 (B1 vs CaseB) 가 추가 가속을 만들지 않는다.

3.3 정답 plan 회복

- 12 셀 중 베이스라인이 정답 plan 으로 회복한 수: **7/12 cell** (cell 단위)
- qid 별: qid 0 = 0/4 · qid 1 = 4/4 · qid 2 = 3/4

- 회복 실패는 sel=0.001 의 결정 경계 cell (베르누이 적중 0 회 시 측정 harness 가 MIN_INJECT=1.0 으로 보정, 클램프된 1.0 이 planner 결정 경계 가까이 떨어져 plan 이 갈림).

3.4 베이스라인 가속의 통계적 견고성

- paired Wilcoxon 부호 순위 검정 + Holm-Bonferroni 보정 (anchor=기본 pgvector, 180 비교): **180/180 = 100% 유의** + 100% large effect (Hedges' $g \geq 0.8$).
- 베이스라인 가속은 통계적으로 압도적·견고하게 확정.

4. 16 method 중 가장 정확한 method

4.1 정확도 ranking 상위 5 (paired vs 베이스라인)

Method	알고리즘 한 줄	paired better%	median Δ%
chao_weighted	Chao 1982 가중 우선순위 sampling: 각 벡터에 norm·PCA·iDistance 가중치 w 부여 후 priority $u^{(1/w)}$ 의 quantile 분할	100.0%	-6.22%
pca2d_hilbert_xy2d	PCA 로 2 차원 환원 후 Wikipedia 표준 xy2d Hilbert curve algorithm 으로 1D 순서 분할	98.9%	-5.91%
pca4_skilling_hilbert_approx	PCA 로 4 차원 환원 후 Skilling 2004 알고리즘 근사 (4-axis × 8-bit Hilbert key)	100.0%	-5.75%
ica_fastica	Hyvärinen 1999 FastICA 의 독립 성분 분석 1D 투영 후 quantile 분할	100.0%	-5.69%
pca1d	Pearson 1901 PCA 의 첫 주성분 1D 투영 후 quantile 분할	97.9%	-5.55%

4.2 본 연구의 최저 Q-error method = **chao_weighted**

알고리즘 본질: 각 벡터에 가중치 w_i (L2 norm·PCA 1D 절대값·KMeans iDistance 중 하나) 를 부여하고, 균등 무작위값 u_i 의 $1/w_i$ 제곱을 priority 로 두어 quantile 로 K=20 stratum 에 분할한다 (Chao 1982 의 "weighted reservoir" 기법). 본 method 는 paradigm P3 Streaming 에 속하며, PCA 환원 없이 원본 차원에서 직접 동작한다.

- 베이스라인 평균 Q-error = 1.4582 → chao_weighted 결합 mode 평균 Q-error $\approx$ **1.37** (paired median Δ% -6.22% 기준)
- 분포 파악 1 회 cost (fit_time) = **11.03 초**
- Pareto frontier 1순위** — 정확도와 분포 파악 속도의 균형이 가장 좋음

5. 156 plan (12 cell × 13 결합 method) 완전 상세 비교

본 §5 는 사용자 요구에 따라 본 연구의 실제 엔진 측정 정보인 **156 plan** 을 cell × method 단위로 모두 표로 정리한다. 각 plan 마다 B1 (베이스라인) 과 CaseB (결합) 의 plan tree·trim mean latency·plan 회복 여부·inject 검증 정보를 완전히 담는다.

5.1 측정 정의

- 측정 환경: DEEP sf=10 · 4 query (Q3·Q9·Q10·Q12) × 3 qid (0·1·2) = 12 cell · sel=0.001
- 각 cell × 13 결합 method = **156 row** (정합 정확)
- 각 row 의 latency = 15 trial × trim mean (보고서 §5.2 정본 metric)
- plan 비교 = **plan_signature** (pre-order Node Type tuple) 일치 / 불일치
- raw 원자료:
`_internal/cache/rq3/latency/phase2/latency_tpc_h_{q3,q9,q10,q12}_DEEP_sf10_sel0.001_qid{0,1,2}.json` × 12 file

- 추출 산출물: `_internal/cache/rq3/latency/phase2/table_156plan_20260525_001258.{csv,md}`
- 추출 스크립트: `_internal/scripts/extract_156plan_table.py`

5.2 cell × plan 회복 분포 (12-row summary)

Cell (DEEP sf=10 sel=0.001)	B1 plan 회복 (oracle 일치)	CaseB plan 회복 / 13	plan_same / 13	plan_diff / 13	B1 trim mean (ms)	CaseB Δ% median
Q10 qid=0	✗	13	0	13	973.9	+1.81%
Q10 qid=1	✓	13	13	0	1065.4	-2.07%
Q10 qid=2	✓	13	13	0	1060.2	+0.34%
Q12 qid=0	✗	13	0	13	952.6	+3.40%
Q12 qid=1	✓	13	13	0	899.2	-1.20%
Q12 qid=2	✓	13	13	0	830.2	+2.50%
Q3 qid=0	✗	12	0	13	1018.1	-2.76%
Q3 qid=1	✓	12	12	1	936.8	+1.37%
Q3 qid=2	✗	7	6	7	1217.5	-9.21%
Q9 qid=0	✗	13	0	13	894.6	+1.24%
Q9 qid=1	✓	13	13	0	860.9	-2.67%
Q9 qid=2	✓	13	13	0	915.3	-1.19%
합계	7/12	148/156 = 94.9%	96/156 = 61.5%	60/156 = 38.5%	—	—

해석: - 7 cell 은 B1 이 이미 정답 plan — CaseB 13/13 도 같은 plan 유지 (overhead 없음, Δ% 약 ±2%). - B1 plan 회복 못한 5 cell (Q10qid0·Q12qid0·Q3qid0·Q3qid2·Q9qid0) 중 4 cell 에서 CaseB 13/13 또는 12/13 이 정답 plan 으로 회복. 즉 결합 13 method 가 베이스라인이 놓친 plan 을 일관되게 잡는다. - **유일한 부분 회복 cell = Q3 qid=2** (6-way join 의 가장 복잡한 plan 공간). 결합 13 method 중 7 method 만 정답 회복, 6 method 는 다른 plan 으로 분기. 본 cell 의 B1 trim mean = 1217.5 ms 가 12 cell 중 최대.

5.3 method × plan/latency summary (13-row summary)

Method	plan_same	plan_diff	CaseB oracle 회복 / 12	median Δ%	mean Δ%	max abs Δ%	avg Q-error
chao_weighted	8	4	11	+0.34%	-0.50%	8.94%	1.38
cum_sqrtf	7	5	12	-1.59%	-1.37%	10.09%	1.27
ica_fastica	8	4	11	-0.17%	-0.33%	8.41%	3.20
md5_prefix_hash_bucket	8	4	11	+0.73%	+0.29%	5.29%	1.76
pca1d	7	5	12	-0.07%	-1.31%	11.25%	1.54
pca2d_equi_depth_grid	7	5	12	-1.78%	-2.57%	12.06%	1.75
pca2d_hilbert_xy2d	8	4	10	-0.32%	-0.13%	4.49%	1.28
pca2d_zorder_morton	7	5	12	+0.40%	-0.89%	9.21%	1.82
pca4_skilling_hilbert_approx	8	4	11	-1.72%	-0.49%	3.77%	1.70
rabitq_1bit_bucket	8	4	11	-0.85%	-0.30%	7.22%	2.76
rsvd	7	5	12	+0.24%	-0.61%	9.68%	1.53
sparse_rp	6	6	11	+1.19%	+0.69%	9.62%	1.30
takeall_cumsqrtf	7	5	12	-0.58%	-1.03%	11.70%	1.31

- 13 method 모두 median Δ% ±2% 안, mean Δ% ±3% 안. 본 결과는 method 별 latency 차이가 매우 작음을 의미.
- max abs Δ% 가 큰 method (cum_sqrtf 10.09%·pca2d_equi_depth_grid 12.06%·pca1d 11.25%·takeall_cumsqrtf 11.70%) 는 모두 plan 이 변한 cell (B1 wrong plan → CaseB recovered plan) 에서 측정된 큰 차이. 즉 plan 자체가 변한 점만이 latency 차이의 원인.

5.4 156 plan 전체 표

전체 156 plan (cell × method × B1·CaseB plan tree·latency·plan_same·oracle 회복·inject 검증·통계) 는 다음 두 산출물에서 그대로 확인 가능:

- CSV (분석용): `_internal/cache/rq3/latency/phase2/table_156plan_20260525_001258.csv`
- Markdown (사람 읽기용 156-row 표): `_internal/cache/rq3/latency/phase2/table_156plan_20260525_001258.md`

표 컬럼:

컬럼	의미
cell	측정 셀 (tpc_h/qN DEEP sf10 sel0.001 qidM)
method	결합 method 명 (정정 후 명칭)
B1_plan	B1 plan tree (pre-order Node Type tuple, abbreviated)
CaseB_plan	CaseB plan tree
plan_same	"same" / "diff" (Node Type tuple 일치 여부)
B1_ms · CaseB_ms	15 trial trim mean latency (단위 ms)
delta_pct	(CaseB – B1) / B1 × 100 (%)
B1_recovers_oracle · CaseB_recovers_oracle	oracle plan 일치 여부 (T/F)
true_card · CaseB_injected_card	실제 카디널리티 · 결합 주입값
q_error · injection_fired	추정 정확도 · 주입 발동 여부
p_holm · hedges_g · cliffs_delta	paired Wilcoxon Holm-보정 p · 효과 크기

5.5 156 plan 중 핵심 cell 5 detail (B1 plan 회복 못한 cell 만)

5 cell × 13 method = 65 row 발췌 — B1 이 정답 plan 을 놓친 cell 에서 결합 13 method 가 어떻게 회복하는지 보여줌.

5.5.1 Q10 qid=0 (B1 wrong, CaseB 13/13 recover)

- B1 plan: `Sort > NL > NL > Gather > NL > NL > Seq > IS > IS > IS > Seq` (B1 trim mean 973.9 ms · oracle 미회복)
- CaseB plan (13 method 공통): `Gather > Sort > HJ > NL > NL > NL > Seq > IS > IS > IS > Hash > Seq` (모두 정답 plan)

method	CaseB_ms	Δ%	CaseB inject	q_error
chao_weighted	981.3	+0.77%	7157.9	1.062
cum_sqrtf	1047.3	+7.54%	6226.2	1.221
ica_fastica	1001.8	+2.87%	1052.6	7.223
md5_prefix_hash_bucket	984.6	+1.10%	3222.2	2.360
pca1d	986.4	+1.28%	3157.9	2.408
pca2d_equi_depth_grid	989.9	+1.65%	3456.8	2.199
pca2d_hilbert_xy2d	995.5	+2.22%	8546.2	1.124
pca2d_zorder_morton	994.1	+2.08%	4211.0	1.805
pca4_skilling_hilbert_approx	1000.2	+2.71%	3052.6	2.491
rabitq_1bit_bucket	940.5	-3.43%	1329.8	5.718
rsvd	991.5	+1.81%	3367.2	2.258
sparse_rp	1010.2	+3.73%	5105.3	1.489
takeall_cumsqrtf	934.6	-4.03%	5068.8	1.500

true_card = 7603. 결합 13 method 모두 plan 회복하지만 inject 값 diversity 크다 (1052 ~ 8546). plan 트리 동일 → latency 사실상 동등 (Δ% 범위 -4.03% ~ +7.54%).

5.5.2 Q12 qid=0 (B1 wrong, CaseB 13/13 recover)

- **B1 plan:** B1 trim mean 952.6 ms · oracle 미회복
- **CaseB plan:** 13 method 모두 oracle 회복
- CaseB Δ% median +3.40%, range 약 ±5%

5.5.3 Q3 qid=0 (B1 wrong, CaseB 12/13 recover, 1 method 미회복)

- **B1 plan:** B1 trim mean 1018.1 ms · oracle 미회복
- **CaseB plan:** 12 method oracle 회복, 1 method 다른 plan (전체 plan_diff 13/13)
- CaseB Δ% median -2.76%

5.5.4 Q3 qid=2 (B1 wrong, CaseB 7/13 recover — 가장 어려운 cell)

- **B1 plan:** B1 trim mean 1217.5 ms · oracle 미회복 (12 cell 중 최대 latency)
- **CaseB plan:** 13 method 중 7 method oracle 회복, 6 method 는 다른 plan 으로 분기 (plan_same 6/13 · plan_diff 7/13)
- CaseB Δ% median -9.21% (12 cell 중 최저), Q3 6-way join 의 plan 공간 복잡성 그대로 노출됨

5.5.5 Q9 qid=0 (B1 wrong, CaseB 13/13 recover)

- **B1 plan:** B1 trim mean 894.6 ms · oracle 미회복
- **CaseB plan:** 13 method 모두 oracle 회복
- CaseB Δ% median +1.24%

5.6 156 plan 결과 요약 — 핵심 의미

측면	값	의미
plan_same 비율	96/156 = 61.5%	CaseB 가 B1 과 같은 plan 으로 수렴한 case
plan_diff 비율	60/156 = 38.5%	CaseB 가 B1 과 다른 plan 으로 분기한 case
CaseB oracle 회복	148/156 = 94.9%	CaseB 13 method 의 정답 plan 회복 robustness
B1 oracle 회복 (12 cell × 13 method 반복)	91/156 (7 cell × 13)	B1 단독 plan 회복 7/12 cell
Δ% median (전체 156)	-0.06%	latency 차이 사실상 0
Δ% mean (전체 156)	-0.66%	mean 도 ±1% 이내
	Δ%	< 5%
injection_fired True	156/156 = 100%	모든 측정에서 inject 발동, 측정 무효 0

본 156 plan 결과의 핵심 의미는 다음 세 가지다:

1. **결합 13 method 가 B1 가 놓친 정답 plan 을 일관되게 회복** — 7/12 cell B1 회복 → 148/156 = 94.9% 결합 회복. plan recovery robustness 향상이 결합 방식의 주된 가치.
2. **plan 이 같으면 latency 동등** — plan_same 96 row 의 Δ% 분포가 0 중심으로 좁게 ($|\Delta\%| < 5\%$ 의 대부분), CaseB inject 값이 B1 inject 값보다 정확해도 plan tree 가 같으면 실행 시간은 거의 같다.
3. **plan 변화가 latency 차이의 유일한 driver** — plan_diff 60 row 가 $|\Delta\%|$ 큰 outlier 의 대부분. 즉 추정값 정확도 (Q-error) 그 자체는 latency 에 직접 영향 X, plan 선택을 통한 간접 영향만 존재.

5.7 3-way 가속의 종합 — 156 plan 위에서의 12 cell mean

12 cell × inject mode = 3-way 가속 mean (trim mean basis, sf=10 DEEP):

inject mode	12 cell trim mean (ms)	가속 배수 vs 기본 pgvector
기본 pgvector	5,677	1.00×
B1 inject	978	5.77×
CaseB inject (결합 13 method 평균)	984	5.70×
oracle inject	992	5.65×

- 보고서 §5.2 verbatim: 12 cell oracle gain 평균 **5.67×** (trim mean) · range 2.93× ~ 7.40×.
- 세 inject 사이의 paired $\Delta\%$ mean +0.30% · median +0.11% (4-way 확장 측정 5/24, 12 cell × 18 variant × 15 trial = 3,240 측정).
- 17 inject variant 모두 $|\Delta\%| \leq 1.12\%$ 안에 모임.
- paired Wilcoxon $p_{\text{holm}} < 0.05 = 13/168 = 7.7\%$ 만 유의, 86.9% small effect (Hedges' $g < 0.5$).

5.8 분산 분해

$\log(\text{exec_ms}) \sim C(\text{query}) + C(\text{qid}) + C(\text{sel}) + C(\text{condition: B1·CaseB·oracle}) + \text{교호작용}$:

- 3 평면 (phase2 DEEP·phase3 SIFT·phase4_extension SSN·YFCC) 통합 2,250 obs, $R^2=0.83$
- 조건 (B1·CaseB·oracle) % **SS = 0.00%** · **p = 0.945**
- 어떤 inject 를 주입했는지가 실제 엔진 응답 시간 변동에 사실상 기여하지 않음

5.9 plan 회복 robustness 확장 — 3 평면 통합 (700 paired cell)

phase2 (DEEP, 156 paired plan) + phase3 (DEEP sel 확장) + phase4_extension (SIFT·SSN·YFCC) 의 3 평면 통합 비교:

측정 결과	값
총 paired B1 ↔ CaseB cell	700
plan_same 비율	92.7%
plan_diff 비율	7.3%
plan_diff 안 paired $\Delta\%$ mean	+0.30%
plan_diff 안 paired $\Delta\%$ median	+0.11%

본 phase2 (DEEP sf=10 156 plan) 의 plan_diff 비율 38.5% 가 3 평면 통합 후 7.3% 로 줄어드는 것은, DEEP sf=10 sel=0.001 환경이 plan 분기에 가장 민감한 (결정 경계 가까운) 환경이기 때문이다. SIFT·SSN·YFCC sel=0.01·0.10 cell 들은 B1 이 이미 정답 plan 으로 잘 수렴한다.

5.10 plan_diff 와 latency 변동의 직접 상관관계

156 plan 안 plan_same (96 row) vs plan_diff (60 row) 의 $\Delta\%$ 분포 직접 비교:

분류	row 수	$\Delta\%$ std (변동 분산)	$\Delta\%$ range	$\Delta\%$ median
plan_same	96	2.82	[-6.78%, +7.22%]	-1.00%
plan_diff	60	4.91 ($\approx 1.74\times$ 큼)	[-12.06%, +7.54%]	+1.28%

본 결과는 다음을 직접 측정한다 — **plan 이 바뀐 cell 에서 latency 변동 분산이 1.74 배 크고 최대 $|\Delta\%|$ 도 12.06% 까지 벌어진다.** 즉 plan 변화 자체가 latency 차이의 dominant driver 이며, plan 이 같은 cell 에서는 추정값 정확도 (Q-error) 가 향상되어도 latency 변동이 좁은 범위 ($|\Delta\%| < 7.22\%$) 에 머문다.

B1 oracle 미회복 5 cell (CaseB 가 회복하는 cell) 의 $|\Delta\%| > 5\%$ 발생률 = $14/65 = 21.5\%$, $|\Delta\%| > 10\% = 4/65 = 6.2\%$ — 본 환경이 plan 변동·latency 변동 모두 더 큰 영역.

본 측정 (sf=10 · sel ≤ 0.10 · 4 query · DEEP·SIFT·SSN·YFCC) 안에서는 plan_diff 비율이 7.3% (3 평면 통합) 까지 줄어드는 cell 분포라, latency 개선 효과가 통계적으로 saturate 된 결과로 나타난다. plan_diff 가 더 자주 발생하는 환경 — **sf=100 (Disk I/O bound)** · 큰 selectivity (≥ 0.5 , heuristic 33% 가까운 영역) · 다중 벡터 concat (큰 차원) · WIKI sf=10 (768d) · 타 엔진 (VBASE·DuckDB·vss·Milvus, 다른 plan logic) — 에서는 결합 13 method 의 plan 회복 가치가 절대 latency 차이로도 더 크게 노출될 가능성이 있다. 본 평면 확장 검증은 Future Work (§8.1) 로 carry.

6. 평균 비교 통제군 (dual-Bernoulli) 측정

6.1 측정 설계

method 자리에 또 다른 무작위 베르누이 표본을 두고, B1 추정값과 산술 평균하는 이중 베르누이 ensemble 측정 (이하 CaseC). 두 베르누이는 같은 카디널리티 추정 알고리즘 (식 1-6) 위에서 서로 독립 seed 로 작동.

6.2 측정 결과 (95 cell 전수)

25 cell × 3 selectivity × 3 K 평면의 95 (cell × sel × K) 조합 전수:

비교	better%	median Δ%
CaseC vs 베이스라인	95/95 = 100%	-11.32%
CaseC vs 결합 (CaseB)	95/95 = 100%	-5.98%

- CaseC 평균 Q-error = **1.3060** (베이스라인 1.4595 · 결합 1.4022 대비 모두 더 정확)
- 95 cell 전수에서 두 독립 베르누이 표본의 평균이 베이스라인보다, 그리고 결합 13 method 보다도 정확함

6.3 결과의 의미

본 측정은 결합의 89.1% 우위가 다음 두 효과의 합임을 직접 측정한다:

1. 두 독립 추정량 평균에 따른 분산 감소 효과 (베이스라인 단일 표본 대비 표본 용량 2배 효과)
2. 분포 인지 method 의 추가 효과

CaseC (dual-Bernoulli) 가 CaseB (Bernoulli + 분포 인지 method) 보다 정확하다는 95/95 = 100% 결과는, 위 두 효과 중 (1) 이 지배적임을 의미한다.

7. 측정 한계

7.1 측정 평면 한계

- A2-Fig8 (DEEP+CC3M sf=10, 1024d): 16 method 중 4 method 만 측정 (희소 cell, 단독 finding 인용 X)
- WIKI sf=10 실제 엔진 측정: 768d SeqScan 이 statement_timeout (180 초) 초과 — 측정 불가
- scale factor 1-100 실제 엔진 측정: sf=1 은 작은 테이블이라 IndexScan 경로 선택 → 카디널리티 주입 미발동 (plan-invariant), sf=100 은 미진행 (Future Work)
- 타 엔진 (VBASE·DuckDB·vss·Milvus): 미측정 (Future Work)
- 측정 portfolio = **41.9%** (1,508 / 의도 max 3,600), 완전 요인 설계 아닌 구조화 portfolio — K=20·sel=0.01 중심으로 측정 밀도 집중

7.2 측정의 통계 검정 floor

- trial 10 회로 한쪽 꼬리 Wilcoxon 최소 p값 1/1024 ≈ 0.001 에 몰림
- method·paradigm 우열은 p값보다 Δ%·효과 크기 (Hedges' g · Cliff's δ) 로 판단

7.3 sf=10 한정 일반화

본 연구의 실제 엔진 측정은 모두 sf=10 (DEEP·SIFT·SSN·YFCC 4 데이터셋) 환경 기준. sf=1 (in-memory fit) 과 sf=100 (Disk I/O bound) 환경에서는 plan 변경 시 latency 증감 폭이 다를 수 있음.

7.4 plan_diff 분포의 측정 평면 의존성

본 측정 평면 안에서 plan_diff 가 차지하는 비율은 3 평면 통합 후 **7.3%** (52/700 paired cell) 로 좁다. §5.10 의 검증에서 plan_diff 가 latency 변동의 dominant driver 임을 직접 측정했으므로, **본 결과의 latency 동등성은 본 측정 평면의 plan_diff 비율이 낮은 결과다.** plan_diff 가 더 자주 나타나는 환경 (sf=100·큰 selectivity·다중 벡터·WIKI·타 엔진) 으로 확장 시 결합 13 method 의 plan 회복 robustness 가 절대 latency 차이로도 더 크게 노출될 가능성이 열려 있으며, 본 확장 검증은 §8.1 Future Work 로 carry.

8. Future Work

8.1 검증 범위 확장 — plan_diff 자주 발생하는 환경 우선

§5.10 의 검증 결과 (plan_diff 안 $\Delta\%$ std 4.91 vs plan_same 2.82, $\approx 1.74\times$ 큼) 에 따라, 다음 환경은 결합 13 method 의 plan 회복 가치를 절대 latency 차이로 더 크게 노출할 가능성이 있어 후속 검증 우선순위가 높다:

- **scale factor 확장 (sf=100, Disk I/O bound)** — sf=10 대비 $10\times$ latency, plan 공간 복잡, plan_diff 잠재 더 큼
- **큰 selectivity (≥ 0.5 , heuristic 33% 가까운 영역)** — fixed heuristic plan 결정 경계가 자주 갈리는 영역
- **다중 벡터·concat (DEEP+SIFT 등, 큰 차원 224 ~ 1024d)** — plan space 더 복잡
- **WIKI sf=10 (768d)** — statement_timeout 한계 해결 후 측정
- **타 엔진 (VBASE · DuckDB-vss · Milvus)** — 다른 plan 선택 logic, plan_diff 분포 다를 수 있음
- **산업 자원 trade-off** — RAM · CPU · sample storage cost 분석

8.2 History-aware Adaptive Sampling (신 방향)

- 유사 query 의 과거 selectivity feedback 누적
- 현재 vector predicate 의 카디널리티를 더 적은 **sampling** 으로 추정
- sampling cost ↓ · 정확도 유지 · latency 개선 후보

9. 결론

본 연구는 Exqutor 논문의 적응적 표본 추출에서 표본 선택 단계를 통제 변인으로 분리해 1,508 측정 + 156 plan 단위 상세 비교로 검증한 결과를 다음과 같이 정리한다:

- **베이스라인의 가속 효과는 견고하게 확정** — 기본 pgvector 대비 평균 5.77 배 (12 cell · trim mean basis · 180/180 통계 유의 · 100% large effect).
- **결합 13 method 가 정답 plan 회복 robustness 를 94.9% 까지 향상** — B1 단독 7/12 cell → CaseB 148/156 plan. plan 회복이 결합 방식의 주된 가치.
- **추정 정확도의 추가 향상이 실제 엔진 응답 시간 추가 가속으로 직결되지 않음** — paired $\Delta\%$ median +0.11% · 분산 분해 조건 % SS = 0.00%. plan 이 같으면 latency 동등, plan 이 다르면 plan 변화가 latency 차이의 유일한 driver.
- **결합 우위는 두 독립 추정량 평균의 분산 감소 효과 + 분포 인지의 추가 효과 합** — dual-Bernoulli 통제 측정 95/95 = 100% 가 두 효과의 분해를 직접 측정.

작성: 2026-05-25 00:13 KST · 속도는벡터 (조현빈, 박세은 팀장 검토 후 임채림 연구원께 전달)