

본 연구의 알고리즘 — 학부생 수준 설명 (패러다임 → 세부 method)

속도는벡터 · 26-1 인공지능융합설계 · 발표 대본 자료 작성 2026-05-27 · [_drafts/](#) 작업본

발표 대본에 취사선택할 수 있도록 학부 알고리즘 과목 수준의 친절한 설명. 패러다임별 개요 + 그 안의 16개 세부 method 각각.

1. 본 연구의 한 줄 — "표본을 어떻게 뽑느냐"

본 연구는 SQL 쿼리 안에 벡터 유사도 조건이 들어왔을 때 **결과 행의 개수를 미리 추정하는 단계**(카디널리티 추정)에서 "표본을 어떻게 뽑느냐" 한 단계만 통제 변인으로 두고 효과를 측정한다.

Exqutor 논문(arXiv:2512.09695v2)의 §V-B *Adaptive Sampling*은 다음 5 단계 파이프라인을 제안한다.

Query → ① 표본 추출 → ② cardinality 추정 → ③ Q-error 측정 → ④ N 갱신 (→ ① 반복)
★ 본 연구의 개입 위치

본 연구는 ② **cardinality 추정** 안에서 표본을 무작위 베르누이로 뽑던 단계를 "**데이터 분포를 보고 층화(stratification)해서 뽑는다**"로 바꾸었을 때 추정 오차가 어떻게 달라지는지를 검증한다. 논문의 식 1-6과 표본 예산 $N=385$ 는 그대로 두고, 표본 선택 방식만 바꾸었다.

2. 세 가지 비교 방식 (3-way matched)

한 측정 안에서 세 가지 방식을 **동시에 산출**한다. 같은 시드·같은 데이터·같은 쿼리·같은 표본 예산을 쓰므로 외생 요소가 완전히 통제된다.

2.1 베이스라인 (Baseline · B1)

논문 그대로의 무작위 베르누이 표본 추출. - 각 행을 동전 던지기처럼 확률 p 로 뽑는다 ($p = N/\text{전체행수}$). - 표본의 적중 비율로 전체 카디널리티를 추정한다. - **장점**: 단순·편향 없음. - **단점**: 데이터가 한쪽에 몰린 분포(skewed)에서 분산이 크다.

2.2 단독 대체 (Single Replacement · CaseA · 음성 대조군)

베이스라인의 표본을 분포 인지 method의 표본으로 통째 치환한다. - 분포 인지 method가 "어느 영역에서 뽑을지"를 결정. - **목적**: "분포 인지 method 단독으로 무작위를 대체할 수 있을까" 검증. - **결과(미리 알림)**: 35.2%의 측정에서만 베이스라인을 이겼고 평균 +12.90% 더 나뉘었다 → 단독 대체 불가.

2.3 결합 (Combined · CaseB)

베이스라인 추정값과 분포 인지 추정값의 산술 평균.

$$\text{est_final} = (\text{est_baseline} + \text{est_method}) / 2.0$$

- 두 독립 추정량을 평균 → 분산 $\sqrt{2}$ 감소 (양상불 효과).
- **결과**: 89.1% (1,344/1,508)의 측정에서 베이스라인을 이김, 중앙값 -4.38% 개선.

3. ★ Paradigm 별 분류 — 16 method 가 어떻게 표본 선택을 하나

본 연구에서 측정한 16개 method 는 **표본 선택 메커니즘**에 따라 7개 paradigm 으로 분류된다. paradigm 별로 직관을 먼저 보고, 그 안의 세부 method 각각을 설명한다.

Paradigm	직관 한 줄	본 연구 method
P1 Cluster	데이터를 k 개 군집으로 묶고 그 안에서 뽑는다	gmm, minibatch_partial, faiss_ivf
P2 Spatial	고차원 공간을 1차원 곡선·격자로 펼친 뒤 뽑는다	hilbert_real, skilling_hilbert, zorder_morton
P3 Streaming	데이터를 한 번 흘려보내며 가중치로 뽑는다	chao_weighted
P4 DimReduction	고차원을 저차원으로 줄여서 뽑는다	ica_fastica, pca1d, sparse_rp, rsvd
P5 QMC	표본을 균등하게 퍼는 통계학 알고레이션 규칙	cum_sqrtf, lavallee_hidioglou
P6 Quantization	데이터를 작은 코드로 양자화한 뒤 뽑는다	mhst2, rabbitq_strat
P9 InfoTheoretic	정보 이론으로 분포 요약(스케치)을 만든다	hyperloglog

4. Paradigm + 세부 method 학부생 톤 설명

P1 Cluster — 군집화 계열

직관: K-means 처럼 비슷한 행끼리 모아 K 개 군집(cluster)을 만들고, 각 군집에서 일정 수만큼 뽑는다. "비슷한 것끼리 묶었으니 균형 잡힌 표본이 된다" 는 발상.

⚠ **본 연구 결과 (carry §4.7 honest limitation):** 군집화 3 method (gmm, minibatch_partial, faiss_ivf) 는 다중 벡터 고차원(864차원) 에서 군집화 자체가 파탄 — 안정적 우월성을 보이지 못해 **권장에서 제외**.

4.1.1 gmm — Gaussian Mixture Model

- 데이터가 **K개의 정규분포(Gaussian) 합** 으로 이루어졌다고 가정.
- EM 알고리즘으로 각 정규분포의 평균·분산·혼합 비율을 학습.
- 각 행을 가장 가까운 정규분포에 배정 → 그 군집에서 표본 추출.
- **한계:** 데이터가 정규분포가 아니면 군집 경계가 부정확. 학부 머신러닝 수업의 EM/GMM 단원.

4.1.2 minibatch_partial — MiniBatch K-means partial fit

- K-means 의 한 번에 모든 데이터 보는 비싼 단계를 작은 batch (미니배치) 로 쪼개서 점진적으로 학습.
- **partial_fit** 인터페이스로 데이터를 한 chunk 씩 흘려보내며 cluster center 갱신.
- 대규모 데이터에 적합한 변형.
- 학부 자료구조·알고리즘의 "온라인 알고리즘" 개념.

4.1.3 faiss_ivf — FAISS Inverted File Index

- Facebook AI Similarity Search (FAISS) 라이브러리의 IVF 인덱스 구조.
- 벡터 공간을 Voronoi cell 로 나누고 각 행을 가장 가까운 cell 에 배정 → 그 cell 의 inverted list 에서 표본.
- **벡터 검색 인덱스 자체** 를 표본 선택 도구로 재사용.
- 본 연구 paradigm 표에서는 P2 Spatial 로 분류 (IVF 가 공간 분할 메커니즘이라서).

P2 Spatial — 공간 분할 계열

직관: 고차원 벡터를 **1차원 곡선·격자에 매핑** 한 뒤, 그 1차원 좌표를 정렬해 균등하게 뽑는다. "공간을 채우는 곡선 (space-filling curve)" 이라는 수학적 도구를 활용.

4.2.1 `hilbert_real` — Hilbert curve "real" 정렬 (실제는 PCA 2D 사전식 정렬)

- ★ 명칭 정직성 (보고서 §4.7 carry): 이름은 Hilbert curve 이지만 본 연구 구현은 PCA 로 2차원 축소 후 사전식(lexicographic) 정렬 의 alias 다. 진정한 Hilbert curve 는 별도 method (`skilling_hilbert`).
- PCA 1·2축으로 투영 → (x, y) 좌표를 사전식 정렬 → 정렬 순서로 균등 표본.
- 장점: 빠르고 직관적.
- 단점: 진짜 Hilbert curve 의 공간 인접성 보존 성질은 잃음.

4.2.2 `skilling_hilbert` — 진짜 Hilbert curve 정렬

- 차원 d 의 Hilbert 곡선을 따라 모든 행에 1차원 인덱스 부여.
- Hilbert 곡선의 핵심 성질: **공간상 가까운 점은 곡선상 1차원 인덱스도 가깝다** (locality preservation).
- John Skilling (2004) 의 알고리즘 — 비트 시프트로 효율 구현.
- 학부 컴퓨터그래픽스·이미지처리 수업의 공간 채움 곡선 단원.

4.2.3 `zorder_morton` — Morton order (Z-order curve)

- 각 좌표의 비트를 **interleave** 해서 1차원 코드 생성.
- 예: $x=5$ (101)· $y=3$ (011) → $z = 011011$ (비트 섞기).
- Hilbert 보다 단순하지만 locality preservation 약함 (큰 jump 가 일부 발생).
- 학부 데이터베이스의 GIS 인덱스 단원.

P3 Streaming — 스트리밍 계열

직관: 데이터를 **한 번만 흘려보내며** (single-pass) 표본을 결정한다. 메모리 효율 극대 — 모든 데이터를 메모리에 올릴 필요 없음.

4.3.1 `chao_weighted` — Chao-Lee 가중 스트리밍 표본

- Chao (1982) 의 weighted reservoir sampling 변형.
- 각 행에 가중치 w_i 를 부여 — 본 연구에서는 행의 norm 또는 밀도 추정값.
- 흐르는 데이터에서 **확률 $w_i / \sum w$ 로 표본 선택**.
- 표본 추출 단계 1-pass · $O(N)$ 시간 · $O(K)$ 공간.
- 본 연구 결과 1위**: Q-error 중앙값 **-6.22%**, better 100% (1,508 cell 전수).
- fit_time 11초** (빠른 편) — **정확도·속도 균형 최우수** (보고서 §4.6 권장 1순위).

P4 DimReduction — 차원 축소 계열

직관: 고차원 벡터를 **저차원으로 투영**한 뒤 그 저차원 공간에서 표본 선택. 고차원의 저주(curse of dimensionality)를 피하는 발상.

4.4.1 `ica_fastica` — Independent Component Analysis (FastICA)

- PCA 가 분산을 최대화하는 축을 찾는다면, ICA 는 **통계적으로 독립인 축** 을 찾는다.
- Hyvärinen 의 FastICA 알고리즘 — fixed-point iteration.
- 신호 처리의 BSS (Blind Source Separation, 칵테일 파티 문제) 가 대표 응용.
- 학부 신호처리·머신러닝 수업.

4.4.2 `pca1d` — 1차원 PCA

- 첫 번째 주성분 (PC1) 만 사용** — 분산이 가장 큰 축 1개.
- 행을 PC1 축에 사영 → 1차원 좌표 → 정렬·균등 표본.
- 가장 단순한 차원 축소 — 한 줄로 끝.

- 학부 선형대수·통계의 SVD/PCA 단원.

4.4.3 `sparse_rp` — Sparse Random Projection (Li-Hastie-Church 2006)

- ★ 명칭 정직성 (보고서 §4.7 carry): 본 연구 구현은 Li, Hastie, Church (2006) "Very Sparse Random Projections" 의 $1/\sqrt{D}$ 희소 random projection 변형.
- 무작위 행렬 R (대부분 0, 일부 $\pm 1/\sqrt{D}$) 로 곱해서 차원 축소.
- Johnson-Lindenstrauss 보조정리에 따라 거리 보존.
- 학부 머신러닝의 "random projection" 단원.

4.4.4 `rsvd` — Randomized SVD

- 정확한 SVD 가 $O(n^3)$ 너무 비싼 데, 랜덤 투영으로 근사 SVD 를 $O(nk^2)$ 안에 구한다.
- Halko, Martinsson, Tropp (2011) 의 표준 알고리즘.
- 추출된 좌측 특이벡터 (low-rank approximation) 로 행을 임베딩 → 표본 추출.

P5 QMC — 통계학 표본 할당 규칙

직관: 모집단을 미리 정한 strata (계층) 로 나누고, 각 계층에서 최적 개수씩 뽑는다. 통계학에서 100년 가까이 연구된 표본 할당 이론.

4.5.1 `cum_sqrtf` — Cumulative $\sqrt{f}$ rule (Dalenius-Hodges 1959)

- 모집단을 1차원 축으로 정렬 → 데이터 밀도 $f(x)$ 의 누적 $\sqrt{f}$ 함수 그래프 그림.
- 그 누적 $\sqrt{f}$ 가 균등 간격이 되는 점 에서 계층 경계를 정의 → 각 계층에서 동일 개수 표본.
- 직관: 밀집한 영역엔 좁은 계층, 희소한 영역엔 넓은 계층 → 표본 분산 최소.
- 보고서 §2.3 carry — Cochran 1977 §5.5 *Optimum Allocation* 의 표준 규칙.

4.5.2 `lavallee_hidiroglou` — Lavallée-Hidiroglou (1988) 알고리즘

- 비대칭 분포 (skewed) 에서 take-all stratum + take-some strata 의 최적 분할을 반복으로 찾는다.
- 캐나다 통계청 (Statistics Canada) 의 산업 인구조사에서 개발된 알고리즘.
- 극단값 분포(예: 회사 매출 — 소수 대기업 + 다수 중소기업) 에서 강력.

P6 Quantization — 양자화 계열

직관: 고차원 벡터를 짧은 비트 코드 로 압축한 뒤, 그 코드 공간에서 군집화 또는 정렬.

4.6.1 `mhst2` — Multi-dimensional Histogram (MHIST-2)

- Poosala-Ioannidis (1997) "Selectivity Estimation Without the Attribute Value Independence Assumption" 의 multi-dim histogram.
- d 차원 데이터를 bin 으로 분할 — 각 bin 의 빈도수 저장.
- 분포가 균질한 bin 부터 합치고, 분포가 이질적인 bin 은 더 잘게 — 적응적 histogram.
- 학부 DB 의 selectivity estimation 단원.

4.6.2 `rabitq_strat` — RaBitQ stratification

- Gao, Long (2024) "RaBitQ: Quantizing High-Dimensional Vectors with a Theoretical Error Bound" 의 1-bit 양자화.
- 각 차원을 부호 (+/-) 한 비트로 압축 → d 차원 벡터가 d 비트 코드.
- 코드 별 hash bucket → bucket 안 random sample.
- 최신 벡터 압축 method — 본 연구가 stratification 도구로 차용.

P9 InfoTheoretic — 정보 이론 계열

직관: 데이터의 **분포 요약 (sketch)** 을 정보 이론적으로 만들어 전체 분포를 추정.

4.9.1 hyperloglog — HyperLogLog cardinality estimator

- Flajolet 외 (2007) 의 확률적 카디널리티 추정 자료구조.
- 각 행의 hash 값의 **선두 0 의 개수** 의 최대값을 m개 bucket 에 저장 → 그 통계로 **distinct count** 추정.
- 메모리 $O(\log \log n)$ — 1억 distinct value 추정에 1.5 KB 면 충분.
- ★ **본 연구 핵심 통찰 (보고서 §4.2.2 carry)**: hyperloglog 는 **분포 무관 무작위 해시** — 분포 인지 method 가 아니다. 그런데도 결합 (CaseB) 에 넣으면 -4.58% 개선으로 둔갑한다 → "결합의 효과는 분포 인지 X · 단순히 두 독립 추정량 평균의 일반 통계 효과" 라는 본 연구 핵심 메커니즘의 **결정적 증거**.

5. AdaptiveState — 표본 크기를 학습으로 조정 (Exqutor §V-B 식 1-6)

본 연구가 측정에 사용한 추정 루프. 학부 통계·머신러닝의 momentum 개념을 빌렸다.

5.1 초기 표본 크기 — 식 1 (paper p.6 verbatim)

$$N_{\text{initial}} = \lceil z^2 \cdot \hat{p} \cdot (1 - \hat{p}) / e^2 \rceil = 385$$

- $z = 1.96$ (95% 신뢰구간)
- $\hat{p}$ = 추정 적중 비율 (사전 추정)
- e = 허용 오차
- **N = 385 행이 초기 표본** (Bernoulli 정리, 학부 통계의 표본 크기 결정).

5.2 Momentum 갱신 — 식 3-6

δ	$= \alpha \cdot (Q\text{-error} - \beta) - (100 - \alpha) \cdot \text{sampling_ratio}$	(식 3, 오차)
V_t	$= m \cdot V_{\{t-1\}} + \eta \cdot \delta$	(식 4, momentum)
N_{new}	$= N_{\text{old}} + V_t$	(식 5, 표본 크기 갱신)
η_{new}	$= \gamma \cdot \eta$	(식 6, 학습률 감쇠)

- $m = 0.9$ (momentum)
- $\eta_0 = 0.1$ (학습률)
- $\alpha = 50$ (델타 가중치)
- $\beta = 1.5$ (목표 Q-error)
- $\gamma = 0.99$ (감쇠)
- update_period = 50 query 마다

→ **학부 머신러닝 SGD with momentum** 과 정확히 같은 update 구조. 손실 함수 (Q-error) 가 목표 ($\beta=1.5$) 보다 크면 표본을 늘리고, 작으면 줄인다.

6. 평가 지표 — Q-error · plan 회복

6.1 Q-error (식 2, paper p.7 verbatim)

$$Q\text{-error} = \max(C_{\text{est}} / C_{\text{true}}, C_{\text{true}} / C_{\text{est}})$$

- 항상 ≥ 1
- 1.0 = 완벽 추정
- 2.0 = 2배 오차 (과대 또는 과소)
- 학부 ML 의 MSE·MAE 와 다른 점: **비대칭 오차에 대칭 페널티** (DB 옵티마이저가 양방향 오차 모두에 민감).

6.2 Plan 회복 비율

- 추정값을 엔진에 주입했을 때, **정답 plan** (오라클이 정확한 카디널리티로 만든 plan) 과 동일한 plan 을 만들었는가?
- Node Type 의 pre-order tuple 로 plan signature 비교.
- 본 연구: 베이스라인 7/12 = 58% · 결합 13종 평균 **148/156 = 94.9%** plan 회복.

7. 실험 결과 요약 (한 페이지)

7.1 Q-error (offline, 1,508 cell)

방식	평균 추정 오차	베이스라인 이긴 비율
베이스라인 (B1)	1.944	—
단독 대체 (CaseA)	1.984 (더 나쁨)	35.2% ← 음성 대조군
결합 (CaseB)	1.477	89.1% (1,344/1,508)

7.2 method paradigm 별 평균 (offline · 보고서 §4.3 carry)

Paradigm	중앙값 $\Delta\%$ (vs B1)
P3 Streaming (chao_weighted)	-6.22% ①
P4 DimReduction 평균	-4.72%
P2 Spatial 평균	-4.66%
P9 InfoTheoretic (hyperloglog)	-4.58%
P5 QMC 평균	-4.43%
P6 Quantization 평균	-3.52%
P1 Cluster 평균	-1.40% (불안정 — 권장 제외)

7.3 Engine latency (12 cell)

- 베이스라인 (no-inject) → 추정값 주입 모든 방식: **5.67× 가속** · 정답 plan 회복 7/12 → **148/156 = 94.9%**
- 4 방식 inject 끼리: $|\Delta\%| \leq 1.12\%$ **동등** (paired Wilcoxon)
- → "어떤 추정값이든 주입만 하면" 가속 / 4 방식 간 latency 차이는 측정 노이즈 안

8. 한 줄 결론

"표본 선택 단계 한 곳의 개입만으로 추정 오차의 개선 메커니즘 (= 두 독립 추정량 평균 효과, 분포 인지 X) 과 엔진 단 latency 의 구조적 한계 (= 추정 정확도 $\uparrow \neq$ latency $\uparrow$) 를 controlled verification 으로 동시에 규명한 negative + methodological 결과."

9. 발표 대본 활용 가이드

본 문서의 각 paradigm/method 설명은 발표 슬라이드의 5초~15초 짧은 부연설명 으로 취사선택할 수 있다.

추천 활용

- 슬라이드 5 (Exqutor Adaptive Sampling 5 단계): §1 의 pipeline 그림 + §5 의 식 1-6 momentum 풀이
- 슬라이드 7 (3 방식 통제 실험): §2 의 베이스라인·단독대체·결합 정의 3 줄
- 슬라이드 9 (메커니즘 — 단독 대체 음성): §4.9.1 hyperloglog 의 "분포 무관 무작위 해시인데 평균에 넣으면 둔갑" 핵심 증거
- 슬라이드 11 (engine plan 회복): §6.2 plan signature 정의 + §7.3 5.67× 가속 + 94.9% 회복
- Q&A 대비: §4 의 paradigm 별 직관 한 줄 (청자가 "왜 16 method 인가" 묻는 경우)

시간 부족 시 우선순위 (3 분 안 핵심)

1. §2 세 방식 정의 (40초)
2. §4.3.1 chao_weighted (P3 Streaming) 1순위 (30초)
3. §4.9.1 hyperloglog 의 결정적 증거 (30초)
4. §6 Q-error · plan 회복 정의 (30초)
5. §7 결과 요약 (50초)

작성: 2026-05-27 00:15 KST · 본 문서는 발표 대본 자료 carry — 학부 알고리즘·통계·DB 수업 들은 학생 누구나 이해 가능한 톤으로 작성.