



한글 자모 구조를 활용한 3채널 LLM 워터마킹

3-Channel LLM Watermarking based on Hangeul Jamo Structure

TEAM

강희지, 강재현, 박서현, 여운봉

컴퓨터과학과

지도

노알버트 교수님

연세대학교 컴퓨터종합설계 2025

CAPSTONE DESIGN PROJECT

1 연구 배경 및 문제점

기존 BPE 토큰라이저의 한계

- 형태소 훼손: 한글의 의미적 최소 단위가 파괴됨
- 용량 부족: 단일 토큰당 워터마크 삽입 공간 협소
- 재토큰화 오류: 탐지 과정에서 정보 유실 발생

Conventional (BPE)

Low Capacity

인공 ##지능

Proposed (Jamo)

3x Capacity

ㄴ ㅡ ㅇ

제안 솔루션 (Solution)

3채널 자모 분리: 초/중/종성을 독립적인 정보 채널로 활용하여 삽입 용량 증대

Generation-time 개입: Logits 단계에서 확률을 편향시켜 품질 저하 없이 실시간 삽입

2 핵심 기술: 3채널 자모 분해

워터마크 삽입 과정 예시

Payload (메시지):

"ABC"

→ 67 68 69

→ 0100 0001 0100 0010...

TARGET: 01

이번 단계에 선택할 음소: 초성

후보 1: "인공지능"

Selected!

→ Add bias

ㄴ

Index: 1

$9 \bmod 4 = 01$ (Match!)

후보 2: "학습"

ㄴ

Index: 7

$7 \bmod 4 = 11$ ✗

3 시스템 파이프라인

0110

Payload Input

메시지를 이진 비트스트림으로 변환

ABC → 01000001...

0110

Logits Prediction

LLM의 다음 토큰 확률 분포 예측

Top-K Candidates

0110

Jamo Decomposition

마지막 글자를 초/중/종성으로 3채널 분리

능 → ㄴ, ㅡ, ㅇ

0110

Bit Matching & Biasing

Target 비트와 일치하는 토큰의 확률을 증폭

Logits[match] += δ

0110

Watermarked Text

워터마크가 삽입된 텍스트 생성 완료

Output Generation

0110

Visualized by MarkLLM Toolkit

똥 입 니까 "라고 대답 하며, 그는 이렇게 대답 한다. " 그 일 게 되 러면 우리 가 노력 하도록 하 을 하고, 노력 하는 것 에서 부터 시작 해야 할 니 다"라고 덧붙 이 는 그는 미국 식 정 당 에 대 해 회의 적인 생각 을 거 듭

Watermarked

말 니 다. " * 저는 여기 았 아 당신 의 꿈 과 희망 을 믿 는 단 말 씀 입 니 다 ! " * 저는 이렇게 말 씀 드 리 지 요. 제 꿈 을 이루 는 것 만 을 원 합 니 다. 꿈 의 세 계 에 서 는 할 상 신 이

Unwatermarked

4 실험 결과

METRIC

VALUE

Payload Capacity

3.0 bits/token

Robustness

(Custom Deletion Attack)

91.7%

MarkLLM

Robustness Evaluation

TPR: 0.695
F1: 0.82

Detection Result (Example)

Extracted: 01000001 0100010...

Recovered Message:

"ABC"

* KoGPT2-base-v2, Bias 5.0 조건 실험 결과

5 결론 및 기대효과

0110

한국어 최적화

자모 구조를 보존하는 최초의 3채널 워터마킹

0110

고용량 데이터

기존 대비 획기적인 정보 삽입량 확보

0110

오픈소스 확장성

다양한 LLM 및 토큰라이저에 즉시 적용 가능

본 기술은 AI 생성 콘텐츠의 저작권을 보호하고 불법 유포를 추적하는 기술로 활용될 수 있을 것입니다.



GitHub

프로젝트 데모 및
보고서 전문 확인

SCAN ME!