

Skew-Aware Stratified Sampling 을 이용한 벡터 카디널리티 추정 정확도 개선 연구

인종설 중간보고서

팀명 : 속도는벡터

팀 원	
팀장	박세은
팀원	강재현
팀원	이동욱
팀원	조현빈

지도교수

박광현 교수님

지도 연구원

이채림 연구원

2026 년 4 월

Contents

1. 연구 주제

2. 연구의 필요성

3. 연구 내용

- I. Exqutor 의 두 보완책과 단일 테이블 사각지대
- II. RQ1 — 사각지대의 구조적 한계 확인
- III. RQ2 — 두 단계 sanitize 의 직교 측정
- IV. RQ3 — 분포를 모르는 환경으로의 확장 (설계)

4. 현재 진행 상황

5. 일정 및 역할 배분

1. 연구 주제

이번 연구의 주제는 벡터 데이터베이스에서 거리 기반 조건 $WHERE (v \leftrightarrow q) < D$ 의 카디널리티(cardinality) 추정 문제이다. 우리는 최근 발표된 Exqutor (arXiv:2512.09695v2) 시스템이 단일 테이블 vector range query 시나리오에서는 활성화되지 않는다는 사실을 소스 코드를 직접 분석하여 확인하였고, 이 사각지대를 두 단계의 sampling 개선으로 보완할 때 추정 정확도가 어느 정도 개선되는지를 정량적으로 측정하였다. 새로운 알고리즘을 제안하기보다는 기존 시스템의 구조적 한계를 분석하고 단계적인 sanitize 의 효과를 측정하는 데 무게를 두었으며, 따라서 본 보고서의 산출물은 측정 가능한 정확도 개선 수치와 그에 대한 인과적 설명으로 구성된다.

2. 연구의 필요성

벡터 데이터베이스의 활용 범위는 최근 몇 년 사이 크게 넓어졌다. 대규모 언어 모델의 RAG (Retrieval-Augmented Generation) 파이프라인, 멀티모달 검색, 추천 시스템, 이상 탐지 등 다양한 응용에서 벡터 유사도 검색은 핵심 연산이 되었으며, 단순한 top-k 검색을 넘어 WHERE ($v \leftrightarrow q$) < D 형태의 거리 임계값 기반 범위 검색과 관계형 연산(조인·집계·필터)이 결합된 분석 쿼리, 즉 VAQ (Vector-Augmented Analytical Query) 형태로 사용되는 경우가 많다.

이러한 쿼리를 효율적으로 실행하려면 옵티마이저가 각 연산의 결과 행 수를 정확하게 추정해야 한다. 카디널리티 추정값은 인덱스 사용 여부, 조인 알고리즘과 순서 등 실행 계획의 거의 모든 결정에 영향을 미치기 때문이다. 그러나 pgvector·VBASE·DuckDB 등 주요 시스템은 카디널리티를 각각 33.3 %, 50 %, 100 % 의 고정 비율로 추정하기 때문에, 0.001 % 에서 100 % 까지 변동하는 실제 카디널리티와 큰 괴리가 생긴다. 이로 인한 잘못된 plan 선택은 실행 시간을 최대 4 orders of magnitude (약 1 만 배) 까지 증가시킨다.

Exqutor 는 이 한계를 인덱스의 유무에 따라 두 경로로 보완한다. 인덱스가 있을 때는 ECQO (Exact Cardinality Query Optimization) 로 HNSW 인덱스에 range query 를 직접 한 번 실행하여 정확한 카디널리티를 얻고, 인덱스가 없을 때는 Adaptive Sampling 으로 모멘텀 기반의 동적 샘플링을 통해 카디널리티를 근사한다. 그러나 Exqutor 의 vector.c 를 직접 분석한 결과, Adaptive Sampling 의 핵심 hook 은 다중 테이블 조인 시나리오에서만 활성화되도록 설계되어 있어 이미지 검색·추천·RAG retrieval 의 근간인 단일 테이블 vector range query 가 보완책에서 배제된다는 사실을 확인하였다. 이는 원논문에 명시되지 않은 사각지대이며, 이번 연구는 이 빈자리에서 단일 테이블에 적합한 sampling 방식을 단계적으로 검증한다.

3. 연구 내용

I. Exqutor 의 두 보완책과 단일 테이블 사각지대

Exqutor 의 두 보완책은 동작 원리 자체가 서로 다르다. ECQO 는 벡터 인덱스가 있을 때 옵티마이저의 plan 수립 단계에서 가벼운 range query 를 실제로 실행하여 정확한 카디널리티를 얻는 방식이다. 인덱스 검색이 매우 빠르다는 점을 활용하므로 오버헤드가 매우 작고, 결과적으로 카디널리티는 추정이 아니라 정확한 값으로 옵티마이저에 전달된다. 반면 Adaptive Sampling 은 인덱스가 없을 때 사용되는 방식으로, TABLESAMPLE 절을 통해 일부 행만 추출하여 임계값을 만족하는 비율을 계산하고 그 비율로부터 카디널리티를 근사한다. 두 방법 모두 옵티마이저의 비용 모델에 정확한 정보를 제공함으로써 잘못된 plan 선택을 막는 것이 목적이며, 원논문은 두 방법으로 pgvector 에서 최대 약 1,000 배, VBASE 에서 최대 약 1 만 배의 속도 향상을 보고한다.

그러나 우리가 발견한 설계상의 제약은 Adaptive Sampling 쪽에 집중되어 있다. `vector.c` 의 line 243 에 있는 `if (table_count > 2)` 조건문은 Adaptive Sampling 의 핵심 hook 이 호출되기 위한 진입 조건이고, 따라서 테이블이 두 개 이하인 단일 테이블 쿼리는 이 조건을 통과하지 못한다. 예를 들어 `SELECT count(*) FROM partsupp_deep_10_subset_1m WHERE (ps_embedding <-> q) < D` 와 같이 매우 일반적인 형태의 vector range query 는 hook 경로에서 배제되어 PostgreSQL 의 default selectivity 1/3 로 fall-through 된다. 우리는 이 동작을 직접 소스 검증으로 처음 정량 확인하였으며, Exqutor 가 자신의 multi-table only design intent 로 배제한 사각지대(blind spot)에 해당한다고 본다.

이 사각지대를 다음 세 단계의 연구 질문으로 분석·개선한다. RQ1 에서는 사각지대의 구조적 한계와 설계상의 제약을 직접 소스 검증으로 정량화한다. RQ2 에서는 데이터의 분포를 알 수 있을 때 두 가지 직교적인 sanitize, 즉 block sampling bias 제거 (BERNOULLI 교체) 와 data-side k-means 기반 stratified sampling 의 native 구현이 카디널리티 추정 정확도를 어느 정도 개선하는지를 측정한다. RQ3 에서는 데이터의 분포를 사전에 모르는 상황에서 RQ2 의 공간 인식 효과를 어느 정도 회수할 수

있는지를 Recovery Rate 라는 프레임워크로 평가한다. 본 보고서는 RQ1 과 RQ2 의 결과를 보고하고, RQ3 는 설계 안만을 제시한다.

II. RQ1 — 사각지대의 구조적 한계 확인

RQ1의 목표는 Exqutor의 Adaptive Sampling이 단일 테이블 vector range query 시나리오에서 실제로 어떤 한계를 가지는지를 직접 소스 검증과 EXPLAIN ANALYZE로 드러내는 것이다. 검증 과정에서 우리는 다음 네 가지 발견에 도달하였다.

첫째, **hook trigger 사각지대**가 존재한다. `vector.c` line 243의 `if (table_count > 2)` 조건은 단일 테이블 쿼리의 카디널리티 추정 경로 자체를 배제한다. 우리의 검증 query는 `table_count = 1`이므로 hook이 우회되고 PostgreSQL의 default selectivity 1/3으로 fall-through된다. 이 동작은 Exqutor 원논문의 본문에는 명시되지 않은 설계상의 제약이며, 우리의 직접 소스 검증으로 처음 정량 확인되었다.

둘째, hook을 강제로 활성화할 경우 **plan replacement 부작용**이 발생한다. 위 hook을 `table_count >= 1`로 한 줄 우회하면, 단일 테이블 시나리오에서는 outer query의 base relation 자체가 Sample Scan으로 plan-tree가 교체되어 outer query의 결과가 sample 안의 부분 카운트로 격하된다. 실제 100,000행이 결과로 나와야 할 `SELECT count(*)`가 32를 반환하는 식이다. 다중 테이블 조인에서는 base table의 sample scan이 join 결과에 부분적으로만 영향을 주지만, 단일 테이블에서는 outer query 자체의 의미가 깨져 버린다. 따라서 hook의 단순한 강제 활성화는 해법이 되지 못하며, sampling 방식 자체를 손보아야 한다는 결론으로 자연스럽게 이어진다.

셋째, **TABLESAMPLE SYSTEM block bias**의 문제가 있다. Adaptive Sampling이 사용하는 TABLESAMPLE SYSTEM은 PostgreSQL의 8 KB 페이지 블록 단위로 데이터를 추출하기 때문에, 같은 블록 안의 행들은 함께 추출되거나 함께 배제된다. 그 결과 행 단위의 균일성이 깨지고 추정의 분산이 커진다. 이 발견은 RQ2-1의 sanitize 대상으로 곧장 이어진다.

넷째, **query feature**를 사전에 식별하기 어렵다는 점이 확인되었다. 4가지 글로벌 skewness 지표 (Fisher γ , log-Fisher γ , tail ratio P99/P50, Bowley skew)와 query 별 median Q-error의 Spearman 상관을 96차원 DEEP 1M subset의 6,000 추정에서 검증한 결과, 24개 조합 모두에서 절대값 0.2 미만으로 가설이 강하게 기각되었다. 100 query 모두가 Fisher $\gamma < 0$ (left-skewed)이며

tail ratio 도 좁은 범위에 모여 있는 점에서, 고차원 벡터의 거리 집중 현상이 글로벌 지표의 변별력을 평탄화시킨 것으로 해석된다. 이 결과는 query 시점에 분포를 사전 식별하는 단순 휴리스틱이 작동하지 않음을 의미하며, 이번 연구가 RQ2 (distribution-aware) 와 RQ3 (distribution-agnostic) 두 트랙을 모두 다루어야 하는 핵심 근거가 된다. 한편 hook 을 강제 활성화한 직후의 update 경로에서는 q-error 발산, sample_size NaN, SIGSEGV 같은 추가 발산이 관찰되었으며, 본 측정에서는 update 경로를 차단하여 sampling method 자체의 효과만을 분리해서 측정하였다.

III. RQ2 — 두 단계 sanitize 의 직교 측정

RQ2 는 데이터의 분포를 알 수 있을 때 두 가지 직교적인 sanitize 가 카디널리티 추정 정확도를 어느 정도 개선하는지를 측정한다. **RQ2-1 (Block sampling bias 제거)** 는 `vector.c` 의 `TABLESAMPLE SYSTEM(p%)` 호출을 `TABLESAMPLE BERNOULLI(p%)` 로 교체하여 block bias 를 제거하고 행 단위 균일성을 회복하는 것이다. **RQ2-2 (Stratified sampling)** 는 data-side 에서 사전에 k-means ($K = 20$) 으로 데이터를 20 개 cluster 로 분할한 뒤, 각 cluster 별로 균등 샘플을 추출하고 Horvitz-Thompson 가중치 (cluster 별 inclusion probability 의 역수) 를 적용해 카디널리티를 계산하는 것이다. 두 sanitize 는 서로 직교하므로 ablation matrix 에서 효과를 분리해서 측정할 수 있다.

(1) RQ2-1 검증 — Block bias 제거의 효과

DEEP 1M 데이터셋에서 100 개 쿼리와 6 개 selectivity 구간에 대해 SYSTEM 과 BERNOULLI 만을 변화시킨 paired Wilcoxon 검정을 수행하였다. 표 1 은 EXPLAIN ANALYZE 의 `plan_rows` 를 reference 로 한 Python counterfactual 결과이며, native `vector.c` 한 줄 교체로 측정한 같은 비교에서도 + 3.8 ~ + 9.6 % 의 같은 자릿수 개선이 확인되어 두 측정의 방향이 일치한다.

표 1. Selectivity 별 SYSTEM 과 BERNOULLI 의 median Q-error 비교 (DEEP 1M, 100 query, plan_rows 기반 Python counterfactual)

Selectivity	SYSTEM median	BERNOULLI median	개선율	p-value	승리 (SYS<BERN)
0.001	2.5970	2.5970	+0.0 %	0.596	6 / 8
0.010	1.5584	1.2987	+20.0 %	0.240	45 / 40
0.050	1.2031	1.1948	+0.7 %	0.0009	58 / 37
0.100	1.2120	1.1323	+7.0 %	<0.001	66 / 31
0.300	1.2095	1.0794	+12.0 %	<0.001	76 / 24
0.500	1.1527	1.0519	+9.6 %	<0.001	78 / 22

Selectivity 0.050 이상의 4 개 구간에서 모두 paired Wilcoxon $p < 0.001$ 로 SYSTEM 의 Q-error 가 BERNOULLI 보다 통계적으로 유의하게 크게 나타났으며, 가장 큰 효과는 selectivity 0.500 에서 100 개 쿼리 가운데 78 개가 SYSTEM 쪽 불리한 결과로, median 기준 약 9.6 %p 의 개선이었다.

vector.c 한 줄의 교체만으로 Exqutor 의 카디널리티 추정 정확도가 측정 가능한 수준으로 개선될 수 있음을 보여 주는 결과이다. 반면 selectivity 가 매우 낮은 구간 ($s = 0.001, 0.010$) 에서는 결과 행 수가 절대적으로 작아 plan_rows 의 정수 양자화가 측정의 분해능을 제한하기 때문에 두 표본 간의 통계적 차이가 뚜렷하지 않았으며, 이 영역의 효과는 RQ2-2 의 stratified sampling 에서 별도로 다룬다.

(2) RQ2-2 검증 — Stratified sampling 의 5-seed 평가


KM20 stratified sampling 의 BERN 대비 추가 효과를 5 개 seed (setseed 0.1 ~ 0.5) 의 반복 측정으로 검증하였다. 표 2 는 세 데이터셋 (DEEP 1M, DEEP 8M, SIFT 1.5M) 의 selectivity 0.500 / 0.050 / 0.010 구간에 대한 5-seed 평균 개선율과 95 % 신뢰구간이다. 측정은 모두 native vector.c 의 STRAT 분기에서 수행되었으며, q-error 산출에는 hook 이 elog 로 서버 로그에 기록한 hook_est 를 기준으로 사용하였다.

표 2. KM20 vs BERN 의 5-seed 평균 개선율과 95 % 신뢰구간 (native vector.c 측정)

데이터셋	s = 0.500	s = 0.050	s = 0.010
DEEP 1M	+1.64 % [+1.11, +2.18]	+1.85 % (단일 seed)	+8.93 % (단일 seed)
DEEP 8M	+1.76 % [+0.65, +2.86]	+0.55 % [-3.11, +4.21]	-0.71 % (노이즈 영역)
SIFT 1.5M	+3.07 % [+2.66, +3.48]	+4.39 % [+2.63, +6.15]	-0.53 % (양자화 영역)

DEEP 1M 의 $s = 0.500 / 0.300 / 0.100$ 세 구간은 모두 95 % 신뢰구간의 하한이 양수로 확정되었고, DEEP 8M 의 $s = 0.500$ 신뢰구간 [+0.65, +2.86] 은 1M 의 [+1.11, +2.18] 과 겹쳐 데이터 규모가 달라져도 효과가 유지됨을 보여 준다. SIFT 1.5M 의 $s = 0.500$ 신뢰구간 [+2.66, +3.48] 은 DEEP 의 신뢰구간과 겹치지 않으며, 더 쏠린 분포에서는 KM20 의 효과가 약 두 배로 커지는 것이 관찰된다. 그림 1 은 세 데이터셋의 selectivity 별 개선율 변화를 함께 보여 준다.

Figure 7 · DEEP 1M Selectivity Gradient — KM20 vs RANDOM20 (95% CI)



주: KM20은 모든 selectivity에서 양의 개선. RANDOM20은 $s=0.01$ 에서 -10.67%로 악화.
 격차가 클수록 공간 인식의 가치가 큼 (좁은 쿼리일수록 KM20 우위 확대).
 $s=0.05, s=0.01$ 은 단일 측정(Phase 6)이라 CI 없음 — 보충 5-seed 재측정은 최종보고서 예정.


그림 1. 세 데이터셋의 selectivity 별 KM20 vs BERN 개선율 (5-seed 95 % CI)

(3) Two-Level Decomposition — 표본 안정화와 공간 인식의 분리

KM20의 개선분이 어떤 메커니즘에서 비롯되는지를 알아보기 위해 우리는 두 수준으로 분해하였다.

Level 1 (표본 안정화)은 단순히 데이터를 $K = 20$ 으로 분할하여 비례 배분만 적용해도 발생하는 표본 크기 안정화 효과이고, **Level 2 (공간 인식)**는 cluster가 거리 기반 (KM20)일 때만 추가로 발생하는 공간 인식 효과이다. DEEP 1M의 selectivity 0.010에서 KM20과 RANDOM20의 격차는 19.6%p로 측정되었으며, 좁은 selectivity 영역에서 무작위 파티션은 오히려 -10.67%로 악화된 반면 KM20은 +8.93%를 유지하였다. 즉 Level 2가 단독으로 +19.60%p를 기여한 셈이다. 이 결과는 우리가 본 연구의 출발에서 세웠던 가설 — *데이터의 쏠림이 클수록 공간 인식 sampling의 가치가 크다* — 의 인과 관계를 직접 보여 준다.

Figure 9 · Two-Level Decomposition — KM20 개선을 비례 배분(L1)과 공간 인식(L2)으로 분해




주: Level 1은 RANDOM20의 개선분(파티션 품질 무관). Level 2는 KM20-RANDOM20 격차(공간 인식 기여). selectivity가 클수록 Level 2의 기여가 급증하며, DEEP 1M s=0.01에서 Level 2 단독 +19.60%p, SIFT는 s=0.50부터 이미 Level 2(+2.06%)가 유의 — 풀림이 클수록 공간 인식의 영향이 낮은 구간에 발현.

그림 2. Two-Level Decomposition — Level 1 (표본 안정화) 과 Level 2 (공간 인식) 의 분리

(4) HHI 와 CV — 데이터셋별 효과 격차의 사전 예측

SIFT 의 KM20 효과가 DEEP 의 약 두 배에 달하는 이유를 정량적으로 설명하기 위해 우리는 각 데이터셋의 $K = 20$ cluster 크기 분포를 HHI (Herfindahl-Hirschman Index) 와 CV (변동계수) 로 측정하였다. HHI 는 각 cluster 비율의 제곱합으로, 균일할 때 $1/K = 0.05$ 이며 한 cluster 에 집중될수록 1.0 에 가까워진다. 측정 결과 DEEP 1M 의 cluster 크기 CV 는 0.234 였고 SIFT 1.5M 은 0.394 로 약 68 % 더 쏠려 있었으며, 이러한 쏠림 격차가 KM20 효과의 약 두 배 격차와 함께 커지는 경향을 보였다. 즉 KM20 의 효과는 데이터셋이 가지고 있는 고유한 cluster 쏠림 분포로부터 어느 정도 사전에 예측할 수 있으며, 이는 RQ3 (distribution-agnostic) 단계에서의 비교 baseline 으로도 활용된다.

Figure 10 · 데이터셋 클러스터 쉐임 — DEEP 1M vs SIFT 1.5M



주: HHI는 각 클러스터 비율의 제곱합(균일=1/K=0.05), CV는 표준편차/평균(균일=0).
SIFT는 최대 클러스터 14.8만으로 기대값 7.5만의 2배, 클러스터 1과 18 합계가 전체의 약 19% (기대 10%).
쉐임의 정량 차이가 Figure 8의 KM20 효과 2배 격차의 직접적 원인.

그림 3. DEEP 1M 과 SIFT 1.5M 의 K = 20 cluster 크기 분포 비교

IV. RQ3 — 분포를 모르는 환경으로의 확장 (설계)

RQ3 는 데이터의 분포를 사전에 모르는 상황에서 사전 학습 없이 RQ2 의 공간 인식 효과를 어느 정도 회수할 수 있는지를 측정한다. 회수율은 **Recovery Rate = (방법 X - RANDOM20) / (KM20 - RANDOM20)** 로 정의하고, 다음 세 패러다임의 일곱 가지 방법을 동일한 metric 으로 비교하는 프레임워크를 설계하였다.

Offline Partition 패러다임은 데이터를 적재할 때 한 번만 계산해 두는 경량의 사전 처리에 해당한다. 여기에는 LSH 랜덤 하이퍼플레인 (A), Random Projection (C, Johnson-Lindenstrauss lemma 기반), Hilbert Curve (E, 공간 데이터베이스의 space-filling 기법을 벡터 카디널리티 추정에 처음 적용), Mini-batch K-means (F, 1 ~ 5 % 데이터만으로 근사 학습) 의 네 가지가 포함된다. **Online Query-Adaptive** 패러다임은 쿼리 시점에 pilot sample 로 동적으로 적응하는 방식으로, Distance-Shell (G, 쿼리 벡터 중심의 동심원) 과 KDE-pilot (B, Neyman 의 최적 배분) 의 두 가지를 포함한다. **Weight-based** 패러다임은 파티션 없이 가중치만으로 분산을 줄이는 방식으로, Importance Sampling (H) 한 가지를 포함한다. 본 보고서 시점에서는 일곱 가지 방법의 설계만 확정된 상태이며, 실제 측정은 최종보고서 단계의 W5 ~ W7 (4/28 ~ 5/18) 에서 수행한다.

4. 현재 진행 상황

4 월 초에는 지도 연구실로부터 Exqutor 의 소스 코드와 실험용 데이터셋, 그리고 실험 서버에 대한 접속 권한을 인계받아 빌드와 환경 세팅을 수행하였다. 4 월 14 일까지 빌드와 권한 설정 그리고 `vector.c` 의 patch 적용을 마쳤고, 같은 시점에 본 연구의 출발 가설이었던 글로벌 skewness 가설을 직접 검증하는 과정에서 가설의 기각과 단일 테이블 사각지대 발견이라는 두 가지 핵심 발견에 도달하였다. 4 월 15 일에는 RANDOM20 대조 실험을 통해 좁은 selectivity 영역에서 19.6 %p 의 격차를 확보하였고, 이로써 본 연구 가설의 인과 관계를 데이터로 뒷받침하였다.

이어서 4 월 16 일에는 DEEP 8M 으로 외적 타당성을 확인하였고, 4 월 17 일에는 SIFT 1.5M 까지 확장하여 5-seed 95 % 신뢰구간을 산출하였다. 4 월 21 일에는 자문위원으로부터 본 연구 방향에 대한 회신을 받았으며, 단일 테이블 시나리오로의 좁힘과 두 sanitize 의 직교 측정 설계가 적절하다는 평가였다. 그 이후로 본 보고서의 작성에 착수하여 4 월 28 일의 중간 발표 및 보고 마감을 준비하고 있다.

실험 측면에서는 본 보고서에 보고된 모든 결과 — 표 1 의 SYSTEM ↔ BERNOULLI 비교, 표 2 의 5-seed 신뢰구간, 그림 1 ~ 3 의 selectivity gradient 와 Two-Level decomposition, cluster skew 비교 — 가 모두 확보된 상태이다. 모든 측정 데이터와 빌드 산출물은 재현 가능하도록 보존하였으며, 원본 코드와 수정본을 함께 유지하여 추후의 검증과 비교를 용이하게 하였다. RQ3 의 측정 결과는 5 월의 비교 실험을 마친 뒤 최종보고서에서 보고한다.

5. 일정 및 역할 배분

표 3. 캡스톤 2026-1 학기 전체 일정

주차 / 기간	핵심 작업	상태
W1 ~ W5 (3/2 ~ 4/5)	팀 구성, 논문 리딩, 1 차 자문, 연구제안서·수행계획서 작성·제출, 연구 방향 확정	완료
W6 (4/6 ~ 4/12)	실험 서버 권한 인계 및 Exqutor 환경 세팅	완료
W7 (4/13 ~ 4/19)	vector.c 빌드 완료, RQ1 motivation 발견, RQ2-1·RQ2-2 실험 수행	완료
W8 (4/20 ~ 4/26)	외적 타당성 실험 (DEEP 8M, SIFT 1.5M), 2 차 자문 회신 반영	완료
W9 (4/27 ~ 5/3)	중간보고서 및 중간발표 자료 작성·제출	진행
W10 ~ W12 (5/4 ~ 5/24)	RQ3 일곱 가지 sampling 방법 비교 실험 수행 및 결과 분석	예정
W13 ~ W15 (5/25 ~ 6/14)	최종발표 (5/27 ~ 5/29), 전시회 (6/5), 최종보고서 작성·제출 (6/11)	예정

표 4. 팀원별 역할 배분

팀원	주요 역할
박세은 (팀장)	팀 일정·문서 관리, 자문 컨택, 회의 주재
강재현	발표 자료 작성, 발표 담당, 시각화 제작
조현빈	Exqutor 코드 분석, 실험 구현, 통계 분석
이동욱	보고서 작성, 실험 결과 검증, 자문 회신 정리

중간발표 이후의 5 월은 RQ3 의 일곱 가지 sampling 방법을 동일한 측정 파이프라인에서 비교하는 작업에 집중하며, 6 월에는 최종발표·전시회·최종보고서 작성을 마무리한다.