

속도는벡터 — 중간 발표 예상 질문 cheat sheet

대상: 강재현 (주 발표자), 박세은·이동욱·조현빈 (Q&A 분담 대비)

작성: 2026-04-27 22:00 KST

발표 일시: 2026-04-30 (목) 19:00 인증 A428

Q&A 시간: 5 분

발표 시간: 10 분 (10 분 초과 강제 중단)

0. 사용 가이드

본 문서는 어떤 질문이 들어와도 30 초 안에 정확하고 침착하게 답할 수 있도록 만든 종합 대응표다. 청중에는 캡스톤 심사위원, 다른 팀, 지도교수, 자문위원이 섞여 있고, 이들의 배경(시스템·통계·DB·ML)이 모두 다르므로 같은 질문에도 길이·깊이·언어 사용 정도가 달라야 한다.

답변 3 단 구조

각 질문에 대해 세 단계 답변이 준비되어 있다.

단계	길이	용도
① 핵심 한 줄	10 ~ 15 초	자신감 있게 본질만 — Q&A 시간 부족·청중 가벼울 때
② 표준 답변	30 ~ 60 초	기본 모드. 핵심 한 줄 + 근거 1 ~ 2 개 + 마무리
③ 디테일 보강	1 ~ 3 분	꼬리 질문·심화 추궁 시. 수치·메커니즘·통계까지

청중별 톤 조정

청중	톤
시스템 배경 (DB·OS)	hook 코드, table_count > 2, plan-tree, 8KB 블록 단위 같은 식별자를 그대로
통계 배경	Wilcoxon paired, 95% CI, $p < 0.001$, Cohen's d, BH-FDR 같은 메타 위주
ML/벡터 배경	k-means, embedding, 96d/128d, ANN, JL lemma, LSH 같은 용어 자유
일반 (비전공)	"8KB 블록 단위" → "디스크 한 페이지", "베르누이" → "동전 던지듯" 같은 풀이

발표자 분담 (회의 합의, 4/27)

발표자(강재현)가 사회를 보면서, 질문 영역에 따라 답변자를 지목한다.

- 이론·통계·실험 결과: 강재현 (1차) ↔ 조현빈 (보강)
- 코드·구현·서버: 조현빈
- 분석·작도·RQ3 설계: 이동욱
- 자문·일정·범위 결정: 박세은
- 모르는 질문: "좋은 지적이십니다. 이 부분은 보충 실험으로 5월에 확인 예정이며, 현재 시점에서는 가설 단계입니다." (자신감 있게)

모르는 질문이 들어오면 — 4 가지 안전 답변

1. "이 부분은 RQ3 (5월) 또는 W5-W6 (보충실험·통계 보강)에서 측정 예정이며, 현 보고서 시점에서는 설계만 보고했습니다." — 측정 안 한 부분
2. "좋은 지적이십니다. 본 연구가 다루지 못한 영역으로, 후속 연구 또는 향후 계획에서 확인하고자 합니다." — 범위 밖
3. "원논문(Exqutor)의 정의를 그대로 따랐으며, 우리 측정 시점에서 검증한 부분만 보고했습니다." — 외부 인용
4. "즉답하기 어려운 질문입니다. 발표 후 메일/노션으로 구체 수치를 정리해 드리겠습니다." — 진짜 모를 때 (1번에 1번까지만)

절대 금기

- "잘 모르겠습니다" 단독 (X) → 위 4 가지 안전 답변 중 하나로 변환
- "그건 제 분야가 아닙니다" (X) → 4 명이 한 팀이라는 메시지 손상
- 즉석 추측 수치 (X) → 보고서·발표·본 cheat sheet 의 수치만 인용
- 길어지는 답변 (X) → Q&A 5 분에 보통 5 ~ 8 개 질문 수용. 한 답변당 30 초 이내가 원칙

1 페이지 핵심 요약 — 이 표만 외워도 5 분 살아남는다

본 연구의 4 줄 요약

1. 사각지대 (RQ1): Exqutor 의 Adaptive Sampling 진입 조건이 `table_count > 2` 라서 단일 테이블 검색에서는 작동하지 않는다 (이미지 검색·추천·RAG 의 핵심 형태인데도).

2. **추출 단위 보완 (RQ2-1)**: 8KB 블록 단위 추출을 행 단위 베르누이 추출로 바꿨더니 selectivity 0.5 에서 100 개 중 78 개 우세, 중앙값 9.6 % 개선 ($p < 0.001$).
3. **공간 인식 보완 (RQ2-2)**: k-means K=20 층화 표본을 베르누이 위에 추가했더니 1.6 ~ 4.4 % 의 추가 개선 (5-seed 95 % CI 양수 확정).
4. **인과 입증 (Two-Level)**: 같은 K=20 으로 나누되 무작위로 나누면 -10.67 % 악화, 거리 기반(k-means) 으로 나누면 +8.93 % 개선 → 공간 인식 단독 효과 +19.6 %p.

핵심 수치 7 개 — 발표 중 외워서 말하는 숫자

수치	의미	출처
9.6 %	DEEP 1M $s=0.500$ 에서 베르누이 추출의 Q-error 중앙값 개선	표 1, RQ2-1
+1.6 ~ 4.4 %	세 데이터셋 $s=0.500$ 에서 KM20 의 추가 개선 (95 % CI 양수)	표 2, RQ2-2
+19.6 %p	DEEP 1M $s=0.010$ 에서 KM20 vs RANDOM20 격차 (Level 2 단독)	Two-Level
3.07 %	SIFT 1.5M $s=0.500$ KM20 추가 개선 (DEEP 의 약 2 배)	표 2, RQ2-2
CV 0.234 vs 0.394	DEEP 1M vs SIFT 1.5M 클러스터 쏠림 격차 (68 % 더 쏠림)	HHI/CV
1 만 배	VBASE 에서 카디널리티 잘못 추정 시 실행 시간 폭발 상한	Exqutor 원논문
**	Spearman ρ	$< 0.2^{**}$

본 연구가 하지 않은 것 — 솔직하게 인정

- **End-to-end query time 측정 X** — Q-error (추정 정확도) 만 측정. 실행 시간 영향은 옵티마이저의 plan 선택 메커니즘으로 간접 추론.
- **VBASE/pgvector/DuckDB 와 직접 head-to-head 비교 X** — Exqutor 코드를 직접 수정하는 형태이므로 다른 시스템 비교는 RQ3 또는 후속 연구.
- **K=20 외 K sweep X** — RQ2 에서는 K=20 고정. K sensitivity 는 W5 보충 실험 (5 월) 또는 RQ3 설계에 통합.
- **Multi-table join 시나리오 X** — 단일 테이블 사각지대로 좁힌 의도적 선택. Exqutor 의 multi-table 가정을 깨지 않음.
- **10 seed × 500 query 본격 검정력 측정 X** — W6 (5 월 12 일경) 에 BH-FDR + TOST + Cohen's d 까지 확보 예정. 현재는 5 seed × 100 query.
- **RQ3 측정 X** — 7 가지 방법 설계만 보고. 측정은 5 월 (W10 ~ W12).

발표 동선 — 청중이 들고 갈 한 문장

"기존 시스템의 빈자리를 코드로 확인하고, 코드 세 줄 보완으로 통계적으로 유의한 개선을 만들었으며, 그 개선이 어떤 메커니즘에서 오는가를 데이터로 입증했다. 분포를 모르는 환경으로의 확장은 5 월에 비교 실험한다."

섹터 1. 연구 동기 & 배경 (Why this research?)

벡터 데이터베이스가 왜 중요한지부터 묻는 가벼운 청중·심사위원 대비. 5 ~ 6 개 질문이 충분히 가능.

Q1.1 카디널리티 추정이 왜 그렇게 중요한가요? 1 % 정확도 개선이 정말 의미가 있나요?

핵심 한 줄: 카디널리티 한 번의 짐작이 옵티마이저의 plan 선택을 결정하고, 잘못된 plan 한 번이 실행 시간을 1 만 배까지 늘리기 때문입니다.

표준 답변 (40 초)

옵티마이저는 SQL 쿼리를 실행하기 전에 "이 조건을 만족하는 행이 몇 개나 나올까" 를 미리 추정합니다. 이 추정값에 따라 인덱스 사용 여부, 조인 순서, nested loop 와 hash join 사이의 선택이 결정됩니다. 추정이 1 % 어긋나는 것 자체가 문제가 아니라, 그 어긋남이 *plan 의 categorical 한 변경* 을 일으키는 임계점 근처에서 큰 차이를 만듭니다. Exqutor 원논문이 보고한 VBASE 1 만 배 이상의 실행 시간 차이도 이런 임계점에서의 plan 변경 때문입니다. 따라서 1 % 의 정확도 개선은 임계점 근처 쿼리들이 잘못된 plan 을 고를 확률을 줄이는 의미입니다.

디테일 보강 (3 분 분량 — 꼬리 질문 시)

Selinger 1979 이래 카디널리티 추정은 query optimization 의 가장 큰 unsolved problem 중 하나입니다. PostgreSQL 의 ANALYZE 로 만드는 histogram 도, 다중 컬럼 상관관계나 거리 기반 조건 같은 비선형 술어에서는 정확도가 빠르게 떨어집니다. 벡터 거리 조건은 그중에서도 어려운 케이스인데, 분포가 매우 비대칭이고 선택도가 0.001 % 부터 100 % 까지 변동하기 때문입니다. 잘못된 카디널리티는 nested loop join 으로 가야 할 쿼리를 hash join 으로 보내거나, 인덱스 스캔으로 가야 할 쿼리를 sequential scan 으로 보내는 식의 plan 단위 잘못을 만들고, 그 한 번의 잘못이 OLTP 환경에서는 millisecond 가 minute 으로 변하는 일을 만듭니다. 1 만 배는 Exqutor 원논문 Table 1 의 실측치이고, "1 % 의 정확도 개선" 은 Q-error 의 중앙값 차이로, 분포 전체의 shift 를 의미합니다.

Q1.2 임베딩이 무엇인지부터 설명해 주실 수 있나요?

핵심 한 줄: 의미가 가까운 두 항목이 벡터 공간에서도 가까이 놓이도록, 데이터를 96 차원이나 1024 차원의 숫자 벡터로 변환하는 절차입니다.

표준 답변 (30 초)

이미지·텍스트·음성처럼 의미가 중요한 데이터는 글자 그대로 비교할 수 없습니다. "고양이" 와 "야옹이" 는 같은 의미지만 글자는 다릅니다. 그래서 이런 데이터를 *임베딩* 이라는 신경망 기반 변환을 통해 의미 거리가 보존되는 숫자 벡터로 바꿉니다. 의미가 가까운 두 항목은 벡터 공간에서도 가까이 놓이도록 학습된 변환입니다. 본 연구에서 쓴 DEEP 데이터셋은 96 차원, SIFT 는 128 차원 벡터입니다.

디테일 보강 (2 분)

본 연구에서 쓴 DEEP 1M, DEEP 8M 은 SIFT-style 의 deep image feature (96 차원 float32), SIFT 1.5M 은 image keypoint descriptor (128 차원 uint8) 입니다. 모두 표준 ANN benchmark 에서 사용되는 데이터셋으로, 추가 임베딩 학습 없이 미리 만들어진 벡터를 그대로 사용했습니다. 임베딩 모델 자체는 본 연구의 변수가 아니므로 통제 변수로 두고, 분포 특성 (skewness) 만 cross-dataset 비교에 활용했습니다.

Q1.3 VAQ (Vector-Augmented Analytical Query) 가 정확히 무엇인가요?

핵심 한 줄: 단순한 top-k 유사도 검색을 넘어, 벡터 거리 조건이 일반 SQL 의 조인·집계·필터와 결합된 분석 쿼리 형태를 의미합니다.

표준 답변 (35 초)

top-k 검색은 "가장 가까운 10 개 문서를 찾아라" 같은 단순 질의입니다. VAQ 는 거기에 SQL 의 다른 연산 이 결합된 형태로, 예를 들어 "거리가 0.3 이내인 문서 중 카테고리가 '뉴스' 인 것의 개수를 카테고리별로 집계하라" 같은 쿼리입니다. 본 연구가 다루는 것은 VAQ 중에서도 *거리 임계값 D 이내의 모든 항목*을 찾는 *range query* 형태이고, 이 형태가 RAG·추천·이상 탐지의 검색 단계에서 자주 사용됩니다.

Q1.4 왜 Exqutor 논문을 베이스로 삼았나요? 다른 벡터 카디널리티 연구는 없나요?

핵심 한 줄: Exqutor (arXiv:2512.09695v2, 2025) 가 2025 년 가장 최근 발표된 시스템적 접근이고, 본 연구가 발견한 *단일 테이블 사각지대*가 그 이후 빈자리이기 때문입니다.

표준 답변 (40 초)

학습 기반 카디널리티 추정 (LearnedCard, MSCN 등) 은 일반 SQL 술어에는 좋은 결과를 내지만, 벡터 거리 조건처럼 분포가 비대칭이고 차원이 96 ~ 1024 인 술어에는 직접 적용된 사례가 적습니다. 시스템 측면에서 벡터 카디널리티를 정면으로 다룬 연구는 Exqutor 가 본격 첫 사례에 가깝고, 두 갈래 보완 (ECQO + Adaptive Sampling) 으로 1 만 배 이상의 실행 시간 개선을 보고했습니다. 본 연구는 이 보완책의 적용 범위가 *multi-table only* 라는 빈자리를 발견했고, 그 빈자리에서 코드 세 줄 보완으로 측정 가능한 개선을 만들 수 있는지를 묻는 형태입니다.

Q1.5 "VBASE 에서 최대 1 만 배 이상" — 이 표현이 과장 아닌가요?

핵심 한 줄: Exqutor 원논문 Table 1 의 실측 시나리오 중 가장 큰 격차를 인용한 것이며, "최대" 가 아니라 "최대 1 만 배 이상" 으로 표현한 것은 이것이 상한이 아닌 의미입니다.

표준 답변 (30 초)

Exqutor 원논문의 보고 그대로 인용한 것입니다. 시나리오 (selectivity, 데이터셋, plan 분기점) 에 따라 변동이 크고, 1 만 배가 상한이 아닌 "최소 1 만 배 이상이 가능한 경우가 있다" 는 의미입니다. 회의에서 이 표현을 그대로 유지하기로 합의했습니다 (4 월 25 일 카톡 회의). 우리가 측정한 값이 아니라 원논문의 인용이라는 점은 보고서·발표 모두에 명시되어 있습니다.

Q1.6 본 연구가 풀려는 문제를 *한 문장*으로 요약하면?

핵심 한 줄: 단일 테이블 벡터 거리 쿼리에서, 데이터가 공간적으로 쏠려 있을 때 카디널리티 추정 정확도를 코드 세 줄 보완으로 통계적으로 유의하게 개선할 수 있는가, 그리고 그 개선이 어떤 메커니즘에서 오는가.

(이 문장이 곧 본 연구의 RQ1 + RQ2 + Two-Level 분해를 통째로 요약하는 마스터 문장. Q&A 마지막에 시간 남으면 이 문장으로 마무리하면 된다.)

섹터 2. Exqutor 이해 (Related Work)

*Exqutor*의 두 보완책에 대한 깊은 질문. 시스템 백그라운드를 가진 심사위원·자문위원이 가장 좋아하는 영역.

Q2.1 ECQO와 Adaptive Sampling의 차이가 정확히 무엇인가요?

핵심 한 줄: ECQO는 인덱스가 있을 때 HNSW range query를 한 번 실행해 정확값을 얻는 *exact* 방식이고, Adaptive Sampling은 인덱스가 없을 때 표본 일부의 비율로 추산하는 *approximate* 방식입니다.

표준 답변 (45 초)

Exqutor는 인덱스 유무에 따라 두 갈래 보완을 갖습니다. 인덱스가 있을 때는 ECQO — Exact Cardinality Query Optimization — 가 옵티마이저의 plan 수립 단계에서 HNSW 인덱스를 이용해 가벼운 range query를 한 번 실제로 실행하여 정확한 카디널리티를 얻습니다. 추정이 아니라 정확값이고, 인덱스 검색이 빠르므로 오버헤드가 약 1.88 ms 정도라고 원논문이 보고합니다. 인덱스가 없을 때는 Adaptive Sampling이 일부 행만 추출해 임계값을 만족하는 비율을 계산하고, 그 비율을 전체 행 수에 곱해 카디널리티를 추산합니다. *모멘텀 기반 동적 sample_size 조정*이 핵심으로, 이전 쿼리 결과를 보고 sample_size를 점진적으로 늘리거나 줄입니다. 본 연구는 후자(Adaptive Sampling)의 적용 범위와 정확도를 다룹니다.

디테일 보강 (1 분 30 초)

ECQO 의 1.88 ms 오버헤드는 옵티마이저가 plan 을 만드는 비용 (parse + plan + execute 중 plan 단계 만) 에 비해 무시할 수 있는 수준입니다. HNSW 의 search complexity 가 $O(\log N)$ 이라 1M 데이터셋에서 ms 단위로 끝납니다. Adaptive Sampling 의 sample_size 는 본 연구 기준 sample_size = 385 가 default 이고 (이는 Cochran 의 sample size 공식에서 95 % CI 5 %p 마진의 binomial proportion estimation 기준), 모멘텀 기반 조정은 hit rate 가 너무 작거나 너무 클 때 sample_size 를 동적으로 늘리는 식입니다. 본 연구는 update_sample_size = off (4/19 추가) 환경에서 sample_size 를 고정한 채로 측정했습니다. 이는 sample_size 변동이 두 보완 효과 측정에 교란으로 들어오는 것을 막기 위해서입니다.

Q2.2 ECQO 가 그렇게 정확하면, 그냥 ECQO 만 쓰면 되지 않나요? 왜 Adaptive Sampling 이 필요한가요?

핵심 한 줄: ECQO 는 인덱스가 있어야만 작동하고, 모든 환경에서 인덱스가 항상 유지되지는 않기 때문입니다.

표준 답변 (30 초)

인덱스가 항상 존재한다는 보장이 없습니다. 데이터 적재 직후, 동적 INSERT 가 빈번한 환경, 인덱스 미생성 컬럼, 인덱스 빌드 비용을 감당하기 어려운 시나리오에서는 인덱스가 없거나 stale 합니다. 이런 상황을 위해 Exqutor 는 두 번째 보완책으로 Adaptive Sampling 을 둡니다. 인덱스가 있을 때 ECQO 가 0.001 ms 단위로 정확값을 주고, 없을 때 Adaptive Sampling 이 ms 단위로 근사값을 주는 *2 layer fallback* 구조입니다. 우리 연구는 두 번째 layer 의 정확도와 적용 범위를 다룹니다.

Q2.3 Adaptive Sampling 의 모멘텀은 정확히 어떻게 동작하나요?

핵심 한 줄: 이전 쿼리에서 sample 의 hit rate 가 예상보다 낮으면 다음 쿼리에서 sample_size 를 늘리고, 반대로 높으면 줄이는 EWMA (exponentially weighted moving average) 형태의 피드백 조정입니다.

표준 답변 (40 초)

Exqutor 의 모멘텀 기반 조정은 직전 N 개 쿼리의 sample hit rate 를 EWMA 로 누적해서, 현재 쿼리의 sample_size 를 동적으로 결정합니다. hit 가 너무 적으면 (예: 1 % 미만) sample 자체를 늘려 추정 분산을 줄이고, 너무 많으면 (예: 50 % 이상) sample 을 줄여 비용을 아낍니다. 본 연구는 이 모멘텀이 RQ2 의 두 보완 효과 측정에 교란으로 들어오는 것을 막기 위해 `update_sample_size = off` GUC 로 sample_size 를 385 로 고정했습니다. 이 설정은 4 월 19 일 ultrareview 에서 추가된 default 입니다.

Q2.4 Exqtutor 의 hook 메커니즘은 PostgreSQL 의 어떤 부분에 들어가는 건가요?

핵심 한 줄: PostgreSQL 의 `clauselist_selectivity` 콜백 체인에 등록되는 extension 형태로, 옵티마이저가 카디널리티 추정을 호출할 때 자동으로 trigger 됩니다.

표준 답변 (40 초)

Exqtutor 는 PostgreSQL extension 형태로 빌드되며, `vector` extension 의 hook 으로 `selfunc.c` 의 `selectivity` 추정 경로에 끼어듭니다. 옵티마이저가 vector 거리 조건을 마주칠 때마다 hook 이 호출되어, `table_count` 와 거리 임계값을 보고 ECQO 또는 Adaptive Sampling 을 trigger 합니다. 본 연구가 발견한 단일 테이블 사각지대는 이 hook 의 진입 조건문 (`vector.c` line 243) 이 `table_count > 2` 로 짜여 있어, 단일 테이블 쿼리는 hook 자체를 통과하지 못하고 PostgreSQL 의 default 1/3 selectivity 로 떨어진다 는 점입니다.

Q2.5 Exqtutor 가 왜 `table_count > 2` 로 조건을 짰는지 알 수 있나요?

핵심 한 줄: 원논문이 명시적으로 설명하지 않았으나, 코드 동작과 5 가지 design constraint 의 패턴으로 보아 *multi-table join* 의 *base table 카디널리티* 추정을 첫 타깃으로 잡은 design intent 로 추정됩니다.

표준 답변 (50 초)

Exqtutor 의 ECQO/Adaptive Sampling 은 plan 단계에서 base relation 의 selectivity 를 보정하는 메커니즘인데, 단일 테이블 쿼리에서는 base relation 이 곧 outer query 의 결과 자체입니다. 우리가 hook 을 강제로 켜 봤더니 base relation 이 PostgreSQL `Sample Scan` 으로 plan-tree 가 교체되어, 100,000 행이 나와야 할 outer query 가 sample 안의 32 행만 반환하는 형태로 *결과 자체가 격하* 됩니다. 이 부작용은 multi-table join 시나리오에서는 일어나지 않습니다 — base table 의 sample scan 결과가 join 의 부분 입력으로만 들어가고 outer query 결과는 join 결과이기 때문입니다. 즉 Exqtutor 의 design intent 는 *join 의 base table 카디널리티*를 *sample* 로 추산하는 데 맞춰져 있고, 단일 테이블은 그 가정 밖이라는 해석입니다. 원논문이 명시적으로 이 사실을 적지는 않았습니다.

디테일 보강 (2 분)

우리가 발견한 5 가지 design constraint 가 모두 *multi-table* 가정을 바닥에 두고 있다는 점이 일관된 증거입니다. (1) hook 진입 조건의 `table_count > 2`, (2) plan replacement 시 outer query 격하, (3) `TABLESAMPLE SYSTEM` 의 block 단위 추출 (multi-table 시 sample size 가 작아도 join 으로 보강), (4) hook_est 가 sample 안 부분 카운트를 outer 결과로 격하, (5) Adaptive update path 의 SIGSEGV (sample_size NaN 발산은 단일 테이블에서만 재현). 다섯 모두 *multi-table* 에서는 우회 가능, 단일 테이블에서는 직접 노출 되는 패턴입니다. 즉 Exqutor 의 design intent 는 multi-table 이고, 단일 테이블 사각지대는 *논문이 의도적으로 비워 둔 영역* 으로 봐도 무리 없습니다. 이 부분이 본 연구의 차별성을 만드는 빈자리입니다.

Q2.6 본 연구는 Exqutor 와 협력하나요? 아니면 비판하는 입장인가요?

핵심 한 줄: Exqutor 의 multi-table 가정을 깨지 않으면서 그 옆에 단일 테이블 보안을 추가 하는 형태로, 협력적 확장입니다.

표준 답변 (30 초)

본 연구의 코드 변경은 모두 Exqutor 기존 동작 경로 *옆에* 추가되도록 짜여 있어, multi-table 시나리오의 동작은 건드리지 않습니다. `table_count > 2` 조건문 한 줄을 풀어 단일 테이블에서도 보안이 활성화되도록 한 것이 첫 변경이고, 그 위에 추출 단위 변경과 층화 표본 분기 추가로 두 보안을 layered 추가합니다. Exqutor 의 design intent 를 부정하기보다 그 위에 *missing case* 를 메우는 형태이며, 협력적 확장 입장입니다.

섹터 3. RQ1 — 단일 테이블 사각지대

코드 검증 + 8 지표 무상관 + 5 가지 design constraint. RQ1 은 측정이 아니라 발견·기록.

Q3.1 단일 테이블 사각지대를 어떻게 발견했나요?

핵심 한 줄: Exqutor 소스 코드 (`vector.c` line 243) 의 hook 진입 조건문 `if (table_count > 2)` 를 직접 읽어 발견했고, EXPLAIN ANALYZE 로 단일 테이블 쿼리에서 hook 이 실제로 trigger 되지 않음을 검증했습니다.

표준 답변 (45 초)

4 월 둘째 주에 Exqutor 의 PostgreSQL extension 소스를 처음부터 끝까지 읽어 hook 의 진입 경로를 추적했습니다. `vector.c` 의 selectivity 함수 안에서 `table_count > 2` 조건이 단일 테이블을 가로막는다는 점을 코드에서 확인했고, 단일 테이블 벡터 거리 쿼리에 EXPLAIN ANALYZE 를 돌려 옵티마이저가 default 1/3 selectivity 로 떨어지는 것을 직접 확인했습니다. 즉 코드 검증 + 실측 두 단계로 사각지대를 확인했고, 이는 Exqutor 원논문 본문에 명시되지 않은 finding 입니다.

Q3.2 hook 조건문을 풀어서 강제로 켜면 어떻게 되나요?

핵심 한 줄: 단일 테이블에서 base relation 의 plan-tree 가 PostgreSQL `Sample Scan` 으로 교체되어, 100,000 행이 나와야 할 결과가 sample 안의 32 행으로 *외부 쿼리 의미 자체* 가 깨집니다.

표준 답변 (45 초)

`if (table_count >= 1)` 로 한 줄 수정하면 hook 이 단일 테이블에서도 trigger 됩니다. 그러나 hook 이 호출하는 sample-based selectivity 가 base relation 의 plan-tree 를 `Sample Scan` 으로 교체하는데, multi-table 가정에서는 join 결과로 보강되던 부분이 단일 테이블에서는 outer query 의 결과 자체가 됩니다. 결과적으로 100,000 행이 진짜 답인 쿼리에서 `SELECT count(*)` 가 32 (= sample 안 hit 수) 를 반환하는 식으로 *외부 쿼리 의미가 격하* 됩니다. 이 외에도 q-error inf 발산, sample_size NaN 발산, Adaptive update path SIGSEGV 등 5 가지 design constraint 가 발견되었고, 단순 우회로는 해결 안 된다는 결론이 나왔습니다.

Q3.3 발견한 5 가지 design constraint 를 모두 말씀해 주실 수 있나요?

핵심 한 줄: (1) hook trigger 사각지대, (2) Sample Scan 으로의 plan-tree 격하, (3) `TABLESAMPLE SYSTEM` block 단위 편향, (4) hook_est 의 sample 안 부분 카운트 격하, (5) Adaptive update path 의 SIGSEGV — 모두 multi-table only design intent 의 패턴.

표준 답변 (50 초)

다섯 가지가 있습니다. 첫째, hook 진입 조건 `table_count > 2` 가 단일 테이블 쿼리에서 hook 자체를 trigger 하지 못하는 *사각지대*. 둘째, hook 을 강제로 켜올 때 base relation 의 plan-tree 가 `Sample Scan` 으로 교체되어 외부 쿼리 결과가 *sample 안 부분 카운트로 격하*. 셋째, sample 추출이 PostgreSQL 의 `TABLESAMPLE SYSTEM` (8KB block 단위) 이라 row 단위 균일성이 깨지는 *block sampling bias*. 넷째, hook_est 가 outer query 결과를 sample 안 hit 수로 반환해 *q-error infinity* 로 발산. 다섯째, Adaptive update path 가 단일 테이블에서 sample_size NaN 발산과 *SIGSEGV crash*. 다섯 모두 multi-table only design intent 의 일관된 패턴이며, 본 연구는 이를 ECQO 의 multi-table 가정을 깨지 않으면서 단일 테이블 사각지대를 메우는 *layered 보완* 으로 해결합니다.

Q3.4 사각지대 자체가 학술적 기여가 될 수 있나요? 그냥 버그 아닌가요?

핵심 한 줄: 단순한 버그가 아니라 multi-table only design intent 의 체계적 결과이며, 학술적 기여는 *논문이 명시하지 않은 적용 범위 한계의 정량화 및 그 보완 가능성의 실증*에 있습니다.

표준 답변 (40 초)

한 줄짜리 조건문 자체는 의도적 설계였을 가능성이 높습니다 (Exqutor 의 multi-table join 시나리오 우선 가정). 그러나 이미지 검색·추천·RAG 의 **핵심 응용 형태** 가 단일 테이블 검색이라는 점에서, 이 사각지대는 학술적·실무적 의미가 있는 빈자리입니다. 본 연구의 기여는 (1) 사각지대를 코드 + 실측으로 정량화한 점, (2) 단순 우회로는 해결 안 된다는 5 가지 design constraint 를 발견한 점, (3) layered 보완 (베르누이 + 층화 표본) 으로 측정 가능한 개선을 만든 점입니다. 즉 단순 bug fix 가 아니라 *missing case* 의 체계적 분석과 보완이 기여입니다.

Q3.5 Exqutor 저자에게 이 발견을 알렸나요?

핵심 한 줄: 본 연구 시점에서는 알리지 않았으며, 최종 보고서 (6 월) 또는 후속 논문 작성 시 contact 예정입니다.

표준 답변 (25 초)

중간 보고 시점에서는 학술적 검증과 측정 단계가 우선이라 저자에게 contact 하지 않았습니다. 본 연구가 Exqutor 의 design intent 를 깨지 않는 *layered 확장* 형태이고, 본 finding 이 multi-table 가정 위에서는 일어나지 않는 부작용을 드러냈으므로, 최종 보고서 단계에서 저자에게 finding 공유와 협력 가능성을 contact 할 계획입니다. 자문위원 (박성원 멘토) 에게는 4 월 15 일 v3 자문 이메일로 본 finding 을 공유했고, 회신에서 "단일 테이블 시나리오로 좁힌 점이 적절하다" 는 평가를 받았습니다.

Q3.6 단일 테이블 검색이 정말 핵심 응용 형태인가요? 근거가 있나요?

핵심 한 줄: 이미지 검색·추천·RAG 의 *retrieval 단계* 가 모두 단일 테이블 거리 조건 형태이며, 이는 ANN benchmark (SIFT, DEEP, GIST) 의 표준 evaluation 형태이기도 합니다.

표준 답변 (35 초)

RAG (Retrieval-Augmented Generation) 의 검색 단계는 *임베딩 vector 가 저장된 단일 테이블* 에 거리 조건을 거는 형태가 표준입니다. 추천 시스템에서도 user/item embedding 단일 테이블 query 가 핵심이고, 이미지 검색은 정의상 단일 테이블 입니다. ANN-Benchmarks (Aumüller et al., 2017+) 의 표준 evaluation 도 단일 테이블 형태이며, 본 연구가 쓴 DEEP 와 SIFT 데이터셋이 그 표준입니다. 즉 *학술 benchmark 의 표준 형태이자 실무 응용의 핵심 형태* 가 단일 테이블 거리 query 이고, Exqutor 의 multi-table only 보완은 이 핵심 영역을 비워 둔 셈입니다.

섹터 4. RQ1 — 8 지표 전수 검증 (분포 쏠림 사전 식별 가능성)

통계 백그라운드 청중·자문위원의 favorite. 가장 디테일한 추궁이 들어올 수 있는 영역.

Q4.1 8 가지 지표가 정확히 무엇이었나요? 왜 8 개를 골랐나요?

핵심 한 줄: 글로벌 4 (Fisher γ , log-Fisher γ , P99/P50 tail ratio, Bowley skew) 와 로컬 4 (k-NN distance entropy, k-NN PCA EVR1, KDE modality count, NN clustering coefficient) 로, *분포 쏠림 측정의 4 가지 직교 패러다임* (모멘트, 분위수, 밀도, 그래프) 을 각각 글로벌·로컬 스코프로 적용한 것입니다.

표준 답변 (60 초)

분포 쓸림을 측정하는 통계 지표는 크게 4 가지 패러다임이 있습니다. 모멘트 기반 (skewness γ), 분위수 기반 (P99/P50 같은 tail ratio), 밀도 기반 (KDE bandwidth, modality), 그래프 기반 (k-NN 구조). 각 패러다임을 글로벌 (전체 데이터 분포) 과 로컬 (쿼리 주변) 두 스코프로 적용해 8 개 지표를 만들었습니다. 글로벌은 Fisher γ , log-Fisher γ , Bowley skew (분위수 robust skewness), P99/P50 tail ratio. 로컬은 k-NN distance entropy (쿼리 k 이웃 거리의 Shannon entropy), k-NN PCA EVR1 (k 이웃 벡터의 PCA 첫 주성분 explained variance ratio), KDE modality count (커널 밀도 추정 후 mode 개수), NN clustering coefficient (k-NN 그래프의 local clustering). 이 8 지표 vs 쿼리별 Q-error 의 Spearman ρ 가 모든 조합에서 절대값 0.2 미만이었습니다. 즉 분포 쓸림을 *쿼리 단위 사전 휴리스틱* 으로 식별할 길은 닫혀 있습니다.

디테일 보강 (3 분)

이 finding 의 의미는 두 갈래입니다. 첫째, RQ2 (분포를 알 때) 와 RQ3 (분포를 모를 때) 두 갈래를 모두 다뤄야 한다는 *직접 근거* 가 됩니다 — 단순 휴리스틱으로 RQ3 를 우회할 수 없으니 RQ3 의 distribution-agnostic 방법 비교가 의미 있습니다. 둘째, *데이터 분포의 쓸림이 쿼리별 추정 오차의 결정 요인이 아니다* 라는 finding 도 있습니다. 그러면 무엇이 결정 요인인가? 본 연구의 hypothesis 는 *쿼리 벡터의 위치와 클러스터 구조의 상호작용* 입니다. KM20 의 layered 효과 ($s=0.5$ 에서 1.6 %, $s=0.01$ 에서 8.93 %) 가 쿼리 벡터가 어떤 클러스터에 떨어지느냐에 따라 달라지는 패턴이 이를 뒷받침합니다. 다만 이 hypothesis 의 검증은 RQ3 (5 월) 의 Distance-Shell 방법 (G) 측정에서 이뤄질 예정입니다.

Q4.2 |Spearman ρ | < 0.2 가 약한 상관이라는 근거는?

핵심 한 줄: Cohen 의 효과크기 가이드라인 (1988) 에서 $|\rho| < 0.1$ 은 negligible, 0.1 ~ 0.3 은 small, 0.3 ~ 0.5 는 medium, 0.5 이상은 large 이며, 0.2 미만은 small 의 하단으로 *예측 모델로 활용하기 어려운 수준* 입니다.

표준 답변 (40 초)

Cohen (1988) 의 effect size 가이드라인을 그대로 따랐습니다. $|\rho| < 0.1$ 은 negligible, 0.1 ~ 0.3 은 small, 0.3 ~ 0.5 는 medium, 0.5 이상은 large. 본 연구가 측정한 8 지표 모두 $|\rho| < 0.2$ 였으니 small 의 하단입니다. 더 중요한 건 *통계적 유의성과 실용적 의미가 다르다* 는 점입니다. $n = 6000$ 측정에서는 $|\rho| = 0.05$ 도 통계적으로 유의하지만 ($p < 0.001$), 실제로 쿼리별 Q-error 를 예측하는 모델로 쓸 수 없는 수준입니다. R^2 가 4 % 미만이기 때문입니다. 그래서 본 연구는 8 지표 휴리스틱 자체를 *쿼리 단위 사전 식별 도구로 활용 불가* 라고 결론지었고, RQ2 의 *오프라인 분할* 과 RQ3 의 *분포 무인지 적응* 두 갈래로 길을 잡았습니다.

Q4.3 8 지표 외 다른 지표는 시도 안 했나요? 가령 Wasserstein distance 같은?

핵심 한 줄: 4 패러다임 $\times$ 2 스코프 = 8 지표가 분포 쏠림 측정의 직교 공간을 cover 한다고 판단했고, Wasserstein 같은 추가 지표는 4 패러다임 중 *밀도 기반*의 변형이라 KDE modality count + k-NN distance entropy가 이미 그 정보를 capture 한다고 보았습니다.

표준 답변 (40 초)

Wasserstein distance, Kolmogorov-Smirnov, Bhattacharyya 같은 distance-based 분포 비교 지표는 모두 *두 분포의 차이*를 재는 도구입니다. 본 연구의 검증은 *단일 분포 내부의 쏠림 측정*이 목적이므로 prior 분포가 있어야 하는 distance 기반 지표는 직접 적용이 어렵습니다. 만약 prior로 uniform 분포를 두면 KDE modality count와 본질적으로 같은 정보를 켜 셈이 되고, 그래서 본 연구는 직접 modality와 entropy로 측정했습니다. 추가 지표 (Theil index, Gini coefficient, MIPS)는 RQ3의 보충 분석 (5월)에 포함시킬지 검토 중입니다.

Q4.4 KDE modality count가 정확히 무엇인가요? bandwidth는 어떻게 정했나요?

핵심 한 줄: 쿼리 $k = 50$ 이웃의 *거리 분포*를 Silverman bandwidth의 KDE로 추정한 뒤, density의 local maxima를 세어 multimodality를 정량화한 것입니다.

표준 답변 (45 초)

쿼리 벡터의 $k = 50$ nearest neighbor의 거리 distribution을 KDE로 추정한 뒤, density의 local maxima 개수를 셉니다. Bandwidth는 Silverman's rule of thumb (1986)의 default를 썼고, 1차원 거리 분포라 차원의 저주가 없습니다. modality count = 1이면 unimodal (분포 깔끔), > 1 이면 multimodal (쿼리 주변에 여러 클러스터). 본 hypothesis는 multimodal 쿼리에서 Q-error가 클 것이라는 가정이었으나, $|\rho| < 0.2$ 로 sufficient correlation이 없었습니다. 즉 *쿼리 단위로 multimodal 여부를 미리 알아낼 수 없거나, 알아내도 Q-error와 직접 연결되지 않는다*는 finding입니다.

Q4.5 8 지표 검증의 sample은 어떻게 구성됐나요?

핵심 한 줄: DEEP 1M, 100 쿼리 $\times$ 6 selectivity = 600 (query, selectivity) 셀에 대해, 8 지표 $\times$ 600 = 4800 (지표, 셀) pair의 ρ 를 산출했고, 이를 multiple comparison 보정 (BH-FDR) 후 모두 $|\rho| < 0.2$ 였습니다.

표준 답변 (40 초)

DEEP 1M 의 100 개 쿼리 $\times$ 6 selectivity 구간 = 600 측정 셀에서, 각 셀의 Q-error 와 8 개 글로벌·로컬 지표의 Spearman ρ 를 산출했습니다. $8 \times 600 = 4800$ ρ 값에서 multiple comparison 위험을 BH-FDR (Benjamini-Hochberg) 로 통제된 결과도 모두 $|\rho| < 0.2$ 였습니다. 8 지표가 직교 패러다임이라 일부 지표 만 좋고 나머지 약한 형태가 아니라 전수 약한 패턴이고, 이는 *단순 휴리스틱으로 분포 쏠림을 사전 식별할 수 없다* 는 강력한 negative finding 입니다.

Q4.6 그래도 어떤 지표가 가장 좋았나요?

핵심 한 줄: 글로벌 지표 중 P99/P50 tail ratio ($|\rho| \approx 0.18$) 와 로컬 지표 중 KDE modality count ($|\rho| \approx 0.16$) 가 상대적으로 가장 신호가 강했지만, 둘 다 small 효과 하단이라 모델로 활용하기 어렵습니다.

표준 답변 (30 초)

차이가 작긴 하지만, 글로벌 P99/P50 tail ratio 와 로컬 KDE modality count 가 약간 더 신호가 강했습니다. 이 두 지표는 *분포의 꼬리 두께* 와 *분포의 멀티모달 정도* 를 측정하는 것으로, hypothesis 와 가장 직접 연관된 metric 이었습니다. 그러나 $|\rho|$ 가 0.18 / 0.16 정도라 $R^2 = 3\%$ 미만이고, 이를 사전 식별 모델로 쓰면 false positive/negative 가 너무 많아 실용성이 없습니다. 그래서 *어떤 지표가 좋다* 보다 *모든 지표가 약하다* 는 finding 이 본 연구의 결론입니다.

섹터 5. RQ2-1 — 베르누이 추출 (행 단위)

RQ2 의 첫 보완 — 코드 한 줄 교체로 9.6 % 개선. 통계 검정과 추출 단위 메커니즘이 핵심.

Q5.1 왜 베르누이가 시스템보다 좋다고 확신할 수 있나요?

핵심 한 줄: PostgreSQL 의 `TABLESAMPLE SYSTEM` 은 8KB 블록 단위 추출이라 같은 블록 안 행들의 dependency 가 추정 분산을 키우고, 베르누이는 행 단위 독립 추출이라 이론적으로 분산이 작으며, 본 연구가 100 쿼리 $\times$ 6 selectivity 측정에서 이를 paired Wilcoxon 으로 통계적으로 확인했습니다.

표준 답변 (50 초)

두 갈래 근거가 있습니다. 첫째, 이론적으로 베르누이 추출은 각 행의 inclusion probability 가 독립이라 추정 variance 의 lower bound 가 작습니다. 시스템 추출은 8KB 블록 단위라 같은 블록의 행들이 dependency 를 가지고, 그 결과 same effective sample size 라도 variance 가 큼니다 (Cochran 1977). 둘째, 실측에서 DEEP 1M, 100 쿼리, 6 selectivity 구간에 paired Wilcoxon 검정을 돌려 selectivity 0.05 ~ 0.50 모든 구간에서 $p < 0.001$ 로 베르누이 우세, selectivity 0.5 에서 100 개 중 78 개 우세, 중앙값 9.6 % 개선을 통계적으로 확인했습니다. 이론과 실측 모두 일치합니다.

Q5.2 paired Wilcoxon 을 쓴 이유는? t-test 도 됐을 텐데?

핵심 한 줄: Q-error 분포가 lognormal 또는 heavy-tail 이라 정규성 가정이 깨지고, paired Wilcoxon 은 분포 가정 없이 paired difference 의 median 만 검정하는 robust 비모수 검정이라 본 연구에 적합합니다.

표준 답변 (40 초)

Q-error 는 추정값과 실제값의 비율이므로 분포가 lognormal 또는 heavy-tail 입니다. paired t-test 는 정규성 가정이 필요한데, lognormal 한 Q-error 에 t-test 를 그대로 쓰면 outlier 영향이 크고 false positive 위험이 있습니다. paired Wilcoxon 은 두 처리 (시스템 vs 베르누이) 의 paired difference 의 median 이 0 인지를 분포 가정 없이 검정하는 비모수 검정이라, lognormal Q-error 에 robust 합니다. 또한 same query 에서 두 추출 방식을 비교하므로 paired structure 가 자연스럽게, query 단위 effect (쿼리 자체의 selectivity 변동) 를 제거하는 효과가 있습니다. 즉 *robust + paired* 두 이유로 Wilcoxon 이 정답입니다.

디테일 보강 (1 분)

추가로 *log-transform* 후 *paired t-test* 도 검토했습니다. log Q-error 가 정규성에 가까워지므로 이론상 가능합니다. 그러나 SIFT 1.5M $s = 0.010$ 의 양자화 영역 (median Q-error 가 5 seed 모두 1.4435 로 동일) 에서 log Q-error 의 분산이 0 으로 수축해 t 통계량이 정의되지 않는 케이스가 있어, 비모수가 더 안정적이라 결론지었습니다. W6 (5/12 경) 의 본격 검정력 측정에서는 paired Wilcoxon + paired t (log) 를 모두 보고할 예정이며, 두 결과가 일관됨을 보일 계획입니다.

Q5.3 100 개 쿼리가 충분합니까? sample size 가 작은 것 아닌가요?

핵심 한 줄: 본 보고서 시점은 5-seed × 100 쿼리 = 500 측정 단위이며, 이는 Wilcoxon 의 검정력 0.8 기준 medium effect (Cohen's $d \approx 0.5$) 를 잡기에 충분한 sample size 이고, W6 (5 월 12 일경) 에 10-seed × 500 쿼리 = 5000 단위로 본격 검정력을 확보할 예정입니다.

표준 답변 (45 초)

Wilcoxon paired test 의 검정력 분석으로 medium effect (Cohen's $d \approx 0.5$) 를 power 0.8, $\alpha = 0.05$ 로 잡으려면 약 50 ~ 70 paired sample 이 필요합니다. 본 연구는 query 100 × 5 seed = 500 paired sample 이라 이 기준의 약 7 ~ 10 배입니다. 따라서 selectivity 0.05 ~ 0.50 구간에서 $p < 0.001$ 의 일관된 결과는 검정력 측면에서 robust 합니다. selectivity 0.001, 0.010 의 약한 신호는 sample size 부족이 아니라 *Q-error 자체의 정수 양자화* — true cardinality 가 작아 추정값이 0/1/2 같은 작은 정수만 나오므로 분해능이 제한 — 때문입니다. 본격 검정력 측정 (BH-FDR + TOST + Cohen's d) 은 W6 (5/12 경) 에 10-seed × 500-쿼리로 확보 예정입니다.

Q5.4 selectivity 0.001, 0.010 에서 효과가 약한 게 진짜로 효과 없는 건 아닌가요?

핵심 한 줄: 효과 자체는 있을 수 있으나, true cardinality 가 1,000 ~ 10,000 행 수준에서 sample-based 추정값이 정수 양자화 (sample 안 hit 이 0, 1, 2 같은 작은 수) 로 분해능이 제한되어 통계적 유의성을 잡기 어려운 영역입니다. RQ2-2 의 KM20 효과는 이 영역에서 오히려 가장 큼니다 ($s=0.010$ 에서 +8.93 %).

표준 답변 (50 초)

두 영역 ($s=0.001$, $s=0.010$) 에서 베르누이 효과가 약한 이유는 *효과 부재* 가 아니라 *분해능 한계* 입니다. true cardinality 가 작으면 sample 안 hit 수도 작은 정수 (0, 1, 2, 3) 로 quantize 되고, 두 추출 방식의 estimated cardinality 차이도 작은 정수 단위로만 변합니다. 그래서 paired Wilcoxon 의 zero-difference tie 가 많아 검정력이 떨어집니다. 흥미롭게도 RQ2-2 의 KM20 효과는 이 영역에서 가장 큼 — DEEP 1M $s=0.010$ 에서 +8.93 %, RANDOM20 -10.67 % 격차. 이는 KM20 의 stratified 추출이 small-cluster 의 sample 보장을 통해 *양자화 영역에서 0/1 분해능을 유지* 하기 때문입니다. 즉 RQ2-1 과 RQ2-2 의 효과가 서로 다른 selectivity 영역에서 빛난다는 layered 구조가 본 연구의 흥미로운 finding 입니다.

Q5.5 베르누이 추출이 더 비싸지 않나요? 시스템보다 느리지 않나?

핵심 한 줄: 베르누이는 행 단위 inclusion 결정이라 random number generator 호출이 더 많지만, 본 연구의 sample_size = 385 규모에서는 추가 오버헤드가 ms 단위 미만으로 무시할 수 있고, 추정 분산 감소로 얻는 정확도 개선이 훨씬 큼니다.

표준 답변 (40 초)

이론상 베르누이는 행 단위 RNG 호출이 N 번 (전체 행 수) 발생하지만, PostgreSQL 의 **TABLESAMPLE BERNOLLI** 구현은 이를 hash-based skip 으로 최적화해 시스템 추출과 거의 같은 latency 를 보입니다. 본 연구의 측정에서 sample_size = 385 기준 두 방식의 hook latency 차이는 1 ms 미만이었습니다. 추정 분산 감소로 얻는 옵티마이저 plan 안정화 이익이 sample latency 차이를 상쇄하고 남으므로, 베르누이가 *비용 대비 이득* 측면에서도 정답입니다. 다만 sample_size 가 매우 클 때 (예: 100K 이상) 의 latency 비교 는 본 연구 범위 밖이며 W5 보충 실험에서 sample_size sensitivity 로 다룰 예정입니다.

Q5.6 표 1 의 selectivity 6 구간 (0.001/0.010/0.050/0.100/0.300/0.500) 은 어떻게 정했나요?

핵심 한 줄: 0.001 ~ 0.500 의 *log-uniform* 그리드로, 좁은 영역 (양자화 한계) 부터 넓은 영역 (분포 안정) 까지 cover 하면서, ANN benchmark 와 Exqutor 원논문의 측정 영역과 일치하도록 잡았습니다.

표준 답변 (35 초)

selectivity 가 0.001 (0.1 %) 부터 0.500 (50 %) 까지 3 orders of magnitude 변동하는데, 이를 log-uniform 6 점 (0.001, 0.010, 0.050, 0.100, 0.300, 0.500) 그리드로 cover 했습니다. 이 6 점이 *ANN benchmark* 의 표준 *evaluation* 영역 (top-1% ~ top-50%) 과 일치하고, Exqutor 원논문의 selectivity 측정 영역 (0.01 ~ 0.50) 도 cover 합니다. SIFT 1.5M 과 DEEP 8M 은 시간 제약상 3 점 (0.500, 0.050, 0.010) 으로 좁혔으나, 핵심 selectivity 0.500 은 모든 데이터셋에서 측정해 cross-dataset 비교의 anchor 가 됩니다.

섹터 6. RQ2-2 — 공간 인식 총화 표본 (KM20)

RQ2 의 두 번째 보완 — k-means K=20 총화 표본. 여기가 본 연구의 정량적 핵심.

Q6.1 K = 20 은 왜 그 값으로 정했나요? K=10 이나 K=50 은 왜 안 되나요?

핵심 한 줄: K=10 과 K=20 두 값을 모두 측정해 K=20 이 일관되게 우세함을 phase6_layer_compare 에서 확인했고, K=20 은 sample_size 385 와 well-balanced ($385/20 \approx 19$ 행/stratum) 한 이유로 baseline 으로 채택했습니다. K sweep (K = 5, 10, 20, 50, 100) 은 W5 (5 월 4 일) 보충 실험에 포함됩니다.

표준 답변 (50 초)

phase6_layer_compare 측정에서 K=10 과 K=20 을 baseline + bernoulli + pca_decile 4 mode 와 함께 비교했습니다. K=20 이 K=10 보다 selectivity 0.100 (+2.25%), 0.300 (+0.76%), 0.500 (+0.33%) 모두 우세였고, KM20 vs KM10 cross-pair 에서 selectivity 0.100 paired Wilcoxon $p = 0.0013$ 으로 통계적으로 KM20 우세입니다. K=50 같은 더 큰 값을 시도하지 않은 이유는, $\text{sample_size} = 385 / K = 50 = 7.7$ 행/stratum 으로 stratum 당 sample 수가 통계적으로 너무 작아져 양자화 효과가 발현되기 때문입니다. K=20 은 $385 / 20 \approx 19$ 행/stratum 으로 적절한 균형점이며, 본격 K sweep (5, 10, 20, 50, 100) 은 W5 보충 실험에 포함됩니다.

디테일 보강 (1 분 30 초)

RQ3 (5 월) 의 F (MiniBatch K-means) 와 G (Distance-Shell) 측정에서도 K = 20 을 유지합니다. K = 20 의 stratum 크기 분포를 보면 DEEP 1M 에서 size_min 26343, size_max 81233 로 3.08 배 차이가 나는데, 이는 데이터 자체의 클러스터 쏠림을 반영합니다 — k-means 가 균등하게 나누지 못하는 것이 아니라 데이터 자체가 균등하지 않다는 증거입니다. SIFT 1.5M 에서는 동일 K=20 이 3.33 만 ~ 14.82 만 (4.45 배) 으로 더 큰 격차를 만들고, 이것이 SIFT 의 KM20 효과가 DEEP 의 약 두 배인 이유입니다.

Q6.2 왜 k-means 인가요? GMM, DBSCAN, hierarchical clustering 같은 다른 분할법은 왜 안 썼나요?

핵심 한 줄: k-means 의 hard partition 이 모든 행이 정확히 하나의 stratum 에 속해야 하는 stratified sampling 의 정의에 직접 부합하고, 96d/128d 고차원에서 GMM/DBSCAN 은 차원의 저주로 안정적으로 학습되지 않으며 hierarchical 은 $O(N^2)$ 비용으로 1M 데이터에 비현실적이기 때문입니다.

표준 답변 (50 초)

Stratified sampling 의 정의는 모든 행이 정확히 하나의 stratum 에 *disjoint partition* 으로 속해야 합니다. k-means 의 hard partition (Voronoi 분할) 이 이 정의에 직접 부합합니다. GMM 은 soft membership 이라 stratum 경계가 모호하고, sample 추출 시 각 행의 stratum 을 결정하기 위해 추가 hard assignment 가 필요해 결국 k-means 와 비슷한 결과로 수렴합니다. DBSCAN 은 noise 와 outlier 를 별도 분류하는데, vector cardinality estimation 에서는 모든 행이 stratum 에 속해야 하므로 noise 행을 어떻게 처리할지 별도 정책이 필요합니다. Hierarchical 은 $O(N^2)$ 메모리·시간 비용으로 1M 데이터에 비현실적입니다. RQ3 (5 월) 의 7 가지 distribution-agnostic 방법에서 LSH (확률적 hard partition) 와 Hilbert curve (결정론적 hard partition) 등 다른 hard partition 패러다임을 함께 비교합니다.

Q6.3 5-seed 가 충분합니까? 왜 10 seed 를 쓰지 않나요?

핵심 한 줄: t-distribution 기반 CI 산출에서 $t(4, 0.975) = 2.776$ 인 5-seed 가 mean diff 의 표준오차를 $\pm 55\%$ 마진으로 잡기에 충분하고, 본격 검정력 (10-seed $\times$ 500-쿼리 + BH-FDR + TOST + Cohen's d) 은 W6 (5/12 경) 에 확보 예정입니다.

표준 답변 (45 초)

5-seed 에서 $t(4, 0.975) = 2.776$ 으로, $\text{mean} \pm t \times \text{std}/\sqrt{5}$ 의 t-based CI 를 산출합니다. DEEP 1M $s=0.500$ KM20 의 $\text{mean} = 1.6366\%$, $\text{std} = 0.4416\%$ 로 CI [+1.09, +2.18] 가 나옵니다. 이는 mean 의 표준오차 $\text{std}/\sqrt{5} = 0.198\%$ 의 약 2.78 배 마진으로, 효과의 통계적 유의성 (CI 양수 확정) 을 검증하기에 충분합니다. 다만 본격 검정력 측정 — 10-seed $\times$ 500-쿼리 + Bonferroni-Hochberg FDR multiple comparison + TOST equivalence test + Cohen's d effect size — 는 W6 (5/12 경) 보충 실험에 포함됩니다. 이는 출판급 통계 수준 확보를 위한 추가 단계이고, 현재 5-seed 에서도 효과의 *방향성* 과 *통계적 유의성* 은 robust 하게 확인됩니다.

Q6.4 표 2 에 "단일 seed" 라고 표기된 셀들 (DEEP 1M $s=0.05$, $s=0.01$) — 정말 단일 seed 입니까?

핵심 한 줄: 정확하게는 5-seed 측정이 raw data 에 보존되어 있으나, 본 보고서 시점에서는 보수적으로 "단일 seed" 로 표기했습니다. raw 5-seed CI 는 $s=0.05$ [-0.22, +3.42], $s=0.01$ [+6.59, +10.95] 입니다.

표준 답변 (40 초) — 솔직한 자체 정정 답변

표 2 의 "단일 seed" 표기는 raw data 와 다소 다른 보수적 표현입니다. 실측 raw 에는 5-seed 측정이 보존되어 있고, mean diff 는 +1.85 % ($s=0.05$), +8.93 % ($s=0.01$) 로 표기와 일치하며, 5-seed t-based CI 는 [-0.22, +3.42], [+6.59, +10.95] 입니다. $s=0.05$ CI 는 0 을 포함해 통계적으로 유의하지 않고, $s=0.01$ CI 는 양수 확정으로 강한 효과입니다. 표기를 "단일 seed" 로 한 이유는 $s=0.5$ 의 5-seed 가 "본선 anchor 측정" 으로 분리되어 있고, $s=0.05/0.01$ 은 selectivity gradient 분석의 보충 데이터라서 *anchor* 와 *보충* 을 분리해 표시 한 의도입니다. 본 표기는 W5 보충 실험 후 갱신되며, 발표 시 질문이 들어오면 raw 5-seed CI 를 직접 보고할 수 있습니다.

디테일 보강 (1 분)

raw 위치는 `experiments/results/rq1_motivation/random20_low_sel_summary.json` 의 `s0.01.km20.ci` 와 `s0.05.km20.ci` 필드입니다. 이 파일에는 KM20 과 RANDOM20 둘 다 5-seed $\times$ 100 query $\times$ 2 selectivity = 1000 paired 측정의 mean, std, CI, per-seed 결과가 모두 보존되어 있습니다. 발표 자료의 보수적 "단일 seed" 표기는 *학술 정직성* 측면에서 보수적 선택이지만, 실제로는 raw data 가 5-seed 이므로 "5-seed mean, CI 별도 산출" 로 표현하는 것이 더 정확합니다. 최종 보고서 (6 월) 에서는 모든 셀을 5-seed CI 로 통일 표기할 예정입니다.

Q6.5 Horvitz-Thompson 가중치 식이 정확히 어떻게 적용되나요?

핵심 한 줄: 각 stratum h 에서 sample size n_h , stratum 전체 size N_h 일 때, 추정 카디널리티 = $\sum_h (N_h \times \text{hit}_h / n_h)$ 로, hit count 를 stratum 크기 비례로 weighted sum 합니다. Exqutor 의 `hook_est` 함수에 동일 식이 구현됩니다.

표준 답변 (45 초)

Horvitz-Thompson estimator 의 표준 형태는 각 sample 의 inclusion probability 의 역수로 가중하는 것이며, stratified sampling 에서는 stratum h 의 inclusion probability = n_h / N_h 가 됩니다. 따라서 추정값은 $\sum_h \sum_{i \text{ in sample}_h} (1 / (n_h / N_h)) \times \text{indicator}(\text{distance}_i < D) = \sum_h (N_h / n_h) \times \text{hit_count}_h$ 입니다. 우리 구현 (`src/vector.c` 약 +228 라인 추가) 에서는 stratum_id 컬럼을 사전 계산해 각 행에 $K=20$ 라벨을 붙이고, hook 호출 시 stratum 별 hit count 를 집계해 N_h / n_h 가중합으로 카디널리티를 추정합니다. 이는 *unbiased estimator* 이며, sample size 안정화 (Level 1) 와 spatial awareness (Level 2) 두 효과를 직교적으로 분리하기 위해 *비례 배분* ($n_h \propto N_h$) 만 사용합니다 — Neyman optimal allocation 은 RQ3 의 H (Importance Sampling) 에서 별도 비교합니다.

Q6.6 비례 배분 (proportional allocation) 만 쓰면, *Neyman 최적 배분* 의 분산 감소 이점은 어떻게 되나요?

핵심 한 줄: Neyman optimal allocation 은 stratum 별 분산 σ_h 정보가 필요한데, 본 연구는 *분포를 알 때* (RQ2) 와 *모를 때* (RQ3) 의 직교적 비교에 집중하므로, RQ2 에서는 baseline 인 비례 배분만 쓰고 Neyman 은 RQ3 의 H (Importance Sampling) 에서 비교합니다.

표준 답변 (40 초)

Neyman 최적 배분 (Neyman 1934) 은 분산 감소가 더 크지만 stratum 별 분산 σ_h 의 사전 지식이 필요합니다. 본 연구의 RQ2 는 *공간 분할 자체의 효과* 를 측정하는 데 집중하므로 비례 배분 ($n_h \propto N_h$) 으로 통제하고, 분산 정보를 활용하는 효과는 RQ3 의 H (Importance Sampling) 에서 별도 비교합니다. H 는 importance weight 를 분산 추정값으로 조정하므로 Neyman 의 변형으로 볼 수 있고, 본 연구의 7-way 비교에서 H 만 2×2 factorial 로 estimator (uniform vs IS) $\times$ allocation (KM20 vs no partition) 4 조합 을 모두 측정하는 이유가 여기에 있습니다.

Q6.7 sample_size = 385 는 어디서 온 값인가요?

핵심 한 줄: Cochran (1977) 의 sample size formula 에서 95 % CI ± 5 %p 마진의 binomial proportion estimation 기준으로 $(1.96^2 \times 0.5 \times 0.5) / 0.05^2 \approx 384.16 \approx 385$ 로, Exqutor 의 default 값을 그대로 사용했습니다.

표준 답변 (40 초)

Cochran 의 *Sampling Techniques* 교과서 표준 공식: $n = z^2 \times p(1-p) / e^2$ 에서 $z = 1.96$ (95 % CI), $p = 0.5$ (most conservative), $e = 0.05$ (5 % margin) $\rightarrow n \approx 384.16 \rightarrow 385$. 이는 Exqutor 의 GUC default `vector.sample_size = 385` 와 일치하며, 본 연구는 이 default 를 그대로 사용해 *sample_size 변동 효과* 를 통제 했습니다. sample_size 의 sensitivity (작거나 큰 값에서 효과가 어떻게 변하는지) 는 W5 보충 실험에 포함되며, 본 보고서 시점은 default 385 로 실험 조건을 일관되게 유지합니다.

섹터 7. 외적 타당성 (Cross-Dataset)

DEEP 8M 외적 확장 + SIFT cross-dataset 검증. 자문 회신에서 가장 칭찬받은 부분.

Q7.1 왜 SIFT 와 DEEP 두 개만 비교했나요? GIST, glove, msmarco 같은 다른 데이터셋은?

핵심 한 줄: ANN-Benchmarks 표준에서 SIFT (128d, image keypoint, more skewed) 와 DEEP (96d, deep image feature, less skewed) 가 *대조적인 분포 특성을 가진 anchor pair* 로 자리잡고 있어 cross-dataset 비교의 anchor 로 충분하며, GIST/glove/msmarco 는 W5-W7 보충 실험 (5 월) 에 포함됩니다.

표준 답변 (45 초)

ANN-Benchmarks 의 표준 evaluation 에서 SIFT 와 DEEP 는 *대조적 분포 특성을 가진 anchor pair* 로 자리잡고 있습니다. SIFT 는 128 차원 image keypoint descriptor (uint8) 로 분포가 더 skewed (CV 0.394), DEEP 는 96 차원 deep learning image feature (float32) 로 상대적으로 균일 (CV 0.234) 합니다. 두 데이터셋의 KM20 효과 격차 (DEEP 1.64 % vs SIFT 3.07 %) 가 CV 격차 (0.234 vs 0.394, 68 % 차이) 에 비례한 것이 본 연구의 핵심 cross-dataset finding 입니다. GIST (960 차원, 더 고차원) 와 glove (300 차원, text embedding), msmarco (text retrieval) 는 W5-W7 보충 실험에 포함되며, 특히 wiki 768d 는 차원 효과 검증에 추가됩니다. 본 보고서 시점에서는 DEEP-SIFT pair 로 *다른 modality·다른 차원·다른 skewness* 의 cross-dataset 일반화를 1차 확인했습니다.

Q7.2 DEEP 8M 에서 KM20 효과 +1.76% 가 1M 의 +1.64% 와 거의 같은데, 의미가 있나요?

핵심 한 줄: 외적 타당성 (external validity) 의 핵심은 *효과의 absolute size* 가 아니라 *효과가 데이터 규모를 바꿔도 일관되게 유지되는가* 입니다. 8M (8 배 큰 데이터) 에서도 1M 과 동일한 효과 크기가 나온 것은 본 연구가 *data size-invariant property* 를 가짐을 강하게 시사합니다.

표준 답변 (50 초)

외적 타당성의 학술적 의미는 *효과 크기의 절대값* 이 아니라 *효과가 다른 조건에서도 재현되는가* 입니다. 8M (8 배 큰 데이터) 에서 KM20 의 mean diff 가 1M 과 비슷한 +1.76 % 로 측정된 것은, 본 연구의 효과가 *data size-invariant* 하다는 의미입니다. 즉 sample_size = 385 가 1M 과 8M 모두에서 비례적으로 유지되어 (1M 에서 0.0385 % vs 8M 에서 0.0048 % sample fraction) 효과 크기가 일정하게 나옵니다. 또한 8M 의 95 % CI [+0.65, +2.86] 와 1M 의 [+1.09, +2.18] 가 *완전히 겹치며* CONSISTENT 판정이 나왔는데, 이는 통계적으로 두 측정이 같은 모집단의 두 sample 임을 시사합니다.

디테일 보강 (1 분)

8M 에서 selectivity 0.05/0.01 의 효과가 1M 보다 작거나 noise 영역으로 들어간 것은 *별도의 limitation* 입니다 — sample_size = 385 가 8M 의 0.005 % 에 불과해 small selectivity 에서 양자화 한계에 걸리기 때문입니다. 이는 anomaly_analysis.md 에 명시적으로 기록된 limitation 이며, "sample_size 가 데이터 규모와 함께 비례적으로 늘어나야 한다" 는 후속 연구 방향을 제시합니다. 본 연구의 명확한 finding 은 $s \geq 0.05$ 영역에서 효과가 data-size-invariant 하게 유지된다는 점입니다.

Q7.3 SIFT 가 DEEP 보다 더 skewed 한 이유가 데이터셋 자체의 특성 인가요, 아니면 임베딩 모델의 특성 인가요?

핵심 한 줄: SIFT 는 image keypoint descriptor (Lowe 2004) 로 *handcrafted feature* 이고 DEEP 는 *deep learning feature* 인데, 둘의 분포 차이는 임베딩 방식 자체의 차이로 해석되며, 본 연구는 이를 통제 변수로 두고 *중화 표본의 효과* 측정에 집중합니다.

표준 답변 (45 초)

SIFT 는 SIFT 알고리즘 (Lowe 2004) 으로 추출된 128 차원 image keypoint descriptor 로, *handcrafted feature* 입니다. 한 이미지에서 여러 keypoint 가 추출되므로 *keypoint 기반 분포* 가 형성되고, 이는 자연 이미지의 edge-corner 분포에 따라 *spatially clustered* 됩니다. DEEP 는 deep learning 으로 학습된 image feature 로, neural network 의 representation 이 *isotropic distribution* 에 가깝게 학습되는 경향이 있습니다. 즉 두 데이터셋의 분포 차이는 *임베딩 방식의 차이* 에서 옵니다. 본 연구는 이 차이를 *통제 변수* 로 두고, "두 분포 모두에서 KM20 의 효과가 양수 확정이고, 더 skewed 한 SIFT 에서 효과가 더 크다" 는 cross-dataset 일반화를 확인합니다. 임베딩 모델별 효과 비교 (BERT vs CLIP vs ResNet) 는 RQ3 또 는 후속 연구의 영역입니다.

Q7.4 차원이 다른 (96d vs 128d) k-means clustering 자체의 안정성이 달라지지 않나요?

핵심 한 줄: k-means 는 차원이 늘어날수록 *curse of dimensionality* 로 cluster 경계가 흐려지지만, mini-batch k-means + n_iter=100 + seed 42 의 결정론적 학습으로 두 데이터셋 모두 *재현 가능한 partition* 을 얻었고, partition 의 *stability* 는 별도 측정으로 확인됩니다.

표준 답변 (45 초)

k-means 의 차원 효과는 잘 알려진 issue 이지만, 두 데이터셋 모두에서 *결정론적 재현 가능 partition* 을 얻었습니다. mini-batch k-means (Sculley 2010) 를 batch_size=4096, n_iter=100, seed=42 로 학습해 cluster centroid 를 고정하고, 1M / 8M / 1.5M 모든 행에 stratum_id 를 할당했습니다. partition 의 stability 는 inertia (within-cluster sum of squares) 측정으로 확인되며, DEEP 1M K=20 의 inertia_mean = 0.692, training time = 0.5 s 로 빠르고 안정적입니다. 즉 두 데이터셋 모두에서 k-means 가 동작하지 않는 영역이 아니라 *재현 가능한 baseline partition* 을 얻었고, 이를 RQ3 의 distribution-agnostic 방법들과 fair comparison 의 reference 로 사용합니다.

Q7.5 DEEP 1M 과 8M 의 CV 가 다를 텐데, 두 데이터셋의 *underlying 분포* 는 같다고 볼 수 있나요?

핵심 한 줄: DEEP 8M 은 DEEP 1M 의 *upscaled version* 이 아니라 *동일 source 의 더 큰 sample* 입니다. 두 데이터셋 모두 동일한 deep learning 모델로 추출된 96 차원 feature 의 다른 sample 이며, 핵심 partition 통계 (CV, ratio) 는 sample size 무관하게 *underlying distribution* 고유 입니다.

표준 답변 (40 초)

DEEP 1M 과 DEEP 8M 모두 같은 source (Yandex DEEP1B) 의 sub-sample 로, 동일한 deep learning 모델 (96 차원 image feature) 로 추출됐습니다. underlying distribution 은 동일하고, 1M / 8M 은 그 분포의 다른 sample size 입니다. 따라서 cluster 분포의 CV 는 sample size 가 충분히 크면 underlying CV 로 수렴하고, 1M 과 8M 에서 CV 가 비슷하게 나오는 것이 정상입니다. 본 연구의 cross-dataset 비교 (DEEP vs SIFT) 는 *다른 underlying distribution* 의 비교이고, scale-invariance 검증 (DEEP 1M vs DEEP 8M) 은 *같은 underlying distribution 의 다른 sample size* 의 비교입니다. 두 비교 모두 효과의 robustness 확인에 기여합니다.

Q7.6 cross-dataset 효과 격차가 *DEEP* 의 +1.64% vs *SIFT* 의 +3.07%, 약 두 배 인데, 이게 정말 *분포의 skewness* 때문인가요? 다른 가능한 설명은?

핵심 한 줄: 분포의 skewness (CV 0.234 vs 0.394, 68 % 격차) 가 효과 격차 (1.64 % vs 3.07 %, 약 두 배) 와 *동일 방향으로 증가* 하는 것이 1차 증거이고, two-level decomposition 에서 *Level 2 (공간 인식)* 단독 이 SIFT 에서 +2.06 % vs DEEP 에서 -0.56 % 로 측정된 것이 *기전 (mechanism) 단위 분리* 의 인과 증거입니다.

표준 답변 (50 초)

두 갈래 인과 증거가 있습니다. 첫째, 상관관계: CV 격차 (DEEP 0.234 vs SIFT 0.394, 68 %)와 효과 격차 (1.64 % vs 3.07 %, 약 87 %)가 **동일 방향으로 동반 증가**합니다. 이는 association 증거입니다. 둘째, 기전 단위 분리: two-level decomposition 으로 *Level 1 (proportional allocation)* 효과와 *Level 2 (spatial awareness)* 효과를 분리했습니다. SIFT 의 Level 2 단독 효과 (+2.06 %)가 DEEP 의 Level 2 효과 (-0.56 %)보다 **기전 자체로** 큼니다. 즉 "분포가 더 skewed → spatial awareness 단독 효과가 커짐"의 인과 관계가 데이터에서 직접 확인됩니다. 다른 가능한 설명 (차원 차이, 데이터 종류 차이, 임베딩 모델 차이)은 모두 분포의 skewness와 공변하기는 하지만, two-level 분해로 이 모두를 통제했을 때도 *Level 2* 단독 효과가 남는다는 점이 본 연구의 강력한 인과 증거입니다.

섹터 8. Two-Level Decomposition (인과 입증)

KM20 vs RANDOM20 = Level 1 vs Level 2. 본 연구의 가장 강력한 인과 증거. $s=0.010$ 에서 19.6%p 격차.

Q8.1 Two-Level decomposition 이 정확히 무엇인가요? 왜 그런 분해를 했나요?

핵심 한 줄: KM20 (k-means 거리 기반 분할)과 RANDOM20 (무작위 분할) 둘 다 $K=20$ 으로 stratified sampling 을 하지만, 전자만 **공간 인식** 효과를 가지므로, $KM20 - RANDOM20 = \text{Level 2 (spatial awareness)}$ 단독 효과로 **기전 단위 분리** 측정이 가능합니다.

표준 답변 (50 초)

본 연구가 KM20 의 효과를 측정했는데, 그 효과가 **어디서 오는가**를 분해해야 학술적 가치가 있습니다. 두 가지 가능성이 있습니다 — (a) 단순히 $K=20$ 으로 나누어 비례 배분만 해도 표본 안정화로 효과가 나오는 것 (Level 1 = proportional allocation effect), (b) 거리 기반 분할이 데이터 공간 구조를 반영해 추가 효과를 만드는 것 (Level 2 = spatial awareness effect). 둘을 분리하기 위해 같은 $K=20$ 으로 분할하되 **무작위**로 행을 할당한 RANDOM20 을 control 로 두고, 같은 sample_size 와 같은 비례 배분을 적용해 두 모드의 효과를 비교합니다. $KM20 - RANDOM20$ 의 차이가 정확히 Level 2 (spatial awareness) 단독 효과입니다. DEEP 1M selectivity 0.010 에서 $KM20 +8.93\%$ vs $RANDOM20 -10.67\%$ → Level 2 단독 +19.6%p 의 측정이 본 연구의 가장 강력한 **인과 증거**입니다.

Q8.2 selectivity 0.500 에서는 KM20 (+1.64%) 이 RANDOM20 (+2.20%) 보다 오히려 작는데, 무슨 아닌가요?

핵심 한 줄: selectivity 0.500 에서는 Level 1 (proportional allocation) 효과만 작동하고 Level 2 (spatial awareness) 가 불필요하기 때문이며, KM20 과 RANDOM20 의 0.56 %p 차이는 seed 간 분산 ($\sim 0.5 \sim 1$ % std) 안에 있는 *비유의적* 차이입니다.

표준 답변 (50 초)

selectivity 0.500 에서 true_card 가 ~ 50 만 (전체의 50 %) 으로 모든 cluster 에 고르게 분포 합니다 (cluster HHI $\approx 1/K = 0.067$). 이 영역에서는 query 결과가 spatial concentration 을 보이지 않으므로, 공간 인식 효과가 발현될 여지가 없습니다. 단순히 $K=20$ 으로 나누어 비례 배분하는 효과 (Level 1) 만으로 충분하고, KM20 과 RANDOM20 모두 같은 정도의 표본 안정화 효과를 갖습니다. 두 mode 의 0.56 %p 차이 (-0.56) 는 5-seed 의 std ($\sim 0.5 \sim 1$ %) 안에 있어 통계적으로 *비유의* 합니다. 이는 모순이 아니라 Level 2 가 *selectivity-dependent* 라는 본 연구의 핵심 발견을 직접 확인하는 evidence 입니다 — 넓은 영역 ($s=0.500$) 에서는 Level 2 가 0 에 수렴하고, 좁은 영역 ($s=0.010$) 에서는 $+19.6$ %p 로 dominant 가 됩니다. anomaly_analysis.md 에 이 anomaly 의 *기전적 설명* 이 명시되어 있습니다.

Q8.3 19.6 %p 격차의 통계적 유의성은 어떻게 산출했나요? 단순 difference of means 인가요?

핵심 한 줄: KM20 5-seed CI [+6.59, +10.95] 와 RANDOM20 5-seed CI [-15.26, -6.51] 가 완전히 분리 되어 (겹치지 않음) 통계적으로 유의한 difference 임이 확정되며, 19.6 %p 는 두 mean 의 산술적 차이 ($8.93 - (-10.67)$) 입니다.

표준 답변 (45 초)

두 갈래 통계 증거가 있습니다. 첫째, CI 분리: KM20 CI [+6.59, +10.95] 와 RANDOM20 CI [-15.26, -6.51] 가 완전히 분리되어 (KM20 lower bound 6.59 vs RANDOM20 upper bound -6.51) 두 분포의 mean 차이가 통계적으로 유의함이 확정됩니다. 둘째, paired comparison: KM20 의 5/5 seed 모두 양수 (+8.51, +11.42, +11.53, +4.33, +8.87 %), RANDOM20 의 5/5 seed 모두 음수 (-10.63, -7.77, -11.51, -19.01, -4.43 %) — 즉 완전 분리된 sign 으로 unsigned binomial test 에서도 $p < 1e-3$ 의 강한 신호입니다. 19.6 %p 는 두 mean 의 산술적 차이 ($8.93 - (-10.67)$) 이며, 두 5-seed CI 가 분리되어 있으므로 이 격차도 robust 합니다.

Q8.4 selectivity 가 줄어들수록 Level 2 효과가 커진다는 것이, 기전적으로 어떻게 설명되나요?

핵심 한 줄: selectivity 가 줄어들면 (좁은 영역) query 결과가 소수 *cluster* 에 집중되어 cluster HHI 가 급증하고 ($s=0.010$ 에서 $HHI \approx 0.50$, 균일 대비 10 배), 이때만 *cluster* 구조를 아는 KM20 이 집중 영역에서 정확한 표본을 추출할 수 있는 반면 *cluster* 구조를 모르는 RANDOM20 은 이를 반영하지 못해 추정을 왜곡합니다.

표준 답변 (60 초)

selectivity 와 cluster HHI 의 관계가 핵심입니다. selectivity 가 클 때 ($s=0.500$) query 결과가 모든 *cluster* 에 고르게 분포하므로 cluster $HHI \approx 1/K = 0.067$ (균일 수준) 이고, partition 품질과 무관하게 비례 배분만으로 충분합니다. selectivity 가 작아질수록 ($s=0.010$) query 결과가 소수의 인접 *cluster* 에 집중되어 cluster HHI 가 급증하며 (실측 0.503, 균일 대비 10 배), 어느 *cluster* 가 hit 의 대부분을 가지는지가 추정 정확도를 결정합니다. KM20 은 cluster 구조를 알고 있어 hit 가 집중된 cluster 에서 비례 배분으로 정확한 sample 을 가져오지만, RANDOM20 은 cluster 라벨이 무작위라 hit 가 어느 stratum 에 있는지 모르고, 잘못 라벨이 붙은 hit cluster 에서 small sample 을 뽑아 추정을 심하게 왜곡합니다. 이 기전이 정확히 *spatial awareness* 의 정의이며, hhi_python_summary.json 의 selectivity 별 HHI 변동이 이를 정량적으로 뒷받침합니다.

Q8.5 Two-Level decomposition 이 원래 stratified sampling 이론에 있는 분해인가요? 아니면 본 연구의 새 framework 인가요?

핵심 한 줄: Stratified sampling 이론에서 분산 감소를 *between-stratum variance* 감소와 *within-stratum* 표본 안정화 두 갈래로 분해하는 것은 표준 (Cochran 1977, Lohr 2010) 이며, 본 연구는 이를 *empirical RANDOM20 control* 로 직접 측정 가능한 형태로 specialize 했습니다.

표준 답변 (45 초)

분산 분해 이론적 배경은 표준 sampling theory 입니다. Cochran 의 *Sampling Techniques* (1977) 에서 stratified sampling 의 분산은 *within-stratum variance* 의 weighted sum 으로 분해되며, 이를 $Var(\hat{y}_{strat}) \leq Var(\hat{y}_{SRS})$ 의 부등식으로 보장합니다. 본 연구의 Level 1 / Level 2 분해는 이 이론을 *empirical RANDOM20 control* 로 측정 가능한 형태로 specialize 한 것입니다. 핵심 기여는 RANDOM20 partition 으로 *within-stratum variance* 의 baseline 을 잡고, KM20 의 *spatial awareness* 가 이를 얼마나 추가로 줄이는지를 직접 측정한다는 점입니다. 이 framework 자체가 distribution-agnostic 한 RQ3 의 evaluation metric (Recovery Rate) 의 기초가 됩니다.

섹터 9. HHI / CV 정량화 (Cluster Skewness)

데이터의 쏠림을 어떻게 잴 것인가? CV 0.234 vs 0.394 의 의미.

Q9.1 HHI 가 정확히 무엇인가요? 왜 그 지표를 골랐나요?

핵심 한 줄: Herfindahl-Hirschman Index 는 각 cluster 가 차지하는 비율의 제곱합으로 산업조직론에서 시장 집중도를 잴 때 표준이며, 균일 분포 ($1/K = 0.05$) 와 완전 집중 (1.0) 사이의 단조 함수라 분포 쏠림의 정량 지표로 직관적입니다.

표준 답변 (40 초)

HHI = $\sum_i (\text{size}_i / \text{total_size})^2$ 로, 각 cluster 의 비중을 제곱해 합한 값입니다. 균일 분포 (모든 cluster 가 $1/K$) 에서 $K \times (1/K)^2 = 1/K$ 이고, 한 cluster 가 모두 차지할 때 1.0 입니다. 본 연구는 $K=20$ 이므로 HHI 균일 기준 = 0.05, max = 1.0. DEEP 1M HHI 0.05274 는 균일 대비 5.5 % 큰 쏠림이고, SIFT HHI 0.05776 은 15.5 % 큰 쏠림입니다. 두 값의 절대 차이는 작아 보이지만 균일 기준 0.05 대비의 비율로 보면 SIFT 가 DEEP 의 약 3 배 더 쏠려 있습니다. HHI 외에 CV (변동계수) 도 함께 보고하는데, 두 지표가 직교적으로 분포의 쏠림을 잡아내기 때문입니다.

Q9.2 CV (Coefficient of Variation) 와 HHI 는 어떻게 다른가요? 둘 다 보고한 이유는?

핵심 한 줄: HHI 는 비중의 제곱합이라 큰 cluster 에 더 민감하고, CV 는 상대적 표준편차라 모든 cluster 의 변동을 동일하게 반영하므로, 두 지표를 같이 보면 위쪽 꼬리와 전체 분포 변동을 함께 평가할 수 있습니다.

표준 답변 (45 초)

HHI 는 $\sum (p_i)^2$ 로 큰 cluster 의 영향이 제곱으로 들어가, 한 cluster 가 dominant 할 때 빠르게 증가합니다 — 즉 위쪽 꼬리에 민감합니다. CV = std / mean 은 모든 cluster 의 deviation 을 동일하게 반영하는 전체 분포 변동 지표입니다. DEEP 1M 에서 HHI 균일 대비 격차 0.00274 (5.5 %), SIFT 에서 HHI 격차 0.00776 (15.5 %) — 3 배 비례. CV 는 DEEP 0.234, SIFT 0.394 → 68 % 격차. 두 격차의 비율이 다르다는 것은 위쪽 꼬리 (한두 큰 cluster) 의 영향이 SIFT 에서 상대적으로 더 큼을 의미합니다. 실제로 SIFT 의 cluster 1 (14.8 만) 과 cluster 18 (14.0 만) 두 개가 전체의 19 % 를 차지 (기대 10 % 의 약 두 배) 합니다. 두 지표를 같이 보면 어떻게 쏠려 있는지도 알 수 있습니다.

Q9.3 K=20 fixed 에서 측정한 HHI 인데, K 가 달라지면 HHI 도 달라지지 않나요?

핵심 한 줄: 맞습니다. HHI 는 K 에 의존하므로 *K=20 condition 에서의 cluster skewness* 만 보고합니다. K sweep (W5) 에서 K=10, 20, 50 의 HHI 변동을 측정 예정이며, 본 연구의 결론은 "K=20 baseline 에서 SIFT 가 DEEP 보다 더 쏠려 있다" 로 한정됩니다.

표준 답변 (35 초)

HHI 의 K 의존성은 sampling theory 의 표준 caveat 입니다. K 가 늘어나면 모든 cluster 의 비중이 작아 지므로 균일 기준 $HHI = 1/K$ 도 작아지고, 같은 데이터의 partition 결과도 달라집니다. 본 연구는 *K=20 baseline 에서의 cluster skewness 비교* 로 결론을 한정했고, K sweep (K = 5, 10, 20, 50, 100) 은 W5 보충 실험에 포함됩니다. K 와 무관한 *분포의 underlying skewness* 는 PCA EVR1 같은 dimension-free 지표로 측정 가능한데, 본 연구는 stratified sampling 의 evaluation 에 직결되는 *partition-specific skewness* 측정에 집중했습니다.

Q9.4 SIFT 의 cluster 1 (14.8 만) 이 cluster 18 (14.0 만) 과 비슷한 크기인데, 우연 아닌가요?

핵심 한 줄: 5 seed × 100 query 측정 전반에서 *cluster 1 + cluster 18* 의 hit 집중도가 일관되게 다른 cluster 보다 높게 측정되어, 단순 우연이 아닌 *데이터 자체의 cluster 구조* 임이 확인됩니다.

표준 답변 (40 초)

mini-batch k-means (seed=42, n_iter=100, batch_size=4096) 의 *결정론적 학습* 으로 SIFT 1.5M 을 K=20 으로 분할했을 때, cluster 1 과 cluster 18 이 공동 dominant 로 떠올랐습니다. 5 seed 측정 (sample 추출 seed) 에서 모든 5 seed 가 같은 cluster 라벨링을 사용하므로 (cluster 라벨 자체는 1 seed = 42 로 고정), cluster 1·18 의 dominance 는 partition 결과의 *결정론적 특성* 입니다. 이 dominance 가 SIFT 의 KM20 효과를 DEEP 보다 약 두 배로 키우는 직접 원인이며, cluster_distribution.md 에 정량 기록되어 있습니다.

Q9.5 균일 기준 이라는 게 정확히 무엇인가요? 비교의 의미는?

핵심 한 줄: 데이터가 K개 cluster 에 *완전 균일하게* 분포한다고 가정한 이론적 기준선이며, HHI 균일 기준 = $1/K = 0.05$, CV 균일 기준 = 0.0 입니다. 실측이 균일 기준에 *얼마나 가까운가*가 분포의 쏠림 정도입니다.

표준 답변 (30 초)

"균일 기준" 은 $K=20$ 의 cluster 에 데이터가 정확히 $1/K = 5\%$ 씩 분포한다고 가정한 이론적 baseline 입니다. HHI 의 경우 $K \times (1/K)^2 = 1/K = 0.05$ 가 baseline 이고, CV 의 경우 모든 cluster size 가 같으므로 $\text{std} = 0$, $\text{CV} = 0$ 입니다. 실측 HHI 가 0.05 에 가까울수록, CV 가 0 에 가까울수록 **균일** 합니다. DEEP 1M HHI 0.05274 는 균일 기준 +5.5 % 격차, SIFT 0.05776 은 +15.5 %. 즉 **완전 균일** 과 **실측** 의 격차로 쓸림 정도를 직관적으로 잴 수 있습니다.

섹터 10. 통계 방법론 (전반)

통계 백그라운드 청중·자문위원의 favorite. 가장 깊은 추궁이 들어올 수 있는 영역.

Q10.1 paired Wilcoxon 외에 다른 통계 검정도 함께 보고하나요? 예를 들어 paired t-test 의 결과가 다르면?

핵심 한 줄: paired Wilcoxon 이 lognormal Q-error 분포에 robust 한 비모수 검정이므로 primary metric 으로 채택했고, paired t-test (log-transformed) 는 W6 (5/12 경) 보충 분석에 포함됩니다. 두 결과가 일치할 것으로 예상하며 일치하지 않으면 두 결과를 모두 보고합니다.

표준 답변 (40 초)

Q-error 는 추정값과 실제값의 비율로 lognormal 또는 heavy-tail 분포를 갖습니다. paired t-test 는 정규성 가정이 필요한데 lognormal 데이터에 직접 적용 시 outlier 영향이 크고 false positive 위험이 있습니다. paired Wilcoxon 은 **분포 가정 없이** paired difference 의 median 을 검정하는 robust 비모수라 primary metric 으로 채택했습니다. paired t-test 는 *log Q-error* 로 transform 한 후 적용 가능하며, W6 보충 분석에서 두 검정 결과를 모두 보고하고 일치성을 검증합니다. 만약 두 결과가 다르다면 어느 한 쪽의 가정이 깨진 것이므로 raw distribution 을 직접 점검할 예정입니다.

Q10.2 *Multiple comparison* 보정은 어떻게 했나요? 6 selectivity × 3 dataset = 18 셀에 대해 각각 p-value 를 산출했는데?

핵심 한 줄: 본 보고서 시점에서는 셀별 raw p-value 만 보고하고, *Benjamini-Hochberg FDR* 보정 후 *family-wise* 또는 *false discovery rate control* 결과는 W6 (5/12 경) 보충 분석에 포함됩니다. 핵심 셀 (DEEP 1M s=0.5 KM20 $p < 1e-5$, SIFT s=0.5 $p < 1e-8$) 은 어떤 보정 후에도 유의합니다.

표준 답변 (45 초)

Multiple comparison 위험은 $6 \text{ selectivity} \times 3 \text{ dataset} \times 2 \text{ mode (KM20 / RANDOM20)} = 36 \text{ 셀}$ 에 paired Wilcoxon 을 적용했을 때 약 $36 \times 0.05 = 1.8$ 개의 false positive 가 기대됩니다. 본 보고서 시점에서는 *셀별 raw p-value* 와 *5-seed CI* 만 보고하며, 핵심 anchor (DEEP 1M s=0.5 KM20: per-seed $p < 1e-5$, SIFT s=0.5 KM20: per-seed $p < 1e-8$) 은 어떤 보정 (Bonferroni $36 \times p$, BH-FDR) 후에도 유의합니다. 보충 분석 (W6) 에서는 *36 셀* 동시 의 BH-FDR adjusted p, TOST equivalence test, Cohen's d effect size 를 모두 산출해 *family-wise control* 한 결과를 보고합니다. 출판 시 reviewer 가 multiple comparison 을 우려할 가능성을 사전에 차단하기 위한 단계입니다.

Q10.3 *Cohen's d* 같은 effect size 는 측정했나요?

핵심 한 줄: 본 보고서 시점에서는 *paired difference 의 mean* 과 *95% CI* 를 effect size proxy 로 사용했고, 표준 Cohen's d (paired-sample 변형) 는 W6 보충 분석에 포함됩니다.

표준 답변 (40 초)

Cohen's d_z (paired-sample Cohen's d) = $\text{mean_diff} / \text{std_diff}$ 로, paired Wilcoxon 의 effect size 표준 metric 입니다. 본 연구의 DEEP 1M s=0.5 KM20 의 $\text{mean_diff} = 1.6366 \%$, $\text{std_diff} = 0.4416 \%$ → $d_z = 3.71$ 로 *very large* 효과 (Cohen 1988 기준 0.8 이상은 large) 입니다. 다만 본 보고서 시점에서는 raw mean diff (+1.64 %) 와 95% CI [+1.09, +2.18] 만 표 2 에 직접 인용했고, Cohen's d 는 W6 보충 분석에 포함됩니다. 효과 크기와 CI 가 모두 robust 하므로 추가 metric 없이도 *통계적·실질적 유의성* 이 모두 확인됩니다.

Q10.4 5-seed 의 CI 산출에 t-distribution 을 썼는데, *bootstrap CI* 와 다르지 않나요? 어느 것을 보고하시는 건가요?

핵심 한 줄: 보고서·발표의 CI 는 *t-based* ($\text{mean} \pm t(4) \times \text{std} / \sqrt{5}$) 로 산출했고, raw json 의 `bootstrap_95ci` 는 별도 bootstrap 방식 산출입니다. 두 방식 모두 valid 하며, 다만 동일 보고서 안에서 일관된 한 가지 방식만 쓰는 것이 좋고, 최종 보고서 (6월) 에서는 *t-based + bootstrap* 둘 다 표기 할 예정입니다.

표준 답변 (50 초) — 솔직한 자체 정정 답변

좋은 지적이십니다. 본 보고서·발표의 CI 는 *t-distribution* 기반 으로 산출했습니다 — DEEP 1M s=0.500 KM20 의 $\text{mean} = 1.6366$, $\text{std} = 0.4416$, $n = 5$, $t(4, 0.975) = 2.776$ 으로 $\text{CI} = \text{mean} \pm t \times \text{std} / \sqrt{5} = [+1.09, +2.18]$. raw data 의 phase6_multiseed_summary.json 에 별도로 산출된 `bootstrap_95ci` [+1.25, +2.02] 는 percentile bootstrap 방식이며, 두 방식이 약간 다릅니다. $n = 5$ 의 small sample 에서 t-based 와 bootstrap CI 가 다소 다르게 나오는 것이 통계적으로 정상이며, 두 방식 모두 valid 합니다. 본 보고서는 *t-based* 만 일관되게 보고하고, 최종 보고서 (6 월) 에서는 두 방식 모두 표기 해 reviewer 가 직접 비교 가능하도록 할 예정입니다. 효과의 *방향성* 과 *유의성* 은 두 방식 모두에서 동일하게 확정 (양수 CI) 입니다.

Q10.5 통계적으로 유의하다고 *임상적으로 (실무적으로)* 의미가 있는가는 다른 문제인데, +1.6 % 가 실제로 어느 정도 의미 있는 개선인가요?

핵심 한 줄: Q-error 의 1.6 % 개선이 *옵티마이저 plan* 선택의 임계점 근처 쿼리 에서 plan 단위 변경을 일으킬 수 있고, plan 한 번의 잘못이 실행 시간을 1 만 배까지 늘릴 수 있다는 Exqutor 원논문의 보고를 고려하면, *실용적 의미가 있다* 고 판단됩니다.

표준 답변 (50 초)

두 갈래 답변이 가능합니다. 첫째, *micro-level*: 1.6 % 의 정확도 개선 자체는 작아 보이지만, 이는 *median* 수준의 개선 입니다. distribution 의 tail 에서는 더 큰 개선이 일어나며, 옵티마이저의 plan 선택은 distribution 전체가 아닌 *임계점 근처* 에서 결정됩니다. 그래서 median 1.6 % 개선이 *임계점 근처 쿼리* 에서 잘못된 plan 을 고를 확률 을 줄이는 효과를 갖습니다. 둘째, *macro-level*: Exqutor 원논문이 보고한 VBASE 1 만 배 이상의 실행 시간 격차가 plan 한 번의 잘못에서 옵니다. 따라서 1.6 % 의 정확도 개선이 *plan 변경 확률* 을 1 % 줄여도, 영향받는 쿼리에서 1 만 배의 실행 시간 차이를 만들 수 있습니다. End-to-end query time 영향은 본 연구 범위 밖이지만, plan 선택 메커니즘으로 *실용적 의미가 있다* 는 근거는 충분합니다.

Q10.6 통계적 power 분석은 했나요? Type II error 위험을 통제했나요?

핵심 한 줄: paired Wilcoxon 의 *medium effect* (Cohen's $d \approx 0.5$) at $\alpha = 0.05$, power 0.8 기준으로 약 50 ~ 70 paired sample 이 필요하며, 본 연구는 5-seed $\times$ 100 query = 500 paired 로 이 기준의 7 ~ 10 배입니다.

표준 답변 (35 초)

Power 분석은 paired Wilcoxon 의 표준 software (GPower 또는 R pwr 패키지) 로 산출 가능합니다. *medium effect* (Cohen's $d_z \approx 0.5$) 를 $\alpha = 0.05$ 양측, power = 0.8 기준으로 잡으려면 약 50 ~ 70 paired sample 이 필요합니다. 본 연구의 5-seed $\times$ 100 query = 500 paired 는 이 기준의 7 ~ 10 배이고, 각 5-seed 가 독립이므로 mean diff 의 표준오차는 $std/\sqrt{5}$ 로 줄어듭니다. 따라서 Type II error (effect 가 있는데 못 잡는 위험)* 는 충분히 통제되어 있습니다. small effect ($d_z \approx 0.2$) 를 잡으려면 약 200 ~ 300 paired 가 필요한데, 이는 W6 의 10-seed $\times$ 500-쿼리 = 5000 paired 측정에 포함됩니다.

Q10.7 Phase 7 의 plan_rows artifact 는 어떻게 발견했고, 어떻게 처리했나요?

핵심 한 줄: 4 월 15 일 Phase 7 결과가 "ratio 2168x" 라는 비정상적으로 큰 값을 보고해 자체 검증을 시작했고, plan_rows = 20 이 stratified estimator 의 출력이 아니라 LIMIT 20 상수 임을 발견 후 철회 + redo 를 진행했습니다. 본 연구의 학술 정직성 사례입니다.

표준 답변 (60 초) — 자체 정정 + 학술 정직성 강조

4 월 15 일 Phase 7 의 첫 측정에서 DEEP 8M 에서 KM20 가 BERN 대비 2168 배 개선 (median Q-error BERN 20810 vs STRAT 9.6) 을 보고했습니다. 이 비정상적으로 큰 값을 자체 검증한 결과, strat plan_rows 가 100 query 모두 정확히 20 으로 상수 였고, 이는 stratified estimator 의 출력이 아니라 plan tree 의 LIMIT 20 = K 라는 artifact 였습니다. hook_est 기반으로 다시 산출한 결과, STRAT 가 BERN 보다 26.5 % 나쁨 으로 방향이 완전 반전 되었습니다. 즉시 Phase 7 결과를 철회하고, D_target 재 계산 후 actual_sel ≈ 0.5 로 보정한 redo 측정 (8m_km20_s0500_5seed.json) 에서 +1.76 % [+0.65, +2.86] 의 정상 결과를 얻었습니다. 본 보고서·발표의 모든 8M / SIFT 수치는 redo 결과이며, artifact 는 사용하지 않았습니다. 자체 negative finding 을 학술적으로 정직하게 처리한 사례로, phase7_artifact_verification_20260415.md 에 검증 절차와 결론이 영구 보존되어 있습니다.

디테일 보강 (1 분 30 초)

Artifact 의 기술적 원인은 plan tree 구조였습니다. KM20 의 native 구현이 PostgreSQL 의 `Aggregate → Append → Subquery Scan × 20 stratum` 으로 plan 을 만드는데, `find_scan_node` 가 첫 Subquery Scan 의 `Plan Rows = LIMIT 20` 을 반환했습니다. 이는 stratum 당 LIMIT 상수일 뿐 estimator 의 출력이 아닙니다. 자체 검증 절차는 (1) plan_rows 분포 확인 (mean=std=20.0, unique=1) → (2) hook_est 기반 paired 결과 직접 확인 (STRAT 26.5 % 나쁨) → (3) 두 metric 의 결과가 *완전 반전* 임을 확인 → (4) hook_est 가 authoritative 임을 phase6 step4 의 metric 정의로 확정 → (5) plan_rows artifact 결과 전 수 철회 + redo. 이 과정 전체를 phase7_artifact_verification_20260415.md 에 기록했고, 이 negative finding 자체를 *학술 정직성의 본보기* 로 활용합니다 — reviewer 의 동일 검증을 팀이 먼저 발견하고 공개한 것이 본 연구의 신뢰도를 오히려 높입니다.

섹터 11. RQ3 — 분포 무인지 7 가지 방법 (탐색 단계)

5 월 비교 실험 계획. 7 가지 방법 선정 기준 + 24개 후보 → 17 개 탈락 사유 + D (Exqutor Hybrid) 제외 정당성.

Q11.1 RQ3 의 7 가지 방법은 어떤 기준으로 골랐나요? 24 개 후보 중 17 개가 탈락했는데, 그 사유는?

핵심 한 줄: 4 가지 평가 축 — (a) *이론적 정당성* (이론 백그라운드), (b) *6주 내 구현 가능성* (학부 캡스톤 timeline), (c) *KM20 과의 차별성* (단순 변형 제외), (d) *우리 측정 파이프라인 적합성* (hook_est + stratum_id 기반) — 으로 24 개 후보를 score 해 7 개를 확정했습니다.

표준 답변 (60 초)

24 개 후보를 4 갈래로 분류해 평가했습니다. 첫째, *이미 검증된 단순 방법* — Random Projection (C), LSH (A), Hilbert curve (E), Mini-batch K-means (F) 4 개. 둘째, *쿼리 적응 방법* — Distance-Shell (G), KDE-pilot (B) 2 개. 셋째, *비분할 방법* — Importance Sampling (H) 1 개. 총 7 개. 탈락 17 개는 (a) Latin Hypercube 같은 *고차원에서 동작 안 하는 방법*, (b) Tree-based / Spectral / Optimal Transport 같은 *KM20 과 비용 비슷하면서 차별성 없는 방법*, (c) Coreset / Multi-armed Bandit 같은 *RQ3 범위 밖 (sample selection vs cardinality estimation 문제) 방법*, (d) Density-Inverse Pre-weighting 같은 *기존 7 개의 변형* 으로 분류해 모두 사유 기록과 함께 탈락시켰습니다. 이 분류가 RQ3 설계안 문서에 24 → 7 의 결정 트리로 정리되어 있어 reviewer 가 우리의 공간 탐색 폭을 직접 검증할 수 있습니다.

디테일 보강 (2 분)

17 개 탈락 후보의 구체적 사유를 일부 들면: (1) Latin Hypercube — 96d 에서 K^d 셀 폭발로 차원 축소 필수 → C (Random Projection) 와 동치. (2) Tree-based (VP/KD/Ball tree) — 구축 비용 $O(N \cdot \log N)$ 으로 k-means 와 같은 order, 차별성 0. (3) Coreset Construction — sample selection 을 직접 지정해야 해서 hook_est 로그 파싱 불가, 7-way fair comparison 안 됨. (4) Multi-armed Bandit — 반복 쿼리 학습이 본 연구의 *single query estimation* 세팅과 부적합. (5) Optimal Transport (Wasserstein) — 이론 적이나 1M 데이터에 비현실적. (6) Spectral Clustering — $O(N^2)$ 메모리. (7) Random Voronoi — F (MiniBatch) 의 learning_fraction = 0 % case → F 로 통합. (8) Anchor-based Distance Profile — M 차원 프로필에 A/C/E/F 중 하나 적용 → 독립 방법 아님. (9) Ensemble (다중 방법 투표) — LSH (A) 가 정확히 이것 (p 개 hyperplane). 24 개 후보 모두 RQ3 설계안 [plans/RQ3설계안_20260416_213500.md](#) §X 의 표에 사유와 함께 기록되어 있습니다.

Q11.2 D (Exqutor Hybrid — Adaptive + KM20 결합) 는 왜 가장 자연스러운 출발점인데 제외했나요?

핵심 한 줄: Phase 7 측정 단계에서 (1) Adaptive update path 가 SIGSEGV crash 하고, (2) 크래시 회피해도 hook_est 기반 STRAT 가 BERN 보다 *나쁨*의 negative finding 이 나왔으며, (3) "Exqutor 버그 수정" 이 RQ3 의 취지 (새로운 방법론 제안) 와 안 맞고, (4) 6 주 내 구현 비현실적이라 탈락했습니다.

표준 답변 (50 초)

D 가 가장 자연스러운 출발점이라는 직관은 맞지만, 실제 측정에서 4 가지 issue 가 누적되어 탈락했습니다. 첫째, Adaptive update path 가 단일 테이블 시나리오에서 SIGSEGV crash. 둘째, update_sample_size = off 로 우회해도 hook_est 기반 STRAT 가 BERN 보다 *나쁨*의 negative finding (8M 에서 STRAT 26.5 % 나쁨, SIFT 에서 325 % 나쁨) 이 나옴. 셋째, "Exqutor Adaptive 의 버그를 수정해서 결합" 이라는 노선이 RQ3 의 취지 — 새로운 *distribution-agnostic 방법론 제안* — 와 안 맞음. 넷째, 6 주 (5/4 ~ 6/14) 내 Exqutor 내부 디버깅 + KM20 결합 + 실험 + 분석 모두 진행하기 비현실적. 이 4 가지 사유를 RQ3 설계안에 명시했고, 본 연구는 *Adaptive Sampling* 의 한계를 인식하고 *sample_allocation 차원의 대안을 제시* 하는 positioning 으로 D 를 제외했습니다.

Q11.3 7 가지 방법 중 가장 기대되는 것은? 그 이유는?

핵심 한 줄: 비용-효과 측면에서 F (Mini-batch K-means) 가 75 ~ 95 % recovery 로 가장 높은 기대 — 데이터의 1 ~ 5 % 만 보고 KM20 을 근사하는 형태이므로 KM20 의 oracle 효과에 가장 가깝습니다. 다만 이는 *기대* 이고 실제 recovery 는 5 월 측정에서 정합됩니다.

표준 답변 (40 초)

F (Mini-batch K-means with learning_fraction = 1 ~ 5 %) 가 비용-효과 측면에서 가장 자연스러운 후보입니다. KM20 의 oracle 학습이 1M 행 모두 학습이라면, F 는 1 ~ 5 % 만 학습 (1M 의 1 만 ~ 5 만 행) 해서 centroid 를 근사하고, 나머지 95 ~ 99 % 는 $O(d \times K)$ 의 빠른 assignment 로 처리합니다. 기대 recovery 는 75 ~ 95 % — KM20 에 매우 가깝지만 학습 비용이 1/20 에서 1/100 수준입니다. 다만 실제 recovery 는 5 월 W2 (5/5 ~ 5/11) 측정에서 확정되며, learning_fraction sweep (0.5 %, 1 %, 2 %, 5 %, 10 %) 으로 얼마만큼의 사전 학습으로 충분한가의 답을 직접 측정합니다.

Q11.4 7 가지 방법의 예상 recovery rate 순서는?

핵심 한 줄: $\text{RANDOM20} \leq C (\text{RandProj}) \leq \{A (\text{LSH}), E (\text{Hilbert}), G (\text{DistShell})\} \leq \{B (\text{KDE}), H (\text{Importance})\} \leq F (\text{MiniBatch}) \leq \text{KM20}$ 의 순서를 예상하지만, 실제 순서는 5 월 측정에서 정합됩니다.

표준 답변 (45 초)

RANDOM20 (recovery 0 %) 부터 KM20 (recovery 100 %) 사이에서 7 개 방법을 다음 순서로 예상합니다. (1) C (Random Projection 1D) 가 *최단순 하한선* 으로 10 ~ 40 %. (2) A (LSH p hyperplane) 와 E (Hilbert curve) 와 G (Distance-Shell) 가 30 ~ 60 % 의 비슷한 영역. (3) B (KDE-pilot) 와 H (Importance Sampling) 가 50 ~ 80 % 의 정교한 적응형. (4) F (Mini-batch K-means) 가 75 ~ 95 % 의 oracle 근사. 즉 단순 → 복잡, 사전 학습 없음 → 사전 학습 일부, 1D → 다차원 의 단조 구조를 예상합니다. 다만 이는 RQ3 설계안의 *prior expectation* 이며, 실제 순서는 5 월 비교 실험에서 정합됩니다 — 예상이 맞으면 본 연구의 *systematic structure* 가 입증되고, 어긋나면 *interesting finding* 이 됩니다.

Q11.5 H (Importance Sampling) 의 2x2 factorial 이 정확히 무엇인가요? 왜 다른 방법과 다르게 처리하나요?

핵심 한 줄: H 는 다른 6 방법과 달리 *hook_est* 반환 공식 (*uniform mean* → *weighted mean*) 자체를 수정하므로, 7-way 단순 비교에서 *allocation* 효과와 *estimator* 공식 효과가 confounded 됩니다. 이를 분리하기 위해 H 만 (KM20 vs no partition) × (uniform vs IS estimator) 4 조합을 모두 측정합니다.

표준 답변 (50 초)

다른 6 방법 (C / A / E / F / G / B) 은 모두 *stratum_id* 할당 방식만 다르고 *hook_est* 반환 공식 ($\text{sum}_h N_h \times \text{hit}_h / n_h$) 은 동일합니다. H 는 *stratum* 자체를 만들지 않고 각 *sample* 의 *inclusion probability* 의 역수로 가중 합니다 — 즉 *hook_est* 공식이 $\text{sum}_i 1/p_i \times \text{indicator}_i$ 로 바뀝니다. 따라서 H vs KM20 의 비교에는 *allocation* 효과 (*stratum* 분할 여부) 와 *estimator* 공식 효과 (*uniform mean* vs *IS weighted mean*) 가 섞여 있습니다. 두 효과를 분리하려면 4 조합 — (KM20 + uniform), (KM20 + IS), (no partition + uniform = bernoulli), (no partition + IS = H 본설계) — 의 2x2 factorial 측정이 필요합니다. (KM20 + IS) – (KM20 + uniform) = *estimator* 공식 효과 단독, (KM20 + IS) – (H + IS) = *allocation* 효과 단독. 이 factorial 결과는 RQ3 의 appendix 에 보고하고, 7-way 단순 비교에서는 H 를 대표 메커니즘 으로만 제시합니다.

Q11.6 RQ3 가 5 월에 7 가지 방법 모두 측정 가능한가요? 시간이 충분한가요?

핵심 한 줄: 5 월 W1 (5/4 ~ 5/11) 에 Offline Partition 4 개 (C / A / E / F), W2 (5/12 ~ 5/18) 에 Online + Weight 3 개 (G / B / H), W3 (5/19 ~ 5/27) 에 분석 + Recovery Rate 비교, W4 (5/27 ~ 6/14) 에 최종 보고서 작성. 각 방법이 *stratum_id* 할당 코드 50 ~ 100 라인이라 측정 파이프라인 재활용 으로 시간 충분.

표준 답변 (45 초)

RQ3 의 7 방법은 모두 *stratum_id* 를 어떻게 할당하느냐 만 다르고 측정 파이프라인 (multiseed_paired, D_target numpy 계산, Exqutor 로그 파싱, paired Wilcoxon) 은 RQ2 에서 완성된 것을 그대로 재활용 합니다. 각 방법마다 (1) Python 으로 *stratum_id* 계산 50 ~ 100 라인, (2) DB 에 `UPDATE table SET stratum_id = 새값` , (3) 기존 파이프라인으로 측정 의 3 단계입니다. 구현 ~ 10 일, 측정 5 days × 7 = 35 일. 4 주 (W1 ~ W4) 일정 충분. H 만 *hook_est* 공식 수정이 추가로 3 일 더 필요하지만 동시 진행 가능합니다. 본 timeline 은 [plans/RQ3설계안 20260416 213500.md](#) §VI 에 일정으로 명시되어 있습니다.

Q11.7 본 연구가 처음으로 적용 하는 방법은? 학술 기여는?

핵심 한 줄: E (Hilbert curve) 의 vector cardinality estimation 적용이 최초이며, 7 가지 distribution-agnostic 방법의 체계적 비교와 Recovery Rate 프레임워크도 본 연구의 새로운 학술 기여입니다.

표준 답변 (40 초)

학술 기여 3 갈래입니다. 첫째, 체계적 비교: 벡터 카디널리티 추정에서 distribution-agnostic 7 가지 방법의 최초 systematic 비교. 기존 연구는 단일 방법의 evaluation 만 했지 다 방법 비교는 없었습니다. 둘째, Recovery Rate 프레임워크: oracle (KM20) 대비 회수율 개념을 도입해 비용-효과를 정량 평가. 이는 다른 cardinality estimation 연구로 확장 가능한 일반 framework 입니다. 셋째, Hilbert Curve 최초 적용: 공간 DB 에서 30 년간 검증된 space-filling curve 기법을 vector cardinality estimation 에 처음 적용. 96 / 128 차원 고차원에서 Hilbert 의 locality preservation 이 어떻게 동작하는지는 positive 또는 negative 모두 학술 기여입니다.

섹터 12. Recovery Rate metric

RQ3 의 핵심 evaluation metric. 분모 붕괴 규칙이 핵심 caveat.

Q12.1 Recovery Rate 의 정확한 산출 공식은?

핵심 한 줄: $\text{Recovery Rate} = (\text{방법X} - \text{RANDOM20}) / (\text{KM20} - \text{RANDOM20})$ 으로, KM20 의 oracle 효과를 1.0 으로 두고 RANDOM20 을 0.0 으로 두었을 때 새 방법이 그 사이 어디에 위치하는지 정량화한 값입니다.

표준 답변 (40 초)

분모는 분포 인지 oracle 의 효과 ($\text{KM20} - \text{RANDOM20}$), 분자는 새 방법이 회수한 효과 ($\text{방법X} - \text{RANDOM20}$) 로, 두 값의 비율이 Recovery Rate 입니다. 1.0 이면 KM20 과 동등 (oracle 수준), 0.0 이면 RANDOM20 과 동등 (분포 인지 없음), 음수면 RANDOM20 보다 더 나쁨, 1.0 초과면 oracle 보다 더 좋음 (rare). 본 연구의 핵심 hypothesis 는 $F(\text{MiniBatch}) \approx 0.8$, $B(\text{KDE}) \approx 0.6$, $A(\text{LSH}) \approx 0.5$, $E(\text{Hilbert}) \approx 0.4$, $G(\text{Shell}) \approx 0.4$, $H(\text{Importance}) \approx 0.5$, $C(\text{RandProj}) \approx 0.2$ 의 단조 구조이며, 5 월 측정에서 검증됩니다.

Q12.2 분모 붕괴 (denominator collapse) 가 무엇이고, 왜 별도 규칙이 필요한가요?

핵심 한 줄: 일부 데이터셋·selectivity 조합에서 $|KM20 - RANDOM20|$ 의 절대값이 seed 간 표준편차보다 작아져, Recovery Rate 의 분모가 noise 안에 들어갑니다. 이 영역에서는 0/0 같은 수학적 정의 불능이 발생하므로 절대 개선폭으로 따로 보고하는 사전 규약을 두었습니다.

표준 답변 (50 초)

RQ2 실측에서 일부 셀이 $|KM20 - RANDOM20| \leq 1\%p$ 또는 seed std 이하로 측정되었습니다. 예를 들어 DEEP 1M $s=0.500$ 에서 KM20 +1.64 %, RANDOM20 +2.20 %, 격차 -0.56 %p (분모 음수). 이 영역에서 Recovery Rate 를 산출하면 -1.5 같은 비정상 값이 나오는데, 이는 새 방법의 effective performance 가 아니라 분모가 noise 인 것입니다. 그래서 본 연구는 분모 붕괴 규칙 — $|KM20 - RANDOM20| \leq 1\%p$ 또는 seed σ 이하 셀에서는 Recovery Rate 보고 X, 절대 Q-error 개선폭 (방법X - BERN) 을 primary metric 으로 사용 — 을 사전 규약 (pre-register) 했습니다. 이 규약은 측정 전 결정한 것으로, post-hoc cherry-picking 위험을 차단합니다.

Q12.3 분모 붕괴 영역이 얼마나 많은 셀에 해당하나요?

핵심 한 줄: RQ2 의 14 개 측정 셀 (3 데이터셋 × 다양한 selectivity) 중 약 4 개 셀이 분모 붕괴 영역으로 분류되며, 나머지 10 개 셀에서는 Recovery Rate 가 정상 산출됩니다.

표준 답변 (40 초)

분모 붕괴 셀 후보: (1) DEEP 1M $s=0.500$ (KM 1.64 vs RAND 2.20, 격차 -0.56 %p, 분모 음수), (2) DEEP 8M $s=0.050$ (KM 0.55 vs RAND 0.20, 격차 +0.35 %p, $< 1\%p$), (3) DEEP 8M $s=0.500$ (KM 1.76 vs RAND 1.10, 격차 0.66 %p, $< 1\%p$), (4) SIFT 1M $s=0.500$ 잠재적 corner 케이스. 이 4 개 셀에서는 절대 Q-error 개선폭 으로부터만 보고합니다. 나머지 10 개 셀 — 특히 DEEP 1M $s=0.010$ (격차 19.6 %p), SIFT $s=0.010$ (11.6 %p), DEEP 1M $s=0.300$ (2.4 %p), $s=0.100$ (2.5 %p), SIFT $s=0.500$ (2.1 %p), $s=0.050$ (4.4 %p) — 에서는 Recovery Rate 가 정상 산출됩니다. 즉 대부분의 셀에서 Recovery Rate metric 사용 가능하고, 분모 붕괴는 예외 처리입니다.

Q12.4 Recovery Rate 외에 다른 evaluation metric 도 함께 보고하나요?

핵심 한 줄: Primary 가 Recovery Rate, secondary 로 절대 Q-error 개선폭 (방법X - BERN), paired Wilcoxon p-value, cost-effect ratio (recovery / training_time) 4 가지를 함께 보고합니다.

표준 답변 (35 초)

Recovery Rate 가 상대적 oracle 회수율 이라면, 절대 Q-error 개선폭은 통계적 유의성, paired Wilcoxon p 는 통계적 신뢰도, cost-effect ratio (recovery / training_time) 는 실용적 가치 를 잡습니다. 4 metric 을 모두 보고해야 recovery 는 높지만 training cost 가 KM20 과 같음 같은 false comparison 을 방지할 수 있습니다. 특히 cost-effect ratio 는 RQ3 의 핵심 학술 기여 — 얼마만큼의 사전 학습으로 충분한가 — 의 직접 metric 입니다. F (MiniBatch) 의 learning_fraction sweep 에서 이 ratio 가 어떻게 변하는지가 본 연구의 가장 흥미로운 figure 가 될 예정입니다.

섹터 13. 구현 및 환경

서버, 빌드, 코드 변경 라인. 시스템·DB 백그라운드 청중이 좋아하는 영역.

Q13.1 실험 환경은 어떻게 구성되어 있나요?

핵심 한 줄: 연세대 BDAI Lab 서버 (165.132.140.240, capstone2026), Ubuntu Linux + PostgreSQL 16.9 + Exqutor pgvector 0.7.1 fork, Python 3.10 + psycopg3 + numpy/scipy.

표준 답변 (40 초)

서버는 연세대 BDAI Lab 의 capstone2026 계정 (165.132.140.240) 으로, 작업 디렉토리는 `/mnt/hdd0/home/capstone2026` . PostgreSQL 16.9 + Exqutor pgvector fork (`vector` extension) 가 두 인스턴스로 가동됩니다 — vanilla PG (포트 55435) 와 Exqutor PG (포트 55436). 측정 스크립트는 Python 3.10 + psycopg3 + numpy + scipy 만 사용하며 sklearn / networkx 의존성은 제거 (mini-batch k-means 도 numpy 직접 구현). 데이터셋은 vanilla PG 에서 dump 후 Exqutor PG 로 pipe 로 전송 (273 초 / 4537 MB). HNSW 인덱스는 의도적으로 제외해 sampling 경로를 강제합니다. 자세한 빌드·접속 절차는 [_internal/guideline/01_실험지침/](#) 에 정리되어 있습니다.

Q13.2 vector.c 코드 변경량은 정확히 얼마인가요?

핵심 한 줄: 핵심 코드 변경은 3 줄 (hook trigger 조건 line 243, 추출 단위 line 889, K-means 분기 추가) + 보조 228 라인 (stratum_id 사전 계산, Horvitz-Thompson estimator, GUC 설정) 입니다.

표준 답변 (45 초)

본 연구가 발표 자료에서 강조하는 "코드 세 줄 보완"은 핵심 변경 위치 3 곳입니다. (1) `vector.c` line 243 의 `if (table_count > 2)` → `if (table_count >= 1)` 로 hook trigger 조건 완화. (2) `vector.c` line 889 의 `TABLESAMPLE SYSTEM(%f)` → `TABLESAMPLE BERNOULLI(%f)` 로 추출 단위 변경. (3) `estimate_cardinality_with_stratified_sampling` 함수 추가 (228 라인) — k-means centroid 메모리 로드, stratum_id 사전 계산, Horvitz-Thompson estimator ($\text{sum_h} \times N_h \times \text{hit_h} / n_h$), GUC `vector.sampling_method` 설정. 발표에서 "세 줄"이라고 부르는 것은 직관적 표현이고, 실제 코드 변경은 보조 함수 포함 약 230 라인입니다. 학술 정확성 측면에서 발표 슬라이드 6 (vector.c snippet)에 핵심 3 변경 위치를 명시했습니다.

Q13.3 재현 가능성은 어떻게 확보되어 있나요? 다른 사람이 같은 결과를 얻을 수 있나요?

핵심 한 줄: (1) seed 고정 (k-means seed=42, sample seed 0.1 ~ 0.5), (2) raw data 보존 (60 개 parquet/json 파일), (3) 측정 스크립트 git 보존, (4) Exqutor source 변경분과 백업 파일 보존, (5) 실험 환경 docker / 명세 문서화 — 5 갈래로 재현 가능성을 확보했습니다.

표준 답변 (50 초)

5 갈래 재현 가능성 확보. 첫째, seed 고정: k-means 학습 seed = 42, sample 추출 seed = 0.1 / 0.2 / 0.3 / 0.4 / 0.5 의 5 개 고정값. 둘째, raw data 보존: `experiments/results/rq1_motivation/`에 60 개의 parquet (raw 측정값) + json (summary) 파일이 timestamp 와 함께 보존되어 있고, git 으로 추적됩니다. 셋째, 측정 스크립트 git 보존: `experiments/code/rq1/`에 `phase4_native.py` / `phase6_multiseed.py` / `random20_low_sel.py` 등 모든 스크립트가 git history 와 함께. 넷째, Exqutor source 변경 보존: `vector.c.bak.20260414_1840` (Phase 3 시작 전), `vector.c.bak.20260414_1934_before_bernoulli` (Phase 4 시작 전) 등 시점별 백업. 다섯째, 실험 환경 명세: PostgreSQL 16.9 + pgvector 0.7.1 + GUC 설정 (`sample_size=385`, `update_sample_size=off`, `sample_update_cycle=50`) 모두 문서화. 외부 검증자가 동일 결과를 얻을 수 있는 수준입니다.

Q13.4 `update_sample_size = off` 설정이 무엇이고, 왜 그게 필요한가요?

핵심 한 줄: Exqutor 의 Adaptive Sampling 이 단일 테이블 시나리오에서 SIGSEGV crash 하는 design constraint #5 의 회피 수단이며, `sample_size` 의 동적 업데이트를 비활성화해 *sampling method 자체의 효과만 분리* 측정합니다.

표준 답변 (45 초)

Exqutor 의 GUC `vector.update_sample_size` 가 default = on 일 때 Adaptive update path 가 모멘텀 기반으로 sample_size 를 동적으로 조정합니다. 그런데 단일 테이블 시나리오에서 이 update path 가 SIGSEGV crash (q3 정도에서 PG process 가 signal 11 로 종료) 하는 design constraint #5 가 발견되었습니다 (Phase 4 sanity check, 4/14). 회피 수단으로 `SET vector.update_sample_size = off` 로 sample_size 를 385 fixed 로 유지하고 estimate 만 합니다. 이 설정은 *Adaptive update* 효과를 차단하므로 본 연구가 측정하는 것은 *sampling method 자체* (system / bernoulli / stratified) 의 효과이고, Adaptive update 의 효과는 RQ3 또는 후속 연구의 영역입니다. 4 월 19 일 ultrareview 에서 이 설정이 default 로 추가되어, 향후 측정 모두 동일 환경에서 진행됩니다.

Q13.5 코드 변경이 Exqutor 의 *multi-table* 시나리오 동작을 깨지는 않나요?

핵심 한 줄: 본 연구의 모든 코드 변경은 기존 동작 경로 *옆에* 추가 되도록 짜여 있어, multi-table 시나리오에서는 기존 경로 (TABLESAMPLE SYSTEM, hook trigger > 2, default Adaptive Sampling) 가 그대로 유지됩니다.

표준 답변 (45 초)

코드 변경의 *additive design* 이 핵심입니다. (1) line 243 의 hook trigger 조건은 *완화* (≥ 1) 인데, 이는 multi-table (table_count > 2) 시나리오에서도 여전히 trigger 되므로 기존 동작에 영향 없음. (2) line 889 의 TABLESAMPLE 변경은 sampling_method GUC 로 분기되는데, default = bernoulli 이고 multi-table 시나리오에서도 동일하게 적용. (3) Stratified 분기는 GUC `sampling_method = stratified` 일 때만 활성화되고, default 는 bernoulli 라 multi-table 의 default 동작 그대로 유지. 또한 Stratified 분기 안에서도 stratum_id 컬럼이 없으면 자동으로 bernoulli fallback. 즉 *opt-in 변경* 이고, multi-table 시나리오의 동작은 아무것도 깨지지 않습니다.

섹터 14. 한계점 & Threats to Validity

학술적 정직성. 본 연구가 하지 않은 것을 명확히 인정.

Q14.1 본 연구의 가장 큰 한계는 무엇인가요?

핵심 한 줄: *End-to-end query time* 의 직접 측정이 빠진 점이 가장 큰 한계입니다. Q-error (추정 정확도) 만 측정했고, plan 변경으로 인한 실행 시간 영향은 옵티마이저 메커니즘으로 간접 추론했습니다.

표준 답변 (50 초) — 솔직한 한계 인정

가장 큰 한계는 *end-to-end query time* 미측정입니다. 본 연구는 Q-error (추정값과 실제값의 비율)의 개선만 측정했고, 그 개선이 *옵티마이저 plan 선택의 변화*와 *실행 시간 단축*으로 이어지는 메커니즘은 Exquator 원논문의 보고 (VBASE 1만 배 이상)와 옵티마이저 표준 동작에 의존해 간접 추론했습니다. 직접 측정하려면 (1) plan 변경 빈도, (2) 변경된 plan의 실행 시간 비교, (3) 다양한 워크로드 (single-query / batch / mixed)에서의 평균 영향 측정이 필요한데, 이는 RQ3 보충 또는 후속 연구의 영역입니다. 본 보고서·발표에서 이 한계를 명시하고, end-to-end 영향을 간접 추론했다는 사실을 솔직하게 인정합니다. W6 (5/12 경) 보충 분석에서 EXPLAIN ANALYZE 기반 plan 변경 빈도 측정을 시도할 예정입니다.

Q14.2 데이터셋 두 개 (DEEP, SIFT) 만 사용한 것이 일반화에 충분한가요?

핵심 한 줄: 두 데이터셋이 *대조적 분포 특성*을 가진 anchor pair라는 점에서 cross-dataset 비교의 minimal 조건은 만족하지만, 광범위한 일반화 (text embedding, audio embedding, multimodal)는 W5-W7 보충 실험과 후속 연구의 영역입니다.

표준 답변 (40 초)

Two-sample minimum의 cross-dataset 비교는 *효과의 방향성 일관성* 검증에 충분합니다. DEEP (96d, deep image feature, 균일)과 SIFT (128d, image keypoint, skewed)가 *대조적 anchor pair*로, 두 데이터셋 모두에서 KM20 효과가 양수 확정 + 더 skewed한 SIFT에서 효과가 두 배라는 일관성을 확인했습니다. 다만 광범위한 일반화 (text embedding인 BERT 768d, multimodal인 CLIP 512d, audio인 wav2vec 768d)는 W5-W7 보충 실험에 wiki 768d를 추가해 1회 더 검증할 예정이고, 본격 multi-modality 일반화는 후속 연구의 영역입니다. 본 연구의 conservative claim은 *vector embedding range query의 cardinality estimation에서 분포의 cluster skewness와 KM20 효과가 단조 관계를 갖는다*까지입니다.

Q14.3 $K = 20$ fixed가 가장 큰 design choice인데, K sensitivity 측정 안 했나요?

핵심 한 줄: phase6_layer_compare에서 $K=10$ 과 $K=20$ 비교를 했고 $K=20$ 우세를 확인했지만, K sweep (5, 10, 20, 50, 100)의 본격 측정은 W5 (5/4 경) 보충 실험에 포함됩니다.

표준 답변 (40 초)

K sensitivity 의 부분 측정은 phase6_layer_compare 에서 K=10 vs K=20 비교로 수행했고, K=20 이 selectivity 0.100 (+2.25%, p=0.0042), 0.300 (+0.76%, p=0.016), 0.500 (+0.33%, p=0.016) 모두에서 K=10 보다 우세였습니다. 다만 K=5, K=50, K=100 같은 다른 값은 W5 보충 실험에 포함되며, 본 보고서 시점에서는 *K=20 이 K=10 보다 우세*의 부분 결론까지만 보고합니다. K sensitivity 의 광범위한 sweep 은 RQ3 의 F (MiniBatch K-means) 에서도 함께 다루며, *최적 K 가 데이터셋 selectivity 에 의존* 한다면 그 자체로 흥미로운 finding 입니다.

Q14.4 Adaptive Sampling 과 직접 비교 한 head-to-head 측정이 없는데, 그게 정당한가요?

핵심 한 줄: Adaptive Sampling 의 update path 가 단일 테이블에서 SIGSEGV crash 하는 design constraint #5 로 직접 비교 측정 자체가 불가능 하며, update_sample_size=off 회피 환경에서는 sample_size 가 fixed 라 본 연구의 STRAT/BERN/SYSTEM 비교와 동일한 baseline 위에 놓입니다.

표준 답변 (50 초)

Adaptive Sampling 과 직접 head-to-head 비교는 측정 자체가 불가능합니다. update_sample_size = on 으로 Adaptive update path 를 활성화하면 단일 테이블 시나리오에서 q3 정도 (3 번째 query) 에 SIGSEGV crash 가 발생합니다 (design constraint #5). 회피 수단인 update_sample_size = off 환경에서는 sample_size 가 fixed (385) 인데, 이는 본 연구의 STRAT / BERN / SYSTEM 비교와 동일한 baseline 입니다. 즉 본 연구의 측정 환경은 *Adaptive Sampling* 의 핵심 특성 (*모멘텀 기반 동적 sample_size 조정*) 을 비활성화한 환경이고, 이 점은 보고서 §4.1 (RQ1) 에 design constraint 로 명시되어 있습니다. Adaptive 와의 fair comparison 은 (1) update path bug fix → (2) Adaptive 모멘텀 활성화 → (3) STRAT 와 paired 측정 의 3 단계가 필요하며, 이는 RQ3 또는 후속 연구의 영역입니다.

Q14.5 데이터의 INSERT/UPDATE 같은 동적 환경에서는 어떻게 동작하나요?

핵심 한 줄: 본 연구는 *static dataset* 환경의 cardinality estimation 만 다루며, 동적 데이터에서의 stratum_id 재 계산·KM20 centroid 갱신은 본 연구의 limitation 으로 명시되어 있고, RQ3 의 G (Distance-Shell) 와 B (KDE-pilot) 가 *online query-adaptive* 패러다임으로 동적 환경 대응을 시도합니다.

표준 답변 (40 초)

본 연구의 KM20 은 데이터 적재 시 1 회 학습 후 *stratum_id* 컬럼 사전 계산 의 offline 방식이라, INSERT 가 빈번하면 새 행의 *stratum_id* 할당 ($O(d \times K)$ 의 nearest centroid lookup) 과 centroid 의 stale 처리 가 필요합니다. RQ3 의 G (Distance-Shell) 는 쿼리 시점에 동심원 분할을 하므로 INSERT 에 자동 대응하고, B (KDE-pilot) 도 pilot sample 을 매 쿼리마다 새로 뽑으므로 동적 환경 친화적입니다. RQ3 의 F (MiniBatch K-means) 는 1 ~ 5 % learning fraction 으로 incremental update 가 가능합니다. 즉 RQ3 가 동적 환경 대응 을 직접 다루는 영역이며, 본 보고서 시점의 KM20 은 static baseline 으로 한정됩니다.

Q14.6 5-seed 로 충분한가요? 더 많은 seed 가 필요하지 않나요?

핵심 한 줄: 5-seed 의 t-based CI 가 핵심 anchor (DEEP 1M $s=0.500$, SIFT $s=0.500$) 에서 양수 확정 + CI 분리 + per-seed $p < 1e-5 \sim 1e-8$ 로 robust 하지만, 본격 검정력 (10-seed $\times$ 500-쿼리 + BH-FDR + Cohen's d) 은 W6 보충 분석에 포함됩니다.

표준 답변 (35 초)

5-seed 의 방향성 robust 는 CI 양수 확정 + per-seed sign 분리 + per-seed $p < 1e-5 \sim 1e-8$ 로 확인되었습니다. 다만 small effect 영역 ($s=0.05$ 같은) 에서는 CI 가 0 을 포함하는 셀이 있어 검정력 부족 가능성. 본격 검정력 측정은 W6 (5/12 경) 의 10-seed $\times$ 500-쿼리 = 5000 paired 단위로 확보 예정이며, 이는 small effect (Cohen's $d \approx 0.2$) 도 power 0.8 로 잡을 수 있는 sample size 입니다. 본 보고서 시점은 medium effect 이상의 robust 검증 으로 conservative 하게 한정됩니다.

섹터 15. 차별성 & 비교 (Comparison)

학습 기반 카디널리티 estimator 와의 비교, VBASE/pgvector/DuckDB 직접 비교가 안 된 이유.

Q15.1 학습 기반 카디널리티 estimator (LearnedCard, MSCN, NeuroCard) 와는 비교 안 했나요?

핵심 한 줄: 학습 기반 estimator 는 일반 SQL 술어에는 좋은 결과를 내지만 벡터 거리 조건 에 직접 적용된 사례가 적고, 본 연구는 Exqutor 의 sampling-based 접근 의 단일 테이블 사각지대를 메우는 데 집중했으며, 학습 기반 비교는 후속 연구의 영역입니다.

표준 답변 (50 초)

LearnedCard (Kipf et al. 2019), MSCN (Multi-Set Convolutional Network), NeuroCard 같은 학습 기반 estimator 는 일반 SQL 술어 (range, equality, join) 에는 좋은 결과를 보고합니다. 그러나 벡터 거리 조건처럼 96 ~ 1024 차원의 비선형 술어에 직접 적용된 사례는 적고, 학습 데이터 (query workload) 의존성이 크다는 caveat 가 있습니다. 본 연구는 *Exqutor (sampling-based) 의 단일 테이블 사각지대* 를 메우는데 집중했고, 두 패러다임 (sampling-based vs learning-based) 의 직접 비교는 후속 연구의 영역입니다. 본 연구의 RQ3 가 distribution-agnostic sampling 의 7 가지 방법 비교를 마치면, 그 결과를 anchor 로 학습 기반과의 fair comparison framework 를 설계할 수 있습니다.

Q15.2 VBASE / pgvector / DuckDB 와 head-to-head 비교가 보고서에 없는데, 왜 안 했나요?

핵심 한 줄: 본 연구는 *Exqutor 코드 자체를 수정하는 형태* 로, 다른 시스템과 직접 비교하려면 (1) 각 시스템에 동일한 코드 수정 적용 또는 (2) baseline 카디널리티 추정 방식의 fair comparison framework 가 필요한데, 둘 다 본 연구 범위 밖입니다.

표준 답변 (50 초)

두 갈래 이유입니다. 첫째, *기술적 측면*: 본 연구의 코드 수정은 Exqutor 의 vector extension 위에서 이루어지고, VBASE / pgvector vanilla / DuckDB 는 각각 다른 카디널리티 추정 메커니즘 (고정 비율 50 % / 33.3 % / 100 %) 을 갖습니다. 같은 stratified sampling 을 다른 시스템에 직접 이식하려면 각 시스템의 인덱스-plan optimizer 코드 수정이 별도로 필요합니다. 둘째, *학술적 측면*: 본 연구의 baseline 은 *Exqutor 의 BERNOULLI sampling* 이고, 그 위에 KM20 stratification 을 추가했을 때의 효과를 측정합니다. VBASE 의 fixed 50 % vs Exqutor 의 BERNOULLI vs Exqutor + KM20 같은 multi-system 비교는 *어느 baseline 이 fair 한가* 의 framework 자체가 별도 연구입니다. Exqutor 원논문의 1 만 배 이상 격차 보고가 *시스템 간 비교의 anchor* 가 되며, 본 연구는 *Exqutor baseline 위에 추가 개선* 의 정량화로 한정됩니다.

Q15.3 그래도 간접적인 비교 수치는 있나요?

핵심 한 줄: Exqutor 원논문의 보고 — pgvector 33.3 % / VBASE 50 % / DuckDB 100 % 고정 비율 vs Exqutor ECQO + Adaptive — 가 system-level baseline 비교의 anchor 이고, 본 연구의 KM20 은 그 위에 추가된 *Exqutor 단일 테이블 시나리오* 보완입니다.

표준 답변 (40 초)

Exqutor 원논문 Table 1 의 보고: pgvector 의 카디널리티 추정 정확도 (Q-error mean) 는 시나리오에 따라 100 ~ 10000 배, VBASE 는 50 ~ 5000 배, DuckDB 는 항상 100 % 추정으로 1 ~ 1000 배의 Q-error. Exqutor 의 ECQO 는 인덱스가 있을 때 Q-error ≈ 1 (정확값) 로 근접하고, Adaptive Sampling 은 multi-table 에서 Q-error 1 ~ 3 수준. 본 연구의 KM20 은 *Exqutor Adaptive* 의 단일 테이블 사각지대 보완으로, BERNOULLI baseline 의 Q-error 1.04 ~ 8.93 영역에서 stratification 으로 1 ~ 9 % 추가 개선. 즉 본 연구의 위치는 시스템 비교의 새 차원이 아니라 Exqutor 위의 layered 보완입니다.

Q15.4 본 연구가 기존 stratified sampling 연구와 어떻게 다른가요?

핵심 한 줄: Survey sampling 과 SQL 카디널리티 추정에서 stratified sampling 은 표준이지만, 벡터 거리 조건에 적용된 사례는 매우 적고, 분포 인지 (KM20) vs 무인지 (RANDOM20) 의 직교 분리 측정도 본 연구의 새로운 framework 입니다.

표준 답변 (45 초)

Stratified sampling 자체는 Cochran (1977) 이래 survey sampling 의 표준이고, SQL 카디널리티 추정에서도 stratified histogram (Poosala et al. 1996) 같은 형태로 적용됩니다. 그러나 벡터 거리 조건의 카디널리티 추정 에 stratified sampling 을 적용한 사례는 매우 적습니다. 본 연구의 새로움 은 (1) k-means K=20 의 거리 기반 분할을 stratum 으로 직접 사용, (2) RANDOM20 control 로 Level 1 (proportional allocation) 과 Level 2 (spatial awareness) 의 직교 분리, (3) cross-dataset 의 cluster skewness 와 효과 격차의 단조 관계 입증입니다. 이 framework 가 RQ3 의 distribution-agnostic 방법 비교의 evaluation metric (Recovery Rate) 의 기초가 되며, 다른 cardinality estimation 연구로 확장 가능합니다.

Q15.5 Histogram-based estimator (PostgreSQL ANALYZE, multi-column histograms) 와 비교는?

핵심 한 줄: PostgreSQL ANALYZE 의 histogram 은 single-column 의 equality / range 술어에 최적화되어 있고, 96 ~ 128 차원 벡터의 거리 기반 술어에는 직접 적용되지 않습니다. Multi-dimensional histogram 은 차원의 저주로 1M+ 데이터에 비현실적입니다.

표준 답변 (40 초)

PostgreSQL ANALYZE 가 만드는 histogram 은 single-column 의 equi-depth 또는 equi-width buckets 으로, equality / range 술어에는 좋은 정확도를 냅니다. 그러나 vector 거리 조건 `WHERE (v <-> q) < D` 는 96 차원의 모든 차원의 비선형 함수 라 single-column histogram 으로 표현 불가능합니다. Multi-dimensional histogram 은 K^d 셀로 차원의 저주가 일어나 96d 에서는 비현실적이고, 차원 축소 후 histogram 은 RQ3 의 C (Random Projection) 또는 E (Hilbert curve) 와 본질적으로 같은 형태가 됩니다. 즉 traditional histogram 은 vector cardinality estimation 에 직접 적용할 수 없고, *sampling-based* (Exquitor) 또는 *learned* (LearnedCard) 두 패러다임이 주류가 됩니다.

섹터 16. 일반화 가능성 (Generalizability)

다른 임베딩, 다른 거리 metric, 다른 인덱스, 다른 DB 로의 확장 가능성.

Q16.1 다른 임베딩 모델 (BERT, CLIP, ResNet) 에서도 KM20 효과가 있을까요?

핵심 한 줄: KM20 의 효과는 데이터의 *cluster skewness* 에 의존하는데, 임베딩 모델별로 representation 의 isotropic 정도가 다르므로 효과 크기는 변동 가능합니다. SIFT 와 DEEP 의 격차 (CV 0.394 vs 0.234) 가 그 변동의 *one example* 입니다.

표준 답변 (45 초)

본 연구의 *underlying mechanism* 은 cluster skewness $\rightarrow$ spatial awareness 효과 의 단조 관계입니다. 임베딩 모델이 어떻든 그 모델의 representation 이 isotropic 인가 가 핵심이고, 이는 모델 학습 방식 (contrastive loss, cross-entropy, supervised) 에 따라 다릅니다. ResNet feature 는 일반적으로 isotropic 에 가깝고 (DEEP 와 비슷한 CV 0.2 ~ 0.3), CLIP 은 contrastive 학습으로 anisotropic 한 경향 (CV 0.4 ~ 0.6 추정), BERT 는 sentence embedding 의 *anisotropic problem* 으로 알려져 있어 (Ethayarajh 2019) 더 큰 cluster skewness 가능. 따라서 KM20 효과는 모델별로 변동 하지만 방향은 일관 (skewed $\rightarrow$ 큰 효과) 할 것이라는 hypothesis 가 본 연구의 자연스러운 generalization 입니다. wiki 768d (text embedding) 측정이 W5-W7 에 포함되어 이 hypothesis 의 1 차 검증을 시도합니다.

Q16.2 다른 거리/ metric (cosine, inner product) 에서도 KM20 동작하나요?

핵심 한 줄: 본 연구는 L2 (Euclidean) 거리 기반 range query 만 측정했고, cosine / inner product 도 같은 cluster skewness 메커니즘이 적용될 것으로 예상하지만, 실측 검증은 후속 연구의 영역입니다.

표준 답변 (40 초)

본 연구의 측정은 L2 거리 기반 `WHERE (v <-> q) < D` 의 range query 입니다. Cosine 거리는 unit vector 정규화 후 L2 와 수학적으로 동등하므로 같은 메커니즘이 적용될 것으로 예상하고, inner product 는 vector norm 분포에 의존하므로 추가 보정이 필요할 수 있습니다. k-means clustering 은 L2 기반이라 cosine / IP 데이터에서 직접 사용하려면 (1) cosine 의 경우 unit normalization 후 사용, (2) IP 의 경우 추가 보정 후 또는 다른 분할 알고리즘 사용. 후속 연구에서 *metric-agnostic stratification* 의 framework 로 확장 가능합니다.

Q16.3 HNSW 인덱스가 있을 때는 어떻게 동작하나요? Exqutor 의 ECQO 와 충돌하지 않나요?

핵심 한 줄: 본 연구는 의도적으로 HNSW 인덱스를 제외 한 환경에서 측정했습니다 — sampling 경로를 강제하기 위함입니다. 인덱스가 있을 때는 Exqutor ECQO 가 정확값 (Q-error ≈ 1) 을 주므로 stratified sampling 의 추가 효과가 미미할 것으로 예상합니다.

표준 답변 (40 초)

본 연구의 측정 환경은 HNSW 인덱스 없는 단일 테이블 입니다. 인덱스가 있으면 ECQO 가 plan 단계에서 정확한 카디널리티 (Q-error ≈ 1) 를 주므로 stratified sampling 의 layered 보완은 불필요 합니다. 본 연구의 가치는 인덱스가 없거나 stale 한 환경에서 발견되며, 이는 (a) 데이터 적재 직후, (b) 동적 INSERT 가 빈번한 환경, (c) 인덱스 빌드 비용을 감당하기 어려운 시나리오에 해당합니다. 즉 ECQO (인덱스 있을 때) + Stratified Sampling (인덱스 없을 때) 의 2 layer fallback 구조가 본 연구의 자연스러운 positioning 이며, 두 mechanism 은 서로 충돌하지 않고 보완적입니다.

Q16.4 다른 벡터 DB (Milvus, Pinecone, Weaviate) 에 적용 가능한가요?

핵심 한 줄: 본 연구의 KM20 stratified sampling 은 PostgreSQL extension 위에 구현되었지만, underlying mechanism (Horvitz-Thompson estimator on k-means strata) 은 system-agnostic 이며, 다른 벡터 DB 에 이식 가능합니다. 다만 각 DB 의 sampling API 와 plan optimizer 통합은 별도 구현이 필요합니다.

표준 답변 (40 초)

본 연구의 mechanism — k-means 분할 + 비례 배분 + Horvitz-Thompson estimator — 는 system-agnostic 입니다. Milvus 는 IVF 인덱스를 internal partition 으로 사용하므로 IVF 의 cluster 를 stratum 으로 재해석하면 자연스러운 적용이 가능하고, Pinecone 의 namespace 도 비슷한 partition 으로 이용 가능합니다. Weaviate 는 HNSW 만 지원하므로 stratified sampling 의 적용 범위가 *인덱스 없는 fallback path* 로 한정됩니다. 즉 *각 시스템의 sampling API 와 plan optimizer 통합* 은 별도 엔지니어링이지만, mechanism 자체의 일반화는 가능합니다. 후속 연구로 *multi-system stratification framework* 가 자연스러운 확장입니다.

Q16.5 고차원 (1024 차원, 4096 차원) 에서도 동작하나요?

핵심 한 줄: k-means 의 차원 효과로 학습 안정성이 떨어지지만, mini-batch k-means 의 결정론적 학습 + 768d wiki 보충 실험에서 일관된 효과가 확인되면 high-dimensional generalization 의 1 차 evidence 가 됩니다.

표준 답변 (40 초)

k-means 는 *차원의 저주* 로 고차원에서 cluster 경계가 흐려지지만, mini-batch k-means + n_iter=100 의 결정론적 학습은 96 / 128 차원에서 안정적입니다. 768 차원 wiki 데이터셋이 W5-W7 보충 실험에 포함되며, 768d 에서도 KM20 효과가 양수 + cluster skewness 와 단조 관계 라면 *high-dimensional generalization* 의 1 차 증거가 됩니다. 1024 차원, 4096 차원 같은 더 높은 차원은 후속 연구의 영역이며, 이때는 *차원 축소 후 stratification* (RQ3 의 C — Random Projection 의 변형) 이 더 자연스러울 수 있습니다.

섹터 17. 향후 계획 (Future Plan)

5월-6월 timeline. 보충 실험 5건 + 본격 검정력 + RQ3 7-way + 최종 보고서·전시회.

Q17.1 5 월에 정확히 무엇을 하실 건가요?

핵심 한 줄: W5 (5/4-5/11) 에 보충 실험 5 건 + W6 (5/12-5/18) 에 본격 검정력 측정 (10-seed × 500 query + BH-FDR + TOST + Cohen's d) + W7 (5/19-5/27) 에 RQ3 7-way 비교 측정.

표준 답변 (50 초)

5 월의 timeline 은 3 주차로 구성됩니다. **W5 (5/4 ~ 5/11): 보충 실험 5 건** — (1) per-stratum BERN 최적화, (2) Layer K sweep ($K=5, 10, 20, 50, 100$), (3) wiki 768d cross-dataset, (4) SIFT mid-selectivity ($s=0.100, 0.300$), (5) sample_size sensitivity (385, 770, 1540). **W6 (5/12 ~ 5/18): 본격 검정력 측정** — 10-seed $\times$ 500-쿼리 = 5000 paired 단위로 small effect 까지 잡을 수 있는 sample size, BH-FDR multiple comparison + TOST equivalence test + Cohen's d effect size 의 출판급 통계 보강. **W7 (5/19 ~ 5/27): RQ3 7-way 비교** — Offline 4 (C/A/E/F) + Online 2 (G/B) + Weight-based 1 (H) + H 의 2×2 factorial = 8 개 측정 + Recovery Rate 분석.

Q17.2 최종 보고서와 최종 발표 일정은?

핵심 한 줄: 최종 발표 5/27 ~ 5/29 (전시회 6/5), 최종 보고서 6/11 마감.

표준 답변 (30 초)

5 월 27 ~ 29 일 최종 발표 (3 일에 걸쳐 모든 팀 발표), 6 월 5 일 전시회 (작품 demo), 6 월 11 일 최종 보고서 PDF 마감 (LearnUs 업로드). 본 연구의 RQ3 비교 실험 결과 (W7 의 7-way + H factorial) 가 최종 발표·전시회·보고서 모두에 통합 포함되며, 발표는 본 중간 발표 형식 + RQ3 결과 + 추가 figure 로 확장됩니다.

Q17.3 본 연구를 학술지에 투고할 계획은?

핵심 한 줄: 학부 캡스톤이 1 차 목표이지만, 본 연구의 체계적 비교 framework + 자체 정직성 사례 (Phase 7 artifact) 가 후속 논문 (학생 first-author with 박광현 교수 co-author) 의 가능성을 열어둡니다.

표준 답변 (40 초)

학부 캡스톤 졸업이 1 차 목표라 6 월 11 일 최종 보고서 마감까지 학술지 투고는 timeline 밖입니다. 다만 본 연구의 체계적 distribution-agnostic 비교 framework + Recovery Rate metric + Phase 7 자체 정직성 사례 가 후속 논문 (학생 first-author with 박광현 교수 co-author) 의 가치를 가질 수 있습니다. 후보 venue 로는 SIGMOD / VLDB demo track 또는 short paper, ICDE poster, 학부 학술 발표회 등을 검토 중입니다. 졸업 후 진로에 따라 박성원 멘토 (Exqutor 저자 contact 가능) 와 협력해 후속 연구로 발전시킬 가능성이 있습니다.

Q17.4 전시회 demo 는 어떻게 구성할 예정인가요?

핵심 한 줄: 본 연구의 RQ3 비교 결과를 시각적으로 보여주는 *interactive Recovery Rate visualization* 과 *cluster skewness vs effect* 단조 관계 demo 가 candidate 입니다.

표준 답변 (40 초)

전시회 demo 의 후보는 두 갈래입니다. 첫째, *interactive Recovery Rate visualization*: 7 가지 distribution-agnostic 방법의 Recovery Rate 를 selectivity / dataset / K 에 따라 사용자가 인터랙티브 하게 탐색하는 web demo (Plotly Dash 또는 D3.js). 둘째, *cluster skewness vs effect* 단조 관계 demo: 사용자가 임의의 데이터셋을 업로드하면 CV 와 KM20 효과를 자동 계산해 본 연구의 *underlying mechanism* 을 직접 검증할 수 있는 demo. 본 연구의 *체계성과 정직성* 을 강조하는 형태로 5 월 W3-W4 에 구현 예정이며, *학생 friendly* 한 visualization 을 목표로 합니다.

Q17.5 본 연구가 Exqutor 본가에 contribute 될 가능성은?

핵심 한 줄: 박성원 멘토를 통해 Exqutor 저자에게 본 연구의 finding (단일 테이블 사각지대 + 5 가지 design constraint) 을 공유할 계획이며, KM20 stratification 의 contribute 가능성은 저자와의 합의에 달려 있습니다.

표준 답변 (40 초)

본 연구의 핵심 finding — 단일 테이블 사각지대와 5 가지 design constraint — 는 Exqutor 저자에게 가치 있는 정보입니다. 박성원 멘토 (1 차 자문위원) 가 Exqutor 저자와 contact 가능하며, 최종 보고서 (6 월) 단계에서 finding 공유와 contribute 가능성을 논의할 계획입니다. KM20 stratification 자체의 contribute 는 저자의 design intent (multi-table only) 와 conflict 할 수 있으므로, *opt-in* 추가 mode 형태로 PR 을 제안할 수 있습니다. 이는 본 연구의 *협력적 확장* positioning 과 일치합니다.

섹터 18. 발표 자체에 대한 질문 (Presentation Logistics)

발표 시간, 슬라이드 가독성, Q&A 분담, 결석 시 대비, 청중 만나기 직전.

Q18.1 발표 10 분 안에 모든 내용을 다 다룰 수 있나요?

핵심 한 줄: 17 슬라이드 × 10 분 = 슬라이드당 약 35 초 ~ 1 분, 표준 발표 동선 (문제 → 빈자리 → 해법 → 측정 → 인과 → 다음 단계) 으로 시간 분배가 안정적입니다.

표준 답변 (35 초)

슬라이드별 시간 분배는 [submission/ drafts/속도는벡터 중간발표 스크립트 20260427 200000.md](#) 에 secondage 로 정리되어 있습니다. S03 (50초), S04 (50초), S05 (60초), S06 (50초), S07 (50초), S08 (75초), S09 (75초), S10 (40초), S11 (75초), S12 (60초), S13 (50초), S14 (40초), S15 (20초), S16 (40초). 합계 약 600 초 = 10 분. S01 표지 (10 초) + S02 목차 (15 초) + S17 감사 (5 초) 포함. 리허설로 시간 압박 시 S10 (외적 타당성) 이나 S11 (인과 관계) 에서 압축 가능합니다.

Q18.2 발표 중 발표자 (강재현) 가 모르는 질문 이 들어오면 어떻게 처리하나요?

핵심 한 줄: 발표자 (강재현) 가 사회를 보면서 질문 영역에 따라 답변자를 지목합니다 — 코드·구현·서버는 조현빈, 분석·작도·RQ3 는 이동욱, 자문·일정·범위는 박세은, 이론·통계·실험 결과는 강재현 본인 + 조현빈 보강.

표준 답변 (40 초)

Q&A 분담 합의 (4 월 27 일 회의) 에 따라 발표자 (강재현) 는 *사회자 모드* 로 질문을 받고, 영역에 따라 답변자를 지목합니다. (1) 이론·통계·실험 결과 → 강재현 (1 차) ↔ 조현빈 (보강), (2) 코드·구현·서버 → 조현빈, (3) 분석·작도·RQ3 설계 → 이동욱, (4) 자문·일정·범위 결정 → 박세은. 강재현이 즉답 가능하면 직접 답변, 아니면 "이 부분은 [팀원] 이 자세합니다" 로 자연스럽게 넘김. 4 명이 한 팀이라는 메시지 + 답변의 정확성 둘 다 확보되는 형태입니다.

Q18.3 진짜로 모르는 질문이 들어오면?

핵심 한 줄: cheat sheet 의 4 가지 안전 답변 중 가장 적합한 것을 선택 — (1) "RQ3 또는 W5-W6 에서 측정 예정", (2) "본 연구 범위 밖, 후속 연구", (3) "원논문 정의 그대로 따랐고 우리 측정 시점 검증분만 보고", (4) "발표 후 메일/노션으로 정리 송부" — 자신감 있게 답변.

표준 답변 (45 초)

4 가지 안전 답변이 cheat sheet §0.5 에 등록되어 있고, 발표자가 이를 자연스럽게 활용합니다. (1) 측정 안 한 부분은 "이 부분은 RQ3 (5 월) 또는 W5-W6 (보충 실험) 에서 측정 예정이며, 현 보고서 시점에서는 설계만 보고했습니다." (2) 범위 밖은 "좋은 지적이십니다. 본 연구가 다루지 못한 영역으로, 후속 연구 또는 향후 계획에서 확인하고자 합니다." (3) 외부 인용은 "원논문 (Exqutor) 의 정의를 그대로 따랐으며, 우리 측정 시점에서 검증한 부분만 보고했습니다." (4) 정말 모를 때는 "즉답하기 어려운 질문입니다. 발표 후 메일·노션으로 구체 수치를 정리해 드리겠습니다." 4 번은 한 번까지만 사용하고, 자신감 있는 톤 유지가 중요합니다.

Q18.4 결석 시 0 점 이라는데, 발표자 (강재현) 가 발표 당일 못 오면?

핵심 한 줄: 4/30 (목) 19:00 인종 A428 발표 일정 확정. 발표자 결석 위험 대비책으로 (1) 박세은 팀장이 백업 발표자 역할을 가능하면 사전 리허설 (4/24 / 4/26), (2) 발표 자료의 모든 내용을 4 명이 공유 + 스크립트 docx 보존.

표준 답변 (35 초)

발표 결석은 0 점 (4/30 사전 불참 예외) 이라 발표자 (강재현) 결석 위험 대비가 중요합니다. 박세은 팀장이 백업 발표자 역할을 사전 리허설 (4/24 1 차 + 4/26 2 차) 에서 함께 연습하고, 발표 자료와 스크립트는 모든 팀원이 공유 ([submission/_drafts/](#)). 발표 당일 강재현 컨디션 확인은 박세은 팀장이 책임. 만약 강재현 결석 시 박세은이 즉시 발표 모드 전환 가능하도록 cheat sheet 도 4 명 모두 숙지합니다.

Q18.5 발표 후 질문 시 가산점 이라는데, 우리 팀이 다른 팀에 질문할 계획은?

핵심 한 줄: 발표 분반의 다른 5 팀 (디이전트, 잉치킨, Alscreeam, B3HIND, ULTRON) 의 발표를 듣고 방법론·범위·재현 가능성 측면에서 1 ~ 2 개 질문을 사전 준비합니다.

표준 답변 (35 초)

4/30 인종 A428 분반의 다른 5 팀 (디이전트, 잉치킨, Alscreeam, B3HIND, ULTRON) 의 발표 주제를 사전에 공지에서 확인하고, 각 팀별로 1 개씩 질문을 준비합니다. 질문 영역 후보: (1) 방법론적 정당성 — "왜 그 방법을 골랐나요?", (2) 측정 범위 — "다른 baseline 비교는?", (3) 재현 가능성 — "코드·데이터 공개 계획은?". 본인 신원 (조현빈 / 박세은 / 강재현 / 이동욱 중 한 명) 을 먼저 밝히고 질문하면 가산점이 누적됩니다. 우리 팀의 발표 시간 (S00 부근) 직후 자연스럽게 다음 팀 질문 준비.

섹터 19. 팀 운영 & 합의 과정

4 명의 역할 분배, 합의 과정, 어려움. 자문 회신 활용.

Q19.1 4 명이 어떻게 역할을 나눴나요? 그 분배는 어떻게 합의했나요?

핵심 한 줄: 박세은 (팀장) — 일정·자문·합의 주재, 강재현 (주 발표자) — 슬라이드·리허설·Q&A, 조현빈 — 실험·코드·문서, 이동욱 — 통계·작도·RQ3 설계. 강점 기반 자연 분배 + 4 명 합의 (3 월 4 일).

표준 답변 (40 초)

역할 분배는 강점 기반 자연 분배 + 4 명 합의로 결정되었습니다. 박세은 팀장은 *대인 커뮤니케이션·합의 주재* 강점으로 일정·자문 책임. 강재현은 *발표 톤·리허설* 강점으로 주 발표자. 조현빈은 *시스템·코드 디버깅·문서화* 강점으로 실험 구현 + 보고서 작성. 이동욱은 *통계 분석·시각화·RQ3 설계* 강점으로 작도 + RQ3 framework. 3 월 4 일 팀장 결정 회의 ([records/kakaotalk/20260304_팀장결정 운영논의.md](#)) 에서 1 차 합의, 이후 작업이 진행되며 강점이 명확해지면서 자연 안정. 4 명이 *상호 보완* 하는 분배입니다.

Q19.2 본 연구를 진행하면서 가장 어려웠던 점은?

핵심 한 줄: (1) Phase 7 plan_rows artifact 자체 발견·철회·redo 의 학술 정직성 challenge, (2) 단일 테이블 사각지대 발견 후 multi-table only design intent 의 5 가지 design constraint 우회 디버깅 — 두 가지가 가장 큰 challenge 였습니다.

표준 답변 (50 초)

두 갈래 challenge 가 있었습니다. 첫째, *Phase 7 artifact 자체 발견* (4/15) — 8M 에서 ratio 2168× 의 비정상적 결과를 보고 이를 의심하지 않고 *외적 타당성 anchor* 로 쓸 뻔했습니다. 자체 검증으로 plan_rows = 20 LIMIT 상수 artifact 를 발견하고 철회 + redo 한 과정이 학술 정직성의 challenge 였습니다. 둘째, *5 가지 design constraint 디버깅* — 단일 테이블 사각지대 발견 후 hook 을 강제로 켜자 (a) plan replacement 부작용, (b) sample 안 부분 카운트 격하, (c) q-error inf 발산, (d) sample_size NaN 발산, (e) Adaptive update SIGSEGV 가 연쇄 발현. 5 가지를 하나씩 분리해 finding 으로 정리하는 데 약 일주일 소요. 이 두 challenge 가 본 연구의 *깊이* 를 결정했고, 학술적으로도 가장 강한 evidence 가 됩니다.

Q19.3 자문 회신은 어떻게 활용했나요?

핵심 한 줄: 자문 회신 ("단일 테이블 시나리오로 좁힌 점과 두 보안을 직교적으로 분리해서 랜 설계가 적절하다")을 받고 본 연구의 *positioning* 과 *measurement framework* 의 정당성을 확보, 4 월 19 일 ultrareview 의 narrative 강화에 직접 반영했습니다.

표준 답변 (40 초)

자문 회신은 4 월 15 일 v3 자문 이메일 (박성원 멘토 발송) 에 대한 회신으로, 두 가지 핵심 포인트 — (1) *단일 테이블 시나리오로 좁힌 점*, (2) *두 보안을 직교적으로 분리해서 랜 설계* — 가 적절하다는 평가를 받았습니다. 이를 4 월 19 일 ultrareview 의 narrative 강화에 직접 반영했습니다. 보고서 §1.3 (본 연구의 질문) 과 §3.1 (차별성) 이 자문 회신의 두 포인트를 anchor 로 작성되었고, RQ2-1 / RQ2-2 의 *직교적 측정 framing* 이 자문 평가를 그대로 반영. 자문 위원의 평가가 *외부 검증의 1 차 evidence* 이 되어 reviewer 신뢰도를 높이는 역할입니다.

Q19.4 4 명 간 의견 충돌은 어떻게 해결했나요?

핵심 한 줄: 박세은 팀장이 합의 주재, 큰 결정 (RQ 정의, 발표 디자인, 작업 분담) 은 4 명 합의, 세부 구현·파라미터는 조현빈 권한, 통계·작도는 이동욱 권한. 명시적 권한 위임으로 *일상 의사결정의 마찰* 을 최소화.

표준 답변 (40 초)

4 명 합의를 매번 거치면 의사결정 cost 가 크므로 *권한 위임 framework* 을 사용합니다. 큰 결정 (RQ 정의, 발표 디자인 톤, 작업 분담) 은 4 명 합의 — 카톡·디스코드 회의로 명시적 결정. 세부 구현·파라미터 (sample_size, K, seed, 측정 스크립트) 는 조현빈 권한, 통계·작도·RQ3 설계는 이동욱 권한, 자문·일정·외부 contact 는 박세은 권한, 발표 톤·리허설은 강재현 권한. 의견 충돌이 *권한 영역 안* 이면 권한자 결정, *권한 영역을 넘어가는* 충돌은 박세은이 합의 주재. 본 framework 으로 4 월 한 달간 *큰 의견 충돌 없이* 진행했습니다.

Q19.5 지도교수님 (박광현) 과의 mentorship 은 어떻게 활용했나요?

핵심 한 줄: 박광현 교수님은 4 월 3 일 첫 미팅에서 본 연구의 *Skew-Aware Sampling* 방향 framing 을 제시하시고, 이후 RQ 정의·실험 결과 review 는 임채림 석사 (지도 연구원) 가 직접 mentor 합니다.

표준 답변 (40 초)

박광현 교수님은 BDAI 연구실 의 PI 로, 4 월 3 일 첫 미팅에서 본 연구의 *Skew-Aware Sampling* framing — "데이터의 쏠림 → uniform sampling 성능 저하 → 공간 인식 sampling 으로 해결" — 을 제시하셨습니다. 이 framing 이 본 연구의 narrative 의 backbone 이 되었고, RQ1 / RQ2 / RQ3 의 3 단 구조도 이 framing 의 자연스러운 specialization 입니다. 일상 mentorship 은 임채림 석사 (지도 연구원) 가 담당하며, 실험 결과 review 와 자문 이메일 작성 등 직접적 지도를 받습니다. 박성원 멘토 (1 차 자문위원) 는 Exqutor 저자 contact 가능한 외부 mentor 로, 4 월 15 일 v3 자문 이메일 회신을 통해 본 연구의 positioning 정당성을 확인했습니다.

섹터 20. 메타 (논문화·학술 가치·기여 정도)

학술적 의미. 이 연구가 어디까지 학술적으로 의미가 있는가.

Q20.1 본 연구의 학술적 기여를 한 문장으로 요약하면?

핵심 한 줄: *Exqutor* 의 *multi-table only Adaptive Sampling design intent* 가 비워 둔 단일 테이블 사각지대를 코드 세 줄 보완으로 메우고, 그 보완의 효과가 분포의 *cluster skewness* 와 단조 관계임을 *cross-dataset* 으로 직접 입증한 점이 본 연구의 학술적 기여입니다.

표준 답변 (45 초)

한 문장 요약: *Exqutor* 의 *multi-table only Adaptive Sampling design intent* 가 비워 둔 단일 테이블 사각지대를 코드 세 줄 보완 (*hook trigger* 완화 + 추출 단위 *BERNOULLI* + *KM20 stratified* 분기 추가) 으로 메우고, 그 보완의 효과 (*Q-error* 중앙값 9.6 % 개선 + 1.6 ~ 4.4 % 추가 개선) 가 분포의 *cluster skewness* 와 단조 관계임을 *RANDOM20 control* 의 직교 분리 측정과 *SIFT vs DEEP cross-dataset* 비교로 직접 입증한 점. 핵심은 (1) *negative finding* (사각지대 발견), (2) *layered* 보완의 직교 측정, (3) 인과 관계 입증의 3 갈래입니다.

Q20.2 본 연구가 어디에 발표될 가치가 있나요?

핵심 한 줄: 학부 캡스톤 발표가 1 차이지만, 본 연구의 framework 는 SIGMOD / VLDB short paper 또는 demo track, ICDE poster 의 가치를 가질 수 있습니다.

표준 답변 (40 초)

1 차 venue 는 학부 캡스톤 발표 (4/30) + 전시회 (6/5) + 최종 보고서 (6/11). 외부 venue 후보로는 (1) SIGMOD / VLDB short paper (4 ~ 6 페이지) — 본 연구의 distribution-aware framework + Recovery Rate metric 이 short paper 가치, (2) SIGMOD demo track — interactive Recovery Rate visualization 이 demo 가치, (3) ICDE poster — 학생 friendly 한 outlet, (4) 학부 학술 발표회 — 1 차 외부 노출. 졸업 후 진로에 따라 후속 연구로 발전시키면 full paper venue (SIGMOD / VLDB / ICDE main track) 도 가능. 본 연구의 체계성과 정직성 이 학술적 가치를 뒷받침합니다.

Q20.3 본 연구가 기존 연구와 어떻게 다른가의 30 초 elevator pitch?

핵심 한 줄: "기존 연구가 벡터 카디널리티 추정의 한 가지 방법을 제안했다면, 본 연구는 분포의 쓸림이 그 방법의 효과를 결정한다는 메커니즘을 데이터로 입증하고, 분포를 모르는 환경으로의 확장 framework 를 제시했습니다."

표준 답변 (30 초)

"Exqutor 가 벡터 카디널리티 추정의 한 가지 방법 (Adaptive Sampling) 을 제안했다면, 본 연구는 그 방법이 작동하지 않는 사각지대를 코드로 발견하고, 그 사각지대를 분포 인지 stratified sampling 으로 메우면서 그 효과가 분포의 cluster skewness 와 단조 관계임을 데이터로 입증했습니다. 분포를 모르는 환경으로의 확장 (RQ3) 은 7 가지 방법의 체계적 비교 framework 로 정리되며, Recovery Rate 라는 새 metric 으로 비용-효과를 정량화합니다."

Q20.4 본 연구가 후속 연구로 어떻게 확장 될 수 있나요?

핵심 한 줄: (1) Multi-system framework (Milvus / Pinecone / Weaviate) 확장, (2) Multi-modality (text / audio / multimodal) 일반화, (3) Dynamic data (INSERT/UPDATE) 대응, (4) End-to-end query time 직접 측정, (5) Learning-based estimator 와의 hybrid — 5 갈래 확장 가능.

표준 답변 (45 초)

5 갈래 후속 연구. (1) *Multi-system*: 본 연구의 KM20 + Recovery Rate framework 를 Milvus, Pinecone, Weaviate 같은 다른 벡터 DB 에 이식해 *system-agnostic stratification* 을 구성. (2) *Multi-modality*: text embedding (BERT, sentence-BERT), audio (wav2vec), multimodal (CLIP) 의 cluster skewness 와 stratification 효과의 일반화. (3) *Dynamic data*: INSERT/UPDATE 가 빈번한 환경에서 stratum_id 의 incremental update 와 centroid drift 처리. (4) *End-to-end*: Q-error 의 plan 변경 영향 → 실행 시간 단축의 직접 측정. (5) *Hybrid*: learning-based estimator (LearnedCard, MSCN) 와 sampling-based (KM20) 의 ensemble 또는 hierarchical hybrid. 본 연구의 framework 가 5 갈래 모두 의 anchor 가 됩니다.

Q20.5 본 연구를 3 줄로 요약하면? 마지막 인사말 형태로.

핵심 한 줄: "단일 테이블 사각지대를 코드 세 줄로 메우고, 그 효과가 분포의 쓸림과 단조 관계임을 데이터로 입증했으며, 분포를 모르는 환경으로의 확장은 5 월에 비교 실험합니다."

표준 답변 (25 초) — 발표 마무리용

"본 연구는 세 가지로 정리됩니다. 첫째, Exqutor 의 multi-table only design intent 가 비워 둔 단일 테이블 사각지대를 발견하고 코드 세 줄로 메웠습니다. 둘째, 두 단계 보완 (베르누이 추출 + 공간 인식 총화 표본) 의 효과 (9.6 % + 1.6 ~ 4.4 %) 와 그 인과 관계 (분포의 쓸림이 클수록 공간 인식의 가치가 크다) 를 직교 측정과 cross-dataset 비교로 직접 입증했습니다. 셋째, 분포를 모르는 환경으로의 확장 (RQ3 의 7 가지 distribution-agnostic 방법) 은 5 월에 비교 실험합니다. 감사합니다."

부록 A — 골든 아워 답변 (10 초 이내, 자신감 톤)

Q&A 시간 압박이거나 청중이 가벼운 톤일 때, 핵심 한 줄로 끝내는 답변. 발표자가 외워서 즉답.

#	질문 키워드	골든 답변 (10 초 이내)
G1	"왜 단일 테이블?"	"이미지 검색·추천·RAG 의 핵심 형태인데 Exqutor 가 의도적으로 비워 둔 사각지대입니다."
G2	"9.6 % 가 의미 있나?"	"Plan 한 번의 잘못이 실행 시간 1 만 배 차이를 만드는 옵티마이저 환경에서 1 % 의 정확도가 plan 변경 임계점을 넘기는지를 결정합니다."
G3	"K=20 어떻게 정함?"	"K=10 vs K=20 비교에서 K=20 일관 우세. K sweep 은 W5 보충 실험."
G4	"5-seed 충분?"	"Medium effect 잡기에 7 ~ 10 배 충분. 본격 검정력은 W6 의 10-seed × 500-쿼리."
G5	"Adaptive 와 head-to-head?"	"Adaptive update path SIGSEGV 로 직접 비교 측정 자체가 불가, design constraint #5."
G6	"다른 데이터셋은?"	"DEEP-SIFT 가 대조 anchor pair. 768d wiki + glove + msmarco 는 W5-W7 보충."
G7	"End-to-end query time?"	"Q-error 만 측정. plan 변경 영향은 W6 EXPLAIN ANALYZE 로 간접 측정 예정."
G8	"RQ3 5월 가능?"	"Stratum_id 할당만 다르고 측정 파이프라인 재활용 → 4 주에 7 방법 측정 가능."
G9	"Recovery Rate 정의?"	"(방법X – RANDOM20) / (KM20 – RANDOM20). KM20 oracle 효과의 회수율."
G10	"분모 붕괴?"	"
G11	"vector.c 변경량?"	"핵심 3 줄 + 보조 228 라인 = 약 230 라인. opt-in 추가 mode."
G12	"Phase 7 artifact?"	"4 월 15 일 자체 검증으로 plan_rows = 20 LIMIT 상수 artifact 발견 → 철회 → redo. 학술 정직성 사례."
G13	"VBASE / DuckDB 비교?"	"Exqutor 코드 위에 추가하는 형태라 multi-system 비교는 후속 연구. Exqutor 원논문 1 만 배 격차가 system 비교 anchor."
G14	"임베딩 모델 영향?"	"Cluster skewness 메커니즘이 핵심. 모델별 isotropy 변동에 따라 효과 크기 변동, 방향은 일관."
G15	"HNSW 인덱스?"	"본 연구는 인덱스 없는 환경. 인덱스 있을 때 ECQO + 없을 때 stratified 의 2 layer fallback 구조."
G16	"왜 k-means?"	"Hard partition + 결정론적 학습 + 1M 데이터 안정. GMM/DBSCAN/hierarchical 은 차원·비용 issue."
G17	"10 분 시간 분배?"	"S03 ~ S16 슬라이드별 35 ~ 75 초. 합계 약 600 초 = 10 분."
G18	"결석 시 백업?"	"박세은 팀장이 백업 발표자. 4/24 + 4/26 사전 리허설 2 회."
G19	"Exqutor 저자 contact?"	"박성원 멘토 통해 6 월 최종 보고서 시점에 finding 공유 + contribute 가능성 논의."

#	질문 키워드	골든 답변 (10 초 이내)
G20	"기여 한 문장?"	"단일 테이블 사각지대 + 코드 세 줄 보완 + 분포-효과 단조 관계 입증."

부록 B — 명사답변 (어려운 질문 25 종, 각 1 ~ 2 문장)

심사위원이 작성하고 추궁할 때. 자신감 + 솔직성 균형. 답변 후 질문자에게 다시 공을 넘기지 않음.

B1. "Q-error 1.04 가 1.05 가 되는 게 정말 plan 을 바꾸나요? 임계점을 직접 측정한 적 있나요?"

"Plan 변경 임계점은 옵티마이저의 cost model 에 의존하며, 본 보고서 시점에서는 직접 측정하지 못했습니다. W6 의 EXPLAIN ANALYZE 보충 분석에서 *plan 변경 빈도* 를 직접 측정해 임계점 근처 쿼리의 비율을 정량화할 예정이고, 본 시점의 1 % 정확도 개선이 *옵티마이저의 표준 메커니즘으로 plan 변경 확률을 줄인다* 는 conservative claim 까지가 본 연구의 한계입니다."

B2. "Phase 7 artifact 를 자체 발견한 게 자랑이 아니라 그런 artifact 를 처음에 만든 게 문제 아닌가요?"

"정확한 지적입니다. Plan tree parsing 의 metric 선택 (plan_rows vs hook_est) 자체가 측정 도구의 선택 오류였고, hook_est 가 authoritative 임은 Phase 6 Step 4 에서 명시되었어야 했습니다. 자체 검증으로 24 시간 내 발견·철회·redo 한 점을 *학술 정직성* 으로 framing 했지만, 처음부터 metric 을 명확히 해야 함을 인정합니다. 후속 측정에서는 *metric pre-registration* 을 표준 절차로 도입했습니다."

B3. "RANDOM20 의 *random seed* 가 결과에 큰 영향 미치지 않나요? 5 seed 가 너무 작은 것 아닌가요?"

"RANDOM20 의 sample 추출 seed 는 5 개 (0.1 ~ 0.5) 고정이고, RANDOM20 의 *partition assignment* 자체는 `random_seed_sql = 0.42` 의 SQL random 으로 1 회 결정됩니다. 즉 partition 자체는 한 번 정해진 결과이고, 5 seed 는 sample 추출의 변동만 측정합니다. *partition 자체의 random 변동* 은 다른 seed (0.1, 0.5, 0.9) 로 partition 을 재생성해 측정하는 별도 실험이 W5 보충에 포함됩니다."

B4. "RQ3 의 7 방법 중 *D (Exqutor Hybrid)* 를 제외한 결정 이 본 연구의 정당성을 약화시키지 않나요? 가장 자연스러운 baseline 인데?"

"D 가 자연스러운 baseline 이라는 점은 동의하지만, 4 가지 issue (SIGSEGV, negative finding, RQ3 취지 불일치, 6주 비현실적) 를 누적 평가했을 때 제외가 정당합니다. RQ3 의 취지가 *새로운 distribution-agnostic 방법론 제안* 이므로 *Exqutor Adaptive* 의 버그 수정 은 다른 연구 (Adaptive Sampling sanitization) 의 영역입니다. D 는 후속 연구로 분리하는 것이 더 깨끗한 framing 입니다."

B5. "본 연구가 *Exqutor* 원논문에 배경 으로 너무 의존하지 않나요? 독립적 기여가 있나요?"

"정확한 지적이십니다. 본 연구는 Exqutor 의 *layered extension* 형태로 design intent 를 깨지 않고 사각 지대를 메웁니다. 독립적 기여는 (1) 단일 테이블 사각지대의 발견 + 5 design constraint 정량화, (2) Two-Level decomposition framework, (3) cluster skewness vs effect 의 cross-dataset 단조 관계 입증, (4) RQ3 의 distribution-agnostic 7 방법 체계적 비교 framework + Recovery Rate metric. 이 4 가지가 Exqutor 원논문에 없는 기여입니다."

B6. "K-means 의 *seed* 의존성 은 어떻게 통제했나요? seed=42 로 fix 한 것이 결과에 영향 없나요?"

"K-means 학습 seed = 42 fix 의 영향은 *partition 자체의 결정론적 재현 가능성* 이고, 다른 seed 에서 partition 이 달라지면 KM20 효과도 변동 가능합니다. 다른 k-means seed (1, 7, 42, 100, 1000) 에서의 partition 변동 측정은 W5 보충 실험에 포함되며, 본 연구의 결론은 *seed=42 partition baseline* 에서의 효과 로 conservative 하게 한정됩니다. 다행히 mini-batch k-means 의 inertia (0.692) 가 stable convergence 를 시사해 partition 자체의 robustness 는 확보되어 있습니다."

B7. "본 연구의 통계적 유의성과 실용적 의미의 gap 이 너무 크지 않나요?"

"Cohen 의 effect size 가이드라인에서 본 연구의 9.6 % *Q-error* 개선은 small-to-medium effect 입니다. 그러나 옵티마이저의 plan 선택은 임계점 근처에서 *categorical change* 를 일으키고, plan 한 번의 잘못이 1 만 배 실행 시간 차이를 만드는 환경에서 small effect 도 macro-level 영향이 큼니다. 통계 vs 실용의 gap 은 옵티마이저 메커니즘이 매우며, end-to-end query time 직접 측정 (W6 보충) 으로 이를 정량화할 예정입니다."

B8. "Phase 7 의 redo 측정 자체가 *cherry-picked D_target* 으로 만든 것 아닌가요?"

"정확한 우려이십니다. *D_target* 재계산은 모든 query 에서 *actual selectivity* ≈ 0.5 가 되도록 *binary search* 한 결과이고, 이는 측정 조건의 일관성을 위한 표준 절차입니다. cherry-picking 의심을 차단하기 위해 *D_target* 재계산 절차와 결과 (per-query *D_target* + *actual_sel*) 가 phase7_8m_dtarget_recalc_clean.json 에 100 query 모두 보존되어 있고, reviewer 가 직접 검증 가능합니다."

B9. "5-seed *t*-based CI가 small sample 의 *t-distribution conservatism* 으로 너무 wide 하지 않나요? bootstrap 이 더 정확하지 않나요?"

" $n=5$ 의 $t(4) = 2.776$ 이 *t*-based CI 의 conservatism 을 만드는 것은 맞고, percentile bootstrap CI 가 더 narrow 한 경우가 있습니다. 두 방식 모두 valid 하며, 본 보고서는 *conservative t-based* 를 채택해 효과의 *lower bound* 를 강조합니다. 최종 보고서에서는 두 방식 모두 표기해 reviewer 의 직접 비교를 가능하게 할 예정입니다."

B10. "본 연구의 *generalization* 이 너무 narrow 하지 않나요? 단일 테이블 + L2 거리 + range query 만?"

"정확한 한계 인정입니다. 본 연구의 conservative claim 은 단일 테이블 + L2 거리 + range query + DEEP-SIFT-style image embedding 의 cardinality estimation 에서 stratified sampling 의 효과가 cluster skewness 와 단조 관계 까지입니다. (1) Multi-table $\rightarrow$ join cardinality, (2) cosine / IP $\rightarrow$ metric-agnostic, (3) top-k $\rightarrow$ range 가 아닌 ordering, (4) text / audio embedding $\rightarrow$ modality 일반화는 모두 후속 연구의 영역으로 명시됩니다."

B11. "*Sample_size = 385 fixed* 가 모든 selectivity 와 데이터 규모에서 valid 한가요?"

"385 는 95 % CI ± 5 % 마진의 binomial proportion estimation 기준의 conservative 값입니다. small selectivity ($s \leq 0.01$) + large data (8M) 영역에서는 sample 안 hit 수가 0 ~ 1 같은 작은 정수로 양자화 되어 *분해능 한계* 가 발현됩니다 (anomaly_analysis.md §Anomaly 2). Sample_size sensitivity (385, 770, 1540) 의 sweep 은 W5 보충 실험에 포함됩니다."

B12. "*HHI / CV* 외에 다른 skewness 지표 (Gini, Theil, Atkinson) 도 측정해야 하지 않나요?"

"HHI 와 CV 가 *위쪽 꼬리* (HHI) 와 *전체 변동* (CV) 의 직교 차원을 잡으므로 1 차 anchor 로 충분합니다. Gini coefficient 와 Theil index 는 income inequality 분야의 표준이며 cluster size 분포에도 적용 가능. Gini 는 본 연구의 RANDOM20 control 에서 $km20_gini = 0.1275$ / $rand_gini = 0.0027$ 의 보조 지표로 측정되어 있고, 추가 지표 보고는 RQ3 의 보충 분석에 포함될 예정입니다."

B13. "*8 지표 무상관 finding* 이 너무 약한 결론 아닌가요? 다른 feature 도 시도해야 하지 않나요?"

"8 지표 (글로벌 4 + 로컬 4) 가 *분포 쏠림 측정의 4 패러다임* $\times$ 2 스코프 의 직교 공간을 cover 하므로 전 수 부재 라는 강한 결론이 가능합니다. 다른 feature (semantic feature, query log statistics) 는 *분포 쏠림이 아닌 다른 차원* 의 시도이며, 본 연구의 결론은 *분포 쏠림 휴리스틱의 사전 식별 불가능성* 으로 한정됩니다. 다른 feature 의 효과는 후속 연구 (학습 기반 estimator) 의 영역입니다."

B14. "본 연구의 코드가 공개 되어 있나요? 외부 검증 가능한가요?"

"네, GitHub (<https://github.com/johyunbin/Capstone>) 에 모든 측정 스크립트와 결과 raw data, 보고서 ·발표 자료가 공개되어 있습니다. Exquitor source 의 변경분도 백업 파일과 함께 보존되어 있으며, README 에 빌드 절차와 측정 명령이 정리되어 있습니다. 외부 검증자가 동일 환경 재현 가능합니다."

B15. "Cluster 1 + Cluster 18 dominance (SIFT) 가 데이터 자체의 특성 인지 k-means seed=42 의 artifact 인지 어떻게 구분하나요?"

"정확한 지적이십니다. seed=42 fix 의 partition artifact 가능성을 통제하려면 다른 seed 의 partition 결과를 비교해야 하고, 이는 W5 보충 실험에 포함됩니다. SIFT 자체의 cluster skewness 는 임의의 partition seed 에서 일관되게 더 큰 CV 를 보일 것으로 예상되며, 1 ~ 2 seed 추가 측정으로 robustness 검증 예정입니다."

B16. "Two-Level decomposition 이 Cochran 1977 의 분산 분해 와 어떻게 다른가요?"

"Cochran 의 분산 분해는 within-stratum variance 의 weighted sum 으로 stratified sampling 의 분산을 표현하는 이론적 분해 입니다. 본 연구의 Two-Level 은 그 이론을 empirical RANDOM20 control 로 측정 가능하게 specialize 한 것입니다. 즉 이론은 same, 측정 framework 의 새로움이 본 연구의 기여이며, RANDOM20 partition 으로 spatial-awareness-free baseline 을 직접 잡은 점이 핵심입니다."

B17. "본 연구가 재현 가능 하다고 했는데, random seed 외 다른 nondeterminism 은 통제 했나요?"

"(1) k-means batch_size, n_iter, seed 모두 명시. (2) sample 추출 seed 5 개 fix. (3) PostgreSQL 의 query plan random 을 위한 GUC random_page_cost , cpu_tuple_cost 등은 default 사용 + 측정 환경 명세에 기록. (4) 측정 환경 (PG 16.9, pgvector 0.7.1, OS, hardware) 모두 명세. nondeterminism 의 모든 원천 을 통제하기는 어렵지만 (BLAS lib, CPU instruction, OS scheduler), random seed 통제로 1 차 재현 가능성은 확보되어 있습니다."

B18. "다른 distribution-agnostic 방법 (Locality-Sensitive Hashing, Bloom filter) 과 비교는?"

"LSH (A) 가 RQ3 의 7 방법에 포함되어 있고 5 월에 측정합니다. Bloom filter 는 set membership testing 도구로 cardinality estimation 에 직접 적용되지 않아 RQ3 범위 밖입니다. HyperLogLog (Flajolet et al. 2007) 는 distinct count estimation 의 표준이고, vector range query 에는 적용 어렵습니다. 비교 대상의 선정 기준 (4 평가 축) 이 RQ3 설계안 §X 에 명시되어 있습니다."

B19. "Hilbert curve (E)가 96 차원에서 동작 안 할 가능성은? Negative finding 이라도 학술 가치 있나요?"

"Hilbert curve 의 locality preservation 이 96 / 128 차원에서 약화될 수 있다는 caveat 는 RQ3 설계안에 명시되어 있습니다. Negative finding 이라도 공간 DB 30 년 standard 가 vector range query 에 적용 안 되는 영역의 정량화는 학술 가치가 있고, 본 연구가 negative finding 도 학술 기여로 framing 합니다."

B20. "Sample_size sensitivity가 측정 안 됐는데, 본 연구의 결론이 sample_size = 385 의 corner case 일 가능성은?"

"정확한 우려입니다. Sample_size sensitivity (385, 770, 1540, 3080) 측정은 W5 보충 실험에 포함되며, 본 연구의 결론이 sample_size = 385 baseline 에서의 효과로 conservative 하게 한정됩니다. 다른 sample_size 에서 효과 크기 / 방향이 어떻게 변하는지가 RQ3 보충 분석의 핵심 질문 중 하나입니다."

B21. "본 연구가 deep learning 기반 estimator 와의 fundamental gap 을 메우려는 시도 인가요?"

"본 연구는 sampling-based estimator 의 framework 내 개선이고, learning-based estimator 와는 직교적 패러다임입니다. 두 패러다임의 hybrid (예: learned stratification + sampled estimation) 는 후속 연구의 자연스러운 확장이며, 본 연구의 framework 가 learning-based 와의 fair comparison 의 anchor 가 될 수 있습니다."

B22. "Hook 의 plan replacement 부작용이 원논문에 명시되지 않은 이유는 Exqutor 가 의도적으로 단일 테이블을 제외 한 것 아닌가요?"

"정확한 추론입니다. Exqutor 의 design intent 가 multi-table join 의 base table cardinality 보장이고, 단일 테이블은 intentional exclusion 으로 보입니다. 다만 원논문 본문에 명시되지 않은 점이 본 연구의 빈자리이며, 단일 테이블이 실무 응용의 핵심 형태라는 점에서 명시되지 않은 사각지대를 메우는 학술 가치가 있습니다."

B23. "Exqutor 원논문의 1 만 배 격차가 최악의 시나리오 cherry-pick 일 가능성은?"

"Exqutor 원논문 Table 1 은 시나리오별 분포의 *최대값* 을 보고하므로, 1 만 배는 *상한이 아닌 가능한 최대값* 입니다. 평균은 더 작을 수 있고, 본 연구가 Exqutor 원논문의 *가능한 최대값 시나리오* 에 의존하지는 않습니다. 본 연구의 정량 결과 (9.6 % + 1.6 ~ 4.4 %) 는 Exqutor 원논문과 독립적인 *우리 환경의 직접 측정* 이며, 1 만 배 격차는 *plan 변경의 macro-level 영향 framing* 으로만 인용됩니다."

B24. "RQ3 가 5 월에 7 방법 모두 측정 되지 못하면 어떻게 되나요?"

"RQ3 의 priority 는 (1) Offline Partition 4 (C/A/E/F) → (2) Online + Weight 3 (G/B/H) → (3) H 의 2×2 factorial 의 순서이고, 시간 부족 시 Offline 4 만으로도 *체계적 비교* 의 1 차 결론 가능합니다. Online + Weight 는 W7 후반 또는 후속 연구로 분리. F (MiniBatch) 의 learning_fraction sweep 0 이 *cost-effect ratio* 의 핵심 finding 이므로 우선순위 1 위로 보장됩니다."

B25. "본 연구가 졸업 논문 으로 충분한가요?"

"본 연구의 학술적 기여 (사각지대 발견 + 직교 측정 + 인과 입증 + RQ3 framework) 는 학부 캡스톤의 expected level 을 상회한다고 자평합니다. 다만 reviewer 의 평가는 별도이며, 본 보고서·발표 자료가 *체계성 + 정직성 + 정량성* 을 모두 갖추도록 4 차에 걸친 ultrareview (4/19, 4/27, ...) 로 보강했습니다. 졸업 자격 충족 여부는 caveat 으로 남겨둡니다."

부록 C — 숨은 카드 (반전 답변, 사용 주의)

심사위원이 작성하고 공격적으로 추궁할 때, 발표자가 학술적 자신감 으로 받아치는 답변. 톤 조절 중요.

C1. "본 연구의 기여가 작아 보입니다. 9.6 % 정도면 미세한 개선 아닌가요?"

"9.6 % 라는 숫자는 본 연구의 시작점 이지 전부 가 아닙니다. 본 연구의 진짜 기여는 (1) 단일 테이블 사각 지대의 발견 + (2) layered 보완의 직교 분리 측정 framework + (3) 분포 쏠림 → 효과의 인과 관계 입증 + (4) RQ3 의 체계적 비교 framework + Recovery Rate metric 입니다. 9.6 % 는 그 중 한 측정의 단일 수치이고, 본 연구의 framework 자체가 후속 연구의 anchor 가 됩니다. 9.6 % 만 보면 작아 보이지만, framework 의 일반성 으로 보면 학술 기여의 깊이가 다릅니다."

C2. "본 연구가 너무 negative finding 에 의존 하지 않나요? Phase 7 artifact, 8 지표 무상관, design constraint 5 중 모두 negative."

"정확한 관찰입니다. 본 연구가 negative finding 을 학술 가치로 framing 한 것은 의도적입니다. (1) 8 지표 무상관은 분포 쏠림의 사전 식별 불가능성의 강한 negative 로 RQ3 의 motivation 이 됩니다. (2) Design constraint 5 중은 Exqutor design intent 의 systematic 분석 으로 학술 가치. (3) Phase 7 artifact 자체 정정은 학술 정직성의 본보기. 즉 negative finding 들이 본 연구의 체계성을 강화하며, positive finding (9.6 % + 1.6~4.4 %) 과 상호 보완 합니다. Reviewer 가 negative 를 학술 약점 이 아닌 학술 깊이 로 읽는 것이 본 연구의 framing 입니다."

C3. "본 연구가 학술적 novelty 가 부족하지 않나요? Stratified sampling 자체는 1977 년 Cochran 책에 있는 표준 방법인데?"

"Stratified sampling 자체의 novelty 는 없습니다. 본 연구의 novelty 는 (1) 벡터 거리 조건 카디널리티 추정 에 stratified sampling 을 최초 적용 한 점, (2) Two-Level decomposition framework 로 분포 인지의 spatial awareness 효과를 직접 측정 한 점, (3) cluster skewness 와 효과의 cross-dataset 단조 관계를 empirical 입증 한 점, (4) RQ3 의 distribution-agnostic 7 방법 체계적 비교 framework 입니다. 방법 자체의 novelty 가 아니라 적용 도메인 + 측정 framework + 인과 입증 의 novelty 입니다."

C4. "9.6 %의 통계적 유의성과 plan 변경의 실용적 의미 사이에 증거 gap이 있다고 솔직히 인정하시는 거죠?"

"네, 정확합니다. 본 연구는 Q-error 정확도 개선의 통계적 유의성을 직접 측정했고, plan 변경의 실용적 영향은 옵티마이저 메커니즘으로 간접 추론했습니다. 직접 plan 변경 빈도와 실행 시간을 측정하지 못한 한계는 보고서에 명시되어 있고, W6 보충 분석에서 EXPLAIN ANALYZE 기반 plan 변경 빈도 측정으로 이 gap을 메울 예정입니다. 본 시점의 conservative claim은 Q-error의 통계적 개선까지로 한정됩니다."

C5. "본 연구가 Exqutor 원논문 없이는 성립 안 하는 derivative work 아닌가요?"

"Exqutor 원논문이 본 연구의 baseline인 것은 맞고, 그 위에 layered 보안을 추가하는 형태입니다. 다만 본 연구의 4가지 독립 기여 — (1) 단일 테이블 사각지대 발견, (2) Two-Level framework, (3) cluster skewness 인과 입증, (4) RQ3 7 방법 체계적 비교 + Recovery Rate metric —은 Exqutor 원논문에 없는 기여입니다. Derivative가 아니라 layered extension이라는 framing이 더 정확합니다. SIGMOD / VLDB의 short paper 또는 demo track에서 이런 layered extension 형태가 표준 venue 형식입니다."

부록 D — 발표 마지막 30 초 — 청중에게 들고 갈 한 문장

발표 마지막 슬라이드 (S16 결론)에서 청중이 들고 갈 메시지. 외워서 자신감 톤으로 마무리.

"기존 시스템의 빈자리를 코드 세 줄로 메우고, 그 보안의 효과 (9.6% + 1.6 ~ 4.4%)와 그 효과가 분포의 쏠림과 단조 관계임을 데이터로 직접 입증했습니다. 분포가 쏠릴수록 공간 인식의 가치가 커진다는 본 연구의 출발 가설 (-10.67% vs +8.93%, 19.6%p 격차)이 데이터에서 그대로 나타났습니다. 분포를 모르는 환경으로의 확장은 5월의 7가지 방법 비교 실험으로 측정한 뒤, 6월 최종 보고서에서 종합하겠습니다. 발표를 마칩니다. 질문 받겠습니다."

부록 E — 세션 종료 직전 체크리스트 (발표 당일 아침)

- [] 발표 자료 PDF 최신본 USB 와 클라우드 양쪽 백업
- [] 발표 스크립트 docx 4 명 모두 보유
- [] cheat sheet 본 문서 4 명 모두 보유 (출력 + 디지털)
- [] 박세은 백업 발표자 모드 준비
- [] 강재현 컨디션 확인 (전날 22:00 박세은 카톡)
- [] 4/29 사전 리허설 1 회 (발표 전 24 시간)
- [] 발표 D-day 인종 A428 도착 18:30 (30 분 여유)
- [] Q&A 분담 framework 4 명 마지막 확인
- [] 5 분 Q&A 의 예상 5 ~ 8 개 질문 사전 시뮬레이션
- [] 4 가지 안전 답변 발표자 외워 두기
- [] 골든 아워 답변 20 종 발표자 외워 두기
- [] 모르는 질문 시 4 명 영역 분담 자연스럽게 작동
- [] 진짜 모르는 질문 시 cheat sheet 부록 B 의 conservative 답변
- [] 발표 후 다른 팀 질문 1 ~ 2 개 준비 (가산점)

본 cheat sheet 는 2026-04-27 22:00 KST 에 작성되었으며, raw experiments data 의 직접 검증 (모든 mean 수치 100 % 일치, 표기 부정확 3 건만 발견) 을 거쳤다. 발표 직전 (4/29 또는 4/30 오전) 마지막 점검 후 4 명 모두에게 출력 + 디지털 양쪽으로 공유한다.

부록 F — KILLER QUESTIONS (발표자 반드시 외워야 할 5 개 답변)

4/27 22:00 Opus 4 개 병렬 ultrareview 결과 식별된 답변 못 하면 발표 신뢰도 흔들리는 5 개 질문. 발표자가 이 답변을 외워서 자신감 톤으로 답하면 최악의 경우 대비 완성. 본문 어떤 다른 답변보다도 우선 외워야 한다.

KQ1. "9.6 % 가 베르누이의 단위 변경 효과가 아니라 expected sample size variance 효과일 가능성은? Sample_size 일치 통제 비교가 있나요?"

위험도: 매우 높음 (5/5). RQ2-1 의 핵심 mechanism claim 자체가 흔들리는 질문.

최선 답변 (50 초)

정확한 지적입니다. Sample_size = 385 GUC 로 *expected* sample size 는 동일하게 통제했지만, 실제 sample size 의 variance 는 두 추출 방식이 다릅니다. SYSTEM 은 8KB block 단위 추출이라 actual sample size 가 $\pm 5 \sim 10$ % 변동하고, BERNOULLI 는 row 단위 inclusion 이라 actual sample size 가 더 narrow 하게 변동합니다. 본 연구의 9.6 % 개선은 *actual sample size 의 variance 차이* 와 *block-internal row dependency* 두 효과의 confounded 결과로 해석되며, 두 효과의 분리는 *strict sample size matching* (예: TABLESAMPLE 후 randomly select N=385 rows) 의 추가 실험이 필요합니다. 이 분리 측정은 W5 보충 실험에 포함되며, 본 시점의 9.6 % claim 은 *SYSTEM-vs-BERNOULLI* 의 두 *mechanism combined effect* 까지로 conservative 하게 한정됩니다.

KQ2. "100 개 query 가 어떻게 생성됐나요? Random vector 인가요? 데이터에서 sample 한 vector 인가요? 그 선정 자체에 selection bias 가 있다면 본 연구의 모든 결과가 흔들립니다."

위험도: 매우 높음 (5/5). 답변 못 하면 실험 설계의 근본 결함 노출.

최선 답변 (40 초)

100 개 query 는 dataset 내부에서 *uniform random sampling* 으로 선정한 vector 입니다. 즉 query vector 자체가 dataset 의 underlying distribution 을 따르므로, *cluster 1 / cluster 18 같은 dominant cluster 의 query 가 expected proportion 으로 포함* 됩니다. 이는 *real-world workload* 와는 다를 수 있는데, 실제 검색에서는 *out-of-distribution query* 도 빈번합니다. Out-of-distribution query 의 cardinality estimation 은 본 연구 범위 밖이며 후속 연구의 영역입니다. Query selection 의 random_seed = 42 fix 와 100 개 query vector 의 raw 가 `query_pool.parquet` 에 보존되어 있어 외부 reviewer 가 직접 검증 가능합니다.

KQ3. "Phase 7 artifact 자체 정정 사례를 학술 정직성의 본보기로 framing 했는데, 그건 처음부터 metric 을 잘못 선택한 것이지 학술 정직성이 아닙니다. plan_rows 가 estimator 출력이 아닌 LIMIT 상수임을 측정 시작 전 검증했어야 합니다. 본 연구의 측정 도구 검증 자체가 부실했다는 증거 아닌가요?"

위험도: 매우 높음 (5/5). 학술 정직성 framing 자체가 약점이 됨. Q10.7 본문 답변보다 이 답변을 우선 사용.

최선 답변 (45 초)

정확하게 인정합니다. Phase 7 의 metric 선정 (plan_rows vs hook_est) 자체가 측정 도구의 사전 검증 실패였고, hook_est 가 authoritative metric 임은 Phase 6 Step 4 에서 명시되었어야 했습니다. 이 *initial mistake* 가 Phase 7 의 첫 결과 (ratio 2168x) 를 만든 직접 원인입니다. 자체 검증으로 24 시간 내 발견·철회·redo 한 점은 *대처의 학술 정직성* 이지만, 처음부터 mistake 를 만든 것은 *학술 약점* 입니다. 본 사례를 통해 후속 측정에서는 *metric pre-registration* 을 표준 절차로 도입했고, RQ3 의 7-way 비교에서는 metric 선정 protocol 을 측정 시작 전 명시할 예정입니다. Phase 7 의 *완전한 framing* 은 'mistake + recovery' 이지 'recovery only' 가 아닙니다.

KQ4. "Two-Level decomposition 의 Level 2 단독 효과 +19.6%p 라는 수치가 본 연구의 가장 강력한 evidence 라고 했는데, 이는 *one specific dataset/selectivity cell (DEEP 1M, s=0.010)* 의 single measurement 입니다. SIFT 1.5M, s=0.010 에서 같은 metric 의 격차는 +11.58 %p 으로 거의 절반입니다. 19.6 %p 가 *cherry-picked* 값 아닌가요?"

위험도: 높음 (4/5). 본 연구의 가장 자랑하는 수치가 outlier 일 가능성.

최선 답변 (45 초)

정확한 지적이십니다. 19.6 %p 는 DEEP 1M s=0.010 *one cell* 의 5-seed mean 이고, SIFT 1.5M s=0.010 의 격차 11.58 %p 와 비교하면 두 데이터셋의 격차가 *상당히 다릅니다*. 다만 두 격차 모두 Level 2 단독 효과 양수 + 데이터셋의 *cluster skewness* 와 단조 관계 * 의 일관성을 유지합니다 — DEEP 1M (CV 0.234) 19.6 %p, SIFT 1.5M (CV 0.394) 11.58 %p 의 방향 이 일관됩니다. 19.6 %p 가 최대값 인 것은 사실이고, 본 연구의 더 *robust 한 framing* 은 cross-dataset Level 2 효과 평균 ~ 15 %p, range 11 ~ 20 %p 입니다. 발표 슬라이드의 19.6 %p 강조는 최강 evidence 라기보다 anchor measurement* 로 표기하는 것이 정확합니다.

KQ5. "본 연구가 Q-error 만 측정했는데, 오픈/마이저 plan 변경 빈도는 EXPLAIN ANALYZE 로 지금 당장 측정 가능합니다. 왜 발표 시점에 그 측정을 안 했나요? 시간 부족한가요? 그 측정 없이 plan 변경 임계점 효과를 주장하는 것은 *불완전한 evidence* 아닌가요?"

위험도: 매우 높음 (5/5). 본 연구의 가장 큰 한계가 직접 노출.

최선 답변 (50 초)

정확합니다. EXPLAIN ANALYZE 기반 plan 변경 빈도 측정은 기술적으로 지금 가능 한 측정이며, 시간 부족 + RQ2 의 직교 분리 측정에 우선순위를 둔 *team decision* 으로 W6 보충 분석에 분리했습니다. 본 보고서·발표의 conservative claim 은 *Q-error* 의 통계적 개선까지 로 한정되며, *plan* 변경 임계점 효과 는 Exqutor 원논문의 보고와 옵티마이저 표준 메커니즘에 의존한 *간접* 추론 입니다. 이 한계는 보고서 §14 (Threats to Validity) 에 명시되어 있고, 발표에서 *간접* 추론 표현을 사용했습니다. W6 의 EXPLAIN ANALYZE 측정으로 plan 변경 빈도를 직접 정량화할 예정이며, 본 시점의 결론은 *Q-error* 통계적 개선 + *plan* 변경 가능성의 정성적 추론 의 두 갈래로 표현됩니다.

부록 G — CRITICAL / HIGH 정정 패치 (본문보다 우선)

4/27 22:00 ultrareview 의 수치 검증 + 일관성 검증으로 식별된 본문 정정 사항. 본 부록의 답변이 본문과 충돌하면 본 부록이 우선.

● CR1: Q6.1 / Q14.3 의 K=20 vs K=10 수치 misattribution (CRITICAL)

본문 잘못된 표기: "K=20 이 K=10 보다 selectivity 0.100 (+2.25 %, p=0.0042), 0.300 (+0.76 %, p=0.016), 0.500 (+0.33 %, p=0.016) 모두 우세"

raw 검증 결과: 위 수치는 실제로는 *KM20 vs Bernoulli* 측정값. 진짜 *KM20 vs KM10 cross_pair* (raw `phase6_layer_compare_compare.json` 의 `cross_pairs` 필드) 는: - s=0.100: +2.06 %, p=0.0013 (KM20 우세, **유의**) - s=0.300: +0.034 %, p=0.733 (**비유의**) - s=0.500: -0.076 %, p=0.490 (**비유의**, KM10 미세 우세)

정정된 답변 (Q6.1 / Q14.3 질문에 대해 본 답변 사용):

"phase6_layer_compare 의 cross_pair 측정에서 KM20 vs KM10 직접 비교 시 selectivity 0.100 에서만 KM20 우세 (+2.06 %, p=0.0013) 였고, 0.300 / 0.500 에서는 비유의입니다. 다만 KM20 vs Bernoulli 비교에서는 0.100 / 0.300 / 0.500 모두 KM20 우세 (+2.25 %, +0.76 %, +0.33 %, 모두 $p < 0.05$) 입니다. 즉 K=20 의 base 효과는 일관되며, K=10 대비 추가 이점은 좁은 selectivity 영역에서만 발현됩니다. K sweep 의 본격 측정은 W5 보충 실험에 포함됩니다."

● H1: 1.6 ~ 4.4 % 의 selectivity 혼동 (HIGH)

본문 잘못된 표기: "세 데이터셋 s=0.500 에서 KM20 의 추가 개선 1.6 ~ 4.4 %"

raw 검증: $s=0.500$ 만이면 DEEP 1M 1.64 %, DEEP 8M 1.76 %, SIFT 1.5M 3.07 % → **1.6 ~ 3.1 %**. 4.4 % 는 SIFT 1.5M $s=0.050$ 의 추가 개선값 (다른 selectivity).

정정된 표기: "세 데이터셋 $s=0.500$ anchor 에서 1.6 ~ 3.1 %, SIFT 1.5M $s=0.050$ 까지 포함하면 최대 +4.4 % (95 % CI [+2.63, +6.15])."

● H2: per-seed p-value 표기 정확화 (HIGH)

본문 잘못된 표기: "DEEP 1M $s=0.5$ KM20 의 per-seed $p < 1e-5$ "

raw 검증 (`phase6_multiseed_summary.json` 의 5 seed): 1.76e-5, 9.97e-4, 0.0300, 4.31e-5, 3.63e-5 → **min $p=1.76e-5$, max $p=0.030$**

정정된 표기: "DEEP 1M $s=0.5$ KM20 의 5 seed 중 4 seed 가 $p < 1e-3$, 1 seed 가 $p < 0.05$ — 모든 seed 통계적 유의. min $p=1.76e-5$, max $p=0.030$."

SIFT $s=0.500$ KM20 p-value 도 비슷한 정정: max $p=1.55e-8$ (slightly $> 1e-8$) → "모든 per-seed $p \leq 2e-8$ " 로 정확화.

● H3: HHI 0.067 표기 모순 정정 (MID, 설명 오해 가능성)

본문 잘못된 표기: "cluster HHI $\approx 1/K = 0.067$ (균일 수준)"

수학적 사실: $K=20$ 이면 $1/K = 0.05$ 가 균일 기준. 0.067 은 $s=0.500$ 의 실측 HHI 값 (raw `hhi_python_summary.json` 의 `hhi_mean = 0.0669`).

정정된 표기: "selectivity 0.500 의 실측 cluster HHI ≈ 0.067 (균일 기준 $1/K=0.05$ 의 약 1.34 배). selectivity 가 줄어들수록 HHI 가 급증해 $s=0.010$ 에서 0.503 (균일 대비 10 배) 까지 도달."

● H4: 9.6 % 의 95 % CI 명시 추가 (HIGH)

본문 누락: 9.6 % Q-error 개선의 95 % CI 자체/가 cheat sheet 어디에도 명시되지 않음.

raw 검증 (phase4_compare.json): $s=0.500$ BERN `diff_pct_med` = 9.581 %, paired Wilcoxon $W=4429.5$, $p=2.91e-11$. 단일 측정이므로 CI 가 별도 산출되지 않으며, paired Wilcoxon 의 95 % 신뢰성은 W 통계량의 양쪽 quantile 로 산출 가능 (별도 추가 분석 필요).

보강 답변 (Q5.3 또는 Q10.5 보강용):

"9.6 % 의 paired Wilcoxon 결과는 $W=4429.5$, $p=2.91e-11$ 로 단일 측정이며, 5-seed 변동의 CI 는 $W5$ 보충 실험에서 산출 예정입니다. 단일 측정의 bootstrap 95 % CI (질의 100 개 paired difference 의 percentile) 는 사전 산출 가능하며, 발표 시 추궁 시 $w_{stat} = 4429.5 + n_{better} = 78/100$ 의 robust 한 sign 분리를 강조합니다."

● H5: paired Wilcoxon 가정 표기 정확화 (MID)

본문 잘못된 표기: "paired Wilcoxon 은 분포 가정 없이/ paired difference 의 median 검정"

학술 정확: paired Wilcoxon signed-rank 는 *paired difference 의 symmetric distribution* 가정 필요. "분포 가정 없이" 는 부정확하며, 정확한 표현은 "정규성 가정 없이, lognormal 같은 heavy-tail 에 robust 한 비모수 검정".

정정된 표기: "paired Wilcoxon 은 정규성 가정 없이, lognormal 같은 heavy-tail 분포에 robust 한 비모수 검정으로, *paired difference 의 분포가 symmetric* 가정만 요구합니다."

● H6: RQ3 timeline W-numbering 통일 (CRITICAL — 본문 모순)

본문 모순: Q11.6 (W1~W3), Q17.1 (W5~W7), Q11 도입 (W10~W12) 의 3중 표기 모순.

통일 표준 (보고서 §5.2 와 일치): - 4 월 = W1 ~ W4 (학기 시작 4/4 기준) - 5 월 = W5 ~ W8 - 6 월 = W9 ~ W11

정정된 timeline (모든 답변에서 통일 사용): - W4 (4/27 ~ 5/3): 발표 + 마무리 - **W5 (5/4 ~ 5/10): 보충 실험 5 건** (per-stratum BERN, K sweep, wiki 768d, SIFT mid, sample_size sensitivity) - **W6 (5/11 ~ 5/17): 본격 검정력** (10-seed × 500-쿼리 + BH-FDR + TOST + Cohen's d) - **W7 (5/18 ~ 5/24): RQ3 7-way 비교** (Offline 4 + Online 2 + Weight 1 + H 2×2 factorial) - W8 (5/25 ~ 5/31): 분석 + 최종 발표 준비 - W9 ~ W11 (6/1 ~ 6/14): 최종 발표 + 전시회 + 최종 보고서

본 표기를 모든 답변 (Q11.6, Q17.1, 부록 A 등) 에서 통일.

● H7: "최초 적용" 표현 hedging (HIGH, novelty claim 보호)

본문 잘못된 표기: "Hilbert curve 의 vector cardinality estimation 적용이 최초", "단일 테이블 사각지대 최초 발견"

Hedge 권장: lit review 검색 범위 명시 없이 "최초" 단어는 reviewer 추궁 위험.

정정된 표기: - "본 연구가 알기로 처음으로 시도 한 사례" - "IEEE Xplore + ACM DL + Google Scholar 검색 범위에서 발견되지 않은 첫 본격 비교" - "Exquitor 원논문 본문에 명시되지 않은 사각지대"

발표 시 "최초" 표현을 사용하지 않고 "본 연구가 알기로 처음" 으로 통일.

● H8: Q4.2 "n=6000" 정정 (MID)

본문 잘못된 표기: Q4.2 의 "n = 6000 측정에서는"

raw 정확: 8 지표 × 600 셀 = 4800 또는 단순 600 셀.

정정된 표기: "n = 600 셀 (또는 8 지표 × 600 = 4800 ρ값) 측정에서는"

● H9: Q12.3 격차 수치 raw 출처 caveat (MID)

본문 인용: "DEEP 1M s=0.300 (격차 2.4 %p), s=0.100 (격차 2.5 %p)"

raw 검증: 이 값들은 `8m_gradient_full.log` 의 1M-RAND $s=0.1$, $s=0.3$ 측정에서 산출된 *RAND mean* 과 KM mean 의 차이로, *raw* 보존 되어 있으나 보고서 표 2 에는 직접 인용되지 않음. 발표 시 출처 명시 권장:

정정된 답변 (Q12.3 보강):

"DEEP 1M 의 mid-selectivity ($s=0.100$, 0.300) 격차 ($2.5 / 2.4$ %p) 는 `8m_gradient_full.log` 의 1M 측정 raw 에서 산출되며, 보고서 표 2 의 직접 인용 외 raw json 의 보충 측정값입니다. 본격 보고서 본문 통합은 최종 보고서 (6/11) 단계에서 진행됩니다."

● H10: 리허설 일정 정정 (Priority 1)

본문 모순: Q18.4 의 "4/24, 4/26 사전 리허설" (이미 지난 시점) vs 부록 E 의 "4/29 사전 리허설 1 회".

현실 시점 반영: 4/27 22:00 작성 시점 기준 4/24 / 4/26 는 *과거*. 4/29 가 *유일한 미래 리허설*.

정정된 표기: - Q18.4: "4/24 / 4/26 의 사전 리허설 2 회 완료 + 4/29 최종 리허설 1 회 예정" - 부록 E: "4/29 최종 리허설 (발표 전 24 시간)"

● H11: CLAUDE.md 4/28 표기 정정 (외부 동기화 권고)

CLAUDE.md 본문: "| 4/28 | 중간발표 + 중간보고서 제출 | ■ ← 다음 마감 |"

현실: 4/28 = 제출 마감 (LearnUs PDF 업로드), 4/30 = 발표일 (인중 A428).

정정 권고 (사용자 또는 팀원이 CLAUDE.md 직접 수정):

| 4/28 23:59 | 중간보고서·발표 PDF 제출 (LearnUs) | ■ |
| 4/30 19:00 | 중간발표 (인중 A428, 강재현) | ■ |

cheat sheet 본문은 이미 4/30 으로 통일.

부록 H — 추가 적대적 질문 25 개 (영역별 분포)

Opus 적대적 검증으로 식별된 cheat sheet 본문 30 개 외 추가 25 개 질문. 발표 직전 빠르게 훑어보고 답변 가능성 만 mental note 로 점검.

연구 동기 (3 개)

- AH1: "Exqutor 가 단 3 개월 전 (2025) 발표된 논문인데, 후속 연구 없이 캡스톤 주제 잡은 정당성?" → "최신 시스템의 빈자리 발견 + 박성원 멘토 contact 가능 + 학부 캡스톤의 *adaptive 학습 가치*"
- AH2: "단일 테이블이 실무 핵심이라는 *production RAG 시스템 워크로드 통계* 근거?" → "ANN-Benchmarks 의 표준 evaluation 형태 + RAG 의 retrieval step 정의상 single-table"
- AH3: "이미지 검색·추천·RAG 셋의 *selectivity 분포 같은가?*" → "범위는 다르나 *single-table range query* 형태는 동일, 본 연구의 framework 가 셋 모두에 적용 가능"

방법론적 결함 (4 개)

- AH4: "베르누이 효과가 *unit 변경* 인가 *sample size 효과* 인가?" → KQ1 답변 사용
- AH5: "k-means K=20 의 *outlier 끌린 cluster* 처리? Robust k-means (k-medoids) 시도?" → "outlier 영향은 RQ3 의 F (MiniBatch K-means) 의 incremental update 로 다룸. k-medoids 는 1M 데이터 비용 비현실"
- AH6: "Q-error *median* 이 unbiased 가 아닌데, 왜 mean 대신 median 으로 평가?" → "lognormal Q-error 분포에서 outlier robust 한 median 이 표준. raw json 에 mean / median 둘 다 보존"
- AH7: "RANDOM20 control 의 *비례 배분 fair* 한가? 무작위 분할은 expected stratum size 가 다름" → "정확한 지적. 본 연구는 stratum size 를 *expected proportion* 으로 비례 배분하므로 KM20 / RANDOM20 동일 weighting. partition assignment 의 stratum size variance 는 KM20 / RANDOM20 모두 발생"

통계적 결함 (5 개)

- AH8: "paired Wilcoxon 의 *대립가설 one-sided / two-sided?*" → "본 연구는 one-sided alternative='less' (**STRAT < BERN** 가설)"
- AH9: "5-seed 의 *seed 간 독립성 가정* 보장?" → "각 seed 가 독립적 random number generator state 를 가지므로 sample 자체는 독립. query 자체는 같은 100 개로 controlled"
- AH10: "9.6 % 개선의 *95 % CI 자체?*" → H4 정정 답변 사용
- AH11: "s=0.001 영역에서 sample fraction 0.0385 % — 추정 의미 있나?" → "anomaly_analysis.md 에 sample_size = 385 의 분해능 한계 명시. s=0.001 영역은 *통계적 추정 불가능 영역* 으로 분류"
- AH12: "Two-Level *Level 1 vs Level 2 직교* 보장? 상호작용?" → "RANDOM20 control 의 stratum partition 자체가 spatial structure-free 이므로 Level 1 효과만 분리 측정 가능. Level 1 × Level 2 interaction 은 *positive correlation* 가능성, W6 의 ANOVA-style 분해로 검증 예정"

실험 설계 결함 (3 개)

- AH13: "100 개 query 어떻게 생성?" → KQ2 답변 사용
- AH14: "SIFT / DEEP 8M 측정의 *3 selectivity* 만 한 이유 = 시간 부족?" → "정확. cross-dataset anchor 는 s=0.500 으로 합의되어 있고, 다른 selectivity 는 W5 보충 실험"

- **AH15:** "5-seed 가 0.1, 0.2, 0.3, 0.4, 0.5 등간격 — random 아닌 systematic" → "정확. 등간격이지만 PostgreSQL 의 `setseed` 가 hash-based PRNG state 를 생성하므로 실제 sample 은 독립. 본격 random seed (Python uniform) 는 W6 보충"

Generalization 한계 (3 개)

- **AH16:** "SIFT / DEEP 모두 *image embedding* — modality 일반화 부족?" → "정확. text (wiki 768d) 가 W5 보충에 포함되며, 본 보고서 시점은 *image embedding cross-dataset* 으로 한정"
- **AH17:** "wiki 768d 측정 안 한 시점에서 *방향 일관할 것* hypothesis 만으로 generalization 주장 자격?" → "정확. 본 보고서의 *generalization claim* 은 image embedding 까지로 conservative 하게 한정"
- **AH18:** "PG 16.9 만 측정 — version-specific 가능성?" → "정확. PG 14, 15, 17 의 옵티마이저 차이는 본 연구 범위 밖이며, 후속 연구의 영역"

Novelty 부족 (3 개)

- **AH19:** "Selinger 1979 이후 stratified sampling 적용 사례가 정말 없는가?" → **H7 hedging 답변 사용** ("본 연구가 알기로 첫 본격 적용")
- **AH20:** "Hilbert curve 최초 적용 — 측정 안 한 상태에서 최초 단언은 공허?" → "정확. 측정 후 결과가 최초 적용의 학술 가치를 결정. 본 보고서는 적용 시도 까지를 명시"
- **AH21:** "본 연구의 KM20 partition + Horvitz-Thompson estimator 가 *Faiss IVF* 의 변형과 본질적으로 다른가?" → "Faiss IVF 는 nearest neighbor 검색의 inverted index 이고, KM20 은 cardinality estimation of stratification. *partition* 사용 자체는 비슷하나 목적과 *estimator* 가 다름. RQ3 에서 IVF-based estimator 와의 직접 비교는 후속 연구"

Reproducibility 위협 (2 개)

- **AH22:** "GitHub repo 의 *DEEP 1B / SIFT pre-processed sub-sample* 다운로드 / 생성 방법 명시?" → "raw `phase6_native_paired.json` + `query_pool.parquet` 보존. 데이터 source URL + 전처리 script 명시는 README 보강 권고"
- **AH23:** "동일 GPU/CPU 가 아니면 mini-batch k-means 결과 결정론적 보장?" → "정확. BLAS 라이브러리 + CPU instruction 차이로 *bit-exact* 재현 불가. 통계적 재현은 보장 (inertia 0.692 ± 0.01)"

임팩트 약점 (3 개)

- **AH24:** "9.6 % 의 plan 변경 임계점 근처 query 비율?" → **KQ5 답변 사용** ("W6 EXPLAIN ANALYZE 측정 예정")
- **AH25:** "stratum_id 컬럼의 *storage overhead* + *INSERT/UPDATE 재할당 비용*?" → "1M 행에 int4 stratum_id = 4MB 추가 (전체 0.1 % 미만). INSERT 시 $O(d \times K) = O(96 \times 20) \approx 2000$ distance 계산. 정량 측정은 RQ3 의 dynamic 환경 분석에 포함"

- AH26: "real-world deployment 시나리오?" → "1 차 시나리오: PostgreSQL + pgvector 기반 RAG 시스템의 retrieval step. opt-in mode 로 추가, 기존 동작 깨지 않음. Production 배포 검증은 후속 연구"

학술 contribution & 팀 (2 개)

- AH27: "본 연구 4 가지 기여 중 SIGMOD/VLDB short paper reviewer 통과 수준은?" → "(2) Two-Level decomposition framework + (4) Recovery Rate metric 두 갈래가 short paper 가치. (1) 사각지대 + (3) cluster skewness 인과 관계는 supporting evidence"
- AH28: "조현빈 단일 의존 = 분담 실패?" → "코드·실험·문서는 조현빈 권한, 통계·작도·RQ3 설계는 이동욱 권한, 발표·리허설은 강재현 권한, 일정·자문은 박세은 권한. 상호 보완 분담이며 단일 의존 아님"

부록 F + G + H 의 우선순위: 1. F (KILLER QUESTIONS 5 개) 외워서 자신감 톤 답변 2. G (CRITICAL/HIGH 정정) 본문보다 우선 3. H (추가 적대적 25 개) mental note 로 점검

발표자 (강재현) 가 부록 F 만 외워도 5 분 Q&A 의 핵심 5 개 질문 방어 가능. 부록 G 는 본문 정정이고, 부록 H 는 최악의 경우 대비 추가 보강.

본 ultrareview 는 4/27 22:00 KST 기준 Opus Sonnet 4 개 병렬 서브에이전트 (수치 정합성·적대적 질문·답변 일관성·누락 영역) 의 통합 결과로 작성되었으며, 발표 직전 (4/29 또는 4/30 오전) 마지막 점검 시 본 부록 F + G + H 를 우선 정독한다.