
속도는 벡터

벡터 분석 쿼리의 카디널리티 추정을 위한
분포 인지 표본 선택

박세은 · 강재현 · 조현빈 · 이동욱

속도는 벡터

박광현 교수

연세대학교 · 지도교수

왜 카디널리티 추정이 중요한가



조건을 만족하는 행의 수를 잘못 추정하면,
데이터베이스가 **잘못된 실행 계획**을 세운다.

기존 벡터 데이터베이스들은 이 값을 데이터와 무관하게 **고정 비율로** 어림하고 있었다.

논문이 푼 것, 우리가 바꾼 것

논문 Exqutor

인덱스가 없을 때
데이터에서 무작위로
표본을 뽑아 추정

추정 알고리즘은 우리가 그대로 인정한다.



표본 뽑는
방식만 교체

우리 연구

표본을 뽑던 그 자리에
데이터 분포를
반영한 표본

추정 알고리즘은 손대지 않는다.

분포를 반영해 표본을 뽑는 세 단계

1

분포 파악

데이터를 비슷한 것끼리 **20개 그룹**으로 나눈다



2

표본 추출

각 그룹에서 **골고루** 표본을 뽑는다



3

결합

논문 추정값과 우리 추정값을 **평균** 낸다

추정 알고리즘과 표본 크기 보정 과정은 **논문 그대로** 둔다.

세 가지 방식을 같은 조건으로 비교했다

비교의 기준

기존 방식

논문 그대로의 무작위 표본 추출로 카디널리티를 추정.

우리 표본만 사용

완전 대체

무작위 표본을 우리 표본으로 통째 교체해 추정.

두 추정값 평균

결합

논문 추정값과 우리 추정값을 평균 내어 함께 사용.


한 번의 측정에서 세 방식을 똑같은 데이터·똑같은 조건으로 동시에 비교했다 — 그래서 차이가 방식 때문임을 분명히 말할 수 있다.

무엇을, 어떤 조건으로 측정했는가


데이터셋	8종 · 96~864 차원	차원과 도메인을 폭넓게 — 작은 차원부터 큰 차원까지
데이터 규모	10만 · 100만 · 1000만	데이터가 커질 때 효과가 어떻게 변하는지 보려고
선택도	0.1% · 1% · 10%	쿼리 조건이 좁을 때부터 넓을 때까지
표본 선택 방법	16가지	7가지 접근을 고루 대표하도록
계층 수	10 · 20 · 30 개	논문 기본값 20을 중심으로 적을 때·많을 때

측정한 데이터셋

단일 벡터 데이터셋



다중 벡터 데이터셋




96차원부터 864차원까지 — 단일 벡터와 다중 벡터를 아우른다.

데이터가 한쪽에 쏠려 있을 때, 무작위는 쏠린 곳만 뽑는다


기존 방식 · 무작위

표본이 쏠린 영역에 집중



분포 인지 표본 추출

전 영역에서 골고루



분포를 반영하면 드문 영역까지 표본에 들어와 추정이 정확해진다.


16가지 방법, 7가지 접근

공간 곡선4 Hilbert 곡선 · Z-order 곡선 · 고차원 Hilbert 곡선 · IVF 클러스터링	차원 축소4 주성분 분석 · 독립성분 분석 · 랜덤 SVD · 희소 랜덤 투영
통계적 증화2 누적 제공근 증화 · Lavallée–Hidiroglou 증화	양자화2 RaBitQ 양자화 · 다차원 히스토그램
클러스터링2 미니배치 K-means · 가우시안 혼합 모델	스트리밍 표본 추출1 가중 표본 추출
정보 이론 기반1 HyperLogLog	

다음 네 장에서 일곱 가지 접근이 각각 어떻게 분포를 반영하는지 그림으로 본다.

공간 곡선 – 고차원을 한 줄로 펼친다

2차원 평면의 점





곡선이 점을 차례로 잇는다

한 줄로 펼친 뒤 균등하게 자른다



가까운 점은 펼친 뒤에도 가깝게 유지된다

차원 축소 – 핵심 축으로 압축한다




통계적 층화 · 양자화 – 값의 구간 · 코드로 나눈다

통계적 층화

같은 양씩 구간을 자른다

각 구간의 면적이 같도록



설문조사 표본설계에서 온 고전 기법

누적 제공근 층화 · Lavallée-Hidiroglou 층화

양자화

벡터를 짧은 코드로 바꾼다

$v = (3.2, -1.8, 0.5, \dots)$

부호 → 0 / 1 코드

1 0 1 0 1 1 0



101

100

011

...


같은 코드를 가진 데이터끼리 묶는다

RaBitQ 양자화 · 다차원 히스토그램

묶거나, 한 번 훑어 요약한다

클러스터링


비슷한 것끼리 묶기



미니배치 K-means · GMM

스트리밍 표본 추출


흘러가며 골라낸다



가중 표본 추출

정보 이론 기반

해시로 요약한다



HyperLogLog

클러스터링 계열은 측정에서 다소 불안정했다 (뒤에서 결과로 다룸).

결합 방식이 추정 오차를 89.1%에서 줄였다

89.1%

결합 방식이 기존 방식보다 추정 오차를 줄인 비율

1508번의 측정 중 1344번 더 정확
추정 오차 중앙값 약 **4.4%** 감소

신호의 견고함

통계적으로 의미 있는 개선

65%

개선 폭이 큰 경우

72%

완전 대체는 불안정하다 – 결합이 답이다

완전 대체

35.2%

기존 방식보다 나은 경우

표본을 우리 것으로 **통째 바꾸면** 우리 방법이 강할 때만 좋고, 약할 때 크게 나빠진다.

두 추정값을 **결합**하면 논문 방식이 안전망 역할을 해 안정적으로 개선된다.

결합

89.1%


효과가 없을 수 있는 완전 대체를 일부러 측정해 – 개선의 원천이 **결합 자체**에 있음을 확인.

16가지 방법 중 14가지가 기존 방식을 안정적으로 이긴다

14 / 16

모든 조건에서 안정적으로 우월한 방법

공간 곡선·차원 축소·층화 계열이 강하다.
클러스터링 계열만 약해 권장에서 제외.



선택도가 높을수록 더 안정적으로 개선된다

선택도는 전체 데이터 중
조건을 만족하는 비율을 말한다.

조건에 맞는 데이터가 많을수록 분포를 반영한 표본의 이점이 **더 분명하게** 드러난다.

선택도 낮음



83.3%

선택도 중간



87.6%

선택도 높음



97.5%

결합 방식이 기존 방식을 이긴 비율

단일 벡터와 다중 벡터 모두에서 일관되게 우월

단일 벡터


89.1%

다중 벡터

89.2%

한 행에 벡터가 하나든 여럿이든, **결합 방식이 기존 방식을 이긴 비율**이 거의 같다 — 효과가 흔들리지 않는다.

데이터를 20개 계층으로 나눌 때가 가장 좋다




계층이 너무 적으면 쏠린 분포를 충분히 나누지 못한다.

계층이 너무 많으면 계층마다 표본이 얇아진다.

20개가 균형점 — 논문이 기본값으로 쓴 값과도 일치한다.

결합 방식이 기존 방식을 이긴 비율

정확도와 분포 파악 시간의 균형



균형

가중 표본 추출

정확도와 속도의 균형점

가장 빠름

희소 랜덤 투영

분포 파악이 가장 빠름

최고 정확도

Hilbert 곡선

정확도 최고, 파악은 느림

데이터 유형을 보고 방법을 자동으로 고른다

1 데이터가 들어온다



2 데이터 유형 판별

크기 · 구조 · 차원



3 유형에 맞는 표본 선택 방법 자동 선택



4 결합 방식으로 카디널리티 추정

사람이 매번
방법을 고르지 않고,
데이터 유형에 따라
자동으로.

측정 결과를 종합해 만든 우리의 제안 — 추정 알고리즘은 그대로 두고, 표본 선택 방법만 데이터에 맞춰 바꾼다.

결론

1

분포를 반영한 표본 선택이
추정 오차를 **89.1%**에서 줄였다



2

통째 교체는 불안정 –
두 추정값의 결합이 답이다



3

선택도·데이터 구조·계층 수
모든 조건에서 일관되게 우월



4

데이터 유형에 따라
방법을 자동으로 고르는 방식을 제안



추정 알고리즘은 그대로 두고, 표본을 뽑는 방식만 바꾸는 것만으로 추정이 더 정확해진다.

한계와 다음 단계

정직하게 남기는 점

- 검증 중 비교 기준의 측정 방식에 작은 문제를 발견해 바로잡았다.
개선 수치가 더 보수적이 됐지만, **더 엄정한 기준** 위의 값이 됐다.
- 가장 큰 규모의 다중 벡터 데이터는 **일부 조합만** 측정했다.

다음 단계

6월 11일

최종 보고서 — 전체 결과 상세

엔진 일반화 검증

**PostgreSQL · DuckDB에서도
같은 효과가 나는지 확인**

감사합니다

질의응답